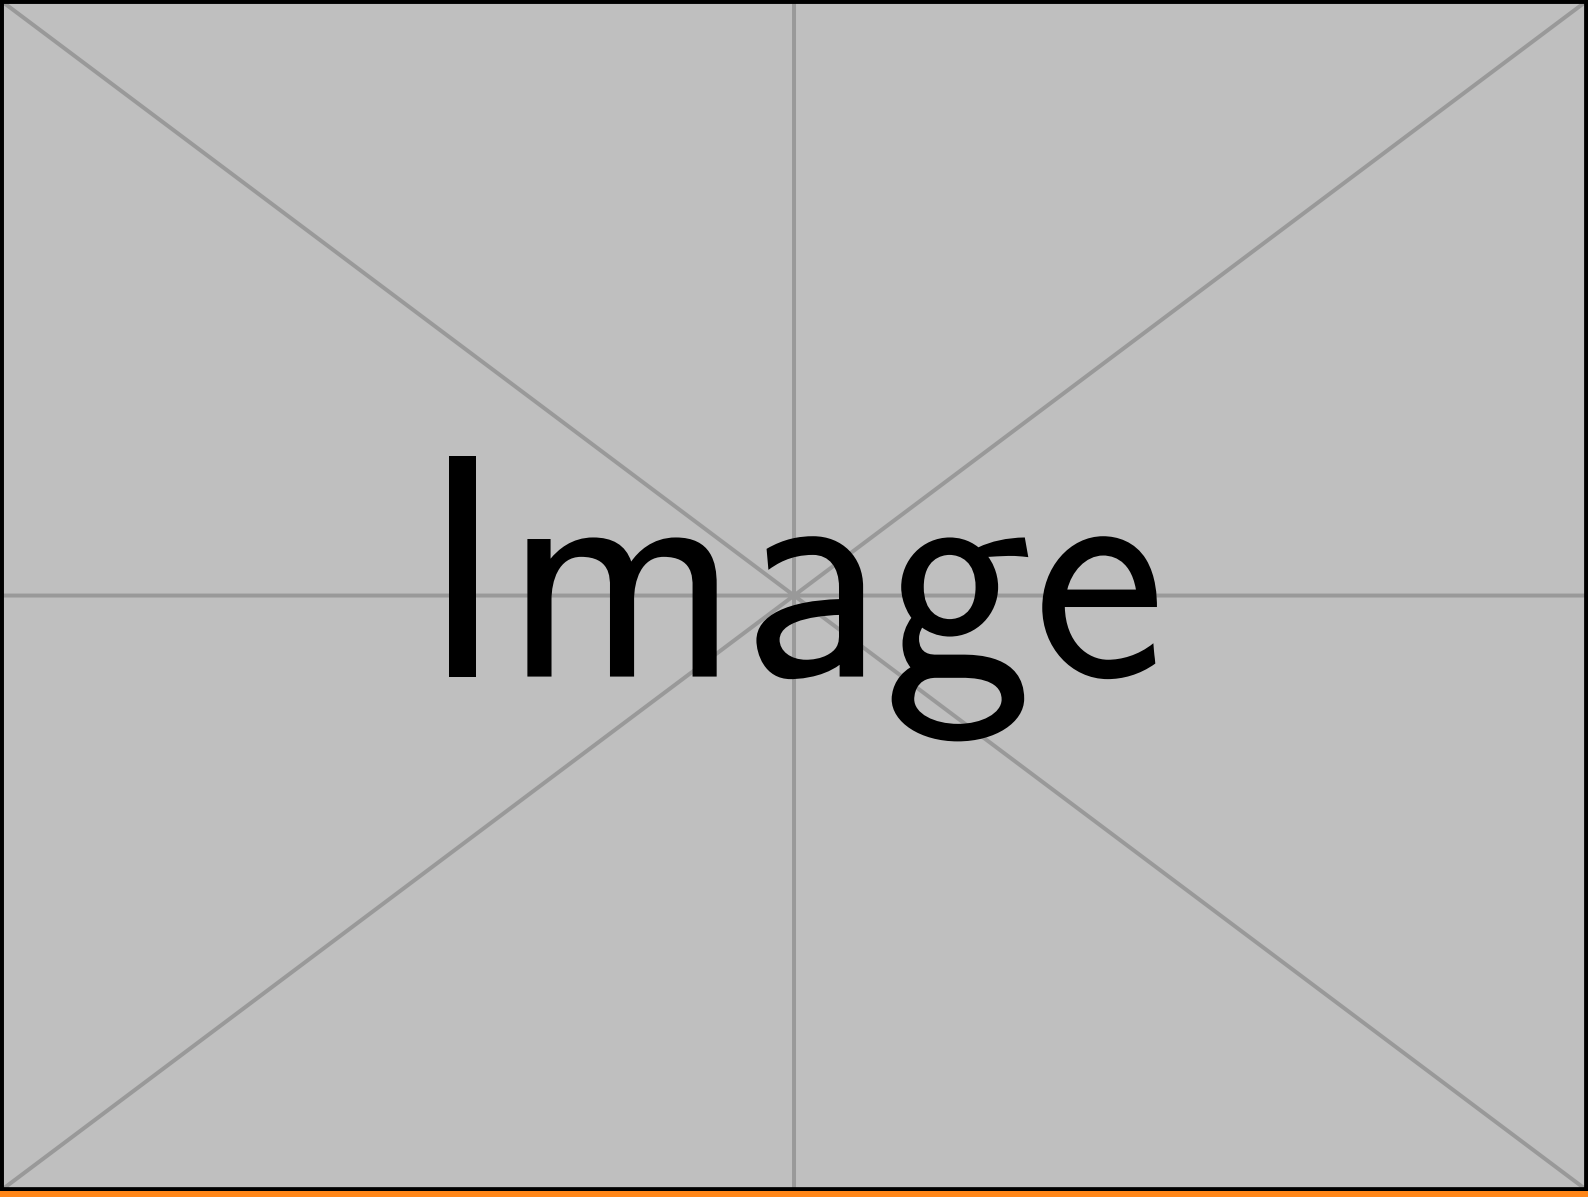


固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

目录

第一章 固定测度的 Token 级优化问题 **1**

1.1 外层同步与内层对象 1
1.2 原始 mirror 子问题的 Gibbs 解 3
1.3 Reward 中心化与回归残差 3
1.4 参数化策略的投影 4

第二章 统一的 token-level Mirror Descent 与 OPD 实例化 **5**

2.1 共同的 mirror 子问题与精确解 5
2.2 从镜像最优性方程到四种可训练目标 6
2.3 四种 inner 的统一推导 8
2.4 镜像系数、数值步长与内层收敛的精确关系 15
2.5 OPD 特化：逐 token reward 与两种信息访问模式 17
2.6 OPD 的七种可运行算法与统一 outer–inner pipeline 26

第三章 KL 估计的统一残差框架 **34**

3.1 目标、采样测度与微分规则 34
3.2 统一构造：精确积分加残差抽样 35
3.3 同一分区上的 KL 粗化与梯度残差 39
3.4 KL 数值：从确定性代理到无偏残差校正 42
3.5 KL 梯度：相同积分下的不同控制 46
3.6 双控制族：事件间方差与尾部内部方差 47
3.7 自动微分：数值与梯度的分别实现 50
3.8 采样设计：on-policy、尾部条件采样与旧 rollout 53
3.9 OPD 使用方式与误差传递 56
3.10 ResOPD 实现与论文实验 59

第四章 Outer 动力学与有限 Inner 误差 **61**

4.1 Hard sync 的精确几何与稳定区间 61
4.2 PMD-Mean 的逐 prefix OPD 动力学 66
4.3 有限 inner 更新的误差 75
4.4 有限 inner 与扰动 Outer 递推 76
4.5 Soft sync 的耦合动力学 80
4.6 访问测度固定的含义 81
4.7 Hard sync 的有限词表数值核验 81

第五章 可枚举 Token 实验与实现边界 **84**

5.1 实验设置 84
5.2 结果 85
5.3 正式 LLM 实验前必须通过的检查 85
5.4 真实语言模型上的四种 Top-J 对照 86

第一章 固定测度的 Token 级优化问题

1.1 外层同步与内层对象

词表记为 $\mathcal{V}$，prompt为 x，生成序列为 $y_{1:H}$，第 t 个 token 之前的 prefix 为 $s_t = (x, y_{<t})$。第 k 轮 outer 开始时的冻结 anchor 为 π_k，本轮第 n 次 inner 更新的 student 为

$$\pi_{k,n}(a \mid s) = \pi_{\theta_{k,n}}(a \mid s), \qquad \pi_{k,0} = \pi_k. \tag{1.1}$$

教师统一记为 π_T，在本轮 inner 内冻结。d_k 表示由 π_k rollout 诱导的 prefix 访问测度，$\widehat{d}_k$ 表示当前 rollout batch 的经验测度。inner 固定 prefix batch、anchor 和教师，只更新 student 参数。

1.1.1 变长轨迹的访问测度与梯度累积

固定第 k 轮 rollout 分布。令轨迹 τ 的有效 response 长度为 $H(\tau)$，包含生成的 EOS，排除 prompt 和 padding；在预算终止时保留实际生成的 token。假定 $0 < \mathbb{E}H < \infty$。本书明确采用归一化的 token 访问测度

$$d_k(A) = \frac{\mathbb{E}_{\tau\sim\pi_k}[\sum_{t=1}^{H(\tau)} \mathbf{1}\{s_t \in A\}]}{\mathbb{E}H}. \tag{1.2}$$

这里 prompt 也按训练数据分布采样。长轨迹贡献更多被访问的 prefix，不是先将每条轨迹的总贡献归一化为一。固定 rollout 后，长度和测度均不对 inner 参数求导。

令每个有效位置的损失或 score surrogate 为 $\ell_\theta(s, a)$。独立 rollout 的经验目标及梯度为

$$N_k = \sum_{i=1}^{B} H_i, \qquad \widehat{L}_k^{\mathrm{tok}}(\theta) = \frac{1}{N_k} \sum_{i=1}^{B} \sum_{t=1}^{H_i} \ell_\theta(s_{i,t}, a_{i,t}), \tag{1.3}$$

$$\nabla \widehat{L}_k^{\mathrm{tok}} = \frac{1}{N_k} \sum_{i,t} \nabla \ell_\theta(s_{i,t}, a_{i,t}). \tag{1.4}$$

总体目标为 $\mathbb{E}_{d_k,\pi_k}\ell_\theta$。有限 batch 的随机分母使上述比率估计量一般不是总体目标的严格无偏估计；在独立轨迹和可积条件下，分子、分母的样本均值分别收敛，其比值一致收敛到总体目标。token 在同一轨迹内相关，因此不能把 N_k 个位置视为独立统计样本来计算置信区间。

命题 1.1 (访问测度与条件动作分布)

上述 token 访问测度对应的总体 prefix–action 联合分布可分解为 $d_k(s)\pi_k(a \mid s)$。对每条轨迹额外乘以 $1/H(\tau)$ 的序列平均，一般改变这一条件动作分布。

证明 在时刻 t 产生动作之前，事件 $\{t \le H\}$ 和 prefix s_t 已由历史决定。因此对任意可积函数 h，条件期望给出

$$\mathbb{E}\sum_{t\ge1} \mathbf{1}\{t \le H\} h(s_t, a_t) = \mathbb{E}\sum_{t\ge1} \mathbf{1}\{t \le H\} \mathbb{E}_{a\sim\pi_k(\cdot|s_t)} h(s_t, a) \tag{1.5}$$

$$= \mathbb{E}H \; \mathbb{E}_{s\sim d_k, a\sim\pi_k} h(s, a). \tag{1.6}$$

除以 $\mathbb{E}H$ 得到所述分解。预算终止只改变历史可测的存活事件，不改变该条件期望步骤。

对于序列权重 $1/H$，长度取决于当前及未来生成动作，不能把该权重从动作条件期望中提出。举例：初始 prefix 下两个动作概率各为 $1/2$；动作 a 立即 EOS，长度为一；动作 b 后确定生成一个 EOS，长度为二。按轨迹长度归一化后，初始位置的联合质量分别为 $1/2$ 和 $1/4$，故给定初始 prefix 的动作概率变成 $2/3$ 与 $1/3$，不同于原策略。

相比之下，先在每条序列内平均、再在 batch 平均得到

$$\widehat{L}_k^{\mathrm{seq}} = \frac{1}{B} \sum_i \frac{1}{H_i} \sum_t \ell_\theta(s_{i,t}, a_{i,t}). \tag{1.7}$$

同一 token 在两个目标中的权重之比为 $(1/(BH_i))/(1/N_k) = \bar{H}/H_i$。例如两条轨迹长度为十和一百，token 平均

给两条轨迹的总质量分别为 1/11 与 10/11；序列平均给它们各 1/2。这两种目标都可以被定义，但不能在不修改访问测度、条件动作分布和梯度推导的情况下互换。若每个 prefix 可独立表示、使用完整条件期望且支持集相同，只改变正的 prefix 权重不改变逐 prefix 的精确 Gibbs 解；共享参数投影、有限样本和上述依赖未来长度的权重没有这一等价保证。

不除以长度的 batch 序列和 $B^{-1}\sum_i\sum_t \ell$，则恰等于 $\bar{H}\widehat{L}_k^{\mathrm{tok}}$。在同一冻结 batch 内它是正的常数倍，最优点不变，但普通梯度尺度、裁剪行为及跨 outer 的相对尺度不同；不能声称 Adam 和裁剪后轨迹也相同。

命题 1.2 (micro-batch 划分不变性)

将本轮有效位置划分为任意不交 micro-batch $\mathcal{B}_m$。若每次 backward 使用 $L_m = N_k^{-1}\sum_{(i,t)\in\mathcal{B}_m}\ell_{i,t}$，只在所有 backward 完成后裁剪并执行一次 optimizer step，则累积梯度与全 batch 的梯度相同，忽略浮点求和次序误差。

证明 梯度对有限和线性，且冻结分母 N_k 与 inner 参数无关，故

$$\sum_m \nabla L_m = \frac{1}{N_k}\sum_m\sum_{(i,t)\in\mathcal{B}_m}\nabla\ell_{i,t} = \nabla\widehat{L}_k^{\mathrm{tok}}. \tag{1.8}$$

若把每个 L_m 改为各自 token 均值后直接累加，每个位置的权重变成 $1/|\mathcal{B}_m|$，不再是 $1/N_k$。只有再乘 $|\mathcal{B}_m|/N_k$ 才恢复相同梯度。若每个 micro-batch 单独裁剪，非线性的裁剪映射也不能穿过求和。

生产实现采用 `loss_agg_mode=token-mean`，在任何 loss 聚合之前填入当前全 batch 的有效 response token 数。数据并行若采用梯度平均，每个 rank 的局部和还需乘以数据并行 rank 数，使跨 rank 平均后恢复全局 token 均值。每份 micro-batch 不能使用自身长度或上一 outer 的 token 数作为分母。

全篇使用同一组 log-ratio 和 KL 记号：

$$U_{k,n}(s,a) \coloneqq \log\frac{\pi_{k,n}(a\mid s)}{\pi_k(a\mid s)}, \tag{1.9}$$

$$r_k(s,a) \coloneqq \log\frac{\pi_T(a\mid s)}{\pi_k(a\mid s)}, \tag{1.10}$$

$$\mathcal{K}_k^T(s) \coloneqq \mathrm{KL}(\pi_k(\cdot\mid s)\|\pi_T(\cdot\mid s)), \tag{1.11}$$

$$\mathcal{K}_{k,n}^S(s) \coloneqq \mathrm{KL}(\pi_k(\cdot\mid s)\|\pi_{k,n}(\cdot\mid s)). \tag{1.12}$$

因此 $\mathbb{E}_{\pi_k}[r_k\mid s] = -\mathcal{K}_k^T(s)$，$\mathbb{E}_{\pi_k}[U_{k,n}\mid s] = -\mathcal{K}_{k,n}^S(s)$。前者是冻结 teacher reward 的均值，后者随 student 更新变化。通用 mirror 问题中的信号记为 f，其冻结中心化 target 为 $G_k = \eta(f - \mathbb{E}_{\pi_k}[f\mid s])$。OPD 实例化时取 $f = r_k$，因此

$$G_k(s,a) \coloneqq \eta\big(r_k(s,a) + \mathcal{K}_k^T(s)\big), \qquad \mathbb{E}_{\pi_k}[G_k\mid s] = 0. \tag{1.13}$$

score 向量记为 $\psi_{k,n}(s,a) = \nabla_{\theta_{k,n}}\log\pi_{k,n}(a\mid s)$，其 anchor 条件均值为 $\bar{\psi}_{k,n}(s) = \mathbb{E}_{\pi_k}[\psi_{k,n}\mid s]$。

镜像系数为 $\eta > 0$，inner 学习率为 $\alpha_{k,n}$。outer 总步数为 K_{out}，每轮 inner 步数为 N，rollout batch 大小为 B，同一 prefix 的辅助 action 样本数为 m，保留的头部 token 数为 J。展开截断阶数用 L，避免与头部大小混用。所有损失统一最小化，算法使用其梯度 $g_{k,n} = \nabla_{\theta_{k,n}}\mathcal{L}$ 执行下降。

同步在 inner 结束后进行。hard sync 取 $\pi_{k+1} = \pi_{k,N}$；概率空间的 soft sync 取

$$\pi_{k+1} = (1-\rho)\pi_k + \rho\pi_{k,N}, \qquad \rho\in(0,1]. \tag{1.14}$$

参数 EMA 是这个概率混合映射的实现近似，需要另行说明。$\lambda_k(s)$ 只表示 PMD-Mean 的归一化乘子，γ 表示自然梯度阻尼。student/anchor importance ratio 记为 $\omega_{k,n} = \pi_{k,n}/\pi_k$，K4 的 score surrogate 记为 $c_{k,n} = \pi_{k,n}/\mathrm{sg}(\pi_{k,n})$，其中 sg 表示停止梯度。

我们研究的 inner 子问题是

$$\max_{p\in\Delta(\mathcal{V})}\mathcal{J}_{k,s}(p) = \mathbb{E}_{a\sim p}[r_k(s,a)] - \frac{1}{\eta}\mathrm{KL}(p\|\pi_k), \qquad \eta>0. \tag{1.15}$$

这里的 p 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 s 不随 inner

更新；它不意味着优化变量 p 必须等于采样分布 π_k。

1.2 原始 mirror 子问题的 Gibbs 解

令

$$Z_k(s) = \sum_{a \in \mathcal{V}} \pi_k(a \mid s) \exp(\eta r_k(s,a)).$$

由于 $r_k = \log \pi_T - \log \pi_k$，有

$$Z_k(s) = \sum_a \pi_k(a \mid s)^{1-\eta} \pi_T(a \mid s)^{\eta}. \tag{1.16}$$

定理 1.1 (Token mirror target)

若有限词表上 $\pi_k(a \mid s) > 0$ 且 $\pi_T(a \mid s) > 0$ 对每个 action 成立，则式 (1.15) 的唯一最大点为

$$\pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \frac{\pi_k(a \mid s) \exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\pi_k(a \mid s)^{1-\eta} \pi_T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.17}$$

并且对任意 p，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta} \log Z_k(s) - \frac{1}{\eta} \mathrm{KL}(p \| \pi_k^{\star,\mathrm{Gibbs}}). \tag{1.18}$$

♡

证明 由式 (1.17)，

$$\log \pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \log \pi_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\begin{aligned} \mathrm{KL}(p \| \pi_k^{\star,\mathrm{Gibbs}}) &= \sum_a p(a \mid s) \left[\log \frac{p(a \mid s)}{\pi_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s) \right] \\ &= \mathrm{KL}(p \| \pi_k) - \eta \mathbb{E}_p[r_k] + \log Z_k(s). \end{aligned}$$

移项得到式 (1.18)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时为零，所以最大点唯一。 □

推论 1.1 (几何插值与极限)

当 $\eta \to 0^+$ 时 $\pi_k^{\star,\mathrm{Gibbs}} \to \pi_k$；当 $\eta = 1$ 时 $\pi_k^{\star,\mathrm{Gibbs}} = \pi_T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log \pi_k^{\star,\mathrm{Gibbs}} = (1-\eta) \log \pi_k + \eta \log \pi_T - \log Z_k.$$

因此 η 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

♡

1.3 Reward 中心化与回归残差

定义 $\bar{r}_k(s) = \mathbb{E}_{a \sim \pi_k}[r_k(s,a)] = -\mathcal{K}_k^T(s)$。将 reward 换成 $r_k - \bar{r}_k$ 后，配分函数为

$$\mathbb{E}_{\pi_k}[e^{\eta(r_k - \bar{r}_k)}] = e^{-\eta \bar{r}_k} Z_k.$$

分子和配分函数同乘一个 action 无关的常数，原始 mirror 问题的 Gibbs 解不变。下面的平方回归需要区分完整配分函数与均值近似。

三个 residual 全部采用 student 减 target 的方向：

$$R_{k,n}^{\mathrm{Part}}(s,a) := U_{k,n}(s,a) - \eta r_k(s,a) + \log Z_k(s), \tag{1.19}$$

$$R_{k,n}^{\mathrm{Mean}}(s,a) := U_{k,n}(s,a) - G_k(s,a), \tag{1.20}$$

$$R_{k,n}^{\mathrm{BPO}}(s,a) := U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}_{k,n}^S(s). \tag{1.21}$$

PMD-Part 的零残差对应 $\pi_{k,n} = \pi_k^{\star,\mathrm{Gibbs}}$。PMD-Mean 以 $\eta \bar{r}_k$ 近似 $\log Z_k$，仅中心化 reward。对非恒定 reward，由严格 Jensen 不等式有 $\mathbb{E}_{\pi_k}[e^{G_k}] > 1$，所以拟合值 $U = G_k$ 不满足概率归一化，最优残差不能为零。其总体最优

分布记为 $\pi_k^{\star,\mathrm{Mean}}$，由第二章的 Lambert-$W$ 解确定。

BPO 则中心化完整的 student–target residual。其 residual 均值为零，而 Mean 的 residual 均值为 $-\mathcal{K}_{k,n}^{S}$。这些定义直接区分两个目标，无需额外改变 residual 符号。

1.4 参数化策略的投影

实际神经网络只能表示参数化策略族。固定 prefix 测度 d_k 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{Part}}(\theta_{k,n}) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{1.22}$$

若模型在每个 history 上可以实现式 (1.17)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章沿用第一章的 outer–inner 记号：π_k 是冻结 anchor，$\pi_{k,n}$ 是当前 student，π_T 是 teacher，d_k 是冻结 prefix 访问测度。所有梯度均在 $\theta = \theta_{k,n}$ 处计算。以下先对一般冻结信号 f 推导，再取 OPD 信号 $f = r_k$。

2.1 共同的 mirror 子问题与精确解

定义 2.1 (Token-level mirror 子问题)

给定固定历史 s、token 信号 $f(s,a)$ 和 anchor π_k，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.1}$$

这里要求 $\eta > 0$；$\eta = 0$ 仅通过极限定义恒等 mirror 映射，不能直接代入含 $1/\eta$ 的训练损失。镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。同时定义配分函数

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\Big(p\Big\|\pi_k^{\star,\mathrm{Gibbs}}(\cdot \mid s)\Big). \tag{2.4}$$

证明 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时取零，因此最优解唯一。

定义 2.2 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

命题 2.1 (优势函数的 anchor 条件均值)

若 $f(s,a) = A^{\pi_k}(s,a)$，则对每个满足 $\pi_k(\cdot \mid s)$ 定义的历史，

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}[f(s,a) \mid s] = 0. \tag{2.5}$$

对于一般 OPD log-ratio 或 teacher score，条件均值需要计算或估计；PMD-Mean 与 BPO 使用相应的中心化 target。

证明 由 $A^{\pi_k}(s,a) = Q^{\pi_k}(s,a) - V^{\pi_k}(s)$ 以及 $V^{\pi_k}(s) = \mathbb{E}_{a\sim\pi_k}[Q^{\pi_k}(s,a) \mid s]$，有

$$\begin{aligned}\mathbb{E}_{\pi_k}[A^{\pi_k}(s,a) \mid s] &= \mathbb{E}_{\pi_k}[Q^{\pi_k}(s,a) \mid s] - V^{\pi_k}(s) \\ &= V^{\pi_k}(s) - V^{\pi_k}(s) = 0.\end{aligned}$$

命题 2.2 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.1) 的最优分布。

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是孤立的分布结论，而是一条可以被 inner optimizer 直接拟合的逐 token 方程。下面先把这条方程、平方损失和 BPO 的中心化残差逐步写出，再进入四种算法的实现。

2.2.1 镜像最优性方程与训练测度

把式(2.3) 移项，得到

$$\log \frac{\pi_k^{\star,\mathrm{Gibbs}}(a \mid s)}{\pi_k(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.6}$$

在参数化 inner 中，左侧由 $\pi_{k,n}$ 近似。因此定义镜像方程残差

$$R_{k,n}^{\mathrm{Part}}(s,a) \coloneqq \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s). \tag{2.7}$$

精确 mirror 解的条件是 $R_{k,n}^{\mathrm{Part}}(s,a) = 0$ 对所有有正概率的 (s,a) 成立。

为什么训练测度是 π_k 而不是 $\pi_{k,n}$？在第 k 个 outer step，rollout 已由冻结的 π_k 产生；我们要解决的是固定 anchor 的 mirror 子问题，而不是在 inner 过程中不断改变积分测度。于是参数化投影定义为

$$\|R_{k,n}^{\mathrm{Part}}\|_k^2 \coloneqq \mathbb{E}_{s\sim d_k}\mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{2.8}$$

这也是 on-policy rollout 下可直接估计的投影几何。若改用行为测度 β_k 采样，必须乘以冻结的 importance weight $\pi_k(a \mid s)/\beta_k(a \mid s)$，否则求解的是 $L_2(d_k\beta_k)$ 投影。

2.2.2 PMD-Part 与 PMD-Mean：从方程到平方损失

PMD-Part直接最小化式(2.7) 的平方。将 student log-ratio 和冻结 target 展开，得到

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \mathrm{sg}(\log Z_f(s))\right]^2. \tag{2.9}$$

其中 sg 表示停止梯度；π_k、f 和 Z_f 在本轮 inner 中都冻结。因为

$$\nabla_\theta \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} = \nabla_\theta \log \pi_{k,n}(a \mid s),$$

其梯度为

$$\nabla_\theta\mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_k,\pi_k}\left[\mathrm{sg}\left(\log \frac{\pi_{k,n}}{\pi_k} - \eta f + \log Z_f\right)\nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.10}$$

这说明 PMD-Part 是 anchor 测度下对完整 mirror log-ratio 的 L_2 投影，而不是把一个 teacher label 当作普通的 supervised token label。

PMD-Mean 使用原论文的均值近似，而不是对 student log-ratio 做条件中心化。使用第一章定义的冻结 target $G_k(s,a) = \eta(f(s,a) - \bar{f}_k(s))$。将完整 target 中的 $\log Z_f(s)$ 用 $\eta\bar{f}_k(s)$ 近似，得到

$$\mathcal{L}_{\text{Mean}}(\theta) = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}\left[\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta\big(f(s,a) - \bar{f}_k(s)\big)\right]^2. \tag{2.11}$$

这里的 reward center 在整个 inner loop 冻结；损失中没有 $\mathrm{KL}(\pi_k\|\pi_{k,n})$。定义 $R^{\text{Mean}}_{k,n} = U_{k,n} - G_k$，直接求导得到

$$\nabla_\theta\mathcal{L}_{\text{Mean}} = \mathbb{E}_{d_k,\pi_k}\left[(U_{k,n} - G_k)\nabla_\theta\log\pi_{k,n}(a \mid s)\right]. \tag{2.12}$$

均值近似遗漏的归一化修正是

$$\log Z_f(s) - \eta\bar{f}_k(s) = \log\mathbb{E}_{\pi_k}[e^{G_k(s,\cdot)} \mid s] \geq 0.$$

非恒定信号对应严格正值，此时 G_k 不满足指数归一化约束。因此 PMD-Mean 即使具有完整函数类和无限样本，也不恢复原始 Gibbs 解；其受约束总体解见定理 2.2。若改为拟合 $U_{k,n} - \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - G_k$，得到的是后面的 BPO 中心化残差，已经改变了 PMD-Mean 的目标。

2.2.3 BPO：中心化最优性残差

BPO将镜像方程残差按冻结 anchor 条件中心化。配分函数项是 action-independent 常数，中心化后消失：

$$R^{\text{BPO}}_{k,n}(s,a) \coloneqq U_{k,n}(s,a) - \eta f(s,a) - \mathbb{E}_{\pi_k}[U_{k,n}(s,\cdot) - \eta f(s,\cdot) \mid s] \tag{2.13}$$

$$= U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}^S_{k,n}(s). \tag{2.14}$$

这里 $\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}^S_{k,n}$，所以 student KL 前是正号。OPD 中 $f = r_k$，故

$$R^{\text{BPO}}_{k,n}(s,a) = \log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^S_{k,n}(s) - \eta\left(\log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^T_k(s)\right). \tag{2.15}$$

BPO 最小化

$$\mathcal{L}_{\text{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R^{\text{BPO}}_{k,n})^2]. \tag{2.16}$$

使用第一章定义的 score $\psi_{k,n}$ 及其 anchor 均值 $\bar{\psi}_{k,n}$，保留 student KL 的导数得到

$$\nabla_\theta\mathcal{K}^S_{k,n} = -\bar{\psi}_{k,n}, \qquad \nabla_\theta R^{\text{BPO}}_{k,n} = \psi_{k,n} - \bar{\psi}_{k,n}.$$

因此精确梯度为

$$\nabla_\theta\mathcal{L}_{\text{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R^{\text{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n})] \tag{2.17}$$

$$= \mathbb{E}_{d_k,\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}^S_{k,n}}{\eta} - f + \bar{f}_k\right)\psi_{k,n}\right]. \tag{2.18}$$

第二行使用 $\mathbb{E}_{\pi_k}[R^{\text{BPO}}_{k,n} \mid s] = 0$，已把 η^{-1} 乘入权重。梯度下降使用上述梯度的负值。消失的是 residual 均值乘以 score 均值，score 的 anchor 期望 $\bar{\psi}_{k,n}$ 本身通常不为零。

2.2.4 MDPO：最小化原始 mirror objective 的负值

MDPO使用原 mirror objective 的负值作为损失，统一执行梯度下降：

$$\mathcal{L}_{\text{MDPO}}(\theta) = -\mathbb{E}_{s\sim d_k,a\sim\pi_{k,n}}[f(s,a)] + \frac{1}{\eta}\mathbb{E}_{s\sim d_k}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.19}$$

逐历史应用式 (2.4)，得到

$$\mathcal{L}_{\text{MDPO}}(\theta \mid s) = -\frac{1}{\eta}\log Z_f(s) + \frac{1}{\eta}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi^{\star,\text{Gibbs}}_k(\cdot \mid s)). \tag{2.20}$$

这里 KL 的左侧分布是当前 student，与 $\mathcal{K}^S_{k,n} = \mathrm{KL}(\pi_k\|\pi_{k,n})$ 的方向不同。

对 student 测度和 log-ratio 同时求导，有

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}} = \mathbb{E}_{d_k,\pi_{k,n}}\left[\left(\frac{U_{k,n}+1}{\eta} - f\right)\psi_{k,n}\right] \tag{2.21}$$

$$= \mathbb{E}_{d_k,\pi_{k,n}}\left[\mathrm{sg}\left(\frac{U_{k,n}}{\eta} - f\right)\psi_{k,n}\right]. \tag{2.22}$$

第二行使用 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n} \mid s] = 0$。其下降方向是 $-\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，无需把 η 吸收进 optimizer 步长。

命题 2.3 (平方回归的投影含义)

若 student 函数类不能表示式(2.6) 的右侧，PMD-Part 的精确 inner 解是镜像方程在函数类诱导的 $L_2(d_k\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 ν，投影也相应变为 $L_2(\nu\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。

证明 平方损失定义了可行 log-ratio 集合上的最小距离问题。对任意光滑可行曲线的一阶切向扰动 v，局部最优残差 $\mathscr{E}^\star$ 满足

$$\mathbb{E}_{\nu,\pi_k}[\mathscr{E}^\star v] = 0.$$

这是残差与可行切空间正交的必要条件。参数化可行集合通常非凸，该条件本身不保证全局最优。若 target 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

2.3 四种 inner 的统一推导

本节先固定算法地图，再给出四种 inner 的可执行 policy-gradient (PG) 形式。这样可以把“优化哪个总体目标”“从哪个分布取样”和“反向传播时哪些量停止梯度”分开。OPD 的两个无镜像 baseline 放在表 2.1 中；它们不是第五、第六种 mirror 解，而是令镜像项消失后的共同极限。

表 2.1: 本章算法与实现的统一地图

方法	训练测度与权重	token 级 PG 系数（乘在 $\nabla_\theta \log \pi_{k,n}$ 上）	精确 inner 解
Token-IS OPD	行为测度 β_k，$w = \pi_{k,n}/\beta_k$	$-w(r_k + \mathcal{K}^T_{k,n})$	无镜像 OPD；$\mathcal{K}^T_{k,n}$ 为 teacher KL baseline
On-policy OPD	$\beta_k = \pi_{k,n}$，$w = 1$	$-(r_k + \mathcal{K}^T_{k,n})$	Token-IS 的 on-policy 特例
PMD-Part	anchor π_k	R^{Part}	Gibbs
PMD-Mean	anchor π_k	R^{Mean}	Lambert-W 投影
BPO	anchor π_k	R^{BPO}/η（含 score 中心化）	Gibbs
MDPO	anchor π_k,$\omega_{k,n} = \pi_{k,n}/\pi_k$	$\omega_{k,n}(U/\eta - f)$	Gibbs

在 tabular policy、完整词表、精确期望和足够 inner 优化的条件下，PMD-Part、BPO 和 MDPO 都满足同一个 Gibbs 固定点

$$\pi^\star_{k,n}(a \mid s) = \frac{\pi_k(a \mid s)e^{\eta f(s,a)}}{\mathbb{E}_{v\sim\pi_k(\cdot|s)}e^{\eta f(s,v)}}. \tag{2.23}$$

它们的区别在于残差是否中心化、是否显式使用 $\omega_{k,n}$ 测度校正以及采用普通梯度还是自然梯度，因此有限 inner steps 的轨迹和方差并不相同。PMD-Mean 拟合 $\eta(f - \bar{f}_k)$ 并另外施加指数归一化，其固定点是 Lambert-W 投影；除非 f 在该 prefix 上为常数，它不等于式 (2.23)。对 OPD 的 $f = r_k$，式 (2.23) 进一步化为

$$\pi^\star_{k,n}(a \mid s) \propto \pi_k(a \mid s)^{1-\eta}\pi_T(a \mid s)^\eta, \tag{2.24}$$

并在 $\eta = 1$ 时到达 teacher 分布。这个结论是四个 mirror inner 的总体收敛解，不适用于没有 U/η 项的 Token-IS/On-policy OPD baseline。

这里 $r_k(s,a) = \log \pi_T(a \mid s) - \log \pi_k(a \mid s)$ 是 OPD 的 sampled reward，$\mathcal{K}^T_{k,n}$ 是对同一 prefix 的 student–teacher

KL baseline。Token-IS 的 w 只修正采样测度；它没有 U/η 镜像项。因而 On-policy OPD 是 Token-IS 的严格特例，而不是 PMD 的另一个有限-η 解。

对 MDPO 要作一个精确限定：若每个 outer step 都重新用当前策略 rollout，确实有 $\pi_k = \beta_k$，从而 $\omega_{k,n}$ 不再承担跨策略的 importance correction；但有限 η 时系数仍包含 U/η，所以得到的是 on-policy MDPO。只有取 $\eta \to \infty$（或显式删除镜像项）时，它才退化为本章的 On-policy OPD baseline。这个区分解释了实验中 `mdpo + on-policy` 与 `opd_onpolicy` 不能仅凭采样方式视为同一个算法。

2.3.1 OPD baseline：Token-IS 与 On-policy 的共同 PG 形式

设 rollout 行为策略为 β_k，训练时的 student 为 $\pi_{k,n}$，并定义

$$w_{k,n}(s,a) = \frac{\pi_{k,n}(a \mid s)}{\beta_k(a \mid s)}, \qquad \rho_{k,n}(s,a) = \log \pi_T(a \mid s) - \log \pi_{k,n}(a \mid s). \tag{2.25}$$

对 teacher–student KL 使用冻结的 prefix baseline $\mathcal{K}^T_{k,n}(s) = \mathrm{KL}(\pi_{k,n}(\cdot \mid s) \| \pi_T(\cdot \mid s))$，Token-IS OPD 的 score gradient 是

$$\nabla_\theta \mathcal{L}_{\text{Token-IS-OPD}} = -\mathbb{E}_{s\sim d_k, a\sim\beta_k}\left[\mathrm{sg}\big(w_{k,n}(s,a)[\rho_{k,n}(s,a) + \mathcal{K}^T_{k,n}(s)]\big)\, \nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.26}$$

这里 $\mathcal{K}^T_{k,n}$ 只作 control variate；它不改变 exact full-vocabulary policy gradient，但会改变有限样本方差。若 $\beta_k = \pi_{k,n}$，则 $w_{k,n} = 1$，得到

$$\nabla_\theta \mathcal{L}_{\text{On-policy-OPD}} = -\mathbb{E}_{s\sim d_k, a\sim\pi_{k,n}}\left[\mathrm{sg}\big(\rho_{k,n}(s,a) + \mathcal{K}^T_{k,n}(s)\big)\, \nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.27}$$

当 rollout 与当前 student 完全同步时，$\rho_{k,n}$ 可直接由 sampled token 的 teacher/student log-prob 得到；不需要额外的 token-IS ratio。实现中 `opd_is` 使用式 (2.26)，`opd_onpolicy` 使用式 (2.27)，两者都不含 U/η 镜像项。

下面的四个 PG 式都在 $\theta = \theta_{k,n}$ 处计算。所有 reward、anchor log-prob、KL center、importance ratio 和 residual 都使用 $\mathrm{sg}(\cdot)$ 作为权重；只有最后的 $\nabla_\theta \log \pi_{k,n}(a \mid s)$ 接收梯度。这样写出的式子正是当前训练代码的 score surrogate，而非把一个会随 student 改变的系数再次反向传播。

2.3.2 PMD-Part：回归完整 Gibbs log-ratio

PMD-Part 的损失已在式 (2.9) 定义。

$$\mathcal{L}_{\text{Part}} = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}[(R^{\text{Part}}_{k,n})^2], \qquad R^{\text{Part}}_{k,n} = U_{k,n} - \eta f + \log Z_f. \tag{2.28}$$

固定 history 后，anchor 与 target 冻结，逐步求导得到

$$\nabla_\theta \mathcal{L}_{\text{Part}}(s) = \frac{1}{2}\nabla_\theta \sum_a \pi_k(a \mid s)(R^{\text{Part}}_{k,n}(s,a))^2 \tag{2.29}$$

$$= \sum_a \pi_k(a \mid s) R^{\text{Part}}_{k,n}(s,a) \nabla_\theta U_{k,n}(s,a) \tag{2.30}$$

$$= \mathbb{E}_{\pi_k}[R^{\text{Part}}_{k,n} \psi_{k,n} \mid s]. \tag{2.31}$$

梯度下降方向为 $-\mathbb{E}_{\pi_k}[R^{\text{Part}}_{k,n}\psi_{k,n} \mid s]$。这是固定 anchor 下的 log-ratio regression，不使用 student-to-anchor 的 action-level importance ratio。

因此 PMD-Part 的纯 PG 形式（用于 sampled token 的实现）为

$$\nabla_\theta \mathcal{L}_{\text{Part}}(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\mathrm{sg}\left(\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s)\right) \nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.32}$$

在 OPD 中直接代入 $f = r_k = \log \pi_T - \log \pi_k$，得到

$$\mathrm{sg}\big[U_{k,n}(s,a) - \eta\big(\log \pi_T(a \mid s) - \log \pi_k(a \mid s)\big) + \log \mathbb{E}_{v\sim\pi_k} \exp(\eta[\log \pi_T(v \mid s) - \log \pi_k(v \mid s)])\big] \nabla_\theta \log \pi_{k,n}(a \mid s). \tag{2.33}$$

若实际 rollout 来自行为测度 β_k，而目标仍是 $L_2(\pi_k)$ 投影，则每个 sampled 平方损失项乘以冻结权重 $\mathrm{sg}(\pi_k(a \mid s)/\beta_k(a \mid s))$。不加这个权重时，算法仍然有清晰含义，但求解的是 $L_2(\beta_k)$ 投影。

Algorithm 1 PMD-Part inner update
Semantics: 固定 *anchor* 下的完整 *Gibbs log-ratio* 回归

Require: frozen π_k, teacher signal f, histories $\{s_i\}_{i=1}^{B}$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$
for $i = 1, \dots, B$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $\log Z_i \leftarrow \mathrm{logsumexp}_{v\in\mathcal{V}}(\log \pi_k(v \mid s_i) + \eta f(s_i, v))$
  $H_i \leftarrow \eta f(s_i, a_i) - \mathrm{stopgrad}(\log Z_i)$
  $U_i \leftarrow \log \pi_{k,n}(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\ell_i \leftarrow \frac{1}{2}\big(U_i - \mathrm{stopgrad}(H_i)\big)^2$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

2.3.3 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean 用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \ \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.34}$$

定理 2.2 (PMD-Mean 的逐历史 Lambert-W 投影)

在有限词表、$\pi_k(a \mid s) > 0$ 且约束可行时，上述仅中心化 reward 的平方回归具有唯一全局最小点，其 KKT 解满足

$$U_a = G_a - W_0\big(\lambda_k(s)e^{G_a}\big), \qquad G_a = \eta\widetilde{f}_k(s,a), \tag{2.35}$$

其中 $\lambda_k(s) \geq 0$ 由 $\sum_a \pi_k(a \mid s)e^{U_a} = 1$ 唯一确定。

证明 以下给出固定历史 s 的 KKT 推导。令词表上的函数值为 U_a 和 $G_a = \eta\widetilde{f}_k(s,a)$，拉格朗日函数为

$$\mathscr{L}(U, \lambda_k) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda_k\left(\sum_a \pi_k(a \mid s)e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda_k e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda_k e^{G_a}$，所以

$$U_a = G_a - W_0\big(\lambda_k e^{G_a}\big), \tag{2.36}$$

其中 λ_k 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda_k) = \sum_a \pi_k(a \mid s)\exp\big(G_a - W_0(\lambda_k e^{G_a})\big), \qquad \lambda_k \geq 0.$$

由于 $\mathbb{E}_{\pi_k}[G \mid s] = 0$，Jensen 不等式给出 $\Phi(0) = \mathbb{E}_{\pi_k}[e^G \mid s] \geq 1$。Lambert–$W$ 的主分支在非负轴上严格递增，所以 Φ 连续且严格递减，且 $\Phi(\lambda_k) \to 0$ 当 $\lambda_k \to \infty$。因此归一化方程有唯一非负根；非恒定 G 对应严格正根，$G \equiv 0$ 时根为零。

对于该根 $\lambda_k \geq 0$，拉格朗日函数的 Hessian 是

$$\nabla_U^2\mathscr{L} = \mathrm{diag}\big(\pi_k(a \mid s)(1 + \lambda_k e^{U_a})\big) \succ 0.$$

因此构造出的 U 唯一最小化这个拉格朗日函数。所有满足归一化约束的 U 都有 $\mathscr{L}(U, \lambda_k) = \mathcal{L}_{\mathrm{Mean}}(U)$，构造的最小点又满足约束，故它是原受约束问题的唯一全局最小点。这一论证不要求指数归一化等式的可行集是凸集。

policy归一化 $\sum_a \pi_{k,n}(a \mid s) = 1$ 正是 log-ratio 坐标中的指数归一化条件。Lambert-W 解对应

$$\pi_k^{\star,\mathrm{Mean}}(a \mid s) = \pi_k(a \mid s) \exp\Big(G_k(s,a) - W_0(\lambda_k(s) e^{G_k(s,a)})\Big).$$

精确 Gibbs 解的 log-ratio 则为

$$U_a^{\mathrm{Gibbs}} = G_a - \log \mathbb{E}_{\pi_k}[e^G \mid s].$$

将其代入 PMD-Mean 的 KKT 条件，要求

$$-\log \mathbb{E}_{\pi_k}[e^G \mid s] + \lambda_k \frac{e^{G_a}}{\mathbb{E}_{\pi_k}[e^G \mid s]} = 0$$

对所有 action 同时成立。非恒定 G 时第一个量严格为负，第二个量随 action 改变，因此不存在满足所有方程的单一 λ_k。PMD-Mean 使用 action-dependent 的 Lambert-W 修正，Gibbs 使用 action-independent 的 log-partition 修正；二者仅在信号恒定时重合。

本节损失的乘子 λ_k 对应原论文乘子除以 τ^2，其中 $\tau = 1/\eta$。对 KKT 条件按 anchor 求均值，由 $\mathbb{E}_{\pi_k}[G] = 0$ 和 $\mathbb{E}_{\pi_k}[\omega_{k,n}] = 1$ 得到

$$\lambda_k = -\mathbb{E}_{\pi_k}[U] = \mathrm{KL}(\pi_k \| \pi_k^{\star,\mathrm{Mean}}).$$

固定这个由解确定的 λ_k，同一分布也唯一最大化

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\pi_k) - \frac{\lambda_k}{2\eta}\chi^2(p\|\pi_k), \qquad \chi^2(p\|\pi_k) = \mathbb{E}_{\pi_k}\left[\left(\frac{p}{\pi_k} - 1\right)^2\right]. \tag{2.37}$$

为验证这一等价，令 ξ 为概率归一化乘子。混合目标的逐 action 一阶条件为

$$f_a - \frac{1}{\eta}(U_a + 1) - \frac{\lambda_k}{\eta}(e^{U_a} - 1) + \xi = 0.$$

在 PMD-Mean 解处有 $U_a + \lambda_k e^{U_a} = \eta(f_a - \bar{f}_k)$；取 $\xi = (1 - \lambda_k)/\eta - \bar{f}_k$ 即满足上式。混合目标中的负 KL 严格凹，负 χ^2 凹，因此这个驻点是唯一全局最大点。这里的等价指总体最优分布相同，不表示两个训练目标在任意参数点上的梯度相同。

实际样本只需估计冻结的 reward center。给定同一 history 的 $m \geq 2$ 个独立 anchor actions，使用 leave-one-out 均值

$$\widehat{\bar{f}}_{-j} = \frac{1}{m-1}\sum_{\ell \neq j} f(s, a_\ell).$$

student log-ratio $U_{k,n}(s,a_j)$ 保持原值，不计算或减去 $\bar{U}_{k,n}$。因为该 center 不依赖 student，leave-one-out reward center 的有限样本平方损失与总体损失只相差一个参数无关的条件方差项，其梯度无偏。若 $m = 1$，需要外部同 prefix 的 reward center；使用不准确的冻结 baseline 会改变回归目标，必须单独记录该误差。

PMD-Mean 的 PG surrogate 只保留 student log-ratio 对应的 score：

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\mathrm{sg}\big(U_{k,n}(s,a) - \eta\big(f(s,a) - \bar{f}_k(s)\big)\big)\,\nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.38}$$

在 OPD 中 $\bar{f}_k(s) = \mathbb{E}_{v\sim\pi_k} r_k(s,v) = -\mathrm{KL}(\pi_k\|\pi_T)$，所以

$$\mathrm{sg}[U_{k,n}(s,a) - \eta\left(\log \pi_T(a \mid s) - \log \pi_k(a \mid s) + \mathrm{KL}(\pi_k(\cdot \mid s)\|\pi_T(\cdot \mid s))\right)]\,\nabla_\theta \log \pi_{k,n}(a \mid s). \tag{2.39}$$

2.3.4 BPO：中心化最优性 residual

BPO 的 residual、损失和梯度分别见式 (2.14)、(2.16)、(2.17)。为后续引用，同一对象记为

$$R_{k,n}^{\mathrm{BPO}} = U_{k,n} - G_k + \mathcal{K}_{k,n}^S, \qquad \mathcal{L}_{\mathrm{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2]. \tag{2.40}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n})]. \tag{2.41}$$

Algorithm 2 PMD-Mean inner update

Semantics: 中心化 *target* 在指数归一化集合上的投影

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, $m \geq 2$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  for $j = 1, \dots, m$ **do**
    sample $a_{ij} \sim \pi_k(\cdot \mid s_i)$
    $U_{ij} \leftarrow \log \pi_{k,n}(a_{ij} \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_{ij} \mid s_i))$
    $F_{ij} \leftarrow f(s_i, a_{ij})$
  end for
  for $j = 1, \dots, m$ **do**
    $\bar{F}_{-j} \leftarrow (m-1)^{-1} \sum_{\ell \neq j} F_{i\ell}$
    $\ell_{ij} \leftarrow \frac{1}{2}[U_{ij} - \eta\, \mathrm{stopgrad}(F_{ij} - \bar{F}_{-j})]^2$
  end for
end for
$g_{k,n} \leftarrow \nabla_\theta [(Bm)^{-1} \sum_{i,j} \ell_{ij}]$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

逐 token 的 PG 展开式为

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{a \sim \pi_k} \left[\mathrm{sg} \left(\frac{U_{k,n}(s,a) + \mathcal{K}^S_{k,n}(s)}{\eta} - f(s,a) + \bar{f}_k(s) \right) \nabla_\theta \log \pi_{k,n}(a \mid s) \right]. \tag{2.42}$$

这里使用 $\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}} \mid s] = 0$ 将 $-\bar{\psi}_{k,n}$ 项吸收到同一个 score expectation 中。OPD 代入后，四个量全部可直接由 prefix、sampled token 以及 teacher/student log-prob 得到：

$$\mathrm{sg} \left[\frac{U_{k,n}(s,a) + \mathrm{KL}(\pi_k \| \pi_{k,n})}{\eta} - \big(\log \pi_T(a \mid s) - \log \pi_k(a \mid s) \big) - \mathrm{KL}(\pi_k \| \pi_T) \right] \nabla_\theta \log \pi_{k,n}(a \mid s). \tag{2.43}$$

式中两个 KL 均条件于同一个 s，且都停止梯度；前者是 student center，后者是 OPD reward center。生产实现的 "bpo" 系数正是式 (2.43) 的括号部分。centered score 来自 student center 的导数。令 $z(s,a) = U_{k,n}(s,a) - \eta f(s,a)$，用一个主 action a_i 和 m 个独立辅助 actions $b_{i\ell}$ 估计 center，则

$$\mathbb{E} \left[\left(z(s,a_i) - \frac{1}{m} \sum_{\ell=1}^m z(s, b_{i\ell}) \right)^2 \right] = \left(1 + \frac{1}{m} \right) \mathrm{Var}_{\pi_k}(z \mid s).$$

因此 sampled 平方损失需乘 $m/(m+1)$，其 autograd 梯度才无偏。若同 prefix 共有 $m \geq 2$ 个 actions，leave-one-out center 使用其余 $m-1$ 个样本，对应系数为 $(m-1)/m$。独立性本身不能消除 residual 与 center 导数乘积中的协方差。

Algorithm 3 BPO inner update

Semantics: 固定 *anchor* 下对正向中心化残差求平方损失

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, auxiliary count $m \geq 1$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$ and $b_{i1}, \dots, b_{im} \sim \pi_k(\cdot \mid s_i)$ independently
  $z_i \leftarrow U_{k,n}(s_i, a_i) - \eta f(s_i, a_i)$
  $\bar{z}_i \leftarrow m^{-1} \sum_{\ell=1}^m [U_{k,n}(s_i, b_{i\ell}) - \eta f(s_i, b_{i\ell})]$
  $\widehat{R}_i^{\mathrm{BPO}} \leftarrow z_i - \bar{z}_i$, $\ell_i \leftarrow \frac{m}{m+1} \frac{(\widehat{R}_i^{\mathrm{BPO}})^2}{2\eta}$
end for
$g_{k,n} \leftarrow \nabla_\theta (B^{-1} \sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

若从行为测度 β 采样，不能先把 z 乘以 importance weight 再平方；这会把二阶矩的权重变成平方。可用两

个独立样本 $a, b \sim \beta(\cdot \mid s)$，令 $w(v) = \mathrm{sg}(\pi_k(v \mid s)/\beta(v \mid s))$，使用

$$\widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \frac{w(a)w(b)}{4\eta}[z(a) - z(b)]^2.$$

因为 $\mathbb{E}_{a,b\sim\pi_k}[(z(a) - z(b))^2] = 2\,\mathrm{Var}_{\pi_k}(z)$，上述估计器的期望恰为原始 BPO 损失，且固定权重下 autograd 给出无偏梯度。

2.3.5 MDPO：直接优化 mirror objective

MDPO 的损失见式 (2.19)。完整词表计算

$$\mathrm{KL}(\pi_{k,n} \| \pi_k) = \sum_a \pi_{k,n}(a \mid s) U_{k,n}(s, a). \tag{2.44}$$

若从 anchor 采样，用显式指数权重改写 student 期望：

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right) \mid s\right]. \tag{2.45}$$

原损失中的指数权重保留梯度；解析求导后的 policy-gradient 权重整体冻结，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[\mathrm{sg}\left(e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right)\right)\psi_{k,n} \mid s\right]. \tag{2.46}$$

也就是说，MDPO 的完整 sampled-token PG 形式已经是

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\mathrm{sg}\left(\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}\left[\frac{1}{\eta}\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - f(s, a)\right]\right)\nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.47}$$

OPD 的代入式为

$$\mathrm{sg}\left[\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}\left(\frac{1}{\eta}\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}\right)\right]\nabla_\theta \log \pi_{k,n}(a \mid s). \tag{2.48}$$

当 rollout 策略就是当前 student，即 $\pi_k = \pi_{k,n}$，ratio 等于 1；有限 η 仍留下 U/η，而 $\eta \to \infty$ 时式 (2.48) 退化为 $-r_k \nabla_\theta \log \pi_{k,n}$，这才是 On-policy OPD 的 PG 形式。额外的 η^{-1} score 项在完整求和时由 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n}] = 0$ 抵消。

自然梯度只改变更新几何。令 $h_{k,n} = \nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，Fisher 信息矩阵为

$$F_{k,n} = \mathbb{E}_{d_k,\pi_{k,n}}[\psi_{k,n}(s, a)\psi_{k,n}(s, a)^\top].$$

anchor 采样时用 $\mathrm{sg}(e^{U_{k,n}})$ 校正测度。tabular categorical logits 的 Fisher 零空间为常数方向，故用伪逆 $F^\dagger_{k,n}$；神经网络参数化中用阻尼 $\gamma > 0$ 或 KL trust region。自然步长与镜像系数 η 分别控制数值更新和总体 target。

Algorithm 4 MDPO natural-gradient inner update
Semantics: 最小化固定 history 的负 mirror objective

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, η, natural step $\alpha_{k,n}$, damping $\gamma \geq 0$
Ensure: updated parameters $\theta_{k,n+1}$

```
for each history s_i do
    sample a_i ~ π_k(· | s_i)
    U_i ← U_{k,n}(s_i, a_i), w_i ← e^{U_i}
    ℓ_i ← w_i(U_i/η − f(s_i, a_i))                ▷ retain the student derivative of w_i
    g_i^score ← ∇_θ log π_{k,n}(a_i | s_i)
end for
g_{k,n} ← ∇_θ(B^{-1} Σ_i ℓ_i)
F ← B^{-1} Σ_i stopgrad(w_i) g_i^score (g_i^score)^⊤
θ_{k,n+1} ← θ_{k,n} − α_{k,n}(F + γI)^† g_{k,n}
return θ_{k,n+1}
```

定理 2.3 (Gibbs 解与 PMD-Mean 的 Lambert-W 解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、未线性化 BPO 和 MDPO 的总体最优解是式 (2.3) 的 Gibbs 分布。PMD-Mean 的总体最优解是定理 2.2 的 Lambert-W 分布；非恒定信号下与 Gibbs

分布不同。参数化 student 或有限样本还会引入函数类投影、采样及优化误差。 ♡

证明 PMD-Part 在零损失处满足 $U_{k,n} = \eta f - \log Z_f$，得到 Gibbs 分布。BPO 的零 residual 只要求 $U_{k,n} = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_{k,n}}] = 1$ 得 $C(s) = \log Z_f(s)$。MDPO 的负 mirror 损失由式 (2.4) 得到唯一最小点。PMD-Mean 的受约束全局最小点及与 Gibbs 解的分离已在定理 2.2 后证明。

命题 2.4 (PMD-Mean 与 BPO 的损失和梯度差异)

固定历史 s，两个 residual 满足 $R^{\mathrm{Mean}}_{k,n} = R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n}$，因此

$$\mathcal{L}_{\mathrm{Mean}}(s) = \eta \mathcal{L}_{\mathrm{BPO}}(s) + \frac{1}{2}(\mathcal{K}^S_{k,n}(s))^2, \tag{2.49}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) + \mathcal{K}^S_{k,n}(s) \nabla_\theta \mathcal{K}^S_{k,n}(s). \tag{2.50}$$

♠

证明 $\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n} \mid s] = 0$，平方展开得

$$\frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n})^2 \mid s] = \frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n})^2 \mid s] + \frac{1}{2}(\mathcal{K}^S_{k,n})^2.$$

再使用损失定义并求导。下降方向的同尺度关系为

$$-\nabla_\theta \mathcal{L}_{\mathrm{Mean}} = -\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} + \mathcal{K}^S_{k,n} \bar{\psi}_{k,n}.$$

初始化 $\pi_{k,0} = \pi_k$ 时 $\mathcal{K}^S_{k,0} = 0$，两者同尺度方向一致；离开 anchor 后差异通常保留。tabular softmax logits 中 $\bar{\psi}_{k,n} = \pi_k - \pi_{k,n}$，额外下降方向是 $\mathcal{K}^S_{k,n}(\pi_k - \pi_{k,n})$。

命题 2.5 (未线性化 BPO 与 PMD-Part 的梯度差异)

固定历史 s，定义

$$C_{k,n}(s) \coloneqq \log Z_f(s) - \eta \bar{f}_k(s) - \mathcal{K}^S_{k,n}(s). \tag{2.51}$$

则 $R^{\mathrm{BPO}}_{k,n} = R^{\mathrm{Part}}_{k,n} - C_{k,n}$，且

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}(s)}{\eta}\bar{\psi}_{k,n}(s). \tag{2.52}$$

♠

证明 逐项展开中心化残差：

$$\begin{aligned} R^{\mathrm{BPO}}_{k,n} &= U_{k,n} - \eta f - \mathbb{E}_{\pi_k}[U_{k,n} - \eta f \mid s] \\ &= U_{k,n} - \eta f + \log Z_f - \left(\log Z_f + \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - \eta \bar{f}_k\right) \\ &= R^{\mathrm{Part}}_{k,n} - C_{k,n}. \end{aligned}$$

这里必须保留 $-\eta \bar{f}_k$，因为一般 OPD 信号的 anchor 均值不为零。由 BPO residual 均值为零，

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \\ &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[(R^{\mathrm{Part}}_{k,n} - C_{k,n})\psi_{k,n} \mid s] \\ &= \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}}{\eta}\bar{\psi}_{k,n}. \end{aligned}$$

在 Gibbs 解处 $R^{\mathrm{Part}}_{k,n} = 0$，其 anchor 均值也为零，因此 $C_{k,n} = 0$，两种梯度同时为零。一般参数点只有 $C_{k,n}\bar{\psi}_{k,n} = 0$ 时才具有相同的同尺度方向。

PMD-Part 回归完整镜像方程，BPO 消去 action-independent 常数再回归中心化方程。二者总体最优分布相同，而 residual、积分后的梯度和有限步轨迹不同。

本书的实际 OPD baseline 定义、Pythia-14M/70M 的训练配置、固定 prefix 的 full-vocabulary 评估以及 final KL/ESS 记录见第 2.6 节。那组实验对应表 2.1 的前两行；它们提供了比较四个 mirror inner 时的无镜像参照线，而不应被当作有限-η mirror inner 的收敛证据。

2.4 镜像系数、数值步长与内层收敛的精确关系

共同子问题确定 Gibbs target，但不能据此把不同训练损失视为同一个参数目标。PMD-Part 与 BPO 回归不同形式的最优性方程，MDPO 直接优化原始子问题；PMD-Mean 进一步近似归一化项，因而改变总体 target。以下在完整有限词表上推导可验证的数值动力学，再说明神经网络实现需要保留哪些区别。

命题 2.6 (BPO 在 categorical logits 中是凸二次目标)

固定历史 s，记 $q_a = \pi_k(a \mid s) > 0$，以无约束 logits ℓ_a 参数化 $p_a = e^{\ell_a}/\sum_b e^{\ell_b}$。令

$$F_q = \mathrm{diag}(q) - qq^\top, \qquad h_a = \ell_a - \log q_a - \eta f_a.$$

精确 BPO 损失、梯度和 Hessian 分别是

$$\mathcal{L}_{\mathrm{BPO}} = \frac{h^\top F_q h}{2\eta}, \qquad \nabla_\ell \mathcal{L}_{\mathrm{BPO}} = \frac{F_q h}{\eta}, \qquad \nabla^2_\ell \mathcal{L}_{\mathrm{BPO}} = \frac{F_q}{\eta}. \tag{2.53}$$

其最小 logits 为 $\ell^\star = \log q + \eta f + c\mathbf{1}$，其中 c 是任意归一化冗余常数；最优概率分布唯一。

证明 将 student 的 log-softmax 展开为 $U_a = \ell_a - \log\sum_b e^{\ell_b} - \log q_a$，有

$$U_a - \eta f_a = h_a - \log\sum_b e^{\ell_b}.$$

对整个量按 q 中心化时，log-softmax 的归一化常数精确消去，所以

$$R_a^{\mathrm{BPO}} = h_a - \sum_b q_b h_b.$$

平方并按 q 求和，得到

$$\sum_a q_a (R_a^{\mathrm{BPO}})^2 = \sum_a q_a h_a^2 - \left(\sum_a q_a h_a\right)^2 = h^\top F_q h.$$

h 对 ℓ 的导数是单位矩阵，故直接求导得到式 (2.53)。对任意向量 v，

$$v^\top F_q v = \mathrm{Var}_{a\sim q}(v_a) \geq 0.$$

严格正的 q 使方差为零当且仅当 v 在所有 action 上恒定，故 F_q 的零空间正是 $\mathrm{span}\{\mathbf{1}\}$。零损失等价于 $h = c\mathbf{1}$，归一化后即 Gibbs 解。这个凸性结论针对独立 categorical logits；共享参数神经网络的复合目标仍可非凸。

定理 2.4 (完整词表 BPO 梯度下降与 MDPO 自然梯度的步长条件)

在上述 categorical 条件下且 $|\mathcal{V}| \geq 2$，固定 anchor、信号和常数步长 $\alpha > 0$。令 $P = I - \mathbf{1}\mathbf{1}^\top/|\mathcal{V}|$，并以

$$e_n = P(\ell_n - \log q - \eta f)$$

度量相对于 Gibbs target 的 logit 误差，则：

1. BPO 的普通梯度下降满足 $e_{n+1} = (I - \alpha F_q/\eta)e_n$。对所有初值收敛的充要条件是 $0 < \alpha < 2\eta/\lambda_{\max}(F_q)$。
2. MDPO 使用当前 student 的精确 Fisher F_{p_n} 和无阻尼伪逆时满足 $e_{n+1} = (1 - \alpha/\eta)e_n$。对所有初值收敛的充要条件是 $0 < \alpha < 2\eta$；$\alpha = \eta$ 在一步内到达 Gibbs target。
3. BPO 若使用冻结 anchor Fisher F_q 的精确伪逆，也满足第二项的同一递推。

第二、三项虽在这一理想参数化下具有相同的有限步概率轨迹，使用的 Fisher 分别为当前 student 和冻结 anchor；不能将两种 preconditioner 互换后仍声称具有该恒等式。

证明 BPO 的梯度已在式 (2.53) 给出。因为 $PF_q = F_q P = F_q$，投影更新为

$$e_{n+1} = e_n - \frac{\alpha}{\eta} F_q e_n.$$

在 $\mathbf{1}^\perp$ 上将 F_q 正交对角化，所有特征值 λ_i 严格为正。每个特征方向的误差乘以 $1 - \alpha\lambda_i/\eta$，其绝对值都小于一当且仅当 $0 < \alpha < 2\eta/\lambda_{\max}(F_q)$。此时以 $\max_i |1 - \alpha\lambda_i/\eta| < 1$ 的因子收缩；边界上最大特征方向以符号翻转保

持幅度，超过边界则该方向发散。

MDPO 的完整词表目标是

$$\mathcal{L}_{\mathrm{MDPO}}(\ell) = \sum_a p_a \left[\frac{\log p_a - \log q_a}{\eta} - f_a \right].$$

softmax Jacobian 为 $\nabla_\ell p = F_p$。对概率与 integrand 同时求导给出

$$\nabla_\ell \mathcal{L}_{\mathrm{MDPO}} = F_p \left[\frac{\log p - \log q + \mathbf{1}}{\eta} - f \right] = \frac{1}{\eta} F_p(\ell - \log q - \eta f),$$

其中利用 $F_p \mathbf{1} = 0$ 消去了 $\mathbf{1}/\eta$ 和 log-softmax 的归一化常数。正概率条件下 $F_p^\dagger F_p = P$，故自然梯度为 e_n/η。投影数值更新即 $e_{n+1} = (1 - \alpha/\eta)e_n$。所有初值的收缩条件是 $|1 - \alpha/\eta| < 1$；$\alpha = \eta$ 时投影误差为零，剩余常数不会改变概率。对 BPO 使用 $F_q^\dagger F_q = P$ 可逐步重复这一论证。

定理 2.4 明确区分 η 与 optimizer 步长。减小 η 将 Gibbs target 拉近 anchor，同时使 BPO、MDPO 原始损失的曲率含有 $1/\eta$；固定数值步长不因此自动稳定。使用阻尼 Fisher、随机 Fisher 估计、Adam、梯度裁剪或有限支持集中心后，上述精确递推不再成立。尤其同一批样本构造的随机 Fisher 伪逆与随机梯度的乘积，不等于总体自然梯度的无偏估计。

在 OPD 中 $f = \log(\pi_T/q)$。当 $\eta = 1$，精确 Gibbs target 是 teacher；定理中的 MDPO 自然梯度还需 $\alpha = 1$、完整期望与独立 categorical logits，才能一步到 teacher。一般 SGD 或 Adam 的一步更新没有这个性质；PMD-Mean 的充分优化解也仍是 Lambert-W 分布。

命题 2.7 (三种方法在 anchor 初值的尺度与小镜像步的 target)

在 $p = q$ 处，三个精确参数梯度满足

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}} = -\eta\, \mathbb{E}_q[f \nabla_\theta \log p], \qquad \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \nabla_\theta \mathcal{L}_{\mathrm{MDPO}} = -\mathbb{E}_q[f \nabla_\theta \log p].$$

固定有限词表、有限冻结信号，令 $h = f - \mathbb{E}_q f$、$\sigma^2 = \mathbb{E}_q h^2$。当 $\eta \to 0$ 时，Mean 与 Gibbs target 的 log-ratio 分别满足

$$U_a^{\mathrm{Mean}} = \eta h_a - \frac{\eta^2 \sigma^2}{2} + O(\eta^3), \qquad U_a^{\mathrm{Gibbs}} = \eta h_a - \frac{\eta^2 \sigma^2}{2} + O(\eta^3).$$

余项在有限词表上对 action 一致有界。因此两者在小步极限到二阶一致，同时保留有限 η 下不同的总体最优解。

证明 初始 log-ratio 和 student KL 均为零，且 $\mathbb{E}_q[\nabla_\theta \log p] = 0$，将这些量代入三个解析梯度即得第一组等式。对 target 展开，Gibbs 的归一化常数满足

$$\log \mathbb{E}_q e^{\eta h} = \frac{\eta^2 \sigma^2}{2} + O(\eta^3)$$

因为 $\mathbb{E}_q h = 0$。Mean 的 KKT 方程为 $U_a = \eta h_a - \lambda e^{U_a}$。在 $(\eta, \lambda) = (0, 0)$ 处，归一化方程对 λ 的导数为 -1，所以隐函数定理给出光滑的 $\lambda(\eta)$ 与 $U(\eta)$。设

$$U_a = \eta A_a + \eta^2 B_a + O(\eta^3), \qquad \lambda = \eta l_1 + \eta^2 l_2 + O(\eta^3).$$

一阶 KKT 与归一化分别给出 $A_a = h_a - l_1$、$\mathbb{E}_q A = 0$，因而 $l_1 = 0$、$A = h$。二阶 KKT 给出 $B_a = -l_2$，二阶归一化给出

$$0 = \mathbb{E}_q \left[B + \frac{A^2}{2} \right] = -l_2 + \frac{\sigma^2}{2}.$$

由此 $l_2 = \sigma^2/2$，得到 Mean 展开。有限词表与固定有限信号保证 Taylor 余项对所有 action 一致。

比较相同 η 下的 SGD 时，Mean 的初始梯度比 BPO、MDPO 小 η 倍；初始方向一致的数值步长对应 $\alpha_{\mathrm{Mean}} = \alpha_{\mathrm{BPO}}/\eta$。这仅用于比较初始化的尺度，离开 anchor 后 Mean 额外的 KL 平方项仍改变方向。Adam 中的动量、平方矩估计、ϵ 和裁剪也使这种 SGD 的尺度换算无法直接套用。

2.4.1 总体梯度、经验损失与训练日志的区别

BPO的中心导数项消去依赖精确条件恒等式 $\mathbb{E}_q[R^{\mathrm{BPO}} \mid s] = 0$。固定 rollout 中每个 prefix 通常只有一个 sampled action，经验残差均值并不为零。即使中心使用完整词表，经验 PG 更新也不必等于对这批动作的 BPO 平方损失直接 autograd；它在固定参数、重新独立抽样的条件下才具有相同总体梯度。训练参数依赖此前复用的这批数据时，不能再把固定参数的条件无偏结论解释成训练每一步的无条件无偏性。

MDPO 从解析梯度删去 $1/\eta$ 项也依赖 $\mathbb{E}_p[\nabla_\theta \log p] = 0$。原始重要性加权目标与删去该项的 PG surrogate，在总体期望下梯度相同，在同一有限样本上相差

$$\frac{1}{\eta|\mathcal{B}_k|} \sum_{(s,a)\in\mathcal{B}_k} \frac{p(a \mid s)}{q(a \mid s)} \nabla_\theta \log p(a \mid s).$$

该项可以作为零均值控制变量选择保留或删除；本书正式 PG 实现删除它，原始 MDPO 自然梯度伪代码保留它。两种 Monte Carlo 梯度的具体数值及方差不同。

停止梯度后的 coefficient 乘 log-prob 是承载解析更新的 surrogate，其标量值可以为负，也没有固定的跨 inner 优化目标含义，因为 coefficient 每步重新计算。inner 收敛应结合真实平方 residual、精确 mirror objective gap、全批量梯度范数和更新幅度判断。Mean 应监控其 Lambert-W target 或受约束平方目标；不能把未到 Gibbs target 当作 Mean 数值优化失败。采用 Tail-aware 中心时还须记录其与 exact KL 的差异，避免把截断中心的残差变小解释成原始 BPO 子问题已经求解。

2.5 OPD 特化：逐 token reward 与两种信息访问模式

在 OPD 中，第 k 个 outer step 先固定 anchor π_k，然后从它产生 rollout。对 prefix $s_t = (x, y_{<t})$ 和实际 sampled token $a_t = y_t$，最直接的局部 teacher reward 是

$$r_k(s_t, a_t) = \log \pi_T(a_t \mid s_t) - \log \pi_k(a_t \mid s_t). \tag{2.54}$$

它满足序列分解

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \log \pi_T(y \mid x) - \log \pi_k(y \mid x).$$

因此在共同 mirror 子问题中应取 $f = r_k$；不能把整条序列的 log-ratio 当作每一个 prefix 的同一个 reward，否则会重复计算后缀差异。

可以对 reward 做两种不同的“归一化”，必须区分它们的理论作用。对任意只依赖 prefix 的 baseline $b_k(s)$，令

$$f_k^{\mathrm{ctr}}(s, a) = r_k(s, a) - b_k(s). \tag{2.55}$$

它只把 partition function 乘上 $e^{-\eta b_k(s)}$，所以 Gibbs policy 不变；取 $b_k(s) = \mathbb{E}_{\pi_k}[r_k(s, \cdot) \mid s]$ 就是条件中心化。若再除以尺度 $\sigma_k(s) > 0$，则

$$f_k^{\mathrm{std}} = (r_k - b_k)/\sigma_k$$

会把有效温度从 η 改成 η/σ_k，不再是同一个 mirror step，除非同时把正则参数改为 $\eta\sigma_k$。因此 OPD 的默认实现只做 additive centering；标准化只能作为明确的 temperature schedule。

2.5.1 完整 vocabulary logits：精确 token mirror target

完整词表 logits 使冻结 reward r_k、teacher center $\mathcal{K}_k^T$、student center $\mathcal{K}_{k,n}^S$ 和 partition function 都可精确求和。OPD 的配分函数为

$$\log Z_k(s) = \mathrm{logsumexp}_{v\in\mathcal{V}} \left((1-\eta) \log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\right). \tag{2.56}$$

相应 Gibbs target 是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \exp\left((1-\eta) \log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) - \log Z_k(s)\right).$$

PMD-Mean 的 target 是定理 2.2 的 $\pi_k^{\star,\mathrm{Mean}}$。完整词表路径消除了条件 token 采样误差；prefix coverage 与数值优化误差仍保留。

四种损失与实际梯度

第一章的条件均值恒等式给出 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}_k^T$、$\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}_{k,n}^S$。因此冻结 Mean target 为 $G_k = \eta(r_k + \mathcal{K}_k^T)$，三个回归 residual 是

$$R_{k,n}^{\mathrm{Part}}(s,v) = U_{k,n}(s,v) - \eta r_k(s,v) + \log Z_k(s), \tag{2.57}$$

$$R_{k,n}^{\mathrm{Mean}}(s,v) = U_{k,n}(s,v) - \eta(r_k(s,v) + \mathcal{K}_k^T(s)), \tag{2.58}$$

$$R_{k,n}^{\mathrm{BPO}}(s,v) = U_{k,n}(s,v) + \mathcal{K}_{k,n}^S(s) - \eta(r_k(s,v) + \mathcal{K}_k^T(s)). \tag{2.59}$$

它们对应

$$\mathcal{L}_{\mathrm{Part}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Part}})^2 \mid s], \tag{2.60}$$

$$\mathcal{L}_{\mathrm{Mean}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Mean}})^2 \mid s], \tag{2.61}$$

$$\mathcal{L}_{\mathrm{BPO}}(s) = \tfrac{1}{2\eta}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2 \mid s], \tag{2.62}$$

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}[U_{k,n}/\eta - r_k \mid s]. \tag{2.63}$$

三个平方损失的解析梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Part}} \psi_{k,n} \mid s], \tag{2.64}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Mean}} \psi_{k,n} \mid s], \tag{2.65}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \tag{2.66}$$

$$= \mathbb{E}_{\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta} - r_k - \mathcal{K}_k^T\right)\psi_{k,n} \mid s\right]. \tag{2.67}$$

这里直接比较 $\nabla\mathcal{L}$，BPO 的 η^{-1} 已乘入权重。其实际下降方向为

$$-\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{\pi_k}\left[\left(r_k + \mathcal{K}_k^T - \frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta}\right)\psi_{k,n} \mid s\right]. \tag{2.68}$$

centered score 的第二项消失，是因为 $\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}} \mid s] = 0$；不能把 $\bar{\psi}_{k,n}$ 自身视为零。Mean residual 的 anchor 均值为 $-\mathcal{K}_{k,n}^S$，所以 Mean 不具有同样的消去。

MDPO 同时微分 student 测度和 log-ratio，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}\left[\left(\frac{U_{k,n} + 1}{\eta} - r_k\right)\psi_{k,n} \mid s\right] \tag{2.69}$$

$$= \mathbb{E}_{\pi_{k,n}}[(U_{k,n}/\eta - r_k)\psi_{k,n} \mid s]. \tag{2.70}$$

第二行使用 student 测度的零均值 score 恒等式。MDPO 使用 student 积分测度，三个回归损失使用 anchor 积分测度。

停止梯度的具体位置

π_k、π_T、$\log Z_k$、$\mathcal{K}_k^T$ 和 G_k 在固定 outer step 冻结。student KL 每个 inner step 重算，原始 BPO 平方损失中保留其导数：

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{\pi_k}[\mathrm{stopgrad}(\log \pi_k) - \log \pi_{k,n} \mid s], \tag{2.71}$$

$$\nabla_\theta \mathcal{K}_{k,n}^S(s) = -\bar{\psi}_{k,n}(s). \tag{2.72}$$

若实现已经解析好的 policy gradient，所有 residual 和 MDPO 权重都整体停止梯度：例如 surrogate

$$\mathbb{E}_{\pi_k}[\mathrm{stopgrad}(R_{k,n}^{\mathrm{Mean}}) \log \pi_{k,n}]$$

的梯度正好等于 Mean 梯度。此处权重的导数已由解析推导处理，再微分一次会改变目标。若直接实现原始平方损失，则 student residual 及 BPO center 保留梯度。Mean 原始损失不含 student KL center。

2.5.2 有限词表与 sampled-token：KL 与 partition 估计

2602.04417的 Top-J 方法直接估计 KL：在 top-J 头部计算精确项，在尾部用采样项校正。它不直接给出本节的 $\log Z_k$，因为

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\left(\frac{\pi_T(a\mid s)}{\pi_k(a\mid s)}\right)^{\eta}\right]. \tag{2.73}$$

这一区别很重要：$\widehat{Z}_k$ 可以无偏，但 $\log \widehat{Z}_k$ 不能无偏。

在固定 prefix s 上，从冻结 anchor 采样 $a_j \sim \pi_k(\cdot\mid s)$，令 $r_k(s,a) = \log \pi_T(a\mid s) - \log \pi_k(a\mid s)$。则两个中心满足

$$\mathcal{K}_k^T(s) = \mathbb{E}_{a\sim\pi_k}[-r_k(s,a)], \tag{2.74}$$

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{a\sim\pi_k}\left[\log \pi_k(a\mid s) - \log \pi_{k,n}(a\mid s)\right]. \tag{2.75}$$

因此 m 个独立 next-token 样本的均值分别是两个 KL 的无偏估计。真实 rollout 中每个 prefix 通常只有一个后继 token；该 token 是无偏单点样本，但不是 conditional KL 的精确值。若要降低方差，可以在已经算出 anchor logits 后额外抽取 $m-1$ 个 token，这只增加 categorical 抽样和 log-prob 记录，无需生成额外长序列。不同 prefix 的 token 不能互相当作同一条件分布的样本。

其中 $\mathcal{K}_k^T$ 在整个 outer step 内固定，teacher/anchor log-prob 可以缓存；$\mathcal{K}_{k,n}^S$ 必须在每个 inner step 重新计算。实现已经推导好的 policy-gradient 时，KL 中心作为权重整体使用 stop-gradient；实现原始 BPO 平方损失时则必须保留 student KL 的导数；PMD-Mean 只需要冻结的 teacher KL center。

对 $\mathcal{K}_{k,n}^S = \mathrm{KL}(\pi_k\|\pi_{k,n})$，取 $S_{k,J}(s) = \mathrm{Top}(\pi_k(\cdot\mid s), J)$，可构造

$$\widehat{\mathcal{K}}_{k,n}^S(s) = \sum_{v\in S_{k,J}(s)} \pi_k(v\mid s)\log\frac{\pi_k(v\mid s)}{\pi_{k,n}(v\mid s)} \tag{2.76}$$

$$+\frac{1}{m}\sum_{j=1}^{m}\mathbf{1}\{a_j\notin S_{k,J}(s)\}\log\frac{\pi_k(a_j\mid s)}{\pi_{k,n}(a_j\mid s)}, \qquad a_j\sim\pi_k(\cdot\mid s). \tag{2.77}$$

对固定 $S_{k,J}$，尾部项是精确尾部求和的无偏 Monte Carlo 估计，且其 autograd 梯度的期望等于真实 KL 梯度。这里的“梯度无偏”是指把该估计量直接放进原始 KL 损失并对 student 反向传播时的性质；本章的最终实现采用已经解析化的 policy-gradient 形式，KL 估计值只作为数值权重，必须整体 stopgrad，因此不需要再对这个估计量执行 autograd。$J=0$ 是纯 sampled-token，$J=|\mathcal{V}|$ 是 exact KL；这两个端点是同一个 top-J 族的插值端点，不单独构成一个算法分支。给定头部后，条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_{k,n}^S\mid S_{k,J}) = \frac{1}{m}\mathrm{Var}_{a\sim\pi_k}\left[\mathbf{1}\{a\notin S_{k,J}\}\log\frac{\pi_k(a\mid s)}{\pi_{k,n}(a\mid s)}\right]. \tag{2.78}$$

增大 J 通常降低尾部质量和方差，但实际大小取决于尾部 log-ratio 的二阶矩。对 $\mathcal{K}_k^T$ 可使用同样的头尾分解；由于它不需要反向传播，anchor 样本均值往往已经足够。

为了把 2602.04417 中“截断偏差换取采样方差”的结论直接用于 OPD，下面给出一个与 KL、score 加权梯度和 partition function 都兼容的统一形式。固定 prefix s，令 $p(v)$ 为 rollout 测度（本章中通常是 $p=\pi_k(\cdot\mid s)$），$h(v)$ 为待求期望的 integrand，定义

$$Q = \mathbb{E}_{v\sim p}[h(v)], \qquad Q_J^{\mathrm{head}} = \sum_{v\in S_J} p(v)h(v), \qquad \tau_J = \mathbb{E}_{v\sim p}[\mathbf{1}\{v\notin S_J\}h(v)], \tag{2.79}$$

其中 S_J 是固定的 top-J 集合。用 m 个独立的 auxiliary token $a_1,\dots,a_m\sim p$ 做尾部校正时，定义

$$\widehat{Q}_{J,m} = Q_J^{\mathrm{head}} + \frac{1}{m}\sum_{j=1}^{m}\mathbf{1}\{a_j\notin S_J\}h(a_j). \tag{2.80}$$

定理 2.5 (Top-J 截断与尾部校正的偏差–方差分解)

在 $\mathbb{E}_p[h^2] < \infty$ 且 S_J 与 auxiliary samples 独立时，纯头部估计 $\widehat{Q}_J^{\mathrm{tr}} = Q_J^{\mathrm{head}}$ 与尾部校正估计 $\widehat{Q}_{J,m}$ 分别满足

$$\mathrm{Bias}(\widehat{Q}_J^{\mathrm{tr}}) = -\tau_J, \qquad \mathrm{Var}(\widehat{Q}_J^{\mathrm{tr}}) = 0, \qquad \mathrm{MSE}(\widehat{Q}_J^{\mathrm{tr}}) = \tau_J^2, \tag{2.81}$$

$$\mathrm{Bias}(\widehat{Q}_{J,m}) = 0, \qquad \mathrm{Var}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \qquad \mathrm{MSE}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \tag{2.82}$$

其中

$$V_J = \mathbb{E}_p\left[\mathbf{1}\{v \notin S_J\} h(v)^2\right] - \tau_J^2. \tag{2.83}$$

如果 $S_J \subseteq S_{J+1}$，则尾部二阶矩 $A_J = \mathbb{E}_p[\mathbf{1}\{v \notin S_J\} h(v)^2]$ 单调不增，且 $V_J \le A_J$。尾部均值 τ_J 在 $h \ge 0$ 时单调不增；对符号不定的 h，它本身不必单调，但有

$$|\tau_J| \le \sqrt{p(S_J^c) A_J}. \tag{2.84}$$

♡

证明 记 $X_j = \mathbf{1}\{a_j \notin S_J\} h(a_j)$。由 $a_j \sim p$，有 $\mathbb{E}[X_j] = \tau_J$，且 $\mathrm{Var}(X_j) = V_J$。因此

$$\mathbb{E}[\widehat{Q}_{J,m}] = Q_J^{\mathrm{head}} + \tau_J = Q, \qquad \mathrm{Var}(\widehat{Q}_{J,m}) = \mathrm{Var}\left(\frac{1}{m}\sum_{j=1}^{m} X_j\right) = \frac{V_J}{m}, \tag{2.85}$$

其中最后一步使用了独立性。纯头部估计没有随机项，且 $Q_J^{\mathrm{head}} - Q = -\tau_J$，从而得到前三个等式。若集合嵌套，$\mathbf{1}\{v \notin S_{J+1}\} \le \mathbf{1}\{v \notin S_J\}$，故对非负 h^2 有 $A_{J+1} \le A_J$。当 $h \ge 0$ 时，尾部指示函数逐点下降，所以 $0 \le \tau_{J+1} \le \tau_J$。一般情形下对尾部随机变量应用 Cauchy–Schwarz 不等式即可得到式 (2.84)。

定理 2.5 有两个直接含义。对 $h_{\mathrm{KL}}(v) = \log \frac{\pi_k(v|s)}{\pi_{k,n}(v|s)}$ 或 $h_T(v) = \log \frac{\pi_k(v|s)}{\pi_T(v|s)}$，$h$ 可能正也可能负，因此不能声称“增大 J 必然单调减小截断 bias”；能够保证的是尾部二阶矩和上界下降。对 $h_Z(v) = \exp(\eta r_k(s,v)) \ge 0$，尾部均值本身单调下降，所以纯截断的 Z_k 估计具有严格的单侧负偏差，而且随 J 减小。这正是 2602.04417 中 truncated KL 与 tail-corrected Top-J KL 的数学区别。

如果最终对象是 score 加权的 policy gradient，使用第一章的 score $\psi_{k,n}$，把 $h(v)$ 换成向量 $h(v)\psi_{k,n}(v)$，定理逐坐标成立，并得到

$$\mathrm{Bias}(\widehat{H}_J^{\mathrm{tr}}) = -\mathbb{E}_p[\mathbf{1}\{v \notin S_J\} h(v)\psi_{k,n}(v)], \qquad \mathrm{Cov}(\widehat{H}_{J,m}) = \frac{1}{m}\mathrm{Cov}_p(\mathbf{1}\{v \notin S_J\} h(v)\psi_{k,n}(v)). \tag{2.86}$$

这描述的是“估计最终梯度权重”的误差，而不是对 detached 估计量求导。本章 Algorithm 5 采用这种解析权重实现：先解析得到 score-function 公式，再把 $\widehat{h}$ 整体 stop-gradient。因此实现不需要保存估计量的 autograd 图；只需控制式 (2.86) 中的数值 bias 和 variance。

对 Z_k，头尾分解应先估计 Z_k 再取对数。令 $S_Z(s)$ 为 $((1-\eta)\log \pi_k + \eta \log \pi_T)$ 的 top-J 索引，则

$$\widehat{Z}_k(s) = \sum_{v \in S_Z(s)} \pi_k(v \mid s)^{1-\eta} \pi_T(v \mid s)^{\eta} \tag{2.87}$$

$$+ \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_Z(s)\} \left(\frac{\pi_T(a_j \mid s)}{\pi_k(a_j \mid s)}\right)^{\eta}, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.88}$$

式 (2.88) 对 Z_k 无偏，但 Jensen 不等式给出

$$\mathbb{E}[\log \widehat{Z}_k] \le \log Z_k, \qquad \mathbb{E}[\log \widehat{Z}_k] - \log Z_k \approx -\frac{\mathrm{Var}(\widehat{Z}_k)}{2Z_k^2}. \tag{2.89}$$

尾部重要性比率具有长尾时，单 token plug-in 估计尤其不稳定；裁剪比率可降方差，但会引入额外偏差。$\eta = 1$ 时 $Z_k = 1$，所以 $\log Z_k = 0$ 精确已知；$\eta = 0$ 时同样如此。$0 < \eta < 1$ 时，若不需要 PMD-Part，PMD-Mean/BPO 可以绕开这项 log-of-mean 偏差。

定理 2.6 (Partition function 的 log-of-mean 偏差)

设 $\widehat{Z}_{J,m}$ 是式 (2.88) 的尾部校正估计，$\mathbb{E}[\widehat{Z}_{J,m}] = Z_k > 0$，假设有限词表上 anchor 与 teacher 均为正概率，且头部集合固定。此时 $\widehat{Z}_{J,m}$ 有与 m 无关的正下界及有限上界。记 $V_J = \mathrm{Var}(\mathbf{1}\{a \notin S_Z\}(\pi_T(a \mid s)/\pi_k(a \mid s))^\eta)$。当 m 足够大时，

$$\mathbb{E}[\log \widehat{Z}_{J,m}] - \log Z_k = -\frac{V_J}{2mZ_k^2} + O(m^{-3/2}), \tag{2.90}$$

$$\mathrm{Var}(\log \widehat{Z}_{J,m}) = \frac{V_J}{mZ_k^2} + O(m^{-3/2}). \tag{2.91}$$

若 $J \geq 1$ 并改用纯头部估计 $Z_J^{\mathrm{tr}} = \sum_{v \in S_Z} \pi_k(v)^{1-\eta}\pi_T(v)^\eta$，则

$$Z_J^{\mathrm{tr}} - Z_k = -\tau_J^Z \leq 0, \qquad \log Z_J^{\mathrm{tr}} - \log Z_k \leq 0, \tag{2.92}$$

其中 $\tau_J^Z \geq 0$ 是式 (2.79) 对 h_Z 的尾部均值。因而纯截断的 log-partition bias 是确定性的单侧偏差，而尾部校正的 plug-in log 估计是由方差诱导的负偏差。 ♡

证明 令 $\varepsilon_Z = \widehat{Z}_{J,m} - Z_k$。由无偏性，$\mathbb{E}[\varepsilon_Z] = 0$，且 $\mathbb{E}[\varepsilon_Z^2] = V_J/m$。在 Z_k 邻域对 $f(z) = \log z$ 作三阶 Taylor 展开：

$$\log(Z_k + \varepsilon_Z) = \log Z_k + \frac{\varepsilon_Z}{Z_k} - \frac{\varepsilon_Z^2}{2Z_k^2} + R_3, \tag{2.93}$$

其中在三阶矩有界时 $\mathbb{E}|R_3| = O(m^{-3/2})$。取期望并使用 $\mathbb{E}[\varepsilon_Z] = 0$ 得到第一式。对同一展开取方差，首阶随机项为 ε_Z/Z_k，故 $\mathrm{Var}(\log \widehat{Z}_{J,m}) = V_J/(mZ_k^2) + O(m^{-3/2})$。最后，$h_Z \geq 0$ 给出 $\tau_J^Z \geq 0$，所以 $Z_J^{\mathrm{tr}} \leq Z_k$；由于 log 单调递增，第二个不等式随之成立。

定理 2.6 说明了为什么不能把“无偏的 $\widehat{Z}_k$”直接等同于“无偏的 $\log Z_k$”。在 PMD-Part 中，若使用 plug-in 估计，$\log Z_k$ 的误差会进入每个 token 的 residual；在完整词表路径上，该误差乘以 anchor 下的 student score 均值，一般不为零；sampled-token 路径还承担随机 score 的额外方差。因此 PMD-Part 对 m、J 和尾部比率的要求严格于 PMD-Mean/BPO。当 m 个样本独立且把同一 prefix 的梯度平均时，partition 诱导的梯度方差按 $1/m$ 下降；当外层有 B 个相互独立 prefix 时，条件于 prefix 的这部分方差进一步按 $1/B$ 下降，但 prefix coverage 误差不随 m 消失。

$\log Z_k$ 的展开估计：从 Z_k 的 plug-in 走向可控偏差

直接计算 $\log \widehat{Z}_k$ 是最简单的方案，但它把非线性的 log 放在 Monte Carlo 均值之后，必然产生 Jensen bias。对于 OPD，Z_k 具有更特殊的结构：

$$Z_k(s) = \mathbb{E}_{a \sim \pi_k}\left[e^{\eta r_k(s,a)}\right], \qquad r_k(s,a) = \log \pi_T(a \mid s) - \log \pi_k(a \mid s). \tag{2.94}$$

因此 $\log Z_k$ 是随机变量 r_k 的 cumulant-generating function 在 η 处的值。令 $\kappa_j(r_k)$ 为 r_k 的第 j 阶 cumulant，则在零点 Taylor 级数的收敛半径内

$$\log Z_k(s) = \sum_{j=1}^{\infty} \frac{\eta^j}{j!}\kappa_j(r_k). \tag{2.95}$$

前两项为

$$\log Z_k(s) = \eta\,\mathbb{E}[r_k] + \frac{\eta^2}{2}\mathrm{Var}(r_k) + R_3(s), \tag{2.96}$$

其中 R_3 收集三阶及以上 cumulant。因为 $\mathbb{E}[r_k] = -\mathcal{K}_k^T$，二阶近似也可以写成

$$\log Z_k(s) \approx -\eta\mathcal{K}_k^T(s) + \frac{\eta^2}{2}\mathrm{Var}_{a \sim \pi_k}[r_k(s,a)]. \tag{2.97}$$

这给出了比 $-\eta\widehat{\mathcal{K}}_k^T$ 更准确的近似：只使用均值会遗漏 log-sum-exp 的二阶曲率项，而该项在 teacher 与 anchor 差异较大时不可忽略。

若从同一个 prefix 取得 m 个 auxiliary token，令 $\widehat{\kappa}_j$ 为对应的 unbiased j 阶 k-statistic，并定义

$$\widehat{L}_{L,m}(s) = \sum_{j=1}^{L} \frac{\eta^j}{j!} \widehat{\kappa}_j(r_k). \tag{2.98}$$

则

定理 2.7 (Cumulant 截断估计器的 bias 与方差)

固定有限词表，假设 $\pi_k(v \mid s) > 0$、$\pi_T(v \mid s) > 0$。令

$$\varphi(t) = \log \mathbb{E}_{\pi_k}[e^{tr_k} \mid s], \qquad p_t(v \mid s) = \frac{\pi_k(v \mid s) e^{tr_k(s,v)}}{\mathbb{E}_{\pi_k}[e^{tr_k} \mid s]}.$$

取固定展开阶数 $L \geq 1$，样本数 $m \geq L$。第 j 阶 k-statistic 无偏估计 $\varphi^{(j)}(0) = \kappa_j(r_k)$，故

$$\mathbb{E}[\widehat{L}_{L,m}] - \log Z_k = -\frac{\eta^{L+1}}{L!} \int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\, du, \tag{2.99}$$

$$\mathrm{Var}(\widehat{L}_{L,m}) = O(m^{-1}). \tag{2.100}$$

余项满足

$$\left| \mathbb{E}[\widehat{L}_{L,m}] - \log Z_k \right| \leq \frac{|\eta|^{L+1}}{(L+1)!} \sup_{t \in [0,\eta]} \left| \kappa_{L+1}^{p_t}(r_k) \right|. \tag{2.101}$$

其中 $\kappa_{L+1}^{p_t}$ 是倾斜分布 p_t 下的 cumulant。

证明 有限词表和正概率使 r_k 有界，φ 在实轴上光滑。对指数倾斜分布求导可得

$$\varphi'(t) = \mathbb{E}_{p_t}[r_k], \qquad \varphi''(t) = \mathrm{Var}_{p_t}(r_k), \qquad \varphi^{(j)}(t) = \kappa_j^{p_t}(r_k).$$

Taylor 积分余项给出

$$\varphi(\eta) = \sum_{j=1}^{L} \frac{\eta^j}{j!} \varphi^{(j)}(0) + \frac{\eta^{L+1}}{L!} \int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\, du.$$

估计器前 L 项逐项无偏，因此其 bias 是余项的负值。对积分取绝对值并使用 $\int_0^1 (1-u)^L du = 1/(L+1)$，得到上界。固定阶 k-statistic 是有界核 U-statistic 的有限线性组合，其方差和相互协方差均为 $O(m^{-1})$，从而得到估计器方差。这里展开的是 log-mgf，余项必须用倾斜 cumulant 控制，不能套用 $e^{\eta r_k}$ 本身的 Taylor 余项界。

对 OPD 的常用二阶实现，$L = 2$ 时可以直接使用样本均值和无偏样本方差：

$$\widehat{L}_{2,m}(s) = \eta \bar{r}_k(s) + \frac{\eta^2}{2} \widehat{\mathrm{Var}}(r_k(s,\cdot)). \tag{2.102}$$

它不再具有 log-of-mean 的 $O(m^{-1})$ Jensen bias；剩余 bias 是明确的 cumulant truncation bias。代价是需要估计方差，并且当 $\eta|r_k|$ 较大时，三阶及以上 cumulant 不能忽略。因此它适合 teacher/anchor 接近、r_k 集中的阶段，不适合重要性比率重尾的阶段。

Top-J 头部还可以进一步降低展开的尾部误差。令

$$Z_H = \sum_{v \in S_Z} \pi_k(v)^{1-\eta} \pi_T(v)^{\eta}, \qquad u(a) = \mathbf{1}\{a \notin S_Z\} \left(\frac{\pi_T(a)}{\pi_k(a)} \right)^{\eta}, \qquad \tau = \mathbb{E}_{\pi_k}[u(a)], \tag{2.103}$$

这里 S_Z 含 J 个头部 tokens。取 $J \geq 1$ 和 $m \geq L$，使 $Z_H > 0$ 且各阶 U-statistic 有定义。则 $Z_k = Z_H + \tau$。当 $\zeta = \tau / Z_H < 1$ 时，

$$\log Z_k = \log Z_H + \sum_{\ell=1}^{\infty} \frac{(-1)^{\ell+1}}{\ell} \zeta^{\ell}. \tag{2.104}$$

用 m 个尾部样本构造

$$\widehat{\tau^{\ell}} = \binom{m}{\ell}^{-1} \sum_{1 \leq i_1 < \cdots < i_\ell \leq m} \prod_{q=1}^{\ell} u(a_{i_q}), \qquad a_i \overset{\text{iid}}{\sim} \pi_k, \tag{2.105}$$

这是 τ^ℓ 的无偏 U-statistic。于是可定义

$$\widehat{L}_{J,L}(s) = \log Z_H + \sum_{\ell=1}^{L} \frac{(-1)^{\ell+1}}{\ell Z_H^\ell} \widehat{\tau}^\ell. \tag{2.106}$$

它的期望等于式 (2.104) 的前 L 项，且截断余项满足

$$\left| \mathbb{E}[\widehat{L}_{J,L}] - \log Z_k \right| \le \frac{\zeta^{L+1}}{(L+1)(1-\zeta)}. \tag{2.107}$$

这个估计器在 J 增大时更有意义：Z_H 增大、ζ 减小，二阶或三阶展开就能达到很小的确定性 truncation bias；$J = 0$ 时 $Z_H = 0$，应退回 cumulant 展开或直接使用正值的 $\log \widehat{Z}$ plug-in。实际实现中建议先用 $L = 2$，同时记录 $\widehat{\zeta}$、plug-in 与展开估计的差异，用它判断是否进入重尾区域。

2602.04417 的合成图可以作为本节偏差–方差实验的模板。论文固定 $|\mathcal{V}| = 32000$，令 reference logits 为 $\mathcal{N}(0, I)$，当前策略 logits 为 $s\mathcal{N}(0, I)$，通过调整 s 使 $\sum_{j \in \mathrm{Top}(\pi, 32)} \pi(j)$ 接近 $\{0.2, 0.5, 0.8, 0.9\}$。对

$$J \in \{4, 8, 16, 32, 64, 128, 256\}, \qquad B \in \{1, 2, 4, \ldots, 32768\}.$$

分别计算 sampled、纯截断和 tail-corrected Top-J 的 token-logit 真梯度与估计梯度，并绘制

$$\mathrm{RelRMSE} = \frac{\sqrt{\mathbb{E}\|\widehat{g} - g_{\mathrm{true}}\|_2^2}}{\|g_{\mathrm{true}}\|_2}. \tag{2.108}$$

交点就是论文所谓 critical sample size。官方仓库 https://github.com/LunjunZhang/ema-pg 公开了 `compute_memory_efficient_kl`、K3^{++}/K4/K5 和 GPU top-J benchmark，但没有公开生成 `simulated_topk_kl_four_masses_v5.pdf` 的脚本；因此我们可以按上述协议在本项目中重建一份，并把 OPD 的 $\log Z_k$ plug-in、二阶 cumulant 和 Top-J 尾部展开作为额外曲线。图中应同时报告 value bias、gradient RelRMSE、尾部命中率和峰值显存，不能只画 KL 数值方差。

偏差–方差定理：从 KL 数值到最终 policy gradient

对一个 prefix 的任意估计器 $\widehat{q}$，最终关心的是带 score 的量 $\widehat{g} = \widehat{q} \nabla_\theta \log \pi_{k,n}$。其均方误差分解为

$$\mathbb{E}\|\widehat{g} - g\|^2 = \|\mathbb{E}[\widehat{g}] - g\|^2 + \mathrm{tr}\,\mathrm{Cov}(\widehat{g}). \tag{2.109}$$

因此，单独比较 $\widehat{\mathcal{K}}$ 的数值方差并不足够：一个有轻微截断偏差但尾部方差极低的估计器，可能比无偏但重尾的 sampled estimator 产生更小的梯度 MSE。2602.04417 的 Top-J 结论正是这个取舍：加入尾部校正保持无偏，代价是尾部采样方差；只保留头部则引入可控的截断偏差。

对 OPD 的 PMD-Part，$\log Z_k$ 的误差直接进入 residual，而 residual 又乘以 score。若使用 $\widehat{c}_k = \log \widehat{Z}_k$，令 $\varepsilon_Z = \widehat{c}_k - \log Z_k$，则单 prefix 的梯度误差包含

$$\varepsilon_Z^{\mathrm{grad}} = \varepsilon_Z \, \mathbb{E}_{v \sim \pi_k} \left[\nabla_\theta \log \pi_{k,n}(v \mid s) \right] \tag{2.110}$$

以及 ε_Z 与 sampled score 的协方差项。完整词表下 score 均值可以精确求和，但只有当 student 等于 anchor 等特殊条件成立时才为零；sampled-token 下即使 partition 估计与 token 独立，其均值误差仍会乘以这个非零 score 均值，有限 batch 还引入随机梯度噪声。故 PMD-Part 对 partition 估计的要求比 BPO/PMD-Mean 更严格。

对同一 prefix 同时估计中心和 policy-gradient 权重时，还要考虑协方差：若 $\widehat{c}$ 与 score 使用同一枚 token，$\mathbb{E}[\widehat{c}\widehat{g}]$ 一般不等于 $\mathbb{E}[\widehat{c}]\mathbb{E}[\widehat{g}]$。采用独立的 auxiliary next-token 样本估计中心，或使用 leave-one-out center，可以消除这类自耦合偏差；代价是额外的 token 抽样和少量 log-prob 存储。跨 prefix 聚合只能降低总体均值方差，不能把不同条件分布下的样本变成同一 conditional center。

最后，prefix 覆盖误差与 token 估计误差应分开记录。即使 token-level estimator 在给定 s 上无偏，rollout 只访问由 π_k 诱导的有限 prefix 多重集，仍有 $\widehat{d}_k - d_k$ 的 outer 测度误差。增加 Top-J 或 auxiliary samples 只降低条件 token 方差，不能修复 prefix coverage；增加 rollout 数量或重新采样 outer batch 才能降低这一项。实验日志应至少分别保存：prefix 数量与重复率、KL/partition 的 batch 均值和方差、尾部采样次数、梯度范数与峰值显存。

Tail-aware 中心的梯度偏差与停止梯度语义

下面固定一个 prefix s 和一个 inner step，写 $q=\pi_k(\cdot\mid s)$、$p=\pi_{k,n}(\cdot\mid s)$、$T=\pi_T(\cdot\mid s)$。假设有限词表上的三者严格为正，p 关于参数可微，$\eta>0$，且 S_J 由冻结的 q 选出，因此求导时支持集不变。用相同的支持集定义两个遗漏的尾部形状项：

$$b_J^T(s)=q(S_J^c)\,\mathrm{KL}\big(q(\cdot\mid S_J^c)\|T(\cdot\mid S_J^c)\big), \tag{2.111}$$

$$b_{J,n}^S(s)=q(S_J^c)\,\mathrm{KL}\big(q(\cdot\mid S_J^c)\|p(\cdot\mid S_J^c)\big). \tag{2.112}$$

若尾部为空，两项按连续延拓定义为零。Tail-aware 的链式分解给出

$$\widehat{\mathcal{K}}_k^T=\mathcal{K}_k^T-b_J^T,\qquad \widehat{\mathcal{K}}_{k,n}^S=\mathcal{K}_{k,n}^S-b_{J,n}^S. \tag{2.113}$$

这些估计对固定 prefix 是确定性的，因而这里的偏差来自尾部聚合，并非来自额外 sampled token 的随机性。

定理 2.8 (Tail-aware Mean/BPO 解析更新的偏差)

令 $g_{\mathrm{Mean}}(s)$、$g_{\mathrm{BPO}}(s)$ 为精确条件 KL 中心的 score-function 梯度，$\widehat{g}_{\mathrm{Mean}}(s)$、$\widehat{g}_{\mathrm{BPO}}(s)$ 为替换成 Tail-aware 中心并对整个权重停止梯度后的条件期望。则

$$\widehat{g}_{\mathrm{Mean}}(s)-g_{\mathrm{Mean}}(s)=\eta b_J^T(s)\mathbb{E}_{a\sim q}[\nabla_\theta\log p(a)], \tag{2.114}$$

$$\widehat{g}_{\mathrm{BPO}}(s)-g_{\mathrm{BPO}}(s)=\left(b_J^T(s)-\frac{b_{J,n}^S(s)}{\eta}\right)\mathbb{E}_{a\sim q}[\nabla_\theta\log p(a)]. \tag{2.115}$$

相应的 BPO 近似残差

$$\widehat{R}_{k,n}^{\mathrm{BPO}}(a)=\log\frac{p(a)}{q(a)}+\widehat{\mathcal{K}}_{k,n}^S-\eta\left(\log\frac{T(a)}{q(a)}+\widehat{\mathcal{K}}_k^T\right) \tag{2.116}$$

满足

$$\mathbb{E}_q[\widehat{R}_{k,n}^{\mathrm{BPO}}]=-b_{J,n}^S+\eta b_J^T. \tag{2.117}$$

对任意固定 prefix 测度 d，总体偏差是上述条件偏差关于 d 的期望。

证明 精确 Mean 残差为 $A_\theta(a)=\log(p(a)/q(a))-\eta(\log(T(a)/q(a))+\mathcal{K}_k^T)$。代入 $\widehat{\mathcal{K}}_k^T=\mathcal{K}_k^T-b_J^T$，逐动作得到

$$\widehat{A}_\theta(a)=A_\theta(a)+\eta b_J^T.$$

两者分别乘以 $\nabla_\theta\log p(a)$，在同一冻结分布 q 下取期望，即得 Mean 的偏差公式。对于 BPO，两个中心的替换给出

$$\widehat{R}_{k,n}^{\mathrm{BPO}}(a)=R_{k,n}^{\mathrm{BPO}}(a)-b_{J,n}^S+\eta b_J^T.$$

精确残差的均值为

$$\mathbb{E}_q[R_{k,n}^{\mathrm{BPO}}]=-\mathcal{K}_{k,n}^S+\mathcal{K}_{k,n}^S-\eta(-\mathcal{K}_k^T+\mathcal{K}_k^T)=0.$$

对替换后的残差取期望便得到所述非零均值。再将逐动作残差差除以 η，乘以 score，并在 q 下取期望，得到 BPO 的偏差公式。最后在固定 d 下积分，期望线性性给出总体结论。

若 $\|\nabla_\theta\log p(a)\|\le G(s)$，三角不等式还给出

$$\|\mathbb{E}_d[\widehat{g}_{\mathrm{Mean}}-g_{\mathrm{Mean}}]\|\le\eta\mathbb{E}_d[b_J^T G], \tag{2.118}$$

$$\|\mathbb{E}_d[\widehat{g}_{\mathrm{BPO}}-g_{\mathrm{BPO}}]\|\le\mathbb{E}_d[|b_J^T-b_{J,n}^S/\eta|G]. \tag{2.119}$$

因此 BPO 的两个中心误差可能抵消，也可能被 $1/\eta$ 放大。单独降低 teacher KL 的 RMSE 不能保证 BPO 梯度误差同步下降。在 $p=q$ 时，$b_{J,n}^S=0$ 且 $\mathbb{E}_q[\nabla_\theta\log p]=\nabla_\theta\sum_a p(a)=0$，所以两种更新的条件偏差都为零；inner 更新后一般不再满足该条件。

命题 2.8 (Tail-aware BPO 平方损失与 SG 更新的区别)

若 student Tail-aware 中心保留梯度，近似平方目标 $\widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \mathbb{E}_q[(\widehat{R}^{\mathrm{BPO}}_{k,n})^2]/(2\eta)$ 的完整梯度为

$$\nabla_\theta \widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \widehat{g}_{\mathrm{BPO}}(s) + \left(b^T_J - \frac{b^S_{J,n}}{\eta}\right) \nabla_\theta \widehat{\mathcal{K}}^S_{k,n}(s). \tag{2.120}$$

Algorithm 5 使用第一项，即对原始 BPO 解析梯度的近似；它一般不等于替换中心后的平方损失梯度。

证明 q, T, S_J 均冻结，因此

$$\nabla_\theta \widehat{R}^{\mathrm{BPO}}_{k,n}(a) = \nabla_\theta \log p(a) + \nabla_\theta \widehat{\mathcal{K}}^S_{k,n}.$$

对平方目标使用链式法则，得到

$$\nabla_\theta \widehat{\mathcal{L}}_{\mathrm{BPO}} = \frac{1}{\eta}\mathbb{E}_q[\widehat{R}^{\mathrm{BPO}}_{k,n} \nabla_\theta \log p] + \frac{1}{\eta}\mathbb{E}_q[\widehat{R}^{\mathrm{BPO}}_{k,n}] \nabla_\theta \widehat{\mathcal{K}}^S_{k,n}.$$

第一项是 SG 权重的 score-function 更新；将上一条定理的残差均值代入第二项，即得结论。精确中心下残差均值为零，第二项消失；有限支持集的 Tail-aware 中心不保证这一消去。

Mean 的情况不同：teacher 中心完全冻结，故 $\nabla_\theta \widehat{A}_\theta = \nabla_\theta \log p$。其平方损失与 $\mathrm{stopgrad}(\widehat{A}_\theta) \log p$ 在每个 sampled action 上具有相同梯度，而不仅是期望梯度相同。上述结论都针对固定参数与固定条件分布；反复复用一批 rollout 并用它更新参数，还会产生有限数据的优化与泛化误差，不能由条件无偏性消除。

缓存上，CPU/NVMe 保存 token IDs、attention mask、response mask、rollout 动作以及 anchor/teacher action log-prob。Tail-aware 路径另外冻结 anchor 的 top-J IDs、头部 log-prob、尾部总质量和 teacher KL 中心；student 的 action log-prob、这些 IDs 上的 log-prob 和尾部质量每个 inner step 重算。Teacher 中心构造完即可释放其完整 logits，无需保存 teacher 全词表分布。保存完整 logits 的代价是 $O(BH|\mathcal{V}|)$，保存 top-J 摘要是 $O(BHJ)$。以 $|\mathcal{V}| = 150{,}000$、FP16 为例，一个 prefix-token 的完整 logits 约 300 kB，8192 token 单序列约 2.46 GB；因此全词表 logits 不放进 replay buffer。GPU 只保留当前 microbatch 的 student 激活及打分 logits，完成摘要与动作权重计算后释放不再需要的打分张量。此路径没有额外 anchor token 抽样；中心的条件采样方差为零，但保留定理 2.8 给出的尾部形状偏差。PMD-Part 暂不启用，因为其 $\log Z_k$ 需要另一套估计与误差控制。

Algorithm 5 直接使用 rollout 保存的 (s, a)，每个 token occurrence 具有相同权重。式中的求和是经验训练目标的梯度：若使用 microbatch，将 $|\mathcal{B}_k|^{-1}$ 换成该批有效 response token 的归约权重，并在累积与分布式归约时保持一致。同一轨迹中的 prefix 具有相关性，随机轨迹长度也影响经验归一化；因此这条有限数据实现不意味着总体 token 测度梯度具有有限样本严格无偏性。对固定 prefix 与固定参数，动作来自 π_k 时，MDPO 的 $\pi_{k,n}/\pi_k$ 比率将条件动作期望变换到当前 student；Mean/BPO 原本就在 anchor 测度下定义，故没有该比率。所有三种权重都在当前 inner 参数处重新计算再停止梯度，而不是在 outer 开始时固定至整个 inner loop。

这里 Tail-aware 只替换 Mean/BPO 的数值中心，解析 score-function 权重整体停止梯度。它不是把动作期望改成头部求和：动作仍按 anchor 分布积分或采样，尾部动作仍参与 reward 和 score 更新。MDPO 的期望按当前 student 分布，若使用冻结 anchor 动作，必须乘以停止梯度的 $\pi_{k,n}/\pi_k$ 测度比。由于 Tail-aware 对中心存在负偏差，有限 J 的 Mean/BPO 更新一般属于有偏近似；$J = |\mathcal{V}|$ 时必然恢复精确解析梯度，有限支持集下也可在上述偏差项为零时恢复。参数 EMA 与概率混合也必须分别实现；以下 categorical 验证采用概率混合，真实模型参数 EMA 不能被声称与它等价。算法的 soft 分支要求策略类能表示逐 prefix 的概率混合；一般神经网络策略类不满足这一封闭性，本文真实模型训练采用 hard sync。若另行采用参数 EMA，更新式为 $\theta_{k+1} = (1-\rho)\theta_k + \rho\theta_{k,N}$，并令 $\pi_{k+1} = \pi_{\theta_{k+1}}$；这是另一条动力学，不能套用概率混合的恒等式。

算法中的同步发生在整个 inner loop 结束之后。因而在固定 k 的所有 N 次更新中，rollout 测度、anchor ratio π_k/π_T 以及所有 mirror target 都保持不变；只有 student 参数 $\theta_{k,n}$ 变化。hard sync 令下一轮 anchor 完全等于 inner 末端 student，soft sync 则令下一轮 anchor 是旧 anchor 与 inner 末端 student 的凸组合。完成同步后丢弃 $\widehat{d}_k$，使用新的 π_{k+1} 重新 rollout，而不是继续复用旧 rollout。若 inner loop 没有收敛，$\pi_{k,N}$ 只是当前固定 mirror 子问题的有限步近似解；outer 动力学仍由上述同步映射严格定义。

只有 sampled next token：无完整词表时的估计路径

如果每个 prefix 只有 rollout 中的下一个 token $a \sim \pi_k(\cdot \mid s)$，仍然可以无偏观测 $r_k(s,a)$，但不能从一个样本无偏得到 $\log Z_k(s)$：先估计 Z_k 再取对数会产生 plug-in bias。因此 sampled-token 路径不应把 PMD-Part 的 exact $\log Z_k$ 假装已知。可行选择如下。

第一，使用 BPO 或 PMD-Mean，以同一个 prefix 的多条 sampled actions 估计 conditional center；它们不需要显式的 $\log Z_k$。跨 prefix 的平均值一般不等于这个条件中心，不能替代它。第二，MDPO 直接使用 anchor 采样下的重要性加权 score，所需信息仅为同一个 sampled token 的 teacher、anchor 和当前 student log-prob。第三，如果只有一条 action，却仍想做 PMD-Part，只能使用外部 baseline 或 self-normalized $\widehat{\log Z}$，并在理论和日志中标记其 bias。MDPO 的解析梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{a\sim\pi_k}\left[\mathrm{sg}\left\{\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}\left(\frac{1}{\eta}\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}\right)\right\}\nabla_\theta \log \pi_{k,n}(a \mid s)\right].$$

该等式先在完整分布上微分，再用 $\pi_{k,n}/\pi_k$ 换测度；student 下常数 $1/\eta$ 的 score 项期望为零。因而这里无需额外选择 KL 数值估计器。整个乘数停止梯度，实现的是已解析的梯度；这个 surrogate 的数值不是 mirror objective 的数值。有限冻结数据上的重要性加权结果仍有采样误差，不能把总体无偏性解释为任意数据复用后的条件无偏性。

对单个 sampled token，PMD-Part 的可实现 loss 是带 baseline 的近似

$$\widehat{\ell}_{\mathrm{Part}} = \frac{1}{2}\left[\eta(r_k(s,a) - b(s)) - U_{k,n}(s,a)\right]^2,$$

它只有在 $b(s) = \log Z_k(s)/\eta$ 时才等于 exact residual；任意其他 baseline 会留下一个 prefix-dependent constant，因而改变 PMD-Part 的有限参数投影。BPO 的中心化 residual 则可用同 prefix 的 m 个 sampled tokens 构造，$m = 1$ 时必须使用跨样本或 frozen center。

完整 vocabulary 与 sampled-token 两条路径的区别是信息论上的：前者能精确知道整个 categorical mirror target，后者只能无偏知道在 anchor 下抽到的一个 action 的 reward。对每个给定方法，两条信息访问路径在无限样本、无函数类误差且 center/partition 估计一致时具有相同总体解；PMD-Mean 的解是 Lambert-W 分布，另外三种方法的解是 Gibbs 分布。有限 batch 下，full-vocabulary 的主要误差是参数优化和 prefix coverage，sampled-token 额外承担 reward、center、KL ratio 和 prefix reuse 的估计方差。

2.6 OPD 的七种可运行算法与统一 outer–inner pipeline

本节把实际实现中的七种算法放在同一个 outer–inner pipeline 中。前两种是无 mirror 正则的 OPD baseline，第三种是删除 mirror 项后的冻结 reward baseline，后四种是固定 anchor 的 mirror inner：Token-IS OPD、On-policy OPD、Frozen-reward OPD、PMD-Part、PMD-Mean、BPO 和 MDPO。这样命名后，“on-policy” 只描述 rollout 测度，“mirror” 只描述目标中是否保留 $\eta^{-1}\,\mathrm{KL}(p\|\pi_k)$；两者不能互相替代。

每个 outer step 都遵循相同顺序：冻结 π_k 和 teacher，生成或读取 rollout，在固定 prefix 测度 d_k 上做 J 次 inner 更新，最后执行一次 outer sync。On-policy OPD 在每轮重新 rollout 且 $J = 1$ 时是 Token-IS OPD 的严格特例。四个 mirror inner 的 sampled-token PG 系数已经在第 2.3 节完全展开；本节把它们与可运行 baseline、收敛解和实现入口对应起来。

在 tabular policy、完整词表、精确期望和 inner 完全收敛时，后三个 mirror 方法 PMD-Part、BPO、MDPO 的共同 OPD 解为

$$\pi^\star_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)\exp(\eta r_k(s,a))}{\mathbb{E}_{v\sim\pi_k}\exp(\eta r_k(s,v))} \propto \pi_k(a \mid s)^{1-\eta}\pi_T(a \mid s)^\eta. \tag{2.121}$$

PMD-Mean 的固定点是 Lambert-W 投影，通常不等于式 (2.121)。当 $\eta = 1$ 时 Gibbs 解等于 teacher；当 $\eta \to \infty$ 时，mirror 项消失；它只有在首个 $p = \pi_k$ 的 inner step 上与 On-policy OPD 的 score 系数相同，后续仍然优化冻结的 r_k，因此不是 On-policy OPD 的整体训练过程。因此“MDPO 一直 on-policy”只会去掉 MDPO 的 token-IS 测度校正，不会在有限 η 下自动变成 On-policy OPD。

表 2.2: OPD 七种算法的训练测度、PG 系数与精确 inner 固定点

算法	rollout / inner 测度	sampled-token PG 系数	精确固定点
Token-IS OPD	anchor π_k，token-IS $w = \pi_{k,n}/\pi_k$	$-w(r_\theta + \mathcal{K}^T_{k,n})$	teacher-directed OPD
On-policy OPD	当前 student，$w = 1$	$-(r_\theta + \mathcal{K}^T_{k,n})$	Token-IS 的特例
Frozen-reward OPD ($\eta = +\infty$)	anchor π_k，$w = \pi_{k,n}/\pi_k$	$-wr_k$	$\arg\max r_k$ 上的分布
PMD-Part	anchor π_k	R^{Part}	Gibbs
PMD-Mean	anchor π_k	R^{Mean}	Lambert-W 投影
BPO	anchor π_k	R^{BPO}/η	Gibbs
MDPO	anchor π_k，$\omega_{k,n} = \pi_{k,n}/\pi_k$	$\omega_{k,n}(U/\eta - r_k)$	Gibbs

2.6.1 四个 mirror inner 的 OPD policy-gradient 形式

以下所有期望均为 $s \sim d_k$、$a \sim \pi_k(\cdot \mid s)$，并且括号中的整项都使用停止梯度。记

$$U_{k,n}(s,a) = \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}, \quad r_k(s,a) = \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}, \quad \mathcal{K}^T_k(s) = \mathrm{KL}(\pi_k \| \pi_T), \quad \mathcal{K}^S_{k,n}(s) = \mathrm{KL}(\pi_k \| \pi_{k,n}). \tag{2.122}$$

由于 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}^T_k(s)$，四个系数完全写成：

$$\nabla_\theta \mathcal{L}_{\text{PMD-Part}} = \mathbb{E}\Big[\mathrm{sg}\Big(U_{k,n} - \eta r_k + \log \mathbb{E}_{v \sim \pi_k} e^{\eta r_k(s,v)}\Big) \nabla_\theta \log \pi_{k,n}(a \mid s)\Big], \tag{2.123}$$

(2.124)

$$\nabla_\theta \mathcal{L}_{\text{PMD-Mean}} = \mathbb{E}\big[\mathrm{sg}\big(U_{k,n} - \eta[r_k + \mathcal{K}^T_k]\big) \nabla_\theta \log \pi_{k,n}(a \mid s)\big], \tag{2.125}$$

$$\nabla_\theta \mathcal{L}_{\text{BPO}} = \mathbb{E}\left[\mathrm{sg}\left(\frac{U_{k,n} + \mathcal{K}^S_{k,n}}{\eta} - r_k - \mathcal{K}^T_k\right) \nabla_\theta \log \pi_{k,n}(a \mid s)\right], \tag{2.126}$$

$$\nabla_\theta \mathcal{L}_{\text{MDPO}} = \mathbb{E}\left[\mathrm{sg}\left(\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}\left[\frac{U_{k,n}}{\eta} - r_k\right]\right) \nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.127}$$

PMD-Part 的 log-partition 项是 action-independent，但必须保留在 residual 中；PMD-Mean 使用 teacher KL 作为 reward center；BPO 还需要 student KL center；MDPO 则通过 $\pi_{k,n}/\pi_k$ 完成 student 测度校正。四式共同使用 anchor rollout，而 Token-IS/On-policy baseline 使用下面的 r_θ 和 $\mathcal{K}^T_{k,n}$，两组系数不能混写。

为避免把同一个比值写成两个对象，后文统一使用

$$\omega_{k,n}(s,a) := \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} = \exp(U_{k,n}(s,a)). \tag{2.128}$$

因此 $\omega_{k,n}$ 与 $e^{U_{k,n}}$ 在数学上完全相同：前者强调它是 importance ratio，后者强调它是 log-ratio 的指数表示。Token-IS 使用一般行为策略 β_k 时另记 $w_{k,n} = \pi_{k,n}/\beta_k$；只有 $\beta_k = \pi_k$ 时才有 $w_{k,n} = \omega_{k,n}$。

2.6.2 $\eta = 1$ 时 BPO、PMD-Mean 与 Token-IS vOPD 的比较

令 $q = \pi_k(\cdot \mid s)$、$p = \pi_{k,n}(\cdot \mid s)$、$T = \pi_T(\cdot \mid s)$，并写

$$\rho_{k,n}(s,a) := \log \frac{T(a)}{p(a)} = r_k(s,a) - U_{k,n}(s,a), \quad \mathcal{K}^T_{k,n}(s) := \mathrm{KL}(p \| T), \quad \mathcal{K}^T_k(s) := \mathrm{KL}(q \| T). \tag{2.129}$$

Token-IS vOPD 的 sampled-token 系数（负号对应最小化 reverse KL）是

$$c_{\text{vOPD}}(s,a) = -\mathrm{sg}\big[w_{k,n}(s,a)\big(\rho_{k,n}(s,a) + \mathcal{K}^T_{k,n}(s)\big)\big]. \tag{2.130}$$

其中 $w_{k,n} = p/\beta_k$；它把行为测度 β_k 变成当前 student 测度 p。

把四个 mirror 系数中的 η 设为 1，BPO 与 PMD-Mean 分别变成

$$c_{\text{BPO}}(s,a) = U_{k,n} + \mathcal{K}^S_{k,n} - r_k - \mathcal{K}^T_k = -\rho_{k,n} + \mathcal{K}^S_{k,n} - \mathcal{K}^T_k, \tag{2.131}$$

$$c_{\text{PMD-Mean}}(s,a) = U_{k,n} - r_k - \mathcal{K}^T_k = -\rho_{k,n} - \mathcal{K}^T_k, \tag{2.132}$$

并且

$$c_{\mathrm{BPO}} - c_{\mathrm{PMD\text{-}Mean}} = \mathcal{K}^S_{k,n}. \tag{2.133}$$

这个差值对 action 不变，但它乘的是在 q 下取样、在 p 上求 score 的梯度；因此只有在 $p = q$ 时才能直接用 $\mathbb{E}_p[\nabla \log p] = 0$ 把它删掉。

当第一个 inner step 使用刚刚 rollout 的策略作为 student 时，$p = q$，于是

$$U_{k,0} = 0, \quad \omega_{k,0} = 1, \quad \mathcal{K}^S_{k,0} = 0, \quad \mathcal{K}^T_{k,0} = \mathcal{K}^T_k, \tag{2.134}$$

从而 BPO、PMD-Mean 和 Token-IS vOPD 的逐 token 系数都退化为

$$c(s,a) = -\big(r_k(s,a) + \mathcal{K}^T_k(s)\big). \tag{2.135}$$

这解释了为什么三者在首个 on-anchor 更新上看起来等价。

对于后续 stale-rollout inner step，等价性消失。取 $\beta_k = q$，即 $w_{k,n} = \omega_{k,n}$，有

$$c_{\mathrm{PMD\text{-}Mean}} - c_{\mathrm{vOPD}} = (\omega_{k,n} - 1)\rho_{k,n} + \omega_{k,n}\mathcal{K}^T_{k,n} - \mathcal{K}^T_k, \tag{2.136}$$

$$c_{\mathrm{BPO}} - c_{\mathrm{vOPD}} = (\omega_{k,n} - 1)\rho_{k,n} + \omega_{k,n}\mathcal{K}^T_{k,n} - \mathcal{K}^T_k + \mathcal{K}^S_{k,n}. \tag{2.137}$$

第一项来自测度：vOPD 需要 $\omega_{k,n}$，而 PMD-Mean 与 BPO 的固定 anchor 梯度直接在 q 下计算。第二项来自中心：vOPD 使用当前 $p\|T$ 的 KL，mirror 方法使用固定 $q\|T$ 的 KL；BPO 还多出 $q\|p$ 的中心化项。所以 $\eta = 1$ 并不把 BPO 或 PMD-Mean 变成 Token-IS OPD；它们只有在 $p = q$ 的首步，或在精确收敛点 $p = T$ 的零梯度条件下相交。

另一方面，PMD-Part、BPO 和 MDPO 的共同 Gibbs 解在 $\eta = 1$ 时满足 $p = T$。PMD-Mean 仍然是 Lambert-W 投影，不能由上述代数恒等式改写成 vOPD，其有限 inner 轨迹与固定点都应单独记录。

2.6.3 $\eta = +\infty$：删除 Mirror Descent KL 项的 baseline

有限 η 的共同 mirror 目标为

$$F_{k,\eta}(p) = \frac{1}{\eta}\,\mathrm{KL}(p\|q) - \mathbb{E}_{a\sim p}[r_k(s,a)], \qquad q = \pi_k(\cdot \mid s), \quad r_k = \log\frac{\pi_T}{q}. \tag{2.138}$$

第一项就是 Mirror Descent 的 proximal KL。取 $\eta \to +\infty$ 后，$1/\eta$ 为零，得到冻结 reward 目标

$$F_{k,\infty}(p) = -\mathbb{E}_{a\sim p}[r_k(s,a)]. \tag{2.139}$$

这不是一个很弱的 mirror step，而是删除 anchor KL 后的另一个优化问题；其中 $r_k = \log(\pi_T/\pi_k)$ 在整个 outer 内冻结。

令当前 student 为 p_θ，并从 anchor q 的 rollout 取样。写 $\omega_\theta = p_\theta/q$，则冻结 reward 的 token-level score 梯度为

$$\nabla_\theta F_{k,\infty}(p_\theta) = -\mathbb{E}_{s\sim d_k,\, a\sim q}\left[\mathrm{sg}(\omega_\theta(s,a) r_k(s,a))\, \nabla_\theta \log p_\theta(a \mid s)\right]. \tag{2.140}$$

因此 MDPO 的 $\omega_\theta(U_\theta/\eta - r_k)$ 在 $\eta = +\infty$ 时只剩 $-\omega_\theta r_k$。Token-IS vOPD 则使用当前 reward $\rho_\theta = \log(\pi_T/p_\theta) = r_k - U_\theta$；两者只有第一个 inner step 相同，之后冻结 reward 不随 student 改变。

在完整词表和 inner 完全收敛时，令

$$m_k(s) = \max_{a:q(a)>0} r_k(s,a), \qquad A_k(s) = \{a : r_k(s,a) = m_k(s)\}. \tag{2.141}$$

有 $F_{k,\infty}(p) \geq -m_k(s)$，等号当且仅当 p 的全部质量落在 $A_k(s)$ 上。因此其最优集合是支持在最高 reward token 上的分布；若最大值唯一，最优策略退化为确定性 token。这正是有限 η Gibbs 解 $p^\star_{k,\eta} \propto q\exp(\eta r_k)$ 在 $\eta \to \infty$ 时的极限，通常不等于 teacher。

删除 proximal 项后，student 没有 anchor 约束，ω_θ 更容易重尾，Token-IS ESS 会下降，固定 reward 的 mode-seeking 还会导致 entropy collapse。有限学习率、gradient clipping 和有限 inner steps 只能减弱这些现象，不能改变目标本身。实验中应同时记录 $\max\omega_\theta$、ESS fraction、student entropy、$\mathrm{KL}(p_\theta\|q)$ 和 reward top-1 mass，不能只比较 teacher KL。

2.6.3.0.1 BPO 与 PMD-Mean 的 $\eta \to +\infty$ 极限。 前面的 argmax 结论是共同 Gibbs 型目标的结论，不能直接套到所有 inner 算法。BPO 与 PMD-Mean 的 residual 中含有 η，而 BPO 的平方损失还含有 $1/\eta$；因此需要区分“固定有限 η 先完成 inner 收敛，再令 $\eta \to +\infty$”和“固定当前 student 后直接取梯度系数极限”。

对 BPO，任意有限 $\eta > 0$ 的精确总体最优解仍是式 (2.121) 的 Gibbs 分布。零 residual 条件给出

$$U_\eta^\star(s,a) = \eta r_k(s,a) - \log Z_k(s), \qquad Z_k(s) = \mathbb{E}_{v\sim q}\left[e^{\eta r_k(s,v)}\right]. \tag{2.142}$$

令 $m_k(s) = \max_a r_k(s,a)$，则有限词表下

$$\lim_{\eta\to+\infty} p_\eta^\star(a \mid s) = \frac{q(a \mid s)\,\mathbf{1}\{r_k(s,a) = m_k(s)\}}{q(A_k(s) \mid s)}, \qquad A_k(s) = \{a : r_k(s,a) = m_k(s)\}. \tag{2.143}$$

所以 BPO 的“先 inner 收敛、后取极限”与 Frozen-reward OPD、PMD-Part 和 MDPO 的固定点相同：只保留最高 frozen reward 的 token；最大值唯一时退化为确定性 token。

另一方面，在当前 p_θ 固定且 $U_{k,n}$、$\mathcal{K}_{k,n}^S$ 不随 η 发散的局部极限下，BPO 的下降方向满足

$$-\nabla_\theta \mathcal{L}_{\mathrm{BPO}} \sim \mathbb{E}_{s\sim d_k,\, a\sim q}\left[(r_k(s,a) + \mathcal{K}_k^T(s))\nabla_\theta \log p_\theta(a \mid s)\right]. \tag{2.144}$$

这里整体学习率需要按 $1/\eta$ 重标度。系数是 centered frozen reward，而非未中心化的 r_k；常数 $\mathcal{K}_k^T$ 只有在 $p_\theta = q$ 的首个 inner step 上因 score 均值为零而消失。因此局部梯度极限与精确 Gibbs 极限描述的是同一条有限-η 轨迹的不同取极限方式，不能用前者替代后者。

PMD-Mean 的固定点不同。令

$$h_k(s,a) = r_k(s,a) + \mathcal{K}_k^T(s), \qquad \mathbb{E}_{a\sim q}[h_k(s,a)] = 0. \tag{2.145}$$

其精确有限-η 解为 Lambert-W 投影

$$p_\eta^\star(a \mid s) = \frac{q(a \mid s)}{\lambda_\eta(s)} W_0\left(\lambda_\eta(s) e^{\eta h_k(s,a)}\right), \qquad \lambda_\eta(s) = \mathbb{E}_{v\sim q}\left[W_0\left(\lambda_\eta(s) e^{\eta h_k(s,v)}\right)\right]. \tag{2.146}$$

命题 2.9 (PMD-Mean 的无限温度极限)

固定 prefix s，假设词表有限、$q(a) > 0$，且 h_k 非恒定。令 $H_+(s) = \mathbb{E}_{v\sim q}[h_k(s,v)_+] > 0$。则

$$\lim_{\eta\to+\infty} p_\eta^\star(a \mid s) = \frac{q(a \mid s)\, h_k(s,a)_+}{H_+(s)}. \tag{2.147}$$

当 $q = t$ 时 $h_k \equiv 0$，所有 η 的解均为 q，该式按退化情形单独理解。

证明 记 $W_\eta(a) = W_0(\lambda_\eta e^{\eta h_k(a)})$。由 (2.146)，$\lambda_\eta = \mathbb{E}_q W_\eta$。当 $h_k(a) > 0$ 时，Lambert–W 的渐近式 $W_0(x) = \log x - \log\log x + o(1)$ 给出 $W_\eta(a)/\eta \to h_k(a)$；当 $h_k(a) \le 0$ 时，$W_\eta(a)/\eta \to 0$。有限词表允许逐项取极限，故

$$\frac{\lambda_\eta}{\eta} = \mathbb{E}_q\left[\frac{W_\eta}{\eta}\right] \longrightarrow \mathbb{E}_q[h_{k+}] = H_+. \tag{2.148}$$

代回 $p_\eta^\star = qW_\eta/\lambda_\eta$ 即得结论。

因此 PMD-Mean 在 $\eta \to +\infty$ 时不执行 hard argmax。它保留所有 $h_k > 0$ 的 token，并按 $q(a)h_k(a)$ 分配质量；由于 $h_k = r_k + \mathcal{K}_k^T$，阈值是 $r_k > -\mathcal{K}_k^T$。在固定 student 上，PMD-Mean 的 residual 梯度除以 η 也形式上趋于

$$\frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Mean}} \longrightarrow -\mathbb{E}_{s\sim d_k,\, a\sim q}\left[h_k(s,a)\nabla_\theta \log p_\theta(a \mid s)\right], \tag{2.149}$$

但其精确 fixed point 仍由上述 Lambert-W 极限决定。BPO 的 fixed-point 极限是最高 reward 支持集上的分布，而 PMD-Mean 的 fixed-point 极限是正部加权分布；这解释了两者在有限 η 时都用于 mirror OPD、在无限 η 时却不再相同。

令 $q = \pi_k(\cdot \mid s)$、$p_\theta = \pi_\theta(\cdot \mid s)$、$T = \pi_T(\cdot \mid s)$。在固定 prefix 上，OPD 的 reverse-KL 目标为

$$J_s(\theta) = \mathrm{KL}(p_\theta \| T) = \mathbb{E}_{a\sim p_\theta}\left[\log p_\theta(a \mid s) - \log T(a \mid s)\right]. \tag{2.150}$$

写 $r_\theta(s,a) = \log T(a \mid s) - \log p_\theta(a \mid s)$，则对任意 p_θ-可积的 prefix，完整梯度是

$$\nabla_\theta J_s(\theta) = -\mathbb{E}_{a\sim p_\theta}\left[r_\theta(s,a)\nabla_\theta \log p_\theta(a \mid s)\right]. \tag{2.151}$$

常数 1 因为 $\mathbb{E}_{p_\theta}[\nabla \log p_\theta] = 0$ 而消失。

vOPD 风格的 baseline 取当前 student 与 teacher 的条件 reverse KL，记为

$$\mathcal{K}^T_{k,n}(s) = \mathrm{KL}(p_\theta \| T). \tag{2.152}$$

它与 action 无关，因此不会改变总体梯度：

$$\mathbb{E}_{p_\theta}[(r_\theta + \mathcal{K}^T_{k,n})\nabla \log p_\theta] = \mathbb{E}_{p_\theta}[r_\theta \nabla \log p_\theta]. \tag{2.153}$$

这个中心是控制变量，不是额外的 mirror penalty。实际实现用固定的 top-J anchor support 加尾部聚合近似 $\mathcal{K}^T_{k,n}$；$J = |\mathcal{V}|$ 时它是 exact。

2.6.4 On-policy OPD：每次 outer step 重新采样

第 k 个 outer step 先令 $\theta_{k,0} = \theta_k$，从当前 student $p_{\theta_{k,0}} = \pi_k$ 生成 rollout。每个 sampled token 都来自当前测度，所以用

$$\widehat{\ell}_{\mathrm{on}}(\theta; s, a) = -\,\mathrm{sg}\big(r_\theta(s,a) + \mathcal{K}^T_{k,n}(s)\big) \log p_\theta(a \mid s) \tag{2.154}$$

进行 score-function 更新。这里 r_θ 和 $\mathcal{K}^T_{k,n}$ 在构造该步梯度后整体停止梯度；它们不是再对同一个 surrogate 反向一次。若 inner 中做 $J > 1$ 个 optimizer step 而不重新 rollout，后续 step 已经是 stale-data 更新，不能继续称作严格 on-policy；本书实验将严格 on-policy baseline 定义为 $J = 1$。

算法中的负号对应最小化 $\mathrm{KL}(p\|T)$。它只使用一个 sampled action 的 reward；$\widehat{\mathcal{K}}^T_{k,0}$ 只作为 baseline，不能把它与 reward 相加后再把其梯度传回 teacher 或 student。实现中的 `mirror_opd_onpolicy` 正是这个形式，并将 anchor support 的 head 与 aggregate tail 缓存到 CPU/NVMe 可复用的 batch。

2.6.5 Token-IS OPD：复用 anchor rollout

若 rollout 来自 $q = \pi_k$，但 inner 当前 policy 是 p_θ，则对固定 prefix 的测度变换为

$$\mathbb{E}_{a\sim p_\theta}[h(a)] = \mathbb{E}_{a\sim q}\left[\frac{p_\theta(a \mid s)}{q(a \mid s)} h(a)\right]. \tag{2.155}$$

因此 token-IS baseline 使用

$$\widehat{\ell}_{\mathrm{IS}}(\theta; s, a) = -\,\mathrm{sg}\left[\frac{p_\theta(a \mid s)}{q(a \mid s)}\left(r_\theta(s,a) + \mathcal{K}^T_{k,n}(s)\right)\right] \log p_\theta(a \mid s). \tag{2.156}$$

当 $q(a \mid s) > 0$ 且 prefix s 的访问测度固定时，式(2.155) 对 action 条件分布是无偏的。它没有修正 outer rollout 的 prefix occupancy：若 student 在 inner 中改变了前缀分布，整条序列的 ratio $\prod_{t\le l} p_\theta(a_t \mid s_t)/q(a_t \mid s_t)$ 才能修正到新的轨迹测度，而 token-IS 只修正当前 prefix 下的下一个 token。这是本实验 baseline 的有意限定，避免长序列乘积带来的极端方差。

这里的 `mirror_opd_is` 使用 $J = 4$ 作为 stale-rollout 对照，且每一步重新计算 u_i 与中心；`mirror_opd_is_no_baseline` 则令 $\widehat{\mathcal{K}}^T_{k,n} = 0$，用于隔离控制变量的作用。重要性权重必须 stop-gradient，否则 surrogate 会多出 ∇w_i 项而不再是式 (2.151) 的 score 估计器。实际训练记录 `importance_ess` 和 `importance_ess_fraction`；当 w_i 重尾时，token-IS 的方差会随 $\mathbb{E}_q[w_i^2]$ 增长，即使其条件期望仍然无偏。

2.6.6 Pythia baseline 实验记录

实验使用 Pythia-14M student、Pythia-70M teacher、WikiText validation prefixes、top-$J = 32$ anchor support、温度 1.0、response length 64、batch 中 1024 有效 token、learning rate 10^{-6} 和 seed 42。两条训练均运行 32 个 outer step；on-policy 每轮只更新一次，token-IS 每轮复用同一 rollout 做 4 个 inner step。评估在固定的 8128 个 prefix 上使用 float32 full-vocabulary teacher forcing，因此评估噪声与训练时的 sampled action 噪声分开。

方法	inner J	初始 $\mathrm{KL}(p\|T)$	最终 $\mathrm{KL}(p\|T)$	初始 $\mathrm{KL}(T\|p)$	最终 $\mathrm{KL}(T\|p)$	最终 ESS fraction
On-policy OPD	1	0.9873	0.9356	0.8907	0.8921	1.0000
Token-IS OPD	4	0.9873	0.9094	0.8907	0.9387	0.9335

两种方法都降低了 $\mathrm{KL}(p\|T)$，所以 baseline 路径和缓存、同步逻辑是可运行的。token-IS 的 teacher-directed reverse KL 降得更多，但 forward KL 上升，且 ESS 降至约 93.35%；这正是用 stale rollout 换取每轮更多 inner 更新的代价。训练日志中的 score coefficient RMS 约为 2.9–3.1，而梯度裁剪前的 norm 约为 1.6×10^3–2.1×10^3，说明当前短实验首先受优化尺度和混合精度路径影响，不能仅凭 32 步断言 token-IS 在长期一定优于 on-policy。此外，旧配置里的 `model_dtype=float32` 只约束权重加载；若未显式设置 FSDP `mixed_precision`，前向仍可能采用 BF16 autocast。正式比较应把这一项写入 resolved config，并同时记录 `dtype`、梯度裁剪、ESS 和 full-vocabulary 固定前缀指标。

Algorithm 5 Tail-aware OPD outer–inner optimization

Semantics: 根据正文重构；冻结 *outer rollout*，以 *Tail-aware KL* 中心运行 *Mean*、*BPO* 或 *MDPO*，再同步并重新 *rollout*

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial student $\pi_0 = \pi_{\theta_{0,0}}$, outer steps K_{out}, rollout batch size $B \geq 1$, horizon $H \geq 1$, method M, $\eta > 0$, inner steps $N \geq 1$, inner learning rate schedule $\{\alpha_{k,n}\}$, sync mode $\text{Sync} \in \{\text{hard}, \text{soft}\}$, soft-sync weight $\rho \in (0, 1]$

Ensure: final policy $\pi_{K_{\text{out}}}$ and parameters $\theta_{K_{\text{out}}}$

for $k = 0, \ldots, K_{\text{out}} - 1$ **do**
  $\mathcal{B}_k \leftarrow \varnothing$ ▷ $\mathcal{B}_k$ stores rollout pairs with multiplicity
  for $i = 1, \ldots, B$ **do**
    sample prompt $x_i \sim \mathcal{D}$
    generate $y_i = (a_{i,1}, \ldots, a_{i,\tau_i})$ with $a_{i,t} \sim \pi_k(\cdot \mid s_{i,t})$, $s_{i,t} = (x_i, a_{i,<t})$; stop at EOS or H tokens
    $\mathcal{B}_k \leftarrow \mathcal{B}_k \uplus \{(s_{i,t}, a_{i,t}) : 1 \leq t \leq \min(\tau_i, H)\}$
  end for
  if $\mathcal{B}_k = \varnothing$, terminate with an empty-rollout error before normalization
  define $\widehat{d}_k$ as the empirical distribution assigning each prefix occurrence in $\mathcal{B}_k$ equal mass
  $\theta_{k,0} \leftarrow \theta_k$ ▷ initialize the inner student from the current outer policy
  query frozen $\log \pi_T(v \mid s)$ and $\log \pi_k(v \mid s)$ for $(s, a) \in \mathcal{B}_k$, $v \in \mathcal{V}$; retain summaries and action log-prob only
  choose and freeze $S_J(s) = \text{TopJ}(\pi_k(\cdot \mid s))$; freeze $\log \pi_k(v \mid s)$ for $v \in S_J(s)$ and $\log \pi_T(a \mid s), \log \pi_k(a \mid s)$ for rollout actions
  $\widehat{\mathcal{K}}_k^T(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s))$ using the same $S_J(s)$ and aggregate tail masses
  omit PMD-Part because it requires $\log Z_k$; use all retained rollout pairs, including tail actions
  for $n = 0, \ldots, N - 1$ **do**
    compute current $\log \pi_{k,n}(v \mid s)$ and $\widehat{\mathcal{K}}_{k,n}^S(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k \| \pi_{k,n})$ on the frozen $S_J(s)$; freeze both centers within this gradient evaluation
    if $M = \text{Mean}$ **then**
      $g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\log \frac{\pi_{k,n}(a|s)}{\pi_k(a|s)} - \eta \left(\log \frac{\pi_T(a|s)}{\pi_k(a|s)} + \widehat{\mathcal{K}}_k^T(s)\right)\right) \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$
    else if $M = \text{BPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\eta^{-1} \left(\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \widehat{\mathcal{K}}_{k,n}^S(s)\right) - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} - \widehat{\mathcal{K}}_k^T(s)\right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    else if $M = \text{MDPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} \left(\eta^{-1} \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}\right)\right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    end if
    $\theta_{k,n+1} \leftarrow \text{OptimizerStep}(\theta_{k,n}, g_{k,n}; \alpha_{k,n})$ ▷ gradient descent: plain SGD gives $\theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  if $\text{Sync} = \text{hard}$ **then**
    $\theta_{k+1} \leftarrow \theta_{k,N}$ and $\pi_{k+1} \leftarrow \pi_{\theta_{k+1}}$
  else
    $\pi_{k+1}(\cdot \mid s) \leftarrow (1 - \rho)\pi_k(\cdot \mid s) + \rho \pi_{k,N}(\cdot \mid s)$ for every prefix s
    choose θ_{k+1} representing this mixture, assuming the policy class is closed under mixtures ▷ categorical probability mixture; neural-model implementation uses hard sync
  end if
end for
return $(\pi_{K_{\text{out}}}, \theta_{K_{\text{out}}})$

Algorithm 6 OPD sampled-token inner update

Semantics: 每个 prefix 只访问 rollout 的下一个 token

Require: frozen anchor π_k, teacher π_T, rollout pairs (s_i, a_i), method M, center size m, η
Ensure: updated student parameters θ

for each prefix s_i **do**
  read $\log \pi_T(a_i \mid s_i)$ and $\log \pi_k(a_i \mid s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  if $M = \text{Mean}$ **then**
    obtain independent auxiliary actions at the same prefix to estimate a frozen reward center $\widehat{\bar{r}}_i$
    $\ell_i \leftarrow \frac{1}{2}[U_{k,n}(s_i, a_i) - \eta\,\text{stopgrad}(r_i - \widehat{\bar{r}}_i)]^2$
  else if $M = \text{BPO}$ **then**
    estimate the reward center and current student log-ratio center at the same prefix
    form a centered residual loss with the $1/(2\eta)$ factor; retain the student center's derivative
    use the finite-sample correction specified in the BPO inner algorithm
  else if $M = \text{MDPO}$ **then**
    $w_i \leftarrow \text{stopgrad}(\pi_{k,n}(a_i \mid s_i)/\pi_k(a_i \mid s_i))$
    $\ell_i \leftarrow \text{stopgrad}\big(w_i[\eta^{-1}\log(\pi_{k,n}(a_i \mid s_i)/\pi_k(a_i \mid s_i)) - r_i]\big)\log \pi_{k,n}(a_i \mid s_i)$
  else if $M = \text{Part}$ **then**
    estimate or load a prefix baseline $\widehat{\log Z_i}$; record its bias source
    update $\frac{1}{2}[\eta r_i - \widehat{\log Z_i} - U_{k,n}(s_i, a_i)]^2$
  end if
end for
perform gradient descent on $B^{-1}\sum_i \ell_i$ while keeping π_k and π_T frozen
return θ

Algorithm 7 On-policy OPD baseline

Semantics: 每个 outer step 用当前 student 重新 rollout；无 mirror 正则

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial policy π_0, outer steps K_{out}, rollout batch B, horizon H
Ensure: $\pi_{K_{\text{out}}}$

for $k = 0, \ldots, K_{\text{out}} - 1$ **do**
  set $\pi_k \leftarrow \pi_{\theta_k}$ and generate (s_i, a_i) with $a_i \sim \pi_k(\cdot \mid s_i)$
  evaluate $\log \pi_k(a_i \mid s_i)$, $\log \pi_T(a_i \mid s_i)$ and the frozen-support estimate $\widehat{\mathcal{K}}^T_{k,0}(s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  $g_k \leftarrow -|\mathcal{B}_k|^{-1}\sum_i \text{sg}(r_i + \widehat{\mathcal{K}}^T_{k,0}(s_i))\nabla_{\theta_k}\log \pi_{\theta_k}(a_i \mid s_i)$
  $\theta_{k+1} \leftarrow \text{OptimizerStep}(\theta_k, g_k)$
end for
return $\pi_{K_{\text{out}}}$

Algorithm 8 Token-IS OPD baseline

Semantics: 复用 anchor rollout；仅修正 prefix 条件下的 token 测度

Require: frozen anchor $q = \pi_k$, teacher π_T, rollout batch $\mathcal{B}_k$, inner steps J, learning rates $\{\alpha_j\}$
Ensure: θ_{k+1}

initialize $\theta \leftarrow \theta_k$
for $j = 0, \ldots, J - 1$ **do**
  evaluate $\log p_\theta(a_i \mid s_i)$ and frozen-support $\widehat{\mathcal{K}}^T_{k,n}(s_i)$ for all $(s_i, a_i) \in \mathcal{B}_k$
  $u_i \leftarrow \log p_\theta(a_i \mid s_i) - \log q(a_i \mid s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log p_\theta(a_i \mid s_i)$
  $w_i \leftarrow \text{sg}(\exp u_i)$
  $g_j \leftarrow -|\mathcal{B}_k|^{-1}\sum_i \text{sg}(w_i(r_i + \widehat{\mathcal{K}}^T_{k,n}(s_i)))\nabla_\theta \log p_\theta(a_i \mid s_i)$
  $\theta \leftarrow \text{OptimizerStep}(\theta, g_j; \alpha_j)$
end for
return $\theta_{k+1} \leftarrow \theta$

第三章 KL 估计的统一残差框架

KL的数值、KL 的参数梯度和某段 loss 的自动微分梯度是三个对象。本章先把前两个对象写成有限词表上的积分，再用同一个残差校正定理分析估计误差，最后检查自动微分是否实现了所需的梯度。算法名称放在相应积分与控制函数确定之后；无偏性和方差由这些对象推出。

3.1 目标、采样测度与微分规则

3.1.1 固定条件与唯一符号

固定 prefix x，省略条件变量。词表 $\mathcal{V}$ 有限，$p = p_\theta$ 是当前 student，q 是冻结参考，ρ 是实际动作采样分布，$A \sim \rho$。q 默认代入 teacher；分析 student–anchor KL 时只代入 $q = \pi_k$。冻结 rollout 则代入 $\rho = \pi_k$。参考分布与采样分布具有不同职责。

假设 $p(v), q(v) > 0$。对 ρ 的支持要求由残差决定，并在总定理中给出。所有期望、协方差和偏差先条件于固定 prefix；若使用历史数据拟合控制，也先条件于这些数据。只对 p 求导，q 与支持集在求导时冻结。统一定义

$$r_v = \log \frac{p(v)}{q(v)}, \qquad s_v = \nabla_\theta \log p(v), \qquad \mathrm{stopgrad}(\cdot) = \mathrm{stopgrad}(\cdot).$$

r_v 始终是 KL log-ratio；前两章的冻结 OPD reward 保留完整记号 $r_k(x, v)$，在 $q = \pi_T$ 时它对应负 log-ratio。s_v 始终表示 score function（得分函数）。

定义 3.1 (积分与误差)

对概率测度 ν 及标量或向量函数 f，记

$$I_\nu(f) = \sum_{v \in \mathcal{V}} \nu(v) f_v.$$

这里 ν 只标记求和权重，代入时取 p 或 q，没有引入额外策略。目标 $I_\nu(f)$ 的估计量 $\widehat{I}$ 的偏差、协方差迹与均方误差为

$$\mathrm{Bias}(\widehat{I}) = \mathbb{E}_\rho \widehat{I} - I_\nu(f), \qquad \mathrm{Var}_\rho(\widehat{I}) = \mathrm{tr}\,\mathrm{Cov}_\rho(\widehat{I}),$$

$$\mathrm{MSE}(\widehat{I}) = \|\mathrm{Bias}(\widehat{I})\|^2 + \mathrm{Var}_\rho(\widehat{I}).$$

标量情形把范数解释为绝对值。估计数值和估计梯度时，只替换 f 的值域。

3.1.2 四个目标积分

记反向和正向 KL 为

$$K = \mathrm{KL}(p\|q), \qquad K^{\mathrm{F}} = \mathrm{KL}(q\|p).$$

有限求和的乘积法则及归一化恒等式给出

$$\sum_v p(v) s_v = \nabla_\theta \sum_v p(v) = 0,$$

$$\begin{aligned} g = \nabla_\theta K &= \sum_v \{(\nabla p(v)) r_v + p(v) \nabla r_v\} \\ &= \sum_v p(v)(r_v + 1) s_v = \sum_v p(v) r_v s_v, \end{aligned}$$

$$g^{\mathrm{F}} = \nabla_\theta K^{\mathrm{F}} = -\sum_v q(v) \nabla r_v = -\sum_v q(v) s_v.$$

因此整章只需要下列四次代入：

目标	积分权重 ν	被积函数 f_v	积分值
反向 KL 数值	p	r_v	$K = I_p(r)$
反向 KL 梯度	p	$r_v s_v$	$g = I_p(rs)$
正向 KL 数值	q	$-r_v$	$K^{\mathrm{F}} = I_q(-r)$
正向 KL 梯度	q	$-s_v$	$g^{\mathrm{F}} = I_q(-s)$

积分权重 ν 决定目标，实际采样分布 ρ 决定怎样估计目标。重要性比率是 ν/ρ，由积分权重与实际采样分布共同决定。

3.1.3 数值微分与随机梯度的区别

对可微函数 $F_\theta(v)$，逐项求导得到

$$\nabla_\theta I_p(F_\theta) = I_p\big(\nabla_\theta F_\theta + F_\theta s\big). \tag{3.1}$$

固定样本索引后，自动微分只能得到 $\nabla_\theta F_\theta(A)$；采样权重的微分项 $F_\theta(A)s_A$ 不会由离散抽样自动出现。反向 KL 取 $F_\theta = r$，两项分别为 s 与 rs，前者的总体均值恰好为零。第 3.7 节将使用这条恒等式统一审计 K1–K5 与稀疏头尾反传。

本章主线是：先选上表的目标，随后选可精确积分的近似 a，用随机样本补回 $f - a$，再选择采样分布和反传 surrogate。确定性截断对应丢弃残差；HETS 对头部取精确近似；ResOPD 与 SC-TA 对尾部采用具有相同积分、不同逐 token 值的近似。

3.2 统一构造：精确积分加残差抽样

KL数值、KL 梯度和 baseline 的统计分析可以共用一个积分问题。固定当前 prefix 后，p、q、r_v 与 s_v 都是词表上的确定函数。选择积分测度 ν 和被积函数 f，便确定了估计目标；选择实际抽样分布 ρ 和可精确积分的近似函数 a，便确定了估计方法。以下所有协方差均针对动作抽样，向量的方差仍指协方差迹。

定义 3.2 (可精确积分的近似函数与残差)

令 $\nu \in \{p, q\}$，$f : \mathcal{V} \to \mathbb{R}^d$，并定义

$$R_v = f_v - a_v, \qquad I_\nu(f) = I_\nu(a) + I_\nu(R).$$

其中 $a : \mathcal{V} \to \mathbb{R}^d$ 的积分 $I_\nu(a)$ 可以精确计算。标量情形取 $d = 1$。令 $A \sim \rho$，假设

$$\nu(v)\|R_v\| > 0 \implies \rho(v) > 0.$$

这个支持条件只要求覆盖非零残差。定义残差修正估计量

$$\widehat{I}_{\nu,\rho,a}(f) = I_\nu(a) + \frac{\nu(A)}{\rho(A)} R_A. \tag{3.2}$$

比率只在实际抽到的动作上计算。$\rho(v) = 0$ 且残差贡献为零的动作无需定义该比率。

该定义中，ν 决定要计算哪个积分，ρ 决定从哪里取得随机动作，a 决定哪些贡献已经被确定性地计算。三个选择应当分别记录。特别地，参考分布 q 出现在 r_v 内，并不意味着积分测度或抽样测度就是 q。

本节条件于当前参数，把这些函数当作词表上的确定值。估计梯度时直接代入向量函数 $f_v = r_v s_v$ 或 $-s_v$；对一个无偏数值估计量再次自动微分，需要另外验证第 3.7 节的规则。

定理 3.1 (残差修正的均值、协方差与均方误差)

记 $m_R = I_\nu(R)$。在定义 3.2 的支持条件下，式 (3.2) 无偏，并且

$$\mathrm{Cov}(\widehat{I}_{\nu,\rho,a}(f)) = \sum_{v:\rho(v)>0} \frac{\nu(v)^2}{\rho(v)} R_v R_v^\top - m_R m_R^\top, \tag{3.3}$$

$$\mathrm{Var}(\widehat{I}_{\nu,\rho,a}(f)) = \sum_{v:\rho(v)>0} \frac{\nu(v)^2}{\rho(v)} \|R_v\|^2 - \|m_R\|^2. \tag{3.4}$$

其相对于 $I_\nu(f)$ 的均方误差等于式 (3.4)。n 个独立同分布动作对应的样本均值，其协方差和均方误差分别为上述结果的 $1/n$。

♡

证明 先逐项计算随机修正项的期望。支持条件保证被略去的动作对 $I_\nu(R)$ 没有贡献，因此

$$\mathbb{E}_\rho\left[\frac{\nu(A)}{\rho(A)} R_A\right] = \sum_{v:\rho(v)>0} \nu(v) R_v = I_\nu(R).$$

加上 $I_\nu(a)$，得到 $I_\nu(a+R) = I_\nu(f)$。确定项不影响协方差；令 $Y = \nu(A)R_A/\rho(A)$，有

$$\mathbb{E}[YY^\top] = \sum_{v:\rho(v)>0} \frac{\nu(v)^2}{\rho(v)} R_v R_v^\top, \qquad \mathbb{E}[Y] = m_R.$$

应用 $\mathrm{Cov}(Y) = \mathbb{E}[YY^\top] - \mathbb{E}[Y]\mathbb{E}[Y]^\top$ 得到矩阵公式。对矩阵取迹，并使用 $\mathrm{tr}(zz^\top) = \|z\|^2$，得到迹方差。最后，无偏性给出

$$\mathbb{E}\|\widehat{I} - I_\nu(f)\|^2 = \mathrm{tr}\,\mathrm{Cov}(\widehat{I}).$$

独立样本之间的交叉协方差为零，因而平均后的协方差除以 n。

3.2.1 精确项误差、错误权重与缺失支持

残差公式同时给出实现偏差的核对方式。令 $\mathcal{D} = \{v : \rho(v) > 0\}$，允许实际使用的权重 $\widetilde{w}(v)$ 偏离 $\nu(v)/\rho(v)$，并允许确定积分项存在固定误差 $\delta \in \mathbb{R}^d$。实际输出为

$$\widetilde{I} = I_\nu(a) + \delta + \widetilde{w}(A) R_A.$$

这里先条件于所有已冻结的缓存和控制参数；随机缓存的处理在本节末给出。

定理 3.2 (三种误差来源的统一偏差)

上述输出相对于 $I_\nu(f)$ 的偏差恰为

$$b_I = \delta + \sum_{v\in\mathcal{D}} \big(\rho(v)\widetilde{w}(v) - \nu(v)\big) R_v - \sum_{v\notin\mathcal{D}} \nu(v) R_v. \tag{3.5}$$

记 $\widetilde{m}_R = \sum_{v\in\mathcal{D}} \rho(v)\widetilde{w}(v) R_v$，则

$$\mathrm{Cov}(\widetilde{I}) = \sum_{v\in\mathcal{D}} \rho(v)\widetilde{w}(v)^2 R_v R_v^\top - \widetilde{m}_R \widetilde{m}_R^\top, \tag{3.6}$$

$$\mathbb{E}\|\widetilde{I} - I_\nu(f)\|^2 = \mathrm{tr}\,\mathrm{Cov}(\widetilde{I}) + \|b_I\|^2. \tag{3.7}$$

♡

证明 由 $I_\nu(f) = I_\nu(a) + \sum_v \nu(v) R_v$，直接相减得

$$\mathbb{E}[\widetilde{I}] - I_\nu(f) = \delta + \sum_{v\in\mathcal{D}} \rho(v)\widetilde{w}(v) R_v - \sum_v \nu(v) R_v.$$

把最后一个求和分成 $\mathcal{D}$ 及其补集，就得到式 (3.5)。协方差由随机项的一阶、二阶矩计算。均方误差展开为

$$\mathbb{E}\|(\widetilde{I} - \mathbb{E}\widetilde{I}) + b_I\|^2 = \mathbb{E}\|\widetilde{I} - \mathbb{E}\widetilde{I}\|^2 + \|b_I\|^2,$$

其中交叉项因 $\mathbb{E}[\widetilde{I} - \mathbb{E}\widetilde{I}] = 0$ 消失。

精确积分误差、重要性权重误差和缺失支持具有不同来源，却都在同一个残差上累积。若近似函数已经精

确覆盖某个动作，即 $R_v = 0$，该动作的权重误差或支持缺失不会产生偏差。反之，即使头部计算完全精确，缺失尾部的残差均值仍会留下系统偏差。无偏性的严格条件是式 (3.5) 为零；三个误差项也能相互抵消，因此分别为零是便于验证的充分条件。

3.2.2 已知积分控制函数的最优线性组合

现在固定 ν 与 ρ，假设 ρ 覆盖 ν 的支持。取 m 个向量控制函数 $h_j : \mathcal{V} \to \mathbb{R}^d$，每个积分 $I_\nu(h_j)$ 已知。标量系数 c_j 组成 $c \in \mathbb{R}^m$，并令

$$a_{c,v} = \sum_{j=1}^{m} c_j h_{j,v}, \qquad w(v) = \frac{\nu(v)}{\rho(v)}, \qquad X = w(A) f_A,$$
$$U_j = w(A) h_{j,A} - I_\nu(h_j), \qquad X_0 = X - I_\nu(f).$$

于是 $\mathbb{E} U_j = 0$，且主估计量可以逐样本写成

$$\widehat{I}_c = X - \sum_j c_j U_j.$$

这一步把选择近似函数转化为在零均值随机函数空间中投影。

定理 3.3 (Gram 矩阵、最优控制与精确超额方差)

定义对称半正定矩阵 Γ、向量 ζ 和基准方差 V_0：

$$\Gamma_{ij} = \mathbb{E}_\rho \langle U_i, U_j \rangle, \qquad \zeta_j = \mathbb{E}_\rho \langle U_j, X_0 \rangle, \qquad V_0 = \mathbb{E}_\rho \|X_0\|^2.$$

令 $\Gamma^\dagger$ 为 Moore–Penrose 伪逆，则迹方差最优的系数集合为

$$c^* = \Gamma^\dagger \zeta + \ker \Gamma.$$

最优值及任意系数相对于最优值的代价分别为

$$V_{\min} = V_0 - \zeta^\top \Gamma^\dagger \zeta, \tag{3.8}$$
$$\operatorname{Var}(\widehat{I}_c) - V_{\min} = (c - \Gamma^\dagger \zeta)^\top \Gamma (c - \Gamma^\dagger \zeta). \tag{3.9}$$

这里最小化的是协方差迹；一般向量控制下不同时最小化所有方向的方差。 ♡

证明 估计量的中心化形式为 $X_0 - \sum_j c_j U_j$，故展开平方得到

$$\operatorname{Var}(\widehat{I}_c) = V_0 - 2 c^\top \zeta + c^\top \Gamma c.$$

对任意 $z \in \ker \Gamma$，有

$$0 = z^\top \Gamma z = \mathbb{E} \left\| \sum_j z_j U_j \right\|^2.$$

因此 $\sum_j z_j U_j = 0$ 几乎处处成立，进而

$$z^\top \zeta = \mathbb{E} \left\langle \sum_j z_j U_j, X_0 \right\rangle = 0.$$

这证明 $\zeta \perp \ker \Gamma$，即 $\zeta \in \operatorname{range} \Gamma$。令 $c_0 = \Gamma^\dagger \zeta$，便有 $\Gamma c_0 = \zeta$。对二次式配方得

$$V_0 - 2 c^\top \zeta + c^\top \Gamma c = V_0 - c_0^\top \Gamma c_0 + (c - c_0)^\top \Gamma (c - c_0).$$

由伪逆恒等式，$c_0^\top \Gamma c_0 = \zeta^\top \Gamma^\dagger \zeta$。最后一个二次型非负，且恰在 $c - c_0 \in \ker \Gamma$ 时为零，得到全部结论。

单控制的协方差除以方差公式是该定理在 $m = 1$ 时的特例；多个相关控制必须使用整个 Gram 矩阵。控制之间的相关项决定一个控制能否补充另一个控制已经消去的波动。增加控制函数使可选空间包含原来的空间，因此最优迹方差只能下降或保持不变；实际使用不准确的系数，其代价由式 (3.9) 精确给出。

3.2.3 固定残差时的最优抽样分布

控制函数改变残差，抽样分布改变残差的二阶矩权重。因此控制优化与抽样优化属于同一方差问题的两个坐标。

定理 3.4 (残差范数决定迹方差最优抽样)

固定 a，令 $L_R = \sum_v \nu(v)\|R_v\|$。若 $L_R > 0$，则主估计量的最优抽样分布为

$$\rho^*(v) = \frac{\nu(v)\|R_v\|}{L_R},$$

其最小迹方差为

$$\mathrm{Var}_{\min} = L_R^2 - \|I_\nu(R)\|^2.$$

若 $L_R = 0$，则 $I_\nu(a) = I_\nu(f)$，直接返回确定积分项便有零方差。

证明 令 $\mathcal{R} = \{v : \nu(v)\|R_v\| > 0\}$。对任何满足残差支持条件的 ρ，由 Cauchy–Schwarz 不等式，

$$\begin{aligned} L_R^2 &= \left(\sum_{v\in\mathcal{R}} \frac{\nu(v)\|R_v\|}{\sqrt{\rho(v)}}\sqrt{\rho(v)}\right)^2 \\ &\le \left(\sum_{v\in\mathcal{R}} \frac{\nu(v)^2\|R_v\|^2}{\rho(v)}\right)\left(\sum_{v\in\mathcal{R}} \rho(v)\right) \\ &\le \sum_{v\in\mathcal{R}} \frac{\nu(v)^2\|R_v\|^2}{\rho(v)}. \end{aligned}$$

取 $\rho = \rho^*$ 时，全部质量放在 $\mathcal{R}$，且两向量成比例，两个不等式均取等。代入式 (3.4) 得到最优值。若 $L_R = 0$，则 $\nu(v)R_v = 0$ 对所有动作成立，目标已被精确积分项覆盖。

在标量情形，最优二阶矩由 $|R|$ 决定；在向量情形，由欧氏范数决定。即使取最优抽样，残差方向随动作变化仍会产生方差。零方差要求三角不等式取等，也就是所有非零残差向量沿同一个有向射线。若额外要求 ρ 对整个词表严格为正，而最优解对零残差动作赋零质量，则上述值是可逼近的下确界。

改变 a 会同时改变 Γ、ζ 和 ρ^*；改变 ρ 也会改变控制系数的最优解。因而在某个采样分布上拟合出的最优控制系数，不能直接声明在另一个采样分布上仍然最优。

这些最优值是总体矩已知时的 oracle 结论。稀疏 teacher payload 不提供所有未知尾部的 r_v，因此一般不能直接构造 ρ^* 或精确计算最优 Gram 系数。它们用于给出可达到的下界、判断控制特征是否有用，以及设计独立样本上的近似拟合；可计算算法必须另外说明这些量如何取得。

3.2.4 分区后统一分离事件内部与事件之间的方差

定理 3.5 (on-policy 残差的分区协方差)

令 $\rho = \nu$，$\{C_\ell\}_{\ell=1}^{L}$ 为词表分区，忽略零质量单元。记

$$\omega_\ell = \nu(C_\ell), \quad \mu_\ell = \mathbb{E}_\nu[R_A \mid A \in C_\ell], \quad \Sigma_\ell = \mathrm{Cov}_\nu(R_A \mid A \in C_\ell), \quad \bar{\mu} = \sum_\ell \omega_\ell \mu_\ell.$$

则

$$\mathrm{Cov}(\widehat{I}_{\nu,\nu,a}(f)) = \sum_\ell \omega_\ell \Sigma_\ell + \sum_\ell \omega_\ell (\mu_\ell - \bar{\mu})(\mu_\ell - \bar{\mu})^\top. \tag{3.10}$$

证明 因为重要性比率为一，估计量的协方差就是 R_A 的协方差。条件于 $A \in C_\ell$，写成

$$R_A - \bar{\mu} = (R_A - \mu_\ell) + (\mu_\ell - \bar{\mu}).$$

外积展开后，第一项的条件期望为 Σ_ℓ，第二项为确定外积。两个交叉项均含 $\mathbb{E}[R_A - \mu_\ell \mid A \in C_\ell] = 0$，故为零。最后按单元概率 ω_ℓ 求和即得结论。

该公式使头尾控制的作用可以逐项识别。在 $\nu = \rho = p$ 的例子中，取头部 S 与尾部 S^c，局部记 $P = p(S)$、$\tau_p = 1 - P$、$J_A = \mathbf{1}\{A \notin S\}$。令 $a_v = f_v$ 在头部成立，且 $a_v = b$ 在尾部成立。记尾部条件均值为 μ_f、条件协方差为 Σ_f，则

$$I_p(a) = \sum_{v \in S} p(v) f_v + \tau_p b, \qquad R_A = J_A(f_A - b),$$

$$\mathrm{Cov}(\widehat{I}) = \tau_p \Sigma_f + P\tau_p(\mu_f - b)(\mu_f - b)^\top. \tag{3.11}$$

减去常向量 b 不改变尾部内部协方差，只改变头尾事件之间的条件均值差。取 $b = \mu_f$ 消去事件间项；要进一步降低事件内部项，需要尾部随动作变化的控制函数。数值目标与梯度目标只需分别代入 $f_v = r_v$ 与 $f_v = r_v s_v$，全部计算便沿用同一分区公式。

3.2.5 残差均值、残差波动与随机控制的条件化

若仅返回确定近似 $I_\nu(a)$，其偏差为 $-I_\nu(R)$，方差为零。若补上正确的残差抽样，偏差变为零，留下的是加权残差的中心二阶矩。由此，近似误差的均值与抽样误差的波动必须分别分析：残差均值为零不保证方差小，残差几乎为常向量也不保证确定近似无偏。

控制函数、系数和采样分布可以由历史数据学习。令 $\mathcal{F}$ 包含拟合数据和冻结缓存；若条件于 $\mathcal{F}$，这些对象已固定，且新动作满足 $A \mid \mathcal{F} \sim \rho_{\mathcal{F}}$，前述定理均可逐条件应用。若目标 $I_\nu(f)$ 本身固定且每个条件估计量无偏，则

$$\mathbb{E}[\widehat{I} \mid \mathcal{F}] = I_\nu(f), \qquad \mathrm{Cov}(\widehat{I}) = \mathbb{E}[\mathrm{Cov}(\widehat{I} \mid \mathcal{F})].$$

若条件偏差为随机向量 $b_{\mathcal{F}}$，全协方差公式则给出

$$\mathrm{Cov}(\widehat{I}) = \mathbb{E}[\mathrm{Cov}(\widehat{I} \mid \mathcal{F})] + \mathrm{Cov}(b_{\mathcal{F}}), \qquad \mathrm{Bias}(\widehat{I}) = \mathbb{E}[b_{\mathcal{F}}].$$

同一动作同时参与控制拟合与残差评估时，条件抽样关系需要重新证明。例如 $\mathbb{E}U = 0$ 一般不能推出 $\mathbb{E}[c(A)U] = 0$。独立校准集或交叉拟合（cross-fitting）可以使每个评估动作独立于用于构造其控制函数的训练数据，从而恢复逐条件无偏性；交叉拟合各折之间仍能相关，总方差不能直接按独立样本数相除。

3.3 同一分区上的 KL 粗化与梯度残差

头部精确求和、尾部合并和尾部残差抽样，都可以从同一个词表分区推导。分区同时规定可精确计算的粗粒度目标和需要抽样的细粒度残差。下面始终固定 prefix、当前参数和参考分布；只在明确写出梯度时对 student 参数求导。

定义 3.3 (词表分区与桶内分布)

令 $\mathcal{C}$ 是有限词表 $\mathcal{V}$ 的一个分区，各个单元 $C \in \mathcal{C}$ 非空且两两不交，并满足 $\bigcup_{C \in \mathcal{C}} C = \mathcal{V}$。分区在求导时固定。定义

$$P_C = \sum_{v \in C} p(v), \qquad Q_C = \sum_{v \in C} q(v), \qquad \ell_C = \log \frac{P_C}{Q_C},$$

以及桶内条件分布和平均 score

$$p_C(v) = \frac{p(v)}{P_C}, \qquad q_C(v) = \frac{q(v)}{Q_C}, \qquad \bar{s}_C = \sum_{v \in C} p_C(v) s_v = \nabla \log P_C.$$

用 $C(v)$ 表示包含 v 的唯一单元。粗粒度反向 KL 与桶内形状 KL 分别定义为

$$K_{\mathcal{C}} = \sum_{C \in \mathcal{C}} P_C \ell_C, \qquad D_C = \mathrm{KL}(p_C \| q_C).$$

这里 $K_{\mathcal{C}}$ 是桶标签分布之间的 KL；D_C 描述保留桶标签以后仍未解释的条件分布差异。

定理 3.6 (同一分区上的双向 KL 链式分解)

在本章正支持假设下，反向 KL 和正向 KL 分别满足

$$K = K_{\mathcal{C}} + \sum_{C\in\mathcal{C}} P_C D_C, \tag{3.12}$$

$$K^{\mathrm{F}} = K^{\mathrm{F}}_{\mathcal{C}} + \sum_{C\in\mathcal{C}} Q_C D^{\mathrm{F}}_C, \tag{3.13}$$

其中

$$K^{\mathrm{F}}_{\mathcal{C}} = -\sum_C Q_C \ell_C, \qquad D^{\mathrm{F}}_C = \mathrm{KL}(q_C \| p_C).$$

因此两种方向的粗粒度 KL 都是对应完整 KL 的下界。等号成立当且仅当每个单元内的条件分布相同。

证明 对任意 $v \in C$，完整 log-ratio 可以逐点写为

$$r_v = \log \frac{p(v)}{q(v)} = \ell_C + \log \frac{p_C(v)}{q_C(v)}.$$

先乘以 $p(v) = P_C p_C(v)$，在单元内求和，再对单元求和，得到

$$\sum_v p(v) r_v = \sum_C P_C \ell_C + \sum_C P_C \sum_{v\in C} p_C(v) \log \frac{p_C(v)}{q_C(v)}.$$

这就是反向分解。将上面的逐点恒等式取负并乘以 $q(v) = Q_C q_C(v)$，按相同顺序求和，得到正向分解。所有质量严格为正，且每个条件 KL 非负；条件 KL 等于零恰好对应桶内条件分布相同，故得到下界及等号条件。

命题 3.1 (分区细化的标量单调性)

设 $\mathcal{C}'$ 细化 $\mathcal{C}$。记 $\mathcal{C}'|_C$ 为包含在 C 内的细单元集合，则

$$K_{\mathcal{C}'} - K_{\mathcal{C}} = \sum_{C\in\mathcal{C}} P_C \,\mathrm{KL}\left(\left(\frac{P_{C'}}{P_C}\right)_{C'\in\mathcal{C}'|_C} \middle\| \left(\frac{Q_{C'}}{Q_C}\right)_{C'\in\mathcal{C}'|_C} \right) \geq 0.$$

正向版本交换两组质量，并将外层权重改为 Q_C。因此细化使粗粒度 KL 的标量偏差绝对值和平方偏差单调下降；全部单元都是 singleton 时偏差为零。

证明 对每个 C，利用 $\sum_{C'\subseteq C} P_{C'} = P_C$，将新增贡献写成

$$\sum_{C'\subseteq C} P_{C'} \log \frac{P_{C'}}{Q_{C'}} - P_C \log \frac{P_C}{Q_C} = P_C \sum_{C'\subseteq C} \frac{P_{C'}}{P_C} \log \frac{P_{C'}/P_C}{Q_{C'}/Q_C}.$$

右边是 P_C 乘以细单元标签之间的条件 KL。对 C 求和即得所述等式。结合粗粒度下界，误差 $K - K_{\mathcal{C}}$ 非负且随细化下降，其平方也下降。

定理 3.7 (粗粒度 KL 的真实梯度及其残差)

记 $g_{\mathcal{C}} = \nabla K_{\mathcal{C}}$。则

$$g_{\mathcal{C}} = \sum_C P_C \ell_C \bar{s}_C = \sum_v p(v) \ell_{C(v)} s_v, \tag{3.14}$$

$$g - g_{\mathcal{C}} = \sum_C P_C \mathbb{E}_{p_C}[(r_A - \ell_C) s_A] \tag{3.15}$$

$$= \sum_C P_C \left\{ \mathrm{Cov}_{p_C}(r_A - \ell_C, s_A) + D_C \bar{s}_C \right\}. \tag{3.16}$$

标量与向量的协方差定义为

$$\mathrm{Cov}_{p_C}(u_A, s_A) = \mathbb{E}_{p_C}[(u_A - \mathbb{E}_{p_C} u_A)(s_A - \bar{s}_C)].$$

证明 由于 q 固定，$\nabla Q_C = 0$，而 $\nabla P_C = P_C \bar{s}_C$。逐项求导得到

$$\begin{aligned}\nabla K_{\mathcal{C}} &= \sum_C \{\ell_C \nabla P_C + P_C \nabla \ell_C\} \\ &= \sum_C \ell_C \nabla P_C + \sum_C \nabla P_C \\ &= \sum_C P_C \ell_C \bar{s}_C.\end{aligned}$$

最后一步用了 $\sum_C \nabla P_C = \nabla 1 = 0$。将 $P_C \bar{s}_C$ 展开为桶内加权 score，得到第二种表示。完整梯度为 $g = \sum_v p(v) r_v s_v$，与粗粒度梯度逐项相减，得到式 (3.15)。又因为

$$\mathbb{E}_{p_C}[r_A - \ell_C] = D_C,$$

用 $\mathbb{E}[us] = \mathrm{Cov}(u,s) + \mathbb{E}[u]\mathbb{E}[s]$ 展开每个桶内期望，就得到式 (3.16)。

式 (3.16) 把梯度误差分为桶内相关项和条件形状 KL 乘以平均 score 的项。标量粗化误差只包含 D_C 的加权和，梯度误差还依赖 score 的方向与桶内相关性。因此标量下界的单调改进不能直接推出梯度偏差范数单调下降；梯度结论需要单独分析这些向量项。

对正向 KL，冻结权重 Q_C 使粗粒度梯度变成

$$g^{\mathrm{F}}_{\mathcal{C}} = -\sum_C Q_C \bar{s}_C, \qquad g^{\mathrm{F}} - g^{\mathrm{F}}_{\mathcal{C}} = -\sum_C Q_C \{\mathbb{E}_{q_C}[s_A] - \bar{s}_C\}.$$

这里平均 student score $\bar{s}_C$ 的积分分布仍是 p_C；它不能替换成 teacher 条件均值。第一式来自 $\nabla \ell_C = \bar{s}_C$，第二式来自完整正向梯度 $-\sum_v q(v) s_v$。

3.3.1 一个标量代理与两个同积分的梯度代理

使用前文的精确积分加残差抽样构造，令标量代理为

$$a^{\mathrm{K}}_v = \ell_{C(v)}, \qquad I_p(a^{\mathrm{K}}) = K_{\mathcal{C}}.$$

在 $A \sim p$ 下，相应无偏数值估计量为

$$\widehat{K}_{\mathcal{C}} = K_{\mathcal{C}} + r_A - \ell_{C(A)}.$$

它的均值由链式分解得到完整 K，方差为 $\mathrm{Var}_p(r_A - \ell_{C(A)})$。桶内条件形状相同时，残差逐点为零，估计量成为确定性的完整 KL。

梯度积分的目标函数为 $r_v s_v$。同一个粗粒度梯度允许两种可精确积分的代理：

$$\begin{aligned}a^{\mathrm{G,const}}_v &= \ell_{C(v)} \bar{s}_{C(v)}, \\ a^{\mathrm{G,score}}_v &= \ell_{C(v)} s_v.\end{aligned}$$

两者逐点不同，但精确积分相同：

$$I_p(a^{\mathrm{G,const}}) = \sum_C P_C \ell_C \bar{s}_C = I_p(a^{\mathrm{G,score}}) = g_{\mathcal{C}}.$$

因此它们产生两个不同的无偏梯度估计量：

$$\widehat{g}^{\mathrm{const}}_{\mathcal{C}} = g_{\mathcal{C}} + r_A s_A - \ell_{C(A)} \bar{s}_{C(A)}, \tag{3.17}$$

$$\widehat{g}^{\mathrm{score}}_{\mathcal{C}} = g_{\mathcal{C}} + (r_A - \ell_{C(A)}) s_A. \tag{3.18}$$

两种代理之差为

$$\psi_v = \ell_{C(v)}(s_v - \bar{s}_{C(v)}), \qquad \mathbb{E}_{p_C}[\psi_A] = 0.$$

所以改变这两个代理之间的线性组合，只改变桶内零均值波动。它不改变粗粒度精确积分，也不改变每个桶内残差的条件均值。在前文控制矩阵与 Gram 二次型框架中，ψ_A 就是一列已知均值为零的控制特征；其最优系数由残差与该特征的协方差决定，取系数一不自动保证降低方差。

3.3.2 头部 singleton 与尾部单桶的特例

令 S 为冻结的 teacher Top-J 支持，定义 $P=\sum_{v\in S}p(v)$、$Q=\sum_{v\in S}q(v)$、$\tau_p=1-P$、$\tau_q=1-Q$ 和 $J_A=\mathbf{1}\{A\notin S\}$，本节头尾公式假设 $0<P,Q<1$。头部积分为

$$H=\sum_{v\in S}p(v)r_v,\qquad h_g=\sum_{v\in S}p(v)r_v s_v.$$

令 $\mathcal{C}=\{\{v\}:v\in S\}\cup\{\mathcal{V}\setminus S\}$。头部单元满足 $\ell_{\{v\}}=r_v$、$\bar{s}_{\{v\}}=s_v$；尾部单元满足

$$\ell_{\text{tail}}=\log\frac{\tau_p}{\tau_q},\qquad \bar{s}_{\text{tail}}=\nabla\log\tau_p,\qquad b_{\text{TA}}=\ell_{\text{tail}}\bar{s}_{\text{tail}}.$$

因此 $K_{\mathcal{C}}=H+\tau_p\ell_{\text{tail}}$ 是 Tail-aware KL，且 $g_{\mathcal{C}}=h_g+\tau_p b_{\text{TA}}$。三个残差构造分别成为

$$\widehat{K}_{\mathcal{C}}=H+\tau_p\ell_{\text{tail}}+J_A(r_A-\ell_{\text{tail}}),$$
$$\widehat{g}_{\mathcal{C}}^{\text{const}}=h_g+\tau_p b_{\text{TA}}+J_A(r_A s_A-b_{\text{TA}}),$$
$$\widehat{g}_{\mathcal{C}}^{\text{score}}=h_g+\tau_p b_{\text{TA}}+J_A(r_A-\ell_{\text{tail}})s_A.$$

第一式是标量残差估计量；第二式是 ResOPD；第三式是 SC-TA。HETS 使用头部精确代理和零尾部代理，因而是另一个代理选择。上述分类从积分目标和代理函数同时确定估计量，不依赖算法名称。

目标与方法	头部近似 a_v	尾部近似 a_v
数值 HETS	r_v	0
数值桶残差校正	r_v	ℓ_{tail}
梯度 HETS	$r_v s_v$	0
梯度 ResOPD	$r_v s_v$	b_{TA}
梯度 SC-TA	$r_v s_v$	$\ell_{\text{tail}}s_v$

表中每一行都使用式 (3.2)；确定积分项是该行的 $I_p(a)$，采样项始终是 f_A-a_A。数值 Tail-aware 与梯度粗化则只返回各自行的确定积分项，没有补回残差。

命题 3.2 (标量精确时，常向量代理仍可有方差)

若 $p_{\text{tail}}=q_{\text{tail}}$，则上述标量残差估计量和 SC-TA 都是确定性的完整目标，而 ResOPD 的协方差为

$$\text{Cov}(\widehat{g}^{\text{ResOPD}})=\tau_p\ell_{\text{tail}}^2\,\text{Cov}_{p_{\text{tail}}}(s_A).$$

证明 桶内条件分布相同意味着尾部 $r_v=\ell_{\text{tail}}$。标量残差和 SC-TA 的随机残差于是逐点为零。ResOPD 则仍有随机残差

$$J_A\ell_{\text{tail}}(s_A-\bar{s}_{\text{tail}}).$$

它在尾部条件下均值为零，在头部为零，因此总体均值为零，二阶矩恰好是命题中的协方差。

例如取 $p=(0.4,0.2,0.4)$、$q=(0.7,0.1,0.2)$ 和 $S=\{1\}$，则两个尾部条件分布均为 $(1/3,2/3)$，且 $\tau_p=0.6$、$\ell_{\text{tail}}=\log 2$。在完整 softmax logits 参数化下，$s_v=e_v-p$，尾部 score 的协方差迹为 $1-(1/3)^2-(2/3)^2=4/9$。ResOPD 的方差因此为 $\frac{4}{15}(\log 2)^2>0$；标量残差估计量与 SC-TA 的方差均为零。这个例子直接区分了可精确积分的 KL 数值、粗粒度真实梯度以及不同梯度代理留下的抽样波动。

3.4 KL 数值：从确定性代理到无偏残差校正

本节固定目标 $K=I_p(r)$，所以总定理中的 $f_v=r_v$ 是标量。随机估计量默认使用 $\rho=p$；任意 ρ 的权重与支持条件见第 3.8 节。先给出 Top-J 记号，再分类确定性代理、全词表单样本控制和稀疏头尾控制。每个估计量的误差都相对同一个完整 K。

3.4.1 头部与尾部记号

沿用前节的 $S, P, Q, \tau_p, \tau_q, J_A, H$ 和 ℓ_{tail}。令

$$K = \mathrm{KL}(p\|q) = \sum_v p(v) r_v, \qquad H = \sum_{v\in S} p(v) r_v,$$

并令尾部条件分布为

$$p_{\text{tail}}(v) = \frac{p(v)}{\tau_p}, \qquad q_{\text{tail}}(v) = \frac{q(v)}{\tau_q}, \qquad v \notin S.$$

定义尾部质量项和尾部形状项

$$M = \tau_p \log \frac{\tau_p}{\tau_q}, \qquad B = \tau_p \,\mathrm{KL}(p_{\text{tail}}\|q_{\text{tail}}) \geq 0.$$

推论 3.1 (头尾分区的 KL 链式分解)

在 $p \ll q$ 且 $0 < \tau_p, \tau_q < 1$ 时，

$$K = H + M + B. \tag{3.19}$$

证明 在定理 3.6 中取头部 singleton 与单个尾桶。singleton 的条件 KL 为零，粗粒度 KL 是 $H + M$，唯一剩余的条件形状项是 B，故得到所述恒等式。

该分解说明 sparse teacher payload 能够知道 H、P、Q，因而知道 M，但不知道尾部形状项 B。所有 Top-J scalar estimator 的差异都可以直接归结为是否丢弃、聚合或抽样估计 B。

3.4.2 确定性估计量

截断 Top-J 估计量定义为

$$\widehat{K}^{\text{trunc}} = H.$$

由式 (3.19)，其条件偏差和方差为

$$\mathrm{Bias}(\widehat{K}^{\text{trunc}}) = -M - B, \qquad \mathrm{Var}(\widehat{K}^{\text{trunc}}) = 0. \tag{3.20}$$

它删除了尾部贡献；偏差 $-M - B$ 可正可负，因为 M 的符号可以正也可以负，而 B 总是非负。

Tail-aware scalar 估计量把尾部聚合为一个伪 token：

$$\widehat{K}^{\text{TA}} = H + M.$$

命题 3.3 (Tail-aware scalar 的偏差)

$$\mathrm{Bias}(\widehat{K}^{\text{TA}}) = -B, \qquad \mathrm{Var}(\widehat{K}^{\text{TA}}) = 0.$$

因此它是完整 KL 的确定性下界，且当且仅当尾部条件分布相等时达到完整 KL。

证明 将 $\widehat{K}^{\text{TA}} = H + M$ 与 $K = H + M + B$ 相减即可。$B \geq 0$ 来自 KL 非负性。

Normalized Top-J 不是完整 KL 的估计量，而是头部条件分布的另一个目标：

$$K_J^{\text{norm}} = \mathrm{KL}\left(\frac{p|_S}{P}\middle\|\frac{q|_S}{Q}\right) = \frac{H}{P} + \log\frac{Q}{P}.$$

它的条件方差为零，但相对完整 KL 的确定性偏差为

$$\mathrm{Bias}(K_J^{\text{norm}}) = \frac{H}{P} + \log\frac{Q}{P} - (H + M + B). \tag{3.21}$$

这个偏差没有固定符号，因为 Normalized Top-J 同时改变了头部权重并删除了尾部形状。

3.4.3 单 token KL 估计器的基准族

先记录不依赖 Top-J 的单 token 族。令 $A \sim p$，$r = r_A$，并假设相应矩存在。反向 KL 的直接 estimator 为

$$\widehat{K}_1 = r.$$

它满足

$$\mathbb{E}[\widehat{K}_1] = K, \qquad \mathrm{Bias}(\widehat{K}_1) = 0, \qquad \mathrm{Var}(\widehat{K}_1) = \mathrm{Var}_p(r).$$

常用的平方 estimator 为

$$\widehat{K}_2 = \frac{1}{2} r^2,$$

其相对于 K 的偏差和方差为

$$\mathrm{Bias}(\widehat{K}_2) = \frac{1}{2}\mathbb{E}_p[r^2] - K, \qquad \mathrm{Var}(\widehat{K}_2) = \frac{1}{4}\left(\mathbb{E}_p[r^4] - \mathbb{E}_p[r^2]^2\right). \tag{3.22}$$

非负修正 estimator 为

$$\widehat{K}_3 = e^{-r} + r - 1.$$

因为 $e^{-r} = q(A)/p(A)$，有

$$\mathbb{E}_p[e^{-r}] = \sum_v q(v) = 1,$$

故 $\mathbb{E}[\widehat{K}_3] = K$，且

$$\mathrm{Var}(\widehat{K}_3) = \mathrm{Var}_p(e^{-r} + r - 1). \tag{3.23}$$

K3 的方差还可展开为

$$\mathrm{Var}(\widehat{K}_3) = \mathrm{Var}_p(r) + \mathrm{Var}_p(e^{-r}) + 2\,\mathrm{Cov}_p(r, e^{-r}).$$

因此 K3 比 K1 方差小的充要条件是

$$\mathrm{Var}_p(e^{-r}) + 2\,\mathrm{Cov}_p(r, e^{-r}) < 0.$$

K3 的逐样本非负性来自 $e^{-r} \geq 1 - r$，并不推出全局方差排序。对 $q(v) = p(v)(1 + \varepsilon u_v)$、$\mathbb{E}_p[u] = 0$ 的局部扰动，逐项 Taylor 展开给出

$$r_v = -\varepsilon u_v + \frac{\varepsilon^2 u_v^2}{2} + O(\varepsilon^3), \quad K = \frac{\varepsilon^2}{2}\mathbb{E}_p[u^2] + O(\varepsilon^3),$$

$$\widehat{K}_2 = \frac{\varepsilon^2 u_A^2}{2} + O(\varepsilon^3), \quad \widehat{K}_3 = \frac{\varepsilon^2 u_A^2}{2} + O(\varepsilon^3).$$

这解释了 K2 的局部二阶正确性，以及 K3 在两分布接近时将单点波动从一阶降到二阶的机制。K1 是总定理中 $a = 0$ 的特例。K3 则取 $a_v = 1 - e^{-r_v}$，因为 $I_p(a) = 1 - \sum_v q(v) = 0$，总定理给出 $r_A - a_A = e^{-r_A} + r_A - 1$。K2 改变了数值目标而未补回残差，所以需要直接报告上面的偏差。

3.4.4 采样尾部的无偏 scalar 估计量

令

$$\mu_r = \mathbb{E}[r_A \mid A \notin S] = \log \frac{\tau_p}{\tau_q} + \mathrm{KL}(p_{\mathrm{tail}} \| q_{\mathrm{tail}}).$$

则 $\tau_p \mu_r = M + B$。头部精确、尾部采样（Head-Exact Tail-Sampled，HETS）的数值估计量为

$$\widehat{K}^{\mathrm{HETS}} = H + J_A r_A. \tag{3.24}$$

它是总定理中头部 $a_v = r_v$、尾部 $a_v = 0$ 的特例。本章后续统一称为 HETS 数值估计量；EMA 只在对应原项目名称时出现。时间上的指数滑动平均不属于此命名。

定理 3.8 (HETS 数值的无偏性与方差)

若 $A \sim p$ 且 $\mathbb{E}_p[r_A^2] < \infty$，则

$$\mathbb{E}[\widehat{K}^{\mathrm{HETS}}] = K,$$

并且

$$\mathrm{Var}(\widehat{K}^{\mathrm{HETS}}) = \tau_p \,\mathrm{Var}(r_A \mid A \notin S) + P\tau_p \mu_r^2 \tag{3.25}$$

$$= \sum_{v \notin S} p(v) r_v^2 - \left(\sum_{v \notin S} p(v) r_v \right)^2 . \tag{3.26}$$

♡

证明 尾部修正的期望为

$$\mathbb{E}[J_A r_A] = \sum_{v \notin S} p(v) r_v = \tau_p \mu_r = M + B.$$

加上 H 得到 K。对随机变量 $J_A r_A$ 按 J_A 使用全方差公式：头部条件下它为零，尾部条件下它为 r_A，因此

$$\mathrm{Var}(J_A r_A) = \tau_p \,\mathrm{Var}(r_A \mid A \notin S) + P\tau_p \mu_r^2.$$

还可以用尾部桶 scalar

$$\ell_{\mathrm{tail}} = \log \frac{\tau_p}{\tau_q}$$

作残差化：

$$\widehat{K}^{\text{Res-scalar}} = H + \tau_p \ell_{\mathrm{tail}} + J_A (r_A - \ell_{\mathrm{tail}}). \tag{3.27}$$

它满足

$$\mathbb{E}[\widehat{K}^{\text{Res-scalar}}] = K,$$

且

$$\mathrm{Var}(\widehat{K}^{\text{Res-scalar}}) = \tau_p \,\mathrm{Var}(r_A \mid A \notin S) + P\tau_p (\mu_r - \ell_{\mathrm{tail}})^2. \tag{3.28}$$

所以 scalar 残差化相对 HETS 的方差差为

$$\mathrm{Var}(\widehat{K}^{\mathrm{HETS}}) - \mathrm{Var}(\widehat{K}^{\text{Res-scalar}}) = P\tau_p (2\mu_r \ell_{\mathrm{tail}} - \ell_{\mathrm{tail}}^2). \tag{3.29}$$

它严格降低方差当且仅当 $|\mu_r - \ell_{\mathrm{tail}}| < |\mu_r|$。当固定的 $\ell_{\mathrm{tail}} \neq 0$ 且尾部内部形状 KL 足够小时，μ_r 足够接近 ℓ_{tail}，严格降方差条件成立；若 $\ell_{\mathrm{tail}} = 0$，两估计量逐样本相同。

命题 3.4 (标量尾部控制族)

对任意在抽样前固定的实数 β，令

$$\widehat{K}(\beta) = H + \tau_p \beta + J_A (r_A - \beta).$$

则它对 K 无偏，且

$$\mathrm{Var}(\widehat{K}(\beta)) = \tau_p \,\mathrm{Var}_{\mathrm{tail}}(r_A) + P\tau_p (\mu_r - \beta)^2.$$

因此最优标量控制为 $\beta^* = \mu_r$；HETS 取 $\beta = 0$，式 (3.27) 取 $\beta = \ell_{\mathrm{tail}}$。

♠

证明 先计算均值：

$$\mathbb{E}[\widehat{K}(\beta)] = H + \tau_p \beta + \tau_p (\mu_r - \beta) = H + \tau_p \mu_r = K.$$

再计算中心化随机项的二阶矩：

$$\begin{aligned}\mathrm{Var}(\widehat{K}(\beta)) &= \mathbb{E}[J_A(r_A-\beta)^2] - \{\mathbb{E}[J_A(r_A-\beta)]\}^2 \\ &= \tau_p\{\mathrm{Var}_{\mathrm{tail}}(r_A) + (\mu_r-\beta)^2\} - \tau_p^2(\mu_r-\beta)^2 \\ &= \tau_p\,\mathrm{Var}_{\mathrm{tail}}(r_A) + P\tau_p(\mu_r-\beta)^2.\end{aligned}$$

最后一项非负并在 $\beta=\mu_r$ 时为零，给出最优值。将 $\beta=0$ 与 $\beta=\ell_{\mathrm{tail}}$ 代入并相减即得式 (3.29)。

这个 scalar 构造是本章从控制族导出的 KL 数值估计量，应与论文中以向量梯度为目标的 ResOPD 算法区别命名。因为 $\mu_r=\ell_{\mathrm{tail}}+D_{\mathrm{tail}}$，其中 $D_{\mathrm{tail}}=\mathrm{KL}(p_{\mathrm{tail}}\|q_{\mathrm{tail}})$，方差改变量也等于

$$P\tau_p\{\ell_{\mathrm{tail}}^2 + 2\ell_{\mathrm{tail}}D_{\mathrm{tail}}\}.$$

当 $\ell_{\mathrm{tail}}\geq 0$ 时它非负；当 $\ell_{\mathrm{tail}}<0$ 时，它在 $D_{\mathrm{tail}}>-\ell_{\mathrm{tail}}/2$ 下为负。这给出 scalar 残差化反而增大方差的明确条件。

3.5 KL 梯度：相同积分下的不同控制

本节固定目标 $g=I_p(rs)$，总定理中的 $f_v=r_vs_v$ 是向量，随机估计量默认使用 $\rho=p$。数值估计量的分类逐项迁移到这个目标，但其控制函数和最优系数须在向量二阶矩下重新计算。沿用前节的 $h_g,\bar{s}_{\mathrm{tail}},b_{\mathrm{TA}}$，并定义

$$\mu_g=\mathbb{E}_p[r_As_A\mid J_A=1],\qquad d_P=\nabla P=\sum_{v\in S}p(v)s_v,\qquad g=h_g+\tau_p\mu_g.$$

头部截断梯度为 h_g，其偏差和方差为

$$\mathrm{Bias}(h_g)=-\tau_p\mu_g,\qquad \mathrm{Var}(h_g)=0. \tag{3.30}$$

3.5.1 HETS 与 ResOPD 的向量残差化

尾部残差化在线策略蒸馏（On-Policy Distillation with Tail Residualization，ResOPD）从 HETS 的尾部梯度中减去可计算控制向量，再解析加回同一控制的期望。

HETS 梯度 estimator 定义为

$$\widehat{g}^{\mathrm{HETS}}=h_g+J_Ar_As_A. \tag{3.31}$$

它无偏，且

$$\mathrm{Var}(\widehat{g}^{\mathrm{HETS}})=\tau_p\,\mathrm{Var}_{\mathrm{tail}}(r_As_A)+P\tau_p\|\mu_g\|_2^2. \tag{3.32}$$

将尾部聚合为伪 token，定义

$$b_{\mathrm{TA}}=\log\frac{\tau_p}{\tau_q}\,\nabla_\theta\log\tau_p. \tag{3.33}$$

这个控制向量来自定理 3.7 的粗粒度梯度。对头尾分区直接代入该定理，得到 $\nabla(H+\tau_p\ell_{\mathrm{tail}})=h_g+\tau_pb_{\mathrm{TA}}$。因此完整梯度与粗粒度梯度之差为 $\tau_p(\mu_g-b_{\mathrm{TA}})$。使用 $J_A(r_As_A-b_{\mathrm{TA}})$ 对该残差作无偏抽样，再加上粗粒度精确梯度，便得到 ResOPD。对任意 action-independent 向量 b（与标量尾部形状项 B 区分），定义统一控制族

$$\widehat{g}(b)=h_g+\tau_pb+J_A(r_As_A-b). \tag{3.34}$$

定理 3.9 (ResOPD 控制族的无偏性与方差)

在 $A\sim p$ 且 b 在抽样前冻结时，

$$\mathbb{E}[\widehat{g}(b)]=g,$$

并且

$$\mathrm{Var}(\widehat{g}(b))=\tau_p\,\mathrm{Var}_{\mathrm{tail}}(r_As_A)+P\tau_p\|\mu_g-b\|_2^2. \tag{3.35}$$

HETS 是 $b = 0$；ResOPD 是 $b = b_{\mathrm{TA}}$。 ♡

证明 条件期望为

$$\mathbb{E}[\widehat{g}(b)] = h_g + \tau_p b + \tau_p(\mu_g - b) = g.$$

给定 $J_A = 0$ 时 estimator 为 $h_g + \tau_p b$，给定 $J_A = 1$ 时其条件均值为 $h_g + \tau_p b + \mu_g - b$，两者均值差为 $\mu_g - b$。尾部条件下的随机部分为 $r_A s_A - b$，其协方差与 $r_A s_A$ 相同。对事件 J_A 使用全协方差公式，得到式 (3.35)。

ResOPD 与 HETS 的方差差为

$$\mathrm{Var}(\widehat{g}^{\mathrm{HETS}}) - \mathrm{Var}(\widehat{g}^{\mathrm{ResOPD}}) = P\tau_p \left(2\langle \mu_g, b_{\mathrm{TA}}\rangle - \|b_{\mathrm{TA}}\|_2^2\right). \tag{3.36}$$

因此 ResOPD 的优势条件是 $\|\mu_g - b_{\mathrm{TA}}\|_2 < \|\mu_g\|_2$。这正是 ResOPD 与 scalar KL 残差化的共同结构，区别只在于 scalar 的尾部均值是 μ_r，向量梯度的尾部均值是 μ_g。

该方差结论也有完整的协方差版本。记 $\Sigma_{\mathrm{tail}} = \mathrm{Cov}_{\mathrm{tail}}(r_A s_A)$，则

$$\mathrm{Cov}(\widehat{g}(b)) = \tau_p \Sigma_{\mathrm{tail}} + P\tau_p(\mu_g - b)(\mu_g - b)^\top.$$

取迹即得到前面的方差公式。最优的无约束向量控制是 $b^* = \mu_g$，此时只剩 $\tau_p \Sigma_{\mathrm{tail}}$；该向量需要未知尾部，因此理论最优值不能作为 sparse payload 下的可计算算法。ResOPD 使用可计算的 b_{TA} 逼近它。

HETS 也不保证对每个分布都比直接 sampled-token 方差小。令 $\mu_{g,H} = \mathbb{E}[r_A s_A \mid A \in S]$、$V_H = \mathrm{Var}(r_A s_A \mid A \in S)$，全方差公式给出

$$\mathrm{Var}(r_A s_A) = PV_H + \tau_p \,\mathrm{Var}_{\mathrm{tail}}(r_A s_A) + P\tau_p \|\mu_{g,H} - \mu_g\|^2,$$

$$\mathrm{Var}(r_A s_A) - \mathrm{Var}(\widehat{g}^{\mathrm{HETS}}) = PV_H + P\tau_p\{\|\mu_{g,H}\|^2 - 2\langle \mu_{g,H}, \mu_g\rangle\}.$$

头部精确求和删除了头部内部方差，但同时改变了事件间均值差，因此应使用这个差值判断排序。

3.5.2 多样本、均方误差与支持集边界

以上随机 estimator 均按单个动作计算。对固定 prefix 下 n 个独立动作，使用同一确定性头部和控制项、对随机修正取平均，则偏差保持不变、协方差除以 n。标量均方误差为

$$\mathrm{MSE}(\widehat{K}) = \mathrm{Bias}(\widehat{K})^2 + \mathrm{Var}(\widehat{K}),$$

向量均方误差为

$$\mathbb{E}\|\widehat{g} - g\|^2 = \|\mathrm{Bias}(\widehat{g})\|^2 + \mathrm{Var}(\widehat{g}).$$

因此确定性截断的零抽样方差不等于零估计误差；增加样本也无法消除它的偏差。这里的 $1/n$ 结论要求条件独立，同一条 trajectory 上不同 prefix 的 token 不能直接视为同一固定分布的独立重复。

当 $S = \mathcal{V}$ 时，所有尾部修正按连续延拓取零，头部求和等于完整 KL 或其完整 score 梯度，方差为零；当 $S = \varnothing$ 时，HETS 退化为直接 sampled-token，$\tau_p = \tau_q = 1$ 使 ResOPD 控制为零。存在零概率时必须先检查绝对连续性及矩条件；尤其 K3 的 $\mathbb{E}_p[q(A)/p(A)] = 1$ 要求 q 的质量全部落在 p 的支持上。

3.6 双控制族：事件间方差与尾部内部方差

单控制 ResOPD 只改变头部与尾部两个事件的条件均值差。本节将总定理中的近似扩展为一个尾部常向量与一个条件零均值方向，并使用同一套 $r_v, s_v, J_A, \tau_p, \mu_g, b_{\mathrm{TA}}$ 记号。定义尾部平均 score

$$\bar{s}_{\mathrm{tail}} = \mathbb{E}_p[s_A \mid J_A = 1] = \frac{1}{\tau_p} \sum_{v \notin S} p(v) s_v = \nabla_\theta \log \tau_p.$$

沿用 $\ell_{\mathrm{tail}} = \log(\tau_p/\tau_q)$，于是 $b_{\mathrm{TA}} = \ell_{\mathrm{tail}} \bar{s}_{\mathrm{tail}}$。定义向量

$$\psi_v = \ell_{\mathrm{tail}}(s_v - \bar{s}_{\mathrm{tail}}), \qquad R_v^{\mathrm{shape}} = (r_v - \ell_{\mathrm{tail}}) s_v, \qquad v \notin S.$$

其中 ψ_v 是尾部条件零均值波动，R_v^{shape} 是尾部形状残差。逐点恒等式为

$$r_v s_v = b_{\text{TA}} + \psi_v + R_v^{\text{shape}}, \qquad \mathbb{E}_p[\psi_A \mid J_A = 1] = 0. \tag{3.37}$$

这些定义没有改变目标或采样分布。

3.6.1 双控制是总定理的两个正交方向

在式 (3.2) 中取头部 $a_v = r_v s_v$、尾部 $a_v = b + \gamma\psi_v$。因为 $\mathbb{E}_{p_{\text{tail}}}\psi_A = 0$，精确积分为 $h_g + \tau_p b$，立即得到下面的双控制估计量。

其正交结构也可以直接从 Gram 矩阵看出。尾部常向量的第 j 个坐标对应零均值控制 $(J_A - \tau_p)e_j$，尾部内部控制为 $J_A\psi_A$，其中 e_j 为参数空间的标准基向量。两列的 Gram 交叉项为

$$\mathbb{E}_p\langle (J_A - \tau_p)e_j, J_A\psi_A\rangle = P\tau_p\mathbb{E}_{p_{\text{tail}}}\langle e_j, \psi_A\rangle = 0.$$

因此 on-policy 下的 Gram 矩阵分成事件控制和尾部内部控制两个块。后面的两个平方代价来自这一块对角结构，而非两个控制之间的巧合抵消。

定理 3.10 (双控制估计量及其精确协方差)

对抽样前固定的向量 b 与标量 γ，定义

$$\widehat{g}(b,\gamma) = h_g + \tau_p b + J_A(r_A s_A - b - \gamma\psi_A), \qquad A \sim p.$$

则 $\mathbb{E}_p[\widehat{g}(b,\gamma)] = g$，并且

$$\operatorname{Cov}(\widehat{g}(b,\gamma)) = \tau_p \operatorname{Cov}_{\text{tail}}(r_A s_A - \gamma\psi_A) + P\tau_p(\mu_g - b)(\mu_g - b)^\top, \tag{3.38}$$

$$\operatorname{Var}(\widehat{g}(b,\gamma)) = \tau_p \operatorname{Var}_{\text{tail}}(r_A s_A - \gamma\psi_A) + P\tau_p\|\mu_g - b\|^2. \tag{3.39}$$

♡

证明 尾部条件下 ψ_A 的均值为零，所以

$$\mathbb{E}_p[J_A(r_A s_A - b - \gamma\psi_A)] = \tau_p(\mu_g - b).$$

加上确定性部分 $h_g + \tau_p b$ 就是 g。给定 $J_A = 0$ 时，估计量是常向量 $h_g + \tau_p b$；给定 $J_A = 1$ 时，均值为 $h_g + \tau_p b + \mu_g - b$，协方差为 $\operatorname{Cov}_{\text{tail}}(r_A s_A - \gamma\psi_A)$。两分支均值差为 $\mu_g - b$。将这两个条件协方差与条件均值协方差相加，得到式 (3.38)；取迹得到式 (3.39)。

定理 3.11 (双控制的最优值与精确代价)

令

$$V_\psi = \operatorname{Var}_{\text{tail}}(\psi_A), \qquad C_\psi = \mathbb{E}_{\text{tail}}\langle r_A s_A - \mu_g, \psi_A\rangle.$$

当 $V_\psi > 0$ 时，迹方差最优控制为

$$b^* = \mu_g, \qquad \gamma^* = \frac{C_\psi}{V_\psi}.$$

任意 b, γ 相对最优值的方差差恰好为

$$\operatorname{Var}(\widehat{g}(b,\gamma)) - \operatorname{Var}(\widehat{g}(b^*,\gamma^*)) = P\tau_p\|b - \mu_g\|^2 + \tau_p V_\psi(\gamma - \gamma^*)^2. \tag{3.40}$$

当 $V_\psi = 0$ 时，γ 不影响估计量的方差。

♡

证明 由 $\mathbb{E}_{\text{tail}}\psi_A = 0$，

$$\operatorname{Var}_{\text{tail}}(r_A s_A - \gamma\psi_A) = \operatorname{Var}_{\text{tail}}(r_A s_A) - 2\gamma C_\psi + \gamma^2 V_\psi.$$

对 γ 配方，得到

$$\operatorname{Var}_{\text{tail}}(r_A s_A - \gamma\psi_A) = \operatorname{Var}_{\text{tail}}(r_A s_A) - \frac{C_\psi^2}{V_\psi} + V_\psi(\gamma - \gamma^*)^2.$$

再代入式 (3.39)，两个非负平方项分别由 $b = \mu_g$ 与 $\gamma = \gamma^*$ 消去。若 $V_\psi = 0$，则 $\psi_A = 0$ 在尾部条件分布下几乎

处处成立。

3.6.2 HETS、ResOPD 与 SC-TA 的统一分类

样本修正 Tail-aware（Sample-Corrected Tail-Aware，SC-TA）与 ResOPD 的区别在尾部内部控制。双控制族中的坐标为

估计量	b	γ
HETS	0	0
ResOPD	b_{TA}	0
SC-TA	b_{TA}	1
不可计算的联合最优值	μ_g	γ^*

三种可计算估计量在 $A \sim p$ 下均无偏。令 $g_{\mathrm{TA}} = h_g + \tau_p b_{\mathrm{TA}}$，则逐样本有

$$\begin{aligned} \widehat{g}^{\mathrm{ResOPD}} &= g_{\mathrm{TA}} + J_A(R_A^{\mathrm{shape}} + \psi_A), \\ \widehat{g}^{\mathrm{SC\text{-}TA}} &= g_{\mathrm{TA}} + J_A R_A^{\mathrm{shape}}, \\ \widehat{g}^{\mathrm{SC\text{-}TA}} - \widehat{g}^{\mathrm{ResOPD}} &= -J_A\psi_A. \end{aligned}$$

这个差的期望为零，逐样本一般不为零。

命题 3.5 (SC-TA 与 ResOPD 的方差排序)

当 $V_\psi > 0$ 时，

$$\mathrm{Var}(\widehat{g}^{\mathrm{ResOPD}}) - \mathrm{Var}(\widehat{g}^{\mathrm{SC\text{-}TA}}) = \tau_p(2C_\psi - V_\psi) = \tau_p V_\psi(2\gamma^* - 1).$$

因此 SC-TA 方差更小当且仅当 $\gamma^* > 1/2$。一个充分条件为

$$\mathrm{Var}_{\mathrm{tail}}(R_A^{\mathrm{shape}}) < \frac{1}{4}\,\mathrm{Var}_{\mathrm{tail}}(\psi_A).$$

证明 在同一个 $b = b_{\mathrm{TA}}$ 下，事件间方差相同。将 $\gamma = 0, 1$ 代入尾部内部二次式并相减，得到第一式。由 $r_A s_A = b_{\mathrm{TA}} + R_A^{\mathrm{shape}} + \psi_A$，

$$C_\psi = V_\psi + \mathbb{E}_{\mathrm{tail}}\langle R_A^{\mathrm{shape}} - \mathbb{E}_{\mathrm{tail}} R_A^{\mathrm{shape}}, \psi_A\rangle.$$

Cauchy–Schwarz 不等式给出交叉项的下界

$$\mathbb{E}_{\mathrm{tail}}\langle R_A^{\mathrm{shape}} - \mathbb{E}_{\mathrm{tail}} R_A^{\mathrm{shape}}, \psi_A\rangle \geq -\sqrt{\mathrm{Var}_{\mathrm{tail}}(R_A^{\mathrm{shape}})V_\psi}.$$

给定充分条件时，右侧严格大于 $-V_\psi/2$，故 $2C_\psi - V_\psi > 0$。

当尾部条件形状完全相同，$r_v = \ell_{\mathrm{tail}}$ 对所有尾部 token 成立，此时 $R_A^{\mathrm{shape}} = 0$，SC-TA 等于确定性的完整梯度；ResOPD 仍保留 $J_A\psi_A$ 的零均值波动。因此即使尾部桶已经完全描述 KL 数值，ResOPD 的梯度估计也可以有非零方差。若 $V_\psi = 0$，两者逐样本相同。这是区分标量 KL 与向量梯度的一个直接例子。

上述所有排序针对协方差迹。较小的迹不推出协方差矩阵在半正定序下更小；事件间协方差之差是两个秩一矩阵之差，某些方向上的方差仍可增大。

当动作改由 ρ 抽样时，令 $w_A = p(A)/\rho(A)$，并假设 ρ 覆盖全部尾部。正确的重要性控制变成 $(J_A w_A - \tau_p)e_j$ 与 $J_A w_A \psi_A$。其交叉项为

$$\sum_{v \notin S} \frac{p(v)^2}{\rho(v)}\langle e_j, \psi_v\rangle,$$

一般不为零：ψ 的零均值只针对 p_{tail}，而这个交叉矩使用 p^2/ρ。因此非 on-policy 的最优常向量与内部控制应由完整 Gram 矩阵联合求解。仅在块交叉项确实为零时，才可以分别优化两个控制。

3.7 自动微分：数值与梯度的分别实现

前面的统一框架估计已经指定的积分。本节检查标量程序的反传究竟对应哪个积分。若一个程序同时用于 KL 日志与训练，审计对象应记录为 forward 数值和 backward 向量组成的有序对。本节涉及随机梯度的期望与偏差时默认 $\rho = p$；固定索引的逐样本求导规则本身不依赖抽样分布。

3.7.1 一个函数的两种求导路径

定理 3.12 (固定样本反传与采样测度补偿)

令 ϕ 是不另依赖参数 θ 的可微实函数，$A \sim p$，反传时固定样本索引。定义

$$F_A = \phi(r_A), \qquad \kappa_A = \frac{p(A)}{\operatorname{stopgrad}(p(A))}, \qquad L_A = \kappa_A \phi(r_A).$$

两者的 forward 值逐样本相同，固定样本导数分别为

$$\nabla F_A = \phi'(r_A) s_A, \qquad \nabla L_A = \{\phi(r_A) + \phi'(r_A)\} s_A.$$

后者的期望等于 $\nabla I_p(\phi(r))$。若仅将系数停止梯度，$\kappa_A \operatorname{stopgrad}(\phi(r_A))$ 的导数则为 $\phi(r_A) s_A$。 ♡

证明 固定索引下 $\nabla r_A = s_A$，链式法则给出第一式。forward 时 $\kappa_A = 1$；分母停止梯度，因而 $\nabla \kappa_A = s_A$。乘积法则给出第二式。再由式 (3.1)，

$$\nabla I_p(\phi(r)) = I_p\big(\phi'(r)s + \phi(r)s\big),$$

等于第二种导数的期望。停止整个 ϕ 时只保留 $\nabla \kappa_A$ 一项，得到最后的规则。

这个变换把 K1–K4 的差异归到同一个问题：给定 forward 函数后，程序保留了哪些乘积法则项。数值无偏是 $I_p(\phi(r)) = K$，裸反传无偏则是 $I_p(\phi'(r)s) = g$，两者是不同等式。

程序	forward 值	固定样本 backward
K1	r_A	s_A
K2	$r_A^2/2$	$r_A s_A$
K3	$e^{-r_A} + r_A - 1$	$(1 - e^{-r_A}) s_A$
K4	r_A	$r_A s_A$
$\mathrm{K4}^{\mathrm{live}}$	r_A	$(r_A + 1) s_A$
$\mathrm{K3}^{++}$	$e^{-r_A} + r_A - 1$	$r_A s_A$

数值方差按第二列计算，梯度方差按第三列计算。K5 的目标是正向 KL，随后单独代入同一求导规则。

3.7.2 K4 与固定样本的梯度替换

K1与 K3 的数值都无偏；K2 是以二阶矩换取局部稳定性的有偏 proxy。若需要同时让数值和自动微分梯度对应同一个 K，使用停止 log-ratio 系数的 K4：

$$\kappa_A = \frac{p(A)}{\operatorname{sg}(p(A))}, \qquad \widehat{K}_4 = \kappa_A \operatorname{stopgrad}(r_A).$$

数值上 $\kappa_A = 1$，所以 $\mathbb{E}[\widehat{K}_4] = K$；反传时

$$\nabla_\theta \widehat{K}_4 = r_A s_A,$$

因此

$$\mathbb{E}_p[\nabla_\theta \widehat{K}_4] = \nabla_\theta K = g.$$

K4 与 K1 的 forward 值逐样本相同，故 K4 的数值偏差为零，数值方差也为 $\mathrm{Var}_p(r)$。stop-gradient 只改变求导规则。另定义本项目单 token 测试采用的 live-log-ratio 变体

$$\widehat{K}_4^{\mathrm{live}} = \kappa_A r_A, \qquad \nabla \widehat{K}_4^{\mathrm{live}} = (r_A + 1) s_A.$$

它的数值仍与 K4 相同，梯度期望也相同，但梯度方差不同。后文始终保留上标 live，不将两种反传路径共用一个名称。

定理 3.13 (K4 的数值与梯度无偏性)

在本章正支持与固定参考假设下，$\widehat{K}_4$ 和 $\widehat{K}_4^{\mathrm{live}}$ 的数值均对 K 无偏，自动微分梯度均对 g 无偏。

证明 两者的数值为 r_A，期望是 $\sum_v p(v) r_v = K$。两者的梯度分别为 $r_A s_A$ 与 $(r_A+1)s_A$，期望之差为 $\sum_v p(v) s_v = 0$，因此都等于 g。

3.7.3 K3^{++} 与正向 KL 的 K5

EMA-PG 的公开实现使用上述停止系数 K4，并定义 K3^{++} 与 K5；以下公式先去掉 clipping，单独分析数学对象。[1]

$$\widehat{K}_{3++} = \kappa_A (e^{-r_A} + r_A - 1).$$

它的数值与 K3 相同，因此对反向 K 无偏，数值方差也与 K3 相同。其反传为

$$\nabla \widehat{K}_{3++} = \{e^{-r_A} + r_A - 1 + 1 - e^{-r_A}\} s_A = r_A s_A.$$

因此它与 K4 的 backward 逐样本相同，梯度偏差为零，梯度方差也完全相同；数值方差的差异不能解释成梯度方差的差异。

K5 对应正向目标 $K^{\mathrm{F}} = \mathrm{KL}(q\|p)$，定义为

$$\widehat{K}_5 = -\operatorname{stopgrad}(e^{-r_A}) r_A + \log p(A) - \operatorname{stopgrad}(\log p(A)).$$

其 forward 值为 $-e^{-r_A} r_A$。在 $A \sim p$ 下，

$$\mathbb{E}_p[\widehat{K}_5] = -\sum_v q(v) r_v = K^{\mathrm{F}}, \qquad \mathrm{Var}(\widehat{K}_5) = \mathbb{E}_p[e^{-2r_A} r_A^2] - (K^{\mathrm{F}})^2.$$

它相对本章默认反向目标 K 的数值偏差是 $K^{\mathrm{F}} - K$，不能与 K1–K4 按同一个无偏目标直接并列。反传为

$$\nabla \widehat{K}_5 = (1 - e^{-r_A}) s_A, \qquad \mathbb{E}_p[\nabla \widehat{K}_5] = -\sum_v q(v) s_v = \nabla K^{\mathrm{F}}.$$

其梯度方差为

$$\mathbb{E}_p[(1 - e^{-r_A})^2 \|s_A\|^2] - \left\| \sum_v q(v) s_v \right\|^2.$$

这里正向目标只改变 KL 的积分方向，student 与 score 的定义保持不变。

若数值稳定化把 K3 的函数 $\phi(r) = e^{-r} + r - 1$ 改成分段可导的 $\widetilde{\phi}(r)$，K3^{++} 的数值偏差和梯度偏差分别变成

$$\mathbb{E}_p[\widetilde{\phi}(r_A)] - K, \qquad \mathbb{E}_p[(\widetilde{\phi}(r_A) + \widetilde{\phi}'(r_A) - r_A) s_A].$$

公开代码对 log-ratio 与输出均有 clamp，因此无 clipping 恒等式的适用条件是相关 clamp 未激活，或相关偏差项经额外核验为零。

[1] 代码版本固定为 EMA-PG `f9b9776`，定义见该版本的 `core_algos.py`。

3.7.4 数值 estimator 的自动微分梯度

把已经抽到的动作视为固定索引，对 K1–K4 直接反传，得到

$$G_1 = s_A, \quad G_2 = r_A s_A, \quad G_3 = (1 - e^{-r_A}) s_A, \quad G_4 = r_A s_A.$$

令 $u_q = \mathbb{E}_q[s_A]$，则这些随机梯度相对于 g 的偏差为

$$\mathrm{Bias}(G_1) = -g, \quad \mathrm{Bias}(G_2) = 0, \quad \mathrm{Bias}(G_3) = -u_q - g, \quad \mathrm{Bias}(G_4) = 0.$$

对应方差逐项为

$$\begin{aligned}
\mathrm{Var}(G_1) &= \mathbb{E}_p \|s_A\|^2, \\
\mathrm{Var}(G_2) &= \mathbb{E}_p[r_A^2 \|s_A\|^2] - \|g\|^2, \\
\mathrm{Var}(G_3) &= \mathbb{E}_p[(1 - e^{-r_A})^2 \|s_A\|^2] - \|u_q\|^2, \\
\mathrm{Var}(G_4) &= \mathbb{E}_p[r_A^2 \|s_A\|^2] - \|g\|^2.
\end{aligned}$$

例如 $\mathbb{E}_p[G_3] = \mathbb{E}_p[s_A] - \mathbb{E}_p[(q(A)/p(A)) s_A] = -u_q$。由此得到两个明确区别：K2 的数值有偏但其固定样本反传梯度无偏；K1 与 K3 的数值无偏但其裸反传梯度通常有偏。这些期望在每次抽样均使用当前 p 时成立；不能将固定样本的导数与包含采样测度导数的 $\nabla_\theta \mathbb{E}_{p_\theta}$ 混用。

确定性 Top-J 数值目标的梯度也可以显式计算。记

$$d_P = \nabla_\theta P = \sum_{v \in S} p(v) s_v, \qquad \ell_{\mathrm{tail}} = \log(\tau_p / \tau_q).$$

由乘积法则与 $\nabla_\theta \tau_p = -d_P$，有

$$\begin{aligned}
\nabla_\theta H &= h_g + d_P, \\
\nabla_\theta (H + M) &= h_g - \ell_{\mathrm{tail}} d_P = h_g + \tau_p b_{\mathrm{TA}}, \\
\nabla_\theta K_J^{\mathrm{norm}} &= \frac{h_g}{P} - \frac{H}{P^2} d_P.
\end{aligned}$$

所以三者相对于完整 KL 梯度的偏差依次为

$$d_P - \tau_p \mu_g, \qquad \tau_p (b_{\mathrm{TA}} - \mu_g), \qquad \frac{h_g}{P} - \frac{H}{P^2} d_P - g,$$

方差均为零。尤其 h_g 是停止系数的头部 score 梯度，$\nabla H = h_g + d_P$ 是头部数值的真实梯度；两者必须分别命名。

3.7.5 停止梯度 surrogate 的显式构造

为把数学上的梯度向量对应到可反传的标量，记 sg 为停止梯度算子。固定抽样动作和事件，定义

$$\begin{aligned}
L_{\mathrm{HETS}} &= \sum_{v \in S} \mathrm{sg}(p(v) r_v) \log p(v) + J_A \, \mathrm{sg}(r_A) \log p(A), \\
L_{\mathrm{Res}} &= L_{\mathrm{HETS}} + \mathrm{sg}((\tau_p - J_A) \ell_{\mathrm{tail}}) \log \tau_p.
\end{aligned}$$

逐项反传，得到

$$\begin{aligned}
\nabla L_{\mathrm{HETS}} &= h_g + J_A r_A s_A, \\
\nabla L_{\mathrm{Res}} &= h_g + J_A r_A s_A + (\tau_p - J_A) \ell_{\mathrm{tail}} \nabla \log \tau_p \\
&= h_g + \tau_p b_{\mathrm{TA}} + J_A (r_A s_A - b_{\mathrm{TA}}).
\end{aligned}$$

这两条等式依赖停止整个系数的梯度，包括其中的 $p(v)$、r_v、τ_p 和 ℓ_{tail}；若遗漏停止操作，就会引入额外导数。

若希望 forward 展示某个数值估计量 F，同时 backward 使用 L 的梯度，可定义

$$\widetilde{L} = \mathrm{sg}(F) + L - \mathrm{sg}(L).$$

逐样本有 $\widetilde{L} = F$，但 $\nabla \widetilde{L} = \nabla L$。因此 forward 的数值偏差和 backward 的梯度偏差可以独立设计，审计时必须同

时给出 F 和 L。

3.7.6 K4 尾部反传与 HETS 的精确关系

前文 HETS 数值估计量在项目中也称为 EMA，其公式为 $\widehat{K}^{\mathrm{HETS}} = H + J_A r_A$。若头部按真实数值 H 求导，而尾部使用本章明确命名的 K4^{live} 构造，则自动微分得到

$$\widehat{g}^{\text{EMA-K4}} = h_g + d_P + J_A(r_A + 1)s_A, \qquad d_P = \nabla_\theta P.$$

这与 HETS 的 $h_g + J_A r_A s_A$ 相差 $d_P + J_A s_A$。因为 $\mathbb{E}_p[J_A s_A] = \nabla_\theta \tau_p = -d_P$，差值期望为零，但样本和方差均不同。

定理 3.14 (头尾 score 常数的匹配)

对固定实数 α，定义

$$\widehat{g}_\alpha = h_g + \alpha d_P + J_A(r_A + \alpha)s_A.$$

则它对 g 无偏，且

$$\mathrm{Var}(\widehat{g}_\alpha) = \sum_{v \notin S} p(v)(r_v + \alpha)^2 \|s_v\|^2 - \|\tau_p \mu_g - \alpha d_P\|^2. \tag{3.41}$$

$\alpha = 0$ 是 HETS，$\alpha = 1$ 是真实头部数值加 masked K4^{live} 尾部的反传。

证明 期望为

$$h_g + \alpha d_P + \tau_p \mu_g + \alpha \sum_{v \notin S} p(v) s_v = h_g + \tau_p \mu_g = g.$$

确定性头部不贡献协方差；随机尾部的均值为 $\tau_p \mu_g - \alpha d_P$，二阶矩为式 (3.41) 的求和项，两者相减得到方差。

如果误把真实头部梯度 $h_g + d_P$ 与尾部的 $J_A r_A s_A$ 拼接，得到的期望为 $g + d_P$，偏差为 d_P。若头部停止系数为 h_g，尾部却使用 $J_A(r_A + 1)s_A$，偏差为 $-d_P$。两端的 score 常数必须匹配；仅凭“精确头部加 sampled tail”这句话无法判断无偏性。

EMA-PG 固定版本的 `compute_memory_efficient_kl` 在 `full_reverse` 路径中直接反传头部 H，尾部使用停止 log-ratio 的 K4。因此在共同固定支持、无 clipping 且尾部测度校正正确时，forward 无偏，backward 的偏差为 d_P。actor 传入的 log-importance weight 已 detach，不能通过它的导数消掉 d_P。[2]本章所证明的无偏 EMA 数值结构与论文 HETS 的向量结构，不能据名称相近就认定为该路径的逐样本反传行为。

本仓库的 `tests/test_kl_estimators.py` 核验单 token K4^{live} 的数值与梯度，对应 $(r_A+1)s_A$。`experiments/analysis/ema_topk_k_analysis.py` 中的结构统计采用 $h_g + d_P$ 头部与 $r_A s_A$ 尾部，其期望具有上述 d_P 偏差；这些统计不能作为正确匹配头尾常数的估计量或 HETS 的无偏性证据。`src/mirroropd/training/losses.py` 的 OPD baseline 使用停止梯度的 Tail-aware 标量，属于 scalar baseline 路径。本章的数学分类分别描述这三个实际对象。

3.8 采样设计：on-policy、尾部条件采样与旧 rollout

总定理从一开始区分 ν 与 ρ。本节把已有结论用于实际采样设计，所有积分目标和 log-ratio 保持不变。

[2]同一固定版本的 actor 路径见 `dp_actor.py`。

3.8.1 重要性校正与最优尾部常控制

推论 3.2 (直接重要性采样)

总定理取 $a=0$，便得到

$$\widehat{I}=\frac{\nu(A)}{\rho(A)}f_A,\qquad \mathbb{E}_\rho\widehat{I}=I_\nu(f),\qquad \mathrm{Var}_\rho(\widehat{I})=\sum_v\frac{\nu(v)^2}{\rho(v)}\|f_v\|^2-\|I_\nu(f)\|^2,$$

其中求和只作用于 $\rho(v)>0$ 的非零贡献。对反向 KL 的数值和梯度，分别取 $(\nu,f)=(p,r)$、(p,rs)；对正向目标，分别取 $(q,-r)$、$(q,-s)$。

尾部常控制的近似函数为头部 $a_v=f_v$、尾部 $a_v=b$。本小节比较所有可能的常控制，统一要求 $\rho(v)>0$ 对每个尾部动作成立；精确头部允许 $\rho(v)=0$。这个条件保证二次型对任意 b 都有定义。定义

$$h_f=\sum_{v\in S}p(v)f_v,\qquad \mu_f=\mathbb{E}_{p_{\mathrm{tail}}}f_A,\qquad w_v=p(v)/\rho(v).$$

总定理直接给出

$$\widehat{I}_\rho(b)=h_f+\tau_p b+J_Aw_A(f_A-b),\tag{3.42}$$

$$\mathrm{Var}_\rho(\widehat{I}_\rho(b))=\sum_{v\notin S}\frac{p(v)^2}{\rho(v)}\|f_v-b\|^2-\tau_p^2\|\mu_f-b\|^2.\tag{3.43}$$

为了与各估计量的标签对应，标量代入 $f=r,b=\beta$ 的式子记为

$$\widehat{K}_\rho(\beta)=H+\tau_p\beta+J_Aw_A(r_A-\beta),\tag{3.44}$$

向量代入 $f=rs$ 的式子记为

$$\widehat{g}_\rho(b)=h_g+\tau_p b+J_Aw_A(r_As_A-b).\tag{3.45}$$

式 (3.43) 的两次代入就是它们各自的方差；两种值域无需再证明两遍重要性采样。

命题 3.6 (任意采样测度下的最优尾部常控制)

记

$$W=\sum_{v\notin S}\frac{p(v)^2}{\rho(v)},\qquad U_f=\sum_{v\notin S}\frac{p(v)^2}{\rho(v)}f_v,\qquad T_f=\tau_p\mu_f.$$

若 $W>\tau_p^2$，则

$$b^*_\rho=\frac{U_f-\tau_pT_f}{W-\tau_p^2}.$$

若 $W=\tau_p^2$，尾部控制逐样本抵消，方差与 b 无关。

证明 展开式 (3.43)，与 b 有关的项为

$$-2\langle U_f-\tau_pT_f,b\rangle+(W-\tau_p^2)\|b\|^2.$$

当二次项系数严格为正时配方即得最优值。由 Cauchy–Schwarz，

$$\tau_p^2\le\left(\sum_{v\notin S}\frac{p(v)^2}{\rho(v)}\right)\left(\sum_{v\notin S}\rho(v)\right)\le W.$$

等号要求 ρ 全部质量在尾部，且与 p_{tail} 成比例，此时 $\rho=p_{\mathrm{tail}}$、$J_Aw_A=\tau_p$，式 (3.42) 的控制项直接抵消。当 $\rho=p$ 时，$W=\tau_p$、$U_f=T_f$，最优控制退化为 μ_f。

3.8.2 尾部条件采样与真正的分层方差减少

若能够单独从 p_{tail} 采样 $B_1, \dots, B_n$，则

$$\widehat{I}_{\text{tail}} = h_f + \frac{\tau_p}{n} \sum_{i=1}^{n} f_{B_i}, \qquad \operatorname{Var}(\widehat{I}_{\text{tail}}) = \frac{\tau_p^2}{n} \operatorname{Var}_{p_{\text{tail}}}(f).$$

证明是在总定理中取 $\rho = p_{\text{tail}}$，再独立平均。常控制 β 或 b 逐样本完全抵消，故此时 ResOPD 型的尾部常量控制没有额外作用。相同 n 下，on-policy 头尾控制的方差为

$$\frac{1}{n}\{\tau_p \operatorname{Var}_{p_{\text{tail}}}(f) + P\tau_p \|\mu_f - b\|^2\}.$$

它与条件尾部采样的差为

$$\frac{P\tau_p}{n}\{\operatorname{Var}_{p_{\text{tail}}}(f) + \|\mu_f - b\|^2\} \geq 0.$$

这是数学上的同样本数比较。实际采样器是否能取得尾部条件样本、是否需要额外 teacher 查询和拒绝采样，决定成本比较。

更一般地，若对每个分区单元独立抽样 n_C 次，则

$$\widehat{I}_{\text{strat}} = \sum_C P_C \frac{1}{n_C} \sum_{i=1}^{n_C} f_{B_{C,i}}, \qquad \operatorname{Var}(\widehat{I}_{\text{strat}}) = \sum_C \frac{P_C^2}{n_C} \operatorname{Var}_{p_C}(f).$$

这类分层积分直接消去了单元之间的抽样质量波动。给定连续预算 $\sum_C n_C = N$、定义 $\sigma_C^2 = \operatorname{Var}_{p_C}(f)$，Cauchy–Schwarz 给出

$$\sum_C \frac{P_C^2 \sigma_C^2}{n_C} \geq \frac{(\sum_C P_C \sigma_C)^2}{N}, \qquad n_C^* = \frac{N P_C \sigma_C}{\sum_D P_D \sigma_D}.$$

零方差单元可以精确返回其常值；整数预算需另外取整。这里优化的是协方差迹，向量情形也使用相同 σ_C。

3.8.3 截断与旧 rollout 的偏差由残差决定

若仍以单位权重使用头尾控制，实际 $A \sim \rho$，总偏差定理给出

$$\mathbb{E}_\rho[\widehat{I}(b)] - I_p(f) = \sum_{v \notin S} (\rho(v) - p(v))(f_v - b). \tag{3.46}$$

令 $\tau_\rho = \rho(S^c)$、$\mu_{f,\rho} = \mathbb{E}_\rho[f_A \mid J_A = 1]$，条件协方差分解给出

$$\operatorname{Var}_\rho(\widehat{I}(b)) = \tau_\rho \operatorname{Var}_{\rho,\text{tail}}(f_A) + (1 - \tau_\rho)\tau_\rho \|\mu_{f,\rho} - b\|^2. \tag{3.47}$$

因此更低的实际抽样方差与非零目标偏差可以同时出现。

旧 rollout 应使用实际生成概率 ρ 校正；当前完整 softmax 只定义目标 p。温度变换保留支持时，若 ρ 已知便可校正。top-p/top-k 删除未知尾部动作时，总定理中的缺失支持项

$$-\sum_{v:\rho(v)=0} p(v)(f_v - a_v)$$

给出无法由有限重要性权重恢复的贡献。只有已精确覆盖的动作残差为零时，支持缺失才不影响该目标。

若把正确权重 w_v 截断为 $\bar{w}_v$，额外偏差为

$$\sum_{v:\rho(v)>0} \rho(v)(\bar{w}_v - w_v)(f_v - a_v).$$

这也是同一个偏差定理的特例。通过近似减小未知动作上的残差，是缓解权重误差的方法；它不改变对支持和生成测度的要求。

3.8.4 正向 Top-J：只替换积分权重与函数

使用完全相同的 p, q, S, τ_p, τ_q，定义正向头部

$$H^{\text{F}} = -\sum_{v \in S} q(v) r_v, \qquad B^{\text{F}} = \tau_q \operatorname{KL}(q_{\text{tail}} \| p_{\text{tail}}).$$

逐项将尾部 log-ratio 拆成质量与条件形状，得到

$$K^{\mathrm{F}} = H^{\mathrm{F}} - \tau_q \ell_{\mathrm{tail}} + B^{\mathrm{F}}.$$

因此正向 Truncated、Tail-aware、Normalized 三个数值目标分别为

$$H^{\mathrm{F}}, \qquad H^{\mathrm{F}} - \tau_q \ell_{\mathrm{tail}}, \qquad \frac{H^{\mathrm{F}}}{Q} + \log \frac{P}{Q}.$$

相对完整正向 K^{F} 的偏差分别为

$$\tau_q \ell_{\mathrm{tail}} - B^{\mathrm{F}}, \qquad -B^{\mathrm{F}}, \qquad \frac{H^{\mathrm{F}}}{Q} + \log \frac{P}{Q} - K^{\mathrm{F}},$$

且固定 prefix 下方差均为零。这里 B^{F} 与前文 B 分别对应不同方向的尾部条件 KL，上标始终保留。

对标量尾部控制 β，完整正向 KL 的无偏校正为

$$\widehat{K}^{\mathrm{F}}_{\rho}(\beta) = H^{\mathrm{F}} + \tau_q \beta + J_A \frac{q(A)}{\rho(A)}(-r_A - \beta).$$

令 $\mu_r^{\mathrm{F}} = \mathbb{E}_{q_{\mathrm{tail}}}[-r_A]$，则其方差为

$$\mathrm{Var}_{\rho}(\widehat{K}^{\mathrm{F}}_{\rho}(\beta)) = \sum_{v \notin S} \frac{q(v)^2}{\rho(v)}(-r_v - \beta)^2 - \tau_q^2(\mu_r^{\mathrm{F}} - \beta)^2.$$

证明是定理 3.2 在尾部对积分分布 q 的直接应用：修正项均值是 $\tau_q(\mu_r^{\mathrm{F}} - \beta)$，恰好补齐尾部。

梯度方面，定义 $h_g^{\mathrm{F}} = -\sum_{v \in S} q(v) s_v$。因为 q 固定，逐项求导给出

$$\nabla H^{\mathrm{F}} = h_g^{\mathrm{F}},$$

$$\nabla(H^{\mathrm{F}} - \tau_q \ell_{\mathrm{tail}}) = h_g^{\mathrm{F}} - \tau_q \bar{s}_{\mathrm{tail}},$$

$$\nabla\left(\frac{H^{\mathrm{F}}}{Q} + \log \frac{P}{Q}\right) = \frac{h_g^{\mathrm{F}}}{Q} + \frac{d_P}{P}.$$

三者的梯度偏差分别是上述向量减去 g^{F}，梯度方差均为零。这里 $\bar{s}_{\mathrm{tail}} = \nabla \log \tau_p$ 是 student 尾部平均 score；它不能替换为未知的 teacher 尾部平均 score。特别地，正向 Tail-aware 梯度偏差为

$$\sum_{v \notin S} q(v) s_v - \tau_q \bar{s}_{\mathrm{tail}}.$$

正向头部梯度与反向头部梯度的差异来自积分权重：H^{F} 的权重 q 冻结，因此没有反向 ∇H 中的 d_P 项。

正向无偏向量控制同样使用原来的向量符号 b：

$$\widehat{g}^{\mathrm{F}}_{\rho}(b) = h_g^{\mathrm{F}} + \tau_q b + J_A \frac{q(A)}{\rho(A)}(-s_A - b).$$

令 $\mu_g^{\mathrm{F}} = \mathbb{E}_{q_{\mathrm{tail}}}[-s_A]$，有

$$\mathrm{Var}_{\rho}(\widehat{g}^{\mathrm{F}}_{\rho}(b)) = \sum_{v \notin S} \frac{q(v)^2}{\rho(v)} \|-s_v - b\|^2 - \tau_q^2 \|\mu_g^{\mathrm{F}} - b\|^2.$$

所有正向估计的支持覆盖要求作用于未知的 q 尾部。这样，BPO 的正向 student–anchor center 与 OPD 的反向 student–teacher KL 都使用同一套采样与误差定义。

3.9 OPD 使用方式与误差传递

3.9.1 Score baseline 是积分为零的控制

本小节默认 $\rho = p$。vOPD在总定理中对应 $f_v = r_v s_v$、$a_v = c(x) s_v$。由于 $I_p(a) = c(x) I_p(s) = 0$，它直接成为 $(r_A - c) s_A$。对其他覆盖残差支持的采样分布，正确形式是 $(p(A)/\rho(A))(r_A - c) s_A$。因此 baseline 是否对 KL 数值无偏，不是这个构造的无偏条件；控制积分为零才是条件。下面求出的最优 c 就是 Gram 定理的单列控制解。

Sampled-token estimator 为

$$\widehat{g}^{\mathrm{sample}} = r_A s_A.$$

它无偏，且

$$\mathrm{Var}(\widehat{g}^{\mathrm{sample}}) = \mathbb{E}_p[r_A^2\|s_A\|_2^2] - \|g\|_2^2. \tag{3.48}$$

对任意在抽样前固定的 scalar $c(x)$，vOPD 型 estimator 为

$$\widehat{g}_c^{\mathrm{vOPD}} = (r_A - c)s_A. \tag{3.49}$$

命题 3.7 (固定 scalar baseline 的无偏性与最优值)

对任意 action-independent $c(x)$，$\widehat{g}_c^{\mathrm{vOPD}}$ 无偏。其二阶矩为

$$\mathbb{E}\|\widehat{g}_c^{\mathrm{vOPD}}\|_2^2 = \mathbb{E}_p[(r_A - c)^2\|s_A\|_2^2],$$

当 $\mathbb{E}_p\|s_A\|^2 > 0$ 时，使该二阶矩最小的 scalar 是

$$c^* = \frac{\mathbb{E}_p[r_A\|s_A\|_2^2]}{\mathbb{E}_p[\|s_A\|_2^2]}. \tag{3.50}$$

一般 $c^* \neq K$，因此用 KL 数值 K 作为 vOPD baseline 是合法的中心化，但不必是 score-gradient 方差最优的 baseline。若 $\mathbb{E}_p\|s_A\|^2 = 0$，score 在 p 下几乎处处为零，所有 baseline 对应的梯度均为零。

证明

$$\mathbb{E}_p[(r_A - c)s_A] = \mathbb{E}_p[r_A s_A] - c\mathbb{E}_p[s_A] = g.$$

对二阶矩关于 c 求导并令其为零，得到式 (3.50)。

进一步记 $D_s = \mathbb{E}_p\|s_A\|^2 > 0$，展开平方并配方，得到精确的方差表达式

$$\begin{aligned}\mathrm{Var}(\widehat{g}_c^{\mathrm{vOPD}}) &= \mathbb{E}_p[r_A^2\|s_A\|^2] - 2c\mathbb{E}_p[r_A\|s_A\|^2] + c^2 D_s - \|g\|^2 \\ &= \mathrm{Var}(\widehat{g}_{c^*}^{\mathrm{vOPD}}) + D_s(c - c^*)^2.\end{aligned}$$

这给出任意固定 KL proxy 作为 baseline 的代价，而无需假定该 proxy 对 K 无偏。

命题 3.8 (独立随机 KL baseline 的误差传递)

令 C 与当前动作 A 条件独立，$m = \mathbb{E}[C]$、$\sigma_C^2 = \mathrm{Var}(C)$，且反传时停止 C 的梯度。则 $(r_A - C)s_A$ 对 g 无偏，且

$$\mathrm{Var}((r_A - C)s_A) = \mathrm{Var}((r_A - m)s_A) + D_s\sigma_C^2.$$

若写 $m = K + \delta$，则

$$\mathrm{Var}((r_A - C)s_A) = \mathrm{Var}(\widehat{g}_{c^*}^{\mathrm{vOPD}}) + D_s\{(K + \delta - c^*)^2 + \sigma_C^2\}.$$

证明 条件于 A，$\mathbb{E}_C[(r_A - C)^2] = (r_A - m)^2 + \sigma_C^2$。乘以 $\|s_A\|^2$ 后取 A 的期望，并减去相同的 $\|g\|^2$，即可得到结论。

所以在 vOPD 中只改进后面的 KL 数值估计时，应比较 scalar baseline 的均值与方差；当两个 baseline 均对 K 无偏且独立时，梯度方差之差恰好是 D_s 乘以 scalar 方差之差。ResOPD 的向量控制方差结论不能直接用于这个比较。

如果 baseline 是与当前 action 共同随机化的 C_A，则上述证明失效：偏差为

$$\mathrm{Bias}(\widehat{g}_C) = -\mathbb{E}[C_A s_A]. \tag{3.51}$$

因此随机 baseline 保持无偏的充要条件是 $\mathbb{E}[C_A s_A] = 0$。独立样本或 leave-one-out/cross-fitting 是保证这个条件的构造方式；仅有 $\mathbb{E}[C_A] = K$ 不够。

同样本 K1 baseline 提供一个极端反例：取 $C_A = r_A$，则 $(r_A - C_A)s_A = 0$，偏差恰好为 $-g$，尽管 $\mathbb{E}[C_A] = K$。数值无偏不能消除 baseline 与 score 的相关性。

3.9.2 旧 rollout 下的最优 baseline

若 $A \sim \rho$，且 ρ 覆盖 p 的支持，令 $w_A = p(A)/\rho(A)$。控制 cs_A 的正确修正仍然无偏，因为

$$\mathbb{E}_\rho[w_A(r_A - c)s_A] = I_p(rs) - cI_p(s) = g.$$

但是其二阶矩使用 p^2/ρ 权重。定义

$$D_{s,\rho} = \sum_v \frac{p(v)^2}{\rho(v)}\|s_v\|^2.$$

若该值为正，对二阶矩关于 c 配方得到

$$c^*_\rho = \frac{\sum_v p(v)^2\rho(v)^{-1}r_v\|s_v\|^2}{D_{s,\rho}},$$

$$\mathrm{Var}_\rho(w_A(r_A - c)s_A) = \mathrm{Var}_\rho(w_A(r_A - c^*_\rho)s_A) + D_{s,\rho}(c - c^*_\rho)^2.$$

这直接来自 Gram 定理取控制列 $w_A s_A$。若 $D_{s,\rho} = 0$，所有 score 均为零，baseline 不影响结果。

对与当前动作独立的随机 baseline C，令 $m = \mathbb{E}C$、$\sigma_C^2 = \mathrm{Var}\, C$。条件于动作展开平方，得到

$$\mathrm{Var}_\rho(w_A(r_A - C)s_A) = \mathrm{Var}_\rho(w_A(r_A - m)s_A) + D_{s,\rho}\sigma_C^2.$$

因此两个独立、同均值的 KL baseline 的比较，只需比较其标量方差，梯度方差差为 $D_{s,\rho}$ 乘以该差；当前 on-policy 情形是 $\rho = p$ 的特例。若 baseline 与动作相关，无偏性的条件也相应变成 $\mathbb{E}_\rho[w_A C_A s_A] = 0$。

3.9.3 Sampled OPD 与 vOPD

固定 teacher 作为 q，sampled OPD 取停止系数 r_A，其最小化梯度为 $r_A s_A$；若使用 reward 最大化记号，reward 是 $-r_A$，两种表述符号相反而更新方向相同。vOPD 取 $(r_A - c(x))s_A$，其中 $c(x)$ 可取完整 K、Tail-aware 下界或独立随机 KL baseline。第三章已经证明：action-independent baseline 的数值偏差不产生梯度偏差；同 action 的无偏 KL 估计反而可以产生梯度偏差。

本仓库生产 OPD baseline 对 $q = \pi_T$ 使用 $H + \tau_p \log(\tau_p/\tau_q)$，并在梯度系数中停止。它是完整 KL 的有偏数值下界，但作为 action-independent baseline，在正确采样测度或正确重要性校正下保持 OPD 梯度无偏。若 rollout 来自冻结 π_k，则此处 $\rho = \pi_k$，需要 p/ρ；baseline 本身使用 teacher 作为 q，二者不可混用。

3.9.4 Mirror 目标中的 student–anchor KL

对 MDPO，令本节参考 $q = \pi_k$，固定 reward 为前两章的 $r_k(x, v)$。负 mirror 目标为

$$\mathcal{L}_{\mathrm{MDPO}} = \eta^{-1}K - \mathbb{E}_p[r_k(x, A)].$$

逐项求导并利用 score 均值为零，得到

$$\nabla\mathcal{L}_{\mathrm{MDPO}} = \mathbb{E}_p[u_A^{\mathrm{MDPO}} s_A], \qquad u_v^{\mathrm{MDPO}} = \eta^{-1}r_v - r_k(x, v).$$

在冻结 rollout $\rho = \pi_k$ 下，无偏估计为

$$\widehat{g}_{\mathrm{MDPO}} = \frac{p(A)}{\rho(A)}u_A^{\mathrm{MDPO}} s_A, \qquad \mathrm{Var}_\rho(\widehat{g}_{\mathrm{MDPO}}) = \sum_v \frac{p(v)^2}{\rho(v)}(u_v^{\mathrm{MDPO}})^2\|s_v\|^2 - \|\nabla\mathcal{L}_{\mathrm{MDPO}}\|^2.$$

如果 $\|u_v^{\mathrm{MDPO}} s_v\| \le C$，则二阶矩满足

$$\mathbb{E}_\rho\|\widehat{g}_{\mathrm{MDPO}}\|^2 \le C^2 \sum_v \frac{p(v)^2}{\rho(v)} = C^2\{1 + \chi^2(p\|\rho)\}. \tag{3.52}$$

这说明 stale rollout 与当前 student 分离时的重要性权重代价。

BPO 的 student center 是相反方向的 $\mathrm{KL}(\pi_k\|p)$，在本节 $q = \rho = \pi_k$ 下就是 K^{F}；teacher center 是冻结的 $\mathrm{KL}(\pi_k\|\pi_T)$。PMD-Mean 的目标使用冻结 reward 中心而不含同样的 student KL center。它们的原目标就在 anchor 测度下定义，不能因 MDPO 需要 p/ρ，便给 Mean 或 BPO 机械乘上该比率。center 放入平方损失后还会出现同

样本相关项，须使用第二章的有限样本与留一修正；一个 KL scalar estimator 的无偏性不替代整个目标梯度的证明。

3.9.5 确定性代理的平方误差

记 $M = \tau_p \ell_{\text{tail}}$、$B = \tau_p \,\mathrm{KL}(p_{\text{tail}} \| q_{\text{tail}})$。Tail-aware与截断的平方误差差为

$$(K - H)^2 - \{K - (H + M)\}^2 = (M + B)^2 - B^2 = M(M + 2B).$$

因此 $M \geq 0$ 时 Tail-aware 的标量平方误差不大于截断；$M < 0$ 时删除的质量项与形状项可抵消，零方差确定性 proxy 的排序不能只按是否保留更多项判断。

支持细分的 KL 单调性已经由第 3.3 节的一般分区定理证明；该性质控制确定性粗化偏差，不能推出 HETS 或 ResOPD 的抽样方差单调下降。

3.9.6 Normalized 与 Truncated 的 logit 行为

令 $p = \mathrm{softmax}(\theta)$，其 score 为 $s_{v,j} = \mathbf{1}\{v = j\} - p(j)$。Normalized Top-$J$ 只依赖头部相对 logits，故对 $j \notin S$ 有

$$\frac{\partial K_J^{\text{norm}}}{\partial \theta_j} = 0.$$

截断数值的真实梯度则满足

$$\frac{\partial H}{\partial \theta_j} = -p(j)(H + P), \qquad j \notin S.$$

这由 $\nabla H = \sum_{v \in S} p(v)(r_v + 1)s_v$ 逐坐标代入得到。当 $H + P > 0$ 时，梯度下降增加尾部 logits。停止系数的头部梯度 h_g 省去了 P 对应的边界项，但仍缺失完整尾部。因此这两种截断训练路径也必须分别报告。

3.9.7 固定 prefix 误差与访问测度下误差

令 $x \sim d$，条件偏差为 $\beta(x) = \mathbb{E}[\widehat{K} \mid x] - K(x)$，条件方差为 $V(x)$。则

$$\mathbb{E}_{x,A}[\widehat{K} - K] = \mathbb{E}_d[\beta(x)], \qquad \mathbb{E}_{x,A}[(\widehat{K} - K)^2] = \mathbb{E}_d[\beta(x)^2 + V(x)].$$

而原始 estimator 的总体方差是

$$\mathrm{Var}_{x,A}(\widehat{K}) = \mathbb{E}_d[V(x)] + \mathrm{Var}_d(K(x) + \beta(x)).$$

这三个统计量分别回答总体有符号误差、逐 prefix 均方误差和 estimator 自身的总体波动。确定性 Tail-aware 有 $V(x) = 0$，但 RMSE $= \sqrt{\mathbb{E}_d[B(x)^2]}$，一般不等于 $|\mathbb{E}_d[-B(x)]|$。向量估计量将平方替换为范数平方、方差替换为协方差迹，结论保持相同形式。访问测度 d 在不同 outer 轮次的变化由第四章单独处理。

3.10 ResOPD 实现与论文实验

本节沿用前文的 r_v、score s_v、头部向量 h_g、尾部均值 μ_g 与事件 J_A，将控制族对应到公开训练实现。[3]

3.10.1 代码调用链与停止梯度

开源仓库没有单独的 “HETS” loss mode；HETS 是论文中的比较基线。发布代码注册的唯一新模式是 “resopd”，而 sampled-token、Top-k 和普通 “k1/k2/k3” 路径属于其他 loss mode。

teacher 路径从 `verl/experimental/teacher_loop/teacher_manager.py` 开始。选择 “loss_mode=resopd” 后，vLLM 必须返回 teacher Top-J 的 token ids/log-probs，以及实际 student token 的 teacher log-prob。

[3]论文来源为 ResOPD；本仓库保存的全文为 `docs/papers/2610.04882_zh_CN/`。代码来源为 InternLM/ResOPD。

`verl/workers/rollout/vllm_rollout/prompt_logprobs.py` 保存两组字段：

- 头部支持：`prompt_ids` 与 `prompt_logprobs`。
- 实际动作：`sampled_prompt_ids` 与 `sampled_prompt_logprobs`。

实际动作的 teacher log-prob 即使落在 Top-J 之外也必须保留。

student logits 经 `verl/trainer/distillation/fsdp/losses.py` 对齐后，`verl/trainer/distillation/losses.py` 将四个 payload 送入 `verl/trainer/distillation/resopd.py` 的 `resopd_loss`。该 kernel 的数学对应关系如下：

1. 完整 student logits 做 log-softmax，得到头部 $p(v)$、r_v 和 P；teacher Top-J log-prob 在进入计算时 detach。
2. 从实际 token 得到 r_A，并用 `student_tail_mass`、`teacher_tail_mass` 构造 $\log(\tau_p/\tau_q)$。
3. 用 `support_score` 计算 b_{TA}，并令 `centered_event` $= \mathbf{1}\{A \in S\} - P$。
4. 通过 `surrogate - surrogate.detach()` 保留 forward 数值、替换 backward，得到式 (3.34) 中 $b = b_{\mathrm{TA}}$ 的特例。

实现中的 teacher 数值、事件系数和控制项均停止梯度。仓库 docstring 明确说明返回值不是确定性 KL 目标，单个 forward value 可以为负；应审计 backward 梯度、期望和协方差，而不是把 loss 平均值解释成完整 KL。

无偏性要求 A 来自当前完整 student 分布，或按本章给出的重要性权重校正。发布脚本使用温度 1、`top_p=1`、`top_k=-1`。论文的主要数学实验使用温度 1、`top_p=0.95`、`top_k=20`；全支持审计与跨领域实验采用完整祖先采样。这些设置必须分别报告：重新计算未截断 logits 能恢复目标概率 p，不能把已生成动作的测度 ρ 改回 p。

3.10.2 公开实验与 baseline

论文的基线可按目标分成三组。第一组是有偏确定性 Top-k 方法：Teacher Top-k fKL、Teacher Top-k rKL 和 TA-OPD（尾部伪 token 的粗粒度 KL）。第二组是无偏 reverse-KL 梯度 estimator：Sampled-token OPD、教师 Top-k 支持上的 vOPD、HETS 和 ResOPD。第三组是机制消融：支持大小 $k \in \{1, 4, 16, 32, 64\}$、完整祖先采样与 top-$p$/top-$k$ 截断、学习率敏感性，以及统一双控制族中的 SC-TA（$\gamma = 1$；ResOPD 为 $\gamma = 0$）。

冻结 prefix 审计在 GSM8K、HMMT26 和 DeepMath 上枚举完整动作，报告梯度协方差迹和 NSR。Top-4 下，论文报告 ResOPD 相对 sampled-token OPD 降低 52.5%–75.0% 的协方差迹，并在五个面板中优于 HETS。端到端数学实验使用 Qwen3.5-27B 教师和 Qwen3.5-4B 学生，评估 DeepMath、AIME26、HMMT26、OlymMATH；科学/代码迁移使用 Qwen3-30B-A3B-Instruct 到 Qwen3-4B，评估 GPQA-D、SuperGPQA、LiveCodeBench v5/v6。论文报告数学平均分 ResOPD 50.12%、HETS 45.72%，迁移平均分 ResOPD 44.15%、HETS 43.63%。

仓库公开了可直接运行的 DeepMath 子集：1,024 条训练样本和 252 条 held-out 样本；入口为 `examples/resopd/run_resopd.sh`，默认 FSDP2 student、vLLM teacher、Top-4、full-support rollout。`tests/resopd` 包含 estimator、teacher payload 和 verl integration 检查，发布验证记录 22 个 standalone 与 13 个 integration checks。

需要避免的概念混淆是：HETS 是稀疏 rKL 梯度基线，不是 PPO 的 value baseline；ResOPD 的 b_{TA} 是 control variate。仓库中普通 verl 的 “k1/k2/k3” KL penalty、GRPO、RLOO、ReMax 等属于框架通用路径，并非论文中同一 teacher payload 下的 HETS/ResOPD 方差基线。

第四章 Outer 动力学与有限 Inner 误差

第三章给出固定 prefix 下 KL 数值与梯度估计的条件误差。本章分析 inner 优化如何把这种误差传到 outer 同步后的策略，依次讨论精确 Gibbs 更新、PMD-Mean 更新、有限 inner、soft sync 和访问测度变化。沿用前两章的 π_k、$\pi_{k,n}$ 与 π_T；它们分别是冻结 anchor、inner student 和 teacher。

4.1 Hard sync 的精确几何与稳定区间

本节固定一个 prefix，省略条件变量。沿用 π_k 表示第 k 轮冻结 anchor，π_T 表示固定 teacher。词表 $\mathcal{V}$ 有限，$\pi_0(v) > 0$、$\pi_T(v) > 0$ 对所有 token 成立。假设 inner 优化确实得到 Gibbs target，随后将这个 target 完整复制为下一轮 anchor。这个假设同时排除了有限 inner 误差、模型表达能力不足和参数同步与分布同步之间的差异。

定义 4.1 (精确 Gibbs hard sync)

对任意 $\eta > 0$ 和严格正分布 π，定义

$$T_\eta(\pi)(v) = \frac{\pi(v)^{1-\eta}\pi_T(v)^\eta}{Z_\eta(\pi)}, \qquad Z_\eta(\pi) = \sum_{w\in\mathcal{V}} \pi(w)^{1-\eta}\pi_T(w)^\eta.$$

精确 hard sync 是 $\pi_{k+1} = T_{\eta_k}(\pi_k)$。$\eta_k$ 是 mirror 更新的步长；它与优化器学习率及每轮 inner steps 是不同量。

♣

严格正性使负指数也有定义。因此本节先分析所有 $\eta > 0$ 的数学更新，再区分通常采用的 $0 < \eta \le 1$ 区间。若初始分布有零概率，$0 < \eta < 1$ 的更新会一直保留这些零概率，不能恢复 teacher 的完整支持集；$\eta > 1$ 的负幂则在这些 token 上失去定义。有限 logits 的 softmax 满足正性，而显式截断后的采样分布不能直接代入本节结论。

4.1.1 归一化常数消去后的精确收缩

定义 4.2 (Log-ratio 跨度与 Hilbert 距离)

对 token 函数 f，定义

$$\operatorname{osc}_v f_v = \max_v f_v - \min_v f_v.$$

对两个严格正概率分布，定义

$$d_H(\pi, \widetilde{\pi}) = \operatorname{osc}_v \log \frac{\pi(v)}{\widetilde{\pi}(v)}, \qquad b_k = d_H(\pi_k, \pi_T).$$

d_H 是正概率单纯形上的 Hilbert 距离。它忽略 log-density 中与 token 无关的加性常数，恰好对应概率归一化所消除的自由度。

♣

这个定义确实给出距离。非负性来自最大值减最小值；对称性来自 $\operatorname{osc}(-f) = \operatorname{osc}(f)$；三角不等式来自 $\operatorname{osc}(f+g) \le \operatorname{osc}(f) + \operatorname{osc}(g)$。若 $d_H(\pi, \widetilde{\pi}) = 0$，则两个分布的概率比是常数，归一化迫使这个常数等于一。

定理 4.1 (两条 hard-sync 轨迹的精确收缩)

相同 teacher 和相同步长下，任意严格正分布满足

$$d_H(T_\eta(\pi), T_\eta(\widetilde{\pi})) = |1-\eta| d_H(\pi, \widetilde{\pi}). \tag{4.1}$$

特别地，π_T 是不动点，而且

$$b_{k+1} = |1-\eta_k| b_k.$$

♡

证明 先逐 token 相除，再取对数：

$$\log \frac{T_\eta(\pi)(v)}{T_\eta(\widetilde{\pi})(v)} = (1-\eta)\log \frac{\pi(v)}{\widetilde{\pi}(v)} - \log Z_\eta(\pi) + \log Z_\eta(\widetilde{\pi}).$$

最后两个项与 token 无关，在跨度中抵消。对任意实数 c，$\operatorname{osc}(cf) = |c|\operatorname{osc}(f)$，从而得到式 (4.1)。将 $\widetilde{\pi} = \pi_T$ 代入，并使用 $T_\eta(\pi_T) = \pi_T$，得到第二个结论。

定理 4.2 (常步长与变步长的精确解)

记

$$A_0 = 1, \qquad A_k = \prod_{j=0}^{k-1}(1-\eta_j), \qquad u_v = \log \frac{\pi_0(v)}{\pi_T(v)}.$$

任意正步长序列的精确解为

$$\pi_k(v) = \frac{\pi_T(v)e^{A_k u_v}}{\sum_w \pi_T(w)e^{A_k u_w}}, \qquad b_k = |A_k| b_0. \tag{4.2}$$

常步长时 $A_k = (1-\eta)^k$，也可以写成

$$\pi_k(v) = \frac{\pi_0(v)^{(1-\eta)^k}\pi_T(v)^{1-(1-\eta)^k}}{\sum_w \pi_0(w)^{(1-\eta)^k}\pi_T(w)^{1-(1-\eta)^k}}.$$

♡

证明 $k=0$ 时 $\pi_T(v)e^{u_v} = \pi_0(v)$，配分函数等于一。假设第 k 轮公式成立，其归一化常数记为 C_k。下一轮未归一化权重为

$$\begin{aligned}\pi_k(v)^{1-\eta_k}\pi_T(v)^{\eta_k} &= C_k^{-(1-\eta_k)}\pi_T(v)e^{(1-\eta_k)A_k u_v} \\ &= C_k^{-(1-\eta_k)}\pi_T(v)e^{A_{k+1}u_v}.\end{aligned}$$

第一项不依赖 token，归一化后消失。由归纳得到分布闭式。取相对 teacher 的 log-ratio 后，归一化常数同样在跨度中抵消，得到 $b_k = |A_k|b_0$。

推论 4.1 (常步长的完整稳定分类)

对非 teacher 初值，精确 hard sync 的行为如下。

1. $0 < \eta < 1$ 时，$A_k > 0$ 且趋于零，策略从同一侧趋向 teacher。
2. $\eta = 1$ 时，第一轮更新等于 teacher，此后保持不变。
3. $1 < \eta < 2$ 时，A_k 正负交替并趋于零，策略在 teacher 两侧交替收敛。
4. $\eta = 2$ 时，$A_k = (-1)^k$，形成精确二周期。
5. $\eta > 2$ 时，$|A_k|$ 发散，log-ratio 跨度发散，策略不能趋向 teacher。

因此完整的全局渐近稳定区间是 $0 < \eta < 2$。teacher KL 的每步单调下降需要另外分析。

♡

证明 前四项直接由式 (4.2) 得到。第五项中，偶数轮的 A_k 趋于正无穷，奇数轮趋于负无穷。偶数轮的概率质量集中到 u_v 最大的 token 集合，奇数轮集中到最小的 token 集合；各集合内部的极限概率与 π_T 成比例。非 teacher 初值使 u 非常数，所以两个集合互不相交。

有限正 teacher 下仍有

$$\mathrm{KL}(\pi_k \| \pi_T) \le \log \frac{1}{\min_v \pi_T(v)}.$$

因此这里发散的是 log-ratio 跨度和反向 KL，而正向 teacher KL 保持有界。反向 KL 发散，是因为上述集中使某些具有正 teacher 质量的 token 概率趋于零。

命题 4.1 (变步长的充要条件)

非 teacher 初值下，$\pi_k \to \pi_T$ 当且仅当 $A_k \to 0$。若每个 $\eta_k \in (0,2)$，且没有任何一步等于一，则这个条件

等价于

$$\sum_{k=0}^{\infty} \eta_k(2-\eta_k) = \infty.$$

若某一步等于一，则此后 $A_k = 0$，直接收敛。

♠

证明 $A_k \to 0$ 时由有限词表闭式得到逐 token 收敛。反过来，概率趋向严格正 teacher 时 $b_k \to 0$；因为 $b_0 > 0$，故 $|A_k| \to 0$。对 $a_k = |1-\eta_k| \in (0,1)$，无限乘积 $\prod_k a_k$ 为零，当且仅当 $\sum_k (1-a_k)$ 发散。这个标准乘积判据可以由 $-\log a \geq 1-a$，以及 a 接近一时 $-\log a \leq 2(1-a)$ 推出。最后使用

$$1-a_k \leq 1-a_k^2 \leq 2(1-a_k), \qquad 1-a_k^2 = \eta_k(2-\eta_k),$$

得到等价条件。

例如 $\eta_k = 1/(k+2)$ 给出 $A_K = 1/(K+1) \to 0$。若改成 $\eta_k = 1/(k+2)^2$，则

$$A_K = \prod_{n=2}^{K+1} \frac{(n-1)(n+1)}{n^2} = \frac{K+2}{2(K+1)} \longrightarrow \frac{1}{2}.$$

第二种步长虽然每轮都执行正确方向的 hard sync，但总更新量有限，最终仍保留初始 log-ratio 的一半。

4.1.2 配分函数与两个方向的 KL 路径

沿用上节 u_v，定义一条由初始策略和 teacher 唯一确定的路径：

$$\psi(a) = \log \sum_v \pi_T(v) e^{a u_v}, \qquad \pi^{[a]}(v) = \pi_T(v) e^{a u_v - \psi(a)}.$$

这里 a 是路径坐标，实际第 k 轮取 $a = A_k$；它不代表新的策略变量。归一化给出 $\psi(0) = \psi(1) = 0$，以及 $\pi^{[0]} = \pi_T$、$\pi^{[1]} = \pi_0$。

定理 4.3 (KL 路径的精确积分)

配分函数满足

$$\psi'(a) = \mathbb{E}_{\pi^{[a]}} u, \qquad \psi''(a) = \mathrm{Var}_{\pi^{[a]}}(u).$$

沿路径的正向与反向 KL 分别为

$$\mathrm{KL}(\pi^{[a]} \| \pi_T) = a\psi'(a) - \psi(a) = \int_0^a z\psi''(z)\,\mathrm{d}z, \tag{4.3}$$

$$\mathrm{KL}(\pi_T \| \pi^{[a]}) = \psi(a) - a\psi'(0) = \int_0^a (a-z)\psi''(z)\,\mathrm{d}z. \tag{4.4}$$

任意路径两点之间还有

$$\mathrm{KL}(\pi^{[a]} \| \pi^{[c]}) = (a-c)\psi'(a) - \psi(a) + \psi(c).$$

♡

证明 有限词表允许逐项微分。令 $C(a) = \sum_v \pi_T(v) e^{a u_v}$，则

$$\psi'(a) = \frac{C'(a)}{C(a)} = \sum_v \pi^{[a]}(v) u_v, \qquad \psi''(a) = \frac{C''(a)}{C(a)} - \left(\frac{C'(a)}{C(a)}\right)^2.$$

右侧正好是 u 的方差。正向 log-ratio 是 $a u_v - \psi(a)$，在 $\pi^{[a]}$ 下取期望得到第一式。其关于 a 的导数为 $a\psi''(a)$，在零点的值为零，积分得到式 (4.3)。反向 log-ratio 是 $\psi(a) - a u_v$，在 teacher 下取期望得到第二式；再对 ψ 在零点使用带积分余项的二阶展开，得到式 (4.4)。最后两条路径分布的 log-ratio 为 $(a-c)u_v - \psi(a) + \psi(c)$，取期望即得。

由于 $\psi''(a) \geq 0$，正向 KL 在 $a > 0$ 上随 a 增大而增大，在 $a < 0$ 上随 a 增大而减小。反向 KL 的导数 $\psi'(a) - \psi'(0)$ 也具有相同符号。因此 $0 < \eta \leq 1$ 下，两个方向的 KL 都逐轮下降。$1 < \eta < 2$ 时，连续两轮的 a 符号不同，跨度收缩本身不能比较它们的 KL 大小。

推论 4.2 (局部 KL 速率与全局绝对界)

非 teacher 初值、固定 $0 < \eta < 2$ 且 $\eta \neq 1$ 时，

$$\lim_{k\to\infty} \frac{\mathrm{KL}(\pi_{k+1}\|\pi_T)}{\mathrm{KL}(\pi_k\|\pi_T)} = (1-\eta)^2.$$

对所有实数 A_k，还有

$$\mathrm{KL}(\pi_k\|\pi_T) \le \frac{A_k^2 b_0^2}{8}.$$

♡

证明 在零点展开得到

$$\mathrm{KL}(\pi^{[a]}\|\pi_T) = \frac{a^2}{2}\,\mathrm{Var}_{\pi_T}(u) + O(|a|^3).$$

非 teacher 初值使该方差严格正；将 $a = A_k$ 与 $A_{k+1} = (1-\eta)A_k$ 代入并相除，得到极限。任意支撑在长度为 b_0 的区间内的随机变量，方差不超过 $b_0^2/4$。把这个界代入式 (4.3)，得到 $a^2 b_0^2/8$；当 $a < 0$ 时反向积分同样给出正的 $a^2/2$ 因子。

这个全局绝对界以初始跨度衡量误差；它没有把当前 KL 与初始 KL 作比例比较。局部极限 $(1-\eta)^2$ 也不能提升为全局单步收缩因子。

4.1.3 精确三点恒等式与单步下降

定理 4.4 (Hard sync 的三点 KL 恒等式)

记 $\pi^+ = T_\eta(\pi)$。对任意 $\eta > 0$，

$$\eta\,\mathrm{KL}(\pi\|\pi_T) = \eta\,\mathrm{KL}(\pi^+\|\pi_T) + (1-\eta)\,\mathrm{KL}(\pi^+\|\pi) + \mathrm{KL}(\pi\|\pi^+). \tag{4.5}$$

♡

证明 从更新定义分别减去 anchor 和 teacher 的 log-density：

$$\log\frac{\pi^+}{\pi} = -\eta\log\frac{\pi}{\pi_T} - \log Z_\eta(\pi),$$

$$\log\frac{\pi^+}{\pi_T} = (1-\eta)\log\frac{\pi}{\pi_T} - \log Z_\eta(\pi).$$

第一式在 π 下取负期望，得到

$$\mathrm{KL}(\pi\|\pi^+) = \eta\,\mathrm{KL}(\pi\|\pi_T) + \log Z_\eta(\pi).$$

第二式在 π^+ 下取期望，并与第一式在 π^+ 下的期望组合，得到

$$\eta\,\mathrm{KL}(\pi^+\|\pi_T) + (1-\eta)\,\mathrm{KL}(\pi^+\|\pi) = -\log Z_\eta(\pi).$$

两式相加，配分函数消去，即为所需恒等式。

当 $0 < \eta \le 1$ 时，式 (4.5) 的最后两个项非负。常步长的下降量和累计更新量因此满足

$$\mathrm{KL}(\pi_k\|\pi_T) - \mathrm{KL}(\pi_{k+1}\|\pi_T) = \frac{1-\eta}{\eta}\,\mathrm{KL}(\pi_{k+1}\|\pi_k) + \frac{1}{\eta}\,\mathrm{KL}(\pi_k\|\pi_{k+1}),$$

$$\sum_{k=0}^{\infty} \mathrm{KL}(\pi_k\|\pi_{k+1}) \le \eta\,\mathrm{KL}(\pi_0\|\pi_T).$$

后一式由前式对有限轮数求和、去掉非负项，再令轮数趋于无穷得到。它控制整个 hard-sync 轨迹的累计 KL 移动量。

Gibbs target 对任意正步长仍是一个严格凸目标的唯一最优点。具体地，定义

$$F_\eta(p) = \mathrm{KL}(p\|\pi_T) + (\eta^{-1} - 1)\,\mathrm{KL}(p\|\pi).$$

直接代入 π^+ 的 log-density，得到

$$F_\eta(p) = \eta^{-1}\,\mathrm{KL}(p\|\pi^+) - \eta^{-1}\log Z_\eta(\pi).$$

所以 $\eta > 1$ 时虽然第二个 KL 的系数为负，整个目标的熵系数仍为 $1/\eta > 0$，最优点仍唯一。最优点存在、hard-sync 稳定和 teacher KL 单步下降是三个不同结论。

4.1.4 KL 收缩的两个数值反例

取二元词表，$\pi_0 = (10^{-12}, 1-10^{-12})$、$\pi_T = (0.1, 0.9)$、$\eta = 1.1$。直接代入更新得到

$$\pi_1 = (0.5856848855168,\ 0.4143151144832),$$

$$\mathrm{KL}(\pi_0\|\pi_T) = 0.1053605156314, \qquad \mathrm{KL}(\pi_1\|\pi_T) = 0.7138510884672.$$

跨度严格缩小到初值的 0.1，正向 KL 却增加到约 6.7753 倍。这说明 $1 < \eta < 2$ 的稳定性不能表述为每一步 teacher KL 下降。

取 $\pi_0 = (1-10^{-12}, 10^{-12})$、$\pi_T = (0.01, 0.99)$、$\eta = 0.5$，得到

$$\pi_1 = (0.9999900502246,\ 0.0000099497753721),$$

$$\mathrm{KL}(\pi_0\|\pi_T) = 4.6051701859549, \qquad \mathrm{KL}(\pi_1\|\pi_T) = 4.6049999147314.$$

此时 KL 的比值约为 0.9999630，超过 $1-\eta = 0.5$ 与 $(1-\eta)^2 = 0.25$。这一次 KL 确实下降，但远处的下降速度不能套用 teacher 附近的二阶渐近速率。

4.1.5 从跨度到分布误差的最优 TV 界

定理 4.5 (Hilbert 距离控制 TV 的 sharp 界)

任意严格正概率分布 p, q 满足

$$\mathrm{TV}(p,q) \le \tanh\left(\frac{d_H(p,q)}{4}\right). \tag{4.6}$$

对每个给定正跨度，都存在二元分布达到等号。

♡

证明 令 $L_v = p(v)/q(v)$、$m = \min L_v$、$M = \max L_v$、$\delta = d_H(p,q)$。归一化给出 $\mathbb{E}_q L = 1$，所以 $m \le 1 \le M$，且 $M/m = e^{\delta}$。$\delta = 0$ 时两个分布相等，结论成立。以下设 $\delta > 0$。

凸函数 $|L-1|$ 在 $[m, M]$ 上不超过端点连接的弦线，因此

$$|L-1| \le \frac{M-L}{M-m}(1-m) + \frac{L-m}{M-m}(M-1).$$

在 q 下取期望，再除以二，得到

$$\mathrm{TV}(p,q) = \tfrac{1}{2}\mathbb{E}_q|L-1| \le \frac{(M-1)(1-m)}{M-m}.$$

记 $h = e^{\delta}$，代入 $M = hm$ 将右侧化为

$$\frac{h+1-hm-m^{-1}}{h-1}.$$

由 $hm + m^{-1} \ge 2\sqrt{h}$，继续得到

$$\mathrm{TV}(p,q) \le \frac{\sqrt{h}-1}{\sqrt{h}+1} = \tanh(\delta/4).$$

为了达到等号，取两个 token 的概率比分别为 $M = e^{\delta/2}$ 和 $m = e^{-\delta/2}$，在 q 下赋予质量

$$q(L=M) = \frac{1}{1+e^{\delta/2}}, \qquad q(L=m) = \frac{e^{\delta/2}}{1+e^{\delta/2}}.$$

这些质量满足 $\mathbb{E}_q L = 1$。随机变量只取端点值，使弦线界取等号；$hm = m^{-1}$ 又使算术–几何均值界取等号。故整个界达到等号。

结合 hard-sync 闭式立即得到

$$\mathrm{TV}(\pi_k, \pi_T) \le \tanh(|A_k|b_0/4).$$

对于常步长 $0 < \eta < 2$，若要求 TV 不超过 $\delta \in (0,1)$，充分条件是

$$|1-\eta|^k b_0 \le 4\,\mathrm{artanh}(\delta).$$

当 b_0 已不超过右侧时，初始策略就满足要求；否则取 $\eta \neq 1$，可解出所需 outer 轮数

$$k \ge \frac{\log(b_0/[4\,\mathrm{artanh}(\delta)])}{-\log|1-\eta|}.$$

这个保证以逐 prefix 的精确 Gibbs 更新为前提。它没有把有限 inner、参数共享或 rollout 测度变化隐藏到精确公式中。

4.2 PMD-Mean 的逐 prefix OPD 动力学

本节固定一个 prefix x，在有限词表 $\mathcal{V}$ 上分析 PMD-Mean 的总体最优解。假设 teacher 与当前 anchor 在每个 token 上均有正概率。每轮 inner 精确求解后执行 hard sync。以下结论描述这一分布空间更新；参数共享、有限 inner、采样误差与 prefix 测度变化需要另外控制。

原始 PMD-Mean 论文的三个相关结论在本地源文件中对应以下标签：

总体解定理：`thm:pmdmean_solution`。

混合正则化解释：`eq:mixed_subproblem`。

精细损失恒等式：`lem:pmdmean_quad_growth`。

本节采用逐 prefix 的 OPD reward 重新推导这些关系，并进一步证明 teacher KL 下降与 outer 收敛。本文乘子 λ 对应未缩放平方损失；若原论文温度为 $\tau = \eta^{-1}$，则 $\lambda = \lambda_{\mathrm{paper}}/\tau^2$。

4.2.1 代入 OPD reward 后的 Lambert-W 更新

固定第 k 轮与 prefix x，局部记

$$\begin{aligned} q_a &= \pi_k(a \mid x), & t_a &= \pi_T(a \mid x), \\ r_a &= \log\frac{t_a}{q_a}, & \kappa &= \mathrm{KL}(q\|t) = -\mathbb{E}_q r, \\ h_a &= r_a + \kappa, & G_a &= \eta h_a. \end{aligned} \tag{4.7}$$

因此 $\mathbb{E}_q h = \mathbb{E}_q G = 0$。待求 student 分布记为 p，其 log-ratio 为 $U_a = \log(p_a/q_a)$。PMD-Mean 的单轮问题是

$$\min_{p_a>0,\ \sum_a p_a = 1} L_{\mathrm{Mean}}(p), \qquad L_{\mathrm{Mean}}(p) = \frac{1}{2}\sum_a q_a (U_a - \eta h_a)^2. \tag{4.8}$$

定理 4.6 (OPD 下 PMD-Mean 的精确单轮解)

式 (4.8) 有唯一全局最优分布 $p^\star$。它满足

$$\begin{aligned} U_a^\star &= \eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right), \\ p_a^\star &= q_a \exp\left\{\eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right)\right\}. \end{aligned} \tag{4.9}$$

这里 $\lambda \ge 0$ 由 $\sum_a p_a^\star = 1$ 唯一确定，并且

$$\lambda = \mathrm{KL}(q\|p^\star). \tag{4.10}$$

若 $q \neq t$，则 $\lambda > 0$，还可以写成

$$p_a^\star = \frac{q_a}{\lambda} W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right). \tag{4.11}$$

若 $q = t$，则 $\lambda = 0$ 且 $p^\star = q = t$。

证明 log-ratio 坐标中的约束是 $\mathbb{E}_q e^U = 1$。拉格朗日函数及一阶条件为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\mathbb{E}_q(U-\eta h)^2 + \lambda(\mathbb{E}_q e^U - 1),$$

$$U_a - \eta h_a + \lambda e^{U_a} = 0.$$

令 $v_a = \eta h_a - U_a$，得到 $v_a e^{v_a} = \lambda e^{\eta h_a}$，从而

$$U_a = \eta h_a - W_0(\lambda e^{\eta h_a}).$$

定义归一化函数

$$\Phi(\lambda) = \sum_a q_a \exp\{\eta h_a - W_0(\lambda e^{\eta h_a})\}.$$

W_0 在非负实轴上严格递增，因此 Φ 连续且严格递减。当 $q \neq t$ 时，h 非恒定；严格 Jensen 不等式给出

$$\Phi(0) = \mathbb{E}_q e^{\eta h} > e^{\eta \mathbb{E}_q h} = 1.$$

当 $\lambda \to \infty$ 时，恒等式

$$e^{\eta h_a - W_0(\lambda e^{\eta h_a})} = \lambda^{-1} W_0(\lambda e^{\eta h_a})$$

说明 $\Phi(\lambda) \to 0$。故存在唯一正根。若 $q = t$，则 $h = 0$，唯一非负根为零。

对构造出的非负乘子，拉格朗日函数的 Hessian 为

$$\nabla_U^2 \mathscr{L} = \operatorname{diag}\big(q_a(1+\lambda e^{U_a})\big) \succ 0.$$

所以一阶条件确定了拉格朗日函数的唯一全局最小点。在任意可行点上，拉格朗日函数等于原目标，故这个可行最小点也是约束问题的唯一全局最优点。

最后对一阶条件取 q 均值，代入 $\mathbb{E}_q h = 0$ 与 $\mathbb{E}_q e^{U^\star} = 1$：

$$\mathbb{E}_q U^\star + \lambda = 0, \qquad \lambda = -\mathbb{E}_q \log \frac{p^\star}{q} = \mathrm{KL}(q\|p^\star).$$

将 h 展开即可得到式 (4.9)。

恢复全局记号时，$p^\star = \pi_k^{\star,\mathrm{Mean}}(\cdot \mid x)$，$\kappa = \mathcal{K}_k^T(x)$，而乘子是逐 prefix 的 $\lambda_k(x)$。hard sync 更新为 $\pi_{k+1} = \pi_k^{\star,\mathrm{Mean}}$。式 (4.9) 展示了 teacher–anchor 概率比如何进入 Lambert-W；W_0 中的修正随动作变化，不能吸收到一个公共配分常数中。

4.2.2 归一化乘子的 Rényi 界

定义 teacher 与 anchor 的混合矩

$$Z_\alpha(q,t) = \sum_a q_a^{1-\alpha} t_a^\alpha, \qquad \alpha > 0. \tag{4.12}$$

当 $\alpha \neq 1$ 时，Rényi 散度满足 $\log Z_\alpha = (\alpha-1)D_\alpha(t\|q)$。$Z_1 = 1$，相关表达式在 $\alpha = 1$ 处按连续延拓理解。

命题 4.2 (OPD 归一化界)

对任意 $\eta > 0$，

$$\frac{Z_\eta(Z_\eta - e^{-\eta\kappa})}{Z_{2\eta}} \le \lambda \le \eta\kappa + \log Z_\eta. \tag{4.13}$$

特别地，$\eta = 1$ 时

$$\frac{1-e^{-\kappa}}{1+\chi^2(t\|q)} \le \lambda \le \kappa. \tag{4.14}$$

证明 令 $X_a = e^{\eta h_a}$，$A = \mathbb{E}_q X$，$B = \mathbb{E}_q X^2$。式 (4.11) 的归一化条件为

$$\lambda = \mathbb{E}_q W_0(\lambda X).$$

先考虑 $\lambda > 0$。利用 W_0 的凹性，

$$\lambda \le W_0(\lambda A).$$

函数 $w \mapsto we^w$ 在非负轴递增，故

$$\lambda e^{\lambda} \le \lambda A, \qquad \lambda \le \log A.$$

另一方面，$W_0(z) \ge z/(1+z)$。此不等式可以由 $z = we^w$ 与 $(1-w)e^w \le 1$ 验证；$w \ge 1$ 时右侧验证直接成立。再用 Cauchy–Schwarz 得到

$$\begin{aligned}\lambda &\ge \mathbb{E}_q \frac{\lambda X}{1+\lambda X} \\ &\ge \frac{(\mathbb{E}_q[\lambda X])^2}{\mathbb{E}_q[\lambda X(1+\lambda X)]} = \frac{\lambda A^2}{A+\lambda B}.\end{aligned}$$

消去 λ 并整理，得到 $\lambda \ge A(A-1)/B$。当 $\lambda = 0$ 时，$q = t$，$A = B = 1$，两个界均成立。

OPD reward 的代入给出

$$A = e^{\eta\kappa} Z_\eta, \qquad B = e^{2\eta\kappa} Z_{2\eta}.$$

将它们代回即可得到式 (4.13)。当 $\eta = 1$ 时，$Z_1 = 1$，且

$$Z_2 = \sum_a \frac{t_a^2}{q_a} = 1 + \chi^2(t\|q),$$

因此得到式 (4.14)。

4.2.3 Teacher KL 的单步改进

命题 4.3 (精确 Mean 更新的 teacher KL 下降)

单轮精确解满足

$$\mathrm{KL}(p^\star\|t) \le \kappa - \left(\eta^{-1} - 1\right)\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q). \tag{4.15}$$

当 $0 < \eta \le 1$ 且 $q \ne t$ 时，$\mathrm{KL}(p^\star\|t) < \mathrm{KL}(q\|t)$。

证明 固定由 Mean 解确定的 λ，定义

$$J_\lambda(p) = \mathbb{E}_p r - \eta^{-1}\mathrm{KL}(p\|q) - \frac{\lambda}{2\eta}\chi^2(p\|q).$$

对 p_a 求导并加入归一化乘子 ξ，其一阶条件为

$$r_a - \frac{U_a + 1}{\eta} - \frac{\lambda}{\eta}\left(\frac{p_a}{q_a} - 1\right) + \xi = 0.$$

Mean 的 KKT 为 $U_a^\star + \lambda p_a^\star/q_a = \eta(r_a + \kappa)$。取 $\xi = \kappa + (1-\lambda)/\eta$，可验证 $p^\star$ 满足上述条件。J_λ 关于 p 的 Hessian 是对角阵，对角项为 $-1/(\eta p_a) - \lambda/(\eta q_a) < 0$；因此 $p^\star$ 是其唯一全局最大点。

比较 $p^\star$ 与可行分布 q，

$$\mathbb{E}_{p^\star} r - \eta^{-1}\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q) \ge J_\lambda(q) = -\kappa.$$

再用

$$\mathrm{KL}(p^\star\|t) = \mathrm{KL}(p^\star\|q) - \mathbb{E}_{p^\star} r$$

得到式 (4.15)。若 $q \ne t$，则 $\lambda > 0$。此时 $p^\star \ne q$：否则 KKT 要求 $\eta h_a = \lambda$ 对所有动作成立，而 h 非恒定。这保证 $\chi^2(p^\star\|q) > 0$，故在 $0 < \eta \le 1$ 时严格下降。

4.2.4 Log-ratio 跨度与 outer 收敛

定义逐 prefix 的 log-ratio 跨度

$$b(q,t)=\max_a \log\frac{q_a}{t_a}-\min_a \log\frac{q_a}{t_a}. \tag{4.16}$$

该量不受公共归一化常数影响。对于正概率分布，$b(q,t)=0$ 当且仅当 $q=t$。

定理 4.7 (精确 Mean outer 的跨度收敛率)

若 $0<\eta\le 1$，则

$$b(p^\star,t)\le\left(1-\frac{\eta}{1+\eta b(q,t)}\right)b(q,t). \tag{4.17}$$

固定正 teacher、正初始策略和常数 $0<\eta\le 1$，每轮精确 Mean inner 后 hard sync。令 $b_k(x)=b(\pi_k(\cdot\mid x),\pi_T(\cdot\mid x))$，则

$$b_k(x)\le\left(1-\frac{\eta}{1+\eta b_0(x)}\right)^k b_0(x)\longrightarrow 0. \tag{4.18}$$

因此 $\pi_k(\cdot\mid x)\to\pi_T(\cdot\mid x)$。当 $\eta=1$ 时，单步还满足

$$b_{k+1}(x)\le\frac{b_k(x)^2}{1+b_k(x)}. \tag{4.19}$$

♡

证明 固定本轮 λ,κ，将概率比写成 reward 的连续函数

$$w(r)=\exp\{\eta(r+\kappa)-W_0(\lambda e^{\eta(r+\kappa)})\}.$$

动作 a 的概率比为 $p_a^\star/q_a=w(r_a)$。它满足

$$\log w(r)+\lambda w(r)=\eta(r+\kappa),\qquad \frac{d\log w(r)}{dr}=\frac{\eta}{1+\lambda w(r)}>0.$$

所以概率比随 reward 严格递增，且其 log-ratio 斜率受到 Lambert-W 修正压缩。对 teacher 的 log-ratio 函数为

$$v(r)=\log w(r)-r,\qquad v'(r)=-1+\frac{\eta}{1+\lambda w(r)}.$$

在 $0<\eta\le 1$ 时，$v'\le 0$。设 $r_{\max}=\max_a r_a$、$r_{\min}=\min_a r_a$，并令 $w_{\max}=w(r_{\max})$。由于 w 递增，

$$|v'(r)|\le 1-\frac{\eta}{1+\lambda w_{\max}}\quad (r_{\min}\le r\le r_{\max}).$$

均值定理因此给出

$$b(p^\star,t)=v(r_{\min})-v(r_{\max})\le\left(1-\frac{\eta}{1+\lambda w_{\max}}\right)(r_{\max}-r_{\min}).$$

由归一化 $\mathbb{E}_q w(r)=1$，可知 $w_{\max}\ge 1$。其 KKT 与 $\kappa=-\mathbb{E}_q r\le -r_{\min}$ 给出

$$\lambda w_{\max}=\eta(r_{\max}+\kappa)-\log w_{\max}\le\eta(r_{\max}-r_{\min})=\eta b(q,t).$$

代入即可证明式 (4.17)。

逐轮应用单步界，先得到 $b_{k+1}\le b_k\le b_0$。函数 $x\mapsto 1-\eta/(1+\eta x)$ 递增，因此每轮收缩因子都不超过 $1-\eta/(1+\eta b_0)<1$，归纳得到式 (4.18)。概率归一化同时保证

$$\min_a\log\frac{\pi_k(a\mid x)}{\pi_T(a\mid x)}\le 0\le\max_a\log\frac{\pi_k(a\mid x)}{\pi_T(a\mid x)}.$$

所以每个动作的 log-ratio 绝对值不超过 $b_k(x)$；跨度趋零推出逐动作概率收敛。最后令 $\eta=1$ 即得到式 (4.19)。

$\eta=1$ 的二次上界保证超线性收敛；第 4.2.9 节进一步利用归一化乘子的二阶性质，得到真实局部三次阶数。一般起点上的一次更新仍是 Lambert-W 分布。不同 prefix 的 $b_0(x)$ 可以不同，因此上述逐 prefix 结论不自动给出全 prefix 的统一收敛率。

4.2.5 一般 OPD reward 的大步长极限

原论文对二元 reward 分析 $\tau \to 0$。OPD reward 通常有多个取值，可以直接在其完整取值分布上推广这一极限。以下固定 q, t，只令单轮步长 $\eta \to \infty$。

命题 4.4 (正中心化 log-ratio 的极限分布)

若 $q \neq t$，定义 $[x]_+ = \max\{x, 0\}$ 与

$$c = \sum_a q_a [h_a]_+ > 0.$$

则

$$\frac{\lambda}{\eta} \longrightarrow c, \qquad p_a^\star \longrightarrow \frac{q_a [h_a]_+}{c}. \tag{4.20}$$

证明 $\mathbb{E}_q h = 0$ 且 h 非恒定，所以 $h_{\max} > 0$，并且 $c > 0$。乘子上界给出

$$\lambda \le \log \mathbb{E}_q e^{\eta h} \le \eta h_{\max}.$$

选择满足 $h_a = h_{\max}$ 的动作 a_+。概率归一化意味着 $w(r_{a_+}) = p^\star_{a_+}/q_{a_+} \le 1/q_{a_+}$。于是 KKT 给出

$$\eta h_{\max} = \log w(r_{a_+}) + \lambda w(r_{a_+}) \le \log(1/q_{a_+}) + \lambda/q_{a_+}.$$

故

$$q_{a_+} h_{\max} - \frac{q_{a_+} \log(1/q_{a_+})}{\eta} \le \frac{\lambda}{\eta} \le h_{\max}.$$

λ/η 的任意序列都有收敛子列，其极限 c' 严格为正。沿该子列，当 $h_a > 0$ 时，令 $z_a = \lambda e^{\eta h_a}$。由 $W_0(z) = \log z - \log\log z + o(1)$，

$$\frac{W_0(z_a)}{\eta} \to h_a, \qquad w(r_a) = \frac{W_0(z_a)}{\lambda} \to \frac{h_a}{c'}.$$

当 $h_a = 0$ 时，$w(r_a) = W_0(\lambda)/\lambda = O(\log\eta/\eta) \to 0$。当 $h_a < 0$ 时，$z_a \to 0$，由 $W_0(z) = z(1 + o(1))$ 得到 $w(r_a) = e^{\eta h_a}(1 + o(1)) \to 0$。有限词表允许逐项取极限，归一化因此要求

$$1 = \lim \sum_a q_a w(r_a) = \frac{\sum_a q_a [h_a]_+}{c'}.$$

所以所有子列极限都等于 c，证明了乘子与分布的整个序列收敛。

二元 reward $r \in \{0, 1\}$、成功率 $p = \mathbb{E}_q r$ 时，$\mathbb{E}_q[r - p]_+ = p(1 - p)$，因此该一般结论恢复原论文的 $\lambda/\eta \to p(1 - p)$。对 OPD，它给出

$$p_a^\star \longrightarrow \frac{q_a [\log(t_a/q_a) + \mathrm{KL}(q\|t)]_+}{\mathbb{E}_q[\log(t/q) + \mathrm{KL}(q\|t)]_+}.$$

Gibbs 在大步长下集中到 t_a/q_a 最大的动作，而 Mean 的极限给所有正中心化 reward 的动作分配质量。这个固定 anchor 的大步长极限与 $0 < \eta \le 1$ 下的 outer teacher 收敛是两个不同结论。

4.2.6 有限 inner 的精细损失恒等式

命题 4.5 (Mean excess loss 的精确分解)

对任意正概率分布 p，

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q\left[\left(\log\frac{p}{p^\star}\right)^2\right] + \lambda\,\mathrm{KL}(p^\star\|p). \tag{4.21}$$

证明 记 $U = \log(p/q)$、$U^\star = \log(p^\star/q)$。展开平方得到

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q(U - U^\star)^2 + \mathbb{E}_q[(U - U^\star)(U^\star - G)].$$

KKT 给出 $U^\star - G = -\lambda p^\star/q$，所以第二项等于

$$-\lambda \mathbb{E}_{p^\star} \log \frac{p}{p^\star} = \lambda \,\mathrm{KL}(p^\star \| p).$$

代回即得所需恒等式。

例如，总体 inner excess loss 不超过 ϵ 时，$\mathbb{E}_q[\log(p/p^\star)^2] \le 2\epsilon$；若 $q \neq t$，还有 $\mathrm{KL}(p^\star\|p) \le \epsilon/\lambda$。接近 teacher 时 λ 趋零，后一个界会变松，因此不能据此声称所有轮次都有统一的 KL 误差控制。

4.2.7 LOO 中心估计与二元分析的迁移范围

命题 4.6 (逐 prefix LOO Mean 的期望损失)

固定 prefix、anchor 和候选 student p，令 $A_1, \dots, A_m \overset{\text{iid}}{\sim} q$，$m \ge 2$。定义

$$\widehat{r}_{-i} = \frac{1}{m-1}\sum_{j\neq i} r(A_j), \qquad \widehat{L}_{\mathrm{Mean}}(p) = \frac{1}{2m}\sum_{i=1}^{m}\big[U(A_i) - \eta\big(r(A_i) - \widehat{r}_{-i}\big)\big]^2.$$

则

$$\mathbb{E}\widehat{L}_{\mathrm{Mean}}(p) = L_{\mathrm{Mean}}(p) + \frac{\eta^2}{2(m-1)}\,\mathrm{Var}_q[r]. \tag{4.22}$$

证明 令 $\bar r = \mathbb{E}_q r$ 与 $e_{-i} = \widehat{r}_{-i} - \bar r$。第 i 项 residual 为

$$U(A_i) - \eta(r(A_i) - \bar r) + \eta e_{-i}.$$

LOO 保证 e_{-i} 与 A_i 独立，且 $\mathbb{E}e_{-i} = 0$、$\mathbb{E}e_{-i}^2 = \mathrm{Var}_q[r]/(m-1)$。展开平方取期望，交叉项为零，因此

$$\mathbb{E}\left[U(A_i) - \eta(r(A_i) - \widehat{r}_{-i})\right]^2 = \mathbb{E}_q[U - \eta(r-\bar r)]^2 + \frac{\eta^2\,\mathrm{Var}_q[r]}{m-1}.$$

对 i 求均值并乘 $1/2$ 即得结论。不同 LOO residual 之间的依赖不影响这个期望恒等式。

附加项与候选 student 无关。因而在有限词表的可微参数化中，冻结 anchor 与 reward 后，LOO Mean 梯度是总体 Mean 梯度的无偏估计。这里的 $\mathrm{Var}_q[r]$ 是完整 prefix OPD log-ratio 的方差。若对整个词表求和，可以直接计算 reward 均值，此时不产生这项中心采样误差。

原论文二元分析中的 $p(1-p)$、成功率 $J(\pi)$ 和 $1-J(\pi)$ 分别依赖 Bernoulli reward 的方差与成功事件解释。OPD 的 reward 通常连续取值且每轮随 anchor 改变，应使用 $\mathrm{Var}_{\pi_k}[\log(\pi_T/\pi_k)]$、teacher KL 与 log-ratio 跨度。总体 Lambert-W 解、混合 KL–χ^2 解释、归一化界和 excess-loss 恒等式均无需二元假设；二元成功率递推及其统计常数需要重新证明。

式 (4.22) 是固定候选分布的期望恒等式，不能直接替代数据依赖 ERM 的高概率界。要控制训练得到的 student，仍需给出可实现性或逼近误差、策略类复杂度、优化误差以及 reward/log-ratio 的界。逐 prefix 的有限正概率分布给出有限 reward 范围，但这个范围不一定在所有 prefix 与 outer 轮次上一致。式 (4.21) 则说明：统计分析应围绕约束最优分布的 excess loss 展开；将 Lambert-W 修正本身算作不可消失的 target-estimation 误差，会掩盖 Mean 的总体一致性。

4.2.8 Mean hard sync 的完整稳定区间

以下仍固定一个 prefix，沿用 $q = \pi_k(\cdot \mid x)$、$t = \pi_T(\cdot \mid x)$、$r_a = \log(t_a/q_a)$、$\kappa = \mathrm{KL}(q\|t)$ 和 $w_a = p^\star_a/q_a$。词表有限，teacher 的每个概率均严格为正，步长 η 在 outer 轮次间固定。乘子 $\lambda = \mathrm{KL}(q\|p^\star)$ 由当前 anchor 决定。跨度统一记为 $b(q,t) = d_H(q,t) = \max_a \log(q_a/t_a) - \min_a \log(q_a/t_a)$，因此逐轮的 $b_k = d_H(\pi_k, t)$。精确 Mean 的 KKT 写为

$$\log w_a + \lambda w_a = \eta(r_a + \kappa), \qquad \sum_a q_a w_a = 1. \tag{4.23}$$

这里讨论的是每轮精确求解并更新 $\pi_{k+1} = p^\star$ 的分布空间动力学。步长的稳定区间和单轮 teacher KL 的下降区间是两个不同性质。

定理 4.8 (Mean hard sync 的全局稳定区间)

固定严格正的 teacher 和严格正的初始 anchor。若 $0 < \eta \le 2$，精确 Mean hard sync 满足

$$b(\pi_{k+1}, t) < b(\pi_k, t) \quad \text{只要} \pi_k \neq t, \qquad \pi_k \longrightarrow t.$$

当 $0 < \eta < 2$ 时，定义

$$C_\eta(b) = \max\left\{1 - \frac{\eta}{1+\eta b}, \eta - 1\right\}. \tag{4.24}$$

则 $0 \le C_\eta(b) < 1$ 对 $b > 0$ 成立，而且

$$b(\pi_{k+1}, t) \le C_\eta(b(\pi_k, t))b(\pi_k, t) \le C_\eta(b(\pi_0, t))b(\pi_k, t). \tag{4.25}$$

当 $\eta > 2$ 时，teacher 固定点局部不稳定。

♡

证明 首先考虑 $q \neq t$，此时 $\lambda > 0$。固定当前轮次的 λ, κ，把 w_a 写为 r_a 的函数 $w(r)$。对式 (4.23) 求导得到

$$\frac{d \log w(r)}{dr} = \frac{\eta}{1 + \lambda w(r)}.$$

令 $v(r) = \log w(r) - r$，则 $v(r_a) = \log(p^\star_a / t_a)$，并且

$$v'(r) = -1 + \frac{\eta}{1 + \lambda w(r)}. \tag{4.26}$$

当 $0 < \eta \le 2$ 时，$\lambda w(r) > 0$ 保证 $-1 < v'(r) < 1$。在有限区间 $[r_{\min}, r_{\max}]$ 上连续性进一步给出 $\sup_r |v'(r)| < 1$。对任意动作对应用均值定理，得到严格跨度收缩。

为了得到显式界，归一化保证 $w_{\max} \ge 1$，而 $\kappa = -\mathbb{E}_q r \le -r_{\min}$。最大 reward 处的 KKT 因此给出

$$\lambda w_{\max} = \eta(r_{\max} + \kappa) - \log w_{\max} \le \eta(r_{\max} - r_{\min}) = \eta b(q, t).$$

结合 $\lambda w(r) > 0$，式 (4.26) 的值落在

$$-1 + \frac{\eta}{1 + \eta b(q,t)} \le v'(r) < \eta - 1.$$

令 $L = -1 + \eta/(1+\eta b)$、$U = \eta - 1$。由于 $L \le U$，有 $|v'| \le \max\{-L, U\} = C_\eta(b)$；这个写法同时覆盖导数同号和异号的情况，由此得到单步界。C_η 关于 b 非减，且当 $0 < \eta < 2$、$b > 0$ 时严格小于一。逐轮归纳即得几何收敛。

边界 $\eta = 2$ 的上述显式因子等于一，需要使用精确更新的连续性。归一化给出

$$\min_a \log(q_a/t_a) \le 0 \le \max_a \log(q_a/t_a).$$

因此 $b(q,t) \le b_0$ 蕴含

$$t_a e^{-b_0} \le q_a \le t_a e^{b_0}.$$

所有迭代均落在严格正概率单纯形内的紧集上。精确更新关于 q 连续：归一化方程关于 λ 严格单调，在 $q \neq t$ 处其根连续；在 $q = t$ 附近，$\lambda \le \log \mathbb{E}_q e^{\eta(r+\kappa)} \to 0$，KKT 给出 $p^\star \to t$。

设单调下降的跨度趋于 $b_\infty > 0$。在紧集

$$\{q : b_\infty \le b(q,t) \le b_0\}$$

上，函数 $b(q,t) - b(p^\star(q), t)$ 连续且处处严格为正，因此存在统一正下界。这与跨度收敛矛盾，故 $b_\infty = 0$，并且 $q_k \to t$。若某轮已经到达 t，后续轮次保持 t。

最后，在 teacher 附近采用下面定义的中心化坐标，更新的线性化为 $y \mapsto (1-\eta)y$。当 $\eta > 2$ 时，$|1-\eta| > 1$。存在邻域和常数 $c > 1$，使每个非零充分小误差的更新范数至少放大 c 倍，因此固定点局部不稳定。

该定理扩大了 Mean 的 hard sync 稳定范围。前面的 teacher KL 单步下降证明仍直接适用于 $0 < \eta \le 1$；跨度收缩证明则允许 $1 < \eta \le 2$。在后一范围内，不能把跨度的严格下降直接换成每轮 KL 严格下降。

4.2.9 $\eta = 1$ 的三次跨度界

命题 4.7 (Mean 的三次单步上界)

当 $\eta = 1$ 时，令 $b = b(q,t)$，则

$$b(p^\star, t) \le \frac{e^b b^2}{8 + e^b b^2}\, b. \tag{4.27}$$

该界和式 (4.19) 同时成立，可以取两者的较小值。特别地，$b \to 0$ 时

$$b(p^\star, t) \le \left(\frac{1}{8} + O(b)\right) b^3.$$

♠

证明 在 $\eta = 1$ 时，$0 < d\log w/dr \le 1$，故

$$\max_a \log w_a - \min_a \log w_a \le b.$$

归一化 $\mathbb{E}_q w = 1$ 保证 $w_{\min} \le 1 \le w_{\max}$，从而 $w_{\max} \le e^b$。乘子界给出 $\lambda \le \kappa$。另一方面，由 $\mathbb{E}_q e^r = \sum_a t_a = 1$，

$$\kappa = -\mathbb{E}_q r = \log \mathbb{E}_q e^{r - \mathbb{E}_q r}.$$

为写出 Hoeffding 界的常数，令 $F(u) = \log \mathbb{E}_q \exp\{u(r - \mathbb{E}_q r)\}$。有 $F(0) = F'(0) = 0$，而 $F''(u)$ 等于指数倾斜分布下 r 的方差。跨度仍为 b，故以区间中点为参照有 $F''(u) \le b^2/4$。两次积分给出

$$\kappa = F(1) = \int_0^1 (1-u) F''(u)\, du \le b^2/8.$$

因此

$$\lambda w_{\max} \le e^b b^2/8.$$

式 (4.26) 在 $\eta = 1$ 时为

$$|v'(r)| = \frac{\lambda w(r)}{1 + \lambda w(r)} \le \frac{e^b b^2}{8 + e^b b^2}.$$

再用均值定理便得到结论。$q = t$ 时两边均为零。

三次界来自两个不同因素：归一化乘子在 teacher 附近是二阶小量，动作间的 reward 差异是一阶小量。仅用 $\lambda w_{\max} \le b$ 会丢掉乘子的二阶性质，因此得到的二次界不能描述真实局部阶数。

4.2.10 统一 teacher 坐标下的精细展开

为了比较不同步长，定义同一个 teacher 中心化误差坐标

$$y_a = \log(q_a/t_a) - \mathbb{E}_t \log(q/t), \qquad \mathbb{E}_t y = 0, \qquad V = \mathbb{E}_t y^2. \tag{4.28}$$

于是 $q_a = t_a e^{y_a}/\mathbb{E}_t e^y$。更新后的 y_a^+ 采用完全相同的定义，将 q 换成 $p^\star$。记 $\delta = \|y\|_\infty$。以下大 O 常数只依赖固定 teacher、有限词表及固定步长 η，与接近 teacher 的具体方向无关。

定理 4.9 (Mean 更新的三阶局部展开)

对固定 $\eta > 0$，当 $\delta \to 0$ 时，

$$\begin{aligned} \kappa &= \frac{1}{2} V + O(\delta^3), \\ \lambda &= \frac{\eta^2}{2} V + O(\delta^3), \\ y_a^+ &= (1-\eta) y_a + \frac{\eta^3}{2} V y_a + O(\delta^4). \end{aligned} \tag{4.29}$$

最后一个余项关于动作一致有界。对于 $\eta = 1$，有

$$V^+ = \frac{1}{4} V^3 + O(V^{7/2}), \qquad \frac{\mathrm{KL}(p^\star \| t)}{\mathrm{KL}(q\|t)^3} \longrightarrow 1 \quad (q \to t,\ q \ne t). \tag{4.30}$$

♡

证明 令 $Z = \mathbb{E}_t e^y$。$\mathbb{E}_t y = 0$ 和有限维 Taylor 展开给出

$$Z = 1 + \frac{1}{2}V + O(\delta^3), \qquad \log Z = \frac{1}{2}V + O(\delta^3).$$

又因为 $q_a = t_a e^{y_a}/Z$，

$$\mathbb{E}_q y = \frac{\mathbb{E}_t[ye^y]}{Z} = V + O(\delta^3).$$

所以 $\kappa = \mathbb{E}_q y - \log Z = V/2 + O(\delta^3)$。中心化 reward 恰好等于

$$r_a + \kappa = -y_a + \mathbb{E}_q y.$$

记 $G_a = \eta(-y_a + \mathbb{E}_q y)$，则 $\mathbb{E}_q G = 0$ 且 $G_a = O(\delta)$。归一化方程为

$$\Phi(\lambda, y) = \mathbb{E}_q \exp\{G - W_0(\lambda e^G)\} - 1 = 0.$$

在 $(\lambda, y) = (0, 0)$，$\Phi = 0$ 且 $\partial_\lambda \Phi = -1$。$W_0$ 在零点解析，隐函数定理因此给出局部解析的 $\lambda(y)$。为确定首项，先计算

$$\mathbb{E}_q e^G = 1 + \frac{1}{2}\mathbb{E}_q G^2 + O(\delta^3) = 1 + \frac{\eta^2}{2}V + O(\delta^3).$$

由于 $W_0(z) = z + O(z^2)$，归一化式进一步写为

$$0 = \mathbb{E}_q e^G - 1 - \lambda \mathbb{E}_q e^{2G} + O(\lambda^2).$$

隐函数的连续性及此式先给出 $\lambda = O(\delta^2)$，继而得到

$$\lambda = \frac{\eta^2}{2}V + O(\delta^3).$$

下面对 KKT 解做 teacher 中心化。记 $\mathcal{C}_t f = f - \mathbb{E}_t f$。因公共归一化常数在中心化后消失，

$$y^+ = y + \mathcal{C}_t G - \mathcal{C}_t W_0(\lambda e^G) = (1 - \eta)y - \mathcal{C}_t W_0(\lambda e^G).$$

λ 在动作间是公共标量，且 $\lambda = O(\delta^2)$，故

$$\mathcal{C}_t W_0(\lambda e^G) = \lambda \mathcal{C}_t e^G + O(\delta^4),$$
$$\mathcal{C}_t e^G = \mathcal{C}_t G + O(\delta^2) = -\eta y + O(\delta^2).$$

因此

$$y^+ = (1 - \eta)y + \eta\lambda y + O(\delta^4) = (1 - \eta)y + \frac{\eta^3}{2}Vy + O(\delta^4).$$

当 $\eta = 1$ 时，$y^+ = Vy/2 + R$，其中 $\|R\|_\infty = O(\delta^4)$。固定 $t_{\min} = \min_a t_a > 0$ 保证

$$t_{\min}\delta^2 \le V \le \delta^2.$$

从而 $\|R\|_\infty = O(V^2)$。对平方取 teacher 均值，得到

$$V^+ = \frac{1}{4}V^3 + V\mathbb{E}_t[yR] + \mathbb{E}_t R^2 = \frac{1}{4}V^3 + O(V^{7/2}).$$

同一 KL 展开分别用于旧、新分布：

$$\mathrm{KL}(q\|t) = \frac{1}{2}V + O(V^{3/2}), \qquad \mathrm{KL}(p^\star\|t) = \frac{1}{2}V^+ + O((V^+)^{3/2}).$$

分子首项为 $V^3/8$，分母首项也为 $V^3/8$，由此得到比值极限。

沿任意固定非恒定方向 z，取 $q_\epsilon \propto t\exp(\epsilon z)$。中心化后 $y = \epsilon(z - \mathbb{E}_t z)$。因此 $\eta = 1$ 时

$$\frac{b(p^\star, t)}{b(q_\epsilon, t)^3} \longrightarrow \frac{\mathrm{Var}_t(z)}{2(\max_a z_a - \min_a z_a)^2}.$$

Popoviciu 方差界使该极限不超过 $1/8$，与三次跨度上界的局部常数一致。这个方向依赖的跨度常数和方向无关的 KL 三次比值是同一展开的两个结果。

4.2.11 边界步长 $\eta = 2$ 的幂率

定理 4.10 (Mean 边界步长的渐近 KL 率)

固定有限词表、严格正 teacher、严格正初始 anchor，在 $\eta = 2$ 下执行精确 Mean hard sync。若某轮到达 teacher，则后续 KL 恒为零。若没有任何有限轮次到达 teacher，则

$$kV_k \longrightarrow \frac{1}{8}, \qquad k\,\mathrm{KL}(\pi_k\|t) \longrightarrow \frac{1}{16}. \tag{4.31}$$

♡

证明 全局稳定定理已经给出 $\pi_k \to t$，从而 $V_k \to 0$。三阶展开在 $\eta = 2$ 时成为

$$y^+ = -y + 4Vy + R, \qquad \|R\|_\infty = O(V^2).$$

对平方取 t 均值：

$$\begin{aligned} V^+ &= (-1+4V)^2 V + 2(-1+4V)\mathbb{E}_t[yR] + \mathbb{E}_t R^2 \\ &= V - 8V^2 + O(V^{5/2}). \end{aligned}$$

未有限步到达 teacher 意味着所有 $V_k > 0$。当 k 足够大时，$V_{k+1}/V_k \to 1$，因此

$$\frac{1}{V_{k+1}} - \frac{1}{V_k} = \frac{V_k - V_{k+1}}{V_k V_{k+1}} = 8 + O(\sqrt{V_k}) \longrightarrow 8.$$

从某个固定轮次开始累加，并对平均增量取极限，得到 $1/(kV_k) \to 8$。最后

$$\mathrm{KL}(\pi_k\|t) = \frac{1}{2}V_k + O(V_k^{3/2})$$

给出 $k\,\mathrm{KL}(\pi_k\|t) \to 1/16$。

Gibbs更新在同一坐标中恰好满足 $y^+ = (1-\eta)y$。当 $\eta = 2$ 时，Gibbs 的 $y^+ = -y$ 构成两周期，V 恒定。Mean 的 $4Vy$ 修正提供三次阻尼，因而其边界步长收敛，但仅具有 $1/k$ 的 KL 渐近率。当 $\eta = 1$ 时，Gibbs 一步到达 teacher，Mean 则保留三阶误差。两者具有相同 teacher 固定点，但精确 outer 更新及其边界行为不同。

4.3 有限 inner 更新的误差

设方法 M 的总体最优分布为 $\pi_k^{\star,M}$，inner 算法在固定 x 上得到 $\pi_{k,n}$。PMD-Mean 使用 Lambert-W target，另外三种方法使用 Gibbs target $\pi_k^{\star,\mathrm{Gibbs}}$。本节 m 表示独立梯度样本数。定义优化误差

$$e_{k,n}(x) = \mathrm{TV}\Big(\pi_{k,n}(\cdot\mid x), \pi_k^{\star,M}(\cdot\mid x)\Big).$$

对参数化损失，假设梯度是 L_{sm}-Lipschitz，随机梯度 $\widehat{g}_n$ 条件无偏且满足

$$\mathbb{E}[\widehat{g}_n \mid \theta_{k,n}] = \nabla\mathcal{L}(\theta_{k,n}), \qquad \mathbb{E}\big[\|\widehat{g}_n - \nabla\mathcal{L}(\theta_{k,n})\|^2 \mid \theta_{k,n}\big] \le \frac{\sigma^2}{m}.$$

普通 SGD 取 $\theta_{k,n+1} = \theta_{k,n} - \alpha\widehat{g}_n$，$0 < \alpha \le 1/L_{\mathrm{sm}}$。由光滑性不等式及条件无偏性，

$$\begin{aligned} \mathbb{E}[\mathcal{L}(\theta_{k,n+1}) \mid \theta_{k,n}] &\le \mathcal{L}(\theta_{k,n}) - \alpha\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2}{2}\mathbb{E}[\|\widehat{g}_n\|^2 \mid \theta_{k,n}] \\ &\le \mathcal{L}(\theta_{k,n}) - \frac{\alpha}{2}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2\sigma^2}{2m}. \end{aligned}$$

设 $\mathcal{L}_*$ 是损失下界，对 $n = 0, \dots, N-1$ 求和得到

$$\frac{1}{N}\sum_{n=0}^{N-1}\mathbb{E}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 \le \frac{2(\mathcal{L}(\theta_{k,0}) - \mathcal{L}_*)}{\alpha N} + \frac{L_{\mathrm{sm}}\alpha\sigma^2}{m}.$$

此式控制平均梯度范数。将它转成 $e_{k,n}$ 的分布误差界还需要局部曲率或梯度与分布距离之间的定量关系。

对采用 student/anchor importance ratio 的 MDPO estimator，方差界包含 $1 + \chi^2(\pi_{k,n}\|\pi_k)$。PMD-Mean 和 BPO 的 anchor-measure estimator 直接分析 residual、score 与 center 的联合二阶矩。

PMD-Mean 到 Gibbs 分布的差异还包含总体目标偏差：

$$\mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Gibbs}}) \le \mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Mean}}) + \mathrm{TV}(\pi_k^{\star,\mathrm{Mean}}, \pi_k^{\star,\mathrm{Gibbs}}).$$

增加 inner steps 只能降低第一项，第二项由均值近似决定。

4.3.1 Excess loss 到逐 token 误差的转换

命题 4.8 (最小 anchor 概率下的确定性转换)

固定 prefix，假设 $\pi_k(v) \geq m_0 > 0$，且 PMD-Mean 或 PMD-Part 的总体 inner excess loss 不超过 δ_k。对于各自的正确总体最优分布 $\pi_k^{\star,M}$，有

$$\max_v \left| \log \frac{\widehat{\pi}_{k+1}(v)}{\pi_k^{\star,M}(v)} \right| \leq \sqrt{\frac{2\delta_k}{m_0}}.$$

♠

证明 Mean 的式 (4.21) 给出

$$\delta_k \geq \frac{1}{2}\mathbb{E}_{\pi_k}\left[\log \frac{\widehat{\pi}_{k+1}}{\pi_k^{\star,\mathrm{Mean}}}\right]^2.$$

Part 在其零 residual 的 Gibbs 最优点处同样满足该平方恒等式。对任意 token v，期望中的单项不超过总和，因此

$$\frac{m_0}{2}\left[\log \frac{\widehat{\pi}_{k+1}(v)}{\pi_k^{\star,M}(v)}\right]^2 \leq \delta_k.$$

开平方后对 v 取最大值得到结论。

这个转换需要总体 excess loss 与正的最小 anchor 概率。有限词表在单个 prefix 上保证某个 $m_0 > 0$，但不能保证它在所有 prefix 和 outer 轮次上统一远离零。前节 SGD 的平均梯度范数界也不自动给出 δ_k；要串联两者，还需误差界或 Polyak–Łojasiewicz 条件等定量假设。

4.4 有限 inner 与扰动 Outer 递推

本节先在 $0 < \eta \leq 1$ 下以 Gibbs inner 方法为对象，随后给出整个稳定区间的推广。实际第 k 轮只运行 N_k 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left| \log \frac{\widehat{\pi}_{k+1}(a \mid x)}{\pi_k^{\star,\mathrm{Gibbs}}(a \mid x)} \right| \leq \varepsilon_k$$

对未归一化的正权重成立（若已是归一化策略，则直接使用该假设）。归一化至多使逐 token 的 log-ratio 误差从 ε_k 增至 $2\varepsilon_k$，但不改变误差跨度，其值至多为 $2\varepsilon_k$。由定理 4.5，

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi_k^{\star,\mathrm{Gibbs}}) \leq \tanh(\varepsilon_k/2). \tag{4.32}$$

几何插值在 log-ratio 振幅上收缩，不能据此前的推论直接宣称 TV 每步以 $1-\eta$ 收缩。定义

$$b_k = \max_a \log \frac{\pi_k(a \mid x)}{\pi_T(a \mid x)} - \min_a \log \frac{\pi_k(a \mid x)}{\pi_T(a \mid x)}.$$

精确 Gibbs 更新把振幅变成 $(1-\eta)b_k$；上述逐 action log-density 误差最多再增加 $2\varepsilon_k$。因此

$$b_{k+1} \leq (1-\eta)b_k + 2\varepsilon_k, \tag{4.33}$$

归纳展开得到

$$b_{K_{\mathrm{out}}} \leq (1-\eta)^{K_{\mathrm{out}}} b_0 + 2\sum_{j=0}^{K_{\mathrm{out}}-1} (1-\eta)^{K_{\mathrm{out}}-1-j}\varepsilon_j.$$

归一化分布的 log-ratio 最小值不大于零，最大值不小于零，故 $|\log(\pi_{K_{\mathrm{out}}}/\pi_T)| \leq b_{K_{\mathrm{out}}}$。进一步由定理 4.5 得到更紧的分布距离界：

$$\mathrm{TV}(\pi_{K_{\mathrm{out}}}, \pi_T) \leq \tanh(b_{K_{\mathrm{out}}}/4).$$

若 $\varepsilon_j \leq \bar{\varepsilon}$，振幅的稳态上界为 $2\bar{\varepsilon}/\eta$。这给出 Gibbs 方法有限 inner 误差的几何累积关系。

对于 PMD-Mean，取 $0 < \eta \le 1$，有限 inner 输出执行 hard sync，并假设它在所有 action 上满足

$$\left| \log \frac{\widehat{\pi}_{k+1}(a \mid x)}{\pi_k^{\star,\mathrm{Mean}}(a \mid x)} \right| \le \varepsilon_k.$$

由本章 Mean 跨度收缩定理和振幅的三角不等式，得到

$$b_{k+1} \le \left(1 - \frac{\eta}{1+\eta b_k}\right) b_k + 2\varepsilon_k.$$

若已知整个训练段 $b_k \le A_0$，则定义 $c_0 = 1 - \eta/(1+\eta A_0) < 1$，归纳可得

$$b_{K_{\mathrm{out}}} \le c_0^{K_{\mathrm{out}}} b_0 + 2 \sum_{j=0}^{K_{\mathrm{out}}-1} c_0^{K_{\mathrm{out}}-1-j} \varepsilon_j.$$

这里的统一跨度上界是附加假设；精确 inner 的初始跨度上界不能自动替代含优化误差的迭代上界。前节 excess-loss 恒等式提供加权均方 log-ratio 和 KL 控制；将其换成上述逐 action 误差，还需要 anchor 最小概率下界等条件。

定理 4.11 (Mean 在有界 inner 扰动下的不变跨度)

若 $0 < \eta \le 1$ 且每轮误差满足 $\varepsilon_k \le \bar{\varepsilon} < 1/2$，定义

$$b_\infty = \frac{2\bar{\varepsilon}}{\eta(1-2\bar{\varepsilon})}, \qquad A = \max\{b_0, b_\infty\}.$$

则所有 k 均有 $b_k \le A$。令 $c_A = 1 - \eta/(1+\eta A)$，则

$$b_K \le c_A^K b_0 + 2 \sum_{j=0}^{K-1} c_A^{K-1-j} \varepsilon_j, \qquad \limsup_{k\to\infty} b_k \le b_\infty.$$

♡

证明 令 $f(b) = b - \eta b/(1+\eta b) + 2\bar{\varepsilon}$。在 $b \ge 0$ 上

$$f'(b) = 1 - \frac{\eta}{(1+\eta b)^2} \ge 0.$$

解 $f(b) = b$ 得 $b = b_\infty$。当 $A \ge b_\infty$ 时，$\eta A/(1+\eta A) \ge 2\bar{\varepsilon}$，所以 $f(A) \le A$。由 $b_{k+1} \le f(b_k)$ 与单调性归纳得到 $b_k \le A$。将这个上界代入收缩因子，得到 $b_{k+1} \le c_A b_k + 2\varepsilon_k$，展开递推即是第一式。

为证明稳态界，构造 $u_0 = A$、$u_{k+1} = f(u_k)$。单调性给出 $b_k \le u_k$，而 $u_k \ge b_\infty$ 且单调下降，故存在极限。连续性要求该极限为 f 的唯一非负不动点 b_∞，从而 $\limsup b_k \le b_\infty$。当 $\bar{\varepsilon} = 0$ 时该不动点为零，恢复精确 inner 的收敛结论。

4.4.1 使用旧 anchor target 的附加误差

若实际优化的是旧 anchor π_j 对应的 Gibbs target，而当前 outer anchor 已为 π_k，则归一化常数消去后

$$\mathrm{osc}_v \log \frac{\pi_j^{\star,\mathrm{Gibbs}}(v)}{\pi_k^{\star,\mathrm{Gibbs}}(v)} = (1-\eta)\,\mathrm{osc}_v \log \frac{\pi_j(v)}{\pi_k(v)}.$$

因此对当前 target 的总跨度误差，至多是相对旧 target 的优化跨度误差加上右侧的 stale-anchor 项。teacher 与 η 在这两个 target 间固定是该等式的前提。这个 target 漂移与第三章中旧 rollout 的采样测度偏差是两个独立问题，分别进入 outer 递推和梯度估计。

4.4.2 Hard sync 的确定性误差与 teacher 漂移

固定 prefix，并允许 teacher 随 outer 轮次改变，记 $t_k = \pi_{T,k}(\cdot \mid x)$。把实际输出写成

$$\pi_{k+1}(a) \propto \pi_k(a)^{1-\eta_k} t_k(a)^{\eta_k} \exp\{e_k(a)\}. \tag{4.34}$$

这里 e_k 是输出相对精确 Gibbs target 的未归一化 log-density 误差。它可以包含有限 inner、目标计算和参数共享带来的偏差；本节先直接分析输出误差，不把梯度方差直接当作 e_k 的方差。记 $\mathrm{osc}\, f = \max_a f(a) - \min_a f(a)$，

并定义

$$b_k = d_H(\pi_k, t_k), \qquad E_k = \operatorname{osc} e_k, \qquad D_k = d_H(t_k, t_{k+1}).$$

其中 d_H 是前节定义的 log-ratio 跨度。D_k 描述 teacher 分布漂移，与最后一节的 prefix 访问测度漂移分开。

定理 4.12 (输出误差的输入–状态界)

若所有分布严格为正，则式 (4.34) 满足

$$b_{k+1} \le |1-\eta_k| b_k + E_k + D_k. \tag{4.35}$$

固定 $0 < \eta < 2$，令 $c = |1-\eta| < 1$，则

$$b_K \le c^K b_0 + \sum_{j=0}^{K-1} c^{K-1-j}(E_j + D_j).$$

若 $E_j + D_j \le B$，则 $\limsup_K b_K \le B/(1-c)$。若 $E_j + D_j \to 0$，则 $b_K \to 0$。

♡

证明 对更新取相对 t_{k+1} 的 log-ratio：

$$\log \frac{\pi_{k+1}}{t_{k+1}} = (1-\eta_k) \log \frac{\pi_k}{t_k} + e_k + \log \frac{t_k}{t_{k+1}} - \log Z_k.$$

动作无关的 $\log Z_k$ 在跨度中抵消。由 $\operatorname{osc}(f+g) \le \operatorname{osc} f + \operatorname{osc} g$ 和 $\operatorname{osc}(af) = |a| \operatorname{osc} f$，得到式 (4.35)。逐次代入递推得到卷积式，再利用 $\sum_{i=0}^{K-1} c^i = (1-c^K)/(1-c)$ 得到稳态上界。

对消失扰动，给定 $\delta > 0$，选 J 使 $j \ge J$ 时 $E_j + D_j \le (1-c)\delta$。有限前缀贡献 $c^K b_0 + \sum_{j<J} c^{K-1-j}(E_j + D_j)$ 趋于零，剩余贡献至多 δ。令 $\delta \downarrow 0$ 得到收敛。

该界解释了 hard sync 对误差的放大系数。$0 < \eta \le 1$ 时分母为 η，$1 \le \eta < 2$ 时分母为 $2-\eta$。相同的逐轮输出跨度误差在 $\eta = 1$ 时具有最小最坏情形放大系数；接近稳定区间两端时误差积累更强。

固定 teacher、固定误差向量 e 时，不动点可以精确求出：

$$\pi_\infty(a) = \frac{t(a)\exp\{e(a)/\eta\}}{\sum_v t(v)\exp\{e(v)/\eta\}}, \qquad d_H(\pi_\infty, t) = \frac{\operatorname{osc} e}{\eta}.$$

证明是在不动点更新中把 $\eta \log(\pi_\infty/t) = e -$ 常数 解出。对于 $\eta \le 1$，它达到上述最坏情形稳态界。对于 $\eta > 1$，固定误差的稳态比一般界小，因为一般界还允许误差随轮次交替；在居中 log-ratio 坐标中取 $e_k = (-1)^{k+1} e$，便可产生 $\operatorname{osc} e/(2-\eta)$ 的交替稳态跨度。

4.4.3 随机输出误差的精确矩递推

固定 teacher $t = \pi_T$，定义相对 teacher 的居中坐标

$$y_k(a) = \log \frac{\pi_k(a)}{t(a)} - \mathbb{E}_t \log \frac{\pi_k}{t}, \qquad \xi_k(a) = e_k(a) - \mathbb{E}_t e_k.$$

$\mathbb{E}_t y_k = \mathbb{E}_t \xi_k = 0$。居中操作是线性的，因此归一化常数完全消去，式 (4.34) 给出精确线性系统

$$y_{k+1} = (1-\eta) y_k + \xi_k. \tag{4.36}$$

这个等式在大误差时也成立；把 $\|y_k\|^2$ 换成 KL 时才需要局部近似。

定理 4.13 (Hard sync 的偏差与协方差传播)

令 $a_\eta = 1-\eta$。若 y_0 确定、$\mathbb{E}[\xi_k \mid \mathcal{F}_k] = 0$、$\mathbb{E}[\xi_k \xi_k^\top \mid \mathcal{F}_k] = \Sigma_k$ 为确定矩阵，且 y_k 是 $\mathcal{F}_k$ 可测的，则

$$\mathbb{E} y_K = a_\eta^K y_0, \qquad \operatorname{Cov}(y_K) = \sum_{j=0}^{K-1} a_\eta^{2(K-1-j)} \Sigma_j.$$

若 $0 < \eta < 2$ 且 $\Sigma_j = \Sigma$，则

$$\operatorname{Cov}(y_K) \longrightarrow \frac{\Sigma}{\eta(2-\eta)}. \tag{4.37}$$

若 $\xi_k = m + \nu_k$，其中 ν_k 条件均值为零，则 $\mathbb{E}y_K \to m/\eta$，协方差结论对 ν_k 保持成立。 ♡

证明 展开式 (4.36)：

$$y_K = a_\eta^K y_0 + \sum_{j=0}^{K-1} a_\eta^{K-1-j}\xi_j.$$

条件均值为零推出 $\mathbb{E}\xi_j = 0$。对 $i < j$，ξ_i 已是 $\mathcal{F}_j$ 可测，所以

$$\mathbb{E}[\xi_i\xi_j^\top] = \mathbb{E}[\xi_i\mathbb{E}(\xi_j^\top \mid \mathcal{F}_j)] = 0.$$

双重求和中的交叉项消失，只留下所给协方差和。常协方差时，平方几何级数的分母为 $1 - a_\eta^2 = \eta(2-\eta)$。非零均值情形直接对 $\mathbb{E}y_{k+1} = a_\eta\mathbb{E}y_k + m$ 求解。

令 $M_t = \mathrm{diag}(t)$。由 $\pi_k = t\exp(y_k)/\mathbb{E}_t\exp(y_k)$，在 $\|y_k\|_\infty \to 0$ 时有

$$\mathrm{KL}(\pi_k\|t) = \frac{1}{2}y_k^\top M_t y_k + O(\|y_k\|_\infty^3).$$

因此有限时间的二阶预期 KL 为

$$\frac{1}{2}\left[(\mathbb{E}y_K)^\top M_t(\mathbb{E}y_K) + \mathrm{tr}\{M_t\,\mathrm{Cov}(y_K)\}\right].$$

固定 $0 < \eta < 2$，若 ν_k 是独立高斯向量，并令 $m = \epsilon\bar{m}$、$\Sigma = \epsilon^2\bar{\Sigma}$ 随同一尺度 $\epsilon \downarrow 0$ 缩小，其中 $\bar{m}, \bar{\Sigma}$ 固定，则稳态三阶绝对矩为 $O(\epsilon^3)$。上式的稳态二阶项就是

$$\frac{1}{2\eta^2}m^\top M_t m + \frac{\mathrm{tr}(M_t\Sigma)}{2\eta(2-\eta)}. \tag{4.38}$$

稳态预期 KL 等于该二阶项加 $O(\epsilon^3)$。式 (4.37) 则是精确的 log-ratio 协方差结论。仅有二阶矩假设时不能宣称 KL 的高阶余项也受控。

误差注入的位置决定步长依赖。若每轮实际输出的误差 ξ_k 具有固定协方差，式 (4.38) 的无偏噪声底与 $[\eta(2-\eta)]^{-1}$ 成正比。若误差来自 reward 估计，并以 $\xi_k = \eta\zeta_k$ 进入指数，固定的是 ζ_k 的协方差 Σ_ζ，则噪声底改为

$$\frac{\eta}{2(2-\eta)}\,\mathrm{tr}(M_t\Sigma_\zeta).$$

第二种模型中减小步长降低稳态噪声，同时减慢确定性收敛。第三章的 KL estimator 无偏性控制相应 reward 或梯度误差的条件均值；从它到本节的 m, Σ 还要经过 inner 优化和停止梯度规则，不能直接等同。

4.4.4 同步操作与分布空间模型的对应关系

4.4.4.1 保留快速 outer 收敛所需的 inner 精度

固定 teacher，记每轮相对正确 target 的输出跨度误差为 E_k。Gibbs 在 $c = |1-\eta| \in (0,1)$ 时满足 $b_{k+1} \le cb_k + E_k$。若 $E_k \le B\gamma^k$，其中 $0 < \gamma < 1$，则卷积可精确求和：

$$b_K \le c^K b_0 + \begin{cases} B(c^K - \gamma^K)/(c-\gamma), & c \ne \gamma, \\ BKc^{K-1}, & c = \gamma. \end{cases}$$

所以输出误差衰减得比理想动力学慢时，outer 收敛率由 γ 决定；相同衰减率时还会出现 K 因子。若一个 inner 求解器能保证 $E_k \le C\beta^{N_k}$，其中 $0 < \beta < 1$，要达到 $E_k \le B\gamma^k$，充分的 inner 步数为

$$N_k \ge \max\left\{0, \frac{\log(C/B) + k\log(1/\gamma)}{\log(1/\beta)}\right\}.$$

这里指数收敛的 inner 假设必须另行证明；前面的普通非凸 SGD 梯度范数界不提供这个保证。

Mean 在 $\eta = 1$ 时，令 $H(b) = e^b b^2/(8 + e^b b^2)$，三次跨度定理给出

$$b_{k+1} \le H(b_k)b_k + E_k.$$

当 $b_k \to 0$ 时，保留三次阶数需要 $E_k = O(b_k^3)$；若希望保留精确 Mean 的三次首项，则需要更强的 $E_k = o(b_k^3)$。结合前述最小 anchor 概率下的 excess-loss 转换，$E_k \le 2\sqrt{2\delta_k/m_0}$，在所考察轮次具有统一 $m_0 > 0$ 时，一个充分条

件是 $\delta_k = O(b_k^6)$，保留首项则取 $o(b_k^6)$。若只能给出逐轮下界 $m_{0,k}$，相应条件改为 $\delta_k = O(m_{0,k}b_k^6)$ 或 $o(m_{0,k}b_k^6)$。即使 $\eta = 1$ 的精确 outer 极快，固定 inner 精度也会使这段快速收敛提前停止。

固定误差上界 $E_k \le E$ 时可以得到比一般 Mean 不变跨度界更精细的局部结论。若 $H(2E) \le 1/2$ 且 $b_0 \le 2E$，由于 H 非减，

$$b_{k+1} \le H(2E)\,2E + E \le 2E.$$

归纳得到不变邻域。对 $L = \limsup b_k$，递推进一步给出

$$L \le H(2E)L + E, \qquad L \le \frac{E}{1 - H(2E)} = E + O(E^3) \quad (E \downarrow 0).$$

这个结论要求初值位于上述局部邻域；它没有替代前面适用于大跨度的全局扰动界。

4.4.4.2 同步边界的冻结量

本章 hard sync 表示把下一轮 anchor 完全设为本轮 inner 输出。一次参数复制满足这一定义，却不保证 inner 输出已等于逐 prefix 的总体最优分布。共享参数、梯度裁剪、有限 batch 与有限 inner 都进入 e_k；若梯度采样规则改变了总体目标，e_k 还包含持续的目标偏差。

同时冻结 rollout 采样测度、anchor log-probability、reward 和其 KL center，才形成前两章的固定 inner 子问题。只更新 anchor 参数而保留上一轮的 log-probability 或 center，会形成不一致的子问题。下一轮必须在同一同步边界上更新这些量，或者把过期误差显式计入本章的递推。

分布空间的可解性与参数空间的可实现性分开检查。逐 prefix 自由分布能同时实现所有 Gibbs target；有限容量的共享模型通常只能逼近它们。本章的精确收敛结论适用于前一种模型，扰动定理为后一种模型提供条件性结论，前提是实际输出误差得到测量或上界。

4.5 Soft sync 的耦合动力学

若 anchor 使用指数滑动平均（exponential moving average，EMA），其概率空间理想化更新率记为 ζ（第三章的 ρ 专用于采样分布）。令

$$\pi_{k+1} = (1 - \zeta)\pi_k + \zeta\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。对 PMD-Part、BPO 和 MDPO，精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \pi_k^{1-\eta}\pi_T^{\eta}.$$

在固定 prefix 上令 $q = \pi_k$、$t = \pi_T$、$z = \log(q/t)$，假设 $\max_a |z_a| \le \varepsilon$，$\eta$ 固定且 inner 精确求解。归一化 $\mathbb{E}_t e^z = 1$ 的 Taylor 展开给出

$$\mathbb{E}_t z = -\frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3), \qquad \kappa = \mathbb{E}_t[e^z z] = \frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

因此 OPD 的混合配分函数满足

$$\log Z_\eta = \log \mathbb{E}_t e^{(1-\eta)z} = -\frac{\eta(1-\eta)}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

对于 Gibbs 更新，$\log(p^\star/t) = (1-\eta)z - \log Z_\eta$，一阶项为 $(1-\eta)z$。

PMD-Mean 的精确更新使用 Lambert-W target。由式 (4.13)，

$$0 \le \lambda \le \eta\kappa + \log Z_\eta = \frac{\eta^2}{2}\mathbb{E}_t z^2 + O(\varepsilon^3) = O(\varepsilon^2).$$

又因 $G = \eta(-z + \kappa) = O(\varepsilon)$，有 $W_0(\lambda e^G) = O(\varepsilon^2)$。故 Mean 也满足

$$\log(p^\star/t) = z + G - W_0(\lambda e^G) = (1-\eta)z + O(\varepsilon^2).$$

两类精确 inner 的概率空间混合 $q_{\mathrm{new}} = (1-\zeta)q + \zeta p^\star$，其中 $\zeta \in (0,1]$，均满足

$$\begin{aligned} q_{\mathrm{new}}/t &= (1-\zeta)e^z + \zeta e^{(1-\eta)z+O(\varepsilon^2)} \\ &= 1 + (1-\zeta\eta)z + O(\varepsilon^2), \\ \log(q_{\mathrm{new}}/t) &= (1-\zeta\eta)z + O(\varepsilon^2). \end{aligned}$$

这是 teacher 附近的局部展开。Mean 的精确全局递推仍由 Lambert-W 决定。较小的 ζ 减缓 anchor 漂移和局部 teacher tracking；有限 inner 或参数 EMA 还需要加入相应误差项。

4.6 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 d_k 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，d_{k+1} 改变，必须额外记录 coverage drift：

$$\varepsilon_k^{\mathrm{visit}} = \mathrm{TV}(d_{k+1}, d_k).$$

若 token loss 在所有 history 上有上界 C，则访问测度改变使目标值的期望变化至多 $2C\varepsilon_k^{\mathrm{visit}}$；若要控制梯度的期望变化，需另行假设逐 prefix 梯度向量的范数不超过 C_g，此时界为 $2C_g\varepsilon_k^{\mathrm{visit}}$。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

4.7 Hard sync 的有限词表数值核验

本节用完全可求解的 categorical 子问题核验前述动力学。实验程序为 `experiments/toy/hard_sync_audit.py`，结果保存在 `results/hard-sync-audit/`。所有计算使用 float64，随机种子为 20261010。这是固定 prefix 下的分布空间实验；其证据范围是精确更新与受控输出扰动，LLM 的参数共享、随机梯度和 rollout 变化需要分别测量。

4.7.1 实验问题与可证伪的判据

实验在运行前固定以下判据。

1. Gibbs 的跨度递推与三点 KL 恒等式应在数值误差内成立。词表大小取 $2, 4, 8$，每个大小生成 12 组独立正分布，步长取 $0.2, 0.8, 1, 1.2, 1.8, 2, 2.2$，共检查 252 个更新。绝对残差阈值取 10^{-12}。
2. 独立 SciPy Lambert-W 求解器与仓库 `token_inner.mean_target` 的 36 组输出逐坐标差不超过 10^{-12}。各步长的 Mean KKT 残差与归一化残差也不超过 10^{-12}。这同时检查理论更新与参考实现的对应关系。
3. 固定 $t = (0.2, 0.3, 0.5)$、$z = (-1, 0.2, 0.8)$，令 $q_\epsilon \propto t\exp(\epsilon z)$。扫描 $\epsilon = 0.4, 0.2, 0.1, 0.05, 0.02, 0.01$，Mean 在 $\eta = 1$ 时的 KL 三次比值应趋于一；最小 ϵ 的相对偏差阈值为 2%。
4. 同一 teacher 下，从 $q_0 \propto t\exp(0.2z)$ 出发，运行 $\eta = 2$ 的 10000 轮精确更新。Gibbs 应保持二周期，Mean 的 $k\,\mathrm{KL}(\pi_k\|t)$ 应接近 $1/16$；最终绝对偏差阈值为 0.004。
5. 输出噪声和 reward 噪声分别按式 (4.36) 注入。用 20000 条独立路径、240 步以及 $\eta = 0.2, 0.5, 1, 1.5, 1.8$，比较 teacher 加权二阶矩的样本均值和精确有限时间预测。每个均值须落在预测值的五个 Monte Carlo 标准误差以内。

4.7.2 数值稳定性与局部阶数

KL三次收敛会迅速产生接近机器精度的 KL。直接计算 $\sum_a p_a \log(p_a/t_a)$ 会把一阶正负项相消，影响三次比值。令 $d_a = p_a/t_a - 1$，归一化给出 $\sum_a t_a d_a = 0$，因此改写为

$$\mathrm{KL}(p\|t) = \sum_a t_a\{(1+d_a)\log(1+d_a) - d_a\}.$$

当 $|d_a| < 10^{-3}$ 时，程序使用

$$(1+d)\log(1+d) - d = \sum_{n=2}^{9} \frac{(-1)^n d^n}{n(n-1)} + O(d^{10}).$$

这保留局部 KL 的二阶首项。Mean 归一化根也用 $\mathbb{E}_q \operatorname{expm1}(G - W_0(\lambda e^G)) = 0$ 求解，避免两个接近一的数相减。求根器同时记录 KKT 残差。

本方向的 teacher 方差与跨度为

$$\operatorname{Var}_t(z) = 0.4644, \qquad \operatorname{osc} z = 1.8,$$

所以理论预测

$$\frac{b(p^\star, t)}{b(q_\epsilon, t)^3} \to \frac{0.4644}{2 \cdot 1.8^2} = 0.071666\ldots.$$

逐点数值与 KL 三次比值保存在 `cubic.csv`；它们检验乘子的二阶修正，而非仅检验一次线性化。

预设的各项数值判据均通过。表 4.1 汇总残差与局部、边界常数；这里的实测值来自上述固定配置。

表 4.1: 精确 hard-sync 更新的数值核验。

项目	实测结果
Gibbs 三点恒等式最大绝对残差	1.78×10^{-15}
Mean 独立求解与参考实现最大坐标差	2.78×10^{-16}
Mean KKT 与归一化最大残差	3.55×10^{-15}
$\epsilon = 0.01$ 的 KL 三次比值	1.011557，极限为 1
同一点的跨度三次比值	0.071591，极限为 0.071667
$\eta = 2$、$k = 10000$ 的 Mean k KL	0.062303，极限为 0.0625

4.7.3 边界阻尼与噪声位置

图 4.1 左侧比较同一初值下的边界步长：Gibbs 的两周期与 Mean 的缓慢衰减清楚分离。虚线是独立推导的 $1/(16k)$，并未用实验数据拟合。

右侧从零误差出发，先生成独立 $N(0, \sigma^2 I)$ 向量，再减去其 teacher 均值，取 $\sigma = 0.01$。该居中噪声满足

$$\mathbb{E}\|\xi\|_t^2 = \sigma^2 \left(1 - \sum_a t_a^2\right).$$

对固定输出噪声，有限时间精确预测为

$$\mathbb{E}\|y_K\|_t^2 = \sigma^2 \left(1 - \sum_a t_a^2\right) \frac{1 - (1-\eta)^{2K}}{\eta(2-\eta)}.$$

对于 reward 噪声，再乘 η^2。图中误差条是均值的 1.96 个标准误差，虚线是上述预测。两个噪声模型呈现不同步长趋势，与输入位置的理论分析一致。

实验中的浮点求根和有限时间误差不替代证明。相反，精确恒等式、局部阶数、边界常数与随机二阶矩分别给出四类独立的数值约束，使实现错误能被具体定位。配置、源码版本、脚本校验和及最大残差记录在 `metadata.json`，完整复现命令与逐项结果见实验报告。

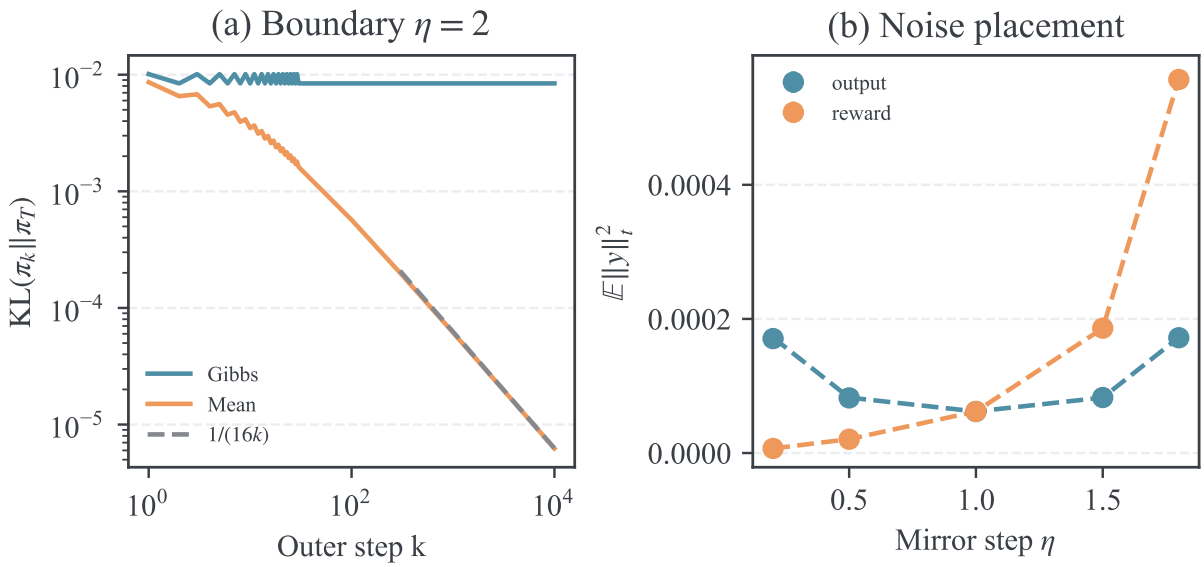


图 4.1: 固定三元词表下的 hard-sync 审计。左：$\eta = 2$ 的精确 Gibbs 与 Mean teacher KL；右：固定输出噪声和固定 reward 噪声的 teacher 加权二阶矩。点和实线来自数值更新，虚线来自独立理论预测。

第五章 可枚举 Token 实验与实现边界

5.1 实验设置

实验脚本位于 `experiments/toy/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\pi_0 = (0.62, 0.23, 0.10, 0.05), \qquad \pi_T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略 $\pi_{0,0} = (0.70, 0.15, 0.10, 0.05)$ 开始，使用 400 步、学习率 0.15，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。为核对离开 anchor 后的梯度，这个固定 anchor 实验采用偏离 anchor 的初始化。正式 OPD outer–inner 算法从 $\pi_{k,0} = \pi_k$ 开始。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整词表下的中心化 residual 平方损失；MDPO 使用 exact categorical Fisher preconditioner。

5.1.1 画图实验的输入数据与三层数据集

本项目的图不能直接从一批混合的 rollout 日志中生成。每一张图都必须注明它使用的是哪一个策略、哪一个 prefix 测度以及哪一种词表访问方式。实验输入按由易到难分为三层。

第一层是可枚举的 categorical oracle。固定一个 prefix s，直接生成 anchor、teacher 和 student 的完整 logits，并通过 softmax 得到 $\pi_k(\cdot \mid s)$、$\pi_T(\cdot \mid s)$ 和 $\pi_{k,n}(\cdot \mid s)$。anchor 可以用随机 logits 加温度生成，teacher 可以通过独立随机 logits 或与 anchor 具有指定 KL 的混合分布生成。每个 prefix 保存完整的概率向量、两个 log-prob 向量以及 exact

$$\mathcal{K}_k^T(s) = \mathrm{KL}(\pi_k \| \pi_T), \qquad \mathcal{K}_{k,n}^S(s) = \mathrm{KL}(\pi_k \| \pi_{k,n}),$$

和

$$\log Z_k(s) = \log \sum_{v \in \mathcal{V}} \exp\big((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\big).$$

这一层不需要文本数据，也不运行模型 rollout；它提供所有估计量的 ground truth，专门用于画 bias、variance、均方误差和梯度误差曲线。

第二层是真实模型产生的 prefix 数据，但仍然冻结 outer step。先选定一个不参与训练的 prompt 文件 $\mathcal{X} = \{x_i\}_{i=1}^{N_x}$，每个 prompt 只作为输入，不需要人工答案或 reward label。用当前 anchor π_k 对每个 prompt 采样若干条 response，得到

$$s_{i,t} = (x_i, y_{i,<t}), \qquad a_{i,t} = y_{i,t}, \qquad a_{i,t} \sim \pi_k(\cdot \mid s_{i,t}).$$

保存 prompt id、token ids、attention mask、response mask、prefix 长度、anchor 对采样 token 的 log-prob，以及 teacher 对同一 token 的 log-prob。KL 或 $\log Z_k$ 的估计不应把不同 prefix 混在一起：同一 prefix 的多个 next-token 样本才能用于估计条件期望；不同 prefix 只能在外层按照经验访问测度 $\widehat{d}_k$ 聚合。

第三层才是完整的 OPD outer loop。第 k 轮只使用 π_k 生成 rollout，缓存该轮的 prefix 集合和 anchor/teacher 的 token-level log-prob；随后固定这些数据运行 N 个 inner steps，得到 $\pi_{k,N}$，再执行 hard sync 或 soft sync 得到 π_{k+1}。同步后必须重新 rollout，不能把上一轮的 prefix 和旧 anchor log-prob 继续当作新一轮数据。这样得到的序列

$$\{(\widehat{d}_k, \pi_k, \pi_{k,n}, \pi_T) : k = 0, \dots, K_{\mathrm{out}} - 1,\ n = 0, \dots, N\}$$

才是 outer 动力学图的输入。

图中以 J 表示保留的头部 token 数量。对每个固定 prefix，同时记录 full-vocabulary oracle、sampled-token、top-J 三条估计路径。建议先画以下三组图：

1. 在第一层 oracle 上，以 J 或同 prefix 样本数 m 为横轴，画 $\mathcal{K}_k^T$、$\mathcal{K}_{k,n}^S$ 和 $\log Z_k$ 的 bias、standard deviation、RMSE；

2. 在第二层真实 prefix 上，以 inner step n 为横轴，画 exact-oracle 可用部分的 KL、sampled estimator 的方差、anchor–student 的 χ^2 或有效样本量；
3. 在第三层 outer loop 上，以 k 为横轴，分别画 teacher KL、mirror-target KL、policy–anchor KL、token-level loss、rollout reward，以及 hard sync 与 soft sync 的差异。

第一层的分布是唯一可以逐 prefix 得到无偏误差标签的地方，因此必须先完成。第二层用于回答估计量在真实语言模型的长尾词表上是否仍然稳定。第三层只在前两层通过后运行，否则一条性能曲线无法判断变化来自 OPD 本身、prefix 分布漂移、KL 估计偏差还是 inner 优化没有收敛。

5.2 结果

表 5.1 区分有限步优化误差、到 Gibbs 分布的距离和总体目标差异。方法 M 的自身最优分布为 $\pi_0^{\star,M}$，400 步后的 student 为 $\pi_{0,N}$，$N = 400$。PMD-Mean 的最优分布由 Lambert-W 归一化方程求得，其余三种方法的最优分布为 $\pi_0^{\star,\mathrm{Gibbs}}$。定义

$$
\begin{aligned}
e_M^{\mathrm{opt}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,M}),\\
e_M^{\mathrm{Gibbs}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,\mathrm{Gibbs}}),\\
e_M^{\mathrm{target}} &= \mathrm{TV}(\pi_0^{\star,M}, \pi_0^{\star,\mathrm{Gibbs}}).
\end{aligned}
$$

第一项衡量有限步优化误差，第三项衡量方法总体目标的差异。

表 5.1: 固定测度 token inner 的可枚举实验，400 步后结果。

η	方法	e_M^{opt}	e_M^{Gibbs}	e_M^{target}
0.25	PMD-Part	1.11e-03	1.11e-03	0.00e+00
0.25	PMD-Mean	6.81e-04	9.26e-03	9.12e-03
0.25	BPO	1.96e-08	1.96e-08	0.00e+00
0.25	MDPO	8.33e-17	8.33e-17	0.00e+00
0.50	PMD-Part	2.65e-03	2.65e-03	0.00e+00
0.50	PMD-Mean	3.58e-04	6.86e-02	6.85e-02
0.50	BPO	1.23e-04	1.23e-04	0.00e+00
0.50	MDPO	1.25e-16	1.25e-16	0.00e+00
0.80	PMD-Part	2.97e-03	2.97e-03	0.00e+00
0.80	PMD-Mean	4.11e-05	1.90e-01	1.90e-01
0.80	BPO	4.53e-03	4.53e-03	0.00e+00
0.80	MDPO	2.78e-16	2.78e-16	0.00e+00

PMD-Mean 到自身最优解的误差随优化下降，但到 Gibbs 解的距离保留了结构性差异。例如 $\eta = 0.8$ 时，其有限步优化误差为 4.11×10^{-5}，两个总体最优解的距离为 0.1904。继续优化只能消除前者。

BPO 的最优解仍为 Gibbs 分布，但本实验的固定步长与 400 步预算下，$\eta = 0.8$ 时尚有 4.53×10^{-3} 的优化误差。MDPO 使用精确 categorical Fisher 自然梯度，在该四动作问题上达到浮点精度。该结果比较的是指定 optimizer 与预算下的误差，不构成一般模型上的收敛速度排序。

η 同时影响 Gibbs target、Mean 的 Lambert-W target 以及各损失的梯度尺度。Algorithm 5 中 BPO 的 η^{-1} 已显式进入梯度权重，实验使用相同学习率时也保留这个尺度，不能把缩放后的方向当作实际梯度。

5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，核对 Mean 的 Lambert-W 归一化、KKT 条件与最优点梯度；核对 Mean/BPO 的损失及梯度差异恒等式；

2. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
3. 对随机 p, q，用大量样本检查 K4 value 与 exact KL$(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
4. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
5. 检查固定 anchor 采样的 importance correction 在 p/q 接近一时无偏；
6. 人为改变 student 与 anchor 的偏离程度，测量 χ^2 与重要性加权估计方差；增加 inner steps 不保证二者单调上升；
7. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `toy_token_inner.py`（从仓库根用 `PYTHONPATH=src uv run --with torch python` 运行）生成，结果保存在 `results/toy/toy_token_inner.csv`。独立的 `tests/test_kl_estimators.py` 使用 200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 5.6×10^{-5}，gradient 的 ℓ_2 误差为 1.5×10^{-3}。

`tests/test_mean_bpo.py` 进一步核对 Mean 与 BPO 的解析梯度、有限差分、最优点和有限样本尺度修正；它与 toy 实验分别检验推导正确性和有限步优化行为。

5.4 真实语言模型上的四种 Top-J 对照

为了把上一章的四个数学对象放回 OPD 场景，我们使用 GSM8K test 的全部 1,319 个 prompt。Student 为 Qwen3-1.7B，Teacher 为 Qwen3-4B，温度固定为 1.0；每个 prompt 生成一条完整 student rollout。对 rollout 的每个 prefix，打分阶段计算 student 与 teacher 的完整词表分布，随后只保存汇总量和审计样本。打分采用 NF4 权重量化、bf16 计算，因此这里的 full-vocabulary KL 是该量化模型对的 oracle。生成采用 bf16 vLLM，其 sampled token 来自与 NF4 打分略有不同的 proposal；EMA 的理论方差严格按 NF4 student 分布计算，观测误差另行报告。总计得到 350,166 个 prefix。实验元数据、逐 J 汇总和绘图脚本分别位于 `results/qwen3_gsm8k_pair_kl/metadata.json`、`results/qwen3_gsm8k_pair_kl/kl_summary_by_k.csv` 和 `experiments/plotting/plot_pair_kl.py`。

令 S_J 为 student 概率的 top-J 支持集。表 5.2 中的 bias 和 RMSE 都相对于同一 prefix 上的完整

$$\mathcal{K}^{\text{full}}(s) = \mathrm{KL}\big(\pi_{k,n}(\cdot \mid s) \| \pi_T(\cdot \mid s)\big)$$

计算。Truncated、Normalized 和 Tail-Aware 的条件采样方差恒为零；EMA Top-J 的 variance 是一个尾部 sampled token 修正的理论条件方差。四种方法使用完全相同的 prefix 和 student 支持集，没有额外增加每个 prefix 的采样数。Tail-Aware 尾部质量在 float64 下直接累加，避免头部质量接近一时用 $1 - P_J$ 相减丢失精度。审计样本同时保存 teacher 在该支持集上的质量 Q_J 与 Tail-Aware 值。

表 5.2: Qwen3-1.7B student 与 Qwen3-4B teacher 在 GSM8K rollout prefix 上的 Top-J KL 统计。EMA 的 RMSE 是理论 sampled-tail RMSE；Normalized 的 $J = 0$ 未定义。

J	P_J	$\text{bias}_{\text{trunc}}$	$\text{RMSE}_{\text{trunc}}$	RMSE_{EMA}	$\text{bias}_{\text{norm}}$	$\text{RMSE}_{\text{norm}}$
0	0	-0.26932	1.03968	0.80948	–	–
1	0.94208	-0.07672	0.39307	0.68557	-0.26932	1.03968
2	0.98676	-0.02187	0.15337	0.40189	-0.08392	0.54660
4	0.99747	-0.00465	0.04761	0.18864	-0.02629	0.28804
8	0.99949	-0.00094	0.01416	0.08308	-0.00874	0.15007
16	0.99988	-0.00023	0.00488	0.03959	-0.00310	0.08367
32	0.99996	-0.00008	0.00217	0.02249	-0.00127	0.05438

结果体现了四种定义之间的结构性差异。首先，student 的 top-J 质量在 $J = 4$ 时已经达到 0.99747，在 $J = 32$ 时达到 0.99996，所以截断项的偏差和 RMSE 很快下降。其次，EMA Top-J 在任何 J 上都保持理论无偏，但只要尾部 log-ratio 的二阶矩仍然较大，sampled correction 就会带来明显方差；在 $J = 32$ 时它的理论 RMSE 仍为 0.02249，高于截断项的 0.00217。这不是无偏性失效，而是典型的 bias–variance trade-off。

Normalized Top-J 的行为不同。$J = 1$ 时两边都是同一个 point mass，局部 KL 几乎为零，因此相对于完整 KL 的 bias 为 -0.26932。随着 J 增大，条件分布逐渐包含更多质量，RMSE 从 1.03968 降至 0.05438；但在 $J = 32$ 时

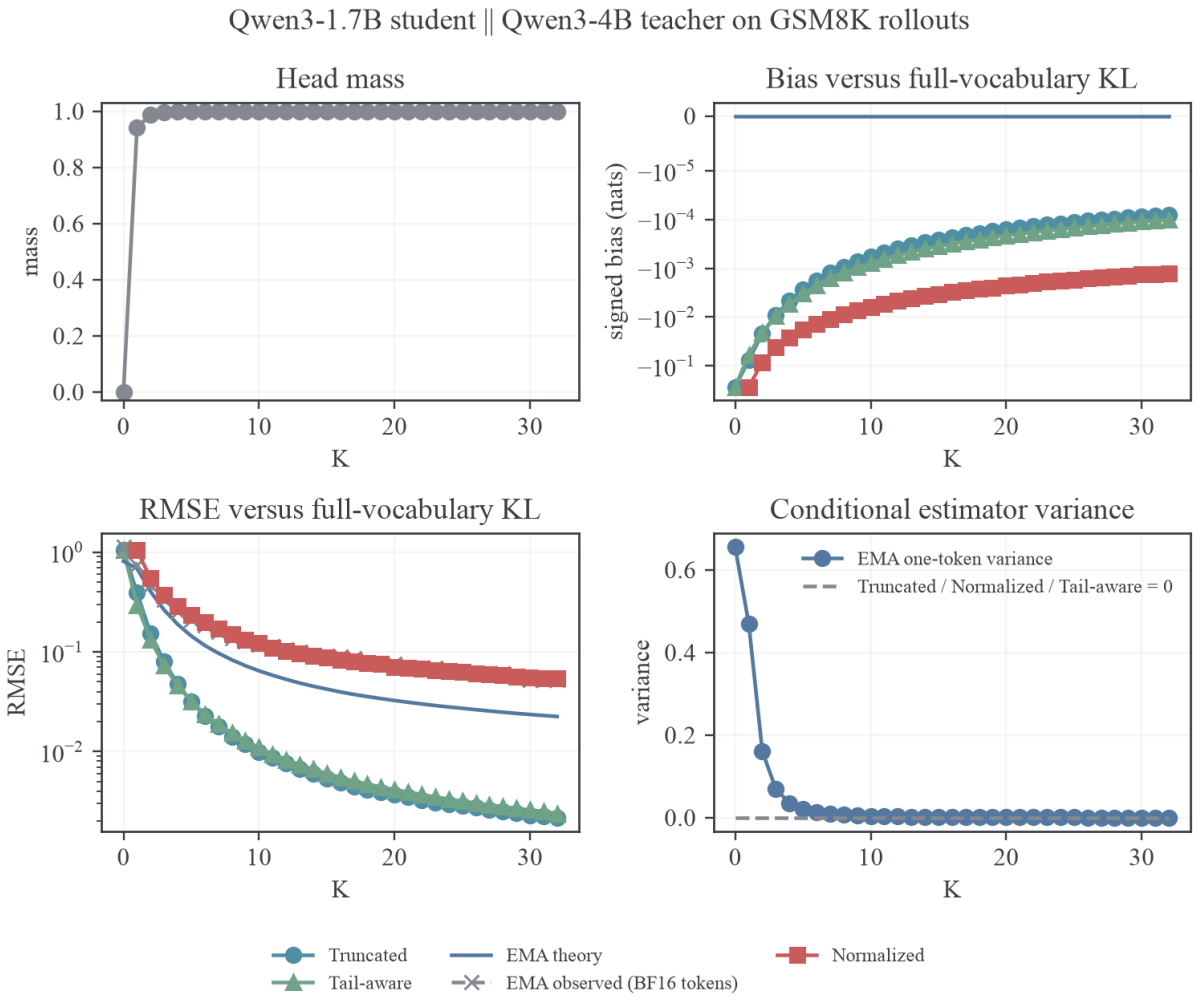


图 5.1: 真实 GSM8K rollout 上四种 Top-J KL 的误差曲线。bias 保留正负号；variance 是固定 prefix 的条件采样方差，不是不同 prefix 之间的数值方差。EMA observed 使用 bf16 rollout token，与 NF4 打分分布的理论曲线分开。

仍明显高于截断项。这说明归一化修复的是局部目标的概率尺度，而不是尾部 token-wise KL。它适合作为 dense local OPD 目标，却不能被解释为完整 KL 的高精度估计量。

Tail-Aware 的全量结果见表 5.3。其 RMSE 随 J 单调下降，符合上一章的支持集细化定理。在 $J = 1, 2, 4$ 时，其 RMSE 小于 Truncated；在 $J = 8, 16, 32$ 时，Truncated 略小。这正对应尾部质量项与尾部形状项的抵消：Tail-Aware 恢复质量项后，剩下的误差严格为非正的尾部形状偏差，而 Truncated 的两个遗漏项可以部分相互抵消。这个标量 RMSE 排序不等于训练稳定性的排序，也不能作为四种 OPD 训练方法最终性能的结论。

这组实验不能支持“所有情况下都应该使用 normalized Top-J”这一结论。它支持更精确的选择规则：当我们需要在有限支持集上构造稳定的多 token 蒸馏 reward 时使用 $\mathcal{K}_J^{\mathrm{norm}}$；当我们需要完整 vanilla OPD KL 的估计时使用 EMA Top-J；当我们希望保留尾部总质量、又不承受 sampled correction 的方差时使用 Tail-Aware Top-J；Truncated Top-J 则作为低方差、有明确尾部偏差的基线。

表 5.3: 同一批 350,166 个 prefix 上补全的 Tail-Aware 结果。条件采样方差在所有 J 上均为零。

J	mean Tail-Aware KL	bias	RMSE
0	0	-0.269321	1.039683
1	0.209759	-0.059561	0.295078
2	0.248414	-0.020907	0.131407
4	0.263978	-0.005343	0.045886
8	0.268091	-0.001230	0.015303
16	0.269006	-0.000315	0.005493
32	0.269220	-0.000101	0.002391

参考资料

PMD-Mean的 reward 中心化目标与 Lambert-W 解依据 arXiv:2602.05933 中的 $\mathcal{L}_{\text{mean}}$ 定义与附录约束优化推导。本文 KL 估计量的记号与 K3^{++}、K4、K5、Top-J 估计量来自 arXiv:2602.04417；One-Shot-OPD 的实现审计见 `upstream/One-Shot-OPD/`。