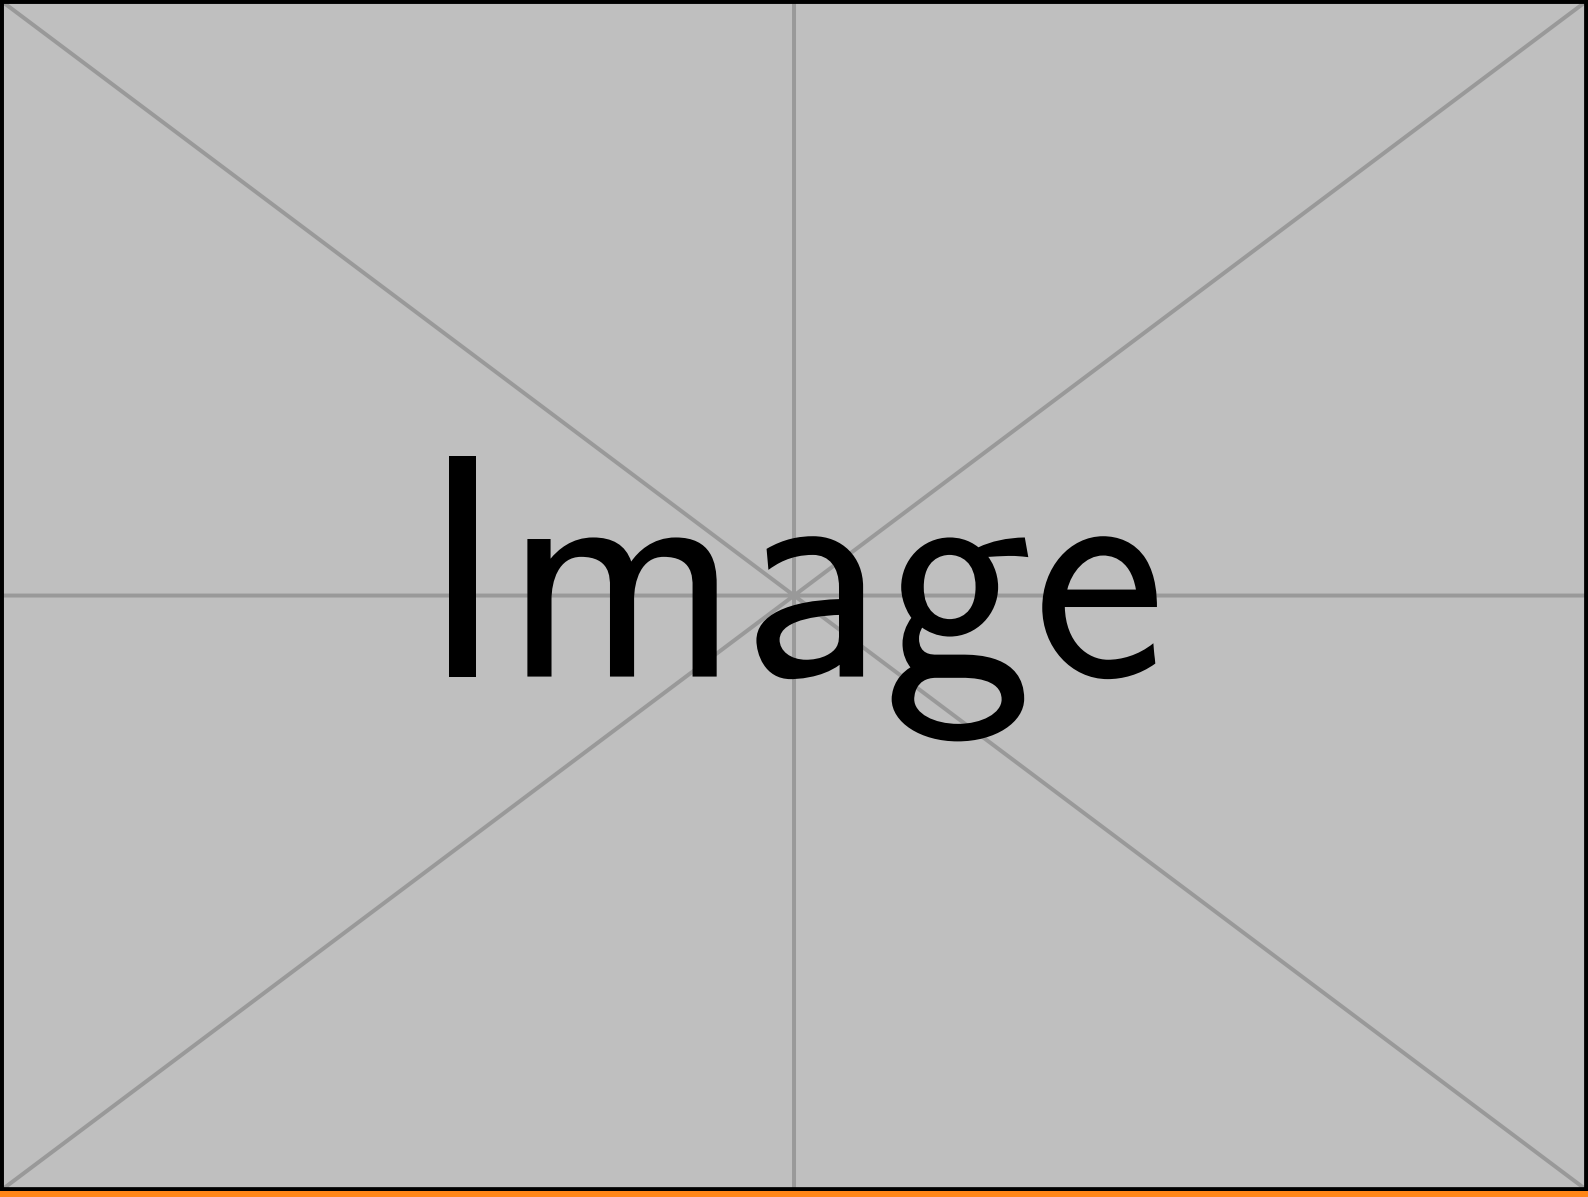


固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

目录

第一章 固定测度的 Token 级优化问题

1.1 外层同步与内层对象

词表记为 $\mathcal{V}$，prompt为 x，生成序列为 $y_{1:H}$，第 t 个 token 之前的 prefix 为 $s_t = (x, y_{<t})$。第 k 轮 outer 开始时的冻结 anchor 为 π_k，本轮第 n 次 inner 更新的 student 为

$$\pi_{k,n}(a \mid s) = \pi_{\theta_{k,n}}(a \mid s), \qquad \pi_{k,0} = \pi_k. \tag{1.1}$$

教师统一记为 π_T，在本轮 inner 内冻结。d_k 表示由 π_k rollout 诱导的 prefix 访问测度，$\widehat{d}_k$ 表示当前 rollout batch 的经验测度。inner 固定 prefix batch、anchor 和教师，只更新 student 参数。

全篇使用同一组 log-ratio 和 KL 记号：

$$U_{k,n}(s,a) \coloneqq \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}, \tag{1.2}$$

$$r_k(s,a) \coloneqq \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}, \tag{1.3}$$

$$\mathcal{K}_k^T(s) \coloneqq \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s)), \tag{1.4}$$

$$\mathcal{K}_{k,n}^S(s) \coloneqq \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_{k,n}(\cdot \mid s)). \tag{1.5}$$

因此 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}_k^T(s)$，$\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}_{k,n}^S(s)$。前者是冻结 teacher reward 的均值，后者随 student 更新变化。通用 mirror 问题中的信号记为 f，其冻结中心化 target 为 $G_k = \eta(f - \mathbb{E}_{\pi_k}[f \mid s])$。OPD 实例化时取 $f = r_k$，因此

$$G_k(s,a) \coloneqq \eta\big(r_k(s,a) + \mathcal{K}_k^T(s)\big), \qquad \mathbb{E}_{\pi_k}[G_k \mid s] = 0. \tag{1.6}$$

score 向量记为 $\psi_{k,n}(s,a) = \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$，其 anchor 条件均值为 $\bar{\psi}_{k,n}(s) = \mathbb{E}_{\pi_k}[\psi_{k,n} \mid s]$。

镜像系数为 $\eta > 0$，inner 学习率为 $\alpha_{k,n}$。outer 总步数为 K_{out}，每轮 inner 步数为 N，rollout batch 大小为 B，同一 prefix 的辅助 action 样本数为 m，保留的头部 token 数为 J。展开截断阶数用 L，避免与头部大小混用。所有损失统一最小化，算法使用其梯度 $g_{k,n} = \nabla_{\theta_{k,n}} \mathcal{L}$ 执行下降。

同步在 inner 结束后进行。hard sync 取 $\pi_{k+1} = \pi_{k,N}$；概率空间的 soft sync 取

$$\pi_{k+1} = (1-\rho)\pi_k + \rho \pi_{k,N}, \qquad \rho \in (0,1]. \tag{1.7}$$

参数 EMA 是这个概率混合映射的实现近似，需要另行说明。$\lambda_k(s)$ 只表示 PMD-Mean 的归一化乘子，γ 表示自然梯度阻尼。student/anchor importance ratio 记为 $\omega_{k,n} = \pi_{k,n}/\pi_k$，K4 的 score surrogate 记为 $c_{k,n} = \pi_{k,n}/\operatorname{sg}(\pi_{k,n})$，其中 sg 表示停止梯度。

我们研究的 inner 子问题是

$$\max_{p \in \Delta(\mathcal{V})} \mathcal{J}_{k,s}(p) = \mathbb{E}_{a \sim p}[r_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p \| \pi_k), \qquad \eta > 0. \tag{1.8}$$

这里的 p 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 s 不随 inner 更新；它不意味着优化变量 p 必须等于采样分布 π_k。

1.2 原始 mirror 子问题的 Gibbs 解

令

$$Z_k(s) = \sum_{a \in \mathcal{V}} \pi_k(a \mid s) \exp(\eta r_k(s,a)).$$

由于 $r_k = \log \pi_T - \log \pi_k$，有

$$Z_k(s) = \sum_a \pi_k(a \mid s)^{1-\eta} \pi_T(a \mid s)^{\eta}. \tag{1.9}$$

定理 1.1 (Token mirror target)

若有限词表上 $\pi_k(a \mid s) > 0$ 且 $\pi_T(a \mid s) > 0$ 对每个 action 成立，则式 (1.8) 的唯一最大点为

$$\pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \frac{\pi_k(a \mid s)\exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\pi_k(a \mid s)^{1-\eta}\pi_T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.10}$$

并且对任意 p，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}). \tag{1.11}$$

♡

证明 由式 (1.10)，

$$\log \pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \log \pi_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\begin{aligned}\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}) &= \sum_a p(a \mid s)\left[\log\frac{p(a \mid s)}{\pi_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s)\right] \\ &= \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[r_k] + \log Z_k(s).\end{aligned}$$

移项得到式 (1.11)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时为零，所以最大点唯一。 □

推论 1.1 (几何插值与极限)

当 $\eta \to 0^+$ 时 $\pi_k^{\star,\mathrm{Gibbs}} \to \pi_k$；当 $\eta = 1$ 时 $\pi_k^{\star,\mathrm{Gibbs}} = \pi_T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log \pi_k^{\star,\mathrm{Gibbs}} = (1-\eta)\log \pi_k + \eta \log \pi_T - \log Z_k.$$

因此 η 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

♡

1.3 Reward 中心化与回归残差

定义 $\bar{r}_k(s) = \mathbb{E}_{a\sim\pi_k}[r_k(s,a)] = -\mathcal{K}_k^T(s)$。将 reward 换成 $r_k - \bar{r}_k$ 后，配分函数为

$$\mathbb{E}_{\pi_k}[e^{\eta(r_k-\bar{r}_k)}] = e^{-\eta\bar{r}_k}Z_k.$$

分子和配分函数同乘一个 action 无关的常数，原始 mirror 问题的 Gibbs 解不变。下面的平方回归需要区分完整配分函数与均值近似。

三个 residual 全部采用 student 减 target 的方向：

$$R_{k,n}^{\mathrm{Part}}(s,a) \coloneqq U_{k,n}(s,a) - \eta r_k(s,a) + \log Z_k(s), \tag{1.12}$$

$$R_{k,n}^{\mathrm{Mean}}(s,a) \coloneqq U_{k,n}(s,a) - G_k(s,a), \tag{1.13}$$

$$R_{k,n}^{\mathrm{BPO}}(s,a) \coloneqq U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}_{k,n}^S(s). \tag{1.14}$$

PMD-Part 的零残差对应 $\pi_{k,n} = \pi_k^{\star,\mathrm{Gibbs}}$。PMD-Mean 以 $\eta\bar{r}_k$ 近似 $\log Z_k$，仅中心化 reward。对非恒定 reward，由严格 Jensen 不等式有 $\mathbb{E}_{\pi_k}[e^{G_k}] > 1$，所以拟合值 $U = G_k$ 不满足概率归一化，最优残差不能为零。其总体最优分布记为 $\pi_k^{\star,\mathrm{Mean}}$，由第二章的 Lambert-$W$ 解确定。

BPO 则中心化完整的 student–target residual。其 residual 均值为零，而 Mean 的 residual 均值为 $-\mathcal{K}_{k,n}^S$。这些定义直接区分两个目标，无需额外改变 residual 符号。

1.4 参数化策略的投影

实际神经网络只能表示参数化策略族。固定 prefix 测度 d_k 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{Part}}(\theta_{k,n}) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{1.15}$$

若模型在每个 history 上可以实现式 (1.10)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章沿用第一章的 outer–inner 记号：π_k 是冻结 anchor，$\pi_{k,n}$ 是当前 student，π_T 是 teacher，d_k 是冻结 prefix 访问测度。所有梯度均在 $\theta = \theta_{k,n}$ 处计算。以下先对一般冻结信号 f 推导，再取 OPD 信号 $f = r_k$。

2.1 共同的 mirror 子问题与精确解

定义 2.1 (Token-level mirror 子问题)

给定固定历史 s、token 信号 $f(s,a)$ 和 anchor π_k，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.1}$$

这里要求 $\eta > 0$；$\eta = 0$ 仅通过极限定义恒等 mirror 映射，不能直接代入含 $1/\eta$ 的训练损失。镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。同时定义配分函数

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\Big(p\Big\|\pi_k^{\star,\mathrm{Gibbs}}(\cdot \mid s)\Big). \tag{2.4}$$

证明 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时取零，因此最优解唯一。

定义 2.2 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

命题 2.1 (优势函数的 anchor 条件均值)

若 $f(s,a) = A^{\pi_k}(s,a)$，则对每个满足 $\pi_k(\cdot \mid s)$ 定义的历史，

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}[f(s,a) \mid s] = 0. \tag{2.5}$$

对于一般 OPD log-ratio 或 teacher score，条件均值需要计算或估计；PMD-Mean 与 BPO 使用相应的中心化 target。

证明 由 $A^{\pi_k}(s,a) = Q^{\pi_k}(s,a) - V^{\pi_k}(s)$ 以及 $V^{\pi_k}(s) = \mathbb{E}_{a\sim\pi_k}[Q^{\pi_k}(s,a) \mid s]$，有

$$\begin{aligned}\mathbb{E}_{\pi_k}[A^{\pi_k}(s,a) \mid s] &= \mathbb{E}_{\pi_k}[Q^{\pi_k}(s,a) \mid s] - V^{\pi_k}(s) \\ &= V^{\pi_k}(s) - V^{\pi_k}(s) = 0.\end{aligned}$$

命题 2.2 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.1) 的最优分布。

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是孤立的分布结论，而是一条可以被 inner optimizer 直接拟合的逐 token 方程。下面先把这条方程、平方损失和 BPO 的中心化残差逐步写出，再进入四种算法的实现。

2.2.1 镜像最优性方程与训练测度

把式(2.3) 移项，得到

$$\log \frac{\pi_k^{\star,\mathrm{Gibbs}}(a \mid s)}{\pi_k(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.6}$$

在参数化 inner 中，左侧由 $\pi_{k,n}$ 近似。因此定义镜像方程残差

$$R_{k,n}^{\mathrm{Part}}(s,a) \coloneqq \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s). \tag{2.7}$$

精确 mirror 解的条件是 $R_{k,n}^{\mathrm{Part}}(s,a) = 0$ 对所有有正概率的 (s,a) 成立。

为什么训练测度是 π_k 而不是 $\pi_{k,n}$？在第 k 个 outer step，rollout 已由冻结的 π_k 产生；我们要解决的是固定 anchor 的 mirror 子问题，而不是在 inner 过程中不断改变积分测度。于是参数化投影定义为

$$\|R_{k,n}^{\mathrm{Part}}\|_k^2 \coloneqq \mathbb{E}_{s\sim d_k}\mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{2.8}$$

这也是 on-policy rollout 下可直接估计的投影几何。若改用行为测度 β_k 采样，必须乘以冻结的 importance weight $\pi_k(a \mid s)/\beta_k(a \mid s)$，否则求解的是 $L_2(d_k\beta_k)$ 投影。

2.2.2 PMD-Part 与 PMD-Mean：从方程到平方损失

PMD-Part直接最小化式(2.7) 的平方。将 student log-ratio 和冻结 target 展开，得到

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \mathrm{sg}(\log Z_f(s))\right]^2. \tag{2.9}$$

其中 sg 表示停止梯度；π_k、f 和 Z_f 在本轮 inner 中都冻结。因为

$$\nabla_\theta \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} = \nabla_\theta \log \pi_{k,n}(a \mid s),$$

其梯度为

$$\nabla_\theta\mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_k,\pi_k}\left[\mathrm{sg}\left(\log \frac{\pi_{k,n}}{\pi_k} - \eta f + \log Z_f\right)\nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.10}$$

这说明 PMD-Part 是 anchor 测度下对完整 mirror log-ratio 的 L_2 投影，而不是把一个 teacher label 当作普通的 supervised token label。

PMD-Mean 使用原论文的均值近似，而不是对 student log-ratio 做条件中心化。使用第一章定义的冻结 target $G_k(s,a) = \eta(f(s,a) - \bar{f}_k(s))$。将完整 target 中的 $\log Z_f(s)$ 用 $\eta\bar{f}_k(s)$ 近似，得到

$$\mathcal{L}_{\text{Mean}}(\theta) = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}\left[\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta\big(f(s,a) - \bar{f}_k(s)\big)\right]^2. \tag{2.11}$$

这里的 reward center 在整个 inner loop 冻结；损失中没有 $\mathrm{KL}(\pi_k\|\pi_{k,n})$。定义 $R^{\text{Mean}}_{k,n} = U_{k,n} - G_k$，直接求导得到

$$\nabla_\theta\mathcal{L}_{\text{Mean}} = \mathbb{E}_{d_k,\pi_k}\left[(U_{k,n} - G_k)\nabla_\theta\log\pi_{k,n}(a \mid s)\right]. \tag{2.12}$$

均值近似遗漏的归一化修正是

$$\log Z_f(s) - \eta\bar{f}_k(s) = \log\mathbb{E}_{\pi_k}[e^{G_k(s,\cdot)} \mid s] \geq 0.$$

非恒定信号对应严格正值，此时 G_k 不满足指数归一化约束。因此 PMD-Mean 即使具有完整函数类和无限样本，也不恢复原始 Gibbs 解；其受约束总体解见定理 2.2。若改为拟合 $U_{k,n} - \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - G_k$，得到的是后面的 BPO 中心化残差，已经改变了 PMD-Mean 的目标。

2.2.3 BPO：中心化最优性残差

BPO将镜像方程残差按冻结 anchor 条件中心化。配分函数项是 action-independent 常数，中心化后消失：

$$R^{\text{BPO}}_{k,n}(s,a) \coloneqq U_{k,n}(s,a) - \eta f(s,a) - \mathbb{E}_{\pi_k}[U_{k,n}(s,\cdot) - \eta f(s,\cdot) \mid s] \tag{2.13}$$

$$= U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}^S_{k,n}(s). \tag{2.14}$$

这里 $\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}^S_{k,n}$，所以 student KL 前是正号。OPD 中 $f = r_k$，故

$$R^{\text{BPO}}_{k,n}(s,a) = \log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^S_{k,n}(s) - \eta\left(\log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^T_k(s)\right). \tag{2.15}$$

BPO 最小化

$$\mathcal{L}_{\text{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R^{\text{BPO}}_{k,n})^2]. \tag{2.16}$$

使用第一章定义的 score $\psi_{k,n}$ 及其 anchor 均值 $\bar{\psi}_{k,n}$，保留 student KL 的导数得到

$$\nabla_\theta\mathcal{K}^S_{k,n} = -\bar{\psi}_{k,n}, \qquad \nabla_\theta R^{\text{BPO}}_{k,n} = \psi_{k,n} - \bar{\psi}_{k,n}.$$

因此精确梯度为

$$\nabla_\theta\mathcal{L}_{\text{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R^{\text{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n})] \tag{2.17}$$

$$= \mathbb{E}_{d_k,\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}^S_{k,n}}{\eta} - f + \bar{f}_k\right)\psi_{k,n}\right]. \tag{2.18}$$

第二行使用 $\mathbb{E}_{\pi_k}[R^{\text{BPO}}_{k,n} \mid s] = 0$，已把 η^{-1} 乘入权重。梯度下降使用上述梯度的负值。消失的是 residual 均值乘以 score 均值，score 的 anchor 期望 $\bar{\psi}_{k,n}$ 本身通常不为零。

2.2.4 MDPO：最小化原始 mirror objective 的负值

MDPO使用原 mirror objective 的负值作为损失，统一执行梯度下降：

$$\mathcal{L}_{\text{MDPO}}(\theta) = -\mathbb{E}_{s\sim d_k,a\sim\pi_{k,n}}[f(s,a)] + \frac{1}{\eta}\mathbb{E}_{s\sim d_k}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.19}$$

逐历史应用式 (2.4)，得到

$$\mathcal{L}_{\text{MDPO}}(\theta \mid s) = -\frac{1}{\eta}\log Z_f(s) + \frac{1}{\eta}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi^{\star,\text{Gibbs}}_k(\cdot \mid s)). \tag{2.20}$$

这里 KL 的左侧分布是当前 student，与 $\mathcal{K}^S_{k,n} = \mathrm{KL}(\pi_k\|\pi_{k,n})$ 的方向不同。

对 student 测度和 log-ratio 同时求导，有

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}} = \mathbb{E}_{d_k,\pi_{k,n}}\left[\left(\frac{U_{k,n}+1}{\eta} - f\right)\psi_{k,n}\right] \tag{2.21}$$

$$= \mathbb{E}_{d_k,\pi_{k,n}}\left[\mathrm{sg}\left(\frac{U_{k,n}}{\eta} - f\right)\psi_{k,n}\right]. \tag{2.22}$$

第二行使用 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n} \mid s] = 0$。其下降方向是 $-\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，无需把 η 吸收进 optimizer 步长。

命题 2.3 (平方回归的投影含义)

若 student 函数类不能表示式(2.6) 的右侧，PMD-Part 的精确 inner 解是镜像方程在函数类诱导的 $L_2(d_k\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 ν，投影也相应变为 $L_2(\nu\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。

证明 平方损失定义了可行 log-ratio 集合上的最小距离问题。对任意光滑可行曲线的一阶切向扰动 v，局部最优残差 $\mathscr{E}^\star$ 满足

$$\mathbb{E}_{\nu,\pi_k}[\mathscr{E}^\star v] = 0.$$

这是残差与可行切空间正交的必要条件。参数化可行集合通常非凸，该条件本身不保证全局最优。若 target 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

2.3 四种 inner 的统一推导

下面保留各方法特有的归一化、采样校正与更新几何。直接对原始损失反向传播时，student的全部参数依赖均保留；使用解析 policy-gradient surrogate 时，权重整体停止梯度。

2.3.1 PMD-Part：回归完整 Gibbs log-ratio

PMD-Part 的损失已在式 (2.9) 定义。

$$\mathcal{L}_{\mathrm{Part}} = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}[(R^{\mathrm{Part}}_{k,n})^2], \qquad R^{\mathrm{Part}}_{k,n} = U_{k,n} - \eta f + \log Z_f. \tag{2.23}$$

固定 history 后，anchor 与 target 冻结，逐步求导得到

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \frac{1}{2}\nabla_\theta \sum_a \pi_k(a \mid s)(R^{\mathrm{Part}}_{k,n}(s,a))^2 \tag{2.24}$$

$$= \sum_a \pi_k(a \mid s) R^{\mathrm{Part}}_{k,n}(s,a)\nabla_\theta U_{k,n}(s,a) \tag{2.25}$$

$$= \mathbb{E}_{\pi_k}[R^{\mathrm{Part}}_{k,n}\psi_{k,n} \mid s]. \tag{2.26}$$

梯度下降方向为 $-\mathbb{E}_{\pi_k}[R^{\mathrm{Part}}_{k,n}\psi_{k,n} \mid s]$。这是固定 anchor 下的 log-ratio regression，不使用 student-to-anchor 的 action-level importance ratio。

若实际 rollout 来自行为测度 β_k，而目标仍是 $L_2(\pi_k)$ 投影，则每个 sampled 平方损失项乘以冻结权重 $\mathrm{sg}(\pi_k(a \mid s)/\beta_k(a \mid s))$。不加这个权重时，算法仍然有清晰含义，但求解的是 $L_2(\beta_k)$ 投影。

2.3.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.27}$$

Algorithm 1 PMD-Part inner update

Semantics: 固定 *anchor* 下的完整 *Gibbs log-ratio* 回归

Require: frozen π_k, teacher signal f, histories $\{s_i\}_{i=1}^{B}$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for $i = 1, \dots, B$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $\log Z_i \leftarrow \mathrm{logsumexp}_{v\in\mathcal{V}}(\log \pi_k(v \mid s_i) + \eta f(s_i, v))$
  $H_i \leftarrow \eta f(s_i, a_i) - \mathrm{stopgrad}(\log Z_i)$
  $U_i \leftarrow \log \pi_{k,n}(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\ell_i \leftarrow \frac{1}{2}\big(U_i - \mathrm{stopgrad}(H_i)\big)^2$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

定理 2.2 (PMD-Mean 的逐历史 Lambert-W 投影)

在有限词表、$\pi_k(a \mid s) > 0$ 且约束可行时，上述仅中心化 reward 的平方回归具有唯一全局最小点，其 KKT 解满足

$$U_a = G_a - W_0\big(\lambda_k(s) e^{G_a}\big), \qquad G_a = \eta \widetilde{f}_k(s, a), \tag{2.28}$$

其中 $\lambda_k(s) \geq 0$ 由 $\sum_a \pi_k(a \mid s) e^{U_a} = 1$ 唯一确定。 ♡

证明 以下给出固定历史 s 的 KKT 推导。令词表上的函数值为 U_a 和 $G_a = \eta \widetilde{f}_k(s, a)$，拉格朗日函数为

$$\mathscr{L}(U, \lambda_k) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda_k \left(\sum_a \pi_k(a \mid s) e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda_k e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda_k e^{G_a}$，所以

$$U_a = G_a - W_0\big(\lambda_k e^{G_a}\big), \tag{2.29}$$

其中 λ_k 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda_k) = \sum_a \pi_k(a \mid s) \exp\big(G_a - W_0(\lambda_k e^{G_a})\big), \qquad \lambda_k \geq 0.$$

由于 $\mathbb{E}_{\pi_k}[G \mid s] = 0$，Jensen 不等式给出 $\Phi(0) = \mathbb{E}_{\pi_k}[e^G \mid s] \geq 1$。Lambert–$W$ 的主分支在非负轴上严格递增，所以 Φ 连续且严格递减，且 $\Phi(\lambda_k) \to 0$ 当 $\lambda_k \to \infty$。因此归一化方程有唯一非负根；非恒定 G 对应严格正根，$G \equiv 0$ 时根为零。

对于该根 $\lambda_k \geq 0$，拉格朗日函数的 Hessian 是

$$\nabla_U^2 \mathscr{L} = \mathrm{diag}\big(\pi_k(a \mid s)(1 + \lambda_k e^{U_a})\big) \succ 0.$$

因此构造出的 U 唯一最小化这个拉格朗日函数。所有满足归一化约束的 U 都有 $\mathscr{L}(U, \lambda_k) = \mathcal{L}_{\mathrm{Mean}}(U)$，构造的最小点又满足约束，故它是原受约束问题的唯一全局最小点。这一论证不要求指数归一化等式的可行集是凸集。

policy归一化 $\sum_a \pi_{k,n}(a \mid s) = 1$ 正是 log-ratio 坐标中的指数归一化条件。Lambert-W 解对应

$$\pi_k^{\star,\mathrm{Mean}}(a \mid s) = \pi_k(a \mid s) \exp\Big(G_k(s, a) - W_0(\lambda_k(s) e^{G_k(s,a)})\Big).$$

精确 Gibbs 解的 log-ratio 则为

$$U_a^{\mathrm{Gibbs}} = G_a - \log \mathbb{E}_{\pi_k}[e^G \mid s].$$

将其代入 PMD-Mean 的 KKT 条件，要求

$$-\log \mathbb{E}_{\pi_k}[e^G \mid s] + \lambda_k \frac{e^{G_a}}{\mathbb{E}_{\pi_k}[e^G \mid s]} = 0$$

对所有 action 同时成立。非恒定 G 时第一个量严格为负，第二个量随 action 改变，因此不存在满足所有方程的单一 λ_k。PMD-Mean 使用 action-dependent 的 Lambert-W 修正，Gibbs 使用 action-independent 的 log-partition 修正；二者仅在信号恒定时重合。

本节损失的乘子 λ_k 对应原论文乘子除以 τ^2，其中 $\tau = 1/\eta$。对 KKT 条件按 anchor 求均值，由 $\mathbb{E}_{\pi_k}[G] = 0$ 和 $\mathbb{E}_{\pi_k}[e^U] = 1$ 得到

$$\lambda_k = -\mathbb{E}_{\pi_k}[U] = \mathrm{KL}(\pi_k \| \pi_k^{\star,\mathrm{Mean}}).$$

固定这个由解确定的 λ_k，同一分布也唯一最大化

$$\mathbb{E}_p[f] - \frac{1}{\eta}\,\mathrm{KL}(p\|\pi_k) - \frac{\lambda_k}{2\eta}\chi^2(p\|\pi_k), \qquad \chi^2(p\|\pi_k) = \mathbb{E}_{\pi_k}\left[\left(\frac{p}{\pi_k} - 1\right)^2\right]. \tag{2.30}$$

为验证这一等价，令 ξ 为概率归一化乘子。混合目标的逐 action 一阶条件为

$$f_a - \frac{1}{\eta}(U_a + 1) - \frac{\lambda_k}{\eta}(e^{U_a} - 1) + \xi = 0.$$

在 PMD-Mean 解处有 $U_a + \lambda_k e^{U_a} = \eta(f_a - \bar{f}_k)$；取 $\xi = (1 - \lambda_k)/\eta - \bar{f}_k$ 即满足上式。混合目标中的负 KL 严格凹，负 χ^2 凹，因此这个驻点是唯一全局最大点。这里的等价指总体最优分布相同，不表示两个训练目标在任意参数点上的梯度相同。

实际样本只需估计冻结的 reward center。给定同一 history 的 $m \geq 2$ 个独立 anchor actions，使用 leave-one-out 均值

$$\widehat{\bar{f}}_{-j} = \frac{1}{m-1}\sum_{\ell \neq j} f(s, a_\ell).$$

student log-ratio $U_{k,n}(s, a_j)$ 保持原值，不计算或减去 $\bar{U}_{k,n}$。因为该 center 不依赖 student，leave-one-out reward center 的有限样本平方损失与总体损失只相差一个参数无关的条件方差项，其梯度无偏。若 $m = 1$，需要外部同 prefix 的 reward center；使用不准确的冻结 baseline 会改变回归目标，必须单独记录该误差。

Algorithm 2 PMD-Mean inner update

Semantics: 中心化 *target* 在指数归一化集合上的投影

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, $m \geq 2$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  for $j = 1, \ldots, m$ **do**
    sample $a_{ij} \sim \pi_k(\cdot \mid s_i)$
    $U_{ij} \leftarrow \log \pi_{k,n}(a_{ij} \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_{ij} \mid s_i))$
    $F_{ij} \leftarrow f(s_i, a_{ij})$
  end for
  for $j = 1, \ldots, m$ **do**
    $\bar{F}_{-j} \leftarrow (m-1)^{-1} \sum_{\ell \neq j} F_{i\ell}$
    $\ell_{ij} \leftarrow \frac{1}{2}[U_{ij} - \eta\,\mathrm{stopgrad}(F_{ij} - \bar{F}_{-j})]^2$
  end for
end for
$g_{k,n} \leftarrow \nabla_\theta[(Bm)^{-1} \sum_{i,j} \ell_{ij}]$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

2.3.3 BPO：中心化最优性 residual

BPO 的 residual、损失和梯度分别见式 (2.14)、(2.16)、(2.17)。为后续引用，同一对象记为

$$R_{k,n}^{\mathrm{BPO}} = U_{k,n} - G_k + \mathcal{K}_{k,n}^{S}, \qquad \mathcal{L}_{\mathrm{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2]. \tag{2.31}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n})]. \tag{2.32}$$

centered score 来自 student center 的导数。令 $z(s,a) = U_{k,n}(s,a) - \eta f(s,a)$，用一个主 action a_i 和 m 个独立辅助 actions $b_{i\ell}$ 估计 center，则

$$\mathbb{E}\left[\left(z(s,a_i) - \frac{1}{m}\sum_{\ell=1}^{m} z(s,b_{i\ell})\right)^2\right] = \left(1+\frac{1}{m}\right)\mathrm{Var}_{\pi_k}(z \mid s).$$

因此 sampled 平方损失需乘 $m/(m+1)$，其 autograd 梯度才无偏。若同 prefix 共有 $m \geq 2$ 个 actions，leave-one-out center 使用其余 $m-1$ 个样本，对应系数为 $(m-1)/m$。独立性本身不能消除 residual 与 center 导数乘积中的协方差。

Algorithm 3 BPO inner update

Semantics: 固定 *anchor* 下对正向中心化残差求平方损失

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^{B}$, auxiliary count $m \geq 1$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$ and $b_{i1}, \ldots, b_{im} \sim \pi_k(\cdot \mid s_i)$ independently
  $z_i \leftarrow U_{k,n}(s_i,a_i) - \eta f(s_i,a_i)$
  $\bar{z}_i \leftarrow m^{-1}\sum_{\ell=1}^{m}[U_{k,n}(s_i,b_{i\ell}) - \eta f(s_i,b_{i\ell})]$
  $\widehat{R}_i^{\mathrm{BPO}} \leftarrow z_i - \bar{z}_i$, $\ell_i \leftarrow \frac{m}{m+1}\frac{(\widehat{R}_i^{\mathrm{BPO}})^2}{2\eta}$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

若从行为测度 β 采样，不能先把 z 乘以 importance weight 再平方；这会把二阶矩的权重变成平方。可用两个独立样本 $a, b \sim \beta(\cdot \mid s)$，令 $w(v) = \mathrm{sg}(\pi_k(v \mid s)/\beta(v \mid s))$，使用

$$\widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \frac{w(a)w(b)}{4\eta}[z(a) - z(b)]^2.$$

因为 $\mathbb{E}_{a,b\sim\pi_k}[(z(a)-z(b))^2] = 2\,\mathrm{Var}_{\pi_k}(z)$，上述估计器的期望恰为原始 BPO 损失，且固定权重下 autograd 给出无偏梯度。

2.3.4 MDPO：直接优化 mirror objective

MDPO 的损失见式 (2.19)。完整词表计算

$$\mathrm{KL}(\pi_{k,n} \| \pi_k) = \sum_a \pi_{k,n}(a \mid s) U_{k,n}(s,a). \tag{2.33}$$

若从 anchor 采样，用显式指数权重改写 student 期望：

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right) \mid s\right]. \tag{2.34}$$

原损失中的指数权重保留梯度；解析求导后的 policy-gradient 权重整体冻结，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[\mathrm{sg}\left(e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right)\right)\psi_{k,n} \mid s\right]. \tag{2.35}$$

额外的 η^{-1} score 项在完整求和时由 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n}] = 0$ 抵消。

自然梯度只改变更新几何。令 $h_{k,n} = \nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，Fisher 信息矩阵为

$$F_{k,n} = \mathbb{E}_{d_k,\pi_{k,n}}[\psi_{k,n}(s,a)\psi_{k,n}(s,a)^\top].$$

anchor 采样时用 $\mathrm{sg}(e^{U_{k,n}})$ 校正测度。tabular categorical logits 的 Fisher 零空间为常数方向，故用伪逆 $F^\dagger_{k,n}$；神经网络参数化中用阻尼 $\gamma > 0$ 或 KL trust region。自然步长与镜像系数 η 分别控制数值更新和总体 target。

Algorithm 4 MDPO natural-gradient inner update

Semantics: 最小化固定 *history* 的负 *mirror objective*

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, η, natural step $\alpha_{k,n}$, damping $\gamma \geq 0$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $U_i \leftarrow U_{k,n}(s_i,a_i)$, $w_i \leftarrow e^{U_i}$
  $\ell_i \leftarrow w_i(U_i/\eta - f(s_i,a_i))$ ▷ retain the student derivative of w_i
  $g_i^{\mathrm{score}} \leftarrow \nabla_\theta \log \pi_{k,n}(a_i \mid s_i)$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$F \leftarrow B^{-1}\sum_i \mathrm{stopgrad}(w_i) g_i^{\mathrm{score}}(g_i^{\mathrm{score}})^\top$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n}(F + \gamma I)^\dagger g_{k,n}$
return $\theta_{k,n+1}$

定理 2.3 (Gibbs 解与 PMD-Mean 的 Lambert-W 解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、未线性化 BPO 和 MDPO 的总体最优解是式 (2.3) 的 Gibbs 分布。PMD-Mean 的总体最优解是定理 2.2 的 Lambert-W 分布；非恒定信号下与 Gibbs 分布不同。参数化 student 或有限样本还会引入函数类投影、采样及优化误差。

证明 PMD-Part 在零损失处满足 $U_{k,n} = \eta f - \log Z_f$，得到 Gibbs 分布。BPO 的零 residual 只要求 $U_{k,n} = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_{k,n}}] = 1$ 得 $C(s) = \log Z_f(s)$。MDPO 的负 mirror 损失由式 (2.4) 得到唯一最小点。PMD-Mean 的受约束全局最小点及与 Gibbs 解的分离已在定理 2.2 后证明。

命题 2.4 (PMD-Mean 与 BPO 的损失和梯度差异)

固定历史 s，两个 residual 满足 $R^{\mathrm{Mean}}_{k,n} = R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n}$，因此

$$\mathcal{L}_{\mathrm{Mean}}(s) = \eta\mathcal{L}_{\mathrm{BPO}}(s) + \frac{1}{2}(\mathcal{K}^S_{k,n}(s))^2, \tag{2.36}$$

$$\nabla_\theta\mathcal{L}_{\mathrm{Mean}}(s) = \eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}}(s) + \mathcal{K}^S_{k,n}(s)\nabla_\theta\mathcal{K}^S_{k,n}(s). \tag{2.37}$$

证明 $\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n} \mid s] = 0$，平方展开得

$$\frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n})^2 \mid s] = \frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n})^2 \mid s] + \frac{1}{2}(\mathcal{K}^S_{k,n})^2.$$

再使用损失定义并求导。下降方向的同尺度关系为

$$-\nabla_\theta\mathcal{L}_{\mathrm{Mean}} = -\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} + \mathcal{K}^S_{k,n}\bar{\psi}_{k,n}.$$

初始化 $\pi_{k,0} = \pi_k$ 时 $\mathcal{K}^S_{k,0} = 0$，两者同尺度方向一致；离开 anchor 后差异通常保留。tabular softmax logits 中 $\bar{\psi}_{k,n} = \pi_k - \pi_{k,n}$，额外下降方向是 $\mathcal{K}^S_{k,n}(\pi_k - \pi_{k,n})$。

命题 2.5 (未线性化 BPO 与 PMD-Part 的梯度差异)

固定历史 s，定义

$$C_{k,n}(s) := \log Z_f(s) - \eta\bar{f}_k(s) - \mathcal{K}^S_{k,n}(s). \tag{2.38}$$

则 $R^{\mathrm{BPO}}_{k,n} = R^{\mathrm{Part}}_{k,n} - C_{k,n}$，且

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}(s)}{\eta}\bar{\psi}_{k,n}(s). \tag{2.39}$$

证明 逐项展开中心化残差：

$$\begin{aligned} R^{\mathrm{BPO}}_{k,n} &= U_{k,n} - \eta f - \mathbb{E}_{\pi_k}[U_{k,n} - \eta f \mid s] \\ &= U_{k,n} - \eta f + \log Z_f - \left(\log Z_f + \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - \eta \bar{f}_k\right) \\ &= R^{\mathrm{Part}}_{k,n} - C_{k,n}. \end{aligned}$$

这里必须保留 $-\eta\bar{f}_k$，因为一般 OPD 信号的 anchor 均值不为零。由 BPO residual 均值为零，

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \\ &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[(R^{\mathrm{Part}}_{k,n} - C_{k,n})\psi_{k,n} \mid s] \\ &= \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}}{\eta}\bar{\psi}_{k,n}. \end{aligned}$$

在 Gibbs 解处 $R^{\mathrm{Part}}_{k,n} = 0$，其 anchor 均值也为零，因此 $C_{k,n} = 0$，两种梯度同时为零。一般参数点只有 $C_{k,n}\bar{\psi}_{k,n} = 0$ 时才具有相同的同尺度方向。

PMD-Part 回归完整镜像方程，BPO 消去 action-independent 常数再回归中心化方程。二者总体最优分布相同，而 residual、积分后的梯度和有限步轨迹不同。

2.4 镜像系数、数值步长与内层收敛的精确关系

共同子问题确定 Gibbs target，但不能据此把不同训练损失视为同一个参数目标。PMD-Part 与 BPO 回归不同形式的最优性方程，MDPO 直接优化原始子问题；PMD-Mean 进一步近似归一化项，因而改变总体 target。以下在完整有限词表上推导可验证的数值动力学，再说明神经网络实现需要保留哪些区别。

命题 2.6 (BPO 在 categorical logits 中是凸二次目标)

固定历史 s，记 $q_a = \pi_k(a \mid s) > 0$，以无约束 logits ℓ_a 参数化 $p_a = e^{\ell_a}/\sum_b e^{\ell_b}$。令

$$F_q = \mathrm{diag}(q) - qq^\top, \qquad h_a = \ell_a - \log q_a - \eta f_a.$$

精确 BPO 损失、梯度和 Hessian 分别是

$$\mathcal{L}_{\mathrm{BPO}} = \frac{h^\top F_q h}{2\eta}, \qquad \nabla_\ell \mathcal{L}_{\mathrm{BPO}} = \frac{F_q h}{\eta}, \qquad \nabla^2_\ell \mathcal{L}_{\mathrm{BPO}} = \frac{F_q}{\eta}. \tag{2.40}$$

其最小 logits 为 $\ell^\star = \log q + \eta f + c\mathbf{1}$，其中 c 是任意归一化冗余常数；最优概率分布唯一。

证明 将 student 的 log-softmax 展开为 $U_a = \ell_a - \log\sum_b e^{\ell_b} - \log q_a$，有

$$U_a - \eta f_a = h_a - \log\sum_b e^{\ell_b}.$$

对整个量按 q 中心化时，log-softmax 的归一化常数精确消去，所以

$$R^{\mathrm{BPO}}_a = h_a - \sum_b q_b h_b.$$

平方并按 q 求和，得到

$$\sum_a q_a (R^{\mathrm{BPO}}_a)^2 = \sum_a q_a h_a^2 - \left(\sum_a q_a h_a\right)^2 = h^\top F_q h.$$

h 对 ℓ 的导数是单位矩阵，故直接求导得到式 (2.40)。对任意向量 v，

$$v^\top F_q v = \mathrm{Var}_{a\sim q}(v_a) \geq 0.$$

严格正的 q 使方差为零当且仅当 v 在所有 action 上恒定，故 F_q 的零空间正是 $\mathrm{span}\{\mathbf{1}\}$。零损失等价于 $h = c\mathbf{1}$，归一化后即 Gibbs 解。这个凸性结论针对独立 categorical logits；共享参数神经网络的复合目标仍可非凸。

定理 2.4 (完整词表 BPO 梯度下降与 MDPO 自然梯度的步长条件)

在上述 categorical 条件下且 $|\mathcal{V}| \geq 2$，固定 anchor、信号和常数步长 $\alpha > 0$。令 $P = I - \mathbf{1}\mathbf{1}^\top/|\mathcal{V}|$，并以

$$e_n = P(\ell_n - \log q - \eta f)$$

度量相对于 Gibbs target 的 logit 误差，则：

1. BPO 的普通梯度下降满足 $e_{n+1} = (I - \alpha F_q/\eta)e_n$。对所有初值收敛的充要条件是 $0 < \alpha < 2\eta/\lambda_{\max}(F_q)$。
2. MDPO 使用当前 student 的精确 Fisher F_{p_n} 和无阻尼伪逆时满足 $e_{n+1} = (1 - \alpha/\eta)e_n$。对所有初值收敛的充要条件是 $0 < \alpha < 2\eta$；$\alpha = \eta$ 在一步内到达 Gibbs target。
3. BPO 若使用冻结 anchor Fisher F_q 的精确伪逆，也满足第二项的同一递推。

第二、三项虽在这一理想参数化下具有相同的有限步概率轨迹，使用的 Fisher 分别为当前 student 和冻结 anchor；不能将两种 preconditioner 互换后仍声称具有该恒等式。

证明 BPO 的梯度已在式 (2.40) 给出。因为 $PF_q = F_qP = F_q$，投影更新为

$$e_{n+1} = e_n - \frac{\alpha}{\eta} F_q e_n.$$

在 $\mathbf{1}^\perp$ 上将 F_q 正交对角化，所有特征值 λ_i 严格为正。每个特征方向的误差乘以 $1 - \alpha\lambda_i/\eta$，其绝对值都小于一当且仅当 $0 < \alpha < 2\eta/\lambda_{\max}(F_q)$。此时以 $\max_i |1 - \alpha\lambda_i/\eta| < 1$ 的因子收缩；边界上最大特征方向以符号翻转保持幅度，超过边界则该方向发散。

MDPO 的完整词表目标是

$$\mathcal{L}_{\mathrm{MDPO}}(\ell) = \sum_a p_a \left[\frac{\log p_a - \log q_a}{\eta} - f_a\right].$$

softmax Jacobian 为 $\nabla_\ell p = F_p$。对概率与 integrand 同时求导给出

$$\nabla_\ell \mathcal{L}_{\mathrm{MDPO}} = F_p \left[\frac{\log p - \log q + \mathbf{1}}{\eta} - f\right] = \frac{1}{\eta} F_p(\ell - \log q - \eta f),$$

其中利用 $F_p\mathbf{1} = 0$ 消去了 $\mathbf{1}/\eta$ 和 log-softmax 的归一化常数。正概率条件下 $F_p^\dagger F_p = P$，故自然梯度为 e_n/η。投影数值更新即 $e_{n+1} = (1 - \alpha/\eta)e_n$。所有初值的收缩条件是 $|1 - \alpha/\eta| < 1$；$\alpha = \eta$ 时投影误差为零，剩余常数不会改变概率。对 BPO 使用 $F_q^\dagger F_q = P$ 可逐步重复这一论证。

定理 2.4 明确区分 η 与 optimizer 步长。减小 η 将 Gibbs target 拉近 anchor，同时使 BPO、MDPO 原始损失的曲率含有 $1/\eta$；固定数值步长不因此自动稳定。使用阻尼 Fisher、随机 Fisher 估计、Adam、梯度裁剪或有限支持集中心后，上述精确递推不再成立。尤其同一批样本构造的随机 Fisher 伪逆与随机梯度的乘积，不等于总体自然梯度的无偏估计。

在 OPD 中 $f = \log(\pi_T/q)$。当 $\eta = 1$，精确 Gibbs target 是 teacher；定理中的 MDPO 自然梯度还需 $\alpha = 1$、完整期望与独立 categorical logits，才能一步到 teacher。一般 SGD 或 Adam 的一步更新没有这个性质；PMD-Mean 的充分优化解也仍是 Lambert-W 分布。

命题 2.7 (三种方法在 anchor 初值的尺度与小镜像步的 target)

在 $p = q$ 处，三个精确参数梯度满足

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}} = -\eta\, \mathbb{E}_q[f \nabla_\theta \log p], \qquad \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \nabla_\theta \mathcal{L}_{\mathrm{MDPO}} = -\mathbb{E}_q[f \nabla_\theta \log p].$$

固定有限词表、有限冻结信号，令 $h = f - \mathbb{E}_q f$、$\sigma^2 = \mathbb{E}_q h^2$。当 $\eta \to 0$ 时，Mean 与 Gibbs target 的 log-ratio

分别满足

$$U_a^{\mathrm{Mean}} = \eta h_a - \frac{\eta^2\sigma^2}{2} + O(\eta^3), \qquad U_a^{\mathrm{Gibbs}} = \eta h_a - \frac{\eta^2\sigma^2}{2} + O(\eta^3).$$

余项在有限词表上对 action 一致有界。因此两者在小步极限到二阶一致，同时保留有限 η 下不同的总体最优解。

证明 初始 log-ratio 和 student KL 均为零，且 $\mathbb{E}_q[\nabla_\theta \log p] = 0$，将这些量代入三个解析梯度即得第一组等式。对 target 展开，Gibbs 的归一化常数满足

$$\log \mathbb{E}_q e^{\eta h} = \frac{\eta^2\sigma^2}{2} + O(\eta^3)$$

因为 $\mathbb{E}_q h = 0$。Mean 的 KKT 方程为 $U_a = \eta h_a - \lambda e^{U_a}$。在 $(\eta, \lambda) = (0, 0)$ 处，归一化方程对 λ 的导数为 -1，所以隐函数定理给出光滑的 $\lambda(\eta)$ 与 $U(\eta)$。设

$$U_a = \eta A_a + \eta^2 B_a + O(\eta^3), \qquad \lambda = \eta l_1 + \eta^2 l_2 + O(\eta^3).$$

一阶 KKT 与归一化分别给出 $A_a = h_a - l_1$、$\mathbb{E}_q A = 0$，因而 $l_1 = 0$、$A = h$。二阶 KKT 给出 $B_a = -l_2$，二阶归一化给出

$$0 = \mathbb{E}_q\left[B + \frac{A^2}{2}\right] = -l_2 + \frac{\sigma^2}{2}.$$

由此 $l_2 = \sigma^2/2$，得到 Mean 展开。有限词表与固定有限信号保证 Taylor 余项对所有 action 一致。

比较相同 η 下的 SGD 时，Mean 的初始梯度比 BPO、MDPO 小 η 倍；初始方向一致的数值步长对应 $\alpha_{\mathrm{Mean}} = \alpha_{\mathrm{BPO}}/\eta$。这仅用于比较初始化的尺度，离开 anchor 后 Mean 额外的 KL 平方项仍改变方向。Adam 中的动量、平方矩估计、ϵ 和裁剪也使这种 SGD 的尺度换算无法直接套用。

2.4.1 总体梯度、经验损失与训练日志的区别

BPO的中心导数项消去依赖精确条件恒等式 $\mathbb{E}_q[R^{\mathrm{BPO}} \mid s] = 0$。固定 rollout 中每个 prefix 通常只有一个 sampled action，经验残差均值并不为零。即使中心使用完整词表，经验 PG 更新也不必等于对这批动作的 BPO 平方损失直接 autograd；它在固定参数、重新独立抽样的条件下才具有相同总体梯度。训练参数依赖此前复用的这批数据时，不能再把固定参数的条件无偏结论解释成训练每一步的无条件无偏性。

MDPO 从解析梯度删去 $1/\eta$ 项也依赖 $\mathbb{E}_p[\nabla_\theta \log p] = 0$。原始重要性加权目标与删去该项的 PG surrogate，在总体期望下梯度相同，在同一有限样本上相差

$$\frac{1}{\eta|\mathcal{B}_k|}\sum_{(s,a)\in\mathcal{B}_k} \frac{p(a \mid s)}{q(a \mid s)} \nabla_\theta \log p(a \mid s).$$

该项可以作为零均值控制变量选择保留或删除；本书正式 PG 实现删除它，原始 MDPO 自然梯度伪代码保留它。两种 Monte Carlo 梯度的具体数值及方差不同。

停止梯度后的 coefficient 乘 log-prob 是承载解析更新的 surrogate，其标量值可以为负，也没有固定的跨 inner 优化目标含义，因为 coefficient 每步重新计算。inner 收敛应结合真实平方 residual、精确 mirror objective gap、全批量梯度范数和更新幅度判断。Mean 应监控其 Lambert-W target 或受约束平方目标；不能把未到 Gibbs target 当作 Mean 数值优化失败。采用 Tail-aware 中心时还须记录其与 exact KL 的差异，避免把截断中心的残差变小解释成原始 BPO 子问题已经求解。

2.5 OPD 特化：逐 token reward 与两种信息访问模式

在 OPD 中，第 k 个 outer step 先固定 anchor π_k，然后从它产生 rollout。对 prefix $s_t = (x, y_{<t})$ 和实际 sampled token $a_t = y_t$，最直接的局部 teacher reward 是

$$r_k(s_t, a_t) = \log \pi_T(a_t \mid s_t) - \log \pi_k(a_t \mid s_t). \tag{2.41}$$

它满足序列分解

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \log \pi_T(y \mid x) - \log \pi_k(y \mid x).$$

因此在共同 mirror 子问题中应取 $f = r_k$；不能把整条序列的 log-ratio 当作每一个 prefix 的同一个 reward，否则会重复计算后缀差异。

可以对 reward 做两种不同的“归一化”，必须区分它们的理论作用。对任意只依赖 prefix 的 baseline $b_k(s)$，令

$$f_k^{\mathrm{ctr}}(s, a) = r_k(s, a) - b_k(s). \tag{2.42}$$

它只把 partition function 乘上 $e^{-\eta b_k(s)}$，所以 Gibbs policy 不变；取 $b_k(s) = \mathbb{E}_{\pi_k}[r_k(s, \cdot) \mid s]$ 就是条件中心化。若再除以尺度 $\sigma_k(s) > 0$，则

$$f_k^{\mathrm{std}} = (r_k - b_k)/\sigma_k$$

会把有效温度从 η 改成 η/σ_k，不再是同一个 mirror step，除非同时把正则参数改为 $\eta\sigma_k$。因此 OPD 的默认实现只做 additive centering；标准化只能作为明确的 temperature schedule。

2.5.1 完整 vocabulary logits：精确 token mirror target

完整词表 logits 使冻结 reward r_k、teacher center $\mathcal{K}_k^T$、student center $\mathcal{K}_{k,n}^S$ 和 partition function 都可精确求和。OPD 的配分函数为

$$\log Z_k(s) = \mathrm{logsumexp}_{v \in \mathcal{V}} \left((1-\eta) \log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) \right). \tag{2.43}$$

相应 Gibbs target 是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \exp\left((1-\eta) \log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) - \log Z_k(s) \right).$$

PMD-Mean 的 target 是定理 2.2 的 $\pi_k^{\star,\mathrm{Mean}}$。完整词表路径消除了条件 token 采样误差；prefix coverage 与数值优化误差仍保留。

四种损失与实际梯度

第一章的条件均值恒等式给出 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}_k^T$、$\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}_{k,n}^S$。因此冻结 Mean target 为 $G_k = \eta(r_k + \mathcal{K}_k^T)$，三个回归 residual 是

$$R_{k,n}^{\mathrm{Part}}(s, v) = U_{k,n}(s, v) - \eta r_k(s, v) + \log Z_k(s), \tag{2.44}$$

$$R_{k,n}^{\mathrm{Mean}}(s, v) = U_{k,n}(s, v) - \eta(r_k(s, v) + \mathcal{K}_k^T(s)), \tag{2.45}$$

$$R_{k,n}^{\mathrm{BPO}}(s, v) = U_{k,n}(s, v) + \mathcal{K}_{k,n}^S(s) - \eta(r_k(s, v) + \mathcal{K}_k^T(s)). \tag{2.46}$$

它们对应

$$\mathcal{L}_{\mathrm{Part}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Part}})^2 \mid s], \tag{2.47}$$

$$\mathcal{L}_{\mathrm{Mean}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Mean}})^2 \mid s], \tag{2.48}$$

$$\mathcal{L}_{\mathrm{BPO}}(s) = \tfrac{1}{2\eta}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2 \mid s], \tag{2.49}$$

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}[U_{k,n}/\eta - r_k \mid s]. \tag{2.50}$$

三个平方损失的解析梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Part}} \psi_{k,n} \mid s], \tag{2.51}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Mean}} \psi_{k,n} \mid s], \tag{2.52}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \tag{2.53}$$

$$= \mathbb{E}_{\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta} - r_k - \mathcal{K}_k^T\right)\psi_{k,n} \mid s\right]. \tag{2.54}$$

这里直接比较 $\nabla\mathcal{L}$，BPO 的 η^{-1} 已乘入权重。其实际下降方向为

$$-\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{\pi_k}\left[\left(r_k + \mathcal{K}_k^T - \frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta}\right)\psi_{k,n} \mid s\right]. \tag{2.55}$$

centered score 的第二项消失，是因为 $\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}} \mid s] = 0$；不能把 $\bar{\psi}_{k,n}$ 自身视为零。Mean residual 的 anchor 均值为 $-\mathcal{K}_{k,n}^S$，所以 Mean 不具有同样的消去。

MDPO 同时微分 student 测度和 log-ratio，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}\left[\left(\frac{U_{k,n}+1}{\eta} - r_k\right)\psi_{k,n} \mid s\right] \tag{2.56}$$

$$= \mathbb{E}_{\pi_{k,n}}[(U_{k,n}/\eta - r_k)\psi_{k,n} \mid s]. \tag{2.57}$$

第二行使用 student 测度的零均值 score 恒等式。MDPO 使用 student 积分测度，三个回归损失使用 anchor 积分测度。

停止梯度的具体位置

π_k、π_T、$\log Z_k$、$\mathcal{K}_k^T$ 和 G_k 在固定 outer step 冻结。student KL 每个 inner step 重算，原始 BPO 平方损失中保留其导数：

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{\pi_k}[\mathrm{stopgrad}(\log \pi_k) - \log \pi_{k,n} \mid s], \tag{2.58}$$

$$\nabla_\theta \mathcal{K}_{k,n}^S(s) = -\bar{\psi}_{k,n}(s). \tag{2.59}$$

若实现已经解析好的 policy gradient，所有 residual 和 MDPO 权重都整体停止梯度：例如 surrogate

$$\mathbb{E}_{\pi_k}[\mathrm{stopgrad}(R_{k,n}^{\mathrm{Mean}}) \log \pi_{k,n}]$$

的梯度正好等于 Mean 梯度。此处权重的导数已由解析推导处理，再微分一次会改变目标。若直接实现原始平方损失，则 student residual 及 BPO center 保留梯度。Mean 原始损失不含 student KL center。

2.5.2 有限词表与 sampled-token：KL 与 partition 估计

2602.04417的 Top-J 方法直接估计 KL：在 top-J 头部计算精确项，在尾部用采样项校正。它不直接给出本节的 $\log Z_k$，因为

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\left(\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}\right)^\eta\right]. \tag{2.60}$$

这一区别很重要：$\widehat{Z}_k$ 可以无偏，但 $\log \widehat{Z}_k$ 不能无偏。

在固定 prefix s 上，从冻结 anchor 采样 $a_j \sim \pi_k(\cdot \mid s)$，令 $r_k(s,a) = \log \pi_T(a \mid s) - \log \pi_k(a \mid s)$。则两个中心满足

$$\mathcal{K}_k^T(s) = \mathbb{E}_{a\sim\pi_k}[-r_k(s,a)], \tag{2.61}$$

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{a\sim\pi_k}\left[\log \pi_k(a \mid s) - \log \pi_{k,n}(a \mid s)\right]. \tag{2.62}$$

因此 m 个独立 next-token 样本的均值分别是两个 KL 的无偏估计。真实 rollout 中每个 prefix 通常只有一个后继 token；该 token 是无偏单点样本，但不是 conditional KL 的精确值。若要降低方差，可以在已经算出 anchor logits

后额外抽取 $m-1$ 个 token，这只增加 categorical 抽样和 log-prob 记录，无需生成额外长序列。不同 prefix 的 token 不能互相当作同一条件分布的样本。

其中 $\mathcal{K}_k^T$ 在整个 outer step 内固定，teacher/anchor log-prob 可以缓存；$\mathcal{K}_{k,n}^S$ 必须在每个 inner step 重新计算。实现已经推导好的 policy-gradient 时，KL 中心作为权重整体使用 stop-gradient；实现原始 BPO 平方损失时则必须保留 student KL 的导数；PMD-Mean 只需要冻结的 teacher KL center。

对 $\mathcal{K}_{k,n}^S = \mathrm{KL}(\pi_k \| \pi_{k,n})$，取 $S_{k,J}(s) = \mathrm{Top}(\pi_k(\cdot \mid s), J)$，可构造

$$\widehat{\mathcal{K}}_{k,n}^S(s) = \sum_{v \in S_{k,J}(s)} \pi_k(v \mid s) \log \frac{\pi_k(v \mid s)}{\pi_{k,n}(v \mid s)} \tag{2.63}$$

$$+ \frac{1}{m} \sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_{k,J}(s)\} \log \frac{\pi_k(a_j \mid s)}{\pi_{k,n}(a_j \mid s)}, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.64}$$

对固定 $S_{k,J}$，尾部项是精确尾部求和的无偏 Monte Carlo 估计，且其 autograd 梯度的期望等于真实 KL 梯度。这里的“梯度无偏”是指把该估计量直接放进原始 KL 损失并对 student 反向传播时的性质；本章的最终实现采用已经解析化的 policy-gradient 形式，KL 估计值只作为数值权重，必须整体 stopgrad，因此不需要再对这个估计量执行 autograd。$J = 0$ 是纯 sampled-token，$J = |\mathcal{V}|$ 是 exact KL；这两个端点是同一个 top-J 族的插值端点，不单独构成一个算法分支。给定头部后，条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_{k,n}^S \mid S_{k,J}) = \frac{1}{m} \mathrm{Var}_{a \sim \pi_k} \left[\mathbf{1}\{a \notin S_{k,J}\} \log \frac{\pi_k(a \mid s)}{\pi_{k,n}(a \mid s)} \right]. \tag{2.65}$$

增大 J 通常降低尾部质量和方差，但实际大小取决于尾部 log-ratio 的二阶矩。对 $\mathcal{K}_k^T$ 可使用同样的头尾分解；由于它不需要反向传播，anchor 样本均值往往已经足够。

为了把 2602.04417 中“截断偏差换取采样方差”的结论直接用于 OPD，下面给出一个与 KL、score 加权梯度和 partition function 都兼容的统一形式。固定 prefix s，令 $p(v)$ 为 rollout 测度（本章中通常是 $p = \pi_k(\cdot \mid s)$），$h(v)$ 为待求期望的 integrand，定义

$$Q = \mathbb{E}_{v \sim p}[h(v)], \qquad Q_J^{\mathrm{head}} = \sum_{v \in S_J} p(v) h(v), \qquad \tau_J = \mathbb{E}_{v \sim p}[\mathbf{1}\{v \notin S_J\} h(v)], \tag{2.66}$$

其中 S_J 是固定的 top-J 集合。用 m 个独立的 auxiliary token $a_1, \ldots, a_m \sim p$ 做尾部校正时，定义

$$\widehat{Q}_{J,m} = Q_J^{\mathrm{head}} + \frac{1}{m} \sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_J\} h(a_j). \tag{2.67}$$

定理 2.5 (Top-J 截断与尾部校正的偏差–方差分解)

在 $\mathbb{E}_p[h^2] < \infty$ 且 S_J 与 auxiliary samples 独立时，纯头部估计 $\widehat{Q}_J^{\mathrm{tr}} = Q_J^{\mathrm{head}}$ 与尾部校正估计 $\widehat{Q}_{J,m}$ 分别满足

$$\mathrm{Bias}(\widehat{Q}_J^{\mathrm{tr}}) = -\tau_J, \qquad \mathrm{Var}(\widehat{Q}_J^{\mathrm{tr}}) = 0, \qquad \mathrm{MSE}(\widehat{Q}_J^{\mathrm{tr}}) = \tau_J^2, \tag{2.68}$$

$$\mathrm{Bias}(\widehat{Q}_{J,m}) = 0, \qquad \mathrm{Var}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \qquad \mathrm{MSE}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \tag{2.69}$$

其中

$$V_J = \mathbb{E}_p\left[\mathbf{1}\{v \notin S_J\} h(v)^2\right] - \tau_J^2. \tag{2.70}$$

如果 $S_J \subseteq S_{J+1}$，则尾部二阶矩 $A_J = \mathbb{E}_p[\mathbf{1}\{v \notin S_J\} h(v)^2]$ 单调不增，且 $V_J \le A_J$。尾部均值 τ_J 在 $h \ge 0$ 时单调不增；对符号不定的 h，它本身不必单调，但有

$$|\tau_J| \le \sqrt{p(S_J^c) A_J}. \tag{2.71}$$

♡

证明 记 $X_j = \mathbf{1}\{a_j \notin S_J\} h(a_j)$。由 $a_j \sim p$，有 $\mathbb{E}[X_j] = \tau_J$，且 $\mathrm{Var}(X_j) = V_J$。因此

$$\mathbb{E}[\widehat{Q}_{J,m}] = Q_J^{\mathrm{head}} + \tau_J = Q, \qquad \mathrm{Var}(\widehat{Q}_{J,m}) = \mathrm{Var}\left(\frac{1}{m} \sum_{j=1}^{m} X_j\right) = \frac{V_J}{m}, \tag{2.72}$$

其中最后一步使用了独立性。纯头部估计没有随机项，且 $Q_J^{\mathrm{head}} - Q = -\tau_J$，从而得到前三个等式。若集合嵌套，$\mathbf{1}\{v \notin S_{J+1}\} \le \mathbf{1}\{v \notin S_J\}$，故对非负 h^2 有 $A_{J+1} \le A_J$。当 $h \ge 0$ 时，尾部指示函数逐点下降，所以 $0 \le \tau_{J+1} \le \tau_J$。一般情形下对尾部随机变量应用 Cauchy–Schwarz 不等式即可得到式 (2.71)。

定理 2.5 有两个直接含义。对 $h_{\mathrm{KL}}(v) = \log \frac{\pi_k(v|s)}{\pi_{k,n}(v|s)}$ 或 $h_T(v) = \log \frac{\pi_k(v|s)}{\pi_T(v|s)}$，$h$ 可能正也可能负，因此不能声称“增大 J 必然单调减小截断 bias”；能够保证的是尾部二阶矩和上界下降。对 $h_Z(v) = \exp(\eta r_k(s,v)) \ge 0$，尾部均值本身单调下降，所以纯截断的 Z_k 估计具有严格的单侧负偏差，而且随 J 减小。这正是 2602.04417 中 truncated KL 与 tail-corrected Top-J KL 的数学区别。

如果最终对象是 score 加权的 policy gradient，使用第一章的 score $\psi_{k,n}$，把 $h(v)$ 换成向量 $h(v)\psi_{k,n}(v)$，定理逐坐标成立，并得到

$$\mathrm{Bias}(\widehat{H}_J^{\mathrm{tr}}) = -\mathbb{E}_p[\mathbf{1}\{v \notin S_J\}h(v)\psi_{k,n}(v)], \qquad \mathrm{Cov}(\widehat{H}_{J,m}) = \frac{1}{m}\mathrm{Cov}_p(\mathbf{1}\{v \notin S_J\}h(v)\psi_{k,n}(v)). \tag{2.73}$$

这描述的是“估计最终梯度权重”的误差，而不是对 detached 估计量求导。本章 Algorithm 5 采用这种解析权重实现：先解析得到 score-function 公式，再把 $\widehat{h}$ 整体 stop-gradient。因此实现不需要保存估计量的 autograd 图；只需控制式 (2.73) 中的数值 bias 和 variance。

对 Z_k，头尾分解应先估计 Z_k 再取对数。令 $S_Z(s)$ 为 $((1-\eta)\log\pi_k + \eta\log\pi_T)$ 的 top-J 索引，则

$$\widehat{Z}_k(s) = \sum_{v \in S_Z(s)} \pi_k(v \mid s)^{1-\eta}\pi_T(v \mid s)^{\eta} \tag{2.74}$$

$$+ \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_Z(s)\}\left(\frac{\pi_T(a_j \mid s)}{\pi_k(a_j \mid s)}\right)^{\eta}, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.75}$$

式 (2.75) 对 Z_k 无偏，但 Jensen 不等式给出

$$\mathbb{E}[\log \widehat{Z}_k] \le \log Z_k, \qquad \mathbb{E}[\log \widehat{Z}_k] - \log Z_k \approx -\frac{\mathrm{Var}(\widehat{Z}_k)}{2Z_k^2}. \tag{2.76}$$

尾部重要性比率具有长尾时，单 token plug-in 估计尤其不稳定；裁剪比率可降方差，但会引入额外偏差。$\eta = 1$ 时 $Z_k = 1$，所以 $\log Z_k = 0$ 精确已知；$\eta = 0$ 时同样如此。$0 < \eta < 1$ 时，若不需要 PMD-Part，PMD-Mean/BPO 可以绕开这项 log-of-mean 偏差。

定理 2.6 (Partition function 的 log-of-mean 偏差)

设 $\widehat{Z}_{J,m}$ 是式 (2.75) 的尾部校正估计，$\mathbb{E}[\widehat{Z}_{J,m}] = Z_k > 0$，假设有限词表上 anchor 与 teacher 均为正概率，且头部集合固定。此时 $\widehat{Z}_{J,m}$ 有与 m 无关的正下界及有限上界。记 $V_J = \mathrm{Var}(\mathbf{1}\{a \notin S_Z\}(\pi_T(a \mid s)/\pi_k(a \mid s))^{\eta})$。当 m 足够大时，

$$\mathbb{E}[\log \widehat{Z}_{J,m}] - \log Z_k = -\frac{V_J}{2mZ_k^2} + O(m^{-3/2}), \tag{2.77}$$

$$\mathrm{Var}(\log \widehat{Z}_{J,m}) = \frac{V_J}{mZ_k^2} + O(m^{-3/2}). \tag{2.78}$$

若 $J \ge 1$ 并改用纯头部估计 $Z_J^{\mathrm{tr}} = \sum_{v \in S_Z} \pi_k(v)^{1-\eta}\pi_T(v)^{\eta}$，则

$$Z_J^{\mathrm{tr}} - Z_k = -\tau_J^Z \le 0, \qquad \log Z_J^{\mathrm{tr}} - \log Z_k \le 0, \tag{2.79}$$

其中 $\tau_J^Z \ge 0$ 是式 (2.66) 对 h_Z 的尾部均值。因而纯截断的 log-partition bias 是确定性的单侧偏差，而尾部校正的 plug-in log 估计是由方差诱导的负偏差。 ♡

证明 令 $\varepsilon_Z = \widehat{Z}_{J,m} - Z_k$。由无偏性，$\mathbb{E}[\varepsilon_Z] = 0$，且 $\mathbb{E}[\varepsilon_Z^2] = V_J/m$。在 Z_k 邻域对 $f(z) = \log z$ 作三阶 Taylor 展开：

$$\log(Z_k + \varepsilon_Z) = \log Z_k + \frac{\varepsilon_Z}{Z_k} - \frac{\varepsilon_Z^2}{2Z_k^2} + R_3, \tag{2.80}$$

其中在三阶矩有界时 $\mathbb{E}|R_3| = O(m^{-3/2})$。取期望并使用 $\mathbb{E}[\varepsilon_Z] = 0$ 得到第一式。对同一展开取方差，首阶随机项为 ε_Z/Z_k，故 $\mathrm{Var}(\log \widehat{Z}_{J,m}) = V_J/(mZ_k^2) + O(m^{-3/2})$。最后，$h_Z \ge 0$ 给出 $\tau_J^Z \ge 0$，所以 $Z_J^{\mathrm{tr}} \le Z_k$；由于 log 单调递增，第二个不等式随之成立。

定理 2.6 说明了为什么不能把“无偏的 $\widehat{Z}_k$”直接等同于“无偏的 $\log Z_k$”。在 PMD-Part 中，若使用 plug-in 估计，$\log Z_k$ 的误差会进入每个 token 的 residual；在完整词表路径上，该误差乘以 anchor 下的 student score 均值，一般不为零；sampled-token 路径还承担随机 score 的额外方差。因此 PMD-Part 对 m、J 和尾部比率的要求严格于 PMD-Mean/BPO。当 m 个样本独立且把同一 prefix 的梯度平均时，partition 诱导的梯度方差按 $1/m$ 下降；当外层有 B 个相互独立 prefix 时，条件于 prefix 的这部分方差进一步按 $1/B$ 下降，但 prefix coverage 误差不随 m 消失。

$\log Z_k$ 的展开估计：从 Z_k 的 plug-in 走向可控偏差

直接计算 $\log \widehat{Z}_k$ 是最简单的方案，但它把非线性的 log 放在 Monte Carlo 均值之后，必然产生 Jensen bias。对于 OPD，Z_k 具有更特殊的结构：

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k}\left[e^{\eta r_k(s,a)}\right], \qquad r_k(s,a) = \log \pi_T(a \mid s) - \log \pi_k(a \mid s). \tag{2.81}$$

因此 $\log Z_k$ 是随机变量 r_k 的 cumulant-generating function 在 η 处的值。令 $\kappa_j(r_k)$ 为 r_k 的第 j 阶 cumulant，则在零点 Taylor 级数的收敛半径内

$$\log Z_k(s) = \sum_{j=1}^{\infty} \frac{\eta^j}{j!}\kappa_j(r_k). \tag{2.82}$$

前两项为

$$\log Z_k(s) = \eta\,\mathbb{E}[r_k] + \frac{\eta^2}{2}\operatorname{Var}(r_k) + R_3(s), \tag{2.83}$$

其中 R_3 收集三阶及以上 cumulant。因为 $\mathbb{E}[r_k] = -\mathcal{K}_k^T$，二阶近似也可以写成

$$\log Z_k(s) \approx -\eta\mathcal{K}_k^T(s) + \frac{\eta^2}{2}\operatorname{Var}_{a\sim\pi_k}[r_k(s,a)]. \tag{2.84}$$

这给出了比 $-\eta\widehat{\mathcal{K}}_k^T$ 更准确的近似：只使用均值会遗漏 log-sum-exp 的二阶曲率项，而该项在 teacher 与 anchor 差异较大时不可忽略。

若从同一个 prefix 取得 m 个 auxiliary token，令 $\widehat{\kappa}_j$ 为对应的 unbiased j 阶 k-statistic，并定义

$$\widehat{L}_{L,m}(s) = \sum_{j=1}^{L} \frac{\eta^j}{j!}\widehat{\kappa}_j(r_k). \tag{2.85}$$

则

定理 2.7 (Cumulant 截断估计器的 bias 与方差)

固定有限词表，假设 $\pi_k(v \mid s) > 0$、$\pi_T(v \mid s) > 0$。令

$$\varphi(t) = \log \mathbb{E}_{\pi_k}[e^{tr_k} \mid s], \qquad p_t(v \mid s) = \frac{\pi_k(v \mid s)e^{tr_k(s,v)}}{\mathbb{E}_{\pi_k}[e^{tr_k} \mid s]}.$$

取固定展开阶数 $L \geq 1$，样本数 $m \geq L$。第 j 阶 k-statistic 无偏估计 $\varphi^{(j)}(0) = \kappa_j(r_k)$，故

$$\mathbb{E}[\widehat{L}_{L,m}] - \log Z_k = -\frac{\eta^{L+1}}{L!}\int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\,du, \tag{2.86}$$

$$\operatorname{Var}(\widehat{L}_{L,m}) = O(m^{-1}). \tag{2.87}$$

余项满足

$$\left|\mathbb{E}[\widehat{L}_{L,m}] - \log Z_k\right| \leq \frac{|\eta|^{L+1}}{(L+1)!}\sup_{t\in[0,\eta]}\left|\kappa_{L+1}^{p_t}(r_k)\right|. \tag{2.88}$$

其中 $\kappa_{L+1}^{p_t}$ 是倾斜分布 p_t 下的 cumulant。 ♡

证明 有限词表和正概率使 r_k 有界，φ 在实轴上光滑。对指数倾斜分布求导可得

$$\varphi'(t) = \mathbb{E}_{p_t}[r_k], \qquad \varphi''(t) = \operatorname{Var}_{p_t}(r_k), \qquad \varphi^{(j)}(t) = \kappa_j^{p_t}(r_k).$$

Taylor 积分余项给出

$$\varphi(\eta)=\sum_{j=1}^{L}\frac{\eta^j}{j!}\varphi^{(j)}(0)+\frac{\eta^{L+1}}{L!}\int_0^1(1-u)^L\varphi^{(L+1)}(u\eta)\,du.$$

估计器前 L 项逐项无偏，因此其 bias 是余项的负值。对积分取绝对值并使用 $\int_0^1(1-u)^L du=1/(L+1)$，得到上界。固定阶 k-statistic 是有界核 U-statistic 的有限线性组合，其方差和相互协方差均为 $O(m^{-1})$，从而得到估计器方差。这里展开的是 log-mgf，余项必须用倾斜 cumulant 控制，不能套用 $e^{\eta r_k}$ 本身的 Taylor 余项界。

对 OPD 的常用二阶实现，$L=2$ 时可以直接使用样本均值和无偏样本方差：

$$\widehat{L}_{2,m}(s)=\eta\bar{r}_k(s)+\frac{\eta^2}{2}\widehat{\mathrm{Var}}(r_k(s,\cdot)). \tag{2.89}$$

它不再具有 log-of-mean 的 $O(m^{-1})$ Jensen bias；剩余 bias 是明确的 cumulant truncation bias。代价是需要估计方差，并且当 $\eta|r_k|$ 较大时，三阶及以上 cumulant 不能忽略。因此它适合 teacher/anchor 接近、r_k 集中的阶段，不适合重要性比率重尾的阶段。

Top-J 头部还可以进一步降低展开的尾部误差。令

$$Z_H=\sum_{v\in S_Z}\pi_k(v)^{1-\eta}\pi_T(v)^{\eta},\qquad u(a)=\mathbf{1}\{a\notin S_Z\}\left(\frac{\pi_T(a)}{\pi_k(a)}\right)^{\eta},\qquad \tau=\mathbb{E}_{\pi_k}[u(a)], \tag{2.90}$$

这里 S_Z 含 J 个头部 tokens。取 $J\ge 1$ 和 $m\ge L$，使 $Z_H>0$ 且各阶 U-statistic 有定义。则 $Z_k=Z_H+\tau$。当 $\zeta=\tau/Z_H<1$ 时，

$$\log Z_k=\log Z_H+\sum_{\ell=1}^{\infty}\frac{(-1)^{\ell+1}}{\ell}\zeta^{\ell}. \tag{2.91}$$

用 m 个尾部样本构造

$$\widehat{\tau^{\ell}}=\binom{m}{\ell}^{-1}\sum_{1\le i_1<\cdots<i_\ell\le m}\prod_{q=1}^{\ell}u(a_{i_q}),\qquad a_i\overset{\text{iid}}{\sim}\pi_k, \tag{2.92}$$

这是 τ^{ℓ} 的无偏 U-statistic。于是可定义

$$\widehat{L}_{J,L}(s)=\log Z_H+\sum_{\ell=1}^{L}\frac{(-1)^{\ell+1}}{\ell Z_H^{\ell}}\widehat{\tau^{\ell}}. \tag{2.93}$$

它的期望等于式 (2.91) 的前 L 项，且截断余项满足

$$\left|\mathbb{E}[\widehat{L}_{J,L}]-\log Z_k\right|\le\frac{\zeta^{L+1}}{(L+1)(1-\zeta)}. \tag{2.94}$$

这个估计器在 J 增大时更有意义：Z_H 增大、ζ 减小，二阶或三阶展开就能达到很小的确定性 truncation bias；$J=0$ 时 $Z_H=0$，应退回 cumulant 展开或直接使用正值的 $\log\widehat{Z}$ plug-in。实际实现中建议先用 $L=2$，同时记录 $\widehat{\zeta}$、plug-in 与展开估计的差异，用它判断是否进入重尾区域。

2602.04417 的合成图可以作为本节偏差–方差实验的模板。论文固定 $|\mathcal{V}|=32000$，令 reference logits 为 $\mathcal{N}(0,I)$，当前策略 logits 为 $s\mathcal{N}(0,I)$，通过调整 s 使 $\sum_{j\in\mathrm{Top}(\pi,32)}\pi(j)$ 接近 $\{0.2,0.5,0.8,0.9\}$。对

$$J\in\{4,8,16,32,64,128,256\},\qquad B\in\{1,2,4,\dots,32768\}.$$

分别计算 sampled、纯截断和 tail-corrected Top-J 的 token-logit 真梯度与估计梯度，并绘制

$$\mathrm{RelRMSE}=\frac{\sqrt{\mathbb{E}\|\widehat{g}-g_{\mathrm{true}}\|_2^2}}{\|g_{\mathrm{true}}\|_2}. \tag{2.95}$$

交点就是论文所谓 critical sample size。官方仓库 https://github.com/LunjunZhang/ema-pg 公开了 `compute_memory_efficient_kl`、K3^{++}/K4/K5 和 GPU top-J benchmark，但没有公开生成 `simulated_topk_kl_four_masses_v5.pdf` 的脚本；因此我们可以按上述协议在本项目中重建一份，并把 OPD 的 $\log Z_k$ plug-in、二阶 cumulant 和 Top-J 尾部展开作为额外曲线。图中应同时报告 value bias、gradient RelRMSE、尾部命中率和峰值显存，不能只画 KL 数值方差。

偏差–方差定理：从 KL 数值到最终 policy gradient

对一个 prefix 的任意估计器 $\widehat{q}$，最终关心的是带 score 的量 $\widehat{g} = \widehat{q}\nabla_\theta \log \pi_{k,n}$。其均方误差分解为

$$\mathbb{E}\|\widehat{g} - g\|^2 = \|\mathbb{E}[\widehat{g}] - g\|^2 + \operatorname{tr}\operatorname{Cov}(\widehat{g}). \tag{2.96}$$

因此，单独比较 $\widehat{\mathcal{K}}$ 的数值方差并不足够：一个有轻微截断偏差但尾部方差极低的估计器，可能比无偏但重尾的 sampled estimator 产生更小的梯度 MSE。2602.04417 的 Top-J 结论正是这个取舍：加入尾部校正保持无偏，代价是尾部采样方差；只保留头部则引入可控的截断偏差。

对 OPD 的 PMD-Part，$\log Z_k$ 的误差直接进入 residual，而 residual 又乘以 score。若使用 $\widehat{c}_k = \log \widehat{Z}_k$，令 $\varepsilon_Z = \widehat{c}_k - \log Z_k$，则单 prefix 的梯度误差包含

$$\varepsilon_Z^{\text{grad}} = \varepsilon_Z \, \mathbb{E}_{v\sim\pi_k}\left[\nabla_\theta \log \pi_{k,n}(v \mid s)\right] \tag{2.97}$$

以及 ε_Z 与 sampled score 的协方差项。完整词表下 score 均值可以精确求和，但只有当 student 等于 anchor 等特殊条件成立时才为零；sampled-token 下即使 partition 估计与 token 独立，其均值误差仍会乘以这个非零 score 均值，有限 batch 还引入随机梯度噪声。故 PMD-Part 对 partition 估计的要求比 BPO/PMD-Mean 更严格。

对同一 prefix 同时估计中心和 policy-gradient 权重时，还要考虑协方差：若 $\widehat{c}$ 与 score 使用同一枚 token，$\mathbb{E}[\widehat{c}\,\widehat{g}]$ 一般不等于 $\mathbb{E}[\widehat{c}]\mathbb{E}[\widehat{g}]$。采用独立的 auxiliary next-token 样本估计中心，或使用 leave-one-out center，可以消除这类自耦合偏差；代价是额外的 token 抽样和少量 log-prob 存储。跨 prefix 聚合只能降低总体均值方差，不能把不同条件分布下的样本变成同一 conditional center。

最后，prefix 覆盖误差与 token 估计误差应分开记录。即使 token-level estimator 在给定 s 上无偏，rollout 只访问由 π_k 诱导的有限 prefix 多重集，仍有 $\widehat{d}_k - d_k$ 的 outer 测度误差。增加 Top-J 或 auxiliary samples 只降低条件 token 方差，不能修复 prefix coverage；增加 rollout 数量或重新采样 outer batch 才能降低这一项。实验日志应至少分别保存：prefix 数量与重复率、KL/partition 的 batch 均值和方差、尾部采样次数、梯度范数与峰值显存。

Tail-aware 中心的梯度偏差与停止梯度语义

下面固定一个 prefix s 和一个 inner step，写 $q = \pi_k(\cdot \mid s)$、$p = \pi_{k,n}(\cdot \mid s)$、$T = \pi_T(\cdot \mid s)$。假设有限词表上的三者严格为正，$p$ 关于参数可微，$\eta > 0$，且 S_J 由冻结的 q 选出，因此求导时支持集不变。用相同的支持集定义两个遗漏的尾部形状项：

$$b_J^T(s) = q(S_J^c)\,\mathrm{KL}\big(q(\cdot \mid S_J^c)\|T(\cdot \mid S_J^c)\big), \tag{2.98}$$

$$b_{J,n}^S(s) = q(S_J^c)\,\mathrm{KL}\big(q(\cdot \mid S_J^c)\|p(\cdot \mid S_J^c)\big). \tag{2.99}$$

若尾部为空，两项按连续延拓定义为零。Tail-aware 的链式分解给出

$$\widehat{\mathcal{K}}_k^T = \mathcal{K}_k^T - b_J^T, \qquad \widehat{\mathcal{K}}_{k,n}^S = \mathcal{K}_{k,n}^S - b_{J,n}^S. \tag{2.100}$$

这些估计对固定 prefix 是确定性的，因而这里的偏差来自尾部聚合，并非来自额外 sampled token 的随机性。

定理 2.8 (Tail-aware Mean/BPO 解析更新的偏差)

令 $g_{\text{Mean}}(s)$、$g_{\text{BPO}}(s)$ 为精确条件 KL 中心的 score-function 梯度，$\widehat{g}_{\text{Mean}}(s)$、$\widehat{g}_{\text{BPO}}(s)$ 为替换成 Tail-aware 中心并对整个权重停止梯度后的条件期望。则

$$\widehat{g}_{\text{Mean}}(s) - g_{\text{Mean}}(s) = \eta b_J^T(s)\mathbb{E}_{a\sim q}[\nabla_\theta \log p(a)], \tag{2.101}$$

$$\widehat{g}_{\text{BPO}}(s) - g_{\text{BPO}}(s) = \left(b_J^T(s) - \frac{b_{J,n}^S(s)}{\eta}\right)\mathbb{E}_{a\sim q}[\nabla_\theta \log p(a)]. \tag{2.102}$$

相应的 BPO 近似残差

$$\widehat{D}_\theta(a) = \log\frac{p(a)}{q(a)} + \widehat{\mathcal{K}}_{k,n}^S - \eta\left(\log\frac{T(a)}{q(a)} + \widehat{\mathcal{K}}_k^T\right) \tag{2.103}$$

满足

$$\mathbb{E}_q[\widehat{D}_\theta] = -b^S_{J,n} + \eta b^T_J. \tag{2.104}$$

对任意固定 prefix 测度 d，总体偏差是上述条件偏差关于 d 的期望。

证明 精确 Mean 残差为 $A_\theta(a) = \log(p(a)/q(a)) - \eta(\log(T(a)/q(a)) + \mathcal{K}^T_k)$。代入 $\widehat{\mathcal{K}}^T_k = \mathcal{K}^T_k - b^T_J$，逐动作得到

$$\widehat{A}_\theta(a) = A_\theta(a) + \eta b^T_J.$$

两者分别乘以 $\nabla_\theta \log p(a)$，在同一冻结分布 q 下取期望，即得 Mean 的偏差公式。对于 BPO，两个中心的替换给出

$$\widehat{D}_\theta(a) = D_\theta(a) - b^S_{J,n} + \eta b^T_J.$$

精确残差的均值为

$$\mathbb{E}_q[D_\theta] = -\mathcal{K}^S_{k,n} + \mathcal{K}^S_{k,n} - \eta(-\mathcal{K}^T_k + \mathcal{K}^T_k) = 0.$$

对替换后的残差取期望便得到所述非零均值。再将逐动作残差差除以 η，乘以 score，并在 q 下取期望，得到 BPO 的偏差公式。最后在固定 d 下积分，期望线性性给出总体结论。

若 $\|\nabla_\theta \log p(a)\| \le G(s)$，三角不等式还给出

$$\|\mathbb{E}_d[\widehat{g}_{\text{Mean}} - g_{\text{Mean}}]\| \le \eta \mathbb{E}_d[b^T_J G], \tag{2.105}$$

$$\|\mathbb{E}_d[\widehat{g}_{\text{BPO}} - g_{\text{BPO}}]\| \le \mathbb{E}_d[|b^T_J - b^S_{J,n}/\eta| G]. \tag{2.106}$$

因此 BPO 的两个中心误差可能抵消，也可能被 $1/\eta$ 放大。单独降低 teacher KL 的 RMSE 不能保证 BPO 梯度误差同步下降。在 $p = q$ 时，$b^S_{J,n} = 0$ 且 $\mathbb{E}_q[\nabla_\theta \log p] = \nabla_\theta \sum_a p(a) = 0$，所以两种更新的条件偏差都为零；inner 更新后一般不再满足该条件。

命题 2.8 (Tail-aware BPO 平方损失与 SG 更新的区别)

若 student Tail-aware 中心保留梯度，近似平方目标 $\widehat{\mathcal{L}}_{\text{BPO}}(s) = \mathbb{E}_q[\widehat{D}^2_\theta]/(2\eta)$ 的完整梯度为

$$\nabla_\theta \widehat{\mathcal{L}}_{\text{BPO}}(s) = \widehat{g}_{\text{BPO}}(s) + \left(b^T_J - \frac{b^S_{J,n}}{\eta}\right) \nabla_\theta \widehat{\mathcal{K}}^S_{k,n}(s). \tag{2.107}$$

Algorithm 5 使用第一项，即对原始 BPO 解析梯度的近似；它一般不等于替换中心后的平方损失梯度。

证明 q, T, S_J 均冻结，因此

$$\nabla_\theta \widehat{D}_\theta(a) = \nabla_\theta \log p(a) + \nabla_\theta \widehat{\mathcal{K}}^S_{k,n}.$$

对平方目标使用链式法则，得到

$$\nabla_\theta \widehat{\mathcal{L}}_{\text{BPO}} = \frac{1}{\eta}\mathbb{E}_q[\widehat{D}_\theta \nabla_\theta \log p] + \frac{1}{\eta}\mathbb{E}_q[\widehat{D}_\theta]\nabla_\theta \widehat{\mathcal{K}}^S_{k,n}.$$

第一项是 SG 权重的 score-function 更新；将上一条定理的残差均值代入第二项，即得结论。精确中心下残差均值为零，第二项消失；有限支持集的 Tail-aware 中心不保证这一消去。

Mean 的情况不同：teacher 中心完全冻结，故 $\nabla_\theta \widehat{A}_\theta = \nabla_\theta \log p$。其平方损失与 $\text{stopgrad}(\widehat{A}_\theta) \log p$ 在每个 sampled action 上具有相同梯度，而不仅是期望梯度相同。上述结论都针对固定参数与固定条件分布；反复复用一批 rollout 并用它更新参数，还会产生有限数据的优化与泛化误差，不能由条件无偏性消除。

缓存上，CPU/NVMe 保存 token IDs、attention mask、response mask、rollout 动作以及 anchor/teacher action log-prob。Tail-aware 路径另外冻结 anchor 的 top-J IDs、头部 log-prob、尾部总质量和 teacher KL 中心；student 的 action log-prob、这些 IDs 上的 log-prob 和尾部质量每个 inner step 重算。Teacher 中心构造完即可释放其完整 logits，无需保存 teacher 全词表分布。保存完整 logits 的代价是 $O(BH|\mathcal{V}|)$，保存 top-J 摘要是 $O(BHJ)$。以 $|\mathcal{V}| = 150{,}000$、FP16 为例，一个 prefix-token 的完整 logits 约 300 kB，8192 token 单序列约 2.46 GB；因此全词表 logits 不放进 replay buffer。GPU 只保留当前 microbatch 的 student 激活及打分 logits，完成摘要与动作权重计

算后释放不再需要的打分张量。此路径没有额外 anchor token 抽样；中心的条件采样方差为零，但保留定理 2.8 给出的尾部形状偏差。PMD-Part 暂不启用，因为其 $\log Z_k$ 需要另一套估计与误差控制。

Algorithm 5 直接使用 rollout 保存的 (s, a)，每个 token occurrence 具有相同权重。式中的求和是经验训练目标的梯度：若使用 microbatch，将 $|\mathcal{B}_k|^{-1}$ 换成该批有效 response token 的归约权重，并在累积与分布式归约时保持一致。同一轨迹中的 prefix 具有相关性，随机轨迹长度也影响经验归一化；因此这条有限数据实现不意味着总体 token 测度梯度具有有限样本严格无偏性。对固定 prefix 与固定参数，动作来自 π_k 时，MDPO 的 $\pi_{k,n}/\pi_k$ 比率将条件动作期望变换到当前 student；Mean/BPO 原本就在 anchor 测度下定义，故没有该比率。所有三种权重都在当前 inner 参数处重新计算再停止梯度，而不是在 outer 开始时固定至整个 inner loop。

这里 Tail-aware 只替换 Mean/BPO 的数值中心，解析 score-function 权重整体停止梯度。它不是把动作期望改成头部求和：动作仍按 anchor 分布积分或采样，尾部动作仍参与 reward 和 score 更新。MDPO 的期望按当前 student 分布，若使用冻结 anchor 动作，必须乘以停止梯度的 $\pi_{k,n}/\pi_k$ 测度比。由于 Tail-aware 对中心存在负偏差，有限 J 的 Mean/BPO 更新一般属于有偏近似；$J = |\mathcal{V}|$ 时必然恢复精确解析梯度，有限支持集下也可在上述偏差项为零时恢复。参数 EMA 与概率混合也必须分别实现；以下 categorical 验证采用概率混合，真实模型参数 EMA 不能被声称与它等价。算法的 soft 分支要求策略类能表示逐 prefix 的概率混合；一般神经网络策略类不满足这一封闭性，本文真实模型训练采用 hard sync。若另行采用参数 EMA，更新式为 $\theta_{k+1} = (1-\rho)\theta_k + \rho\theta_{k,N}$，并令 $\pi_{k+1} = \pi_{\theta_{k+1}}$；这是另一条动力学，不能套用概率混合的恒等式。

算法中的同步发生在整个 inner loop 结束之后。因而在固定 k 的所有 N 次更新中，rollout 测度、anchor ratio π_k/π_T 以及所有 mirror target 都保持不变；只有 student 参数 $\theta_{k,n}$ 变化。hard sync 令下一轮 anchor 完全等于 inner 末端 student，soft sync 则令下一轮 anchor 是旧 anchor 与 inner 末端 student 的凸组合。完成同步后丢弃 $\widehat{d}_k$，使用新的 π_{k+1} 重新 rollout，而不是继续复用旧 rollout。若 inner loop 没有收敛，$\pi_{k,N}$ 只是当前固定 mirror 子问题的有限步近似解；outer 动力学仍由上述同步映射严格定义。

只有 sampled next token：无完整词表时的估计路径

如果每个 prefix 只有 rollout 中的下一个 token $a \sim \pi_k(\cdot \mid s)$，仍然可以无偏观测 $r_k(s,a)$，但不能从一个样本无偏得到 $\log Z_k(s)$：先估计 Z_k 再取对数会产生 plug-in bias。因此 sampled-token 路径不应把 PMD-Part 的 exact $\log Z_k$ 假装已知。可行选择如下。

第一，使用 BPO 或 PMD-Mean，以同一个 prefix 的多条 sampled actions 估计 conditional center；它们不需要显式的 $\log Z_k$。跨 prefix 的平均值一般不等于这个条件中心，不能替代它。第二，MDPO 直接使用 anchor 采样下的重要性加权 score，所需信息仅为同一个 sampled token 的 teacher、anchor 和当前 student log-prob。第三，如果只有一条 action，却仍想做 PMD-Part，只能使用外部 baseline 或 self-normalized $\widehat{\log Z}$，并在理论和日志中标记其 bias。MDPO 的解析梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{a\sim\pi_k}\left[\mathrm{sg}\left\{\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}\left(\frac{1}{\eta}\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}\right)\right\}\nabla_\theta \log \pi_{k,n}(a \mid s)\right].$$

该等式先在完整分布上微分，再用 $\pi_{k,n}/\pi_k$ 换测度；student 下常数 $1/\eta$ 的 score 项期望为零。因而这里无需额外选择 KL 数值估计器。整个乘数停止梯度，实现的是已解析的梯度；这个 surrogate 的数值不是 mirror objective 的数值。有限冻结数据上的重要性加权结果仍有采样误差，不能把总体无偏性解释为任意数据复用后的条件无偏性。

对单个 sampled token，PMD-Part 的可实现 loss 是带 baseline 的近似

$$\widehat{\ell}_{\mathrm{Part}} = \frac{1}{2}\left[\eta(r_k(s,a) - b(s)) - U_{k,n}(s,a)\right]^2,$$

它只有在 $b(s) = \log Z_k(s)/\eta$ 时才等于 exact residual；任意其他 baseline 会留下一个 prefix-dependent constant，因而改变 PMD-Part 的有限参数投影。BPO 的中心化 residual 则可用同 prefix 的 m 个 sampled tokens 构造，$m = 1$ 时必须使用跨样本或 frozen center。

完整 vocabulary 与 sampled-token 两条路径的区别是信息论上的：前者能精确知道整个 categorical mirror target，后者只能无偏知道在 anchor 下抽到的一个 action 的 reward。对每个给定方法，两条信息访问路径在无限样

本、无函数类误差且 center/partition 估计一致时具有相同总体解；PMD-Mean 的解是 Lambert-W 分布，另外三种方法的解是 Gibbs 分布。有限 batch 下，full-vocabulary 的主要误差是参数优化和 prefix coverage，sampled-token 额外承担 reward、center、KL ratio 和 prefix reuse 的估计方差。

2.6 两个可运行的 OPD baseline

本节固定 baseline 的语义，避免把 “on-policy”、“off-policy” 和 mirror descent 混在同一个名称里。两种 baseline 都使用逐 token 的 OPD reward，但都不使用 $\eta^{-1}\,\mathrm{KL}(p\|\pi_k)$ 这个 mirror 正则项。它们的区别只有动作测度：第一种要求当前 student 重新 rollout，第二种复用冻结 anchor 的 rollout，并用 token-level importance sampling 修正条件动作分布。

令 $q=\pi_k(\cdot\mid s)$、$p_\theta=\pi_\theta(\cdot\mid s)$、$T=\pi_T(\cdot\mid s)$。在固定 prefix 上，OPD 的 reverse-KL 目标为

$$J_s(\theta)=\mathrm{KL}(p_\theta\|T)=\mathbb{E}_{a\sim p_\theta}\left[\log p_\theta(a\mid s)-\log T(a\mid s)\right]. \tag{2.108}$$

写 $r_\theta(s,a)=\log T(a\mid s)-\log p_\theta(a\mid s)$，则对任意 p_θ-可积的 prefix，完整梯度是

$$\nabla_\theta J_s(\theta)=-\mathbb{E}_{a\sim p_\theta}\left[r_\theta(s,a)\nabla_\theta\log p_\theta(a\mid s)\right]. \tag{2.109}$$

常数 1 因为 $\mathbb{E}_{p_\theta}[\nabla\log p_\theta]=0$ 而消失。

vOPD 风格的 baseline 取当前 student 与 teacher 的条件 reverse KL，记为

$$D_\theta(s)=\mathrm{KL}(p_\theta\|T). \tag{2.110}$$

它与 action 无关，因此不会改变总体梯度：

$$\mathbb{E}_{p_\theta}[(r_\theta+D_\theta)\nabla\log p_\theta]=\mathbb{E}_{p_\theta}[r_\theta\nabla\log p_\theta]. \tag{2.111}$$

这个中心是控制变量，不是额外的 mirror penalty。实际实现用固定的 top-J anchor support 加尾部聚合近似 D_θ；$J=|\mathcal{V}|$ 时它是 exact。

2.6.1 On-policy OPD：每次 outer step 重新采样

第 k 个 outer step 先令 $\theta_{k,0}=\theta_k$，从当前 student $p_{\theta_{k,0}}=\pi_k$ 生成 rollout。每个 sampled token 都来自当前测度，所以用

$$\widehat{\ell}_{\mathrm{on}}(\theta;s,a)=-\,\mathrm{sg}(r_\theta(s,a)+D_\theta(s))\log p_\theta(a\mid s) \tag{2.112}$$

进行 score-function 更新。这里 r_θ 和 D_θ 在构造该步梯度后整体停止梯度；它们不是再对同一个 surrogate 反向一次。若 inner 中做 $J>1$ 个 optimizer step 而不重新 rollout，后续 step 已经是 stale-data 更新，不能继续称作严格 on-policy；本书实验将严格 on-policy baseline 定义为 $J=1$。

算法中的负号对应最小化 $\mathrm{KL}(p\|T)$。它只使用一个 sampled action 的 reward；$\widehat{D}$ 只作为 baseline，不能把它与 reward 相加后再把其梯度传回 teacher 或 student。实现中的 `mirror_opd_onpolicy` 正是这个形式，并将 anchor support 的 head 与 aggregate tail 缓存到 CPU/NVMe 可复用的 batch。

2.6.2 Token-IS OPD：复用 anchor rollout

若 rollout 来自 $q=\pi_k$，但 inner 当前 policy 是 p_θ，则对固定 prefix 的测度变换为

$$\mathbb{E}_{a\sim p_\theta}[h(a)]=\mathbb{E}_{a\sim q}\left[\frac{p_\theta(a\mid s)}{q(a\mid s)}h(a)\right]. \tag{2.113}$$

因此 token-IS baseline 使用

$$\widehat{\ell}_{\mathrm{IS}}(\theta;s,a)=-\,\mathrm{sg}\left[\frac{p_\theta(a\mid s)}{q(a\mid s)}\left(r_\theta(s,a)+D_\theta(s)\right)\right]\log p_\theta(a\mid s). \tag{2.114}$$

当 $q(a\mid s)>0$ 且 prefix s 的访问测度固定时，式(**??**) 对 action 条件分布是无偏的。它没有修正 outer rollout 的 prefix occupancy：若 student 在 inner 中改变了前缀分布，整条序列的 ratio $\prod_{t\le l}p_\theta(a_t\mid s_t)/q(a_t\mid s_t)$ 才能修正到

新的轨迹测度，而 token-IS 只修正当前 prefix 下的下一个 token。这是本实验 baseline 的有意限定，避免长序列乘积带来的极端方差。

这里的 `mirror_opd_is` 使用 $J = 4$ 作为 stale-rollout 对照，且每一步重新计算 u_i 与中心；`mirror_opd_is_no_baseline` 则令 $\widehat{D}_\theta = 0$，用于隔离控制变量的作用。重要性权重必须 stop-gradient，否则 surrogate 会多出 ∇w_i 项而不再是式 (**??**) 的 score 估计器。实际训练记录 `importance_ess` 和 `importance_ess_fraction`；当 w_i 重尾时，token-IS 的方差会随 $\mathbb{E}_q[w_i^2]$ 增长，即使其条件期望仍然无偏。

2.6.3 Pythia baseline 实验记录

实验使用 Pythia-14M student、Pythia-70M teacher、WikiText validation prefixes、top-$J = 32$ anchor support、温度 1.0、response length 64、batch 中 1024 有效 token、learning rate 10^{-6} 和 seed 42。两条训练均运行 32 个 outer step；on-policy 每轮只更新一次，token-IS 每轮复用同一 rollout 做 4 个 inner step。评估在固定的 8128 个 prefix 上使用 float32 full-vocabulary teacher forcing，因此评估噪声与训练时的 sampled action 噪声分开。

方法	inner J	初始 $\mathrm{KL}(p\|T)$	最终 $\mathrm{KL}(p\|T)$	初始 $\mathrm{KL}(T\|p)$	最终 $\mathrm{KL}(T\|p)$	最终 ESS fraction
On-policy OPD	1	0.9873	0.9356	0.8907	0.8921	1.0000
Token-IS OPD	4	0.9873	0.9094	0.8907	0.9387	0.9335

两种方法都降低了 $\mathrm{KL}(p\|T)$，所以 baseline 路径和缓存、同步逻辑是可运行的。token-IS 的 teacher-directed reverse KL 降得更多，但 forward KL 上升，且 ESS 降至约 93.35%；这正是用 stale rollout 换取每轮更多 inner 更新的代价。训练日志中的 score coefficient RMS 约为 2.9–3.1，而梯度裁剪前的 norm 约为 1.6×10^3–2.1×10^3，说明当前短实验首先受优化尺度和混合精度路径影响，不能仅凭 32 步断言 token-IS 在长期一定优于 on-policy。此外，旧配置里的 `model_dtype=float32` 只约束权重加载；若未显式设置 FSDP `mixed_precision`，前向仍可能采用 BF16 autocast。正式比较应把这一项写入 resolved config，并同时记录 `dtype`、梯度裁剪、ESS 和 full-vocabulary 固定前缀指标。

Algorithm 5 Tail-aware OPD outer–inner optimization

Semantics: 根据正文重构；冻结 *outer rollout*，以 *Tail-aware KL* 中心运行 *Mean*、*BPO* 或 *MDPO*，再同步并重新 *rollout*

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial student $\pi_0 = \pi_{\theta_{0,0}}$, outer steps K_{out}, rollout batch size $B \geq 1$, horizon $H \geq 1$, method M, $\eta > 0$, inner steps $N \geq 1$, inner learning rate schedule $\{\alpha_{k,n}\}$, sync mode $\text{Sync} \in \{\text{hard}, \text{soft}\}$, soft-sync weight $\rho \in (0, 1]$

Ensure: final policy $\pi_{K_{\text{out}}}$ and parameters $\theta_{K_{\text{out}}}$

for $k = 0, \ldots, K_{\text{out}} - 1$ **do**
  $\mathcal{B}_k \leftarrow \varnothing$ ▷ $\mathcal{B}_k$ stores rollout pairs with multiplicity
  for $i = 1, \ldots, B$ **do**
    sample prompt $x_i \sim \mathcal{D}$
    generate $y_i = (a_{i,1}, \ldots, a_{i,\tau_i})$ with $a_{i,t} \sim \pi_k(\cdot \mid s_{i,t})$, $s_{i,t} = (x_i, a_{i,<t})$; stop at EOS or H tokens
    $\mathcal{B}_k \leftarrow \mathcal{B}_k \uplus \{(s_{i,t}, a_{i,t}) : 1 \leq t \leq \min(\tau_i, H)\}$
  end for
  if $\mathcal{B}_k = \varnothing$, terminate with an empty-rollout error before normalization
  define $\widehat{d}_k$ as the empirical distribution assigning each prefix occurrence in $\mathcal{B}_k$ equal mass
  $\theta_{k,0} \leftarrow \theta_k$ ▷ initialize the inner student from the current outer policy
  query frozen $\log \pi_T(v \mid s)$ and $\log \pi_k(v \mid s)$ for $(s, a) \in \mathcal{B}_k$, $v \in \mathcal{V}$; retain summaries and action log-prob only
  choose and freeze $S_J(s) = \text{TopJ}(\pi_k(\cdot \mid s))$; freeze $\log \pi_k(v \mid s)$ for $v \in S_J(s)$ and $\log \pi_T(a \mid s), \log \pi_k(a \mid s)$ for rollout actions
  $\widehat{\mathcal{K}}_k^T(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s))$ using the same $S_J(s)$ and aggregate tail masses
  omit PMD-Part because it requires $\log Z_k$; use all retained rollout pairs, including tail actions
  for $n = 0, \ldots, N - 1$ **do**
    compute current $\log \pi_{k,n}(v \mid s)$ and $\widehat{\mathcal{K}}_{k,n}^S(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k \| \pi_{k,n})$ on the frozen $S_J(s)$; freeze both centers within this gradient evaluation
    if $M = \text{Mean}$ **then**
      $g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\log \frac{\pi_{k,n}(a|s)}{\pi_k(a|s)} - \eta \left(\log \frac{\pi_T(a|s)}{\pi_k(a|s)} + \widehat{\mathcal{K}}_k^T(s) \right) \right) \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$
    else if $M = \text{BPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\eta^{-1} \left(\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \widehat{\mathcal{K}}_{k,n}^S(s) \right) - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} - \widehat{\mathcal{K}}_k^T(s) \right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    else if $M = \text{MDPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} \left(\eta^{-1} \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} \right) \right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    end if
    $\theta_{k,n+1} \leftarrow \text{OptimizerStep}(\theta_{k,n}, g_{k,n}; \alpha_{k,n})$ ▷ gradient descent: plain SGD gives $\theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  if $\text{Sync} = \text{hard}$ **then**
    $\theta_{k+1} \leftarrow \theta_{k,N}$ and $\pi_{k+1} \leftarrow \pi_{\theta_{k+1}}$
  else
    $\pi_{k+1}(\cdot \mid s) \leftarrow (1 - \rho)\pi_k(\cdot \mid s) + \rho \pi_{k,N}(\cdot \mid s)$ for every prefix s
    choose θ_{k+1} representing this mixture, assuming the policy class is closed under mixtures ▷ categorical probability mixture; neural-model implementation uses hard sync
  end if
end for
return $(\pi_{K_{\text{out}}}, \theta_{K_{\text{out}}})$

Algorithm 6 OPD sampled-token inner update

Semantics: 每个 prefix 只访问 rollout 的下一个 token

Require: frozen anchor π_k, teacher π_T, rollout pairs (s_i, a_i), method M, center size m, η
Ensure: updated student parameters θ

for each prefix s_i **do**
  read $\log \pi_T(a_i \mid s_i)$ and $\log \pi_k(a_i \mid s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  if $M = \text{Mean}$ **then**
    obtain independent auxiliary actions at the same prefix to estimate a frozen reward center $\widehat{\bar{r}}_i$
    $\ell_i \leftarrow \frac{1}{2}[U_{k,n}(s_i, a_i) - \eta\,\text{stopgrad}(r_i - \widehat{\bar{r}}_i)]^2$
  else if $M = \text{BPO}$ **then**
    estimate the reward center and current student log-ratio center at the same prefix
    form a centered residual loss with the $1/(2\eta)$ factor; retain the student center's derivative
    use the finite-sample correction specified in the BPO inner algorithm
  else if $M = \text{MDPO}$ **then**
    $w_i \leftarrow \text{stopgrad}(\pi_{k,n}(a_i \mid s_i)/\pi_k(a_i \mid s_i))$
    $\ell_i \leftarrow \text{stopgrad}\big(w_i[\eta^{-1}\log(\pi_{k,n}(a_i \mid s_i)/\pi_k(a_i \mid s_i)) - r_i]\big)\log \pi_{k,n}(a_i \mid s_i)$
  else if $M = \text{Part}$ **then**
    estimate or load a prefix baseline $\widehat{\log Z_i}$; record its bias source
    update $\frac{1}{2}[\eta r_i - \widehat{\log Z_i} - U_{k,n}(s_i, a_i)]^2$
  end if
end for
perform gradient descent on $B^{-1}\sum_i \ell_i$ while keeping π_k and π_T frozen
return θ

Algorithm 7 On-policy OPD baseline

Semantics: 每个 outer step 用当前 student 重新 rollout；无 mirror 正则

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial policy π_0, outer steps K_{out}, rollout batch B, horizon H
Ensure: $\pi_{K_{\text{out}}}$

for $k = 0, \ldots, K_{\text{out}} - 1$ **do**
  set $\pi_k \leftarrow \pi_{\theta_k}$ and generate (s_i, a_i) with $a_i \sim \pi_k(\cdot \mid s_i)$
  evaluate $\log \pi_k(a_i \mid s_i)$, $\log \pi_T(a_i \mid s_i)$ and the frozen-support estimate $\widehat{D}_{\theta_k}(s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  $g_k \leftarrow -|\mathcal{B}_k|^{-1}\sum_i \text{sg}(r_i + \widehat{D}_{\theta_k}(s_i))\nabla_{\theta_k}\log \pi_{\theta_k}(a_i \mid s_i)$
  $\theta_{k+1} \leftarrow \text{OptimizerStep}(\theta_k, g_k)$
end for
return $\pi_{K_{\text{out}}}$

Algorithm 8 Token-IS OPD baseline

Semantics: 复用 anchor rollout；仅修正 prefix 条件下的 token 测度

Require: frozen anchor $q = \pi_k$, teacher π_T, rollout batch $\mathcal{B}_k$, inner steps J, learning rates $\{\alpha_j\}$
Ensure: θ_{k+1}

initialize $\theta \leftarrow \theta_k$
for $j = 0, \ldots, J - 1$ **do**
  evaluate $\log p_\theta(a_i \mid s_i)$ and frozen-support $\widehat{D}_\theta(s_i)$ for all $(s_i, a_i) \in \mathcal{B}_k$
  $u_i \leftarrow \log p_\theta(a_i \mid s_i) - \log q(a_i \mid s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log p_\theta(a_i \mid s_i)$
  $w_i \leftarrow \text{sg}(\exp u_i)$
  $g_j \leftarrow -|\mathcal{B}_k|^{-1}\sum_i \text{sg}(w_i(r_i + \widehat{D}_\theta(s_i)))\nabla_\theta \log p_\theta(a_i \mid s_i)$
  $\theta \leftarrow \text{OptimizerStep}(\theta, g_j; \alpha_j)$
end for
return $\theta_{k+1} \leftarrow \theta$

第三章 KL 估计量、无偏性与方差

3.1 K4 的无偏性

本节固定 prefix s，记 $p = \pi_{k,n}(\cdot \mid s)$、$q = \pi_k(\cdot \mid s)$，并从 p 采样 a。定义

$$c_{k,n}(s,a) = \frac{p(a)}{\mathrm{stopgrad}(p(a))}, \qquad U_{k,n}(s,a) = \log \frac{p(a)}{q(a)}.$$

数值上 $c_{k,n} = 1$，但其导数为 $\nabla \log p(a)$。

定理 3.1 (K4 value and gradient)

若 $p \ll q$ 且二阶矩有限，则

$$\mathbb{E}_{a\sim p}[c_{k,n}(s,a)U_{k,n}(s,a)] = \mathrm{KL}(p\|q),$$

并且自动微分意义下

$$\mathbb{E}_{a\sim p}[\nabla_{\theta_{k,n}}\{c_{k,n}(s,a)U_{k,n}(s,a)\}] = \nabla_{\theta_{k,n}} \mathrm{KL}(p\|q).$$

♡

证明 数值 value 中 $c_{k,n} = 1$，所以第一式是

$$\mathbb{E}_p[-\log(q/p)] = \sum_a p(a)\log(p(a)/q(a)).$$

对 stop-gradient 构造求导时，$U_{k,n} = \log p - \log q$ 的 derivative 与 $c_{k,n}$ 的 derivative 共同给出

$$\nabla_{\theta_{k,n}}\{c_{k,n}U_{k,n}\} = \nabla_{\theta_{k,n}} \log p(a)\,[\log p(a) - \log q(a)] + \nabla_{\theta_{k,n}} \log p(a).$$

最后一项在 p 下期望为零，第一项正是 KL 的 score-function derivative。 □

K1 的数值也无偏，但其 autograd gradient 为零；K3 的 gradient 对应 $\mathrm{KL}(q\|p)$ 的方向；K2 梯度正确但 value 有偏。上述构造针对 MDPO 中的 $\mathrm{KL}(p\|q)$。BPO 的 student center 是相反方向的 $\mathrm{KL}(q\|p)$，应在冻结 anchor q 下估计 $\log(q/p)$；PMD-Mean 不含这个 student KL center。

3.2 固定 anchor 测度上的重要性校正

若工程上必须从 $q = \pi_k$ 采样，令 $\omega_{k,n}(s,a) = p(a)/q(a)$，并在积分权重上停止梯度。对于任意可积向量 h，

$$\mathbb{E}_q[\mathrm{stopgrad}(\omega_{k,n})h(a)] = \mathbb{E}_p[h(a)].$$

对于 OPD，MDPO 的损失为原始 mirror objective 的负值。其固定 anchor 测度梯度估计为

$$\widehat{g}_i^{\mathrm{MDPO}} = \mathrm{stopgrad}(\omega_{k,n}(s,a_i))\,\mathrm{stopgrad}\left[\frac{1}{\eta}U_{k,n}(s,a_i) - r_k(s,a_i)\right]\nabla_{\theta_{k,n}} \log p(a_i), \qquad a_i \sim q.$$

此处 $p = \pi_{k,n}(\cdot \mid s)$、$q = \pi_k(\cdot \mid s)$。梯度权重与 score 的乘积二阶可积时，估计量无偏；若该乘积范数由 C 上界，则

$$\mathbb{E}_q\|\widehat{g}_i^{\mathrm{MDPO}}\|^2 \le C^2\mathbb{E}_q[(p/q)^2] = C^2\big(1 + \chi^2(p\|q)\big). \tag{3.1}$$

这里的 p/q 测度校正属于 MDPO；不能据此为 PMD-Mean 或 BPO 添加 student importance ratio。它们原本就在冻结 anchor 下定义，action 从 q 采样时无需这种校正。

对 BPO，完整 conditional center 已知时的损失梯度为

$$\nabla_{\theta_{k,n}}\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{\pi_k}\left[\frac{R_{k,n}^{\mathrm{BPO}}(s,a)}{\eta}\nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)\right].$$

对 PMD-Mean，损失梯度为

$$\nabla_{\theta_{k,n}}\mathcal{L}_{\mathrm{Mean}} = \mathbb{E}_{\pi_k}\left[R_{k,n}^{\mathrm{Mean}}(s,a)\,\nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)\right].$$

估计 center 时须区分解析 policy-gradient 权重与 sampled 原始平方损失：前者使用停止梯度的权重，后者的 BPO student center 保留梯度，并采用第二章给出的有限样本系数校正。单个 center 估计量的无偏性不自动保证它嵌入平方损失后的梯度无偏。

3.3 Top-J 与完整词表的关系

如果保存当前策略和 anchor 的 top-J logits，完整 reverse KL 可以拆成

$$\sum_{a\in S_J} p(a)\log\frac{p(a)}{q(a)} + \sum_{a\notin S_J} p(a)\log\frac{p(a)}{q(a)}.$$

第一项可精确计算；第二项不能被简单删除，否则得到截断 KL 而非完整 KL。2602.04417 的 Top-J 估计量在尾部使用 masked sampled K4：固定头部集合 S_J，若采样 token 不在 S_J，加入

$$\mathbf{1}(a\notin S_J)\ \mathrm{stopgrad}\left(\frac{p(a)}{\pi_{\mathrm{sampling}}(a)}\right) c_{k,n}(s,a)U_{k,n}(s,a).$$

它同时保持 value 和 gradient 无偏。完整词表 oracle 与 sampled K4 分别核对 mirror target 和尾部估计误差，二者在实验中单独报告。

3.4 四种 Top-J KL 对象的统一定义

本节分析 student–teacher KL。固定一个 prefix s，局部记号为

$$p(v)=\pi_{k,n}(v\mid s),\qquad q(v)=\pi_T(v\mid s),\qquad \ell(v)=\log\frac{p(v)}{q(v)}.$$

所有结论都是逐 prefix 的；外层 OPD 再对 rollout 诱导的访问测度 d_k 取期望。设 $S_J\subseteq\mathcal{V}$ 是选定的 J 个 token 的支持集，通常取 student 或 teacher 的 top-J。定义

$$P_J=\sum_{v\in S_J} p(v),\qquad Q_J=\sum_{v\in S_J} q(v),\qquad P_{\mathrm{tail}}=1-P_J,\qquad Q_{\mathrm{tail}}=1-Q_J.$$

完整 reverse KL 的精确分解为

$$\mathrm{KL}(p\|q)=\underbrace{\sum_{v\in S_J} p(v)\ell(v)}_{H_J} + P_{\mathrm{tail}}\log\frac{P_{\mathrm{tail}}}{Q_{\mathrm{tail}}} + P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}),\tag{3.2}$$

其中 $\widetilde{p}_{\mathrm{tail}}(v)=p(v)/P_{\mathrm{tail}}$、$\widetilde{q}_{\mathrm{tail}}(v)=q(v)/Q_{\mathrm{tail}}$ 只在 $\mathcal{V}\setminus S_J$ 上定义。式 (**??**) 是后面区分四种方法的核心：它把误差明确分成头部、尾部总质量和尾部内部形状三部分。

3.4.1 Normalized Top-J KL：局部条件分布目标

Normalized Top-J 先把两个分布限制到同一个支持集，再分别归一化：

$$\bar{p}_J(v)=\frac{p(v)}{P_J},\qquad \bar{q}_J(v)=\frac{q(v)}{Q_J},\qquad v\in S_J.$$

其目标定义为

$$\mathcal{K}_J^{\mathrm{norm}}=\mathrm{KL}(\bar{p}_J\|\bar{q}_J)=\frac{H_J}{P_J}+\log\frac{Q_J}{P_J}.\tag{3.3}$$

命题 3.1 (Normalized Top-J 的语义)

$\mathcal{K}_J^{\mathrm{norm}}$ 是支持集条件分布的 KL，而不是完整 KL 的无偏估计量。对固定 prefix，它是确定性的；其条件采样方差为零。只有在额外满足尾部质量和尾部形状误差均可忽略时，它才近似完整 KL。

证明 将 $\bar{p}_J$ 和 $\bar{q}_J$ 代入 KL 定义，得到

$$\sum_{v\in S_J}\frac{p(v)}{P_J}\left(\log\frac{p(v)}{q(v)}+\log\frac{Q_J}{P_J}\right)=\frac{H_J}{P_J}+\log\frac{Q_J}{P_J}.$$

该式只依赖 S_J 内的概率以及两个头部质量，不包含式 (**??**) 中的尾部条件 KL。由于给定 p,q,S_J 后没有随机变量，条件方差为零。它的目标分布本身已经由 (p,q) 改成了 $(\bar{p}_J,\bar{q}_J)$，所以不能称为完整 KL 的无偏估计量。

归一化的必要性是目标稳定性，而不是无偏性。若直接优化未归一化的 H_J，对一个保留 token 的概率求导得到

$$\frac{\partial}{\partial p(v)}p(v)\log\frac{p(v)}{q(v)}=\log\frac{p(v)}{q(v)}+1.$$

在尾部可以吸收剩余质量的参数化下，驻点满足 $p(v)=e^{-1}q(v)$。因此未归一化的局部目标会通过整体压低头部概率来降低损失；归一化后，头部内部的共同缩放被消除，目标只比较相对形状。这个稳定性修复同时带来尾部盲区：$\mathcal{K}_J^{\mathrm{norm}}$ 对 top-J 外的 logit 没有直接梯度，且 top-J 内梯度总和为零。

3.4.2 Truncated Top-J：有偏的头部项

Truncated Top-J 保留完整 KL 分解中的第一项：

$$\mathcal{K}_J^{\mathrm{trunc}}=H_J=\sum_{v\in S_J}p(v)\log\frac{p(v)}{q(v)}. \tag{3.4}$$

它不是 KL，因为头部质量通常不等于一。由式 (**??**)，其逐 prefix 偏差为

$$\mathcal{K}_J^{\mathrm{trunc}}-\mathrm{KL}(p\|q)=-P_{\mathrm{tail}}\log\frac{P_{\mathrm{tail}}}{Q_{\mathrm{tail}}}-P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}). \tag{3.5}$$

尾部条件 KL 非负，因此未归一化截断项总是遗漏一个非负的尾部形状项，但尾部总质量项的符号可以正也可以负。它没有 sampled-token 随机性，固定 prefix 下方差为零；因此在样本很少、尾部 log-ratio 很重时，可能比无偏估计量有更低 RMSE。

3.4.3 EMA Top-J：精确头部加 sampled tail correction

EMA-PG 的 Top-J 估计器把 H_J 和尾部的 sampled-token 修正相加。令 $A\sim p$，定义

$$\widehat{\mathcal{K}}_J^{\mathrm{EMA}}=H_J+\mathbf{1}\{A\notin S_J\}\ell(A). \tag{3.6}$$

定理 3.2 (EMA Top-J 的无偏性)

在 $A\sim p$ 且 $p\ll q$ 时，若 $\mathbb{E}_p[|\ell(A)|]<\infty$，则

$$\mathbb{E}[\widehat{\mathcal{K}}_J^{\mathrm{EMA}}\mid s]=\mathrm{KL}(p\|q).$$

若二阶矩有限，其条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_J^{\mathrm{EMA}}\mid s)=\sum_{v\notin S_J}p(v)\ell(v)^2-\left(\sum_{v\notin S_J}p(v)\ell(v)\right)^2. \tag{3.7}$$

♡

证明 由采样分布为 p，

$$\mathbb{E}\left[\mathbf{1}\{A\notin S_J\}\ell(A)\right]=\sum_{v\notin S_J}p(v)\ell(v).$$

与 H_J 相加后正好得到完整词表 KL。因为 H_J 对固定 prefix 是常数，方差只来自尾部随机变量 $\mathbf{1}\{A\notin S_J\}\ell(A)$，展开其二阶矩即得式 (**??**)。

当 $J=0$ 时，式 (**??**) 是 sampled-token KL；当 $J=|\mathcal{V}|$ 时，它退化为完整 KL。它估计的是完整目标，因此不能把头部重新归一化；归一化会改变期望目标并破坏上述无偏性。

3.4.4 Tail-Aware Top-J：把尾部聚合为虚拟 token

Tail-Aware Top-J 只需要头部概率以及头部总质量，就把尾部聚合成一个虚拟 token：

$$\mathcal{K}_J^{\mathrm{TA}} = H_J + P_{\mathrm{tail}} \log \frac{P_{\mathrm{tail}}}{Q_{\mathrm{tail}}}. \tag{3.8}$$

命题 3.2 (Tail-Aware Top-J 是完整 KL 的下界)

$$\mathcal{K}_J^{\mathrm{TA}} = \mathrm{KL}(p\|q) - P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) \le \mathrm{KL}(p\|q).$$

等号当且仅当尾部条件分布相等，或 $P_{\mathrm{tail}} = 0$。♠

证明 将式 (??) 中的尾部形状项移到右侧即可。KL 非负性给出不等式；等号条件来自 $P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) = 0$。

Tail-Aware 与 normalized Top-J 的差别在于：前者保留 P_{tail} 和 Q_{tail} 的质量差，后者把质量都重新缩放成一。Tail-Aware 仍然有尾部形状偏差，但不会允许 student 通过把质量整体移出 S_J 来逃避 KL 惩罚；它因此是一个有结构的下界，而 normalized Top-J 是条件分布目标。

3.4.5 Tail-Aware 的误差及其与截断项的比较

记尾部质量项为 $m_J = P_{\mathrm{tail}} \log(P_{\mathrm{tail}}/Q_{\mathrm{tail}})$，尾部形状项为 $b_J = P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) \ge 0$。由完整分解，四种对象中两个确定性近似的误差分别为

$$\mathcal{K}_J^{\mathrm{trunc}} - \mathrm{KL}(p\|q) = -(m_J + b_J), \qquad \mathcal{K}_J^{\mathrm{TA}} - \mathrm{KL}(p\|q) = -b_J.$$

因此在经验 prefix 测度 $\widehat{d}$ 上，Tail-Aware 的平均 bias、条件采样方差与 RMSE 为

$$\mathrm{Bias}_{\widehat{d}}(\mathrm{TA}) = -\mathbb{E}_{\widehat{d}}[b_J], \qquad \mathbb{E}_{\widehat{d}}[\mathrm{Var}(\mathcal{K}_J^{\mathrm{TA}} \mid s)] = 0, \qquad \mathrm{RMSE}_{\widehat{d}}(\mathrm{TA}) = \sqrt{\mathbb{E}_{\widehat{d}}[b_J^2]}.$$

平均 bias 的平方一般小于逐 prefix bias 平方的平均，因而零条件方差不意味着 $\mathrm{RMSE} = |\mathrm{Bias}_{\widehat{d}}|$。Tail-Aware 与 Truncated 的逐 prefix 平方误差差为

$$(m_J + b_J)^2 - b_J^2 = m_J(m_J + 2b_J).$$

当 $P_{\mathrm{tail}} \ge Q_{\mathrm{tail}}$ 时，$m_J \ge 0$，Tail-Aware 的平方误差不大于截断项；当 $P_{\mathrm{tail}} < Q_{\mathrm{tail}}$ 时，$m_J < 0$，截断遗漏的质量项与形状项可能相互抵消，此时 Tail-Aware 的 RMSE 不保证小于 Truncated。这个抵消降低的是标量估计误差，不能说明未归一化截断项是更合适的训练目标。

对同一 prefix 上嵌套的支持集 $S_J \subseteq S_{J+1}$，增加一个保留 token 相当于把 Tail-Aware 的虚拟尾部 token 分裂成该 token 与剩余尾部。KL 的链式分解给出

$$\mathcal{K}_{J+1}^{\mathrm{TA}} - \mathcal{K}_J^{\mathrm{TA}} = P_{\mathrm{tail}}\,\mathrm{KL}\left(\left(\frac{p(v)}{P_{\mathrm{tail}}}, \frac{P_{\mathrm{tail}} - p(v)}{P_{\mathrm{tail}}}\right) \middle\| \left(\frac{q(v)}{Q_{\mathrm{tail}}}, \frac{Q_{\mathrm{tail}} - q(v)}{Q_{\mathrm{tail}}}\right)\right) \ge 0.$$

这里的 $P_{\mathrm{tail}}, Q_{\mathrm{tail}}$ 属于分裂前的支持集，v 是新增 token。因此 Tail-Aware 随 J 单调逼近完整 KL，其 bias 的绝对值和 RMSE 也单调不增；这可以直接用于检查真实模型统计中的实现错误。该单调性不要求 teacher 的概率排序与 student 相同。

3.5 四种方法在 OPD 中的选择

如果 OPD 的目标是训练一个稳定的局部 dense reward，$\mathcal{K}_J^{\mathrm{norm}}$ 合理，因为它在可获得的支持集上是合法 KL，且固定 prefix 下无额外采样方差。它必须被解释为局部条件蒸馏，而不能写成完整 KL 的估计量。

如果目标是 vanilla OPD 的完整 reward 或完整 reverse KL，应该使用 $\mathcal{K}_J^{\mathrm{EMA}}$，或者使用 $\mathcal{K}_J^{\mathrm{TA}}$ 作为低方差下界。$\mathcal{K}_J^{\mathrm{trunc}}$ 适合做低方差基线，但需要显式报告尾部偏差。

对本项目的符号约定，使用

$$\mathcal{K}_J^{\mathrm{norm}}, \quad \mathcal{K}_J^{\mathrm{trunc}}, \quad \widehat{\mathcal{K}}_J^{\mathrm{EMA}}, \quad \mathcal{K}_J^{\mathrm{TA}}$$

分别表示上述四个对象。它们不能共用一个 $\mathcal{K}_J$，否则会把“改变训练目标”和“估计同一个完整 KL”混为一谈。

3.6 有限 inner 更新的误差

设方法 M 的总体最优分布为 $\pi_k^{\star,M}$，inner 算法在固定 s 上得到 $\pi_{k,n}$。PMD-Mean 使用 Lambert-W target，另外三种方法使用 Gibbs target $\pi_k^{\star,\mathrm{Gibbs}}$。定义优化误差

$$e_{k,n}(s) = \mathrm{TV}\Big(\pi_{k,n}(\cdot \mid s), \pi_k^{\star,M}(\cdot \mid s)\Big).$$

对参数化损失，假设梯度是 L_{sm}-Lipschitz，随机梯度 $\widehat{g}_n$ 条件无偏且满足

$$\mathbb{E}[\widehat{g}_n \mid \theta_{k,n}] = \nabla\mathcal{L}(\theta_{k,n}), \qquad \mathbb{E}\big[\|\widehat{g}_n - \nabla\mathcal{L}(\theta_{k,n})\|^2 \mid \theta_{k,n}\big] \le \frac{\sigma^2}{B}.$$

普通 SGD 取 $\theta_{k,n+1} = \theta_{k,n} - \alpha\widehat{g}_n$，$0 < \alpha \le 1/L_{\mathrm{sm}}$。由光滑性不等式及条件无偏性，

$$\begin{aligned}\mathbb{E}[\mathcal{L}(\theta_{k,n+1}) \mid \theta_{k,n}] &\le \mathcal{L}(\theta_{k,n}) - \alpha\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2}{2}\mathbb{E}[\|\widehat{g}_n\|^2 \mid \theta_{k,n}] \\ &\le \mathcal{L}(\theta_{k,n}) - \frac{\alpha}{2}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2\sigma^2}{2B}.\end{aligned}$$

设 $\mathcal{L}_*$ 是损失下界，对 $n = 0, \dots, N-1$ 求和得到

$$\frac{1}{N}\sum_{n=0}^{N-1}\mathbb{E}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 \le \frac{2(\mathcal{L}(\theta_{k,0}) - \mathcal{L}_*)}{\alpha N} + \frac{L_{\mathrm{sm}}\alpha\sigma^2}{B}.$$

此式控制平均梯度范数。将它转成 $e_{k,n}$ 的分布误差界还需要局部曲率或梯度与分布距离之间的定量关系。

对采用 student/anchor importance ratio 的 MDPO estimator，方差界包含 $1 + \chi^2(\pi_{k,n}\|\pi_k)$。PMD-Mean 和 BPO 的 anchor-measure estimator 直接分析 residual、score 与 center 的联合二阶矩。

PMD-Mean 到 Gibbs 分布的差异还包含总体目标偏差：

$$\mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Gibbs}}) \le \mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Mean}}) + \mathrm{TV}(\pi_k^{\star,\mathrm{Mean}}, \pi_k^{\star,\mathrm{Gibbs}}).$$

增加 inner steps 只能降低第一项，第二项由均值近似决定。

第四章 Outer 同步与有限 inner 的动力学

4.1 Hard sync 的精确动力学

先考虑每个 history 的 teacher 分布 π_T 不随 outer 改变，并且 PMD-Part、未线性化 BPO 或 MDPO 的 inner 精确收敛到式 (1.10) 的 Gibbs 分布。hard sync 定义为

$$\pi_{k+1} = \frac{\pi_k^{1-\eta}\pi_T^{\eta}}{Z_k}.$$

定理 4.1 (Hard-sync geometric interpolation)

若 $0 < \eta \le 1$ 且初始策略与 π_T 互相绝对连续，则

$$\pi_k(a \mid s) = \frac{\pi_0(a \mid s)^{(1-\eta)^k}\pi_T(a \mid s)^{1-(1-\eta)^k}}{\sum_b \pi_0(b \mid s)^{(1-\eta)^k}\pi_T(b \mid s)^{1-(1-\eta)^k}}. \tag{4.1}$$

并且

$$\log\frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} = (1-\eta)^k \log\frac{\pi_0(a \mid s)}{\pi_T(a \mid s)} - \log C_k(s),$$

其中 $C_k(s)$ 是归一化常数。$\eta = 1$ 时一个 exact inner 将策略直接变成 teacher；$0 < \eta < 1$ 时每一轮只消除比例 η 的 log-density mismatch。

证明 归纳证明。$k = 0$ 显然成立。假设式 (??) 成立，则

$$\pi_{k+1} \propto \pi_k^{1-\eta}\pi_T^{\eta} \propto \pi_0^{(1-\eta)^{k+1}}\pi_T^{(1-\eta)(1-(1-\eta)^k)+\eta}.$$

指数合并为 $1-(1-\eta)^{k+1}$，归一化后得到结论。 □

推论 4.1 (Outer contraction)

在任意固定 s 上，unnormalized log-ratio 的 contraction factor 是 $1-\eta$。若 log-ratio 初始振幅不超过 A_0，则归一化后 total variation 满足

$$\mathrm{TV}(\pi_k, \pi_T) \le \frac{1}{2}\left(e^{2A_0(1-\eta)^k} - 1\right).$$

该界说明小 η 不是免费加稳定性：它把每轮变化缩小，同时把达到相同 teacher proximity 所需的 outer steps 增加到 $O(\eta^{-1}\log(1/\varepsilon))$。

4.2 PMD-Mean 的逐 prefix OPD 动力学

本节固定一个 prefix s，在有限词表 $\mathcal{V}$ 上分析 PMD-Mean 的总体最优解。假设 teacher 与当前 anchor 在每个 token 上均有正概率。每轮 inner 精确求解后执行 hard sync。以下结论描述这一分布空间更新；参数共享、有限 inner、采样误差与 prefix 测度变化需要另外控制。

原始 PMD-Mean 论文的三个相关结论在本地源文件中对应以下标签：

总体解定理：`thm:pmdmean_solution`。

混合正则化解释：`eq:mixed_subproblem`。

精细损失恒等式：`lem:pmdmean_quad_growth`。

本节采用逐 prefix 的 OPD reward 重新推导这些关系，并进一步证明 teacher KL 下降与 outer 收敛。本文乘子 λ 对应未缩放平方损失；若原论文温度为 $\tau = \eta^{-1}$，则 $\lambda = \lambda_{\mathrm{paper}}/\tau^2$。

4.2.1 代入 OPD reward 后的 Lambert-W 更新

固定第 k 轮与 prefix s，局部记

$$\begin{aligned} q_a &= \pi_k(a \mid s), & t_a &= \pi_T(a \mid s), \\ r_a &= \log \frac{t_a}{q_a}, & \kappa &= \mathrm{KL}(q\|t) = -\mathbb{E}_q r, \\ h_a &= r_a + \kappa, & G_a &= \eta h_a. \end{aligned} \tag{4.2}$$

因此 $\mathbb{E}_q h = \mathbb{E}_q G = 0$。待求 student 分布记为 p，其 log-ratio 为 $U_a = \log(p_a/q_a)$。PMD-Mean 的单轮问题是

$$\min_{p_a>0,\ \sum_a p_a=1} L_{\mathrm{Mean}}(p), \qquad L_{\mathrm{Mean}}(p) = \frac{1}{2}\sum_a q_a (U_a - \eta h_a)^2. \tag{4.3}$$

定理 4.2 (OPD 下 PMD-Mean 的精确单轮解)

式 (??) 有唯一全局最优分布 $p^\star$。它满足

$$\begin{aligned} U_a^\star &= \eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right), \\ p_a^\star &= q_a \exp\left\{\eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right)\right\}. \end{aligned} \tag{4.4}$$

这里 $\lambda \geq 0$ 由 $\sum_a p_a^\star = 1$ 唯一确定，并且

$$\lambda = \mathrm{KL}(q\|p^\star). \tag{4.5}$$

若 $q \neq t$，则 $\lambda > 0$，还可以写成

$$p_a^\star = \frac{q_a}{\lambda} W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right). \tag{4.6}$$

若 $q = t$，则 $\lambda = 0$ 且 $p^\star = q = t$。

证明 log-ratio 坐标中的约束是 $\mathbb{E}_q e^U = 1$。拉格朗日函数及一阶条件为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\mathbb{E}_q(U-\eta h)^2 + \lambda(\mathbb{E}_q e^U - 1),$$

$$U_a - \eta h_a + \lambda e^{U_a} = 0.$$

令 $v_a = \eta h_a - U_a$，得到 $v_a e^{v_a} = \lambda e^{\eta h_a}$，从而

$$U_a = \eta h_a - W_0(\lambda e^{\eta h_a}).$$

定义归一化函数

$$\Phi(\lambda) = \sum_a q_a \exp\{\eta h_a - W_0(\lambda e^{\eta h_a})\}.$$

W_0 在非负实轴上严格递增，因此 Φ 连续且严格递减。当 $q \neq t$ 时，h 非恒定；严格 Jensen 不等式给出

$$\Phi(0) = \mathbb{E}_q e^{\eta h} > e^{\eta \mathbb{E}_q h} = 1.$$

当 $\lambda \to \infty$ 时，恒等式

$$e^{\eta h_a - W_0(\lambda e^{\eta h_a})} = \lambda^{-1} W_0(\lambda e^{\eta h_a})$$

说明 $\Phi(\lambda) \to 0$。故存在唯一正根。若 $q = t$，则 $h = 0$，唯一非负根为零。

对构造出的非负乘子，拉格朗日函数的 Hessian 为

$$\nabla_U^2 \mathscr{L} = \mathrm{diag}\big(q_a(1 + \lambda e^{U_a})\big) \succ 0.$$

所以一阶条件确定了拉格朗日函数的唯一全局最小点。在任意可行点上，拉格朗日函数等于原目标，故这个可行最小点也是约束问题的唯一全局最优点。

最后对一阶条件取 q 均值，代入 $\mathbb{E}_q h = 0$ 与 $\mathbb{E}_q e^{U^\star} = 1$：

$$\mathbb{E}_q U^\star + \lambda = 0, \qquad \lambda = -\mathbb{E}_q \log \frac{p^\star}{q} = \mathrm{KL}(q\|p^\star).$$

将 h 展开即可得到式 (??)。

恢复全局记号时，$p^\star = \pi_k^{\star,\mathrm{Mean}}(\cdot \mid s)$，$\kappa = \mathcal{K}_k^T(s)$，而乘子是逐 prefix 的 $\lambda_k(s)$。hard sync 更新为 $\pi_{k+1} = \pi_k^{\star,\mathrm{Mean}}$。式 (??) 展示了 teacher–anchor 概率比如何进入 Lambert-W；W_0 中的修正随动作变化，不能吸收到一个公共配分常数中。

4.2.2 归一化乘子的 Rényi 界

定义 teacher 与 anchor 的混合矩

$$Z_\alpha(q,t) = \sum_a q_a^{1-\alpha} t_a^\alpha, \qquad \alpha > 0. \tag{4.7}$$

当 $\alpha \neq 1$ 时，Rényi 散度满足 $\log Z_\alpha = (\alpha-1) D_\alpha(t\|q)$。$Z_1 = 1$，相关表达式在 $\alpha = 1$ 处按连续延拓理解。

命题 4.1 (OPD 归一化界)

对任意 $\eta > 0$，

$$\frac{Z_\eta (Z_\eta - e^{-\eta\kappa})}{Z_{2\eta}} \le \lambda \le \eta\kappa + \log Z_\eta. \tag{4.8}$$

特别地，$\eta = 1$ 时

$$\frac{1 - e^{-\kappa}}{1 + \chi^2(t\|q)} \le \lambda \le \kappa. \tag{4.9}$$

证明 令 $X_a = e^{\eta h_a}$，$A = \mathbb{E}_q X$，$B = \mathbb{E}_q X^2$。式 (??) 的归一化条件为

$$\lambda = \mathbb{E}_q W_0(\lambda X).$$

先考虑 $\lambda > 0$。利用 W_0 的凹性，

$$\lambda \le W_0(\lambda A).$$

函数 $w \mapsto we^w$ 在非负轴递增，故

$$\lambda e^\lambda \le \lambda A, \qquad \lambda \le \log A.$$

另一方面，$W_0(z) \ge z/(1+z)$。此不等式可以由 $z = we^w$ 与 $(1-w)e^w \le 1$ 验证；$w \ge 1$ 时右侧验证直接成立。再用 Cauchy–Schwarz 得到

$$\begin{aligned} \lambda &\ge \mathbb{E}_q \frac{\lambda X}{1 + \lambda X} \\ &\ge \frac{(\mathbb{E}_q[\lambda X])^2}{\mathbb{E}_q[\lambda X(1+\lambda X)]} = \frac{\lambda A^2}{A + \lambda B}. \end{aligned}$$

消去 λ 并整理，得到 $\lambda \ge A(A-1)/B$。当 $\lambda = 0$ 时，$q = t$，$A = B = 1$，两个界均成立。

OPD reward 的代入给出

$$A = e^{\eta\kappa} Z_\eta, \qquad B = e^{2\eta\kappa} Z_{2\eta}.$$

将它们代回即可得到式 (??)。当 $\eta = 1$ 时，$Z_1 = 1$，且

$$Z_2 = \sum_a \frac{t_a^2}{q_a} = 1 + \chi^2(t\|q),$$

因此得到式 (??)。

4.2.3 Teacher KL 的单步改进

命题 4.2 (精确 Mean 更新的 teacher KL 下降)

单轮精确解满足

$$\mathrm{KL}(p^\star\|t) \le \kappa - \left(\eta^{-1}-1\right)\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q). \tag{4.10}$$

当 $0<\eta\le 1$ 且 $q\neq t$ 时，$\mathrm{KL}(p^\star\|t) < \mathrm{KL}(q\|t)$。

证明 固定由 Mean 解确定的 λ，定义

$$J_\lambda(p) = \mathbb{E}_p r - \eta^{-1}\mathrm{KL}(p\|q) - \frac{\lambda}{2\eta}\chi^2(p\|q).$$

对 p_a 求导并加入归一化乘子 ξ，其一阶条件为

$$r_a - \frac{U_a+1}{\eta} - \frac{\lambda}{\eta}\left(\frac{p_a}{q_a}-1\right) + \xi = 0.$$

Mean 的 KKT 为 $U_a^\star + \lambda p_a^\star/q_a = \eta(r_a+\kappa)$。取 $\xi = \kappa + (1-\lambda)/\eta$，可验证 $p^\star$ 满足上述条件。J_λ 关于 p 的 Hessian 是对角阵，对角项为 $-1/(\eta p_a) - \lambda/(\eta q_a) < 0$；因此 $p^\star$ 是其唯一全局最大点。

比较 $p^\star$ 与可行分布 q，

$$\mathbb{E}_{p^\star} r - \eta^{-1}\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q) \ge J_\lambda(q) = -\kappa.$$

再用

$$\mathrm{KL}(p^\star\|t) = \mathrm{KL}(p^\star\|q) - \mathbb{E}_{p^\star} r$$

得到式 (**??**)。若 $q\neq t$，则 $\lambda>0$。此时 $p^\star\neq q$：否则 KKT 要求 $\eta h_a = \lambda$ 对所有动作成立，而 h 非恒定。这保证 $\chi^2(p^\star\|q)>0$，故在 $0<\eta\le 1$ 时严格下降。

4.2.4 Log-ratio 跨度与 outer 收敛

定义逐 prefix 的 log-ratio 跨度

$$b(q,t) = \max_a \log\frac{q_a}{t_a} - \min_a \log\frac{q_a}{t_a}. \tag{4.11}$$

该量不受公共归一化常数影响。对于正概率分布，$b(q,t)=0$ 当且仅当 $q=t$。

定理 4.3 (精确 Mean outer 的跨度收敛率)

若 $0<\eta\le 1$，则

$$b(p^\star,t) \le \left(1 - \frac{\eta}{1+\eta b(q,t)}\right) b(q,t). \tag{4.12}$$

固定正 teacher、正初始策略和常数 $0<\eta\le 1$，每轮精确 Mean inner 后 hard sync。令 $b_k(s) = b(\pi_k(\cdot\mid s), \pi_T(\cdot\mid s))$，则

$$b_k(s) \le \left(1 - \frac{\eta}{1+\eta b_0(s)}\right)^k b_0(s) \longrightarrow 0. \tag{4.13}$$

因此 $\pi_k(\cdot\mid s)\to\pi_T(\cdot\mid s)$。当 $\eta=1$ 时，单步还满足

$$b_{k+1}(s) \le \frac{b_k(s)^2}{1+b_k(s)}. \tag{4.14}$$

证明 固定本轮 λ,κ，将概率比写成 reward 的连续函数

$$w(r) = \exp\{\eta(r+\kappa) - W_0(\lambda e^{\eta(r+\kappa)})\}.$$

动作 a 的概率比为 $p_a^\star/q_a = w(r_a)$。它满足

$$\log w(r) + \lambda w(r) = \eta(r+\kappa), \qquad \frac{d\log w(r)}{dr} = \frac{\eta}{1+\lambda w(r)} > 0.$$

所以概率比随 reward 严格递增，且其 log-ratio 斜率受到 Lambert-W 修正压缩。对 teacher 的 log-ratio 函数为

$$v(r) = \log w(r) - r, \qquad v'(r) = -1 + \frac{\eta}{1+\lambda w(r)}.$$

在 $0 < \eta \le 1$ 时，$v' \le 0$。设 $r_{\max} = \max_a r_a$、$r_{\min} = \min_a r_a$，并令 $w_{\max} = w(r_{\max})$。由于 w 递增，

$$|v'(r)| \le 1 - \frac{\eta}{1+\lambda w_{\max}} \quad (r_{\min} \le r \le r_{\max}).$$

均值定理因此给出

$$b(p^\star, t) = v(r_{\min}) - v(r_{\max}) \le \left(1 - \frac{\eta}{1+\lambda w_{\max}}\right)(r_{\max} - r_{\min}).$$

由归一化 $\mathbb{E}_q w(r) = 1$，可知 $w_{\max} \ge 1$。其 KKT 与 $\kappa = -\mathbb{E}_q r \le -r_{\min}$ 给出

$$\lambda w_{\max} = \eta(r_{\max} + \kappa) - \log w_{\max} \le \eta(r_{\max} - r_{\min}) = \eta b(q,t).$$

代入即可证明式 (**??**)。

逐轮应用单步界，先得到 $b_{k+1} \le b_k \le b_0$。函数 $x \mapsto 1 - \eta/(1+\eta x)$ 递增，因此每轮收缩因子都不超过 $1 - \eta/(1+\eta b_0) < 1$，归纳得到式 (**??**)。概率归一化同时保证

$$\min_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} \le 0 \le \max_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)}.$$

所以每个动作的 log-ratio 绝对值不超过 $b_k(s)$；跨度趋零推出逐动作概率收敛。最后令 $\eta = 1$ 即得到式 (**??**)。

$\eta = 1$ 的二次上界描述接近 teacher 时的精确 outer 收敛；一般起点上的一次更新仍是 Lambert-W 分布。不同 prefix 的 $b_0(s)$ 可以不同，因此上述逐 prefix 结论不自动给出全 prefix 的统一收敛率。

4.2.5 一般 OPD reward 的大步长极限

原论文对二元 reward 分析 $\tau \to 0$。OPD reward 通常有多个取值，可以直接在其完整取值分布上推广这一极限。以下固定 q, t，只令单轮步长 $\eta \to \infty$。

命题 4.3 (正中心化 log-ratio 的极限分布)

若 $q \ne t$，定义 $[x]_+ = \max\{x, 0\}$ 与

$$c = \sum_a q_a [h_a]_+ > 0.$$

则

$$\frac{\lambda}{\eta} \longrightarrow c, \qquad p_a^\star \longrightarrow \frac{q_a[h_a]_+}{c}. \tag{4.15}$$

证明 $\mathbb{E}_q h = 0$ 且 h 非恒定，所以 $h_{\max} > 0$，并且 $c > 0$。乘子上界给出

$$\lambda \le \log \mathbb{E}_q e^{\eta h} \le \eta h_{\max}.$$

选择满足 $h_a = h_{\max}$ 的动作 a_+。概率归一化意味着 $w(r_{a_+}) = p_{a_+}^\star/q_{a_+} \le 1/q_{a_+}$。于是 KKT 给出

$$\eta h_{\max} = \log w(r_{a_+}) + \lambda w(r_{a_+}) \le \log(1/q_{a_+}) + \lambda/q_{a_+}.$$

故

$$q_{a_+} h_{\max} - \frac{q_{a_+}\log(1/q_{a_+})}{\eta} \le \frac{\lambda}{\eta} \le h_{\max}.$$

λ/η 的任意序列都有收敛子列，其极限 c' 严格为正。沿该子列，当 $h_a > 0$ 时，令 $z_a = \lambda e^{\eta h_a}$。由 $W_0(z) = \log z - \log\log z + o(1)$，

$$\frac{W_0(z_a)}{\eta} \to h_a, \qquad w(r_a) = \frac{W_0(z_a)}{\lambda} \to \frac{h_a}{c'}.$$

当 $h_a = 0$ 时，$w(r_a) = W_0(\lambda)/\lambda = O(\log\eta/\eta) \to 0$。当 $h_a < 0$ 时，$z_a \to 0$，由 $W_0(z) = z(1+o(1))$ 得到 $w(r_a) = e^{\eta h_a}(1+o(1)) \to 0$。有限词表允许逐项取极限，归一化因此要求

$$1 = \lim \sum_a q_a w(r_a) = \frac{\sum_a q_a [h_a]_+}{c'}.$$

所以所有子列极限都等于 c，证明了乘子与分布的整个序列收敛。

二元 reward $r \in \{0,1\}$、成功率 $p = \mathbb{E}_q r$ 时，$\mathbb{E}_q[r-p]_+ = p(1-p)$，因此该一般结论恢复原论文的 $\lambda/\eta \to p(1-p)$。对 OPD，它给出

$$p_a^\star \longrightarrow \frac{q_a[\log(t_a/q_a) + \mathrm{KL}(q\|t)]_+}{\mathbb{E}_q[\log(t/q) + \mathrm{KL}(q\|t)]_+}.$$

Gibbs 在大步长下集中到 t_a/q_a 最大的动作，而 Mean 的极限给所有正中心化 reward 的动作分配质量。这个固定 anchor 的大步长极限与 $0 < \eta \le 1$ 下的 outer teacher 收敛是两个不同结论。

4.2.6 有限 inner 的精细损失恒等式

命题 4.4 (Mean excess loss 的精确分解)

对任意正概率分布 p，

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q\left[\left(\log\frac{p}{p^\star}\right)^2\right] + \lambda\,\mathrm{KL}(p^\star\|p). \tag{4.16}$$

证明 记 $U = \log(p/q)$、$U^\star = \log(p^\star/q)$。展开平方得到

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q(U-U^\star)^2 + \mathbb{E}_q[(U-U^\star)(U^\star - G)].$$

KKT 给出 $U^\star - G = -\lambda p^\star/q$，所以第二项等于

$$-\lambda\mathbb{E}_{p^\star}\log\frac{p}{p^\star} = \lambda\,\mathrm{KL}(p^\star\|p).$$

代回即得所需恒等式。

例如，总体 inner excess loss 不超过 ϵ 时，$\mathbb{E}_q[\log(p/p^\star)^2] \le 2\epsilon$；若 $q \ne t$，还有 $\mathrm{KL}(p^\star\|p) \le \epsilon/\lambda$。接近 teacher 时 λ 趋零，后一个界会变松，因此不能据此声称所有轮次都有统一的 KL 误差控制。

4.2.7 LOO 中心估计与二元分析的迁移范围

命题 4.5 (逐 prefix LOO Mean 的期望损失)

固定 prefix、anchor 和候选 student p，令 $A_1,\dots,A_m \overset{\mathrm{iid}}{\sim} q$，$m \ge 2$。定义

$$\widehat{r}_{-i} = \frac{1}{m-1}\sum_{j\ne i} r(A_j), \qquad \widehat{L}_{\mathrm{Mean}}(p) = \frac{1}{2m}\sum_{i=1}^m \left[U(A_i) - \eta\big(r(A_i) - \widehat{r}_{-i}\big)\right]^2.$$

则

$$\mathbb{E}\widehat{L}_{\mathrm{Mean}}(p) = L_{\mathrm{Mean}}(p) + \frac{\eta^2}{2(m-1)}\,\mathrm{Var}_q[r]. \tag{4.17}$$

证明 令 $\bar r = \mathbb{E}_q r$ 与 $e_{-i} = \widehat{r}_{-i} - \bar r$。第 i 项 residual 为

$$U(A_i) - \eta(r(A_i) - \bar r) + \eta e_{-i}.$$

LOO 保证 e_{-i} 与 A_i 独立，且 $\mathbb{E}e_{-i} = 0$、$\mathbb{E}e_{-i}^2 = \mathrm{Var}_q[r]/(m-1)$。展开平方取期望，交叉项为零，因此

$$\mathbb{E}\left[U(A_i) - \eta(r(A_i) - \widehat{r}_{-i})\right]^2 = \mathbb{E}_q[U - \eta(r-\bar r)]^2 + \frac{\eta^2\,\mathrm{Var}_q[r]}{m-1}.$$

对 i 求均值并乘 $1/2$ 即得结论。不同 LOO residual 之间的依赖不影响这个期望恒等式。

附加项与候选 student 无关。因而在有限词表的可微参数化中，冻结 anchor 与 reward 后，LOO Mean 梯度是总体 Mean 梯度的无偏估计。这里的 $\mathrm{Var}_q[r]$ 是完整 prefix OPD log-ratio 的方差。若对整个词表求和，可以直接计算 reward 均值，此时不产生这项中心采样误差。

原论文二元分析中的 $p(1-p)$、成功率 $J(\pi)$ 和 $1-J(\pi)$ 分别依赖 Bernoulli reward 的方差与成功事件解释。OPD 的 reward 通常连续取值且每轮随 anchor 改变，应使用 $\mathrm{Var}_{\pi_k}[\log(\pi_T/\pi_k)]$、teacher KL 与 log-ratio 跨度。总体 Lambert-W 解、混合 KL–χ^2 解释、归一化界和 excess-loss 恒等式均无需二元假设；二元成功率递推及其统计常数需要重新证明。

式 (**??**) 是固定候选分布的期望恒等式，不能直接替代数据依赖 ERM 的高概率界。要控制训练得到的 student，仍需给出可实现性或逼近误差、策略类复杂度、优化误差以及 reward/log-ratio 的界。逐 prefix 的有限正概率分布给出有限 reward 范围，但这个范围不一定在所有 prefix 与 outer 轮次上一致。式 (**??**) 则说明：统计分析应围绕约束最优分布的 excess loss 展开；将 Lambert-W 修正本身算作不可消失的 target-estimation 误差，会掩盖 Mean 的总体一致性。

4.3 有限 inner 与 stale target

本节先以 Gibbs inner 方法为对象。实际第 k 轮只运行 N_k 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi_k^{\star,\mathrm{Gibbs}}(a \mid s)}\right| \le \varepsilon_k$$

在归一化前成立。则归一化后

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi_k^{\star,\mathrm{Gibbs}}) \le \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.18}$$

几何插值在 log-ratio 振幅上收缩，不能据此前的推论直接宣称 TV 每步以 $1-\eta$ 收缩。定义

$$b_k = \max_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} - \min_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)}.$$

精确 Gibbs 更新把振幅变成 $(1-\eta)b_k$；上述逐 action log-density 误差最多再增加 $2\varepsilon_k$。因此

$$b_{k+1} \le (1-\eta)b_k + 2\varepsilon_k, \tag{4.19}$$

归纳展开得到

$$b_{K_{\mathrm{out}}} \le (1-\eta)^{K_{\mathrm{out}}} b_0 + 2\sum_{j=0}^{K_{\mathrm{out}}-1} (1-\eta)^{K_{\mathrm{out}}-1-j}\varepsilon_j.$$

归一化分布的 log-ratio 最小值不大于零，最大值不小于零，故 $|\log(\pi_{K_{\mathrm{out}}}/\pi_T)| \le b_{K_{\mathrm{out}}}$。由 $\mathrm{TV}(\pi_{K_{\mathrm{out}}}, \pi_T) = \frac{1}{2}\mathbb{E}_{\pi_T}[|\pi_{K_{\mathrm{out}}}/\pi_T - 1|]$ 得

$$\mathrm{TV}(\pi_{K_{\mathrm{out}}}, \pi_T) \le \min\left\{1, \frac{1}{2}(e^{b_{K_{\mathrm{out}}}} - 1)\right\}.$$

若 $\varepsilon_j \le \bar{\varepsilon}$，振幅的稳态上界为 $2\bar{\varepsilon}/\eta$。这给出 Gibbs 方法有限 inner 误差的几何累积关系。

对于 PMD-Mean，取 $0 < \eta \le 1$，有限 inner 输出执行 hard sync，并假设它在所有 action 上满足

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi_k^{\star,\mathrm{Mean}}(a \mid s)}\right| \le \varepsilon_k.$$

由本章 Mean 跨度收缩定理和振幅的三角不等式，得到

$$b_{k+1} \le \left(1 - \frac{\eta}{1+\eta b_k}\right) b_k + 2\varepsilon_k.$$

若已知整个训练段 $b_k \le A_0$，则定义 $c_0 = 1 - \eta/(1+\eta A_0) < 1$，归纳可得

$$b_{K_{\mathrm{out}}} \le c_0^{K_{\mathrm{out}}} b_0 + 2\sum_{j=0}^{K_{\mathrm{out}}-1} c_0^{K_{\mathrm{out}}-1-j}\varepsilon_j.$$

这里的统一跨度上界是附加假设；精确 inner 的初始跨度上界不能自动替代含优化误差的迭代上界。前节 excess-loss 恒等式提供加权均方 log-ratio 和 KL 控制；将其换成上述逐 action 误差，还需要 anchor 最小概率下界等条件。

4.4 Soft sync 的耦合动力学

若 anchor 使用 EMA，令

$$\pi_{k+1} = (1-\rho)\pi_k + \rho\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。对 PMD-Part、BPO 和 MDPO，精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \pi_k^{1-\eta}\pi_T^{\eta}.$$

在固定 prefix 上令 $q=\pi_k$、$t=\pi_T$、$z=\log(q/t)$，假设 $\max_a|z_a|\le\varepsilon$，$\eta$ 固定且 inner 精确求解。归一化 $\mathbb{E}_t e^z = 1$ 的 Taylor 展开给出

$$\mathbb{E}_t z = -\frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3), \qquad \kappa = \mathbb{E}_t[e^z z] = \frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

因此 OPD 的混合配分函数满足

$$\log Z_\eta = \log \mathbb{E}_t e^{(1-\eta)z} = -\frac{\eta(1-\eta)}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

对于 Gibbs 更新，$\log(p^\star/t) = (1-\eta)z - \log Z_\eta$，一阶项为 $(1-\eta)z$。

PMD-Mean 的精确更新使用 Lambert-W target。由式 (**??**)，

$$0 \le \lambda \le \eta\kappa + \log Z_\eta = \frac{\eta^2}{2}\mathbb{E}_t z^2 + O(\varepsilon^3) = O(\varepsilon^2).$$

又因 $G = \eta(-z+\kappa) = O(\varepsilon)$，有 $W_0(\lambda e^G) = O(\varepsilon^2)$。故 Mean 也满足

$$\log(p^\star/t) = z + G - W_0(\lambda e^G) = (1-\eta)z + O(\varepsilon^2).$$

两类精确 inner 的概率空间混合 $q_{\text{new}} = (1-\rho)q + \rho p^\star$，其中 $\rho \in (0,1]$，均满足

$$\begin{aligned} q_{\text{new}}/t &= (1-\rho)e^z + \rho e^{(1-\eta)z+O(\varepsilon^2)} \\ &= 1 + (1-\rho\eta)z + O(\varepsilon^2), \\ \log(q_{\text{new}}/t) &= (1-\rho\eta)z + O(\varepsilon^2). \end{aligned}$$

这是 teacher 附近的局部展开。Mean 的精确全局递推仍由 Lambert-W 决定。较小的 ρ 减缓 anchor 漂移和局部 teacher tracking；有限 inner 或参数 EMA 还需要加入相应误差项。

4.5 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 d_k 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，d_{k+1} 改变，必须额外记录 coverage drift：

$$\varepsilon_k^{\text{visit}} = \mathrm{TV}(d_{k+1}, d_k).$$

若 token loss 在所有 history 上有上界 C，则访问测度改变使目标值的期望变化至多 $2C\varepsilon_k^{\text{visit}}$；若要控制梯度的期望变化，需另行假设逐 prefix 梯度向量的范数不超过 C_g，此时界为 $2C_g\varepsilon_k^{\text{visit}}$。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

第五章 可枚举 Token 实验与实现边界

5.1 实验设置

实验脚本位于 `experiments/toy/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\pi_0 = (0.62, 0.23, 0.10, 0.05), \qquad \pi_T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略 $\pi_{0,0} = (0.70, 0.15, 0.10, 0.05)$ 开始，使用 400 步、学习率 0.15，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。为核对离开 anchor 后的梯度，这个固定 anchor 实验采用偏离 anchor 的初始化。正式 OPD outer–inner 算法从 $\pi_{k,0} = \pi_k$ 开始。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整词表下的中心化 residual 平方损失；MDPO 使用 exact categorical Fisher preconditioner。

5.1.1 画图实验的输入数据与三层数据集

本项目的图不能直接从一批混合的 rollout 日志中生成。每一张图都必须注明它使用的是哪一个策略、哪一个 prefix 测度以及哪一种词表访问方式。实验输入按由易到难分为三层。

第一层是可枚举的 categorical oracle。固定一个 prefix s，直接生成 anchor、teacher 和 student 的完整 logits，并通过 softmax 得到 $\pi_k(\cdot \mid s)$、$\pi_T(\cdot \mid s)$ 和 $\pi_{k,n}(\cdot \mid s)$。anchor 可以用随机 logits 加温度生成，teacher 可以通过独立随机 logits 或与 anchor 具有指定 KL 的混合分布生成。每个 prefix 保存完整的概率向量、两个 log-prob 向量以及 exact

$$\mathcal{K}_k^T(s) = \mathrm{KL}(\pi_k \| \pi_T), \qquad \mathcal{K}_{k,n}^S(s) = \mathrm{KL}(\pi_k \| \pi_{k,n}),$$

和

$$\log Z_k(s) = \log \sum_{v \in \mathcal{V}} \exp\big((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\big).$$

这一层不需要文本数据，也不运行模型 rollout；它提供所有估计量的 ground truth，专门用于画 bias、variance、均方误差和梯度误差曲线。

第二层是真实模型产生的 prefix 数据，但仍然冻结 outer step。先选定一个不参与训练的 prompt 文件 $\mathcal{X} = \{x_i\}_{i=1}^{N_x}$，每个 prompt 只作为输入，不需要人工答案或 reward label。用当前 anchor π_k 对每个 prompt 采样若干条 response，得到

$$s_{i,t} = (x_i, y_{i,<t}), \qquad a_{i,t} = y_{i,t}, \qquad a_{i,t} \sim \pi_k(\cdot \mid s_{i,t}).$$

保存 prompt id、token ids、attention mask、response mask、prefix 长度、anchor 对采样 token 的 log-prob，以及 teacher 对同一 token 的 log-prob。KL 或 $\log Z_k$ 的估计不应把不同 prefix 混在一起：同一 prefix 的多个 next-token 样本才能用于估计条件期望；不同 prefix 只能在外层按照经验访问测度 $\widehat{d}_k$ 聚合。

第三层才是完整的 OPD outer loop。第 k 轮只使用 π_k 生成 rollout，缓存该轮的 prefix 集合和 anchor/teacher 的 token-level log-prob；随后固定这些数据运行 N 个 inner steps，得到 $\pi_{k,N}$，再执行 hard sync 或 soft sync 得到 π_{k+1}。同步后必须重新 rollout，不能把上一轮的 prefix 和旧 anchor log-prob 继续当作新一轮数据。这样得到的序列

$$\{(\widehat{d}_k, \pi_k, \pi_{k,n}, \pi_T) : k = 0, \dots, K_{\mathrm{out}} - 1,\ n = 0, \dots, N\}$$

才是 outer 动力学图的输入。

图中以 J 表示保留的头部 token 数量。对每个固定 prefix，同时记录 full-vocabulary oracle、sampled-token、top-J 三条估计路径。建议先画以下三组图：

1. 在第一层 oracle 上，以 J 或同 prefix 样本数 m 为横轴，画 $\mathcal{K}_k^T$、$\mathcal{K}_{k,n}^S$ 和 $\log Z_k$ 的 bias、standard deviation、RMSE；

2. 在第二层真实 prefix 上，以 inner step n 为横轴，画 exact-oracle 可用部分的 KL、sampled estimator 的方差、anchor–student 的 χ^2 或有效样本量；
3. 在第三层 outer loop 上，以 k 为横轴，分别画 teacher KL、mirror-target KL、policy–anchor KL、token-level loss、rollout reward，以及 hard sync 与 soft sync 的差异。

第一层的分布是唯一可以逐 prefix 得到无偏误差标签的地方，因此必须先完成。第二层用于回答估计量在真实语言模型的长尾词表上是否仍然稳定。第三层只在前两层通过后运行，否则一条性能曲线无法判断变化来自 OPD 本身、prefix 分布漂移、KL 估计偏差还是 inner 优化没有收敛。

5.2 结果

表 **??** 区分有限步优化误差、到 Gibbs 分布的距离和总体目标差异。方法 M 的自身最优分布为 $\pi_0^{\star,M}$，400 步后的 student 为 $\pi_{0,N}$，$N = 400$。PMD-Mean 的最优分布由 Lambert-W 归一化方程求得，其余三种方法的最优分布为 $\pi_0^{\star,\mathrm{Gibbs}}$。定义

$$
\begin{aligned}
e_M^{\mathrm{opt}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,M}),\\
e_M^{\mathrm{Gibbs}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,\mathrm{Gibbs}}),\\
e_M^{\mathrm{target}} &= \mathrm{TV}(\pi_0^{\star,M}, \pi_0^{\star,\mathrm{Gibbs}}).
\end{aligned}
$$

第一项衡量有限步优化误差，第三项衡量方法总体目标的差异。

表 5.1: 固定测度 token inner 的可枚举实验，400 步后结果。

η	方法	e_M^{opt}	e_M^{Gibbs}	e_M^{target}
0.25	PMD-Part	1.11e-03	1.11e-03	0.00e+00
0.25	PMD-Mean	6.81e-04	9.26e-03	9.12e-03
0.25	BPO	1.96e-08	1.96e-08	0.00e+00
0.25	MDPO	8.33e-17	8.33e-17	0.00e+00
0.50	PMD-Part	2.65e-03	2.65e-03	0.00e+00
0.50	PMD-Mean	3.58e-04	6.86e-02	6.85e-02
0.50	BPO	1.23e-04	1.23e-04	0.00e+00
0.50	MDPO	1.25e-16	1.25e-16	0.00e+00
0.80	PMD-Part	2.97e-03	2.97e-03	0.00e+00
0.80	PMD-Mean	4.11e-05	1.90e-01	1.90e-01
0.80	BPO	4.53e-03	4.53e-03	0.00e+00
0.80	MDPO	2.78e-16	2.78e-16	0.00e+00

PMD-Mean 到自身最优解的误差随优化下降，但到 Gibbs 解的距离保留了结构性差异。例如 $\eta = 0.8$ 时，其有限步优化误差为 4.11×10^{-5}，两个总体最优解的距离为 0.1904。继续优化只能消除前者。

BPO 的最优解仍为 Gibbs 分布，但本实验的固定步长与 400 步预算下，$\eta = 0.8$ 时尚有 4.53×10^{-3} 的优化误差。MDPO 使用精确 categorical Fisher 自然梯度，在该四动作问题上达到浮点精度。该结果比较的是指定 optimizer 与预算下的误差，不构成一般模型上的收敛速度排序。

η 同时影响 Gibbs target、Mean 的 Lambert-W target 以及各损失的梯度尺度。Algorithm 5 中 BPO 的 η^{-1} 已显式进入梯度权重，实验使用相同学习率时也保留这个尺度，不能把缩放后的方向当作实际梯度。

5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，核对 Mean 的 Lambert-W 归一化、KKT 条件与最优点梯度；核对 Mean/BPO 的损失及梯度差异恒等式；

2. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
3. 对随机 p, q，用大量样本检查 K4 value 与 exact KL$(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
4. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
5. 检查固定 anchor 采样的 importance correction 在 p/q 接近一时无偏；
6. 人为改变 student 与 anchor 的偏离程度，测量 χ^2 与重要性加权估计方差；增加 inner steps 不保证二者单调上升；
7. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `toy_token_inner.py`（从仓库根用 `PYTHONPATH=src uv run --with torch python` 运行）生成，结果保存在 `results/toy/toy_token_inner.csv`。独立的 `tests/test_kl_estimators.py` 使用 200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 5.6×10^{-5}，gradient 的 ℓ_2 误差为 1.5×10^{-3}。

`tests/test_mean_bpo.py` 进一步核对 Mean 与 BPO 的解析梯度、有限差分、最优点和有限样本尺度修正；它与 toy 实验分别检验推导正确性和有限步优化行为。

5.4 真实语言模型上的四种 Top-J 对照

为了把上一章的四个数学对象放回 OPD 场景，我们使用 GSM8K test 的全部 1,319 个 prompt。Student 为 Qwen3-1.7B，Teacher 为 Qwen3-4B，温度固定为 1.0；每个 prompt 生成一条完整 student rollout。对 rollout 的每个 prefix，打分阶段计算 student 与 teacher 的完整词表分布，随后只保存汇总量和审计样本。打分采用 NF4 权重量化、bf16 计算，因此这里的 full-vocabulary KL 是该量化模型对的 oracle。生成采用 bf16 vLLM，其 sampled token 来自与 NF4 打分略有不同的 proposal；EMA 的理论方差严格按 NF4 student 分布计算，观测误差另行报告。总计得到 350,166 个 prefix。实验元数据、逐 J 汇总和绘图脚本分别位于 `results/qwen3_gsm8k_pair_kl/metadata.json`、`results/qwen3_gsm8k_pair_kl/kl_summary_by_k.csv` 和 `experiments/plotting/plot_pair_kl.py`。

令 S_J 为 student 概率的 top-J 支持集。表 **??** 中的 bias 和 RMSE 都相对于同一 prefix 上的完整

$$\mathcal{K}^{\text{full}}(s) = \mathrm{KL}\big(\pi_{k,n}(\cdot \mid s) \| \pi_T(\cdot \mid s)\big)$$

计算。Truncated、Normalized 和 Tail-Aware 的条件采样方差恒为零；EMA Top-J 的 variance 是一个尾部 sampled token 修正的理论条件方差。四种方法使用完全相同的 prefix 和 student 支持集，没有额外增加每个 prefix 的采样数。Tail-Aware 尾部质量在 float64 下直接累加，避免头部质量接近一时用 $1 - P_J$ 相减丢失精度。审计样本同时保存 teacher 在该支持集上的质量 Q_J 与 Tail-Aware 值。

表 5.2: Qwen3-1.7B student 与 Qwen3-4B teacher 在 GSM8K rollout prefix 上的 Top-J KL 统计。EMA 的 RMSE 是理论 sampled-tail RMSE；Normalized 的 $J = 0$ 未定义。

J	P_J	$\text{bias}_{\text{trunc}}$	$\text{RMSE}_{\text{trunc}}$	RMSE_{EMA}	$\text{bias}_{\text{norm}}$	$\text{RMSE}_{\text{norm}}$
0	0	-0.26932	1.03968	0.80948	–	–
1	0.94208	-0.07672	0.39307	0.68557	-0.26932	1.03968
2	0.98676	-0.02187	0.15337	0.40189	-0.08392	0.54660
4	0.99747	-0.00465	0.04761	0.18864	-0.02629	0.28804
8	0.99949	-0.00094	0.01416	0.08308	-0.00874	0.15007
16	0.99988	-0.00023	0.00488	0.03959	-0.00310	0.08367
32	0.99996	-0.00008	0.00217	0.02249	-0.00127	0.05438

结果体现了四种定义之间的结构性差异。首先，student 的 top-J 质量在 $J = 4$ 时已经达到 0.99747，在 $J = 32$ 时达到 0.99996，所以截断项的偏差和 RMSE 很快下降。其次，EMA Top-J 在任何 J 上都保持理论无偏，但只要尾部 log-ratio 的二阶矩仍然较大，sampled correction 就会带来明显方差；在 $J = 32$ 时它的理论 RMSE 仍为 0.02249，高于截断项的 0.00217。这不是无偏性失效，而是典型的 bias–variance trade-off。

Normalized Top-J 的行为不同。$J = 1$ 时两边都是同一个 point mass，局部 KL 几乎为零，因此相对于完整 KL 的 bias 为 -0.26932。随着 J 增大，条件分布逐渐包含更多质量，RMSE 从 1.03968 降至 0.05438；但在 $J = 32$ 时

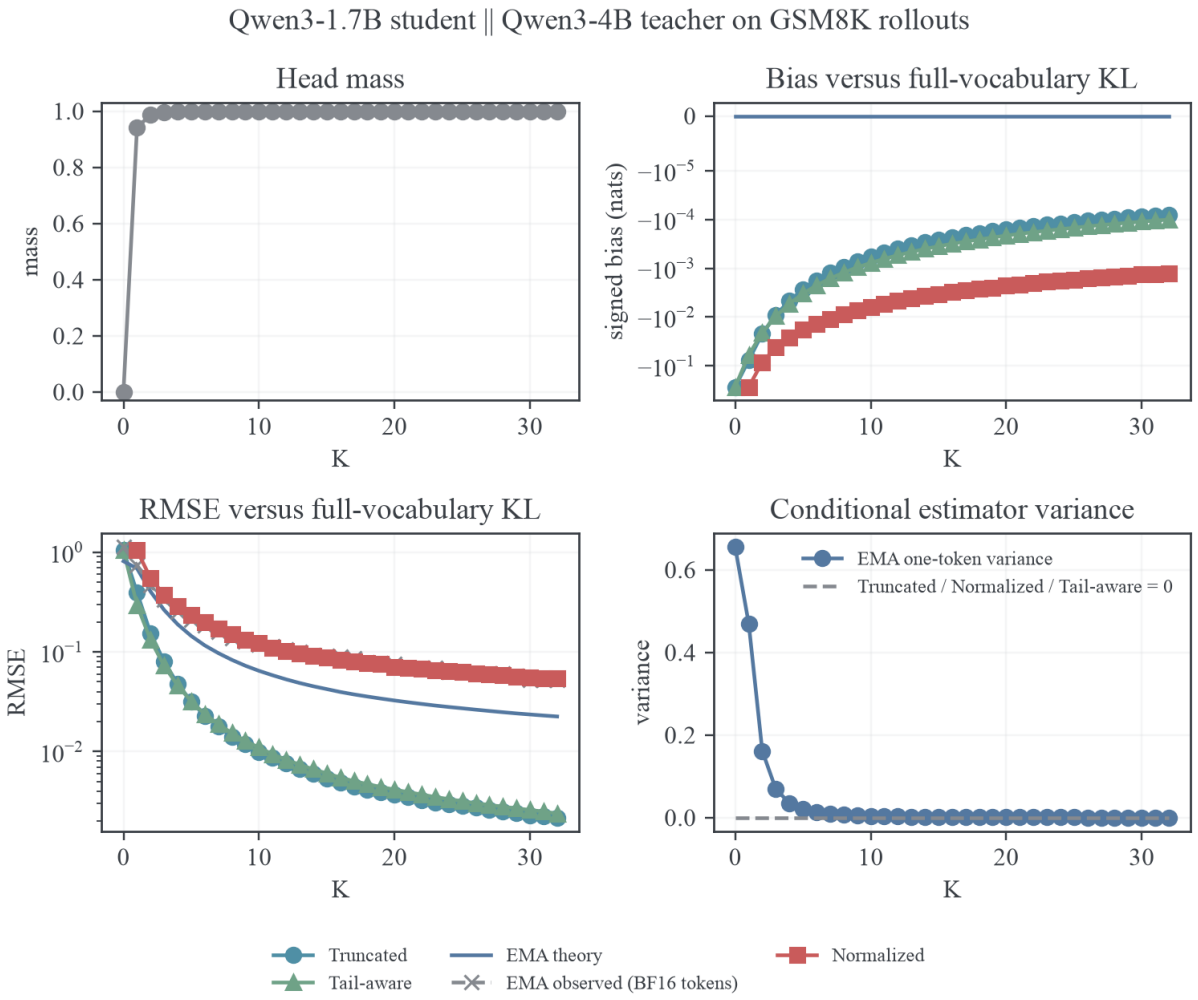


图 5.1: 真实 GSM8K rollout 上四种 Top-J KL 的误差曲线。bias 保留正负号；variance 是固定 prefix 的条件采样方差，不是不同 prefix 之间的数值方差。EMA observed 使用 bf16 rollout token，与 NF4 打分分布的理论曲线分开。

仍明显高于截断项。这说明归一化修复的是局部目标的概率尺度，而不是尾部 token-wise KL。它适合作为 dense local OPD 目标，却不能被解释为完整 KL 的高精度估计量。

Tail-Aware 的全量结果见表 **??**。其 RMSE 随 J 单调下降，符合上一章的支持集细化定理。在 $J = 1, 2, 4$ 时，其 RMSE 小于 Truncated；在 $J = 8, 16, 32$ 时，Truncated 略小。这正对应尾部质量项与尾部形状项的抵消：Tail-Aware 恢复质量项后，剩下的误差严格为非正的尾部形状偏差，而 Truncated 的两个遗漏项可以部分相互抵消。这个标量 RMSE 排序不等于训练稳定性的排序，也不能作为四种 OPD 训练方法最终性能的结论。

这组实验不能支持“所有情况下都应该使用 normalized Top-J”这一结论。它支持更精确的选择规则：当我们需要在有限支持集上构造稳定的多 token 蒸馏 reward 时使用 $\mathcal{K}_J^{\mathrm{norm}}$；当我们需要完整 vanilla OPD KL 的估计时使用 EMA Top-J；当我们希望保留尾部总质量、又不承受 sampled correction 的方差时使用 Tail-Aware Top-J；Truncated Top-J 则作为低方差、有明确尾部偏差的基线。

表 5.3: 同一批 350,166 个 prefix 上补全的 Tail-Aware 结果。条件采样方差在所有 J 上均为零。

J	mean Tail-Aware KL	bias	RMSE
0	0	-0.269321	1.039683
1	0.209759	-0.059561	0.295078
2	0.248414	-0.020907	0.131407
4	0.263978	-0.005343	0.045886
8	0.268091	-0.001230	0.015303
16	0.269006	-0.000315	0.005493
32	0.269220	-0.000101	0.002391

参考资料

PMD-Mean的 reward 中心化目标与 Lambert-W 解依据 arXiv:2602.05933 中的 $\mathcal{L}_{\text{mean}}$ 定义与附录约束优化推导。本文 KL 估计量的记号与 K3^{++}、K4、K5、Top-J 估计量来自 arXiv:2602.04417；One-Shot-OPD 的实现审计见 `upstream/One-Shot-OPD/`。