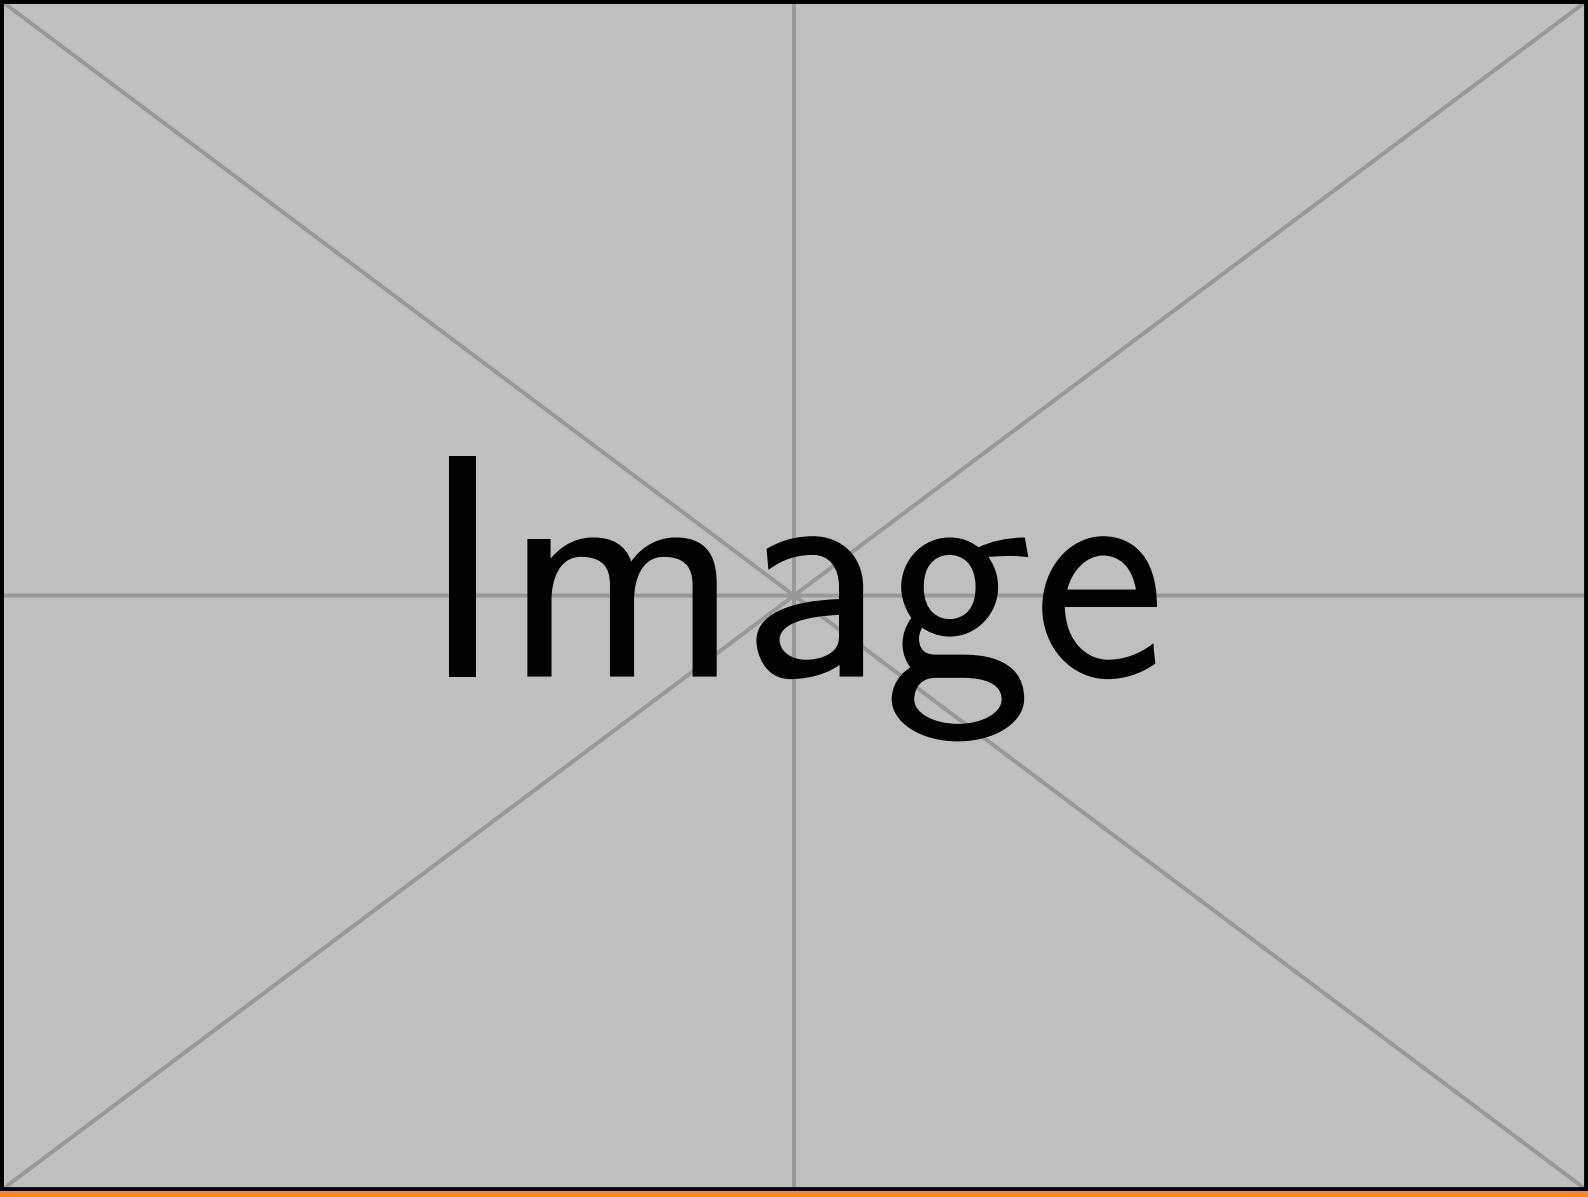


固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

目录

第一章 固定测度的 Token 级优化问题 **1**
1.1 外层同步与内层对象 . . . 1
1.2 原始 mirror 子问题的 Gibbs 解 . . . 1
1.3 Reward 中心化与回归残差 . . . 2
1.4 参数化策略的投影 . . . 2

第二章 统一的 token-level Mirror Descent 与 OPD 实例化 **4**
2.1 共同的 mirror 子问题与精确解 . . . 4
2.2 从镜像最优性方程到四种可训练目标 . . . 5
2.3 四种 inner 的统一推导 . . . 7
2.4 OPD 特化：逐 token reward 与两种信息访问模式 . . . 12

第三章 KL 估计量、无偏性与方差 **24**
3.1 K4 的无偏性 . . . 24
3.2 固定 anchor 测度上的重要性校正 . . . 24
3.3 Top-J 与完整词表的关系 . . . 25
3.4 四种 Top-J KL 对象的统一定义 . . . 25
3.5 四种方法在 OPD 中的选择 . . . 27
3.6 有限 inner 更新的误差 . . . 28

第四章 Outer 同步与有限 inner 的动力学 **29**
4.1 Hard sync 的精确动力学 . . . 29
4.2 PMD-Mean 的逐 prefix OPD 动力学 . . . 29
4.3 有限 inner 与 stale target . . . 35
4.4 Soft sync 的耦合动力学 . . . 36
4.5 访问测度固定的含义 . . . 36

第五章 可枚举 Token 实验与实现边界 **37**
5.1 实验设置 . . . 37
5.2 结果 . . . 38
5.3 正式 LLM 实验前必须通过的检查 . . . 38
5.4 真实语言模型上的四种 Top-J 对照 . . . 39

第一章 固定测度的 Token 级优化问题

1.1 外层同步与内层对象

词表记为 $\mathcal{V}$，prompt为 x，生成序列为 $y_{1:H}$，第 t 个 token 之前的 prefix 为 $s_t = (x, y_{<t})$。第 k 轮 outer 开始时的冻结 anchor 为 π_k，本轮第 n 次 inner 更新的 student 为

$$\pi_{k,n}(a \mid s) = \pi_{\theta_{k,n}}(a \mid s), \qquad \pi_{k,0} = \pi_k. \tag{1.1}$$

教师统一记为 π_T，在本轮 inner 内冻结。d_k 表示由 π_k rollout 诱导的 prefix 访问测度，$\widehat{d}_k$ 表示当前 rollout batch 的经验测度。inner 固定 prefix batch、anchor 和教师，只更新 student 参数。

全篇使用同一组 log-ratio 和 KL 记号：

$$U_{k,n}(s,a) \coloneqq \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}, \tag{1.2}$$

$$r_k(s,a) \coloneqq \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}, \tag{1.3}$$

$$\mathcal{K}_k^T(s) \coloneqq \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s)), \tag{1.4}$$

$$\mathcal{K}_{k,n}^S(s) \coloneqq \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_{k,n}(\cdot \mid s)). \tag{1.5}$$

因此 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}_k^T(s)$，$\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}_{k,n}^S(s)$。前者是冻结 teacher reward 的均值，后者随 student 更新变化。通用 mirror 问题中的信号记为 f，其冻结中心化 target 为 $G_k = \eta(f - \mathbb{E}_{\pi_k}[f \mid s])$。OPD 实例化时取 $f = r_k$，因此

$$G_k(s,a) \coloneqq \eta\big(r_k(s,a) + \mathcal{K}_k^T(s)\big), \qquad \mathbb{E}_{\pi_k}[G_k \mid s] = 0. \tag{1.6}$$

score 向量记为 $\psi_{k,n}(s,a) = \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$，其 anchor 条件均值为 $\bar{\psi}_{k,n}(s) = \mathbb{E}_{\pi_k}[\psi_{k,n} \mid s]$。

镜像系数为 $\eta > 0$，inner 学习率为 $\alpha_{k,n}$。outer 总步数为 K_{out}，每轮 inner 步数为 N，rollout batch 大小为 B，同一 prefix 的辅助 action 样本数为 m，保留的头部 token 数为 J。展开截断阶数用 L，避免与头部大小混用。所有损失统一最小化，算法使用其梯度 $g_{k,n} = \nabla_{\theta_{k,n}} \mathcal{L}$ 执行下降。

同步在 inner 结束后进行。hard sync 取 $\pi_{k+1} = \pi_{k,N}$；概率空间的 soft sync 取

$$\pi_{k+1} = (1-\rho)\pi_k + \rho \pi_{k,N}, \qquad \rho \in (0,1]. \tag{1.7}$$

参数 EMA 是这个概率混合映射的实现近似，需要另行说明。$\lambda_k(s)$ 只表示 PMD-Mean 的归一化乘子，γ 表示自然梯度阻尼。student/anchor importance ratio 记为 $\omega_{k,n} = \pi_{k,n}/\pi_k$，K4 的 score surrogate 记为 $c_{k,n} = \pi_{k,n}/\operatorname{sg}(\pi_{k,n})$，其中 sg 表示停止梯度。

我们研究的 inner 子问题是

$$\max_{p \in \Delta(\mathcal{V})} \mathcal{J}_{k,s}(p) = \mathbb{E}_{a \sim p}[r_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p \| \pi_k), \qquad \eta > 0. \tag{1.8}$$

这里的 p 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 s 不随 inner 更新；它不意味着优化变量 p 必须等于采样分布 π_k。

1.2 原始 mirror 子问题的 Gibbs 解

令

$$Z_k(s) = \sum_{a \in \mathcal{V}} \pi_k(a \mid s) \exp(\eta r_k(s,a)).$$

由于 $r_k = \log \pi_T - \log \pi_k$，有

$$Z_k(s) = \sum_a \pi_k(a \mid s)^{1-\eta} \pi_T(a \mid s)^{\eta}. \tag{1.9}$$

定理 1.1 (Token mirror target)

若有限词表上 $\pi_k(a \mid s) > 0$ 且 $\pi_T(a \mid s) > 0$ 对每个 action 成立，则式 (1.8) 的唯一最大点为

$$\pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \frac{\pi_k(a \mid s)\exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\pi_k(a \mid s)^{1-\eta}\pi_T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.10}$$

并且对任意 p，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}). \tag{1.11}$$

♡

证明 由式 (1.10)，

$$\log \pi_k^{\star,\mathrm{Gibbs}}(a \mid s) = \log \pi_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\begin{aligned}\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}) &= \sum_a p(a \mid s)\left[\log\frac{p(a \mid s)}{\pi_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s)\right] \\ &= \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[r_k] + \log Z_k(s).\end{aligned}$$

移项得到式 (1.11)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时为零，所以最大点唯一。 □

推论 1.1 (几何插值与极限)

当 $\eta \to 0^+$ 时 $\pi_k^{\star,\mathrm{Gibbs}} \to \pi_k$；当 $\eta = 1$ 时 $\pi_k^{\star,\mathrm{Gibbs}} = \pi_T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log \pi_k^{\star,\mathrm{Gibbs}} = (1-\eta)\log \pi_k + \eta \log \pi_T - \log Z_k.$$

因此 η 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

♡

1.3 Reward 中心化与回归残差

定义 $\bar{r}_k(s) = \mathbb{E}_{a\sim\pi_k}[r_k(s,a)] = -\mathcal{K}_k^T(s)$。将 reward 换成 $r_k - \bar{r}_k$ 后，配分函数为

$$\mathbb{E}_{\pi_k}[e^{\eta(r_k-\bar{r}_k)}] = e^{-\eta\bar{r}_k}Z_k.$$

分子和配分函数同乘一个 action 无关的常数，原始 mirror 问题的 Gibbs 解不变。下面的平方回归需要区分完整配分函数与均值近似。

三个 residual 全部采用 student 减 target 的方向：

$$R_{k,n}^{\mathrm{Part}}(s,a) \coloneqq U_{k,n}(s,a) - \eta r_k(s,a) + \log Z_k(s), \tag{1.12}$$

$$R_{k,n}^{\mathrm{Mean}}(s,a) \coloneqq U_{k,n}(s,a) - G_k(s,a), \tag{1.13}$$

$$R_{k,n}^{\mathrm{BPO}}(s,a) \coloneqq U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}_{k,n}^S(s). \tag{1.14}$$

PMD-Part 的零残差对应 $\pi_{k,n} = \pi_k^{\star,\mathrm{Gibbs}}$。PMD-Mean 以 $\eta\bar{r}_k$ 近似 $\log Z_k$，仅中心化 reward。对非恒定 reward，由严格 Jensen 不等式有 $\mathbb{E}_{\pi_k}[e^{G_k}] > 1$，所以拟合值 $U = G_k$ 不满足概率归一化，最优残差不能为零。其总体最优分布记为 $\pi_k^{\star,\mathrm{Mean}}$，由第二章的 Lambert-$W$ 解确定。

BPO 则中心化完整的 student–target residual。其 residual 均值为零，而 Mean 的 residual 均值为 $-\mathcal{K}_{k,n}^S$。这些定义直接区分两个目标，无需额外改变 residual 符号。

1.4 参数化策略的投影

实际神经网络只能表示参数化策略族。固定 prefix 测度 d_k 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{Part}}(\theta_{k,n}) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{1.15}$$

若模型在每个 history 上可以实现式 (1.10)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章沿用第一章的 outer–inner 记号：π_k 是冻结 anchor，$\pi_{k,n}$ 是当前 student，π_T 是 teacher，d_k 是冻结 prefix 访问测度。所有梯度均在 $\theta = \theta_{k,n}$ 处计算。以下先对一般冻结信号 f 推导，再取 OPD 信号 $f = r_k$。

2.1 共同的 mirror 子问题与精确解

定义 2.1 (Token-level mirror 子问题)

给定固定历史 s、token 信号 $f(s,a)$ 和 anchor π_k，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.1}$$

镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。同时定义配分函数

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

♣

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\Big(p\Big\|\pi_k^{\star,\mathrm{Gibbs}}(\cdot \mid s)\Big). \tag{2.4}$$

♡

证明 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^{\star,\mathrm{Gibbs}}(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p\|\pi_k^{\star,\mathrm{Gibbs}}) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^{\star,\mathrm{Gibbs}}$ 时取零，因此最优解唯一。

定义 2.2 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

♣

命题 2.1 (优势函数的 anchor 条件均值)

若 $f(s,a) = A^{\pi_k}(s,a)$，则对每个满足 $\pi_k(\cdot \mid s)$ 定义的历史，

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}[f(s,a) \mid s] = 0. \tag{2.5}$$

对于一般 OPD log-ratio 或 teacher score，条件均值需要计算或估计；PMD-Mean 与 BPO 使用相应的中心化 target。

♠

证明 由 $A^{\pi_k}(s,a) = Q^{\pi_k}(s,a) - V^{\pi_k}(s)$ 以及 $V^{\pi_k}(s) = \mathbb{E}_{a\sim\pi_k}[Q^{\pi_k}(s,a) \mid s]$，有

$$\begin{aligned}\mathbb{E}_{\pi_k}[A^{\pi_k}(s,a) \mid s] &= \mathbb{E}_{\pi_k}[Q^{\pi_k}(s,a) \mid s] - V^{\pi_k}(s) \\ &= V^{\pi_k}(s) - V^{\pi_k}(s) = 0.\end{aligned}$$

命题 2.2 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.1) 的最优分布。

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是孤立的分布结论，而是一条可以被 inner optimizer 直接拟合的逐 token 方程。下面先把这条方程、平方损失和 BPO 的中心化残差逐步写出，再进入四种算法的实现。

2.2.1 镜像最优性方程与训练测度

把式(2.3) 移项，得到

$$\log \frac{\pi_k^{\star,\mathrm{Gibbs}}(a \mid s)}{\pi_k(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.6}$$

在参数化 inner 中，左侧由 $\pi_{k,n}$ 近似。因此定义镜像方程残差

$$R_{k,n}^{\mathrm{Part}}(s,a) \coloneqq \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s). \tag{2.7}$$

精确 mirror 解的条件是 $R_{k,n}^{\mathrm{Part}}(s,a) = 0$ 对所有有正概率的 (s,a) 成立。

为什么训练测度是 π_k 而不是 $\pi_{k,n}$？在第 k 个 outer step，rollout 已由冻结的 π_k 产生；我们要解决的是固定 anchor 的 mirror 子问题，而不是在 inner 过程中不断改变积分测度。于是参数化投影定义为

$$\|R_{k,n}^{\mathrm{Part}}\|_k^2 \coloneqq \mathbb{E}_{s\sim d_k}\mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[R_{k,n}^{\mathrm{Part}}(s,a)^2\right]. \tag{2.8}$$

这也是 on-policy rollout 下可直接估计的投影几何。若改用行为测度 β_k 采样，必须乘以冻结的 importance weight $\pi_k(a \mid s)/\beta_k(a \mid s)$，否则求解的是 $L_2(d_k\beta_k)$ 投影。

2.2.2 PMD-Part 与 PMD-Mean：从方程到平方损失

PMD-Part直接最小化式(2.7) 的平方。将 student log-ratio 和冻结 target 展开，得到

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k, a\sim\pi_k}\left[\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \mathrm{sg}(\log Z_f(s))\right]^2. \tag{2.9}$$

其中 sg 表示停止梯度；π_k、f 和 Z_f 在本轮 inner 中都冻结。因为

$$\nabla_\theta \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} = \nabla_\theta \log \pi_{k,n}(a \mid s),$$

其梯度为

$$\nabla_\theta\mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_k,\pi_k}\left[\mathrm{sg}\left(\log \frac{\pi_{k,n}}{\pi_k} - \eta f + \log Z_f\right)\nabla_\theta \log \pi_{k,n}(a \mid s)\right]. \tag{2.10}$$

这说明 PMD-Part 是 anchor 测度下对完整 mirror log-ratio 的 L_2 投影，而不是把一个 teacher label 当作普通的 supervised token label。

PMD-Mean 使用原论文的均值近似，而不是对 student log-ratio 做条件中心化。使用第一章定义的冻结 target $G_k(s,a) = \eta(f(s,a) - \bar{f}_k(s))$。将完整 target 中的 $\log Z_f(s)$ 用 $\eta\bar{f}_k(s)$ 近似，得到

$$\mathcal{L}_{\text{Mean}}(\theta) = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}\left[\log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta\big(f(s,a) - \bar{f}_k(s)\big)\right]^2. \tag{2.11}$$

这里的 reward center 在整个 inner loop 冻结；损失中没有 $\mathrm{KL}(\pi_k\|\pi_{k,n})$。定义 $R^{\text{Mean}}_{k,n} = U_{k,n} - G_k$，直接求导得到

$$\nabla_\theta\mathcal{L}_{\text{Mean}} = \mathbb{E}_{d_k,\pi_k}\left[(U_{k,n} - G_k)\nabla_\theta\log\pi_{k,n}(a \mid s)\right]. \tag{2.12}$$

均值近似遗漏的归一化修正是

$$\log Z_f(s) - \eta\bar{f}_k(s) = \log\mathbb{E}_{\pi_k}[e^{G_k(s,\cdot)} \mid s] \geq 0.$$

非恒定信号对应严格正值，此时 G_k 不满足指数归一化约束。因此 PMD-Mean 即使具有完整函数类和无限样本，也不恢复原始 Gibbs 解；其受约束总体解见定理 2.2。若改为拟合 $U_{k,n} - \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - G_k$，得到的是后面的 BPO 中心化残差，已经改变了 PMD-Mean 的目标。

2.2.3 BPO：中心化最优性残差

BPO将镜像方程残差按冻结 anchor 条件中心化。配分函数项是 action-independent 常数，中心化后消失：

$$R^{\text{BPO}}_{k,n}(s,a) \coloneqq U_{k,n}(s,a) - \eta f(s,a) - \mathbb{E}_{\pi_k}[U_{k,n}(s,\cdot) - \eta f(s,\cdot) \mid s] \tag{2.13}$$

$$= U_{k,n}(s,a) - G_k(s,a) + \mathcal{K}^S_{k,n}(s). \tag{2.14}$$

这里 $\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}^S_{k,n}$，所以 student KL 前是正号。OPD 中 $f = r_k$，故

$$R^{\text{BPO}}_{k,n}(s,a) = \log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^S_{k,n}(s) - \eta\left(\log\frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} + \mathcal{K}^T_k(s)\right). \tag{2.15}$$

BPO 最小化

$$\mathcal{L}_{\text{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R^{\text{BPO}}_{k,n})^2]. \tag{2.16}$$

使用第一章定义的 score $\psi_{k,n}$ 及其 anchor 均值 $\bar{\psi}_{k,n}$，保留 student KL 的导数得到

$$\nabla_\theta\mathcal{K}^S_{k,n} = -\bar{\psi}_{k,n}, \qquad \nabla_\theta R^{\text{BPO}}_{k,n} = \psi_{k,n} - \bar{\psi}_{k,n}.$$

因此精确梯度为

$$\nabla_\theta\mathcal{L}_{\text{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R^{\text{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n})] \tag{2.17}$$

$$= \mathbb{E}_{d_k,\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}^S_{k,n}}{\eta} - f + \bar{f}_k\right)\psi_{k,n}\right]. \tag{2.18}$$

第二行使用 $\mathbb{E}_{\pi_k}[R^{\text{BPO}}_{k,n} \mid s] = 0$，已把 η^{-1} 乘入权重。梯度下降使用上述梯度的负值。消失的是 residual 均值乘以 score 均值，score 的 anchor 期望 $\bar{\psi}_{k,n}$ 本身通常不为零。

2.2.4 MDPO：最小化原始 mirror objective 的负值

MDPO使用原 mirror objective 的负值作为损失，统一执行梯度下降：

$$\mathcal{L}_{\text{MDPO}}(\theta) = -\mathbb{E}_{s\sim d_k,a\sim\pi_{k,n}}[f(s,a)] + \frac{1}{\eta}\mathbb{E}_{s\sim d_k}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.19}$$

逐历史应用式 (2.4)，得到

$$\mathcal{L}_{\text{MDPO}}(\theta \mid s) = -\frac{1}{\eta}\log Z_f(s) + \frac{1}{\eta}\,\mathrm{KL}(\pi_{k,n}(\cdot \mid s)\|\pi^{\star,\text{Gibbs}}_k(\cdot \mid s)). \tag{2.20}$$

这里 KL 的左侧分布是当前 student，与 $\mathcal{K}^S_{k,n} = \mathrm{KL}(\pi_k\|\pi_{k,n})$ 的方向不同。

对 student 测度和 log-ratio 同时求导，有

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}} = \mathbb{E}_{d_k,\pi_{k,n}}\left[\left(\frac{U_{k,n}+1}{\eta} - f\right)\psi_{k,n}\right] \tag{2.21}$$

$$= \mathbb{E}_{d_k,\pi_{k,n}}\left[\mathrm{sg}\left(\frac{U_{k,n}}{\eta} - f\right)\psi_{k,n}\right]. \tag{2.22}$$

第二行使用 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n} \mid s] = 0$。其下降方向是 $-\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，无需把 η 吸收进 optimizer 步长。

命题 2.3 (平方回归的投影含义)

若 student 函数类不能表示式(2.6) 的右侧，PMD-Part 的精确 inner 解是镜像方程在函数类诱导的 $L_2(d_k\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 ν，投影也相应变为 $L_2(\nu\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。

证明 平方损失定义了可行 log-ratio 集合上的最小距离问题。对任意光滑可行曲线的一阶切向扰动 v，局部最优残差 $\mathscr{E}^\star$ 满足

$$\mathbb{E}_{\nu,\pi_k}[\mathscr{E}^\star v] = 0.$$

这是残差与可行切空间正交的必要条件。参数化可行集合通常非凸，该条件本身不保证全局最优。若 target 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

2.3 四种 inner 的统一推导

下面保留各方法特有的归一化、采样校正与更新几何。直接对原始损失反向传播时，student的全部参数依赖均保留；使用解析 policy-gradient surrogate 时，权重整体停止梯度。

2.3.1 PMD-Part：回归完整 Gibbs log-ratio

PMD-Part 的损失已在式 (2.9) 定义。

$$\mathcal{L}_{\mathrm{Part}} = \frac{1}{2}\mathbb{E}_{d_k,\pi_k}[(R^{\mathrm{Part}}_{k,n})^2], \qquad R^{\mathrm{Part}}_{k,n} = U_{k,n} - \eta f + \log Z_f. \tag{2.23}$$

固定 history 后，anchor 与 target 冻结，逐步求导得到

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \frac{1}{2}\nabla_\theta \sum_a \pi_k(a \mid s)(R^{\mathrm{Part}}_{k,n}(s,a))^2 \tag{2.24}$$

$$= \sum_a \pi_k(a \mid s) R^{\mathrm{Part}}_{k,n}(s,a)\nabla_\theta U_{k,n}(s,a) \tag{2.25}$$

$$= \mathbb{E}_{\pi_k}[R^{\mathrm{Part}}_{k,n}\psi_{k,n} \mid s]. \tag{2.26}$$

梯度下降方向为 $-\mathbb{E}_{\pi_k}[R^{\mathrm{Part}}_{k,n}\psi_{k,n} \mid s]$。这是固定 anchor 下的 log-ratio regression，不使用 student-to-anchor 的 action-level importance ratio。

若实际 rollout 来自行为测度 β_k，而目标仍是 $L_2(\pi_k)$ 投影，则每个 sampled 平方损失项乘以冻结权重 $\mathrm{sg}(\pi_k(a \mid s)/\beta_k(a \mid s))$。不加这个权重时，算法仍然有清晰含义，但求解的是 $L_2(\beta_k)$ 投影。

2.3.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.27}$$

Algorithm 1 PMD-Part inner update

Semantics: 固定 *anchor* 下的完整 *Gibbs log-ratio* 回归

Require: frozen π_k, teacher signal f, histories $\{s_i\}_{i=1}^{B}$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for $i = 1, \dots, B$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $\log Z_i \leftarrow \mathrm{logsumexp}_{v\in\mathcal{V}}(\log \pi_k(v \mid s_i) + \eta f(s_i, v))$
  $H_i \leftarrow \eta f(s_i, a_i) - \mathrm{stopgrad}(\log Z_i)$
  $U_i \leftarrow \log \pi_{k,n}(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\ell_i \leftarrow \frac{1}{2}\big(U_i - \mathrm{stopgrad}(H_i)\big)^2$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

定理 2.2 (PMD-Mean 的逐历史 Lambert-W 投影)

在有限词表、$\pi_k(a \mid s) > 0$ 且约束可行时，上述仅中心化 reward 的平方回归具有唯一全局最小点，其 KKT 解满足

$$U_a = G_a - W_0\big(\lambda_k(s) e^{G_a}\big), \qquad G_a = \eta \widetilde{f}_k(s, a), \tag{2.28}$$

其中 $\lambda_k(s) \geq 0$ 由 $\sum_a \pi_k(a \mid s) e^{U_a} = 1$ 唯一确定。 ♡

证明 以下给出固定历史 s 的 KKT 推导。令词表上的函数值为 U_a 和 $G_a = \eta \widetilde{f}_k(s, a)$，拉格朗日函数为

$$\mathscr{L}(U, \lambda_k) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda_k \left(\sum_a \pi_k(a \mid s) e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda_k e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda_k e^{G_a}$，所以

$$U_a = G_a - W_0\big(\lambda_k e^{G_a}\big), \tag{2.29}$$

其中 λ_k 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda_k) = \sum_a \pi_k(a \mid s) \exp\big(G_a - W_0(\lambda_k e^{G_a})\big), \qquad \lambda_k \geq 0.$$

由于 $\mathbb{E}_{\pi_k}[G \mid s] = 0$，Jensen 不等式给出 $\Phi(0) = \mathbb{E}_{\pi_k}[e^G \mid s] \geq 1$。Lambert–$W$ 的主分支在非负轴上严格递增，所以 Φ 连续且严格递减，且 $\Phi(\lambda_k) \to 0$ 当 $\lambda_k \to \infty$。因此归一化方程有唯一非负根；非恒定 G 对应严格正根，$G \equiv 0$ 时根为零。

对于该根 $\lambda_k \geq 0$，拉格朗日函数的 Hessian 是

$$\nabla_U^2 \mathscr{L} = \mathrm{diag}\big(\pi_k(a \mid s)(1 + \lambda_k e^{U_a})\big) \succ 0.$$

因此构造出的 U 唯一最小化这个拉格朗日函数。所有满足归一化约束的 U 都有 $\mathscr{L}(U, \lambda_k) = \mathcal{L}_{\mathrm{Mean}}(U)$，构造的最小点又满足约束，故它是原受约束问题的唯一全局最小点。这一论证不要求指数归一化等式的可行集是凸集。

policy归一化 $\sum_a \pi_{k,n}(a \mid s) = 1$ 正是 log-ratio 坐标中的指数归一化条件。Lambert-W 解对应

$$\pi_k^{\star,\mathrm{Mean}}(a \mid s) = \pi_k(a \mid s) \exp\Big(G_k(s, a) - W_0(\lambda_k(s) e^{G_k(s,a)})\Big).$$

精确 Gibbs 解的 log-ratio 则为

$$U_a^{\mathrm{Gibbs}} = G_a - \log \mathbb{E}_{\pi_k}[e^G \mid s].$$

将其代入 PMD-Mean 的 KKT 条件，要求

$$-\log \mathbb{E}_{\pi_k}[e^G \mid s] + \lambda_k \frac{e^{G_a}}{\mathbb{E}_{\pi_k}[e^G \mid s]} = 0$$

对所有 action 同时成立。非恒定 G 时第一个量严格为负，第二个量随 action 改变，因此不存在满足所有方程的单一 λ_k。PMD-Mean 使用 action-dependent 的 Lambert-W 修正，Gibbs 使用 action-independent 的 log-partition 修正；二者仅在信号恒定时重合。

本节损失的乘子 λ_k 对应原论文乘子除以 τ^2，其中 $\tau = 1/\eta$。对 KKT 条件按 anchor 求均值，由 $\mathbb{E}_{\pi_k}[G] = 0$ 和 $\mathbb{E}_{\pi_k}[e^U] = 1$ 得到

$$\lambda_k = -\mathbb{E}_{\pi_k}[U] = \mathrm{KL}(\pi_k \| \pi_k^{\star,\mathrm{Mean}}).$$

固定这个由解确定的 λ_k，同一分布也唯一最大化

$$\mathbb{E}_p[f] - \frac{1}{\eta}\,\mathrm{KL}(p\|\pi_k) - \frac{\lambda_k}{2\eta}\chi^2(p\|\pi_k), \qquad \chi^2(p\|\pi_k) = \mathbb{E}_{\pi_k}\left[\left(\frac{p}{\pi_k} - 1\right)^2\right]. \tag{2.30}$$

为验证这一等价，令 ξ 为概率归一化乘子。混合目标的逐 action 一阶条件为

$$f_a - \frac{1}{\eta}(U_a + 1) - \frac{\lambda_k}{\eta}(e^{U_a} - 1) + \xi = 0.$$

在 PMD-Mean 解处有 $U_a + \lambda_k e^{U_a} = \eta(f_a - \bar{f}_k)$；取 $\xi = (1 - \lambda_k)/\eta - \bar{f}_k$ 即满足上式。混合目标中的负 KL 严格凹，负 χ^2 凹，因此这个驻点是唯一全局最大点。这里的等价指总体最优分布相同，不表示两个训练目标在任意参数点上的梯度相同。

实际样本只需估计冻结的 reward center。给定同一 history 的 $m \geq 2$ 个独立 anchor actions，使用 leave-one-out 均值

$$\widehat{\bar{f}}_{-j} = \frac{1}{m-1}\sum_{\ell \neq j} f(s, a_\ell).$$

student log-ratio $U_{k,n}(s, a_j)$ 保持原值，不计算或减去 $\bar{U}_{k,n}$。因为该 center 不依赖 student，leave-one-out reward center 的有限样本平方损失与总体损失只相差一个参数无关的条件方差项，其梯度无偏。若 $m = 1$，需要外部同 prefix 的 reward center；使用不准确的冻结 baseline 会改变回归目标，必须单独记录该误差。

Algorithm 2 PMD-Mean inner update

Semantics: 中心化 *target* 在指数归一化集合上的投影

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, $m \geq 2$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  for $j = 1, \ldots, m$ **do**
    sample $a_{ij} \sim \pi_k(\cdot \mid s_i)$
    $U_{ij} \leftarrow \log \pi_{k,n}(a_{ij} \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_{ij} \mid s_i))$
    $F_{ij} \leftarrow f(s_i, a_{ij})$
  end for
  for $j = 1, \ldots, m$ **do**
    $\bar{F}_{-j} \leftarrow (m-1)^{-1} \sum_{\ell \neq j} F_{i\ell}$
    $\ell_{ij} \leftarrow \frac{1}{2}[U_{ij} - \eta\,\mathrm{stopgrad}(F_{ij} - \bar{F}_{-j})]^2$
  end for
end for
$g_{k,n} \leftarrow \nabla_\theta[(Bm)^{-1} \sum_{i,j} \ell_{ij}]$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

2.3.3 BPO：中心化最优性 residual

BPO 的 residual、损失和梯度分别见式 (2.14)、(2.16)、(2.17)。为后续引用，同一对象记为

$$R_{k,n}^{\mathrm{BPO}} = U_{k,n} - G_k + \mathcal{K}_{k,n}^{S}, \qquad \mathcal{L}_{\mathrm{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2]. \tag{2.31}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \frac{1}{\eta}\mathbb{E}_{d_k,\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n})]. \tag{2.32}$$

centered score 来自 student center 的导数。令 $z(s,a) = U_{k,n}(s,a) - \eta f(s,a)$，用一个主 action a_i 和 m 个独立辅助 actions $b_{i\ell}$ 估计 center，则

$$\mathbb{E}\left[\left(z(s,a_i) - \frac{1}{m}\sum_{\ell=1}^{m} z(s,b_{i\ell})\right)^2\right] = \left(1+\frac{1}{m}\right)\mathrm{Var}_{\pi_k}(z \mid s).$$

因此 sampled 平方损失需乘 $m/(m+1)$，其 autograd 梯度才无偏。若同 prefix 共有 $m \geq 2$ 个 actions，leave-one-out center 使用其余 $m-1$ 个样本，对应系数为 $(m-1)/m$。独立性本身不能消除 residual 与 center 导数乘积中的协方差。

Algorithm 3 BPO inner update

Semantics: 固定 *anchor* 下对正向中心化残差求平方损失

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^{B}$, auxiliary count $m \geq 1$, η, step size $\alpha_{k,n}$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$ and $b_{i1}, \ldots, b_{im} \sim \pi_k(\cdot \mid s_i)$ independently
  $z_i \leftarrow U_{k,n}(s_i,a_i) - \eta f(s_i,a_i)$
  $\bar{z}_i \leftarrow m^{-1}\sum_{\ell=1}^{m}[U_{k,n}(s_i,b_{i\ell}) - \eta f(s_i,b_{i\ell})]$
  $\widehat{R}_i^{\mathrm{BPO}} \leftarrow z_i - \bar{z}_i$, $\ell_i \leftarrow \frac{m}{m+1}\frac{(\widehat{R}_i^{\mathrm{BPO}})^2}{2\eta}$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
return $\theta_{k,n+1}$

若从行为测度 β 采样，不能先把 z 乘以 importance weight 再平方；这会把二阶矩的权重变成平方。可用两个独立样本 $a, b \sim \beta(\cdot \mid s)$，令 $w(v) = \mathrm{sg}(\pi_k(v \mid s)/\beta(v \mid s))$，使用

$$\widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \frac{w(a)w(b)}{4\eta}[z(a) - z(b)]^2.$$

因为 $\mathbb{E}_{a,b\sim\pi_k}[(z(a)-z(b))^2] = 2\,\mathrm{Var}_{\pi_k}(z)$，上述估计器的期望恰为原始 BPO 损失，且固定权重下 autograd 给出无偏梯度。

2.3.4 MDPO：直接优化 mirror objective

MDPO 的损失见式 (2.19)。完整词表计算

$$\mathrm{KL}(\pi_{k,n} \| \pi_k) = \sum_a \pi_{k,n}(a \mid s) U_{k,n}(s,a). \tag{2.33}$$

若从 anchor 采样，用显式指数权重改写 student 期望：

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right) \mid s\right]. \tag{2.34}$$

原损失中的指数权重保留梯度；解析求导后的 policy-gradient 权重整体冻结，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_k}\left[\mathrm{sg}\left(e^{U_{k,n}}\left(\frac{U_{k,n}}{\eta} - f\right)\right)\psi_{k,n} \mid s\right]. \tag{2.35}$$

额外的 η^{-1} score 项在完整求和时由 $\mathbb{E}_{\pi_{k,n}}[\psi_{k,n}] = 0$ 抵消。

自然梯度只改变更新几何。令 $h_{k,n} = \nabla_\theta \mathcal{L}_{\mathrm{MDPO}}$，Fisher 信息矩阵为

$$F_{k,n} = \mathbb{E}_{d_k,\pi_{k,n}}[\psi_{k,n}(s,a)\psi_{k,n}(s,a)^\top].$$

anchor 采样时用 $\mathrm{sg}(e^{U_{k,n}})$ 校正测度。tabular categorical logits 的 Fisher 零空间为常数方向，故用伪逆 $F^\dagger_{k,n}$；神经网络参数化中用阻尼 $\gamma > 0$ 或 KL trust region。自然步长与镜像系数 η 分别控制数值更新和总体 target。

Algorithm 4 MDPO natural-gradient inner update

Semantics: 最小化固定 *history* 的负 *mirror objective*

Require: frozen π_k, signal f, histories $\{s_i\}_{i=1}^B$, η, natural step $\alpha_{k,n}$, damping $\gamma \geq 0$
Ensure: updated parameters $\theta_{k,n+1}$

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $U_i \leftarrow U_{k,n}(s_i,a_i)$, $w_i \leftarrow e^{U_i}$
  $\ell_i \leftarrow w_i(U_i/\eta - f(s_i,a_i))$ ▷ retain the student derivative of w_i
  $g_i^{\mathrm{score}} \leftarrow \nabla_\theta \log \pi_{k,n}(a_i \mid s_i)$
end for
$g_{k,n} \leftarrow \nabla_\theta(B^{-1}\sum_i \ell_i)$
$F \leftarrow B^{-1}\sum_i \mathrm{stopgrad}(w_i) g_i^{\mathrm{score}}(g_i^{\mathrm{score}})^\top$
$\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n}(F + \gamma I)^\dagger g_{k,n}$
return $\theta_{k,n+1}$

定理 2.3 (Gibbs 解与 PMD-Mean 的 Lambert-W 解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、未线性化 BPO 和 MDPO 的总体最优解是式 (2.3) 的 Gibbs 分布。PMD-Mean 的总体最优解是定理 2.2 的 Lambert-W 分布；非恒定信号下与 Gibbs 分布不同。参数化 student 或有限样本还会引入函数类投影、采样及优化误差。

证明 PMD-Part 在零损失处满足 $U_{k,n} = \eta f - \log Z_f$，得到 Gibbs 分布。BPO 的零 residual 只要求 $U_{k,n} = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_{k,n}}] = 1$ 得 $C(s) = \log Z_f(s)$。MDPO 的负 mirror 损失由式 (2.4) 得到唯一最小点。PMD-Mean 的受约束全局最小点及与 Gibbs 解的分离已在定理 2.2 后证明。

命题 2.4 (PMD-Mean 与 BPO 的损失和梯度差异)

固定历史 s，两个 residual 满足 $R^{\mathrm{Mean}}_{k,n} = R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n}$，因此

$$\mathcal{L}_{\mathrm{Mean}}(s) = \eta\mathcal{L}_{\mathrm{BPO}}(s) + \frac{1}{2}(\mathcal{K}^S_{k,n}(s))^2, \tag{2.36}$$

$$\nabla_\theta\mathcal{L}_{\mathrm{Mean}}(s) = \eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}}(s) + \mathcal{K}^S_{k,n}(s)\nabla_\theta\mathcal{K}^S_{k,n}(s). \tag{2.37}$$

证明 $\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n} \mid s] = 0$，平方展开得

$$\frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n} - \mathcal{K}^S_{k,n})^2 \mid s] = \frac{1}{2}\mathbb{E}_{\pi_k}[(R^{\mathrm{BPO}}_{k,n})^2 \mid s] + \frac{1}{2}(\mathcal{K}^S_{k,n})^2.$$

再使用损失定义并求导。下降方向的同尺度关系为

$$-\nabla_\theta\mathcal{L}_{\mathrm{Mean}} = -\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} + \mathcal{K}^S_{k,n}\bar{\psi}_{k,n}.$$

初始化 $\pi_{k,0} = \pi_k$ 时 $\mathcal{K}^S_{k,0} = 0$，两者同尺度方向一致；离开 anchor 后差异通常保留。tabular softmax logits 中 $\bar{\psi}_{k,n} = \pi_k - \pi_{k,n}$，额外下降方向是 $\mathcal{K}^S_{k,n}(\pi_k - \pi_{k,n})$。

命题 2.5 (未线性化 BPO 与 PMD-Part 的梯度差异)

固定历史 s，定义

$$C_{k,n}(s) := \log Z_f(s) - \eta\bar{f}_k(s) - \mathcal{K}^S_{k,n}(s). \tag{2.38}$$

则 $R^{\mathrm{BPO}}_{k,n} = R^{\mathrm{Part}}_{k,n} - C_{k,n}$，且

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}(s)}{\eta}\bar{\psi}_{k,n}(s). \tag{2.39}$$

证明 逐项展开中心化残差：

$$\begin{aligned} R^{\mathrm{BPO}}_{k,n} &= U_{k,n} - \eta f - \mathbb{E}_{\pi_k}[U_{k,n} - \eta f \mid s] \\ &= U_{k,n} - \eta f + \log Z_f - \left(\log Z_f + \mathbb{E}_{\pi_k}[U_{k,n} \mid s] - \eta \bar{f}_k\right) \\ &= R^{\mathrm{Part}}_{k,n} - C_{k,n}. \end{aligned}$$

这里必须保留 $-\eta\bar{f}_k$，因为一般 OPD 信号的 anchor 均值不为零。由 BPO residual 均值为零，

$$\begin{aligned} \nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[R^{\mathrm{BPO}}_{k,n}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \\ &= \frac{1}{\eta}\mathbb{E}_{\pi_k}[(R^{\mathrm{Part}}_{k,n} - C_{k,n})\psi_{k,n} \mid s] \\ &= \frac{1}{\eta}\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) - \frac{C_{k,n}}{\eta}\bar{\psi}_{k,n}. \end{aligned}$$

在 Gibbs 解处 $R^{\mathrm{Part}}_{k,n} = 0$，其 anchor 均值也为零，因此 $C_{k,n} = 0$，两种梯度同时为零。一般参数点只有 $C_{k,n}\bar{\psi}_{k,n} = 0$ 时才具有相同的同尺度方向。

PMD-Part 回归完整镜像方程，BPO 消去 action-independent 常数再回归中心化方程。二者总体最优分布相同，而 residual、积分后的梯度和有限步轨迹不同。

2.4 OPD 特化：逐 token reward 与两种信息访问模式

在 OPD 中，第 k 个 outer step 先固定 anchor π_k，然后从它产生 rollout。对 prefix $s_t = (x, y_{<t})$ 和实际 sampled token $a_t = y_t$，最直接的局部 teacher reward 是

$$r_k(s_t, a_t) = \log \pi_T(a_t \mid s_t) - \log \pi_k(a_t \mid s_t). \tag{2.40}$$

它满足序列分解

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \log \pi_T(y \mid x) - \log \pi_k(y \mid x).$$

因此在共同 mirror 子问题中应取 $f = r_k$；不能把整条序列的 log-ratio 当作每一个 prefix 的同一个 reward，否则会重复计算后缀差异。

可以对 reward 做两种不同的“归一化”，必须区分它们的理论作用。对任意只依赖 prefix 的 baseline $b_k(s)$，令

$$f^{\mathrm{ctr}}_k(s, a) = r_k(s, a) - b_k(s). \tag{2.41}$$

它只把 partition function 乘上 $e^{-\eta b_k(s)}$，所以 Gibbs policy 不变；取 $b_k(s) = \mathbb{E}_{\pi_k}[r_k(s, \cdot) \mid s]$ 就是条件中心化。若再除以尺度 $\sigma_k(s) > 0$，则

$$f^{\mathrm{std}}_k = (r_k - b_k)/\sigma_k$$

会把有效温度从 η 改成 η/σ_k，不再是同一个 mirror step，除非同时把正则参数改为 $\eta\sigma_k$。因此 OPD 的默认实现只做 additive centering；标准化只能作为明确的 temperature schedule。

2.4.1 完整 vocabulary logits：精确 token mirror target

完整词表 logits 使冻结 reward r_k、teacher center $\mathcal{K}^T_k$、student center $\mathcal{K}^S_{k,n}$ 和 partition function 都可精确求和。OPD 的配分函数为

$$\log Z_k(s) = \mathrm{logsumexp}_{v \in \mathcal{V}}\left((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\right). \tag{2.42}$$

相应 Gibbs target 是

$$\pi_k^{\star,\mathrm{Gibbs}}(v \mid s) = \exp((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) - \log Z_k(s)) .$$

PMD-Mean 的 target 是定理 2.2 的 $\pi_k^{\star,\mathrm{Mean}}$。完整词表路径消除了条件 token 采样误差；prefix coverage 与数值优化误差仍保留。

四种损失与实际梯度

第一章的条件均值恒等式给出 $\mathbb{E}_{\pi_k}[r_k \mid s] = -\mathcal{K}_k^T$、$\mathbb{E}_{\pi_k}[U_{k,n} \mid s] = -\mathcal{K}_{k,n}^S$。因此冻结 Mean target 为 $G_k = \eta(r_k + \mathcal{K}_k^T)$，三个回归 residual 是

$$R_{k,n}^{\mathrm{Part}}(s,v) = U_{k,n}(s,v) - \eta r_k(s,v) + \log Z_k(s), \tag{2.43}$$

$$R_{k,n}^{\mathrm{Mean}}(s,v) = U_{k,n}(s,v) - \eta(r_k(s,v) + \mathcal{K}_k^T(s)), \tag{2.44}$$

$$R_{k,n}^{\mathrm{BPO}}(s,v) = U_{k,n}(s,v) + \mathcal{K}_{k,n}^S(s) - \eta(r_k(s,v) + \mathcal{K}_k^T(s)). \tag{2.45}$$

它们对应

$$\mathcal{L}_{\mathrm{Part}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Part}})^2 \mid s], \tag{2.46}$$

$$\mathcal{L}_{\mathrm{Mean}}(s) = \tfrac{1}{2}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{Mean}})^2 \mid s], \tag{2.47}$$

$$\mathcal{L}_{\mathrm{BPO}}(s) = \tfrac{1}{2\eta}\mathbb{E}_{\pi_k}[(R_{k,n}^{\mathrm{BPO}})^2 \mid s], \tag{2.48}$$

$$\mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}[U_{k,n}/\eta - r_k \mid s]. \tag{2.49}$$

三个平方损失的解析梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Part}} \psi_{k,n} \mid s], \tag{2.50}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{Mean}} \psi_{k,n} \mid s], \tag{2.51}$$

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{\eta}\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}}(\psi_{k,n} - \bar{\psi}_{k,n}) \mid s] \tag{2.52}$$

$$= \mathbb{E}_{\pi_k}\left[\left(\frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta} - r_k - \mathcal{K}_k^T\right)\psi_{k,n} \mid s\right]. \tag{2.53}$$

这里直接比较 $\nabla\mathcal{L}$，BPO 的 η^{-1} 已乘入权重。其实际下降方向为

$$-\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{\pi_k}\left[\left(r_k + \mathcal{K}_k^T - \frac{U_{k,n} + \mathcal{K}_{k,n}^S}{\eta}\right)\psi_{k,n} \mid s\right]. \tag{2.54}$$

centered score 的第二项消失，是因为 $\mathbb{E}_{\pi_k}[R_{k,n}^{\mathrm{BPO}} \mid s] = 0$；不能把 $\bar{\psi}_{k,n}$ 自身视为零。Mean residual 的 anchor 均值为 $-\mathcal{K}_{k,n}^S$，所以 Mean 不具有同样的消去。

MDPO 同时微分 student 测度和 log-ratio，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{MDPO}}(s) = \mathbb{E}_{\pi_{k,n}}\left[\left(\frac{U_{k,n}+1}{\eta} - r_k\right)\psi_{k,n} \mid s\right] \tag{2.55}$$

$$= \mathbb{E}_{\pi_{k,n}}[(U_{k,n}/\eta - r_k)\psi_{k,n} \mid s]. \tag{2.56}$$

第二行使用 student 测度的零均值 score 恒等式。MDPO 使用 student 积分测度，三个回归损失使用 anchor 积分测度。

停止梯度的具体位置

π_k、π_T、$\log Z_k$、$\mathcal{K}_k^T$ 和 G_k 在固定 outer step 冻结。student KL 每个 inner step 重算，原始 BPO 平方损失中保留其导数：

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{\pi_k}[\mathrm{stopgrad}(\log \pi_k) - \log \pi_{k,n} \mid s], \tag{2.57}$$

$$\nabla_\theta \mathcal{K}_{k,n}^S(s) = -\bar{\psi}_{k,n}(s). \tag{2.58}$$

若实现已经解析好的 policy gradient，所有 residual 和 MDPO 权重都整体停止梯度：例如 surrogate

$$\mathbb{E}_{\pi_k}[\mathrm{stopgrad}(R_{k,n}^{\mathrm{Mean}})\log \pi_{k,n}]$$

的梯度正好等于 Mean 梯度。此处权重的导数已由解析推导处理，再微分一次会改变目标。若直接实现原始平方损失，则 student residual 及 BPO center 保留梯度。Mean 原始损失不含 student KL center。

2.4.2 有限词表与 sampled-token：KL 与 partition 估计

2602.04417的 Top-J 方法直接估计 KL：在 top-J 头部计算精确项，在尾部用采样项校正。它不直接给出本节的 $\log Z_k$，因为

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\left(\frac{\pi_T(a\mid s)}{\pi_k(a\mid s)}\right)^{\eta}\right]. \tag{2.59}$$

这一区别很重要：$\widehat{Z}_k$ 可以无偏，但 $\log \widehat{Z}_k$ 不能无偏。

在固定 prefix s 上，从冻结 anchor 采样 $a_j \sim \pi_k(\cdot\mid s)$，令 $r_k(s,a) = \log \pi_T(a\mid s) - \log \pi_k(a\mid s)$。则两个中心满足

$$\mathcal{K}_k^T(s) = \mathbb{E}_{a\sim\pi_k}[-r_k(s,a)], \tag{2.60}$$

$$\mathcal{K}_{k,n}^S(s) = \mathbb{E}_{a\sim\pi_k}\left[\log \pi_k(a\mid s) - \log \pi_{k,n}(a\mid s)\right]. \tag{2.61}$$

因此 m 个独立 next-token 样本的均值分别是两个 KL 的无偏估计。真实 rollout 中每个 prefix 通常只有一个后继 token；该 token 是无偏单点样本，但不是 conditional KL 的精确值。若要降低方差，可以在已经算出 anchor logits 后额外抽取 $m-1$ 个 token，这只增加 categorical 抽样和 log-prob 记录，无需生成额外长序列。不同 prefix 的 token 不能互相当作同一条件分布的样本。

其中 $\mathcal{K}_k^T$ 在整个 outer step 内固定，teacher/anchor log-prob 可以缓存；$\mathcal{K}_{k,n}^S$ 必须在每个 inner step 重新计算。实现已经推导好的 policy-gradient 时，KL 中心作为权重整体使用 stop-gradient；实现原始 BPO 平方损失时则必须保留 student KL 的导数；PMD-Mean 只需要冻结的 teacher KL center。

对 $\mathcal{K}_{k,n}^S = \mathrm{KL}(\pi_k\|\pi_{k,n})$，取 $S_{k,J}(s) = \mathrm{Top}(\pi_k(\cdot\mid s), J)$，可构造

$$\widehat{\mathcal{K}}_{k,n}^S(s) = \sum_{v\in S_{k,J}(s)} \pi_k(v\mid s)\log\frac{\pi_k(v\mid s)}{\pi_{k,n}(v\mid s)} \tag{2.62}$$

$$+\frac{1}{m}\sum_{j=1}^{m}\mathbf{1}\{a_j\notin S_{k,J}(s)\}\log\frac{\pi_k(a_j\mid s)}{\pi_{k,n}(a_j\mid s)}, \qquad a_j\sim\pi_k(\cdot\mid s). \tag{2.63}$$

对固定 $S_{k,J}$，尾部项是精确尾部求和的无偏 Monte Carlo 估计，且其 autograd 梯度的期望等于真实 KL 梯度。这里的“梯度无偏”是指把该估计量直接放进原始 KL 损失并对 student 反向传播时的性质；本章的最终实现采用已经解析化的 policy-gradient 形式，KL 估计值只作为数值权重，必须整体 stopgrad，因此不需要再对这个估计量执行 autograd。$J=0$ 是纯 sampled-token，$J=|\mathcal{V}|$ 是 exact KL；这两个端点是同一个 top-J 族的插值端点，不单独构成一个算法分支。给定头部后，条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_{k,n}^S\mid S_{k,J}) = \frac{1}{m}\mathrm{Var}_{a\sim\pi_k}\left[\mathbf{1}\{a\notin S_{k,J}\}\log\frac{\pi_k(a\mid s)}{\pi_{k,n}(a\mid s)}\right]. \tag{2.64}$$

增大 J 通常降低尾部质量和方差，但实际大小取决于尾部 log-ratio 的二阶矩。对 $\mathcal{K}_k^T$ 可使用同样的头尾分解；由于它不需要反向传播，anchor 样本均值往往已经足够。

为了把 2602.04417 中“截断偏差换取采样方差”的结论直接用于 OPD，下面给出一个与 KL、score 加权梯度和 partition function 都兼容的统一形式。固定 prefix s，令 $p(v)$ 为 rollout 测度（本章中通常是 $p=\pi_k(\cdot\mid s)$），$h(v)$ 为待求期望的 integrand，定义

$$Q = \mathbb{E}_{v\sim p}[h(v)], \qquad Q_J^{\mathrm{head}} = \sum_{v\in S_J} p(v)h(v), \qquad \tau_J = \mathbb{E}_{v\sim p}[\mathbf{1}\{v\notin S_J\}h(v)], \tag{2.65}$$

其中 S_J 是固定的 top-J 集合。用 m 个独立的 auxiliary token $a_1, \dots, a_m \sim p$ 做尾部校正时，定义

$$\widehat{Q}_{J,m} = Q_J^{\text{head}} + \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_J\} h(a_j). \tag{2.66}$$

定理 2.4 (Top-J 截断与尾部校正的偏差–方差分解)

在 $\mathbb{E}_p[h^2] < \infty$ 且 S_J 与 auxiliary samples 独立时，纯头部估计 $\widehat{Q}_J^{\text{tr}} = Q_J^{\text{head}}$ 与尾部校正估计 $\widehat{Q}_{J,m}$ 分别满足

$$\text{Bias}(\widehat{Q}_J^{\text{tr}}) = -\tau_J, \qquad \text{Var}(\widehat{Q}_J^{\text{tr}}) = 0, \qquad \text{MSE}(\widehat{Q}_J^{\text{tr}}) = \tau_J^2, \tag{2.67}$$

$$\text{Bias}(\widehat{Q}_{J,m}) = 0, \qquad \text{Var}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \qquad \text{MSE}(\widehat{Q}_{J,m}) = \frac{V_J}{m}, \tag{2.68}$$

其中

$$V_J = \mathbb{E}_p\left[\mathbf{1}\{v \notin S_J\} h(v)^2\right] - \tau_J^2. \tag{2.69}$$

如果 $S_J \subseteq S_{J+1}$，则尾部二阶矩 $A_J = \mathbb{E}_p[\mathbf{1}\{v \notin S_J\} h(v)^2]$ 单调不增，且 $V_J \le A_J$。尾部均值 τ_J 在 $h \ge 0$ 时单调不增；对符号不定的 h，它本身不必单调，但有

$$|\tau_J| \le \sqrt{p(S_J^c) A_J}. \tag{2.70}$$

♡

证明 记 $X_j = \mathbf{1}\{a_j \notin S_J\} h(a_j)$。由 $a_j \sim p$，有 $\mathbb{E}[X_j] = \tau_J$，且 $\text{Var}(X_j) = V_J$。因此

$$\mathbb{E}[\widehat{Q}_{J,m}] = Q_J^{\text{head}} + \tau_J = Q, \qquad \text{Var}(\widehat{Q}_{J,m}) = \text{Var}\left(\frac{1}{m}\sum_{j=1}^{m} X_j\right) = \frac{V_J}{m}, \tag{2.71}$$

其中最后一步使用了独立性。纯头部估计没有随机项，且 $Q_J^{\text{head}} - Q = -\tau_J$，从而得到前三个等式。若集合嵌套，$\mathbf{1}\{v \notin S_{J+1}\} \le \mathbf{1}\{v \notin S_J\}$，故对非负 h^2 有 $A_{J+1} \le A_J$。当 $h \ge 0$ 时，尾部指示函数逐点下降，所以 $0 \le \tau_{J+1} \le \tau_J$。一般情形下对尾部随机变量应用 Cauchy–Schwarz 不等式即可得到式 (2.70)。

定理 2.4 有两个直接含义。对 $h_{\text{KL}}(v) = \log \frac{\pi_k(v|s)}{\pi_{k,n}(v|s)}$ 或 $h_T(v) = \log \frac{\pi_k(v|s)}{\pi_T(v|s)}$，$h$ 可能正也可能负，因此不能声称“增大 J 必然单调减小截断 bias”；能够保证的是尾部二阶矩和上界下降。对 $h_Z(v) = \exp(\eta r_k(s,v)) \ge 0$，尾部均值本身单调下降，所以纯截断的 Z_k 估计具有严格的单侧负偏差，而且随 J 减小。这正是 2602.04417 中 truncated KL 与 tail-corrected Top-J KL 的数学区别。

如果最终对象是 score 加权的 policy gradient，使用第一章的 score $\psi_{k,n}$，把 $h(v)$ 换成向量 $h(v)\psi_{k,n}(v)$，定理逐坐标成立，并得到

$$\text{Bias}(\widehat{H}_J^{\text{tr}}) = -\mathbb{E}_p[\mathbf{1}\{v \notin S_J\} h(v)\psi_{k,n}(v)], \qquad \text{Cov}(\widehat{H}_{J,m}) = \frac{1}{m}\text{Cov}_p(\mathbf{1}\{v \notin S_J\} h(v)\psi_{k,n}(v)). \tag{2.72}$$

这描述的是“估计最终梯度权重”的误差，而不是对 detached 估计量求导。本章 Algorithm 5 采用这种解析权重实现：先解析得到 score-function 公式，再把 $\widehat{h}$ 整体 stop-gradient。因此实现不需要保存估计量的 autograd 图；只需控制式 (2.72) 中的数值 bias 和 variance。

对 Z_k，头尾分解应先估计 Z_k 再取对数。令 $S_Z(s)$ 为 $((1-\eta)\log \pi_k + \eta \log \pi_T)$ 的 top-J 索引，则

$$\widehat{Z}_k(s) = \sum_{v \in S_Z(s)} \pi_k(v \mid s)^{1-\eta} \pi_T(v \mid s)^{\eta} \tag{2.73}$$

$$+ \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_Z(s)\} \left(\frac{\pi_T(a_j \mid s)}{\pi_k(a_j \mid s)}\right)^{\eta}, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.74}$$

式 (2.74) 对 Z_k 无偏，但 Jensen 不等式给出

$$\mathbb{E}[\log \widehat{Z}_k] \le \log Z_k, \qquad \mathbb{E}[\log \widehat{Z}_k] - \log Z_k \approx -\frac{\text{Var}(\widehat{Z}_k)}{2Z_k^2}. \tag{2.75}$$

尾部重要性比率具有长尾时，单 token plug-in 估计尤其不稳定；裁剪比率可降方差，但会引入额外偏差。$\eta = 1$ 时 $Z_k = 1$，所以 $\log Z_k = 0$ 精确已知；$\eta = 0$ 时同样如此。$0 < \eta < 1$ 时，若不需要 PMD-Part，PMD-Mean/BPO 可以绕开这项 log-of-mean 偏差。

定理 2.5 (Partition function 的 log-of-mean 偏差)

设 $\widehat{Z}_{J,m}$ 是式 (2.74) 的尾部校正估计，$\mathbb{E}[\widehat{Z}_{J,m}] = Z_k > 0$，假设有限词表上 anchor 与 teacher 均为正概率，且头部集合固定。此时 $\widehat{Z}_{J,m}$ 有与 m 无关的正下界及有限上界。记 $V_J = \mathrm{Var}(\mathbf{1}\{a \notin S_Z\}(\pi_T(a \mid s)/\pi_k(a \mid s))^\eta)$。当 m 足够大时，

$$\mathbb{E}[\log \widehat{Z}_{J,m}] - \log Z_k = -\frac{V_J}{2mZ_k^2} + O(m^{-3/2}), \tag{2.76}$$

$$\mathrm{Var}(\log \widehat{Z}_{J,m}) = \frac{V_J}{mZ_k^2} + O(m^{-3/2}). \tag{2.77}$$

若 $J \geq 1$ 并改用纯头部估计 $Z_J^{\mathrm{tr}} = \sum_{v \in S_Z} \pi_k(v)^{1-\eta}\pi_T(v)^\eta$，则

$$Z_J^{\mathrm{tr}} - Z_k = -\tau_J^Z \leq 0, \qquad \log Z_J^{\mathrm{tr}} - \log Z_k \leq 0, \tag{2.78}$$

其中 $\tau_J^Z \geq 0$ 是式 (2.65) 对 h_Z 的尾部均值。因而纯截断的 log-partition bias 是确定性的单侧偏差，而尾部校正的 plug-in log 估计是由方差诱导的负偏差。

证明 令 $\varepsilon_Z = \widehat{Z}_{J,m} - Z_k$。由无偏性，$\mathbb{E}[\varepsilon_Z] = 0$，且 $\mathbb{E}[\varepsilon_Z^2] = V_J/m$。在 Z_k 邻域对 $f(z) = \log z$ 作三阶 Taylor 展开：

$$\log(Z_k + \varepsilon_Z) = \log Z_k + \frac{\varepsilon_Z}{Z_k} - \frac{\varepsilon_Z^2}{2Z_k^2} + R_3, \tag{2.79}$$

其中在三阶矩有界时 $\mathbb{E}|R_3| = O(m^{-3/2})$。取期望并使用 $\mathbb{E}[\varepsilon_Z] = 0$ 得到第一式。对同一展开取方差，首阶随机项为 ε_Z/Z_k，故 $\mathrm{Var}(\log \widehat{Z}_{J,m}) = V_J/(mZ_k^2) + O(m^{-3/2})$。最后，$h_Z \geq 0$ 给出 $\tau_J^Z \geq 0$，所以 $Z_J^{\mathrm{tr}} \leq Z_k$；由于 log 单调递增，第二个不等式随之成立。

定理 2.5 说明了为什么不能把“无偏的 $\widehat{Z}_k$”直接等同于“无偏的 $\log Z_k$”。在 PMD-Part 中，若使用 plug-in 估计，$\log Z_k$ 的误差会进入每个 token 的 residual；在完整词表路径上，该误差乘以 anchor 下的 student score 均值，一般不为零；sampled-token 路径还承担随机 score 的额外方差。因此 PMD-Part 对 m、J 和尾部比率的要求严格于 PMD-Mean/BPO。当 m 个样本独立且把同一 prefix 的梯度平均时，partition 诱导的梯度方差按 $1/m$ 下降；当外层有 B 个相互独立 prefix 时，条件于 prefix 的这部分方差进一步按 $1/B$ 下降，但 prefix coverage 误差不随 m 消失。

$\log Z_k$ 的展开估计：从 Z_k 的 plug-in 走向可控偏差

直接计算 $\log \widehat{Z}_k$ 是最简单的方案，但它把非线性的 log 放在 Monte Carlo 均值之后，必然产生 Jensen bias。对于 OPD，Z_k 具有更特殊的结构：

$$Z_k(s) = \mathbb{E}_{a \sim \pi_k}\left[e^{\eta r_k(s,a)}\right], \qquad r_k(s,a) = \log \pi_T(a \mid s) - \log \pi_k(a \mid s). \tag{2.80}$$

因此 $\log Z_k$ 是随机变量 r_k 的 cumulant-generating function 在 η 处的值。令 $\kappa_j(r_k)$ 为 r_k 的第 j 阶 cumulant，则在零点 Taylor 级数的收敛半径内

$$\log Z_k(s) = \sum_{j=1}^{\infty} \frac{\eta^j}{j!}\kappa_j(r_k). \tag{2.81}$$

前两项为

$$\log Z_k(s) = \eta\,\mathbb{E}[r_k] + \frac{\eta^2}{2}\mathrm{Var}(r_k) + R_3(s), \tag{2.82}$$

其中 R_3 收集三阶及以上 cumulant。因为 $\mathbb{E}[r_k] = -\mathcal{K}_k^T$，二阶近似也可以写成

$$\log Z_k(s) \approx -\eta\mathcal{K}_k^T(s) + \frac{\eta^2}{2}\mathrm{Var}_{a \sim \pi_k}[r_k(s,a)]. \tag{2.83}$$

这给出了比 $-\eta\widehat{\mathcal{K}}_k^T$ 更准确的近似：只使用均值会遗漏 log-sum-exp 的二阶曲率项，而该项在 teacher 与 anchor 差异较大时不可忽略。

若从同一个 prefix 取得 m 个 auxiliary token，令 $\widehat{\kappa}_j$ 为对应的 unbiased j 阶 k-statistic，并定义

$$\widehat{L}_{L,m}(s) = \sum_{j=1}^{L} \frac{\eta^j}{j!} \widehat{\kappa}_j(r_k). \tag{2.84}$$

则

定理 2.6 (Cumulant 截断估计器的 bias 与方差)

固定有限词表，假设 $\pi_k(v \mid s) > 0$、$\pi_T(v \mid s) > 0$。令

$$\varphi(t) = \log \mathbb{E}_{\pi_k}[e^{tr_k} \mid s], \qquad p_t(v \mid s) = \frac{\pi_k(v \mid s) e^{tr_k(s,v)}}{\mathbb{E}_{\pi_k}[e^{tr_k} \mid s]}.$$

取固定展开阶数 $L \geq 1$，样本数 $m \geq L$。第 j 阶 k-statistic 无偏估计 $\varphi^{(j)}(0) = \kappa_j(r_k)$，故

$$\mathbb{E}[\widehat{L}_{L,m}] - \log Z_k = -\frac{\eta^{L+1}}{L!} \int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\, du, \tag{2.85}$$

$$\mathrm{Var}(\widehat{L}_{L,m}) = O(m^{-1}). \tag{2.86}$$

余项满足

$$\left| \mathbb{E}[\widehat{L}_{L,m}] - \log Z_k \right| \leq \frac{|\eta|^{L+1}}{(L+1)!} \sup_{t \in [0,\eta]} \left| \kappa_{L+1}^{p_t}(r_k) \right|. \tag{2.87}$$

其中 $\kappa_{L+1}^{p_t}$ 是倾斜分布 p_t 下的 cumulant。

证明 有限词表和正概率使 r_k 有界，φ 在实轴上光滑。对指数倾斜分布求导可得

$$\varphi'(t) = \mathbb{E}_{p_t}[r_k], \qquad \varphi''(t) = \mathrm{Var}_{p_t}(r_k), \qquad \varphi^{(j)}(t) = \kappa_j^{p_t}(r_k).$$

Taylor 积分余项给出

$$\varphi(\eta) = \sum_{j=1}^{L} \frac{\eta^j}{j!} \varphi^{(j)}(0) + \frac{\eta^{L+1}}{L!} \int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\, du.$$

估计器前 L 项逐项无偏，因此其 bias 是余项的负值。对积分取绝对值并使用 $\int_0^1 (1-u)^L du = 1/(L+1)$，得到上界。固定阶 k-statistic 是有界核 U-statistic 的有限线性组合，其方差和相互协方差均为 $O(m^{-1})$，从而得到估计器方差。这里展开的是 log-mgf，余项必须用倾斜 cumulant 控制，不能套用 $e^{\eta r_k}$ 本身的 Taylor 余项界。

对 OPD 的常用二阶实现，$L = 2$ 时可以直接使用样本均值和无偏样本方差：

$$\widehat{L}_{2,m}(s) = \eta \bar{r}_k(s) + \frac{\eta^2}{2} \widehat{\mathrm{Var}}(r_k(s, \cdot)). \tag{2.88}$$

它不再具有 log-of-mean 的 $O(m^{-1})$ Jensen bias；剩余 bias 是明确的 cumulant truncation bias。代价是需要估计方差，并且当 $\eta|r_k|$ 较大时，三阶及以上 cumulant 不能忽略。因此它适合 teacher/anchor 接近、r_k 集中的阶段，不适合重要性比率重尾的阶段。

Top-J 头部还可以进一步降低展开的尾部误差。令

$$Z_H = \sum_{v \in S_Z} \pi_k(v)^{1-\eta} \pi_T(v)^{\eta}, \qquad u(a) = \mathbf{1}\{a \notin S_Z\} \left(\frac{\pi_T(a)}{\pi_k(a)} \right)^{\eta}, \qquad \tau = \mathbb{E}_{\pi_k}[u(a)], \tag{2.89}$$

这里 S_Z 含 J 个头部 tokens。取 $J \geq 1$ 和 $m \geq L$，使 $Z_H > 0$ 且各阶 U-statistic 有定义。则 $Z_k = Z_H + \tau$。当 $\zeta = \tau / Z_H < 1$ 时，

$$\log Z_k = \log Z_H + \sum_{\ell=1}^{\infty} \frac{(-1)^{\ell+1}}{\ell} \zeta^{\ell}. \tag{2.90}$$

用 m 个尾部样本构造

$$\widehat{\tau^{\ell}} = \binom{m}{\ell}^{-1} \sum_{1 \leq i_1 < \cdots < i_\ell \leq m} \prod_{q=1}^{\ell} u(a_{i_q}), \qquad a_i \overset{\text{iid}}{\sim} \pi_k, \tag{2.91}$$

这是 τ^ℓ 的无偏 U-statistic。于是可定义

$$\widehat{L}_{J,L}(s) = \log Z_H + \sum_{\ell=1}^{L} \frac{(-1)^{\ell+1}}{\ell Z_H^\ell} \widehat{\tau}^\ell. \tag{2.92}$$

它的期望等于式 (2.90) 的前 L 项，且截断余项满足

$$\left| \mathbb{E}[\widehat{L}_{J,L}] - \log Z_k \right| \le \frac{\zeta^{L+1}}{(L+1)(1-\zeta)}. \tag{2.93}$$

这个估计器在 J 增大时更有意义：Z_H 增大、ζ 减小，二阶或三阶展开就能达到很小的确定性 truncation bias；$J = 0$ 时 $Z_H = 0$，应退回 cumulant 展开或直接使用正值的 $\log \widehat{Z}$ plug-in。实际实现中建议先用 $L = 2$，同时记录 $\widehat{\zeta}$、plug-in 与展开估计的差异，用它判断是否进入重尾区域。

2602.04417 的合成图可以作为本节偏差–方差实验的模板。论文固定 $|\mathcal{V}| = 32000$，令 reference logits 为 $\mathcal{N}(0, I)$，当前策略 logits 为 $s\mathcal{N}(0, I)$，通过调整 s 使 $\sum_{j \in \mathrm{Top}(\pi, 32)} \pi(j)$ 接近 $\{0.2, 0.5, 0.8, 0.9\}$。对

$$J \in \{4, 8, 16, 32, 64, 128, 256\}, \qquad B \in \{1, 2, 4, \ldots, 32768\}.$$

分别计算 sampled、纯截断和 tail-corrected Top-J 的 token-logit 真梯度与估计梯度，并绘制

$$\mathrm{RelRMSE} = \frac{\sqrt{\mathbb{E}\|\widehat{g} - g_{\mathrm{true}}\|_2^2}}{\|g_{\mathrm{true}}\|_2}. \tag{2.94}$$

交点就是论文所谓 critical sample size。官方仓库 https://github.com/LunjunZhang/ema-pg 公开了 `compute_memory_efficient_kl`、K3^{++}/K4/K5 和 GPU top-J benchmark，但没有公开生成 `simulated_topk_kl_four_masses_v5.pdf` 的脚本；因此我们可以按上述协议在本项目中重建一份，并把 OPD 的 $\log Z_k$ plug-in、二阶 cumulant 和 Top-J 尾部展开作为额外曲线。图中应同时报告 value bias、gradient RelRMSE、尾部命中率和峰值显存，不能只画 KL 数值方差。

偏差–方差定理：从 KL 数值到最终 policy gradient

对一个 prefix 的任意估计器 $\widehat{q}$，最终关心的是带 score 的量 $\widehat{g} = \widehat{q} \nabla_\theta \log \pi_{k,n}$。其均方误差分解为

$$\mathbb{E}\|\widehat{g} - g\|^2 = \|\mathbb{E}[\widehat{g}] - g\|^2 + \mathrm{tr}\,\mathrm{Cov}(\widehat{g}). \tag{2.95}$$

因此，单独比较 $\widehat{\mathcal{K}}$ 的数值方差并不足够：一个有轻微截断偏差但尾部方差极低的估计器，可能比无偏但重尾的 sampled estimator 产生更小的梯度 MSE。2602.04417 的 Top-J 结论正是这个取舍：加入尾部校正保持无偏，代价是尾部采样方差；只保留头部则引入可控的截断偏差。

对 OPD 的 PMD-Part，$\log Z_k$ 的误差直接进入 residual，而 residual 又乘以 score。若使用 $\widehat{c}_k = \log \widehat{Z}_k$，令 $\varepsilon_Z = \widehat{c}_k - \log Z_k$，则单 prefix 的梯度误差包含

$$\varepsilon_Z^{\mathrm{grad}} = \varepsilon_Z \, \mathbb{E}_{v \sim \pi_k} \left[\nabla_\theta \log \pi_{k,n}(v \mid s) \right] \tag{2.96}$$

以及 ε_Z 与 sampled score 的协方差项。完整词表下 score 均值可以精确求和，但只有当 student 等于 anchor 等特殊条件成立时才为零；sampled-token 下即使 partition 估计与 token 独立，其均值误差仍会乘以这个非零 score 均值，有限 batch 还引入随机梯度噪声。故 PMD-Part 对 partition 估计的要求比 BPO/PMD-Mean 更严格。

对同一 prefix 同时估计中心和 policy-gradient 权重时，还要考虑协方差：若 $\widehat{c}$ 与 score 使用同一枚 token，$\mathbb{E}[\widehat{c}\widehat{g}]$ 一般不等于 $\mathbb{E}[\widehat{c}]\mathbb{E}[\widehat{g}]$。采用独立的 auxiliary next-token 样本估计中心，或使用 leave-one-out center，可以消除这类自耦合偏差；代价是额外的 token 抽样和少量 log-prob 存储。跨 prefix 聚合只能降低总体均值方差，不能把不同条件分布下的样本变成同一 conditional center。

最后，prefix 覆盖误差与 token 估计误差应分开记录。即使 token-level estimator 在给定 s 上无偏，rollout 只访问由 π_k 诱导的有限 prefix 多重集，仍有 $\widehat{d}_k - d_k$ 的 outer 测度误差。增加 Top-J 或 auxiliary samples 只降低条件 token 方差，不能修复 prefix coverage；增加 rollout 数量或重新采样 outer batch 才能降低这一项。实验日志应至少分别保存：prefix 数量与重复率、KL/partition 的 batch 均值和方差、尾部采样次数、梯度范数与峰值显存。

Tail-aware 中心的梯度偏差与停止梯度语义

下面固定一个 prefix s 和一个 inner step，写 $q=\pi_k(\cdot\mid s)$、$p=\pi_{k,n}(\cdot\mid s)$、$T=\pi_T(\cdot\mid s)$。假设有限词表上的三者严格为正，p 关于参数可微，$\eta>0$，且 S_J 由冻结的 q 选出，因此求导时支持集不变。用相同的支持集定义两个遗漏的尾部形状项：

$$b_J^T(s)=q(S_J^c)\,\mathrm{KL}\big(q(\cdot\mid S_J^c)\|T(\cdot\mid S_J^c)\big), \tag{2.97}$$

$$b_{J,n}^S(s)=q(S_J^c)\,\mathrm{KL}\big(q(\cdot\mid S_J^c)\|p(\cdot\mid S_J^c)\big). \tag{2.98}$$

若尾部为空，两项按连续延拓定义为零。Tail-aware 的链式分解给出

$$\widehat{\mathcal{K}}_k^T=\mathcal{K}_k^T-b_J^T,\qquad \widehat{\mathcal{K}}_{k,n}^S=\mathcal{K}_{k,n}^S-b_{J,n}^S. \tag{2.99}$$

这些估计对固定 prefix 是确定性的，因而这里的偏差来自尾部聚合，并非来自额外 sampled token 的随机性。

定理 2.7 (Tail-aware Mean/BPO 解析更新的偏差)

令 $g_{\mathrm{Mean}}(s)$、$g_{\mathrm{BPO}}(s)$ 为精确条件 KL 中心的 score-function 梯度，$\widehat{g}_{\mathrm{Mean}}(s)$、$\widehat{g}_{\mathrm{BPO}}(s)$ 为替换成 Tail-aware 中心并对整个权重停止梯度后的条件期望。则

$$\widehat{g}_{\mathrm{Mean}}(s)-g_{\mathrm{Mean}}(s)=\eta b_J^T(s)\mathbb{E}_{a\sim q}[\nabla_\theta\log p(a)], \tag{2.100}$$

$$\widehat{g}_{\mathrm{BPO}}(s)-g_{\mathrm{BPO}}(s)=\left(b_J^T(s)-\frac{b_{J,n}^S(s)}{\eta}\right)\mathbb{E}_{a\sim q}[\nabla_\theta\log p(a)]. \tag{2.101}$$

相应的 BPO 近似残差

$$\widehat{D}_\theta(a)=\log\frac{p(a)}{q(a)}+\widehat{\mathcal{K}}_{k,n}^S-\eta\left(\log\frac{T(a)}{q(a)}+\widehat{\mathcal{K}}_k^T\right) \tag{2.102}$$

满足

$$\mathbb{E}_q[\widehat{D}_\theta]=-b_{J,n}^S+\eta b_J^T. \tag{2.103}$$

对任意固定 prefix 测度 d，总体偏差是上述条件偏差关于 d 的期望。

证明 精确 Mean 残差为 $A_\theta(a)=\log(p(a)/q(a))-\eta(\log(T(a)/q(a))+\mathcal{K}_k^T)$。代入 $\widehat{\mathcal{K}}_k^T=\mathcal{K}_k^T-b_J^T$，逐动作得到

$$\widehat{A}_\theta(a)=A_\theta(a)+\eta b_J^T.$$

两者分别乘以 $\nabla_\theta\log p(a)$，在同一冻结分布 q 下取期望，即得 Mean 的偏差公式。对于 BPO，两个中心的替换给出

$$\widehat{D}_\theta(a)=D_\theta(a)-b_{J,n}^S+\eta b_J^T.$$

精确残差的均值为

$$\mathbb{E}_q[D_\theta]=-\mathcal{K}_{k,n}^S+\mathcal{K}_{k,n}^S-\eta(-\mathcal{K}_k^T+\mathcal{K}_k^T)=0.$$

对替换后的残差取期望便得到所述非零均值。再将逐动作残差差除以 η，乘以 score，并在 q 下取期望，得到 BPO 的偏差公式。最后在固定 d 下积分，期望线性性给出总体结论。

若 $\|\nabla_\theta\log p(a)\|\le G(s)$，三角不等式还给出

$$\|\mathbb{E}_d[\widehat{g}_{\mathrm{Mean}}-g_{\mathrm{Mean}}]\|\le\eta\mathbb{E}_d[b_J^T G], \tag{2.104}$$

$$\|\mathbb{E}_d[\widehat{g}_{\mathrm{BPO}}-g_{\mathrm{BPO}}]\|\le\mathbb{E}_d[|b_J^T-b_{J,n}^S/\eta|G]. \tag{2.105}$$

因此 BPO 的两个中心误差可能抵消，也可能被 $1/\eta$ 放大。单独降低 teacher KL 的 RMSE 不能保证 BPO 梯度误差同步下降。在 $p=q$ 时，$b_{J,n}^S=0$ 且 $\mathbb{E}_q[\nabla_\theta\log p]=\nabla_\theta\sum_a p(a)=0$，所以两种更新的条件偏差都为零；inner 更新后一般不再满足该条件。

命题 2.6 (Tail-aware BPO 平方损失与 SG 更新的区别)

若 student Tail-aware 中心保留梯度，近似平方目标 $\widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \mathbb{E}_q[\widehat{D}_\theta^2]/(2\eta)$ 的完整梯度为

$$\nabla_\theta \widehat{\mathcal{L}}_{\mathrm{BPO}}(s) = \widehat{g}_{\mathrm{BPO}}(s) + \left(b_J^T - \frac{b_{J,n}^S}{\eta}\right) \nabla_\theta \widehat{\mathcal{K}}_{k,n}^S(s). \tag{2.106}$$

Algorithm 5 使用第一项，即对原始 BPO 解析梯度的近似；它一般不等于替换中心后的平方损失梯度。

证明 q, T, S_J 均冻结，因此

$$\nabla_\theta \widehat{D}_\theta(a) = \nabla_\theta \log p(a) + \nabla_\theta \widehat{\mathcal{K}}_{k,n}^S.$$

对平方目标使用链式法则，得到

$$\nabla_\theta \widehat{\mathcal{L}}_{\mathrm{BPO}} = \frac{1}{\eta}\mathbb{E}_q[\widehat{D}_\theta \nabla_\theta \log p] + \frac{1}{\eta}\mathbb{E}_q[\widehat{D}_\theta]\nabla_\theta \widehat{\mathcal{K}}_{k,n}^S.$$

第一项是 SG 权重的 score-function 更新；将上一条定理的残差均值代入第二项，即得结论。精确中心下残差均值为零，第二项消失；有限支持集的 Tail-aware 中心不保证这一消去。

Mean 的情况不同：teacher 中心完全冻结，故 $\nabla_\theta \widehat{A}_\theta = \nabla_\theta \log p$。其平方损失与 $\mathrm{stopgrad}(\widehat{A}_\theta)\log p$ 在每个 sampled action 上具有相同梯度，而不仅是期望梯度相同。上述结论都针对固定参数与固定条件分布；反复复用一批 rollout 并用它更新参数，还会产生有限数据的优化与泛化误差，不能由条件无偏性消除。

缓存上，CPU/NVMe 保存 token IDs、attention mask、response mask、rollout 动作以及 anchor/teacher action log-prob。Tail-aware 路径另外冻结 anchor 的 top-J IDs、头部 log-prob、尾部总质量和 teacher KL 中心；student 的 action log-prob、这些 IDs 上的 log-prob 和尾部质量每个 inner step 重算。Teacher 中心构造完即可释放其完整 logits，无需保存 teacher 全词表分布。保存完整 logits 的代价是 $O(BH|\mathcal{V}|)$，保存 top-J 摘要是 $O(BHJ)$。以 $|\mathcal{V}| = 150{,}000$、FP16 为例，一个 prefix-token 的完整 logits 约 300 kB，8192 token 单序列约 2.46 GB；因此全词表 logits 不放进 replay buffer。GPU 只保留当前 microbatch 的 student 激活及打分 logits，完成摘要与动作权重计算后释放不再需要的打分张量。此路径没有额外 anchor token 抽样；中心的条件采样方差为零，但保留定理 2.7 给出的尾部形状偏差。PMD-Part 暂不启用，因为其 $\log Z_k$ 需要另一套估计与误差控制。

Algorithm 5 直接使用 rollout 保存的 (s, a)，每个 token occurrence 具有相同权重。式中的求和是经验训练目标的梯度：若使用 microbatch，将 $|\mathcal{B}_k|^{-1}$ 换成该批有效 response token 的归约权重，并在累积与分布式归约时保持一致。同一轨迹中的 prefix 具有相关性，随机轨迹长度也影响经验归一化；因此这条有限数据实现不意味着总体 token 测度梯度具有有限样本严格无偏性。对固定 prefix 与固定参数，动作来自 π_k 时，MDPO 的 $\pi_{k,n}/\pi_k$ 比率将条件动作期望变换到当前 student；Mean/BPO 原本就在 anchor 测度下定义，故没有该比率。所有三种权重都在当前 inner 参数处重新计算再停止梯度，而不是在 outer 开始时固定至整个 inner loop。

这里 Tail-aware 只替换 Mean/BPO 的数值中心，解析 score-function 权重整体停止梯度。它不是把动作期望改成头部求和：动作仍按 anchor 分布积分或采样，尾部动作仍参与 reward 和 score 更新。MDPO 的期望按当前 student 分布，若使用冻结 anchor 动作，必须乘以停止梯度的 $\pi_{k,n}/\pi_k$ 测度比。由于 Tail-aware 对中心存在负偏差，有限 J 的 Mean/BPO 更新一般属于有偏近似；$J = |\mathcal{V}|$ 时必然恢复精确解析梯度，有限支持集下也可在上述偏差项为零时恢复。参数 EMA 与概率混合也必须分别实现；以下 categorical 验证采用概率混合，真实模型参数 EMA 不能被声称与它等价。算法的 soft 分支要求策略类能表示逐 prefix 的概率混合；一般神经网络策略类不满足这一封闭性，本文真实模型训练采用 hard sync。若另行采用参数 EMA，更新式为 $\theta_{k+1} = (1-\rho)\theta_k + \rho\theta_{k,N}$，并令 $\pi_{k+1} = \pi_{\theta_{k+1}}$；这是另一条动力学，不能套用概率混合的恒等式。

算法中的同步发生在整个 inner loop 结束之后。因而在固定 k 的所有 N 次更新中，rollout 测度、anchor ratio π_k/π_T 以及所有 mirror target 都保持不变；只有 student 参数 $\theta_{k,n}$ 变化。hard sync 令下一轮 anchor 完全等于 inner 末端 student，soft sync 则令下一轮 anchor 是旧 anchor 与 inner 末端 student 的凸组合。完成同步后丢弃 $\widehat{d}_k$，使用新的 π_{k+1} 重新 rollout，而不是继续复用旧 rollout。若 inner loop 没有收敛，$\pi_{k,N}$ 只是当前固定 mirror 子问题的有限步近似解；outer 动力学仍由上述同步映射严格定义。

只有 sampled next token：无完整词表时的估计路径

如果每个 prefix 只有 rollout 中的下一个 token $a \sim \pi_k(\cdot \mid s)$，仍然可以无偏观测 $r_k(s,a)$，但不能从一个样本无偏得到 $\log Z_k(s)$：先估计 Z_k 再取对数会产生 plug-in bias。因此 sampled-token 路径不应把 PMD-Part 的 exact $\log Z_k$ 假装已知。可行选择如下。

第一，使用 BPO 或 PMD-Mean，以同一个 prefix 的多条 sampled actions 估计 conditional center；它们不需要显式的 $\log Z_k$。第二，使用 MDPO 的 action-sampled objective，并用 K4/K3^{++} 估计 KL 项；这要求保留 student/anchor 的 sampled log-prob。第三，如果只有一条 action，却仍想做 PMD-Part，只能使用外部 baseline、跨 batch center 或 self-normalized $\widehat{\log Z}$，并在理论和日志中标记其 bias。

对单个 sampled token，PMD-Part 的可实现 loss 是带 baseline 的近似

$$\widehat{\ell}_{\mathrm{Part}} = \frac{1}{2}\big[\eta(r_k(s,a) - b(s)) - U_{k,n}(s,a)\big]^2,$$

它只有在 $b(s) = \log Z_k(s)/\eta$ 时才等于 exact residual；任意其他 baseline 会留下一个 prefix-dependent constant，因而改变 PMD-Part 的有限参数投影。BPO 的中心化 residual 则可用同 prefix 的 m 个 sampled tokens 构造，$m = 1$ 时必须使用跨样本或 frozen center。

完整 vocabulary 与 sampled-token 两条路径的区别是信息论上的：前者能精确知道整个 categorical mirror target，后者只能无偏知道在 anchor 下抽到的一个 action 的 reward。对每个给定方法，两条信息访问路径在无限样本、无函数类误差且 center/partition 估计一致时具有相同总体解；PMD-Mean 的解是 Lambert-W 分布，另外三种方法的解是 Gibbs 分布。有限 batch 下，full-vocabulary 的主要误差是参数优化和 prefix coverage，sampled-token 额外承担 reward、center、KL ratio 和 prefix reuse 的估计方差。

Algorithm 5 Tail-aware OPD outer–inner optimization

Semantics: 根据正文重构；冻结 *outer rollout*，以 *Tail-aware KL* 中心运行 *Mean*、*BPO* 或 *MDPO*，再同步并重新 *rollout*

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial student $\pi_0 = \pi_{\theta_{0,0}}$, outer steps K_{out}, rollout batch size $B \geq 1$, horizon $H \geq 1$, method M, $\eta > 0$, inner steps $N \geq 1$, inner learning rate schedule $\{\alpha_{k,n}\}$, sync mode $\text{Sync} \in \{\text{hard}, \text{soft}\}$, soft-sync weight $\rho \in (0, 1]$

Ensure: final policy $\pi_{K_{\text{out}}}$ and parameters $\theta_{K_{\text{out}}}$

for $k = 0, \ldots, K_{\text{out}} - 1$ **do**
  $\mathcal{B}_k \leftarrow \varnothing$ ▷ $\mathcal{B}_k$ stores rollout pairs with multiplicity
  for $i = 1, \ldots, B$ **do**
    sample prompt $x_i \sim \mathcal{D}$
    generate $y_i = (a_{i,1}, \ldots, a_{i,\tau_i})$ with $a_{i,t} \sim \pi_k(\cdot \mid s_{i,t})$, $s_{i,t} = (x_i, a_{i,<t})$; stop at EOS or H tokens
    $\mathcal{B}_k \leftarrow \mathcal{B}_k \uplus \{(s_{i,t}, a_{i,t}) : 1 \leq t \leq \min(\tau_i, H)\}$
  end for
  if $\mathcal{B}_k = \varnothing$, terminate with an empty-rollout error before normalization
  define $\widehat{d}_k$ as the empirical distribution assigning each prefix occurrence in $\mathcal{B}_k$ equal mass
  $\theta_{k,0} \leftarrow \theta_k$ ▷ initialize the inner student from the current outer policy
  query frozen $\log \pi_T(v \mid s)$ and $\log \pi_k(v \mid s)$ for $(s, a) \in \mathcal{B}_k$, $v \in \mathcal{V}$; retain summaries and action log-prob only
  choose and freeze $S_J(s) = \text{TopJ}(\pi_k(\cdot \mid s))$; freeze $\log \pi_k(v \mid s)$ for $v \in S_J(s)$ and $\log \pi_T(a \mid s), \log \pi_k(a \mid s)$ for rollout actions
  $\widehat{\mathcal{K}}_k^T(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s))$ using the same $S_J(s)$ and aggregate tail masses
  omit PMD-Part because it requires $\log Z_k$; use all retained rollout pairs, including tail actions
  for $n = 0, \ldots, N - 1$ **do**
    compute current $\log \pi_{k,n}(v \mid s)$ and $\widehat{\mathcal{K}}_{k,n}^S(s) \leftarrow \mathcal{K}_J^{\text{TA}}(\pi_k \| \pi_{k,n})$ on the frozen $S_J(s)$; freeze both centers within this gradient evaluation
    if $M = \text{Mean}$ **then**
      $g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\log \frac{\pi_{k,n}(a|s)}{\pi_k(a|s)} - \eta \left(\log \frac{\pi_T(a|s)}{\pi_k(a|s)} + \widehat{\mathcal{K}}_k^T(s) \right) \right) \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$
    else if $M = \text{BPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\eta^{-1} \left(\log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} + \widehat{\mathcal{K}}_{k,n}^S(s) \right) - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} - \widehat{\mathcal{K}}_k^T(s) \right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    else if $M = \text{MDPO}$ **then**
      $$g_{k,n} \leftarrow \frac{1}{|\mathcal{B}_k|} \sum_{(s,a) \in \mathcal{B}_k} \text{stopgrad}\left(\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} \left(\eta^{-1} \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)} \right) \right) \cdot \nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)$$
    end if
    $\theta_{k,n+1} \leftarrow \text{OptimizerStep}(\theta_{k,n}, g_{k,n}; \alpha_{k,n})$ ▷ gradient descent: plain SGD gives $\theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  if $\text{Sync} = \text{hard}$ **then**
    $\theta_{k+1} \leftarrow \theta_{k,N}$ and $\pi_{k+1} \leftarrow \pi_{\theta_{k+1}}$
  else
    $\pi_{k+1}(\cdot \mid s) \leftarrow (1 - \rho)\pi_k(\cdot \mid s) + \rho \pi_{k,N}(\cdot \mid s)$ for every prefix s
    choose θ_{k+1} representing this mixture, assuming the policy class is closed under mixtures ▷ categorical probability mixture; neural-model implementation uses hard sync
  end if
end for
return $(\pi_{K_{\text{out}}}, \theta_{K_{\text{out}}})$

Algorithm 6 OPD sampled-token inner update

Semantics: 每个 prefix 只访问 rollout 的下一个 token

Require: frozen anchor π_k, teacher π_T, rollout pairs (s_i, a_i), method M, center size m, η

Ensure: updated student parameters θ

for each prefix s_i **do**
  read $\log \pi_T(a_i \mid s_i)$ and $\log \pi_k(a_i \mid s_i)$
  $r_i \leftarrow \log \pi_T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  if $M = \mathrm{Mean}$ **then**
    obtain independent auxiliary actions at the same prefix to estimate a frozen reward center $\widehat{\bar{r}}_i$
    $\ell_i \leftarrow \frac{1}{2}[U_{k,n}(s_i, a_i) - \eta\,\mathrm{stopgrad}(r_i - \widehat{\bar{r}}_i)]^2$
  else if $M = \mathrm{BPO}$ **then**
    estimate the reward center and current student log-ratio center at the same prefix
    form a centered residual loss with the $1/(2\eta)$ factor; retain the student center's derivative
    use the finite-sample correction specified in the BPO inner algorithm
  else if $M = \mathrm{MDPO}$ **then**
    form $w_i = \exp(\log \pi_{k,n}(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i)))$
    $\ell_i \leftarrow -w_i r_i + \eta^{-1}\widehat{\mathrm{KL}}_i$ with K4/K3^{++} and retain correct autograd paths
  else if $M = \mathrm{Part}$ **then**
    estimate or load a prefix baseline $\widehat{\log Z_i}$; record its bias source
    update $\frac{1}{2}[\eta r_i - \widehat{\log Z_i} - U_{k,n}(s_i, a_i)]^2$
  end if
end for
perform gradient descent on $B^{-1}\sum_i \ell_i$ while keeping π_k and π_T frozen
return θ

第三章 KL 估计量、无偏性与方差

3.1 K4 的无偏性

本节固定 prefix s，记 $p = \pi_{k,n}(\cdot \mid s)$、$q = \pi_k(\cdot \mid s)$，并从 p 采样 a。定义

$$c_{k,n}(s,a) = \frac{p(a)}{\mathrm{stopgrad}(p(a))}, \qquad U_{k,n}(s,a) = \log \frac{p(a)}{q(a)}.$$

数值上 $c_{k,n} = 1$，但其导数为 $\nabla \log p(a)$。

定理 3.1 (K4 value and gradient)

若 $p \ll q$ 且二阶矩有限，则

$$\mathbb{E}_{a\sim p}[c_{k,n}(s,a)U_{k,n}(s,a)] = \mathrm{KL}(p\|q),$$

并且自动微分意义下

$$\mathbb{E}_{a\sim p}[\nabla_{\theta_{k,n}}\{c_{k,n}(s,a)U_{k,n}(s,a)\}] = \nabla_{\theta_{k,n}} \mathrm{KL}(p\|q).$$

♡

证明 数值 value 中 $c_{k,n} = 1$，所以第一式是

$$\mathbb{E}_p[-\log(q/p)] = \sum_a p(a)\log(p(a)/q(a)).$$

对 stop-gradient 构造求导时，$U_{k,n} = \log p - \log q$ 的 derivative 与 $c_{k,n}$ 的 derivative 共同给出

$$\nabla_{\theta_{k,n}}\{c_{k,n}U_{k,n}\} = \nabla_{\theta_{k,n}} \log p(a)\,[\log p(a) - \log q(a)] + \nabla_{\theta_{k,n}} \log p(a).$$

最后一项在 p 下期望为零，第一项正是 KL 的 score-function derivative。 □

K1 的数值也无偏，但其 autograd gradient 为零；K3 的 gradient 对应 $\mathrm{KL}(q\|p)$ 的方向；K2 梯度正确但 value 有偏。上述构造针对 MDPO 中的 $\mathrm{KL}(p\|q)$。BPO 的 student center 是相反方向的 $\mathrm{KL}(q\|p)$，应在冻结 anchor q 下估计 $\log(q/p)$；PMD-Mean 不含这个 student KL center。

3.2 固定 anchor 测度上的重要性校正

若工程上必须从 $q = \pi_k$ 采样，令 $\omega_{k,n}(s,a) = p(a)/q(a)$，并在积分权重上停止梯度。对于任意可积向量 h，

$$\mathbb{E}_q[\mathrm{stopgrad}(\omega_{k,n})h(a)] = \mathbb{E}_p[h(a)].$$

对于 OPD，MDPO 的损失为原始 mirror objective 的负值。其固定 anchor 测度梯度估计为

$$\widehat{g}_i^{\mathrm{MDPO}} = \mathrm{stopgrad}(\omega_{k,n}(s,a_i))\,\mathrm{stopgrad}\left[\frac{1}{\eta}U_{k,n}(s,a_i) - r_k(s,a_i)\right]\nabla_{\theta_{k,n}} \log p(a_i), \qquad a_i \sim q.$$

此处 $p = \pi_{k,n}(\cdot \mid s)$、$q = \pi_k(\cdot \mid s)$。梯度权重与 score 的乘积二阶可积时，估计量无偏；若该乘积范数由 C 上界，则

$$\mathbb{E}_q\|\widehat{g}_i^{\mathrm{MDPO}}\|^2 \le C^2\mathbb{E}_q[(p/q)^2] = C^2\big(1 + \chi^2(p\|q)\big). \tag{3.1}$$

这里的 p/q 测度校正属于 MDPO；不能据此为 PMD-Mean 或 BPO 添加 student importance ratio。它们原本就在冻结 anchor 下定义，action 从 q 采样时无需这种校正。

对 BPO，完整 conditional center 已知时的损失梯度为

$$\nabla_{\theta_{k,n}}\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{\pi_k}\left[\frac{R_{k,n}^{\mathrm{BPO}}(s,a)}{\eta}\nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)\right].$$

对 PMD-Mean，损失梯度为

$$\nabla_{\theta_{k,n}}\mathcal{L}_{\mathrm{Mean}} = \mathbb{E}_{\pi_k}\left[R_{k,n}^{\mathrm{Mean}}(s,a)\,\nabla_{\theta_{k,n}} \log \pi_{k,n}(a \mid s)\right].$$

估计 center 时须区分解析 policy-gradient 权重与 sampled 原始平方损失：前者使用停止梯度的权重，后者的 BPO student center 保留梯度，并采用第二章给出的有限样本系数校正。单个 center 估计量的无偏性不自动保证它嵌入平方损失后的梯度无偏。

3.3 Top-J 与完整词表的关系

如果保存当前策略和 anchor 的 top-J logits，完整 reverse KL 可以拆成

$$\sum_{a\in S_J} p(a)\log\frac{p(a)}{q(a)} + \sum_{a\notin S_J} p(a)\log\frac{p(a)}{q(a)}.$$

第一项可精确计算；第二项不能被简单删除，否则得到截断 KL 而非完整 KL。2602.04417 的 Top-J 估计量在尾部使用 masked sampled K4：固定头部集合 S_J，若采样 token 不在 S_J，加入

$$\mathbf{1}(a\notin S_J)\ \mathrm{stopgrad}\left(\frac{p(a)}{\pi_{\text{sampling}}(a)}\right) c_{k,n}(s,a)U_{k,n}(s,a).$$

它同时保持 value 和 gradient 无偏。完整词表 oracle 与 sampled K4 分别核对 mirror target 和尾部估计误差，二者在实验中单独报告。

3.4 四种 Top-J KL 对象的统一定义

本节分析 student–teacher KL。固定一个 prefix s，局部记号为

$$p(v)=\pi_{k,n}(v\mid s),\qquad q(v)=\pi_T(v\mid s),\qquad \ell(v)=\log\frac{p(v)}{q(v)}.$$

所有结论都是逐 prefix 的；外层 OPD 再对 rollout 诱导的访问测度 d_k 取期望。设 $S_J\subseteq\mathcal{V}$ 是选定的 J 个 token 的支持集，通常取 student 或 teacher 的 top-J。定义

$$P_J=\sum_{v\in S_J} p(v),\qquad Q_J=\sum_{v\in S_J} q(v),\qquad P_{\text{tail}}=1-P_J,\qquad Q_{\text{tail}}=1-Q_J.$$

完整 reverse KL 的精确分解为

$$\mathrm{KL}(p\|q)=\underbrace{\sum_{v\in S_J} p(v)\ell(v)}_{H_J}+P_{\text{tail}}\log\frac{P_{\text{tail}}}{Q_{\text{tail}}}+P_{\text{tail}}\,\mathrm{KL}(\widetilde{p}_{\text{tail}}\|\widetilde{q}_{\text{tail}}),\tag{3.2}$$

其中 $\widetilde{p}_{\text{tail}}(v)=p(v)/P_{\text{tail}}$、$\widetilde{q}_{\text{tail}}(v)=q(v)/Q_{\text{tail}}$ 只在 $\mathcal{V}\setminus S_J$ 上定义。式 (3.2) 是后面区分四种方法的核心：它把误差明确分成头部、尾部总质量和尾部内部形状三部分。

3.4.1 Normalized Top-J KL：局部条件分布目标

Normalized Top-J 先把两个分布限制到同一个支持集，再分别归一化：

$$\bar{p}_J(v)=\frac{p(v)}{P_J},\qquad \bar{q}_J(v)=\frac{q(v)}{Q_J},\qquad v\in S_J.$$

其目标定义为

$$\mathcal{K}_J^{\text{norm}}=\mathrm{KL}(\bar{p}_J\|\bar{q}_J)=\frac{H_J}{P_J}+\log\frac{Q_J}{P_J}.\tag{3.3}$$

命题 3.1 (Normalized Top-J 的语义)

$\mathcal{K}_J^{\text{norm}}$ 是支持集条件分布的 KL，而不是完整 KL 的无偏估计量。对固定 prefix，它是确定性的；其条件采样方差为零。只有在额外满足尾部质量和尾部形状误差均可忽略时，它才近似完整 KL。

证明 将 $\bar{p}_J$ 和 $\bar{q}_J$ 代入 KL 定义，得到

$$\sum_{v\in S_J}\frac{p(v)}{P_J}\left(\log\frac{p(v)}{q(v)}+\log\frac{Q_J}{P_J}\right)=\frac{H_J}{P_J}+\log\frac{Q_J}{P_J}.$$

该式只依赖 S_J 内的概率以及两个头部质量，不包含式 (3.2) 中的尾部条件 KL。由于给定 p,q,S_J 后没有随机变量，条件方差为零。它的目标分布本身已经由 (p,q) 改成了 $(\bar{p}_J,\bar{q}_J)$，所以不能称为完整 KL 的无偏估计量。

归一化的必要性是目标稳定性，而不是无偏性。若直接优化未归一化的 H_J，对一个保留 token 的概率求导得到

$$\frac{\partial}{\partial p(v)}p(v)\log\frac{p(v)}{q(v)}=\log\frac{p(v)}{q(v)}+1.$$

在尾部可以吸收剩余质量的参数化下，驻点满足 $p(v)=e^{-1}q(v)$。因此未归一化的局部目标会通过整体压低头部概率来降低损失；归一化后，头部内部的共同缩放被消除，目标只比较相对形状。这个稳定性修复同时带来尾部盲区：$\mathcal{K}_J^{\mathrm{norm}}$ 对 top-J 外的 logit 没有直接梯度，且 top-J 内梯度总和为零。

3.4.2 Truncated Top-J：有偏的头部项

Truncated Top-J 保留完整 KL 分解中的第一项：

$$\mathcal{K}_J^{\mathrm{trunc}}=H_J=\sum_{v\in S_J}p(v)\log\frac{p(v)}{q(v)}. \tag{3.4}$$

它不是 KL，因为头部质量通常不等于一。由式 (3.2)，其逐 prefix 偏差为

$$\mathcal{K}_J^{\mathrm{trunc}}-\mathrm{KL}(p\|q)=-P_{\mathrm{tail}}\log\frac{P_{\mathrm{tail}}}{Q_{\mathrm{tail}}}-P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}). \tag{3.5}$$

尾部条件 KL 非负，因此未归一化截断项总是遗漏一个非负的尾部形状项，但尾部总质量项的符号可以正也可以负。它没有 sampled-token 随机性，固定 prefix 下方差为零；因此在样本很少、尾部 log-ratio 很重时，可能比无偏估计量有更低 RMSE。

3.4.3 EMA Top-J：精确头部加 sampled tail correction

EMA-PG 的 Top-J 估计器把 H_J 和尾部的 sampled-token 修正相加。令 $A\sim p$，定义

$$\widehat{\mathcal{K}}_J^{\mathrm{EMA}}=H_J+\mathbf{1}\{A\notin S_J\}\ell(A). \tag{3.6}$$

定理 3.2 (EMA Top-J 的无偏性)

在 $A\sim p$ 且 $p\ll q$ 时，若 $\mathbb{E}_p[|\ell(A)|]<\infty$，则

$$\mathbb{E}[\widehat{\mathcal{K}}_J^{\mathrm{EMA}}\mid s]=\mathrm{KL}(p\|q).$$

若二阶矩有限，其条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_J^{\mathrm{EMA}}\mid s)=\sum_{v\notin S_J}p(v)\ell(v)^2-\left(\sum_{v\notin S_J}p(v)\ell(v)\right)^2. \tag{3.7}$$

♡

证明 由采样分布为 p，

$$\mathbb{E}\left[\mathbf{1}\{A\notin S_J\}\ell(A)\right]=\sum_{v\notin S_J}p(v)\ell(v).$$

与 H_J 相加后正好得到完整词表 KL。因为 H_J 对固定 prefix 是常数，方差只来自尾部随机变量 $\mathbf{1}\{A\notin S_J\}\ell(A)$，展开其二阶矩即得式 (3.7)。

当 $J=0$ 时，式 (3.6) 是 sampled-token KL；当 $J=|\mathcal{V}|$ 时，它退化为完整 KL。它估计的是完整目标，因此不能把头部重新归一化；归一化会改变期望目标并破坏上述无偏性。

3.4.4 Tail-Aware Top-J：把尾部聚合为虚拟 token

Tail-Aware Top-J 只需要头部概率以及头部总质量，就把尾部聚合成一个虚拟 token：

$$\mathcal{K}_J^{\mathrm{TA}} = H_J + P_{\mathrm{tail}} \log \frac{P_{\mathrm{tail}}}{Q_{\mathrm{tail}}}. \tag{3.8}$$

命题 3.2 (Tail-Aware Top-J 是完整 KL 的下界)

$$\mathcal{K}_J^{\mathrm{TA}} = \mathrm{KL}(p\|q) - P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) \le \mathrm{KL}(p\|q).$$

等号当且仅当尾部条件分布相等，或 $P_{\mathrm{tail}} = 0$。

证明 将式 (3.2) 中的尾部形状项移到右侧即可。KL 非负性给出不等式；等号条件来自 $P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) = 0$。

Tail-Aware 与 normalized Top-J 的差别在于：前者保留 P_{tail} 和 Q_{tail} 的质量差，后者把质量都重新缩放成一。Tail-Aware 仍然有尾部形状偏差，但不会允许 student 通过把质量整体移出 S_J 来逃避 KL 惩罚；它因此是一个有结构的下界，而 normalized Top-J 是条件分布目标。

3.4.5 Tail-Aware 的误差及其与截断项的比较

记尾部质量项为 $m_J = P_{\mathrm{tail}} \log(P_{\mathrm{tail}}/Q_{\mathrm{tail}})$，尾部形状项为 $b_J = P_{\mathrm{tail}}\,\mathrm{KL}(\widetilde{p}_{\mathrm{tail}}\|\widetilde{q}_{\mathrm{tail}}) \ge 0$。由完整分解，四种对象中两个确定性近似的误差分别为

$$\mathcal{K}_J^{\mathrm{trunc}} - \mathrm{KL}(p\|q) = -(m_J + b_J), \qquad \mathcal{K}_J^{\mathrm{TA}} - \mathrm{KL}(p\|q) = -b_J.$$

因此在经验 prefix 测度 $\widehat{d}$ 上，Tail-Aware 的平均 bias、条件采样方差与 RMSE 为

$$\mathrm{Bias}_{\widehat{d}}(\mathrm{TA}) = -\mathbb{E}_{\widehat{d}}[b_J], \qquad \mathbb{E}_{\widehat{d}}[\mathrm{Var}(\mathcal{K}_J^{\mathrm{TA}} \mid s)] = 0, \qquad \mathrm{RMSE}_{\widehat{d}}(\mathrm{TA}) = \sqrt{\mathbb{E}_{\widehat{d}}[b_J^2]}.$$

平均 bias 的平方一般小于逐 prefix bias 平方的平均，因而零条件方差不意味着 $\mathrm{RMSE} = |\mathrm{Bias}_{\widehat{d}}|$。Tail-Aware 与 Truncated 的逐 prefix 平方误差差为

$$(m_J + b_J)^2 - b_J^2 = m_J(m_J + 2b_J).$$

当 $P_{\mathrm{tail}} \ge Q_{\mathrm{tail}}$ 时，$m_J \ge 0$，Tail-Aware 的平方误差不大于截断项；当 $P_{\mathrm{tail}} < Q_{\mathrm{tail}}$ 时，$m_J < 0$，截断遗漏的质量项与形状项可能相互抵消，此时 Tail-Aware 的 RMSE 不保证小于 Truncated。这个抵消降低的是标量估计误差，不能说明未归一化截断项是更合适的训练目标。

对同一 prefix 上嵌套的支持集 $S_J \subseteq S_{J+1}$，增加一个保留 token 相当于把 Tail-Aware 的虚拟尾部 token 分裂成该 token 与剩余尾部。KL 的链式分解给出

$$\mathcal{K}_{J+1}^{\mathrm{TA}} - \mathcal{K}_J^{\mathrm{TA}} = P_{\mathrm{tail}}\,\mathrm{KL}\left(\left(\frac{p(v)}{P_{\mathrm{tail}}}, \frac{P_{\mathrm{tail}} - p(v)}{P_{\mathrm{tail}}}\right) \middle\| \left(\frac{q(v)}{Q_{\mathrm{tail}}}, \frac{Q_{\mathrm{tail}} - q(v)}{Q_{\mathrm{tail}}}\right)\right) \ge 0.$$

这里的 $P_{\mathrm{tail}}, Q_{\mathrm{tail}}$ 属于分裂前的支持集，v 是新增 token。因此 Tail-Aware 随 J 单调逼近完整 KL，其 bias 的绝对值和 RMSE 也单调不增；这可以直接用于检查真实模型统计中的实现错误。该单调性不要求 teacher 的概率排序与 student 相同。

3.5 四种方法在 OPD 中的选择

如果 OPD 的目标是训练一个稳定的局部 dense reward，$\mathcal{K}_J^{\mathrm{norm}}$ 合理，因为它在可获得的支持集上是合法 KL，且固定 prefix 下无额外采样方差。它必须被解释为局部条件蒸馏，而不能写成完整 KL 的估计量。

如果目标是 vanilla OPD 的完整 reward 或完整 reverse KL，应该使用 $\mathcal{K}_J^{\mathrm{EMA}}$，或者使用 $\mathcal{K}_J^{\mathrm{TA}}$ 作为低方差下界。$\mathcal{K}_J^{\mathrm{trunc}}$ 适合做低方差基线，但需要显式报告尾部偏差。

对本项目的符号约定，使用

$$\mathcal{K}_J^{\mathrm{norm}}, \quad \mathcal{K}_J^{\mathrm{trunc}}, \quad \widehat{\mathcal{K}}_J^{\mathrm{EMA}}, \quad \mathcal{K}_J^{\mathrm{TA}}$$

分别表示上述四个对象。它们不能共用一个 $\mathcal{K}_J$，否则会把“改变训练目标”和“估计同一个完整 KL”混为一谈。

3.6 有限 inner 更新的误差

设方法 M 的总体最优分布为 $\pi_k^{\star,M}$，inner 算法在固定 s 上得到 $\pi_{k,n}$。PMD-Mean 使用 Lambert-W target，另外三种方法使用 Gibbs target $\pi_k^{\star,\mathrm{Gibbs}}$。定义优化误差

$$e_{k,n}(s) = \mathrm{TV}\Big(\pi_{k,n}(\cdot \mid s), \pi_k^{\star,M}(\cdot \mid s)\Big).$$

对参数化损失，假设梯度是 L_{sm}-Lipschitz，随机梯度 $\widehat{g}_n$ 条件无偏且满足

$$\mathbb{E}[\widehat{g}_n \mid \theta_{k,n}] = \nabla\mathcal{L}(\theta_{k,n}), \qquad \mathbb{E}\big[\|\widehat{g}_n - \nabla\mathcal{L}(\theta_{k,n})\|^2 \mid \theta_{k,n}\big] \le \frac{\sigma^2}{B}.$$

普通 SGD 取 $\theta_{k,n+1} = \theta_{k,n} - \alpha\widehat{g}_n$，$0 < \alpha \le 1/L_{\mathrm{sm}}$。由光滑性不等式及条件无偏性，

$$\begin{aligned}\mathbb{E}[\mathcal{L}(\theta_{k,n+1}) \mid \theta_{k,n}] &\le \mathcal{L}(\theta_{k,n}) - \alpha\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2}{2}\mathbb{E}[\|\widehat{g}_n\|^2 \mid \theta_{k,n}] \\ &\le \mathcal{L}(\theta_{k,n}) - \frac{\alpha}{2}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 + \frac{L_{\mathrm{sm}}\alpha^2\sigma^2}{2B}.\end{aligned}$$

设 $\mathcal{L}_*$ 是损失下界，对 $n = 0, \dots, N-1$ 求和得到

$$\frac{1}{N}\sum_{n=0}^{N-1}\mathbb{E}\|\nabla\mathcal{L}(\theta_{k,n})\|^2 \le \frac{2(\mathcal{L}(\theta_{k,0}) - \mathcal{L}_*)}{\alpha N} + \frac{L_{\mathrm{sm}}\alpha\sigma^2}{B}.$$

此式控制平均梯度范数。将它转成 $e_{k,n}$ 的分布误差界还需要局部曲率或梯度与分布距离之间的定量关系。

对采用 student/anchor importance ratio 的 MDPO estimator，方差界包含 $1 + \chi^2(\pi_{k,n}\|\pi_k)$。PMD-Mean 和 BPO 的 anchor-measure estimator 直接分析 residual、score 与 center 的联合二阶矩。

PMD-Mean 到 Gibbs 分布的差异还包含总体目标偏差：

$$\mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Gibbs}}) \le \mathrm{TV}(\pi_{k,n}, \pi_k^{\star,\mathrm{Mean}}) + \mathrm{TV}(\pi_k^{\star,\mathrm{Mean}}, \pi_k^{\star,\mathrm{Gibbs}}).$$

增加 inner steps 只能降低第一项，第二项由均值近似决定。

第四章 Outer 同步与有限 inner 的动力学

4.1 Hard sync 的精确动力学

先考虑每个 history 的 teacher 分布 π_T 不随 outer 改变，并且 PMD-Part、未线性化 BPO 或 MDPO 的 inner 精确收敛到式 (1.10) 的 Gibbs 分布。hard sync 定义为

$$\pi_{k+1} = \frac{\pi_k^{1-\eta}\pi_T^{\eta}}{Z_k}.$$

定理 4.1 (Hard-sync geometric interpolation)

若 $0 < \eta \le 1$ 且初始策略与 π_T 互相绝对连续，则

$$\pi_k(a \mid s) = \frac{\pi_0(a \mid s)^{(1-\eta)^k}\pi_T(a \mid s)^{1-(1-\eta)^k}}{\sum_b \pi_0(b \mid s)^{(1-\eta)^k}\pi_T(b \mid s)^{1-(1-\eta)^k}}. \tag{4.1}$$

并且

$$\log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} = (1-\eta)^k \log \frac{\pi_0(a \mid s)}{\pi_T(a \mid s)} - \log C_k(s),$$

其中 $C_k(s)$ 是归一化常数。$\eta = 1$ 时一个 exact inner 将策略直接变成 teacher；$0 < \eta < 1$ 时每一轮只消除比例 η 的 log-density mismatch。

♡

证明 归纳证明。$k = 0$ 显然成立。假设式 (4.1) 成立，则

$$\pi_{k+1} \propto \pi_k^{1-\eta}\pi_T^{\eta} \propto \pi_0^{(1-\eta)^{k+1}}\pi_T^{(1-\eta)(1-(1-\eta)^k)+\eta}.$$

指数合并为 $1-(1-\eta)^{k+1}$，归一化后得到结论。 □

推论 4.1 (Outer contraction)

在任意固定 s 上，unnormalized log-ratio 的 contraction factor 是 $1-\eta$。若 log-ratio 初始振幅不超过 A_0，则归一化后 total variation 满足

$$\mathrm{TV}(\pi_k, \pi_T) \le \frac{1}{2}\left(e^{2A_0(1-\eta)^k} - 1\right).$$

该界说明小 η 不是免费加稳定性：它把每轮变化缩小，同时把达到相同 teacher proximity 所需的 outer steps 增加到 $O(\eta^{-1}\log(1/\varepsilon))$。

♡

4.2 PMD-Mean 的逐 prefix OPD 动力学

本节固定一个 prefix s，在有限词表 $\mathcal{V}$ 上分析 PMD-Mean 的总体最优解。假设 teacher 与当前 anchor 在每个 token 上均有正概率。每轮 inner 精确求解后执行 hard sync。以下结论描述这一分布空间更新；参数共享、有限 inner、采样误差与 prefix 测度变化需要另外控制。

原始 PMD-Mean 论文的三个相关结论在本地源文件中对应以下标签：

总体解定理：`thm:pmdmean_solution`。

混合正则化解释：`eq:mixed_subproblem`。

精细损失恒等式：`lem:pmdmean_quad_growth`。

本节采用逐 prefix 的 OPD reward 重新推导这些关系，并进一步证明 teacher KL 下降与 outer 收敛。本文乘子 λ 对应未缩放平方损失；若原论文温度为 $\tau = \eta^{-1}$，则 $\lambda = \lambda_{\mathrm{paper}}/\tau^2$。

4.2.1 代入 OPD reward 后的 Lambert-W 更新

固定第 k 轮与 prefix s，局部记

$$\begin{aligned} q_a &= \pi_k(a \mid s), & t_a &= \pi_T(a \mid s), \\ r_a &= \log \frac{t_a}{q_a}, & \kappa &= \mathrm{KL}(q\|t) = -\mathbb{E}_q r, \\ h_a &= r_a + \kappa, & G_a &= \eta h_a. \end{aligned} \tag{4.2}$$

因此 $\mathbb{E}_q h = \mathbb{E}_q G = 0$。待求 student 分布记为 p，其 log-ratio 为 $U_a = \log(p_a/q_a)$。PMD-Mean 的单轮问题是

$$\min_{p_a>0,\ \sum_a p_a=1} L_{\mathrm{Mean}}(p), \qquad L_{\mathrm{Mean}}(p) = \frac{1}{2}\sum_a q_a (U_a - \eta h_a)^2. \tag{4.3}$$

定理 4.2 (OPD 下 PMD-Mean 的精确单轮解)

式 (4.3) 有唯一全局最优分布 $p^\star$。它满足

$$\begin{aligned} U_a^\star &= \eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right), \\ p_a^\star &= q_a \exp\left\{\eta\left(\log\frac{t_a}{q_a} + \kappa\right) - W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right)\right\}. \end{aligned} \tag{4.4}$$

这里 $\lambda \geq 0$ 由 $\sum_a p_a^\star = 1$ 唯一确定，并且

$$\lambda = \mathrm{KL}(q\|p^\star). \tag{4.5}$$

若 $q \neq t$，则 $\lambda > 0$，还可以写成

$$p_a^\star = \frac{q_a}{\lambda} W_0\left(\lambda e^{\eta\kappa}\left(\frac{t_a}{q_a}\right)^\eta\right). \tag{4.6}$$

若 $q = t$，则 $\lambda = 0$ 且 $p^\star = q = t$。 ♡

证明 log-ratio 坐标中的约束是 $\mathbb{E}_q e^U = 1$。拉格朗日函数及一阶条件为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\mathbb{E}_q(U-\eta h)^2 + \lambda(\mathbb{E}_q e^U - 1),$$

$$U_a - \eta h_a + \lambda e^{U_a} = 0.$$

令 $v_a = \eta h_a - U_a$，得到 $v_a e^{v_a} = \lambda e^{\eta h_a}$，从而

$$U_a = \eta h_a - W_0(\lambda e^{\eta h_a}).$$

定义归一化函数

$$\Phi(\lambda) = \sum_a q_a \exp\{\eta h_a - W_0(\lambda e^{\eta h_a})\}.$$

W_0 在非负实轴上严格递增，因此 Φ 连续且严格递减。当 $q \neq t$ 时，h 非恒定；严格 Jensen 不等式给出

$$\Phi(0) = \mathbb{E}_q e^{\eta h} > e^{\eta \mathbb{E}_q h} = 1.$$

当 $\lambda \to \infty$ 时，恒等式

$$e^{\eta h_a - W_0(\lambda e^{\eta h_a})} = \lambda^{-1} W_0(\lambda e^{\eta h_a})$$

说明 $\Phi(\lambda) \to 0$。故存在唯一正根。若 $q = t$，则 $h = 0$，唯一非负根为零。

对构造出的非负乘子，拉格朗日函数的 Hessian 为

$$\nabla_U^2 \mathscr{L} = \mathrm{diag}\big(q_a(1 + \lambda e^{U_a})\big) \succ 0.$$

所以一阶条件确定了拉格朗日函数的唯一全局最小点。在任意可行点上，拉格朗日函数等于原目标，故这个可行最小点也是约束问题的唯一全局最优点。

最后对一阶条件取 q 均值，代入 $\mathbb{E}_q h = 0$ 与 $\mathbb{E}_q e^{U^\star} = 1$：

$$\mathbb{E}_q U^\star + \lambda = 0, \qquad \lambda = -\mathbb{E}_q \log \frac{p^\star}{q} = \mathrm{KL}(q\|p^\star).$$

将 h 展开即可得到式 (4.4)。

恢复全局记号时，$p^\star = \pi_k^{\star,\mathrm{Mean}}(\cdot \mid s)$，$\kappa = \mathcal{K}_k^T(s)$，而乘子是逐 prefix 的 $\lambda_k(s)$。hard sync 更新为 $\pi_{k+1} = \pi_k^{\star,\mathrm{Mean}}$。式 (4.4) 展示了 teacher–anchor 概率比如何进入 Lambert-W；W_0 中的修正随动作变化，不能吸收到一个公共配分常数中。

4.2.2 归一化乘子的 Rényi 界

定义 teacher 与 anchor 的混合矩

$$Z_\alpha(q,t) = \sum_a q_a^{1-\alpha} t_a^\alpha, \qquad \alpha > 0. \tag{4.7}$$

当 $\alpha \neq 1$ 时，Rényi 散度满足 $\log Z_\alpha = (\alpha-1) D_\alpha(t\|q)$。$Z_1 = 1$，相关表达式在 $\alpha = 1$ 处按连续延拓理解。

命题 4.1 (OPD 归一化界)

对任意 $\eta > 0$，

$$\frac{Z_\eta (Z_\eta - e^{-\eta\kappa})}{Z_{2\eta}} \le \lambda \le \eta\kappa + \log Z_\eta. \tag{4.8}$$

特别地，$\eta = 1$ 时

$$\frac{1 - e^{-\kappa}}{1 + \chi^2(t\|q)} \le \lambda \le \kappa. \tag{4.9}$$

♠

证明 令 $X_a = e^{\eta h_a}$，$A = \mathbb{E}_q X$，$B = \mathbb{E}_q X^2$。式 (4.6) 的归一化条件为

$$\lambda = \mathbb{E}_q W_0(\lambda X).$$

先考虑 $\lambda > 0$。利用 W_0 的凹性，

$$\lambda \le W_0(\lambda A).$$

函数 $w \mapsto we^w$ 在非负轴递增，故

$$\lambda e^\lambda \le \lambda A, \qquad \lambda \le \log A.$$

另一方面，$W_0(z) \ge z/(1+z)$。此不等式可以由 $z = we^w$ 与 $(1-w)e^w \le 1$ 验证；$w \ge 1$ 时右侧验证直接成立。再用 Cauchy–Schwarz 得到

$$\begin{aligned} \lambda &\ge \mathbb{E}_q \frac{\lambda X}{1 + \lambda X} \\ &\ge \frac{(\mathbb{E}_q[\lambda X])^2}{\mathbb{E}_q[\lambda X(1+\lambda X)]} = \frac{\lambda A^2}{A + \lambda B}. \end{aligned}$$

消去 λ 并整理，得到 $\lambda \ge A(A-1)/B$。当 $\lambda = 0$ 时，$q = t$，$A = B = 1$，两个界均成立。

OPD reward 的代入给出

$$A = e^{\eta\kappa} Z_\eta, \qquad B = e^{2\eta\kappa} Z_{2\eta}.$$

将它们代回即可得到式 (4.8)。当 $\eta = 1$ 时，$Z_1 = 1$，且

$$Z_2 = \sum_a \frac{t_a^2}{q_a} = 1 + \chi^2(t\|q),$$

因此得到式 (4.9)。

4.2.3 Teacher KL 的单步改进

命题 4.2 (精确 Mean 更新的 teacher KL 下降)

单轮精确解满足

$$\mathrm{KL}(p^\star\|t) \le \kappa - \left(\eta^{-1}-1\right)\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q). \tag{4.10}$$

当 $0<\eta\le 1$ 且 $q\neq t$ 时，$\mathrm{KL}(p^\star\|t) < \mathrm{KL}(q\|t)$。

证明 固定由 Mean 解确定的 λ，定义

$$J_\lambda(p) = \mathbb{E}_p r - \eta^{-1}\mathrm{KL}(p\|q) - \frac{\lambda}{2\eta}\chi^2(p\|q).$$

对 p_a 求导并加入归一化乘子 ξ，其一阶条件为

$$r_a - \frac{U_a+1}{\eta} - \frac{\lambda}{\eta}\left(\frac{p_a}{q_a}-1\right) + \xi = 0.$$

Mean 的 KKT 为 $U_a^\star + \lambda p_a^\star/q_a = \eta(r_a+\kappa)$。取 $\xi = \kappa + (1-\lambda)/\eta$，可验证 $p^\star$ 满足上述条件。J_λ 关于 p 的 Hessian 是对角阵，对角项为 $-1/(\eta p_a) - \lambda/(\eta q_a) < 0$；因此 $p^\star$ 是其唯一全局最大点。

比较 $p^\star$ 与可行分布 q，

$$\mathbb{E}_{p^\star} r - \eta^{-1}\mathrm{KL}(p^\star\|q) - \frac{\lambda}{2\eta}\chi^2(p^\star\|q) \ge J_\lambda(q) = -\kappa.$$

再用

$$\mathrm{KL}(p^\star\|t) = \mathrm{KL}(p^\star\|q) - \mathbb{E}_{p^\star} r$$

得到式 (4.10)。若 $q\neq t$，则 $\lambda>0$。此时 $p^\star\neq q$：否则 KKT 要求 $\eta h_a = \lambda$ 对所有动作成立，而 h 非恒定。这保证 $\chi^2(p^\star\|q)>0$，故在 $0<\eta\le 1$ 时严格下降。

4.2.4 Log-ratio 跨度与 outer 收敛

定义逐 prefix 的 log-ratio 跨度

$$b(q,t) = \max_a \log\frac{q_a}{t_a} - \min_a \log\frac{q_a}{t_a}. \tag{4.11}$$

该量不受公共归一化常数影响。对于正概率分布，$b(q,t)=0$ 当且仅当 $q=t$。

定理 4.3 (精确 Mean outer 的跨度收敛率)

若 $0<\eta\le 1$，则

$$b(p^\star,t) \le \left(1 - \frac{\eta}{1+\eta b(q,t)}\right) b(q,t). \tag{4.12}$$

固定正 teacher、正初始策略和常数 $0<\eta\le 1$，每轮精确 Mean inner 后 hard sync。令 $b_k(s) = b(\pi_k(\cdot\mid s), \pi_T(\cdot\mid s))$，则

$$b_k(s) \le \left(1 - \frac{\eta}{1+\eta b_0(s)}\right)^k b_0(s) \longrightarrow 0. \tag{4.13}$$

因此 $\pi_k(\cdot\mid s)\to\pi_T(\cdot\mid s)$。当 $\eta=1$ 时，单步还满足

$$b_{k+1}(s) \le \frac{b_k(s)^2}{1+b_k(s)}. \tag{4.14}$$

证明 固定本轮 λ,κ，将概率比写成 reward 的连续函数

$$w(r) = \exp\{\eta(r+\kappa) - W_0(\lambda e^{\eta(r+\kappa)})\}.$$

动作 a 的概率比为 $p_a^\star/q_a = w(r_a)$。它满足

$$\log w(r) + \lambda w(r) = \eta(r+\kappa), \qquad \frac{d\log w(r)}{dr} = \frac{\eta}{1+\lambda w(r)} > 0.$$

所以概率比随 reward 严格递增，且其 log-ratio 斜率受到 Lambert-W 修正压缩。对 teacher 的 log-ratio 函数为

$$v(r) = \log w(r) - r, \qquad v'(r) = -1 + \frac{\eta}{1+\lambda w(r)}.$$

在 $0 < \eta \le 1$ 时，$v' \le 0$。设 $r_{\max} = \max_a r_a$、$r_{\min} = \min_a r_a$，并令 $w_{\max} = w(r_{\max})$。由于 w 递增，

$$|v'(r)| \le 1 - \frac{\eta}{1+\lambda w_{\max}} \quad (r_{\min} \le r \le r_{\max}).$$

均值定理因此给出

$$b(p^\star, t) = v(r_{\min}) - v(r_{\max}) \le \left(1 - \frac{\eta}{1+\lambda w_{\max}}\right)(r_{\max} - r_{\min}).$$

由归一化 $\mathbb{E}_q w(r) = 1$，可知 $w_{\max} \ge 1$。其 KKT 与 $\kappa = -\mathbb{E}_q r \le -r_{\min}$ 给出

$$\lambda w_{\max} = \eta(r_{\max} + \kappa) - \log w_{\max} \le \eta(r_{\max} - r_{\min}) = \eta b(q,t).$$

代入即可证明式 (4.12)。

逐轮应用单步界，先得到 $b_{k+1} \le b_k \le b_0$。函数 $x \mapsto 1 - \eta/(1+\eta x)$ 递增，因此每轮收缩因子都不超过 $1 - \eta/(1+\eta b_0) < 1$，归纳得到式 (4.13)。概率归一化同时保证

$$\min_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} \le 0 \le \max_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)}.$$

所以每个动作的 log-ratio 绝对值不超过 $b_k(s)$；跨度趋零推出逐动作概率收敛。最后令 $\eta = 1$ 即得到式 (4.14)。

$\eta = 1$ 的二次上界描述接近 teacher 时的精确 outer 收敛；一般起点上的一次更新仍是 Lambert-W 分布。不同 prefix 的 $b_0(s)$ 可以不同，因此上述逐 prefix 结论不自动给出全 prefix 的统一收敛率。

4.2.5 一般 OPD reward 的大步长极限

原论文对二元 reward 分析 $\tau \to 0$。OPD reward 通常有多个取值，可以直接在其完整取值分布上推广这一极限。以下固定 q, t，只令单轮步长 $\eta \to \infty$。

命题 4.3 (正中心化 log-ratio 的极限分布)

若 $q \ne t$，定义 $[x]_+ = \max\{x, 0\}$ 与

$$c = \sum_a q_a [h_a]_+ > 0.$$

则

$$\frac{\lambda}{\eta} \longrightarrow c, \qquad p_a^\star \longrightarrow \frac{q_a[h_a]_+}{c}. \tag{4.15}$$

证明 $\mathbb{E}_q h = 0$ 且 h 非恒定，所以 $h_{\max} > 0$，并且 $c > 0$。乘子上界给出

$$\lambda \le \log \mathbb{E}_q e^{\eta h} \le \eta h_{\max}.$$

选择满足 $h_a = h_{\max}$ 的动作 a_+。概率归一化意味着 $w(r_{a_+}) = p_{a_+}^\star/q_{a_+} \le 1/q_{a_+}$。于是 KKT 给出

$$\eta h_{\max} = \log w(r_{a_+}) + \lambda w(r_{a_+}) \le \log(1/q_{a_+}) + \lambda/q_{a_+}.$$

故

$$q_{a_+} h_{\max} - \frac{q_{a_+}\log(1/q_{a_+})}{\eta} \le \frac{\lambda}{\eta} \le h_{\max}.$$

λ/η 的任意序列都有收敛子列，其极限 c' 严格为正。沿该子列，当 $h_a > 0$ 时，令 $z_a = \lambda e^{\eta h_a}$。由 $W_0(z) = \log z - \log\log z + o(1)$，

$$\frac{W_0(z_a)}{\eta} \to h_a, \qquad w(r_a) = \frac{W_0(z_a)}{\lambda} \to \frac{h_a}{c'}.$$

当 $h_a = 0$ 时，$w(r_a) = W_0(\lambda)/\lambda = O(\log\eta/\eta) \to 0$。当 $h_a < 0$ 时，$z_a \to 0$，由 $W_0(z) = z(1+o(1))$ 得到 $w(r_a) = e^{\eta h_a}(1+o(1)) \to 0$。有限词表允许逐项取极限，归一化因此要求

$$1 = \lim \sum_a q_a w(r_a) = \frac{\sum_a q_a [h_a]_+}{c'}.$$

所以所有子列极限都等于 c，证明了乘子与分布的整个序列收敛。

二元 reward $r \in \{0,1\}$、成功率 $p = \mathbb{E}_q r$ 时，$\mathbb{E}_q[r-p]_+ = p(1-p)$，因此该一般结论恢复原论文的 $\lambda/\eta \to p(1-p)$。对 OPD，它给出

$$p_a^\star \longrightarrow \frac{q_a[\log(t_a/q_a) + \mathrm{KL}(q\|t)]_+}{\mathbb{E}_q[\log(t/q) + \mathrm{KL}(q\|t)]_+}.$$

Gibbs 在大步长下集中到 t_a/q_a 最大的动作，而 Mean 的极限给所有正中心化 reward 的动作分配质量。这个固定 anchor 的大步长极限与 $0 < \eta \le 1$ 下的 outer teacher 收敛是两个不同结论。

4.2.6 有限 inner 的精细损失恒等式

命题 4.4 (Mean excess loss 的精确分解)

对任意正概率分布 p，

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q\left[\left(\log\frac{p}{p^\star}\right)^2\right] + \lambda\,\mathrm{KL}(p^\star\|p). \tag{4.16}$$

证明 记 $U = \log(p/q)$、$U^\star = \log(p^\star/q)$。展开平方得到

$$L_{\mathrm{Mean}}(p) - L_{\mathrm{Mean}}(p^\star) = \frac{1}{2}\mathbb{E}_q(U-U^\star)^2 + \mathbb{E}_q[(U-U^\star)(U^\star - G)].$$

KKT 给出 $U^\star - G = -\lambda p^\star/q$，所以第二项等于

$$-\lambda\mathbb{E}_{p^\star}\log\frac{p}{p^\star} = \lambda\,\mathrm{KL}(p^\star\|p).$$

代回即得所需恒等式。

例如，总体 inner excess loss 不超过 ϵ 时，$\mathbb{E}_q[\log(p/p^\star)^2] \le 2\epsilon$；若 $q \ne t$，还有 $\mathrm{KL}(p^\star\|p) \le \epsilon/\lambda$。接近 teacher 时 λ 趋零，后一个界会变松，因此不能据此声称所有轮次都有统一的 KL 误差控制。

4.2.7 LOO 中心估计与二元分析的迁移范围

命题 4.5 (逐 prefix LOO Mean 的期望损失)

固定 prefix、anchor 和候选 student p，令 $A_1,\dots,A_m \overset{\mathrm{iid}}{\sim} q$，$m \ge 2$。定义

$$\widehat{r}_{-i} = \frac{1}{m-1}\sum_{j\ne i} r(A_j), \qquad \widehat{L}_{\mathrm{Mean}}(p) = \frac{1}{2m}\sum_{i=1}^m \left[U(A_i) - \eta\big(r(A_i) - \widehat{r}_{-i}\big)\right]^2.$$

则

$$\mathbb{E}\widehat{L}_{\mathrm{Mean}}(p) = L_{\mathrm{Mean}}(p) + \frac{\eta^2}{2(m-1)}\,\mathrm{Var}_q[r]. \tag{4.17}$$

证明 令 $\bar r = \mathbb{E}_q r$ 与 $e_{-i} = \widehat{r}_{-i} - \bar r$。第 i 项 residual 为

$$U(A_i) - \eta(r(A_i) - \bar r) + \eta e_{-i}.$$

LOO 保证 e_{-i} 与 A_i 独立，且 $\mathbb{E}e_{-i} = 0$、$\mathbb{E}e_{-i}^2 = \mathrm{Var}_q[r]/(m-1)$。展开平方取期望，交叉项为零，因此

$$\mathbb{E}\left[U(A_i) - \eta(r(A_i) - \widehat{r}_{-i})\right]^2 = \mathbb{E}_q[U - \eta(r-\bar r)]^2 + \frac{\eta^2\,\mathrm{Var}_q[r]}{m-1}.$$

对 i 求均值并乘 $1/2$ 即得结论。不同 LOO residual 之间的依赖不影响这个期望恒等式。

附加项与候选 student 无关。因而在有限词表的可微参数化中，冻结 anchor 与 reward 后，LOO Mean 梯度是总体 Mean 梯度的无偏估计。这里的 $\mathrm{Var}_q[r]$ 是完整 prefix OPD log-ratio 的方差。若对整个词表求和，可以直接计算 reward 均值，此时不产生这项中心采样误差。

原论文二元分析中的 $p(1-p)$、成功率 $J(\pi)$ 和 $1-J(\pi)$ 分别依赖 Bernoulli reward 的方差与成功事件解释。OPD 的 reward 通常连续取值且每轮随 anchor 改变，应使用 $\mathrm{Var}_{\pi_k}[\log(\pi_T/\pi_k)]$、teacher KL 与 log-ratio 跨度。总体 Lambert-W 解、混合 KL–χ^2 解释、归一化界和 excess-loss 恒等式均无需二元假设；二元成功率递推及其统计常数需要重新证明。

式 (4.17) 是固定候选分布的期望恒等式，不能直接替代数据依赖 ERM 的高概率界。要控制训练得到的 student，仍需给出可实现性或逼近误差、策略类复杂度、优化误差以及 reward/log-ratio 的界。逐 prefix 的有限正概率分布给出有限 reward 范围，但这个范围不一定在所有 prefix 与 outer 轮次上一致。式 (4.16) 则说明：统计分析应围绕约束最优分布的 excess loss 展开；将 Lambert-W 修正本身算作不可消失的 target-estimation 误差，会掩盖 Mean 的总体一致性。

4.3 有限 inner 与 stale target

本节先以 Gibbs inner 方法为对象。实际第 k 轮只运行 N_k 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi_k^{\star,\mathrm{Gibbs}}(a \mid s)}\right| \le \varepsilon_k$$

在归一化前成立。则归一化后

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi_k^{\star,\mathrm{Gibbs}}) \le \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.18}$$

几何插值在 log-ratio 振幅上收缩，不能据此前的推论直接宣称 TV 每步以 $1-\eta$ 收缩。定义

$$b_k = \max_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)} - \min_a \log \frac{\pi_k(a \mid s)}{\pi_T(a \mid s)}.$$

精确 Gibbs 更新把振幅变成 $(1-\eta)b_k$；上述逐 action log-density 误差最多再增加 $2\varepsilon_k$。因此

$$b_{k+1} \le (1-\eta)b_k + 2\varepsilon_k, \tag{4.19}$$

归纳展开得到

$$b_{K_{\mathrm{out}}} \le (1-\eta)^{K_{\mathrm{out}}} b_0 + 2\sum_{j=0}^{K_{\mathrm{out}}-1} (1-\eta)^{K_{\mathrm{out}}-1-j}\varepsilon_j.$$

归一化分布的 log-ratio 最小值不大于零，最大值不小于零，故 $|\log(\pi_{K_{\mathrm{out}}}/\pi_T)| \le b_{K_{\mathrm{out}}}$。由 $\mathrm{TV}(\pi_{K_{\mathrm{out}}}, \pi_T) = \frac{1}{2}\mathbb{E}_{\pi_T}[|\pi_{K_{\mathrm{out}}}/\pi_T - 1|]$ 得

$$\mathrm{TV}(\pi_{K_{\mathrm{out}}}, \pi_T) \le \min\left\{1, \frac{1}{2}(e^{b_{K_{\mathrm{out}}}} - 1)\right\}.$$

若 $\varepsilon_j \le \bar{\varepsilon}$，振幅的稳态上界为 $2\bar{\varepsilon}/\eta$。这给出 Gibbs 方法有限 inner 误差的几何累积关系。

对于 PMD-Mean，取 $0 < \eta \le 1$，有限 inner 输出执行 hard sync，并假设它在所有 action 上满足

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi_k^{\star,\mathrm{Mean}}(a \mid s)}\right| \le \varepsilon_k.$$

由本章 Mean 跨度收缩定理和振幅的三角不等式，得到

$$b_{k+1} \le \left(1 - \frac{\eta}{1+\eta b_k}\right) b_k + 2\varepsilon_k.$$

若已知整个训练段 $b_k \le A_0$，则定义 $c_0 = 1 - \eta/(1+\eta A_0) < 1$，归纳可得

$$b_{K_{\mathrm{out}}} \le c_0^{K_{\mathrm{out}}} b_0 + 2\sum_{j=0}^{K_{\mathrm{out}}-1} c_0^{K_{\mathrm{out}}-1-j}\varepsilon_j.$$

这里的统一跨度上界是附加假设；精确 inner 的初始跨度上界不能自动替代含优化误差的迭代上界。前节 excess-loss 恒等式提供加权均方 log-ratio 和 KL 控制；将其换成上述逐 action 误差，还需要 anchor 最小概率下界等条件。

4.4 Soft sync 的耦合动力学

若 anchor 使用 EMA，令

$$\pi_{k+1} = (1-\rho)\pi_k + \rho\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。对 PMD-Part、BPO 和 MDPO，精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \pi_k^{1-\eta}\pi_T^{\eta}.$$

在固定 prefix 上令 $q=\pi_k$、$t=\pi_T$、$z=\log(q/t)$，假设 $\max_a|z_a|\le\varepsilon$，$\eta$ 固定且 inner 精确求解。归一化 $\mathbb{E}_t e^z=1$ 的 Taylor 展开给出

$$\mathbb{E}_t z = -\frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3), \qquad \kappa = \mathbb{E}_t[e^z z] = \frac{1}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

因此 OPD 的混合配分函数满足

$$\log Z_\eta = \log \mathbb{E}_t e^{(1-\eta)z} = -\frac{\eta(1-\eta)}{2}\mathbb{E}_t z^2 + O(\varepsilon^3).$$

对于 Gibbs 更新，$\log(p^\star/t) = (1-\eta)z - \log Z_\eta$，一阶项为 $(1-\eta)z$。

PMD-Mean 的精确更新使用 Lambert-W target。由式 (4.8)，

$$0 \le \lambda \le \eta\kappa + \log Z_\eta = \frac{\eta^2}{2}\mathbb{E}_t z^2 + O(\varepsilon^3) = O(\varepsilon^2).$$

又因 $G=\eta(-z+\kappa)=O(\varepsilon)$，有 $W_0(\lambda e^G)=O(\varepsilon^2)$。故 Mean 也满足

$$\log(p^\star/t) = z + G - W_0(\lambda e^G) = (1-\eta)z + O(\varepsilon^2).$$

两类精确 inner 的概率空间混合 $q_{\text{new}} = (1-\rho)q + \rho p^\star$，其中 $\rho\in(0,1]$，均满足

$$\begin{aligned} q_{\text{new}}/t &= (1-\rho)e^z + \rho e^{(1-\eta)z+O(\varepsilon^2)} \\ &= 1 + (1-\rho\eta)z + O(\varepsilon^2), \\ \log(q_{\text{new}}/t) &= (1-\rho\eta)z + O(\varepsilon^2). \end{aligned}$$

这是 teacher 附近的局部展开。Mean 的精确全局递推仍由 Lambert-W 决定。较小的 ρ 减缓 anchor 漂移和局部 teacher tracking；有限 inner 或参数 EMA 还需要加入相应误差项。

4.5 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 d_k 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，d_{k+1} 改变，必须额外记录 coverage drift：

$$\varepsilon_k^{\text{visit}} = \mathrm{TV}(d_{k+1}, d_k).$$

若 token loss 在所有 history 上有上界 C，则访问测度改变使目标值的期望变化至多 $2C\varepsilon_k^{\text{visit}}$；若要控制梯度的期望变化，需另行假设逐 prefix 梯度向量的范数不超过 C_g，此时界为 $2C_g\varepsilon_k^{\text{visit}}$。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

第五章 可枚举 Token 实验与实现边界

5.1 实验设置

实验脚本位于 `experiments/toy/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\pi_0 = (0.62, 0.23, 0.10, 0.05), \qquad \pi_T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略 $\pi_{0,0} = (0.70, 0.15, 0.10, 0.05)$ 开始，使用 400 步、学习率 0.15，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。为核对离开 anchor 后的梯度，这个固定 anchor 实验采用偏离 anchor 的初始化。正式 OPD outer–inner 算法从 $\pi_{k,0} = \pi_k$ 开始。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整词表下的中心化 residual 平方损失；MDPO 使用 exact categorical Fisher preconditioner。

5.1.1 画图实验的输入数据与三层数据集

本项目的图不能直接从一批混合的 rollout 日志中生成。每一张图都必须注明它使用的是哪一个策略、哪一个 prefix 测度以及哪一种词表访问方式。实验输入按由易到难分为三层。

第一层是可枚举的 categorical oracle。固定一个 prefix s，直接生成 anchor、teacher 和 student 的完整 logits，并通过 softmax 得到 $\pi_k(\cdot \mid s)$、$\pi_T(\cdot \mid s)$ 和 $\pi_{k,n}(\cdot \mid s)$。anchor 可以用随机 logits 加温度生成，teacher 可以通过独立随机 logits 或与 anchor 具有指定 KL 的混合分布生成。每个 prefix 保存完整的概率向量、两个 log-prob 向量以及 exact

$$\mathcal{K}_k^T(s) = \mathrm{KL}(\pi_k \| \pi_T), \qquad \mathcal{K}_{k,n}^S(s) = \mathrm{KL}(\pi_k \| \pi_{k,n}),$$

和

$$\log Z_k(s) = \log \sum_{v \in \mathcal{V}} \exp\big((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\big).$$

这一层不需要文本数据，也不运行模型 rollout；它提供所有估计量的 ground truth，专门用于画 bias、variance、均方误差和梯度误差曲线。

第二层是真实模型产生的 prefix 数据，但仍然冻结 outer step。先选定一个不参与训练的 prompt 文件 $\mathcal{X} = \{x_i\}_{i=1}^{N_x}$，每个 prompt 只作为输入，不需要人工答案或 reward label。用当前 anchor π_k 对每个 prompt 采样若干条 response，得到

$$s_{i,t} = (x_i, y_{i,<t}), \qquad a_{i,t} = y_{i,t}, \qquad a_{i,t} \sim \pi_k(\cdot \mid s_{i,t}).$$

保存 prompt id、token ids、attention mask、response mask、prefix 长度、anchor 对采样 token 的 log-prob，以及 teacher 对同一 token 的 log-prob。KL 或 $\log Z_k$ 的估计不应把不同 prefix 混在一起：同一 prefix 的多个 next-token 样本才能用于估计条件期望；不同 prefix 只能在外层按照经验访问测度 $\widehat{d}_k$ 聚合。

第三层才是完整的 OPD outer loop。第 k 轮只使用 π_k 生成 rollout，缓存该轮的 prefix 集合和 anchor/teacher 的 token-level log-prob；随后固定这些数据运行 N 个 inner steps，得到 $\pi_{k,N}$，再执行 hard sync 或 soft sync 得到 π_{k+1}。同步后必须重新 rollout，不能把上一轮的 prefix 和旧 anchor log-prob 继续当作新一轮数据。这样得到的序列

$$\{(\widehat{d}_k, \pi_k, \pi_{k,n}, \pi_T) : k = 0, \dots, K_{\mathrm{out}} - 1,\ n = 0, \dots, N\}$$

才是 outer 动力学图的输入。

图中以 J 表示保留的头部 token 数量。对每个固定 prefix，同时记录 full-vocabulary oracle、sampled-token、top-J 三条估计路径。建议先画以下三组图：

1. 在第一层 oracle 上，以 J 或同 prefix 样本数 m 为横轴，画 $\mathcal{K}_k^T$、$\mathcal{K}_{k,n}^S$ 和 $\log Z_k$ 的 bias、standard deviation、RMSE；

2. 在第二层真实 prefix 上，以 inner step n 为横轴，画 exact-oracle 可用部分的 KL、sampled estimator 的方差、anchor–student 的 χ^2 或有效样本量；
3. 在第三层 outer loop 上，以 k 为横轴，分别画 teacher KL、mirror-target KL、policy–anchor KL、token-level loss、rollout reward，以及 hard sync 与 soft sync 的差异。

第一层的分布是唯一可以逐 prefix 得到无偏误差标签的地方，因此必须先完成。第二层用于回答估计量在真实语言模型的长尾词表上是否仍然稳定。第三层只在前两层通过后运行，否则一条性能曲线无法判断变化来自 OPD 本身、prefix 分布漂移、KL 估计偏差还是 inner 优化没有收敛。

5.2 结果

表 5.1 区分有限步优化误差、到 Gibbs 分布的距离和总体目标差异。方法 M 的自身最优分布为 $\pi_0^{\star,M}$，400 步后的 student 为 $\pi_{0,N}$，$N = 400$。PMD-Mean 的最优分布由 Lambert-W 归一化方程求得，其余三种方法的最优分布为 $\pi_0^{\star,\mathrm{Gibbs}}$。定义

$$
\begin{aligned}
e_M^{\mathrm{opt}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,M}),\\
e_M^{\mathrm{Gibbs}} &= \mathrm{TV}(\pi_{0,N}, \pi_0^{\star,\mathrm{Gibbs}}),\\
e_M^{\mathrm{target}} &= \mathrm{TV}(\pi_0^{\star,M}, \pi_0^{\star,\mathrm{Gibbs}}).
\end{aligned}
$$

第一项衡量有限步优化误差，第三项衡量方法总体目标的差异。

表 5.1: 固定测度 token inner 的可枚举实验，400 步后结果。

η	方法	e_M^{opt}	e_M^{Gibbs}	e_M^{target}
0.25	PMD-Part	1.11e-03	1.11e-03	0.00e+00
0.25	PMD-Mean	6.81e-04	9.26e-03	9.12e-03
0.25	BPO	1.96e-08	1.96e-08	0.00e+00
0.25	MDPO	8.33e-17	8.33e-17	0.00e+00
0.50	PMD-Part	2.65e-03	2.65e-03	0.00e+00
0.50	PMD-Mean	3.58e-04	6.86e-02	6.85e-02
0.50	BPO	1.23e-04	1.23e-04	0.00e+00
0.50	MDPO	1.25e-16	1.25e-16	0.00e+00
0.80	PMD-Part	2.97e-03	2.97e-03	0.00e+00
0.80	PMD-Mean	4.11e-05	1.90e-01	1.90e-01
0.80	BPO	4.53e-03	4.53e-03	0.00e+00
0.80	MDPO	2.78e-16	2.78e-16	0.00e+00

PMD-Mean 到自身最优解的误差随优化下降，但到 Gibbs 解的距离保留了结构性差异。例如 $\eta = 0.8$ 时，其有限步优化误差为 4.11×10^{-5}，两个总体最优解的距离为 0.1904。继续优化只能消除前者。

BPO 的最优解仍为 Gibbs 分布，但本实验的固定步长与 400 步预算下，$\eta = 0.8$ 时尚有 4.53×10^{-3} 的优化误差。MDPO 使用精确 categorical Fisher 自然梯度，在该四动作问题上达到浮点精度。该结果比较的是指定 optimizer 与预算下的误差，不构成一般模型上的收敛速度排序。

η 同时影响 Gibbs target、Mean 的 Lambert-W target 以及各损失的梯度尺度。Algorithm 5 中 BPO 的 η^{-1} 已显式进入梯度权重，实验使用相同学习率时也保留这个尺度，不能把缩放后的方向当作实际梯度。

5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，核对 Mean 的 Lambert-W 归一化、KKT 条件与最优点梯度；核对 Mean/BPO 的损失及梯度差异恒等式；

2. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
3. 对随机 p, q，用大量样本检查 K4 value 与 exact KL$(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
4. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
5. 检查固定 anchor 采样的 importance correction 在 p/q 接近一时无偏；
6. 人为改变 student 与 anchor 的偏离程度，测量 χ^2 与重要性加权估计方差；增加 inner steps 不保证二者单调上升；
7. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `toy_token_inner.py`（从仓库根用 `PYTHONPATH=src uv run --with torch python` 运行）生成，结果保存在 `results/toy/toy_token_inner.csv`。独立的 `tests/test_kl_estimators.py` 使用 200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 5.6×10^{-5}，gradient 的 ℓ_2 误差为 1.5×10^{-3}。

`tests/test_mean_bpo.py` 进一步核对 Mean 与 BPO 的解析梯度、有限差分、最优点和有限样本尺度修正；它与 toy 实验分别检验推导正确性和有限步优化行为。

5.4 真实语言模型上的四种 Top-J 对照

为了把上一章的四个数学对象放回 OPD 场景，我们使用 GSM8K test 的全部 1,319 个 prompt。Student 为 Qwen3-1.7B，Teacher 为 Qwen3-4B，温度固定为 1.0；每个 prompt 生成一条完整 student rollout。对 rollout 的每个 prefix，打分阶段计算 student 与 teacher 的完整词表分布，随后只保存汇总量和审计样本。打分采用 NF4 权重量化、bf16 计算，因此这里的 full-vocabulary KL 是该量化模型对的 oracle。生成采用 bf16 vLLM，其 sampled token 来自与 NF4 打分略有不同的 proposal；EMA 的理论方差严格按 NF4 student 分布计算，观测误差另行报告。总计得到 350,166 个 prefix。实验元数据、逐 J 汇总和绘图脚本分别位于 `results/qwen3_gsm8k_pair_kl/metadata.json`、`results/qwen3_gsm8k_pair_kl/kl_summary_by_k.csv` 和 `experiments/plotting/plot_pair_kl.py`。

令 S_J 为 student 概率的 top-J 支持集。表 5.2 中的 bias 和 RMSE 都相对于同一 prefix 上的完整

$$\mathcal{K}^{\text{full}}(s) = \mathrm{KL}\big(\pi_{k,n}(\cdot \mid s) \| \pi_T(\cdot \mid s)\big)$$

计算。Truncated、Normalized 和 Tail-Aware 的条件采样方差恒为零；EMA Top-J 的 variance 是一个尾部 sampled token 修正的理论条件方差。四种方法使用完全相同的 prefix 和 student 支持集，没有额外增加每个 prefix 的采样数。Tail-Aware 尾部质量在 float64 下直接累加，避免头部质量接近一时用 $1 - P_J$ 相减丢失精度。审计样本同时保存 teacher 在该支持集上的质量 Q_J 与 Tail-Aware 值。

表 5.2: Qwen3-1.7B student 与 Qwen3-4B teacher 在 GSM8K rollout prefix 上的 Top-J KL 统计。EMA 的 RMSE 是理论 sampled-tail RMSE；Normalized 的 $J = 0$ 未定义。

J	P_J	$\text{bias}_{\text{trunc}}$	$\text{RMSE}_{\text{trunc}}$	RMSE_{EMA}	$\text{bias}_{\text{norm}}$	$\text{RMSE}_{\text{norm}}$
0	0	-0.26932	1.03968	0.80948	–	–
1	0.94208	-0.07672	0.39307	0.68557	-0.26932	1.03968
2	0.98676	-0.02187	0.15337	0.40189	-0.08392	0.54660
4	0.99747	-0.00465	0.04761	0.18864	-0.02629	0.28804
8	0.99949	-0.00094	0.01416	0.08308	-0.00874	0.15007
16	0.99988	-0.00023	0.00488	0.03959	-0.00310	0.08367
32	0.99996	-0.00008	0.00217	0.02249	-0.00127	0.05438

结果体现了四种定义之间的结构性差异。首先，student 的 top-J 质量在 $J = 4$ 时已经达到 0.99747，在 $J = 32$ 时达到 0.99996，所以截断项的偏差和 RMSE 很快下降。其次，EMA Top-J 在任何 J 上都保持理论无偏，但只要尾部 log-ratio 的二阶矩仍然较大，sampled correction 就会带来明显方差；在 $J = 32$ 时它的理论 RMSE 仍为 0.02249，高于截断项的 0.00217。这不是无偏性失效，而是典型的 bias–variance trade-off。

Normalized Top-J 的行为不同。$J = 1$ 时两边都是同一个 point mass，局部 KL 几乎为零，因此相对于完整 KL 的 bias 为 -0.26932。随着 J 增大，条件分布逐渐包含更多质量，RMSE 从 1.03968 降至 0.05438；但在 $J = 32$ 时

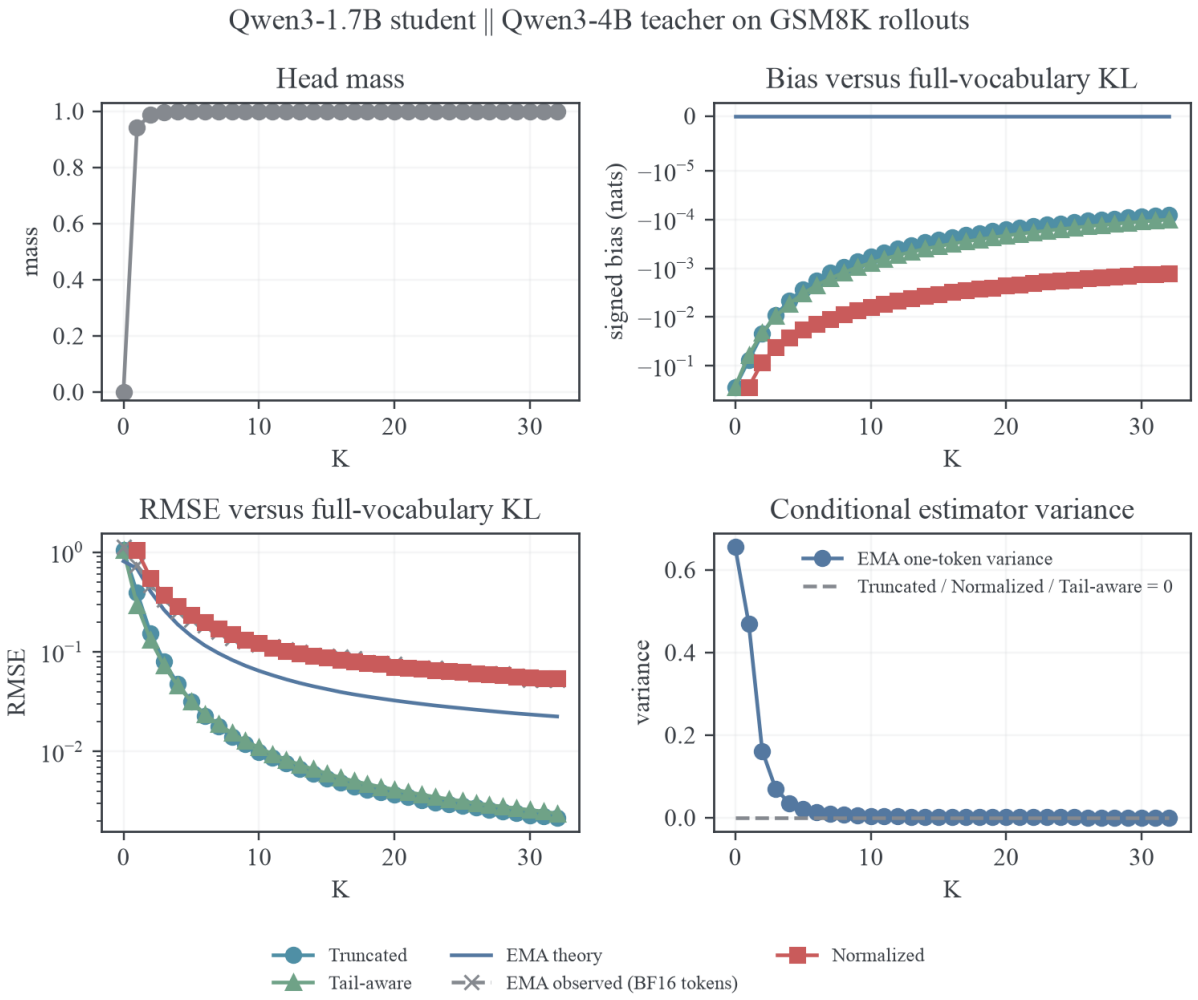


图 5.1: 真实 GSM8K rollout 上四种 Top-J KL 的误差曲线。bias 保留正负号；variance 是固定 prefix 的条件采样方差，不是不同 prefix 之间的数值方差。EMA observed 使用 bf16 rollout token，与 NF4 打分分布的理论曲线分开。

仍明显高于截断项。这说明归一化修复的是局部目标的概率尺度，而不是尾部 token-wise KL。它适合作为 dense local OPD 目标，却不能被解释为完整 KL 的高精度估计量。

Tail-Aware 的全量结果见表 5.3。其 RMSE 随 J 单调下降，符合上一章的支持集细化定理。在 $J = 1, 2, 4$ 时，其 RMSE 小于 Truncated；在 $J = 8, 16, 32$ 时，Truncated 略小。这正对应尾部质量项与尾部形状项的抵消：Tail-Aware 恢复质量项后，剩下的误差严格为非正的尾部形状偏差，而 Truncated 的两个遗漏项可以部分相互抵消。这个标量 RMSE 排序不等于训练稳定性的排序，也不能作为四种 OPD 训练方法最终性能的结论。

这组实验不能支持“所有情况下都应该使用 normalized Top-J”这一结论。它支持更精确的选择规则：当我们需要在有限支持集上构造稳定的多 token 蒸馏 reward 时使用 $\mathcal{K}_J^{\mathrm{norm}}$；当我们需要完整 vanilla OPD KL 的估计时使用 EMA Top-J；当我们希望保留尾部总质量、又不承受 sampled correction 的方差时使用 Tail-Aware Top-J；Truncated Top-J 则作为低方差、有明确尾部偏差的基线。

表 5.3: 同一批 350,166 个 prefix 上补全的 Tail-Aware 结果。条件采样方差在所有 J 上均为零。

J	mean Tail-Aware KL	bias	RMSE
0	0	-0.269321	1.039683
1	0.209759	-0.059561	0.295078
2	0.248414	-0.020907	0.131407
4	0.263978	-0.005343	0.045886
8	0.268091	-0.001230	0.015303
16	0.269006	-0.000315	0.005493
32	0.269220	-0.000101	0.002391

参考资料

PMD-Mean的 reward 中心化目标与 Lambert-W 解依据 arXiv:2602.05933 中的 $\mathcal{L}_{\text{mean}}$ 定义与附录约束优化推导。本文 KL 估计量的记号与 K3^{++}、K4、K5、Top-J 估计量来自 arXiv:2602.04417；One-Shot-OPD 的实现审计见 `upstream/One-Shot-OPD/`。