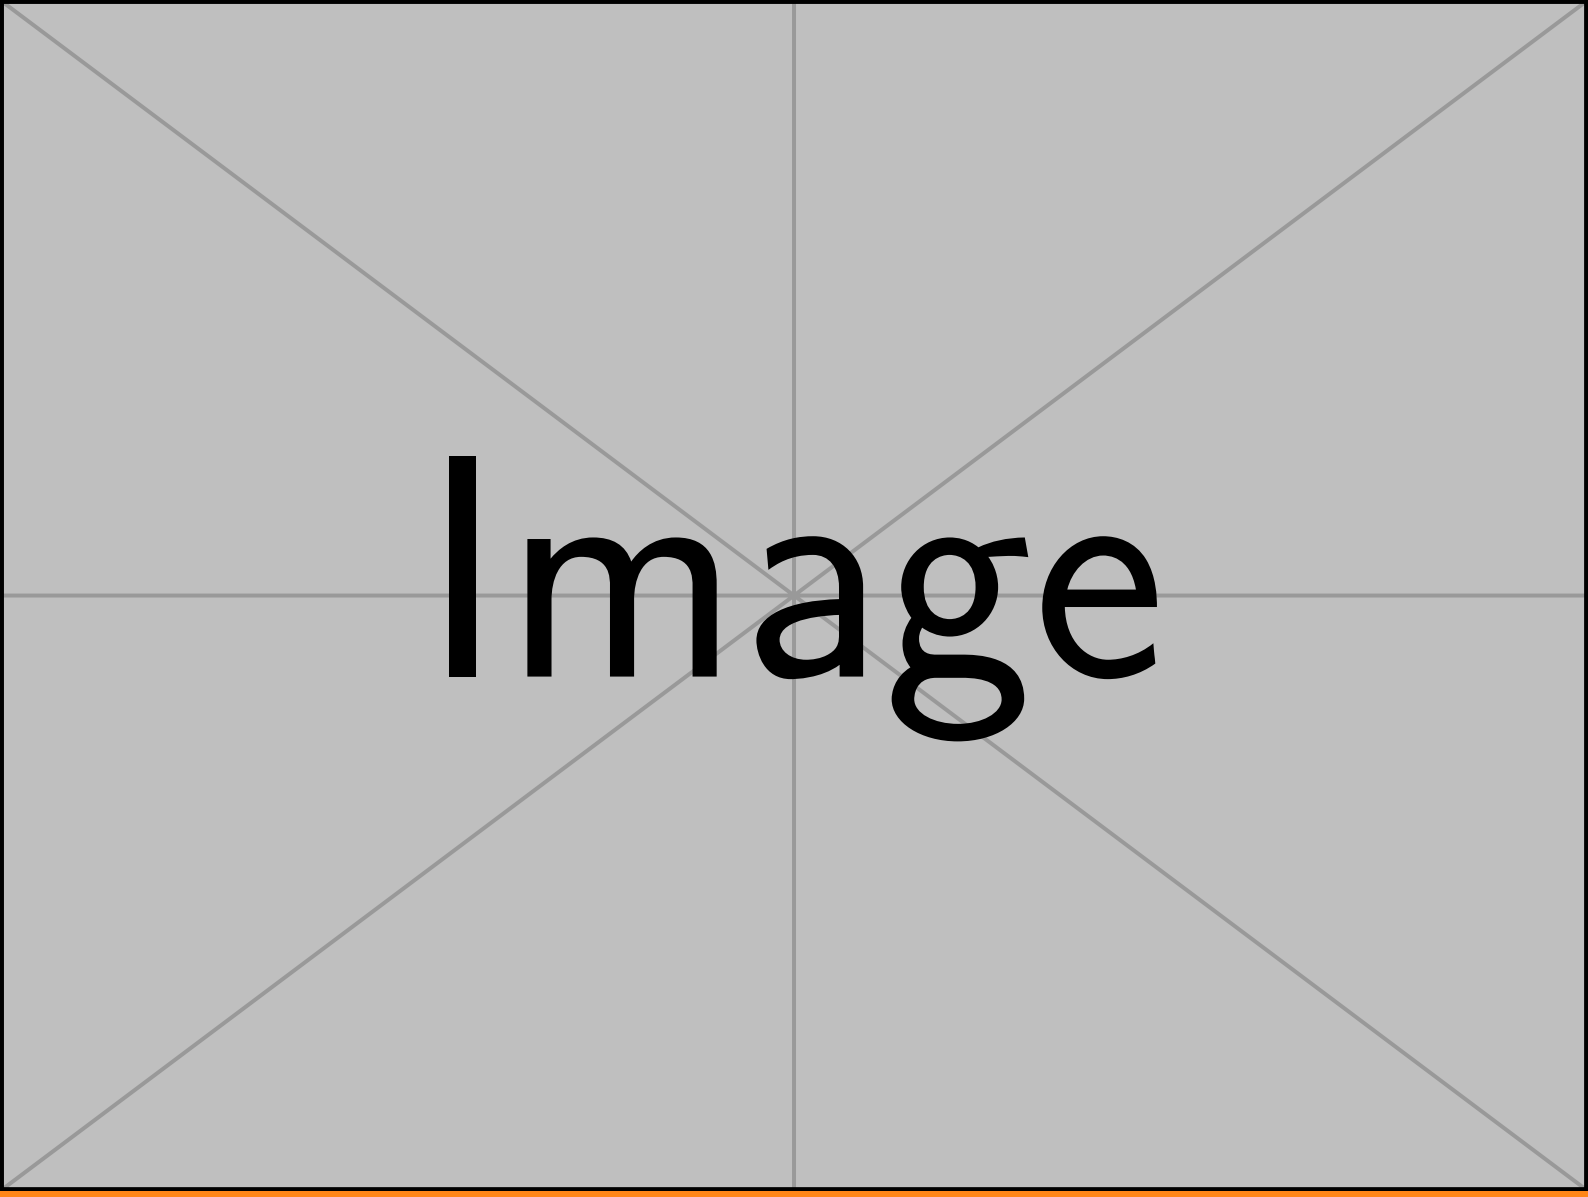



# 固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

# 目录

**第一章 固定测度的 Token 级优化问题** **1**
1.1 外层同步与内层对象 . . . 1
1.2 共同闭式解 . . . 1
1.3 固定测度下的三个等价表述 . . . 2
1.4 参数化策略的投影 . . . 2

**第二章 统一的 token-level Mirror Descent 与 OPD 实例化** **3**
2.1 共同的 mirror 子问题与精确解 . . . 3
2.2 从镜像最优性方程到四种可训练目标 . . . 4
2.3 四种 inner 的统一推导 . . . 5

**第三章 KL 估计量、无偏性与方差** **10**
3.1 K4 的无偏性 . . . 10
3.2 固定 anchor 测度上的重要性校正 . . . 10
3.3 Top-$K$ 与完整词表的关系 . . . 10
3.4 有限 inner 更新的误差 . . . 11

**第四章 Outer 同步与有限 inner 的动力学** **12**
4.1 Hard sync 的精确动力学 . . . 12
4.2 有限 inner 与 stale target . . . 12
4.3 Soft sync 的耦合动力学 . . . 13
4.4 访问测度固定的含义 . . . 13

**第五章 可枚举 Token 实验与实现边界** **14**
5.1 实验设置 . . . 14
5.2 结果 . . . 14
5.3 正式 LLM 实验前必须通过的检查 . . . 14

# 第一章 固定测度的 Token 级优化问题

## 1.1 外层同步与内层对象

第 $k$ 个 outer step 开始时，学生策略、anchor 和教师分别记为

$$\pi_k(\cdot \mid s), \qquad \mu_k(\cdot \mid s), \qquad T(\cdot \mid s).$$

hard sync 时 $\mu_k = \pi_k$；soft sync 时 $\mu_k$ 是学生参数的 EMA。一个 token history $s = (x, y_{<t})$ 在本章内被冻结。外层采样只负责产生一批 history；inner 不再改变该批 history 的访问测度，也不重新计算教师目标。

定义教师相对 anchor 的 token reward

$$r_k(s,a) = \log T(a \mid s) - \log \mu_k(a \mid s).$$

我们研究的 inner 子问题是

$$\max_{p \in \Delta(\mathcal{V})} \mathcal{J}_{k,s}(p) = \mathbb{E}_{a\sim p}[r_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p\|\mu_k), \qquad \eta > 0. \tag{1.1}$$

这里的 $p$ 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 $s$ 不随 inner 更新；它不意味着优化变量 $p$ 必须等于采样分布 $\mu_k$。

## 1.2 共同闭式解

令

$$Z_k(s) = \sum_{a\in\mathcal{V}} \mu_k(a \mid s)\exp(\eta r_k(s,a)).$$

由于 $r_k = \log T - \log \mu_k$，有

$$Z_k(s) = \sum_a \mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}. \tag{1.2}$$

**定理 1.1 (Token mirror target)**

若 $\mu_k(a \mid s) > 0$ 时 $T(a \mid s) > 0$，则式 (1.1) 的唯一最大点为

$$p_k^+(a \mid s) = \frac{\mu_k(a \mid s)\exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.3}$$

并且对任意 $p$，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\,\mathrm{KL}(p\|p_k^+). \tag{1.4}$$

♡

**证明** 由式 (1.3)，

$$\log p_k^+(a \mid s) = \log \mu_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\mathrm{KL}(p\|p_k^+) = \sum_a p(a \mid s)\left[\log \frac{p(a \mid s)}{\mu_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s)\right]$$

$$= \mathrm{KL}(p\|\mu_k) - \eta \mathbb{E}_p[r_k] + \log Z_k(s).$$

移项得到式 (1.4)。KL 非负且仅在 $p = p_k^+$ 时为零，所以最大点唯一。 □

**推论 1.1 (几何插值与极限)**

当 $\eta = 0$ 时 $p_k^+ = \mu_k$ 的一阶极限成立；当 $\eta = 1$ 时 $p_k^+ = T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log p_k^+ = (1-\eta)\log \mu_k + \eta \log T - \log Z_k.$$

因此 $\eta$ 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

## 1.3 固定测度下的三个等价表述

定义 $m_k(s) = \mathbb{E}_{a\sim\mu_k}[r_k(s,a)]$。由 KL 定义，

$$m_k(s) = -\,\mathrm{KL}(\mu_k(\cdot \mid s) \| T(\cdot \mid s)). \tag{1.5}$$

将 reward 换成 $r_k - m_k$ 只改变 partition 的常数：

$$\mathbb{E}_{\mu_k}[e^{\eta(r_k - m_k)}] = e^{-\eta m_k} Z_k,$$

所以闭式分布 $p_k^+$ 不变。这是 PMD-Part 与 PMD-Mean 共享固定点的原因。

若定义 $u_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \mu_k(a \mid s)$，则 exact regression residual 为

$$q_{\mathrm{part}}(s,a;\theta) = u_\theta(s,a) - \eta r_k(s,a) + \log Z_k(s). \tag{1.6}$$

PMD-Mean 使用

$$q_{\mathrm{mean}}(s,a;\theta) = u_\theta(s,a) - \eta[r_k(s,a) - m_k(s)]. \tag{1.7}$$

二者的零点都等价于 $\pi_\theta = p_k^+$，但有限样本中 $\log Z_k$ 与 $m_k$ 的估计方差不同。

## 1.4 参数化策略的投影

实际神经网络只能表示 $\{\pi_\theta\}$。固定 history 测度 $\rho_k(s)$ 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim\rho_k, a\sim\mu_k}\left[q_{\mathrm{part}}(s,a;\theta)^2\right]. \tag{1.8}$$

若模型在每个 history 上可以实现式 (1.3)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

# 第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章只使用一套序列建模符号。给定 prompt $x$，student 生成 rollout $y_{1:H}$；第 $t$ 个 token 的历史为 $s_t = (x, y_{<t})$。固定第 $k$ 个 outer step 的 anchor policy $\pi_k$，候选 student policy 记为 $\pi_\theta$，teacher policy 记为 $T$，镜像正则的温度参数记为 $\eta > 0$。$\eta$ 决定 mirror target 离 anchor 和 teacher 的位置；MDPO 的参数更新步长另记为 $\alpha$。$s_t$ 只表示 rollout 的条件历史，训练样本始终是一条完整的 prompt–rollout；四种 inner 的区别只来自求解同一个 mirror 子问题的方式。

## 2.1 共同的 mirror 子问题与精确解

**定义 2.1 (Token-level mirror 子问题)**

给定固定历史 $s$、token 信号 $f(s,a)$ 和 anchor $\pi_k$，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s))\,. \tag{2.1}$$

镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。同时定义配分函数

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

**定理 2.1 (KL mirror 子问题的 Gibbs 解)**

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^+(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^+(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 $p$，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\big(p\big\|\pi_k^+(\cdot \mid s)\big)\,. \tag{2.4}$$

**证明** 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^+(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 $v$ 按 $p$ 求期望，得到

$$\mathrm{KL}(p\|\pi_k^+) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^+$ 时取零，因此最优解唯一。

**定义 2.2 (中心化 token 信号)**

对任意 $f$ 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

**命题 2.1 (优势函数的 anchor 条件均值)**

若 $f(s,a) = A^{\pi_k}(s,a)$，则对每个满足 $\pi_k(\cdot \mid s)$ 定义的历史，

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}[f(s,a) \mid s] = 0. \tag{2.5}$$

对于一般 OPD log-ratio 或 teacher score，该等式不是定义恒等式，必须显式估计并减去条件均值。

**证明** 由 $A^{\pi_k}(s,a) = Q^{\pi_k}(s,a) - V^{\pi_k}(s)$ 以及 $V^{\pi_k}(s) = \mathbb{E}_{a\sim\pi_k}[Q^{\pi_k}(s,a) \mid s]$，有

$$\begin{aligned}\mathbb{E}_{\pi_k}[A^{\pi_k}(s,a) \mid s] &= \mathbb{E}_{\pi_k}[Q^{\pi_k}(s,a) \mid s] - V^{\pi_k}(s) \\ &= V^{\pi_k}(s) - V^{\pi_k}(s) = 0.\end{aligned}$$

**命题 2.2 (中心化不改变 mirror 最优策略)**

用 $\widetilde{f}_k$ 替代 $f$ 不改变式(2.1) 的最优分布。

**证明** 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

## 2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是一个抽象的分布结论，而是一个可以被监督学习近似的逐 token 方程。把式(2.3) 移项，得到

$$\log \pi_k^+(a \mid s) - \log \pi_k(a \mid s) = \eta f(s,a) - \log Z_f(s). \tag{2.6}$$

左侧是 candidate student 相对于冻结 anchor 的 log-ratio，右侧只由冻结的 token signal 和归一化常数决定。

**定义 2.3 (Mirror log-ratio target)**

定义候选 student 相对于冻结 anchor 的 log-ratio 与 Gibbs target 为

$$U_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \pi_k(a \mid s), \qquad H_k(s,a) = \eta f(s,a) - \log Z_f(s).$$

式(2.3) 等价于 $U_\theta = H_k$；因此 $H_k$ 是参数化 inner 所要实现的逐 token 最优性方程。

由这个定义，求解 mirror 子问题在参数化策略类中的直接替代，就是在训练测度下让 $U_\theta$ 拟合 $H_k$：

$$\min_\theta \ \mathbb{E}\left[(U_\theta - H_k)^2\right]. \tag{2.7}$$

因此 PMD-Part 的平方损失不是额外假设，而是把镜像最优性方程变成参数化模型可优化的投影问题。对式(2.7) 求导，使用

$$\nabla_\theta U_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s),$$

立即得到式(2.12)。

PMD-Mean 来自同一个方程的中心化。由于 $\log Z_f(s)$ 只依赖 $s$，对 anchor action 取条件均值时

$$\mathbb{E}_{\pi_k}[H_k(s,a) \mid s] = \eta\mathbb{E}_{\pi_k}[f(s,a) \mid s] - \log Z_f(s).$$

减去该均值后，未知的 $\log Z_f$ 消失，得到

$$H_k(s,a) - \mathbb{E}_{\pi_k}[H_k(s,\cdot) \mid s] = \eta\widetilde{f}_k(s,a). \tag{2.8}$$

这解释了 PMD-Mean 的 target 来源。它不能只回归中心化 target，还必须保留 $U_\theta = \log(\pi_\theta/\pi_k)$ 的概率归一化约束；否则相差一个依赖历史的常数的所有 log-ratio 都会被视为同一个解。

BPO 再对式(2.6) 两边作同样的中心化，但中心化的是 residual：

$$D_\theta(s,a) = \left[\eta f(s,a) - U_\theta(s,a)\right] - \mathbb{E}_{\pi_k}\left[\eta f(s,\cdot) - U_\theta(s,\cdot) \mid s\right]. \tag{2.9}$$

当 $D_\theta = 0$ 时，只能先推出 $U_\theta = \eta f - C(s)$；概率归一化再唯一确定 $C(s) = \log Z_f(s)$。这就是 BPO 与 PMD-Part

共享精确零点、但有限参数更新不同的原因。BPO 的 score centering 并非预先加入的 baseline，而是对 $\mathbb{E}_{\pi_k}[U_\theta]$ 求导后必然产生的项。

MDPO 则不把式(2.6) 改写成回归，而直接对原始 mirror objective 求最大化。由式(2.4)，对任意参数化 student 有

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}\big(\pi_\theta(\cdot \mid s)\big\|\pi_k^+(\cdot \mid s)\big)\,. \tag{2.10}$$

所以 MDPO 的 inner 是在直接最小化 student 与 Gibbs target 的 reverse KL gap；PMD-Part、PMD-Mean 和 BPO 则是在不同坐标和不同投影测度下最小化该最优性方程的平方残差。

**命题 2.3 (平方回归的投影含义)**

*若 student 函数类不能表示 $H_k$，PMD-Part 的精确 inner 解是 $H_k$ 在函数类诱导的 $L_2(d_{\pi_k}\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 $m$，投影也相应变为 $L_2(m\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。*

**证明** 平方损失是 Hilbert 空间中的正交投影问题。对任意可行扰动 $v$，最优点 $U^\star$ 满足

$$\mathbb{E}_{m,\pi_k}[(U^\star - H_k)v] = 0.$$

这正是 $H_k$ 到可行函数集合的正交投影条件。若 $H_k$ 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

## 2.3 四种 inner 的统一推导

下面固定一个历史，令

$$\ell^T(a) = \log T(a \mid s), \qquad \ell^k(a) = \log \pi_k(a \mid s), \qquad \ell^\theta(a) = \log \pi_\theta(a \mid s).$$

训练时只对 $\ell^\theta$ 反向传播；teacher、anchor、目标常数和所有估计的 KL 都停止梯度。

### 2.3.1 PMD-Part：回归完整 Gibbs log-ratio

定义显式 target

$$H_k(s,a) = \eta f(s,a) - \log Z_f(s), \qquad U_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \pi_k(a \mid s).$$

PMD-Part 在 anchor 测度下最小化

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k,\, a\sim\pi_k}\left[U_\theta(s,a) - H_k(s,a)\right]^2. \tag{2.11}$$

对 target 停止梯度，链式法则给出

$$-\nabla_\theta \mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_k,\pi_k}\left[H_k(s,a) - U_\theta(s,a)\right]\nabla_\theta \log \pi_\theta(a \mid s). \tag{2.12}$$

这一步是普通的 log-ratio regression；它没有把 KL 视为常数，也没有使用 action-level importance ratio。

固定 history 后令 $q_\theta(a) = U_\theta(s,a) - H_k(s,a)$。由于 anchor 测度与 target 都冻结，逐步求导得到

$$\nabla_\theta \mathcal{L}_{\mathrm{Part}}(s) = \frac{1}{2}\nabla_\theta \sum_a \pi_k(a \mid s) q_\theta(a)^2 \tag{2.13}$$

$$= \sum_a \pi_k(a \mid s) q_\theta(a) \nabla_\theta U_\theta(s,a) \tag{2.14}$$

$$= \mathbb{E}_{a\sim\pi_k}[q_\theta(a)\nabla_\theta \log \pi_\theta(a \mid s) \mid s]. \tag{2.15}$$

若实际 rollout 来自行为测度 $\beta_k$，而目标仍是 $L_2(\pi_k)$ 投影，则每个 sampled residual 乘以冻结权重 $\mathrm{sg}(\pi_k(a \mid s)/\beta_k(a \mid s))$。不加这个权重时，算法仍然有清晰含义，但求解的是 $L_2(\beta_k)$ 投影。

**Algorithm 1** PMD-Part inner update
*Semantics:* 固定 *anchor* 下的完整 *Gibbs log-ratio* 回归

**Require:** frozen $\pi_k$, teacher signal $f$, histories $\{s_i\}_{i=1}^{B}$, $\eta$, step size $\alpha$
**Ensure:** updated parameters $\theta$
**for** $i = 1, \dots, B$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $\log Z_i \leftarrow \mathrm{logsumexp}_{v \in \mathcal{V}}(\log \pi_k(v \mid s_i) + \eta f(s_i, v))$
  $H_i \leftarrow \eta f(s_i, a_i) - \mathrm{stopgrad}(\log Z_i)$
  $U_i \leftarrow \log \pi_\theta(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\ell_i \leftarrow \frac{1}{2}\big(U_i - \mathrm{stopgrad}(H_i)\big)^2$
**end for**
$\theta \leftarrow \theta - \alpha \nabla_\theta (B^{-1} \sum_i \ell_i)$
**return** $\theta$

### 2.3.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a \sim \pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a \sim \pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean 用 $\eta \widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \ \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta \widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.16}$$

**定理 2.2 (PMD-Mean 的逐历史 Lambert-$W$ 投影)**

在有限词表、$\pi_k(a \mid s) > 0$ 且约束可行时，上述中心化平方回归的唯一 KKT 解满足

$$U_a = G_a - W\big(\lambda(s) e^{G_a}\big), \qquad G_a = \eta \widetilde{f}_k(s,a), \tag{2.17}$$

其中 $\lambda(s) \geq 0$ 由 $\sum_a \pi_k(a \mid s) e^{U_a} = 1$ 唯一确定。 ♡

**证明** 以下给出固定历史 $s$ 的 KKT 推导。令词表上的函数值为 $U_a$ 和 $G_a = \eta \widetilde{f}_k(s,a)$，拉格朗日函数为

$$\mathscr{L}(U, \lambda) = \frac{1}{2} \sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda \left( \sum_a \pi_k(a \mid s) e^{U_a} - 1 \right).$$

一阶条件为

$$U_a - G_a + \lambda e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda e^{G_a}$，所以

$$U_a = G_a - W\big(\lambda e^{G_a}\big), \tag{2.18}$$

其中 $\lambda$ 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda) = \sum_a \pi_k(a \mid s) \exp\big(G_a - W(\lambda e^{G_a})\big), qquad \lambda \geq 0.$$

Lambert–$W$ 在非负轴上单调递增，因此每一项随 $\lambda$ 单调递减；当 $\lambda = 0$ 时 $\Phi(0) = \sum_a \pi_k(a \mid s) e^{G_a}$，而 $\lambda \to \infty$ 时 $\Phi(\lambda) \to 0$。只要中心化 target 不已经满足 $\Phi(0) = 1$，方程 $\Phi(\lambda) = 1$ 有唯一正根；若 $\Phi(0) = 1$，则 $\lambda = 0$，得到 $U_a = G_a$。因此 PMD-Mean 是中心化 target 在指数归一化集合上的投影。严格凸性和 $\Phi$ 的严格单调性给出 KKT 解的唯一性。

约束 $\sum_a \pi_\theta(a \mid s) = 1$ 正是 log-ratio 坐标中的指数归一化条件。特别地，精确 Gibbs 解的 log-ratio 为

$$U_a^\star = \eta f(s,a) - \log Z_f(s), \qquad U_a^\star - \eta \widetilde{f}_k(s,a) = \eta \bar{f}_k(s) - \log Z_f(s),$$

它与 action 无关，且自动满足 $\sum_a \pi_k(a \mid s) e^{U_a^\star} = 1$；这说明 PMD-Mean 恢复的是同一个 Gibbs 分布，而不是把 $\log Z_f$ 任意设为零。

实际样本中需要分别估计 $\bar{U}_\theta(s)$ 和 $\bar{f}_k(s)$。为避免一个 action 同时出现在 residual 与 center 中，给定 $K \geq 2$

个独立 anchor actions，使用 leave-one-out 均值

$$\widehat{\bar{U}}_{-j} = \frac{1}{K-1}\sum_{\ell\neq j} U_\theta(s,a_\ell), \qquad \widehat{\bar{f}}_{-j} = \frac{1}{K-1}\sum_{\ell\neq j} f(s,a_\ell).$$

若 $K = 1$，center 不可估计，应该退化为 PMD-Part 或使用上一批冻结的 center。center 中的 $U_\theta$ 必须保留梯度；把它整体 stop-gradient 会丢掉归一化约束对应的 centered-score 项。

**Algorithm 2** PMD-Mean inner update

*Semantics:* 中心化 *target* 在指数归一化集合上的投影

**Require:** frozen $\pi_k$, signal $f$, histories $\{s_i\}$, $K \geq 2$, $\eta$, step size $\alpha$
**Ensure:** updated parameters $\theta$

**for** each history $s_i$ **do**
  **for** $j = 1, \ldots, K$ **do**
    sample $a_{ij} \sim \pi_k(\cdot \mid s_i)$
    $U_{ij} \leftarrow \log \pi_\theta(a_{ij} \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_{ij} \mid s_i))$
    $F_{ij} \leftarrow f(s_i, a_{ij})$
  **end for**
  **for** $j = 1, \ldots, K$ **do**
    $\bar{U}_{-j} \leftarrow (K-1)^{-1} \sum_{\ell\neq j} U_{i\ell}$, $\bar{F}_{-j} \leftarrow (K-1)^{-1} \sum_{\ell\neq j} F_{i\ell}$
    $\ell_{ij} \leftarrow \frac{1}{2}[(U_{ij} - \bar{U}_{-j}) - \eta(F_{ij} - \bar{F}_{-j})]^2$
  **end for**
**end for**
$\theta \leftarrow \theta - \alpha \nabla_\theta (BK)^{-1} \sum_{i,j} \ell_{ij}$
**return** $\theta$

### 2.3.3 BPO：中心化最优性 residual

BPO 不显式回归 $\log Z_f$，而将同一个最优性方程的 action-independent 部分消去。定义

$$D_\theta(s,a) = \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{v\sim\pi_k}[\eta f(s,v) - U_\theta(s,v) \mid s]. \tag{2.19}$$

直接展开可得

$$D_\theta(s,a) = \eta \widetilde{f}_k(s,a) - U_\theta(s,a) + \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v) \mid s].$$

未线性化 BPO 的损失为

$$\mathcal{L}_{\mathrm{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[D_\theta(s,a)^2]. \tag{2.20}$$

由于

$$\nabla_\theta \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v)] = \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s)],$$

所以

$$-\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_k,\pi_k}\left[D_\theta(s,a)\left(\nabla_\theta \log \pi_\theta(a \mid s) - \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s) \mid s]\right)\right]. \tag{2.21}$$

BPO 的 score centering 来自对当前 student–anchor KL 的精确求导；它不是因为先对 reward 做了一个近似。

令 $G_\theta(s) = \mathbb{E}_{\pi_k}[\eta f(s,v) - U_\theta(s,v) \mid s]$，则

$$\nabla_\theta D_\theta(s,a) = -\nabla_\theta U_\theta(s,a) + \nabla_\theta \mathbb{E}_{\pi_k}[U_\theta(s,v) \mid s] = -g_\theta(s,a) + \bar{g}_\theta(s).$$

所以 centered score 是对 center 本身求导的结果，而不是把 reward 任意减去 baseline。无偏的 Monte Carlo 实现最好为每个 history 使用独立的 action $a_i$ 计算 residual，再使用独立集合 $\{b_{i\ell}\}$ 估计 $G_\theta(s_i)$；若复用样本，必须用 leave-one-out center。

若从行为测度 $\beta$ 采样，$z_i$ 和每个 center summand 都乘以冻结的 $\mathrm{sg}(\pi_k/\beta)$ 才对应 $\pi_k$ 期望。该权重只改变积分测度，不能对它反向传播。

**Algorithm 3** BPO inner update
*Semantics:* 对中心化最优性 *residual* 求平方损失

**Require:** frozen $\pi_k$, signal $f$, histories $\{s_i\}$, center size $K$, $\eta$, step size $\alpha$
**Ensure:** updated parameters $\theta$
**for** each history $s_i$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$ and $b_{i1}, \dots, b_{iK} \sim \pi_k(\cdot \mid s_i)$ independently
  $z_i \leftarrow \eta f(s_i, a_i) - \log \pi_\theta(a_i \mid s_i) + \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\bar{z}_i \leftarrow K^{-1} \sum_{\ell=1}^{K} [\eta f(s_i, b_{i\ell}) - \log \pi_\theta(b_{i\ell} \mid s_i) + \mathrm{stopgrad}(\log \pi_k(b_{i\ell} \mid s_i))]$
  $d_i \leftarrow z_i - \bar{z}_i$, $\ell_i \leftarrow d_i^2/(2\eta)$
**end for**
$\theta \leftarrow \theta - \alpha \nabla_\theta B^{-1} \sum_i \ell_i$
**return** $\theta$

### 2.3.4 MDPO：直接优化 mirror objective

MDPO 直接最大化式(2.1) 的参数化版本：

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \mathbb{E}_{a \sim \pi_\theta}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(\pi_\theta(\cdot \mid s) \| \pi_k(\cdot \mid s)) \,. \tag{2.22}$$

完整词表时 KL 是

$$\mathrm{KL}(\pi_\theta \| \pi_k) = \sum_a \pi_\theta(a \mid s) \left[\log \pi_\theta(a \mid s) - \log \pi_k(a \mid s)\right] . \tag{2.23}$$

若 action 从 anchor 采样，定义 $R_\theta(s,a) = \exp(\ell^\theta(a) - \ell^k(a))$，则 action-level IS 形式为

$$\widehat{\mathcal{J}}_{\mathrm{MDPO}} = \mathbb{E}_{a \sim \pi_k} \left[ R_\theta(s,a) f(s,a) - \frac{1}{\eta} R_\theta(s,a) \log R_\theta(s,a) \right] . \tag{2.24}$$

其 ascent direction 为

$$\nabla_\theta \mathcal{J}_{\mathrm{MDPO}} = \mathbb{E}_{\pi_k} \left[ R_\theta(s,a) \left( f(s,a) - \frac{1}{\eta} \log R_\theta(s,a) \right) \nabla_\theta \log \pi_\theta(a \mid s) \right] . \tag{2.25}$$

额外的 $-R_\theta/\eta$ 项乘以 score 后，在完整 action 求和中因 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$ 消失。MDPO 因而直接优化 mirror objective，其他三种方法优化的是由同一最优性方程构造的 regression objective。

MDPO 的自然梯度只改变更新几何，不改变上面的 token target。令 $g = \nabla_\theta \mathcal{J}_{\mathrm{MDPO}}$，并令

$$F_\theta = \mathbb{E}_{a \sim \pi_\theta}[g_\theta(a) g_\theta(a)^\top], \qquad g_\theta(a) = \nabla_\theta \log \pi_\theta(a \mid s).$$

若从 anchor 采样，用 $\mathrm{sg}(R_\theta)$ 进行测度校正。由于 categorical Fisher 的零空间是 logits 的常数方向，$F_\theta^\dagger g$ 位于 simplex 切空间；神经网络参数化下则需用阻尼逆 $(F + \lambda I)^{-1}$ 或 KL trust region，不能把自然步长与 mirror 温度 $\eta$ 混用。

**Algorithm 4** MDPO natural-gradient inner update
*Semantics:* 直接优化固定 *history* 的 *mirror objective*

**Require:** frozen $\pi_k$, signal $f$, histories $\{s_i\}$, $\eta$, natural step $\alpha$
**Ensure:** updated parameters $\theta$
**for** each history $s_i$ **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $R_i \leftarrow \exp(\log \pi_\theta(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i)))$
  $j_i \leftarrow R_i f(s_i, a_i) - \eta^{-1} R_i \log R_i$ ▷ 保留 $R_i$ 对 student 的梯度
**end for**
$g \leftarrow \nabla_\theta (B^{-1} \sum_i j_i)$
$g_i^{\mathrm{score}} \leftarrow \nabla_\theta \log \pi_\theta(a_i \mid s_i)$
$F \leftarrow B^{-1} \sum_i \mathrm{stopgrad}(R_i) g_i^{\mathrm{score}} (g_i^{\mathrm{score}})^\top$
$\theta \leftarrow \theta + \alpha (F + \lambda I)^\dagger g$
**return** $\theta$

**定理 2.3 (四种 inner 的共同精确解)**

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、PMD-Mean、未线性化 BPO 和 MDPO 都以式(2.3) 为精确解。PMD-Mean 的结论要求其投影 target 可实现；参数化 student 或有限样本时，四者得到的是不同的投影或优化误差。 ♡

**证明** PMD-Part 在零损失处满足 $U_\theta = \eta f - \log Z_f$，于是得到式(2.3)。BPO 的零 residual 只确定 $U_\theta = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_\theta}] = 1$ 得 $C(s) = \log Z_f(s)$。PMD-Mean 若中心化 target 属于归一化约束集合，则其平方投影残差为零，并由中心化不变性得到同一策略。MDPO 由式(2.4) 直接得到唯一最大点。

**命题 2.4 (未线性化 BPO 与 PMD-Part 的梯度差异)**

固定一个历史 $s$，令

$$q(s,a) = \eta f(s,a) - \log Z_f(s) - U_\theta(s,a), \qquad c(s) = \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] - \eta \mathbb{E}_{\pi_k}[f(s,\cdot) \mid s]. \tag{2.26}$$

则未线性化 BPO residual 满足 $D_\theta = q + c$，并且

$$-\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = -\nabla_\theta \mathcal{L}_{\mathrm{Part}} + c(s)\, \mathbb{E}_{a\sim\pi_k}[\nabla_\theta \log \pi_\theta(a \mid s) \mid s]. \tag{2.27}$$

因此两者在精确镜像解处都有零梯度，但在一般参数点不相同。它们只有在 $c(s)\, \mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$ 时才给出相同的方向。 ♠

**证明** 从 PMD-Part 的最优性残差出发，先把 BPO 的中心化式逐项展开：

$$\begin{aligned} D_\theta(s,a) &= \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{\pi_k}[\eta f(s,\cdot) - U_\theta(s,\cdot) \mid s] \\ &= \eta f(s,a) - \log Z_f(s) - U_\theta(s,a) + \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] \\ &= q(s,a) + c(s). \end{aligned}$$

由定义，$\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$。BPO 的精确梯度为

$$\begin{aligned} -\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} &= \mathbb{E}_{\pi_k}\left[D_\theta\,(g_\theta - \bar{g}_\theta) \mid s\right], \\ g_\theta(a) &= \nabla_\theta \log \pi_\theta(a \mid s), \qquad \bar{g}_\theta = \mathbb{E}_{\pi_k}[g_\theta \mid s]. \end{aligned}$$

代入 $D_\theta = q + c$，并使用 $\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$，可得

$$\begin{aligned} \mathbb{E}_{\pi_k}[D_\theta(g_\theta - \bar{g}_\theta) \mid s] &= \mathbb{E}_{\pi_k}[(q+c)g_\theta \mid s] - \mathbb{E}_{\pi_k}[D_\theta \mid s]\bar{g}_\theta \\ &= \mathbb{E}_{\pi_k}[q g_\theta \mid s] + c(s)\bar{g}_\theta. \end{aligned}$$

而 PMD-Part 的梯度式为 $-\nabla_\theta \mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{\pi_k}[q g_\theta \mid s]$，故式(2.27) 成立。若 $q = 0$，则由归一化约束有 $c = 0$，两边同时为零；离开该点时 $c$ 通常非零，差异项保留。

这个命题说明“都在 token level”只保证它们面对同一个局部镜像根，不保证优化轨迹相同。PMD-Part 回归完整的 action-dependent log-ratio，并把 $\log Z_f$ 当作固定 target；BPO 先消去 action-independent 常数，再对当前 student 的归一化项求导，因此多出 centered score。若使用的参数化使 $\mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$（例如采样测度与当前 student 一致，或在特定 tabular 点上），差异项才会消失。

# 第三章 KL 估计量、无偏性与方差

## 3.1 K4 的无偏性

固定 history，记 $p = \pi_\theta(\cdot \mid s)$、$q = \mu_k(\cdot \mid s)$，并从 $p$ 采样 $a$。定义

$$w(a) = \frac{q(a)}{p(a)}, \qquad r_\theta(a) = \frac{p(a)}{\mathrm{stopgrad}(p(a))}.$$

数值上 $r_\theta = 1$，但其导数为 $\nabla \log p(a)$。

**定理 3.1 (K4 value and gradient)**

若 $p \ll q$ 且二阶矩有限，则

$$\mathbb{E}_{a\sim p}[r_\theta(a)(-\log w(a))] = \mathrm{KL}(p\|q),$$

并且自动微分意义下

$$\mathbb{E}_{a\sim p}[\nabla_\theta\{r_\theta(a)(-\log w(a))\}] = \nabla_\theta \mathrm{KL}(p\|q).$$

♡

**证明** 数值 value 中 $r_\theta = 1$，所以第一式是

$$\mathbb{E}_p[-\log(q/p)] = \sum_a p(a)\log(p(a)/q(a)).$$

对 stop-gradient 构造求导时，$-\log w = \log p - \log q$ 的 derivative 与 $r_\theta$ 的 derivative 共同给出

$$\nabla_\theta\{r_\theta(-\log w)\} = \nabla_\theta \log p(a)\,[\log p(a) - \log q(a)] + \nabla_\theta \log p(a).$$

最后一项在 $p$ 下期望为零，第一项正是 KL 的 score-function derivative。 □

K1 的数值也无偏，但其 autograd gradient 为零；K3 的 gradient 对应 $\mathrm{KL}(q\|p)$ 的方向；K2 梯度正确但 value 有偏。因此 BPO 的 KL 项应优先使用 K4、K3$^{++}$ 或完整 vocabulary 计算。

## 3.2 固定 anchor 测度上的重要性校正

若工程上必须从 $q = \mu_k$ 采样，令 $\rho_\theta(a) = p(a)/q(a)$，并在积分权重上停止梯度。对于任意可积向量 $h$，

$$\mathbb{E}_q[\mathrm{stopgrad}(\rho_\theta)h(a)] = \mathbb{E}_p[h(a)].$$

因此 BPO 的固定测度估计量为

$$\widehat{g}_i = \mathrm{stopgrad}(\rho_i)\left[r_i - \frac{1}{\eta}\widehat{k}_{4,i}\right] g_i, \qquad a_i \sim q.$$

在 $p/q$ 的二阶矩有限时，它无偏；其单样本方差满足

$$\mathbb{E}_q\|\widehat{g}_i\|^2 \le C^2\mathbb{E}_q[\rho_\theta^2] = C^2\big(1 + \chi^2(p\|q)\big), \tag{3.1}$$

其中 $C$ 上界 reward、K4 项和 score 的乘积。故 inner 走远以后，固定 anchor 的估计方差由 $\chi^2(p\|q)$ 控制；这正是必须记录 current-anchor divergence 的原因。

## 3.3 Top-$K$ 与完整词表的关系

如果保存当前策略和 anchor 的 top-$K$ logits，完整 reverse KL 可以拆成

$$\sum_{a\in Q_K} p(a)\log\frac{p(a)}{q(a)} + \sum_{a\notin Q_K} p(a)\log\frac{p(a)}{q(a)}.$$

第一项可精确计算；第二项不能被简单删除，否则得到截断 KL 而非完整 KL。2602.04417 的 Top-$K$ 估计量在尾部使用 masked sampled K4：若采样 token 不在 $Q_K$，加入

$$\mathbf{1}(a \notin Q_K)\ \mathrm{stopgrad}\left(\frac{p(a)}{\pi_{\mathrm{sampling}}(a)}\right) r_\theta(a)(-\log w(a)).$$

它同时保持 value 和 gradient 无偏。对本项目而言，第一版小实验不使用 top-$K$ reward，而先验证 full-vocabulary oracle 和 sampled K4 两条路径；否则无法判断误差来自 mirror target 还是 tail estimator。

## 3.4 有限 inner 更新的误差

设 exact token target 为 $p_k^+$，inner 算法在固定 $s$ 上得到 $p_{k,m}$。定义 total variation error

$$e_{k,m}(s) = \frac{1}{2}\|p_{k,m}(\cdot \mid s) - p_k^+(\cdot \mid s)\|_1.$$

若 loss gradient 是 $L$-smooth，且使用 unbiased gradient with variance at most $\sigma^2/B$，标准 projected SGD 给出

$$\frac{1}{M}\sum_{m=0}^{M-1} \mathbb{E}\|\nabla \mathcal{L}(\theta_m)\|^2 \le \frac{2(\mathcal{L}_0 - \mathcal{L}_*)}{\alpha M} + \frac{L\alpha\sigma^2}{B}.$$

如果使用固定 anchor 而 current policy 逐渐远离它，则 $\sigma^2$ 需要替换为含 $1 + \chi^2(p_{k,m}\|\mu_k)$ 的上界。因而 inner 做得越久，不一定越接近 exact target：优化误差下降的同时，off-policy estimator variance 会上升。

# 第四章 Outer 同步与有限 inner 的动力学

## 4.1 Hard sync 的精确动力学

先考虑每个 history 的 teacher 分布 $T$ 不随 outer 改变，并且 inner 精确收敛到式 (1.3)。hard sync 定义为

$$\mu_k = \pi_k, \qquad \pi_{k+1} = \frac{\pi_k^{1-\eta} T^{\eta}}{Z_k}.$$

**定理 4.1 (Hard-sync geometric interpolation)**

若 $0 < \eta \le 1$ 且初始策略与 $T$ 互相绝对连续，则

$$\pi_k(a \mid s) = \frac{\pi_0(a \mid s)^{(1-\eta)^k} T(a \mid s)^{1-(1-\eta)^k}}{\sum_b \pi_0(b \mid s)^{(1-\eta)^k} T(b \mid s)^{1-(1-\eta)^k}}. \tag{4.1}$$

并且

$$\log \frac{\pi_k(a \mid s)}{T(a \mid s)} = (1-\eta)^k \log \frac{\pi_0(a \mid s)}{T(a \mid s)} - \log C_k(s),$$

其中 $C_k(s)$ 是归一化常数。$\eta = 1$ 时一个 exact inner 将策略直接变成 teacher；$0 < \eta < 1$ 时每一轮只消除比例 $\eta$ 的 log-density mismatch。

♡

**证明** 归纳证明。$k = 0$ 显然成立。假设式 (4.1) 成立，则

$$\pi_{k+1} \propto \pi_k^{1-\eta} T^{\eta} \propto \pi_0^{(1-\eta)^{k+1}} T^{(1-\eta)(1-(1-\eta)^k)+\eta}.$$

指数合并为 $1-(1-\eta)^{k+1}$，归一化后得到结论。 □

**推论 4.1 (Outer contraction)**

在任意固定 $s$ 上，unnormalized log-ratio 的 contraction factor 是 $1-\eta$。若 log-ratio 初始振幅不超过 $B$，则归一化后 total variation 满足

$$\mathrm{TV}(\pi_k, T) \le \frac{1}{2}\left(e^{2B(1-\eta)^k} - 1\right).$$

该界说明小 $\eta$ 不是免费加稳定性：它把每轮变化缩小，同时把达到相同 teacher proximity 所需的 outer steps 增加到 $O(\eta^{-1}\log(1/\varepsilon))$。

♡

## 4.2 有限 inner 与 stale target

实际第 $k$ 轮只运行 $M_k$ 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi^{+}_{k+1}(a \mid s)}\right| \le \varepsilon_k$$

在归一化前成立。则归一化后

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi^{+}_{k+1}) \le \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.2}$$

令 $d_k = \mathrm{TV}(\pi_k, T)$，由 triangle inequality 和 hard-sync contraction 得

$$d_{k+1} \le (1-\eta) d_k + \delta_k, \qquad \delta_k = \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.3}$$

因此

$$d_K \le (1-\eta)^K d_0 + \sum_{j=0}^{K-1} (1-\eta)^{K-1-j} \delta_j.$$

有限 inner 误差不会被简单地“下一轮 rollout”消失；它会以几何权重累积。若 $\delta_j \le \bar{\delta}$，稳态误差上界为 $\bar{\delta}/\eta$。

## 4.3 Soft sync 的耦合动力学

若 anchor 使用 EMA，令

$$\mu_{k+1} = \lambda\mu_k + (1-\lambda)\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \mu_k^{1-\eta} T^{\eta}.$$

忽略归一化扰动并在线性 log-density 坐标中写 $z_k = \log \mu_k - \log T$，得到近似递推

$$z_{k+1} \approx [\lambda + (1-\lambda)(1-\eta)]z_k = [1-(1-\lambda)\eta]z_k.$$

所以 EMA 同时把 outer contraction 从 $1-\eta$ 改成 $1-(1-\lambda)\eta$。当 $\lambda$ 接近 1，anchor 漂移非常慢，训练稳定但 teacher tracking 速度下降；这不是 inner 学习率的效果，而是 outer target 的真实动力学。

## 4.4 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 $\rho_k$ 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，$\rho_{k+1}$ 改变，必须额外记录 coverage drift：

$$\Delta_k = \mathrm{TV}(\rho_{k+1}, \rho_k).$$

若 token loss 在所有 history 上有上界 $C$，则访问测度改变给目标梯度带来至多 $2C\Delta_k$ 的偏差。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

# 第五章 可枚举 Token 实验与实现边界

## 5.1 实验设置

实验脚本位于 `experiments/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\mu = (0.62, 0.23, 0.10, 0.05), \qquad T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略开始，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。这样可以单独检查 token-level inner 的数学对象。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整 categorical objective；MDPO 使用 exact categorical Fisher preconditioner。

## 5.2 结果

表 5.1 报告 400 个 inner updates 后与 exact target 的 total variation 距离和 KL。BPO、MDPO 达到机器精度；PMD-Part、PMD-Mean 使用固定 learning rate，因此保留小的优化误差，降低 learning rate 或继续更新后继续下降。

**表 5.1:** 固定测度 token inner 的可枚举实验。

| $\eta$ | 方法 | $\mathrm{TV}(p, p^+)$ | $\mathrm{KL}(p\|p^+)$ |
|---|---|---|---|
| 0.25 | PMD-Part | 1.11e-3 | 6.79e-6 |
| 0.25 | PMD-Mean | 1.25e-3 | 8.30e-6 |
| 0.25 | BPO | $2.16 \times 10^{-15}$ | $-5.35 \times 10^{-17}$ |
| 0.25 | MDPO | $1.11 \times 10^{-16}$ | $9.34 \times 10^{-17}$ |
| 0.50 | PMD-Part | 2.65e-3 | 2.54e-5 |
| 0.50 | PMD-Mean | 4.71e-3 | 6.85e-5 |
| 0.50 | BPO | $9.54 \times 10^{-13}$ | $5.44 \times 10^{-17}$ |
| 0.50 | MDPO | $1.25 \times 10^{-16}$ | $3.14 \times 10^{-17}$ |
| 0.80 | PMD-Part | 2.97e-3 | 2.65e-5 |
| 0.80 | PMD-Mean | 1.12e-2 | 2.73e-4 |
| 0.80 | BPO | $4.15 \times 10^{-7}$ | $7.20 \times 10^{-13}$ |
| 0.80 | MDPO | $1.80 \times 10^{-16}$ | $-7.73 \times 10^{-17}$ |

实验验证了三个实现结论。第一，四个方法的 exact fixed point 相同；差别在于 residual、policy-gradient estimator 和 Fisher geometry。第二，BPO 必须把 KL 作为带正确梯度的项；K4 可以在不保存完整词表时实现这一点。第三，$\eta$ 改变的是 mirror target 的位置：$\eta$ 越大，target 越接近 teacher；它不能代替 inner optimizer learning rate。

## 5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
2. 对随机 $p, q$，用大量样本检查 K4 value 与 exact $\mathrm{KL}(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
3. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
4. 检查固定 anchor 采样的 importance correction 在 $p/q$ 接近一时无偏；
5. 人为增加 inner steps，确认 current-anchor $\chi^2$ 和估计方差同时上升；
6. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `uv run --with torch python experiments/toy_tok` 生成，结果保存在 `experiments/toy_token_inner.csv`。独立的 `experiments/test_kl_estimators.py` 使用

200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 $5.6 \times 10^{-5}$，gradient 的 $ell_2$ 误差为 $1.5 \times 10^{-3}$。

# 参考资料

本文 KL 估计量的记号与 K3$^{++}$、K4、K5、Top-$k$ 估计量来自科研`/pmd-theory/2602.04417_zh_CN/example_paper.tex`；One-Shot-OPD 的实现审计见科研`/pmd-theory/MirrorOPD/source_audit/One-Shot-OPD/`。