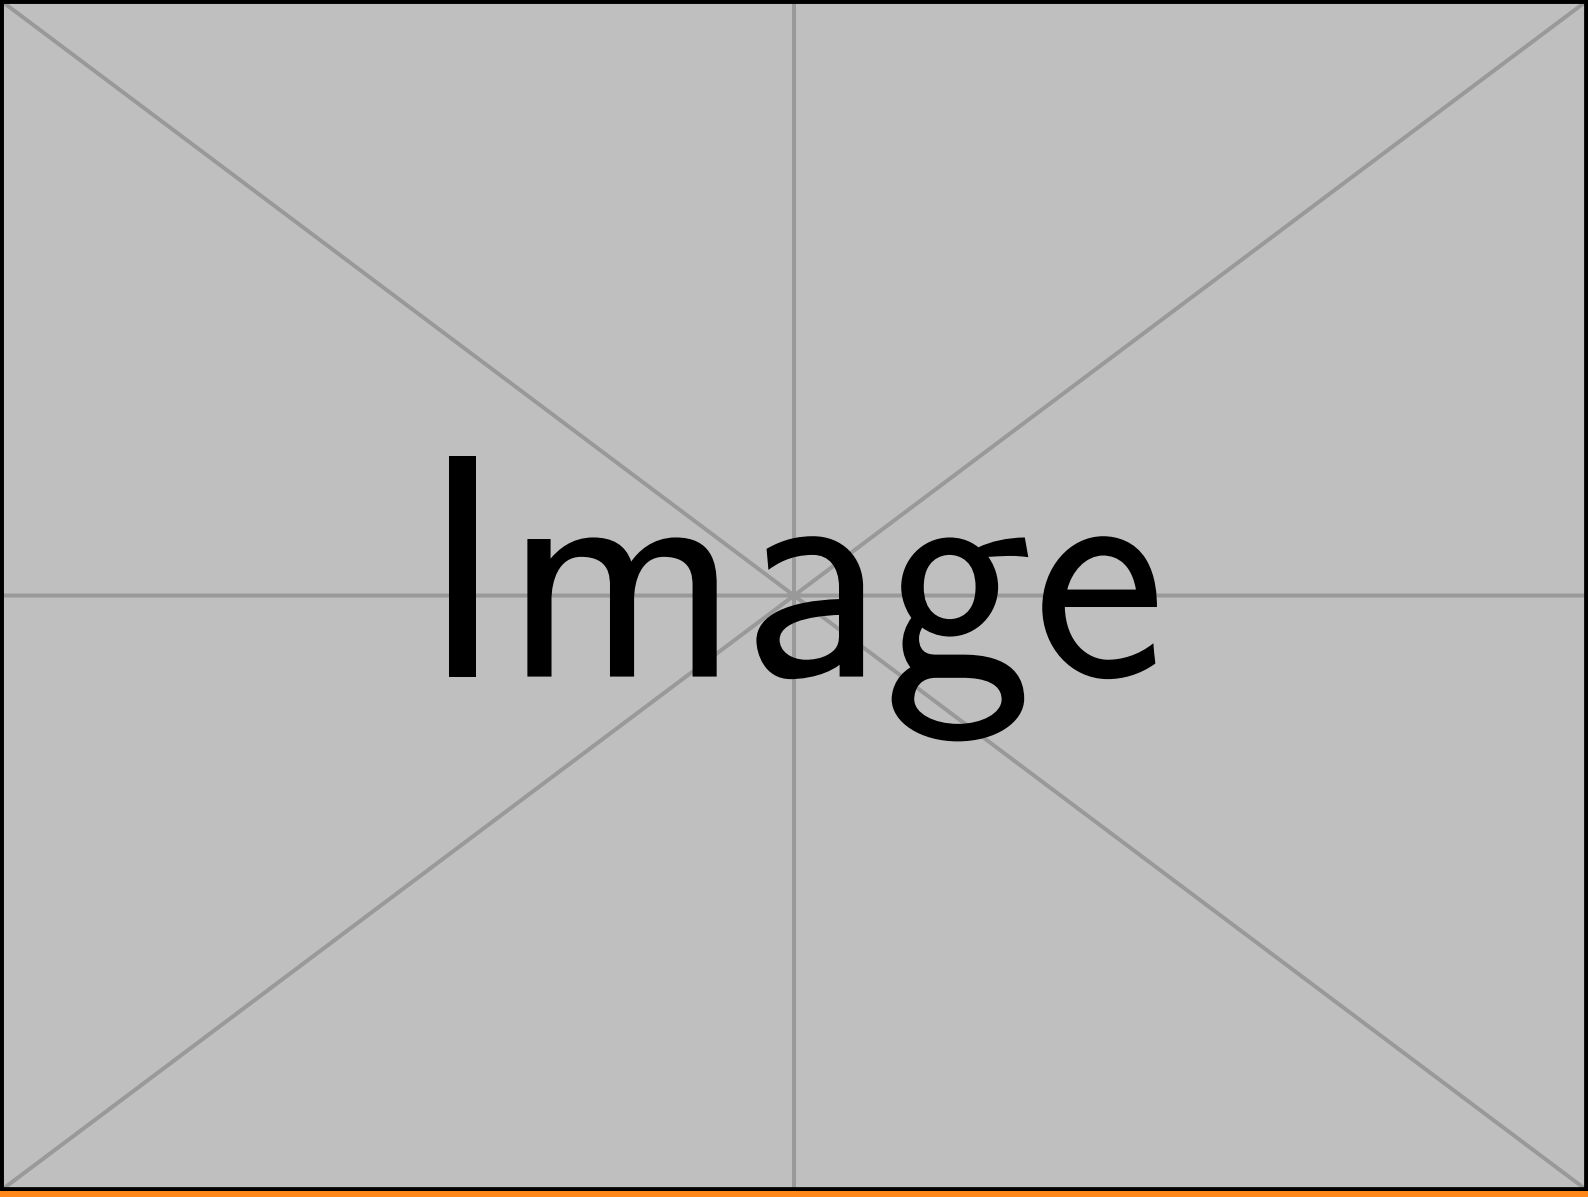


固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

目录

第一章 固定测度的 Token 级优化问题 **1**
1.1 外层同步与内层对象 1
1.2 共同闭式解 1
1.3 固定测度下的三个等价表述 2
1.4 参数化策略的投影 2

第二章 统一的 token-level Mirror Descent 与 OPD 实例化 **3**
2.1 共同的 mirror 子问题与精确解 3
2.2 从镜像最优性方程到四种可训练目标 4
2.3 四种 inner 的统一推导 6
2.4 OPD 特化：逐 token reward 与两种信息访问模式 11

第三章 KL 估计量、无偏性与方差 **20**
3.1 K4 的无偏性 20
3.2 固定 anchor 测度上的重要性校正 20
3.3 Top-K 与完整词表的关系 20
3.4 有限 inner 更新的误差 21

第四章 Outer 同步与有限 inner 的动力学 **22**
4.1 Hard sync 的精确动力学 22
4.2 有限 inner 与 stale target 22
4.3 Soft sync 的耦合动力学 23
4.4 访问测度固定的含义 23

第五章 可枚举 Token 实验与实现边界 **24**
5.1 实验设置 24
5.2 结果 24
5.3 正式 LLM 实验前必须通过的检查 24

第一章 固定测度的 Token 级优化问题

1.1 外层同步与内层对象

第 k 个 outer step 开始时，学生策略、anchor 和教师分别记为

$$\pi_k(\cdot \mid s), \qquad \mu_k(\cdot \mid s), \qquad T(\cdot \mid s).$$

hard sync 时 $\mu_k = \pi_k$；soft sync 时 μ_k 是学生参数的 EMA。一个 token history $s = (x, y_{<t})$ 在本章内被冻结。外层采样只负责产生一批 history；inner 不再改变该批 history 的访问测度，也不重新计算教师目标。

定义教师相对 anchor 的 token reward

$$r_k(s,a) = \log T(a \mid s) - \log \mu_k(a \mid s).$$

我们研究的 inner 子问题是

$$\max_{p \in \Delta(\mathcal{V})} \mathcal{J}_{k,s}(p) = \mathbb{E}_{a\sim p}[r_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p\|\mu_k), \qquad \eta > 0. \tag{1.1}$$

这里的 p 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 s 不随 inner 更新；它不意味着优化变量 p 必须等于采样分布 μ_k。

1.2 共同闭式解

令

$$Z_k(s) = \sum_{a\in\mathcal{V}} \mu_k(a \mid s)\exp(\eta r_k(s,a)).$$

由于 $r_k = \log T - \log \mu_k$，有

$$Z_k(s) = \sum_a \mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}. \tag{1.2}$$

定理 1.1 (Token mirror target)

若 $\mu_k(a \mid s) > 0$ 时 $T(a \mid s) > 0$，则式 (1.1) 的唯一最大点为

$$p_k^+(a \mid s) = \frac{\mu_k(a \mid s)\exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.3}$$

并且对任意 p，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\,\mathrm{KL}(p\|p_k^+). \tag{1.4}$$

♡

证明 由式 (1.3)，

$$\log p_k^+(a \mid s) = \log \mu_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\mathrm{KL}(p\|p_k^+) = \sum_a p(a \mid s)\left[\log \frac{p(a \mid s)}{\mu_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s)\right]$$

$$= \mathrm{KL}(p\|\mu_k) - \eta \mathbb{E}_p[r_k] + \log Z_k(s).$$

移项得到式 (1.4)。KL 非负且仅在 $p = p_k^+$ 时为零，所以最大点唯一。 □

推论 1.1 (几何插值与极限)

当 $\eta = 0$ 时 $p_k^+ = \mu_k$ 的一阶极限成立；当 $\eta = 1$ 时 $p_k^+ = T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log p_k^+ = (1-\eta)\log \mu_k + \eta \log T - \log Z_k.$$

因此 η 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

1.3 固定测度下的三个等价表述

定义 $m_k(s) = \mathbb{E}_{a\sim\mu_k}[r_k(s,a)]$。由 KL 定义，

$$m_k(s) = -\,\mathrm{KL}(\mu_k(\cdot \mid s) \| T(\cdot \mid s)). \tag{1.5}$$

将 reward 换成 $r_k - m_k$ 只改变 partition 的常数：

$$\mathbb{E}_{\mu_k}[e^{\eta(r_k - m_k)}] = e^{-\eta m_k} Z_k,$$

所以闭式分布 p_k^+ 不变。这是 PMD-Part 与 PMD-Mean 共享固定点的原因。

若定义 $u_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \mu_k(a \mid s)$，则 exact regression residual 为

$$q_{\mathrm{part}}(s,a;\theta) = u_\theta(s,a) - \eta r_k(s,a) + \log Z_k(s). \tag{1.6}$$

PMD-Mean 使用

$$q_{\mathrm{mean}}(s,a;\theta) = u_\theta(s,a) - \eta[r_k(s,a) - m_k(s)]. \tag{1.7}$$

二者的零点都等价于 $\pi_\theta = p_k^+$，但有限样本中 $\log Z_k$ 与 m_k 的估计方差不同。

1.4 参数化策略的投影

实际神经网络只能表示 $\{\pi_\theta\}$。固定 history 测度 $\rho_k(s)$ 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim\rho_k, a\sim\mu_k}\left[q_{\mathrm{part}}(s,a;\theta)^2\right]. \tag{1.8}$$

若模型在每个 history 上可以实现式 (1.3)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章固定一套与 outer–inner 动力学一致的记号。给定 prompt x，rollout 为 $y_{1:H}$，第 t 个 token 之前的历史为 $s_t = (x, y_{<t})$，词表为 $\mathcal{V}$。第 k 个 outer step 的冻结 anchor policy 记为 π_k，该轮第 n 个 inner step 的 student policy 记为

$$\pi_{k,n}(a \mid s) := \pi_{\theta_{k,n}}(a \mid s), \qquad \pi_{k,0} = \pi_k. \tag{2.1}$$

teacher policy 记为 π_T；它在一个 outer step 内始终冻结。镜像系数记为 $\eta > 0$，inner optimizer 的步长记为 $\alpha_{k,n}$，两者不能混用。

为避免把不同方向的 KL 和 top-K 中的整数 K 混在一起，本章使用

$$\Delta_{k,n}(s,a) := \log \frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)}, \tag{2.2}$$

$$r_k(s,a) := \log \frac{\pi_T(a \mid s)}{\pi_k(a \mid s)}, \tag{2.3}$$

$$C_k^T(s) := \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s)), \tag{2.4}$$

$$C_{k,n}^{\theta}(s) := \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_{k,n}(\cdot \mid s)). \tag{2.5}$$

因此 $\mathbb{E}_{\pi_k}[r_k \mid s] = -C_k^T(s)$，而 $\mathbb{E}_{\pi_k}[\Delta_{k,n} \mid s] = -C_{k,n}^{\theta}(s)$。这些等式解释了后文两个 KL 的方向：它们都是在冻结 anchor 的 action 测度下取均值，而不是 MDPO 中以 student 为左侧分布的 reverse KL。d_k 表示由 π_k rollout 诱导的 prefix 访问测度；所有 inner 目标先对 $s \sim d_k$、再对 $a \sim \pi_k(\cdot \mid s)$ 取期望。

2.1 共同的 mirror 子问题与精确解

定义 2.1 (Token-level mirror 子问题)

给定固定历史 s、token 信号 $f(s,a)$ 和 anchor π_k，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a \sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\mathrm{KL}(p(\cdot \mid s) \| \pi_k(\cdot \mid s)). \tag{2.6}$$

镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。同时定义配分函数

$$Z_f(s) = \sum_{v \in \mathcal{V}} \pi_k(v \mid s) \exp\big(\eta f(s,v)\big). \tag{2.7}$$

♣

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.6) 的唯一解是

$$\pi_k^+(v \mid s) = \frac{\pi_k(v \mid s) e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log \frac{\pi_k^+(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.8}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}\big(p \big\| \pi_k^+(\cdot \mid s)\big). \tag{2.9}$$

♡

证明 由式(2.8)，有

$$\log \frac{p(v \mid s)}{\pi_k^+(v \mid s)} = \log \frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p \| \pi_k^+) = \mathrm{KL}(p \| \pi_k) - \eta \mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.9)。KL 非负且仅在 $p = \pi_k^+$ 时取零，因此最优解唯一。

定义 2.2 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

命题 2.1 (优势函数的 anchor 条件均值)

若 $f(s,a) = A^{\pi_k}(s,a)$，则对每个满足 $\pi_k(\cdot \mid s)$ 定义的历史，

$$\mathbb{E}_{a\sim\pi_k(\cdot|s)}[f(s,a) \mid s] = 0. \tag{2.10}$$

对于一般 OPD log-ratio 或 teacher score，该等式不是定义恒等式，必须显式估计并减去条件均值。

证明 由 $A^{\pi_k}(s,a) = Q^{\pi_k}(s,a) - V^{\pi_k}(s)$ 以及 $V^{\pi_k}(s) = \mathbb{E}_{a\sim\pi_k}[Q^{\pi_k}(s,a) \mid s]$，有

$$\begin{aligned}\mathbb{E}_{\pi_k}[A^{\pi_k}(s,a) \mid s] &= \mathbb{E}_{\pi_k}[Q^{\pi_k}(s,a) \mid s] - V^{\pi_k}(s) \\ &= V^{\pi_k}(s) - V^{\pi_k}(s) = 0.\end{aligned}$$

命题 2.2 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.6) 的最优分布。

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是孤立的分布结论，而是一条可以被 inner optimizer 直接拟合的逐 token 方程。下面先把这条方程、平方损失和 BPO 的中心化残差逐步写出，再进入四种算法的实现。

2.2.1 镜像最优性方程与训练测度

把式(2.8) 移项，得到

$$\log\frac{\pi_k^+(a \mid s)}{\pi_k(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.11}$$

在参数化 inner 中，左侧由 $\pi_{k,n}$ 近似。因此定义镜像方程残差

$$\mathscr{E}_{k,n}(s,a) := \log\frac{\pi_{k,n}(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s). \tag{2.12}$$

精确 mirror 解的条件是 $\mathscr{E}_{k,n}(s,a) = 0$ 对所有有正概率的 (s,a) 成立。

为什么训练测度是 π_k 而不是 $\pi_{k,n}$？在第 k 个 outer step，rollout 已由冻结的 π_k 产生；我们要解决的是固定 anchor 的 mirror 子问题，而不是在 inner 过程中不断改变积分测度。于是参数化投影定义为

$$\|\mathscr{E}_{k,n}\|_k^2 := \mathbb{E}_{s\sim d_k}\mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\mathscr{E}_{k,n}(s,a)^2\right]. \tag{2.13}$$

这也是 on-policy rollout 下可直接估计的投影几何。若改用行为测度 β_k 采样，必须乘以冻结的 importance weight $\pi_k(a \mid s)/\beta_k(a \mid s)$，否则求解的是 $L_2(d_k\beta_k)$ 投影。

2.2.2 PMD-Part 与 PMD-Mean：从方程到平方损失

PMD-Part直接最小化式(2.12) 的平方。将 student log-ratio 和冻结 target 展开，得到

$$\mathcal{L}_{\mathrm{Part}}(\theta)=\frac{1}{2}\mathbb{E}_{s\sim d_k,a\sim\pi_k}\left[\log\frac{\pi_\theta(a\mid s)}{\pi_k(a\mid s)}-\eta f(s,a)+\mathrm{sg}(\log Z_f(s))\right]^2. \tag{2.14}$$

其中 sg 表示停止梯度；π_k、f 和 Z_f 在本轮 inner 中都冻结。因为

$$\nabla_\theta\log\frac{\pi_\theta(a\mid s)}{\pi_k(a\mid s)}=\nabla_\theta\log\pi_\theta(a\mid s),$$

其梯度为

$$\nabla_\theta\mathcal{L}_{\mathrm{Part}}=\mathbb{E}_{d_k,\pi_k}\left[\mathrm{sg}\left(\log\frac{\pi_\theta}{\pi_k}-\eta f+\log Z_f\right)\nabla_\theta\log\pi_\theta(a\mid s)\right]. \tag{2.15}$$

这说明 PMD-Part 是 anchor 测度下对完整 mirror log-ratio 的 L_2 投影，而不是把一个 teacher label 当作普通的 supervised token label。

PMD-Mean 来自同一个方程的条件中心化。对 $a\sim\pi_k(\cdot\mid s)$ 取均值并相减，得到

$$\left(\log\frac{\pi_\theta(a\mid s)}{\pi_k(a\mid s)}-\mathbb{E}_{v\sim\pi_k}\log\frac{\pi_\theta(v\mid s)}{\pi_k(v\mid s)}\right)=\eta\left(f(s,a)-\mathbb{E}_{v\sim\pi_k}[f(s,v)\mid s]\right).$$

其中

$$\mathbb{E}_{v\sim\pi_k}\log\frac{\pi_\theta(v\mid s)}{\pi_k(v\mid s)}=-\mathrm{KL}(\pi_k\|\pi_\theta),\qquad\mathbb{E}_{v\sim\pi_k}[f(s,v)\mid s]=\bar{f}_k(s). \tag{2.16}$$

因此 PMD-Mean 的显式损失是

$$\mathcal{L}_{\mathrm{Mean}}(\theta)=\frac{1}{2}\mathbb{E}_{d_k,\pi_k}\left[\log\frac{\pi_\theta(a\mid s)}{\pi_k(a\mid s)}+\mathrm{KL}(\pi_k\|\pi_\theta)-\eta\left(f(s,a)-\bar{f}_k(s)\right)\right]^2. \tag{2.17}$$

这个 KL 是对数比值在 anchor 测度下的均值恒等式，不是另加的正则项；它必须保留对 student 的导数，否则就失去归一化约束对应的 centered-score 项。

2.2.3 BPO：完整展开的中心化最优性残差

BPO对式(2.11) 的 residual 做条件中心化。定义

$$D_{k,n}(s,a):=\eta f(s,a)-\log\frac{\pi_{k,n}(a\mid s)}{\pi_k(a\mid s)} \tag{2.18}$$

$$-\mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\eta f(s,v)-\log\frac{\pi_{k,n}(v\mid s)}{\pi_k(v\mid s)}\right]. \tag{2.19}$$

将两个条件均值分别写成 KL，得到

$$\boxed{D_{k,n}(s,a)=\eta\left(f(s,a)-\bar{f}_k(s)\right)-\log\frac{\pi_{k,n}(a\mid s)}{\pi_k(a\mid s)}-C^\theta_{k,n}(s).} \tag{2.20}$$

因为

$$\mathbb{E}_{\pi_k}\log\frac{\pi_{k,n}}{\pi_k}=-\mathrm{KL}(\pi_k\|\pi_{k,n})=-C^\theta_{k,n},$$

式(2.20) 中最后一项的符号是负号。在 OPD $f=r_k=\log(\pi_T/\pi_k)$ 时，$\bar{f}_k=-C^T_k$，于是

$$D_{k,n}(s,a)=\eta\left[\log\frac{\pi_T(a\mid s)}{\pi_k(a\mid s)}+C^T_k(s)\right]-\left[\log\frac{\pi_{k,n}(a\mid s)}{\pi_k(a\mid s)}+C^\theta_{k,n}(s)\right]. \tag{2.21}$$

这就是后文使用的 BPO 权重，不再把它藏在 f_k 或 U_θ 中。

BPO 的平方损失为

$$\mathcal{L}_{\mathrm{BPO}}(\theta)=\frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[D_{k,n}(s,a)^2]. \tag{2.22}$$

对 student 求导时，$C^{\theta}_{k,n}$ 也要微分：

$$\nabla_\theta C^{\theta}_{k,n}(s) = -\mathbb{E}_{v\sim\pi_k}\left[\nabla_\theta \log \pi_{k,n}(v \mid s)\right], \tag{2.23}$$

$$\nabla_\theta D_{k,n}(s,a) = -\nabla_\theta \log \pi_{k,n}(a \mid s) + \mathbb{E}_{v\sim\pi_k}\left[\nabla_\theta \log \pi_{k,n}(v \mid s)\right]. \tag{2.24}$$

因此

$$-\eta\nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_k,\pi_k}\left[D_{k,n}(s,a)\left(\nabla_\theta \log \pi_{k,n}(a \mid s) - \mathbb{E}_{v\sim\pi_k}\nabla_\theta \log \pi_{k,n}(v \mid s)\right)\right]. \tag{2.25}$$

由于 $\mathbb{E}_{\pi_k}[D_{k,n} \mid s] = 0$，第二项在完整词表求和时严格为零；有限 sampled-token batch 中不能把 $\mathbb{E}_{\pi_k}[\nabla \log \pi_{k,n}]$ 直接当作零。

2.2.4 MDPO：直接最大化原始 mirror objective

MDPO 不把式(2.11) 改写成平方回归，而直接最大化

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \mathbb{E}_{s\sim d_k}\left[\mathbb{E}_{a\sim\pi_\theta(\cdot|s)} f(s,a) - \frac{1}{\eta}\,\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s))\right]. \tag{2.26}$$

逐历史地使用式(2.9)，有

$$\mathcal{J}_{\mathrm{MDPO}}(\theta \mid s) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\big(\pi_\theta(\cdot \mid s)\big\|\pi_k^{+}(\cdot \mid s)\big). \tag{2.27}$$

MDPO 的 KL 方向与 PMD/BPO 中的 $C^{\theta}_{k,n}$ 不同：这里是 $\mathrm{KL}(\pi_\theta\|\pi_k^{+})$，而中心化 log-ratio 的均值是 $\mathrm{KL}(\pi_k\|\pi_\theta)$。二者来自不同的积分测度，不能互换。

对式(2.26) 做 score-function 求导，得到

$$\nabla_\theta \mathcal{J}_{\mathrm{MDPO}} = \mathbb{E}_{d_k,a\sim\pi_\theta}\left[\mathrm{sg}\left(f(s,a) - \frac{1}{\eta}\log\frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right)\nabla_\theta \log \pi_\theta(a \mid s)\right]. \tag{2.28}$$

推导中的 $-1/\eta$ 常数项乘以 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$，所以最终式不需要引入额外的 ratio 记号。

命题 2.3 (平方回归的投影含义)

若 student 函数类不能表示式(2.11) 的右侧，PMD-Part 的精确 inner 解是镜像方程在函数类诱导的 $L_2(d_k\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 m，投影也相应变为 $L_2(m\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。

证明 平方损失是 Hilbert 空间中的正交投影问题。对任意可行扰动 v，最优残差 $\mathscr{E}^\star$ 满足

$$\mathbb{E}_{m,\pi_k}[\mathscr{E}^\star v] = 0.$$

这正是镜像方程右侧到可行函数集合的正交投影条件。若 target 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

2.3 四种 inner 的统一推导

下面固定一个历史，令

$$\ell_T(a) = \log \pi_T(a \mid s), \qquad \ell_k(a) = \log \pi_k(a \mid s), \qquad \ell_{k,n}(a) = \log \pi_{k,n}(a \mid s).$$

训练时只对 $\ell_{k,n}$ 反向传播；teacher、anchor、目标常数和已经解析到 policy-gradient 权重中的 KL 都停止梯度。

2.3.1 PMD-Part：回归完整 Gibbs log-ratio

PMD-Part 在 anchor 测度下最小化

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k,\,a\sim\pi_k}\left[\log\frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)} - \eta f(s,a) + \log Z_f(s)\right]^2. \tag{2.29}$$

对 target 停止梯度，链式法则给出

$$-\nabla_\theta \mathcal{L}_{\text{Part}} = \mathbb{E}_{d_k,\pi_k}\left[\eta f(s,a) - \log Z_f(s) - \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right] \nabla_\theta \log \pi_\theta(a \mid s). \tag{2.30}$$

这一步是普通的 log-ratio regression；它没有把 KL 视为常数，也没有使用 action-level importance ratio。

固定 history 后令 $q_{k,n}(a) = \Delta_{k,n}(s,a) - H_k(s,a)$。由于 anchor 测度与 target 都冻结，逐步求导得到

$$\nabla_\theta \mathcal{L}_{\text{Part}}(s) = \frac{1}{2}\nabla_\theta \sum_a \pi_k(a \mid s) q_{k,n}(a)^2 \tag{2.31}$$

$$= \sum_a \pi_k(a \mid s) q_{k,n}(a) \nabla_\theta \Delta_{k,n}(s,a) \tag{2.32}$$

$$= \mathbb{E}_{a\sim\pi_k}[q_{k,n}(a) \nabla_\theta \log \pi_{k,n}(a \mid s) \mid s]. \tag{2.33}$$

若实际 rollout 来自行为测度 β_k，而目标仍是 $L_2(\pi_k)$ 投影，则每个 sampled residual 乘以冻结权重 $\text{sg}(\pi_k(a \mid s)/\beta_k(a \mid s))$。不加这个权重时，算法仍然有清晰含义，但求解的是 $L_2(\beta_k)$ 投影。

Algorithm 1 PMD-Part inner update

Semantics: 固定 anchor 下的完整 Gibbs log-ratio 回归

Require: frozen π_k, teacher signal f, histories $\{s_i\}_{i=1}^B$, η, step size α
Ensure: updated parameters θ

```
for i = 1, ..., B do
    sample a_i ~ π_k(· | s_i)
    log Z_i ← logsumexp_{v∈V}(log π_k(v | s_i) + η f(s_i, v))
    H_i ← η f(s_i, a_i) − stopgrad(log Z_i)
    U_i ← log π_θ(a_i | s_i) − stopgrad(log π_k(a_i | s_i))
    ℓ_i ← ½ (U_i − stopgrad(H_i))^2
end for
θ ← θ − α ∇_θ (B^{-1} Σ_i ℓ_i)
return θ
```

2.3.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.34}$$

定理 2.2 (PMD-Mean 的逐历史 Lambert-W 投影)

在有限词表、$\pi_k(a \mid s) > 0$ 且约束可行时，上述中心化平方回归的唯一 KKT 解满足

$$U_a = G_a - W\big(\lambda(s)e^{G_a}\big), \qquad G_a = \eta\widetilde{f}_k(s,a), \tag{2.35}$$

其中 $\lambda(s) \geq 0$ 由 $\sum_a \pi_k(a \mid s)e^{U_a} = 1$ 唯一确定。 ♡

证明 以下给出固定历史 s 的 KKT 推导。令词表上的函数值为 U_a 和 $G_a = \eta\widetilde{f}_k(s,a)$，拉格朗日函数为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda\left(\sum_a \pi_k(a \mid s)e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda e^{G_a}$，所以

$$U_a = G_a - W\big(\lambda e^{G_a}\big), \tag{2.36}$$

其中 λ 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda) = \sum_a \pi_k(a \mid s) \exp\big(G_a - W(\lambda e^{G_a})\big)\,, qquad \lambda \geq 0.$$

Lambert–W 在非负轴上单调递增，因此每一项随 λ 单调递减；当 $\lambda = 0$ 时 $\Phi(0) = \sum_a \pi_k(a \mid s) e^{G_a}$，而 $\lambda \to \infty$ 时 $\Phi(\lambda) \to 0$。只要中心化 target 不已经满足 $\Phi(0) = 1$，方程 $\Phi(\lambda) = 1$ 有唯一正根；若 $\Phi(0) = 1$，则 $\lambda = 0$，得到 $U_a = G_a$。因此 PMD-Mean 是中心化 target 在指数归一化集合上的投影。严格凸性和 Φ 的严格单调性给出 KKT 解的唯一性。

约束 $\sum_a \pi_\theta(a \mid s) = 1$ 正是 log-ratio 坐标中的指数归一化条件。特别地，精确 Gibbs 解的 log-ratio 为

$$U_a^\star = \eta f(s,a) - \log Z_f(s), \qquad U_a^\star - \eta \widetilde{f}_k(s,a) = \eta \bar{f}_k(s) - \log Z_f(s),$$

它与 action 无关，且自动满足 $\sum_a \pi_k(a \mid s) e^{U_a^\star} = 1$；这说明 PMD-Mean 恢复的是同一个 Gibbs 分布，而不是把 $\log Z_f$ 任意设为零。

实际样本中需要分别估计 $\bar{U}_\theta(s)$ 和 $\bar{f}_k(s)$。为避免一个 action 同时出现在 residual 与 center 中，给定 $K \geq 2$ 个独立 anchor actions，使用 leave-one-out 均值

$$\widehat{\bar{U}}_{-j} = \frac{1}{K-1} \sum_{\ell \neq j} U_\theta(s, a_\ell), \qquad \widehat{\bar{f}}_{-j} = \frac{1}{K-1} \sum_{\ell \neq j} f(s, a_\ell).$$

若 $K = 1$，center 不可估计，应该退化为 PMD-Part 或使用上一批冻结的 center。center 中的 U_θ 必须保留梯度；把它整体 stop-gradient 会丢掉归一化约束对应的 centered-score 项。

Algorithm 2 PMD-Mean inner update

Semantics: 中心化 *target* 在指数归一化集合上的投影

Require: frozen π_k, signal f, histories $\{s_i\}$, $K \geq 2$, η, step size α
Ensure: updated parameters θ

for each history s_i **do**
  for $j = 1, \ldots, K$ **do**
    sample $a_{ij} \sim \pi_k(\cdot \mid s_i)$
    $U_{ij} \leftarrow \log \pi_\theta(a_{ij} \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_{ij} \mid s_i))$
    $F_{ij} \leftarrow f(s_i, a_{ij})$
  end for
  for $j = 1, \ldots, K$ **do**
    $\bar{U}_{-j} \leftarrow (K-1)^{-1} \sum_{\ell \neq j} U_{i\ell}$, $\bar{F}_{-j} \leftarrow (K-1)^{-1} \sum_{\ell \neq j} F_{i\ell}$
    $\ell_{ij} \leftarrow \frac{1}{2}[(U_{ij} - \bar{U}_{-j}) - \eta(F_{ij} - \bar{F}_{-j})]^2$
  end for
end for
$\theta \leftarrow \theta - \alpha \nabla_\theta (BK)^{-1} \sum_{i,j} \ell_{ij}$
return θ

2.3.3 BPO：中心化最优性 residual

BPO 不显式回归 $\log Z_f$，而将同一个最优性方程的 action-independent 部分消去。定义

$$D_{k,n}(s,a) = \eta f(s,a) - \Delta_{k,n}(s,a) - \mathbb{E}_{v \sim \pi_k}[\eta f(s,v) - \Delta_{k,n}(s,v) \mid s]. \tag{2.37}$$

直接展开可得

$$D_{k,n}(s,a) = \eta \widetilde{f}_k(s,a) - \Delta_{k,n}(s,a) + \mathbb{E}_{v \sim \pi_k}[\Delta_{k,n}(s,v) \mid s].$$

未线性化 BPO 的损失为

$$\mathcal{L}_{\mathrm{BPO}}(\theta) = \frac{1}{2\eta} \mathbb{E}_{d_k, \pi_k}[D_{k,n}(s,a)^2]. \tag{2.38}$$

由于

$$\nabla_\theta \mathbb{E}_{v \sim \pi_k}[\Delta_{k,n}(s,v)] = \mathbb{E}_{v \sim \pi_k}[\nabla_\theta \log \pi_{k,n}(v \mid s)],$$

所以

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_k,\pi_k}\left[D_{k,n}(s,a)\left(\nabla_\theta \log \pi_{k,n}(a \mid s) - \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_{k,n}(v \mid s) \mid s]\right)\right]. \tag{2.39}$$

BPO 的 score centering 来自对当前 student–anchor KL 的精确求导；它不是因为先对 reward 做了一个近似。

令 $G_{k,n}(s) = \mathbb{E}_{\pi_k}[\eta f(s,v) - \Delta_{k,n}(s,v) \mid s]$，则

$$\nabla_\theta D_{k,n}(s,a) = -\nabla_\theta \Delta_{k,n}(s,a) + \nabla_\theta \mathbb{E}_{\pi_k}[\Delta_{k,n}(s,v) \mid s] = -\nabla_\theta \log \pi_{k,n}(a \mid s) + \bar{g}_{k,n}(s).$$

所以 centered score 是对 center 本身求导的结果，而不是把 reward 任意减去 baseline。无偏的 Monte Carlo 实现最好为每个 history 使用独立的 action a_i 计算 residual，再使用独立集合 $\{b_{i\ell}\}$ 估计 $G_\theta(s_i)$；若复用样本，必须用 leave-one-out center。

Algorithm 3 BPO inner update

Semantics: 对中心化最优性 *residual* 求平方损失

Require: frozen π_k, signal f, histories $\{s_i\}$, center size K, η, step size α
Ensure: updated parameters θ

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$ and $b_{i1}, \dots, b_{iK} \sim \pi_k(\cdot \mid s_i)$ independently
  $z_i \leftarrow \eta f(s_i, a_i) - \log \pi_\theta(a_i \mid s_i) + \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i))$
  $\bar{z}_i \leftarrow K^{-1}\sum_{\ell=1}^{K}[\eta f(s_i, b_{i\ell}) - \log \pi_\theta(b_{i\ell} \mid s_i) + \mathrm{stopgrad}(\log \pi_k(b_{i\ell} \mid s_i))]$
  $d_i \leftarrow z_i - \bar{z}_i$, $\ell_i \leftarrow d_i^2/(2\eta)$
end for
$\theta \leftarrow \theta - \alpha\nabla_\theta B^{-1}\sum_i \ell_i$
return θ

若从行为测度 β 采样，z_i 和每个 center summand 都乘以冻结的 $\mathrm{sg}(\pi_k/\beta)$ 才对应 π_k 期望。该权重只改变积分测度，不能对它反向传播。

2.3.4 MDPO：直接优化 mirror objective

MDPO 直接最大化式(2.6) 的参数化版本：

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \frac{1}{\eta}\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.40}$$

完整词表时 KL 是

$$\mathrm{KL}(\pi_\theta\|\pi_k) = \sum_a \pi_\theta(a \mid s)\left[\log \pi_\theta(a \mid s) - \log \pi_k(a \mid s)\right]. \tag{2.41}$$

若 action 从 anchor 采样，则只需把 student 期望改写为显式的指数权重，不能把它另记成一个容易与 reward 混淆的 R_θ：

$$\widehat{\mathcal{J}}_{\mathrm{MDPO}} = \mathbb{E}_{a\sim\pi_k}\left[\exp\left(\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right)\left(f(s,a) - \frac{1}{\eta}\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right)\right]. \tag{2.42}$$

其 ascent direction 为

$$\nabla_\theta\mathcal{J}_{\mathrm{MDPO}} = \mathbb{E}_{\pi_k}\left[\exp\left(\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right)\left(f(s,a) - \frac{1}{\eta}\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right)\nabla_\theta \log \pi_\theta(a \mid s)\right]. \tag{2.43}$$

额外的 $-1/\eta$ 项乘以 score 后，在完整 action 求和中因 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$ 消失。MDPO 因而直接优化 mirror objective，其他三种方法优化的是由同一最优性方程构造的 regression objective。

MDPO 的自然梯度只改变更新几何，不改变上面的 token target。令 $g = \nabla_\theta\mathcal{J}_{\mathrm{MDPO}}$，并令

$$F_\theta = \mathbb{E}_{a\sim\pi_\theta}[g_\theta(a)g_\theta(a)^\top], \qquad g_\theta(a) = \nabla_\theta \log \pi_\theta(a \mid s).$$

若从 anchor 采样，用 $\mathrm{sg}(\exp(\log \pi_\theta - \log \pi_k))$ 进行测度校正。由于 categorical Fisher 的零空间是 logits 的常数方向，$F_\theta^\dagger g$ 位于 simplex 切空间；神经网络参数化下则需用阻尼逆 $(F + \lambda I)^{-1}$ 或 KL trust region，不能把自然步长与 mirror 温度 η 混用。

Algorithm 4 MDPO natural-gradient inner update
Semantics: 直接优化固定 history 的 mirror objective

Require: frozen π_k, signal f, histories $\{s_i\}$, η, natural step α
Ensure: updated parameters θ

for each history s_i **do**
  sample $a_i \sim \pi_k(\cdot \mid s_i)$
  $w_i \leftarrow \exp(\log \pi_\theta(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i)))$
  $j_i \leftarrow w_i \left[f(s_i, a_i) - \eta^{-1} \log w_i \right]$ ▷ 保留 w_i 对 student 的梯度
end for
$g \leftarrow \nabla_\theta (B^{-1} \sum_i j_i)$
$g_i^{\mathrm{score}} \leftarrow \nabla_\theta \log \pi_\theta(a_i \mid s_i)$
$F \leftarrow B^{-1} \sum_i \mathrm{stopgrad}(w_i) g_i^{\mathrm{score}} (g_i^{\mathrm{score}})^\top$
$\theta \leftarrow \theta + \alpha (F + \lambda I)^\dagger g$
return θ

定理 2.3 (四种 inner 的共同精确解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、PMD-Mean、未线性化 BPO 和 MDPO 都以式(2.8) 为精确解。PMD-Mean 的结论要求其投影 target 可实现；参数化 student 或有限样本时，四者得到的是不同的投影或优化误差。

证明 PMD-Part 在零损失处满足 $U_\theta = \eta f - \log Z_f$，于是得到式(2.8)。BPO 的零 residual 只确定 $U_\theta = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_\theta}] = 1$ 得 $C(s) = \log Z_f(s)$。PMD-Mean 若中心化 target 属于归一化约束集合，则其平方投影残差为零，并由中心化不变性得到同一策略。MDPO 由式(2.9) 直接得到唯一最大点。

命题 2.4 (未线性化 BPO 与 PMD-Part 的梯度差异)

固定一个历史 s，令

$$q(s,a) = \eta f(s,a) - \log Z_f(s) - U_\theta(s,a), \qquad c(s) = \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] - \eta \mathbb{E}_{\pi_k}[f(s,\cdot) \mid s]. \tag{2.44}$$

则未线性化 BPO residual 满足 $D_\theta = q + c$，并且

$$-\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = -\nabla_\theta \mathcal{L}_{\mathrm{Part}} + c(s)\, \mathbb{E}_{a \sim \pi_k}[\nabla_\theta \log \pi_\theta(a \mid s) \mid s]. \tag{2.45}$$

因此两者在精确镜像解处都有零梯度，但在一般参数点不相同。它们只有在 $c(s)\, \mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$ 时才给出相同的方向。

证明 从 PMD-Part 的最优性残差出发，先把 BPO 的中心化式逐项展开：

$$\begin{aligned} D_\theta(s,a) &= \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{\pi_k}[\eta f(s,\cdot) - U_\theta(s,\cdot) \mid s] \\ &= \eta f(s,a) - \log Z_f(s) - U_\theta(s,a) + \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] \\ &= q(s,a) + c(s). \end{aligned}$$

由定义，$\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$。BPO 的精确梯度为

$$-\eta \nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{\pi_k}\left[D_\theta \left(g_\theta - \bar{g}_\theta \right) \mid s \right], \qquad g_\theta(a) = \nabla_\theta \log \pi_\theta(a \mid s), \qquad \bar{g}_\theta = \mathbb{E}_{\pi_k}[g_\theta \mid s].$$

代入 $D_\theta = q + c$，并使用 $\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$，可得

$$\begin{aligned} \mathbb{E}_{\pi_k}[D_\theta (g_\theta - \bar{g}_\theta) \mid s] &= \mathbb{E}_{\pi_k}[(q+c) g_\theta \mid s] - \mathbb{E}_{\pi_k}[D_\theta \mid s] \bar{g}_\theta \\ &= \mathbb{E}_{\pi_k}[q g_\theta \mid s] + c(s) \bar{g}_\theta. \end{aligned}$$

而 PMD-Part 的梯度式为 $-\nabla_\theta \mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{\pi_k}[q g_\theta \mid s]$，故式(2.45) 成立。若 $q = 0$，则由归一化约束有 $c = 0$，两边同时为零；离开该点时 c 通常非零，差异项保留。

这个命题说明“都在 token level”只保证它们面对同一个局部镜像根，不保证优化轨迹相同。PMD-Part 回归

完整的 action-dependent log-ratio，并把 $\log Z_f$ 当作固定 target；BPO 先消去 action-independent 常数，再对当前 student 的归一化项求导，因此多出 centered score。若使用的参数化使 $\mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$（例如采样测度与当前 student 一致，或在特定 tabular 点上），差异项才会消失。

2.4 OPD 特化：逐 token reward 与两种信息访问模式

在 OPD 中，第 k 个 outer step 先固定 anchor π_k，然后从它产生 rollout。对 prefix $s_t = (x, y_{<t})$ 和实际 sampled token $a_t = y_t$，最直接的局部 teacher reward 是

$$r_k(s_t, a_t) = \log \pi_T(a_t \mid s_t) - \log \pi_k(a_t \mid s_t). \tag{2.46}$$

它满足序列分解

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \log \pi_T(y \mid x) - \log \pi_k(y \mid x).$$

因此在共同 mirror 子问题中应取 $f = r_k$；不能把整条序列的 log-ratio 当作每一个 prefix 的同一个 reward，否则会重复计算后缀差异。

可以对 reward 做两种不同的“归一化”，必须区分它们的理论作用。对任意只依赖 prefix 的 baseline $b_k(s)$，令

$$f_k^{\mathrm{ctr}}(s, a) = r_k(s, a) - b_k(s). \tag{2.47}$$

它只把 partition function 乘上 $e^{-\eta b_k(s)}$，所以 Gibbs policy 不变；取 $b_k(s) = \mathbb{E}_{\pi_k}[r_k(s, \cdot) \mid s]$ 就是条件中心化。若再除以尺度 $\sigma_k(s) > 0$，则

$$f_k^{\mathrm{std}} = (r_k - b_k)/\sigma_k$$

会把有效温度从 η 改成 η/σ_k，不再是同一个 mirror step，除非同时把正则参数改为 $\eta\sigma_k$。因此 OPD 的默认实现只做 additive centering；标准化只能作为明确的 temperature schedule。

2.4.1 完整 vocabulary logits：精确 token mirror target

如果 teacher 和 anchor 都能在 prefix s 返回完整词表 logits，则对每个 $v \in \mathcal{V}$ 计算

$$r_k(s, v) = \log \pi_T(v \mid s) - \log \pi_k(v \mid s), \qquad \log Z_k(s) = \mathrm{logsumexp}_{v \in \mathcal{V}}\big((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\big).$$

于是 exact target 为

$$\pi_k^+(v \mid s) = \exp\big((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) - \log Z_k(s)\big).$$

这时 PMD-Part 的 target、MDPO 的 reverse KL、以及 BPO/PMD-Mean 所需的 anchor conditional center 都可以在同一个 prefix 上精确计算。完整词表路径不需要 action-level importance sampling；唯一的随机性来自 prefix batch 和 optimizer。

在写算法之前先把四个 inner 的计算量化简。对一个固定 prefix，teacher、anchor 和当前 student 的信息都直接写成 token log-probability。PMD 的归一化常数是

$$\log Z_k(s) = \log\left(\sum_{v \in \mathcal{V}} \exp\left((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s)\right)\right). \tag{2.48}$$

因此 exact mirror target 为

$$\pi_k^+(v \mid s) = \exp\left((1-\eta)\log \pi_k(v \mid s) + \eta \log \pi_T(v \mid s) - \log Z_k(s)\right).$$

为了写出 PMD-Mean 和 BPO 的中心化形式，先把两个均值写成 KL 散度。定义

$$C_k^T(s) := \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s)), \tag{2.49}$$

$$C_{k,n}^\theta(s) := \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_{k,n}(\cdot \mid s)). \tag{2.50}$$

在 outer–inner 记号 $\theta_{k,n}$ 中，k 是 outer step 编号，n 是该 outer step 内的 inner optimizer step 编号。因此 $C_{k,n}^\theta(s)$ 简

写 $\mathrm{KL}(\pi_k(\cdot \mid s)\|\pi_{k,n}(\cdot \mid s))$：左侧分布 π_k 在整个 inner loop 固定，右侧 student 随 n 改变，故每次 inner 更新后都要用新参数重算这个量。相反，$C_k^T(s)$ 在固定 outer step 内不随 n 改变。于是

$$\mathbb{E}_{v\sim\pi_k}\left[\log\frac{\pi_T(v \mid s)}{\pi_k(v \mid s)}\right] = -C_k^T(s), \tag{2.51}$$

$$\mathbb{E}_{v\sim\pi_k}\left[\log\frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)}\right] = -C_{k,n}^{\theta}(s). \tag{2.52}$$

后续可以对这两个 KL 分别采用 full vocabulary、top-K 或 sampled-token 估计，但不能混淆它们与 MDPO 中 $\mathrm{KL}(\pi_\theta\|\pi_k)$ 的方向。于是四个 loss 可直接化为

$$\mathcal{L}_{\mathrm{Part}}(s) = \frac{1}{2}\mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\log\frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)} - \eta\log\frac{\pi_T(v \mid s)}{\pi_k(v \mid s)} + \log Z_k(s)\right]^2, \tag{2.53}$$

$$\mathcal{L}_{\mathrm{Mean}}(s) = \frac{1}{2}\mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\left(\log\frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)} + C_{k,n}^{\theta}(s)\right)\right. \tag{2.54}$$

$$\left. - \eta\left(\log\frac{\pi_T(v \mid s)}{\pi_k(v \mid s)} + C_k^T(s)\right)\right]^2, \tag{2.55}$$

$$D_{k,n}(s,v) = \eta\left(\log\frac{\pi_T(v \mid s)}{\pi_k(v \mid s)} + C_k^T(s)\right) \tag{2.56}$$

$$- \left(\log\frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)} + C_{k,n}^{\theta}(s)\right), \tag{2.57}$$

$$\mathcal{L}_{\mathrm{BPO}}(s) = \frac{1}{2\eta}\mathbb{E}_{v\sim\pi_k(\cdot|s)}[D_{k,n}(s,v)^2], \tag{2.58}$$

$$\mathcal{J}_{\mathrm{MDPO}}(s) = \mathbb{E}_{v\sim\pi_{k,n}(\cdot|s)}\left[\log\frac{\pi_T(v \mid s)}{\pi_k(v \mid s)} - \frac{1}{\eta}\log\frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)}\right]. \tag{2.59}$$

由于 $\mathbb{E}_{v\sim\pi_k(\cdot|s)}[D_{k,n}(s,v)] = 0$，BPO 的完整词表梯度进一步化为

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[D_{k,n}(s,v)\nabla_\theta\log\pi_{k,n}(v \mid s)\right]. \tag{2.60}$$

因此完整 vocabulary 路径无需显式计算 centered score 的第二项；它在精确求和中严格抵消。

对应的梯度与 stop-gradient 约定

为便于对照前面的推导，下面这一组梯度公式中的旧记号统一解释为

$$\pi_\theta = \pi_{k,n}, \qquad T = \pi_T, qquad\mathcal{K}_k^T = C_k^T, \qquad \mathcal{K}_{k,n}^{\theta} = C_{k,n}^{\theta}, \qquad D_\theta = D_{k,n}.$$

这些只是同一 outer–inner 状态的记号映射；k 和 n 的冻结关系不变。后续新公式优先写成 $\Delta_{k,n}$、C_k^T、$C_{k,n}^{\theta}$ 和 $D_{k,n}$，从而明确区分不同 KL 方向。下面把式 (2.53)–(2.59) 写成可直接实现的 policy-gradient 形式。固定 outer step k 时，π_k、π_T、$\log Z_k$ 和 $\mathcal{K}_k^T$ 都不依赖当前参数 θ，实现中应使用 stopgrad。相反，$\mathcal{K}_k^{\theta}$ 必须保留对 $\log\pi_\theta$ 的梯度。完整词表下

$$\mathcal{K}_k^{\theta}(s) = \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\mathrm{stopgrad}(\log\pi_k(v \mid s)) - \log\pi_\theta(v \mid s)\right], \tag{2.61}$$

$$\nabla_\theta\mathcal{K}_k^{\theta}(s) = -\mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\nabla_\theta\log\pi_\theta(v \mid s)\right]. \tag{2.62}$$

在下面的 policy-gradient 实现中，A_{Part}、A_{Mean}、D_θ 以及 MDPO 的 log-ratio 权重都必须整体使用 stopgrad。这不是说它们在原始平方损失或原始 MDPO objective 中没有参数依赖，而是这些依赖已经在前面的解析求导中处理过；直接实现 policy-gradient 时若不停止梯度，就会重复求导并产生错误的二阶项。

对 PMD-Part，残差对 θ 的导数就是 $\nabla_\theta\log\pi_\theta(v \mid s)$，故

$$\nabla_\theta\mathcal{L}_{\mathrm{Part}}(s) = \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\mathrm{stopgrad}(A_{\mathrm{Part}}(s,v))\,\nabla_\theta\log\pi_\theta(v \mid s)\right], \tag{2.63}$$

$$A_{\mathrm{Part}}(s,v) = \log\frac{\pi_\theta(v \mid s)}{\pi_k(v \mid s)} - \eta\log\frac{T(v \mid s)}{\pi_k(v \mid s)} + \mathrm{stopgrad}(\log Z_k(s)). \tag{2.64}$$

因此其梯度下降方向是一个以 π_k 为测度、以 $-A_{\mathrm{Part}}$ 为权重的 score-function 更新。

对 PMD-Mean，令 $A_{\mathrm{Mean}}(s,v)$ 表示式 (2.55) 中方括号内的量。由式 (2.61)，

$$\nabla_\theta A_{\mathrm{Mean}}(s,v) = \nabla_\theta \log \pi_\theta(v \mid s) - \mathbb{E}_{u\sim\pi_k(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(u \mid s)\right]. \tag{2.65}$$

于是

$$\nabla_\theta \mathcal{L}_{\mathrm{Mean}}(s) = \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[A_{\mathrm{Mean}}(s,v)\left(\nabla_\theta \log \pi_\theta(v \mid s) - \mathbb{E}_{u\sim\pi_k(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(u \mid s)\right]\right)\right] \tag{2.66}$$

$$= \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\mathrm{stopgrad}(A_{\mathrm{Mean}}(s,v))\,\nabla_\theta \log \pi_\theta(v \mid s)\right], \tag{2.67}$$

其中第二个等号使用了 $\mathbb{E}_{v\sim\pi_k}[A_{\mathrm{Mean}}(s,v)] = 0$。这一步只有在 $\mathcal{K}_k^\theta$ 保留梯度时才成立。

因为 $D_\theta = -A_{\mathrm{Mean}}$，BPO 的梯度为

$$\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = -\frac{1}{\eta}\mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[D_\theta(s,v)\left(\nabla_\theta \log \pi_\theta(v \mid s) - \mathbb{E}_{u\sim\pi_k(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(u \mid s)\right]\right)\right], \tag{2.68}$$

$$-\eta\nabla_\theta \mathcal{L}_{\mathrm{BPO}}(s) = \mathbb{E}_{v\sim\pi_k(\cdot|s)}\left[\mathrm{stopgrad}(D_\theta(s,v))\,\nabla_\theta \log \pi_\theta(v \mid s)\right]. \tag{2.69}$$

这就是前面删除第二项后的严格 policy-gradient 形式；被删除的项是 $\mathbb{E}_{u\sim\pi_k}[D_\theta(s,u)]\mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s)] = 0$，而不是把后一个 score 期望本身当成零。

最后考虑 MDPO。记

$$r_k(s,v) = \log \frac{\pi_T(v \mid s)}{\pi_k(v \mid s)}, \qquad \Delta_{k,n}(s,v) = \log \frac{\pi_{k,n}(v \mid s)}{\pi_k(v \mid s)}.$$

对式 (2.59) 求导时，既要微分外层测度 π_θ，也要微分 U_θ：

$$\nabla_\theta \mathcal{J}_{\mathrm{MDPO}}(s) = \mathbb{E}_{v\sim\pi_{k,n}(\cdot|s)}\left[\left(r_k(s,v) - \frac{1}{\eta}\Delta_{k,n}(s,v) - \frac{1}{\eta}\right)\nabla_\theta \log \pi_{k,n}(v \mid s)\right] \tag{2.70}$$

$$= \mathbb{E}_{v\sim\pi_{k,n}(\cdot|s)}\left[\mathrm{stopgrad}\left(r_k(s,v) - \frac{1}{\eta}\Delta_{k,n}(s,v)\right)\nabla_\theta \log \pi_{k,n}(v \mid s)\right], \tag{2.71}$$

因为 $\mathbb{E}_{v\sim\pi_\theta}[\nabla_\theta \log \pi_\theta(v \mid s)] = 0$。因此 MDPO 是以当前 student π_θ 为采样测度的 policy gradient，而 BPO/PMD-Mean 是以冻结 anchor π_k 为测度、通过 centered residual 形成的 policy gradient。

若 sampled-token 路径估计 $\mathcal{K}_k^\theta$，从 $a \sim \pi_k$ 采样时可以使用

$$\widehat{\mathcal{K}}_k^\theta(s,a) = \frac{\pi_k(a \mid s)}{\mathrm{stopgrad}(\pi_k(a \mid s))}\left[\mathrm{stopgrad}(\log \pi_k(a \mid s)) - \log \pi_\theta(a \mid s)\right]. \tag{2.72}$$

它在数值上是 $\log \pi_k(a \mid s) - \log \pi_\theta(a \mid s)$，但保留了 $-\nabla_\theta \log \pi_\theta(a \mid s)$。若把整个 $\widehat{\mathcal{K}}_k^\theta$ 错误地 stop-gradient，PMD-Mean 和 BPO 都会退化成未中心化的梯度，且不再对应式 (2.65)。

2.4.2 有限词表与 sampled-token：KL 与 partition 估计

2602.04417的 Top-K 方法直接估计 KL：在 top-K 头部计算精确项，在尾部用采样项校正。它不直接给出本节的 $\log Z_k$，因为

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k(\cdot|s)}\left[\left(\frac{T(a \mid s)}{\pi_k(a \mid s)}\right)^\eta\right]. \tag{2.73}$$

这一区别很重要：$\widehat{Z}_k$ 可以无偏，但 $\log \widehat{Z}_k$ 不能无偏。

在固定 prefix s 上，从冻结 anchor 采样 $a_j \sim \pi_k(\cdot \mid s)$，令 $r_k(s,a) = \log T(a \mid s) - \log \pi_k(a \mid s)$。则两个中心满足

$$\mathcal{K}_k^T(s) = \mathbb{E}_{a\sim\pi_k}[-r_k(s,a)], \tag{2.74}$$

$$\mathcal{K}_{k,n}^\theta(s) = \mathbb{E}_{a\sim\pi_k}\left[\log \pi_k(a \mid s) - \log \pi_{\theta_{k,n}}(a \mid s)\right]. \tag{2.75}$$

因此 m 个独立 next-token 样本的均值分别是两个 KL 的无偏估计。真实 rollout 中每个 prefix 通常只有一个后继 token；该 token 是无偏单点样本，但不是 conditional KL 的精确值。若要降低方差，可以在已经算出 anchor logits 后额外抽取 $m-1$ 个 token，这只增加 categorical 抽样和 log-prob 记录，无需生成额外长序列。不同 prefix 的 token

不能互相当作同一条件分布的样本。

其中 $\mathcal{K}_k^T$ 在整个 outer step 内固定，teacher/anchor log-prob 可以缓存；$\mathcal{K}_{k,n}^\theta$ 必须在每个 inner step 重新计算。实现已经推导好的 policy-gradient 时，KL 中心作为权重整体使用 stop-gradient；实现原始 Mean/BPO 平方损失时则必须保留其对 student 的导数。

对 $\mathcal{K}_{k,n}^\theta = \mathrm{KL}(\pi_k \| \pi_{\theta_{k,n}})$，取 $S_k(s) = \mathrm{TopK}(\pi_k(\cdot \mid s))$，可构造

$$\widehat{\mathcal{K}}_{k,n}^\theta(s) = \sum_{v \in S_k(s)} \pi_k(v \mid s) \log \frac{\pi_k(v \mid s)}{\pi_{\theta_{k,n}}(v \mid s)} \tag{2.76}$$

$$+ \frac{1}{m} \sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_k(s)\} \log \frac{\pi_k(a_j \mid s)}{\pi_{\theta_{k,n}}(a_j \mid s)}, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.77}$$

对固定 S_k，尾部项是精确尾部求和的无偏 Monte Carlo 估计，且其 autograd 梯度的期望等于真实 KL 梯度。这里的“梯度无偏”是指把该估计量直接放进原始 KL 损失并对 student 反向传播时的性质；本章的最终实现采用已经解析化的 policy-gradient 形式，KL 估计值只作为数值权重，必须整体 stopgrad，因此不需要再对这个估计量执行 autograd。$K = 0$ 是纯 sampled-token，$K = |\mathcal{V}|$ 是 exact KL；这两个端点是同一个 top-K 族的插值端点，不单独构成一个算法分支。给定头部后，条件方差为

$$\mathrm{Var}(\widehat{\mathcal{K}}_{k,n}^\theta \mid S_k) = \frac{1}{m} \mathrm{Var}_{a \sim \pi_k} \left[\mathbf{1}\{a \notin S_k\} \log \frac{\pi_k(a \mid s)}{\pi_{\theta_{k,n}}(a \mid s)} \right]. \tag{2.78}$$

增大 K 通常降低尾部质量和方差，但实际大小取决于尾部 log-ratio 的二阶矩。对 $\mathcal{K}_k^T$ 可使用同样的头尾分解；由于它不需要反向传播，anchor 样本均值往往已经足够。

为了把 2602.04417 中“截断偏差换取采样方差”的结论直接用于 OPD，下面给出一个与 KL、score 加权梯度和 partition function 都兼容的统一形式。固定 prefix s，令 $p(v)$ 为 rollout 测度（本章中通常是 $p = \pi_k(\cdot \mid s)$），$h(v)$ 为待求期望的 integrand，定义

$$Q = \mathbb{E}_{v \sim p}[h(v)], \qquad Q_K^{\mathrm{head}} = \sum_{v \in S_K} p(v) h(v), \qquad \tau_K = \mathbb{E}_{v \sim p}[\mathbf{1}\{v \notin S_K\} h(v)], \tag{2.79}$$

其中 S_K 是固定的 top-K 集合。用 m 个独立的 auxiliary token $a_1, \ldots, a_m \sim p$ 做尾部校正时，定义

$$\widehat{Q}_{K,m} = Q_K^{\mathrm{head}} + \frac{1}{m} \sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_K\} h(a_j). \tag{2.80}$$

定理 2.4 (Top-K 截断与尾部校正的偏差–方差分解)

在 $\mathbb{E}_p[h^2] < \infty$ 且 S_K 与 auxiliary samples 独立时，纯头部估计 $\widehat{Q}_K^{\mathrm{tr}} = Q_K^{\mathrm{head}}$ 与尾部校正估计 $\widehat{Q}_{K,m}$ 分别满足

$$\mathrm{Bias}(\widehat{Q}_K^{\mathrm{tr}}) = -\tau_K, \qquad \mathrm{Var}(\widehat{Q}_K^{\mathrm{tr}}) = 0, \qquad \mathrm{MSE}(\widehat{Q}_K^{\mathrm{tr}}) = \tau_K^2, \tag{2.81}$$

$$\mathrm{Bias}(\widehat{Q}_{K,m}) = 0, \qquad \mathrm{Var}(\widehat{Q}_{K,m}) = \frac{V_K}{m}, \qquad \mathrm{MSE}(\widehat{Q}_{K,m}) = \frac{V_K}{m}, \tag{2.82}$$

其中

$$V_K = \mathbb{E}_p\left[\mathbf{1}\{v \notin S_K\} h(v)^2\right] - \tau_K^2. \tag{2.83}$$

如果 $S_K \subseteq S_{K+1}$，则尾部二阶矩 $A_K = \mathbb{E}_p[\mathbf{1}\{v \notin S_K\} h(v)^2]$ 单调不增，且 $V_K \le A_K$。尾部均值 τ_K 在 $h \ge 0$ 时单调不增；对符号不定的 h，它本身不必单调，但有

$$|\tau_K| \le \sqrt{p(S_K^c) A_K}. \tag{2.84}$$

♡

证明 记 $X_j = \mathbf{1}\{a_j \notin S_K\} h(a_j)$。由 $a_j \sim p$，有 $\mathbb{E}[X_j] = \tau_K$，且 $\mathrm{Var}(X_j) = V_K$。因此

$$\mathbb{E}[\widehat{Q}_{K,m}] = Q_K^{\mathrm{head}} + \tau_K = Q, \qquad \mathrm{Var}(\widehat{Q}_{K,m}) = \mathrm{Var}\left(\frac{1}{m} \sum_{j=1}^{m} X_j\right) = \frac{V_K}{m}, \tag{2.85}$$

其中最后一步使用了独立性。纯头部估计没有随机项，且 $Q_K^{\mathrm{head}} - Q = -\tau_K$，从而得到前三个等式。若集合嵌

套，$\mathbf{1}\{v \notin S_{K+1}\} \le \mathbf{1}\{v \notin S_K\}$，故对非负 h^2 有 $A_{K+1} \le A_K$。当 $h \ge 0$ 时，尾部指示函数逐点下降，所以 $0 \le \tau_{K+1} \le \tau_K$。一般情形下对尾部随机变量应用 Cauchy–Schwarz 不等式即可得到式 (2.84)。

定理 2.4 有两个直接含义。对 $h_{\mathrm{KL}}(v) = \log \frac{\pi_k(v|s)}{\pi_\theta(v|s)}$ 或 $h_T(v) = \log \frac{\pi_k(v|s)}{T(v|s)}$，$h$ 可能正也可能负，因此不能声称“增大 K 必然单调减小截断 bias”；能够保证的是尾部二阶矩和上界下降。对 $h_Z(v) = \exp(\eta r_k(s,v)) \ge 0$，尾部均值本身单调下降，所以纯截断的 Z_k 估计具有严格的单侧负偏差，而且随 K 减小。这正是 2602.04417 中 truncated KL 与 tail-corrected Top-K KL 的数学区别。

如果最终对象是 score 加权的 policy gradient，令 $g_\theta(v) = \nabla_\theta \log \pi_\theta(v \mid s)$，把 $h(v)$ 换成向量 $h(v)g_\theta(v)$，定理逐坐标成立，并得到

$$\mathrm{Bias}(\widehat{G}_K^{\mathrm{tr}}) = -\mathbb{E}_p[\mathbf{1}\{v \notin S_K\}h(v)g_\theta(v)], \qquad \mathrm{Cov}(\widehat{G}_{K,m}) = \frac{1}{m}\mathrm{Cov}_p(\mathbf{1}\{v \notin S_K\}h(v)g_\theta(v)). \tag{2.86}$$

这描述的是“估计最终梯度权重”的误差，而不是对 detached 估计量求导。本章 Algorithm 5 采用后者：先解析得到 score-function 公式，再把 $\widehat{h}$ 整体 stop-gradient。因此实现不需要保存估计量的 autograd 图；只需控制式 (2.86) 中的数值 bias 和 variance。

对 Z_k，头尾分解应先估计 Z_k 再取对数。令 $S_Z(s)$ 为 $((1-\eta)\log \pi_k + \eta \log T)$ 的 top-K 索引，则

$$\widehat{Z}_k(s) = \sum_{v \in S_Z(s)} \pi_k(v \mid s)^{1-\eta} T(v \mid s)^\eta \tag{2.87}$$

$$+ \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{a_j \notin S_Z(s)\}\left(\frac{T(a_j \mid s)}{\pi_k(a_j \mid s)}\right)^\eta, \qquad a_j \sim \pi_k(\cdot \mid s). \tag{2.88}$$

式 (2.88) 对 Z_k 无偏，但 Jensen 不等式给出

$$\mathbb{E}[\log \widehat{Z}_k] \le \log Z_k, \qquad \mathbb{E}[\log \widehat{Z}_k] - \log Z_k \approx -\frac{\mathrm{Var}(\widehat{Z}_k)}{2Z_k^2}. \tag{2.89}$$

尾部重要性比率具有长尾时，单 token plug-in 估计尤其不稳定；裁剪比率可降方差，但会引入额外偏差。$\eta = 1$ 时 $Z_k = 1$，所以 $\log Z_k = 0$ 精确已知；$\eta = 0$ 时同样如此。$0 < \eta < 1$ 时，若不需要 PMD-Part，PMD-Mean/BPO 可以绕开这项 log-of-mean 偏差。

定理 2.5 (Partition function 的 log-of-mean 偏差)

设 $\widehat{Z}_{K,m}$ 是式 (2.88) 的尾部校正估计，$\mathbb{E}[\widehat{Z}_{K,m}] = Z_k > 0$，且尾部三阶绝对矩有限。记 $V_K = \mathrm{Var}(\mathbf{1}\{a \notin S_Z\}(T(a \mid s)/\pi_k(a \mid s))^\eta)$。当 m 足够大时，

$$\mathbb{E}[\log \widehat{Z}_{K,m}] - \log Z_k = -\frac{V_K}{2mZ_k^2} + O(m^{-3/2}), \tag{2.90}$$

$$\mathrm{Var}(\log \widehat{Z}_{K,m}) = \frac{V_K}{mZ_k^2} + O(m^{-3/2}). \tag{2.91}$$

若改用纯头部估计 $Z_K^{\mathrm{tr}} = \sum_{v \in S_Z} \pi_k(v)^{1-\eta} T(v)^\eta$，则

$$Z_K^{\mathrm{tr}} - Z_k = -\tau_K^Z \le 0, \qquad \log Z_K^{\mathrm{tr}} - \log Z_k \le 0, \tag{2.92}$$

其中 $\tau_K^Z \ge 0$ 是式 (2.79) 对 h_Z 的尾部均值。因而纯截断的 log-partition bias 是确定性的单侧偏差，而尾部校正的 plug-in log 估计是由方差诱导的负偏差。

证明 令 $\Delta = \widehat{Z}_{K,m} - Z_k$。由无偏性，$\mathbb{E}[\Delta] = 0$，且 $\mathbb{E}[\Delta^2] = V_K/m$。在 Z_k 邻域对 $f(z) = \log z$ 作三阶 Taylor 展开：

$$\log(Z_k + \Delta) = \log Z_k + \frac{\Delta}{Z_k} - \frac{\Delta^2}{2Z_k^2} + R_3, \tag{2.93}$$

其中在三阶矩有界时 $\mathbb{E}|R_3| = O(m^{-3/2})$。取期望并使用 $\mathbb{E}[\Delta] = 0$ 得到第一式。对同一展开取方差，首阶随机项为 Δ/Z_k，故 $\mathrm{Var}(\log \widehat{Z}_{K,m}) = V_K/(mZ_k^2) + O(m^{-3/2})$。最后，$h_Z \ge 0$ 给出 $\tau_K^Z \ge 0$，所以 $Z_K^{\mathrm{tr}} \le Z_k$；由于 log 单调递增，第二个不等式随之成立。

定理 2.5 说明了为什么不能把“无偏的 $\widehat{Z}_k$”直接等同于“无偏的 $\log Z_k$”。在 PMD-Part 中，若使用 plug-in 估计，$\log Z_k$ 的误差会进入每个 token 的 residual；在完整词表路径上 score 均值可精确消去该常数项，在 sampled-token

路径上只能依赖有限样本近似消去。因此 PMD-Part 对 m、K 和尾部比率的要求严格于 PMD-Mean/BPO。当 m 个样本独立且把同一 prefix 的梯度平均时，partition 诱导的梯度方差按 $1/m$ 下降；当外层有 B 个相互独立 prefix 时，条件于 prefix 的这部分方差进一步按 $1/B$ 下降，但 prefix coverage 误差不随 m 消失。

$\log Z_k$ 的展开估计：从 Z_k 的 plug-in 走向可控偏差

直接计算 $\log \widehat{Z}_k$ 是最简单的方案，但它把非线性的 log 放在 Monte Carlo 均值之后，必然产生 Jensen bias。对于 OPD，Z_k 具有更特殊的结构：

$$Z_k(s) = \mathbb{E}_{a\sim\pi_k}\left[e^{\eta r_k(s,a)}\right], \qquad r_k(s,a) = \log T(a \mid s) - \log \pi_k(a \mid s). \tag{2.94}$$

因此 $\log Z_k$ 是随机变量 r_k 的 cumulant-generating function 在 η 处的值。令 $\kappa_j(r_k)$ 为 r_k 的第 j 阶 cumulant，则在矩母函数存在的邻域内

$$\log Z_k(s) = \sum_{j=1}^{\infty} \frac{\eta^j}{j!}\kappa_j(r_k). \tag{2.95}$$

前两项为

$$\log Z_k(s) = \eta\,\mathbb{E}[r_k] + \frac{\eta^2}{2}\operatorname{Var}(r_k) + R_3(s), \tag{2.96}$$

其中 R_3 收集三阶及以上 cumulant。因为 $\mathbb{E}[r_k] = -\mathcal{K}_k^T$，二阶近似也可以写成

$$\log Z_k(s) \approx -\eta C_k^T(s) + \frac{\eta^2}{2}\operatorname{Var}_{a\sim\pi_k}[r_k(s,a)]. \tag{2.97}$$

这给出了比 $-\eta\widehat{\mathcal{K}}_k^T$ 更准确的近似：只使用均值会遗漏 log-sum-exp 的二阶曲率项，而该项在 teacher 与 anchor 差异较大时不可忽略。

若从同一个 prefix 取得 m 个 auxiliary token，令 $\widehat{\kappa}_j$ 为对应的 unbiased j 阶 k-statistic，并定义

$$\widehat{L}_{J,m}(s) = \sum_{j=1}^{J} \frac{\eta^j}{j!}\widehat{\kappa}_j(r_k). \tag{2.98}$$

则

定理 2.6 (Cumulant 截断估计器的 bias 与方差)

若 $\mathbb{E}|r_k|^{J+1} < \infty$ 且 cumulant series 在 η 处收敛，则

$$\mathbb{E}[\widehat{L}_{J,m}] - \log Z_k = -\sum_{j=J+1}^{\infty} \frac{\eta^j}{j!}\kappa_j(r_k), \qquad \operatorname{Var}(\widehat{L}_{J,m}) = O(m^{-1}). \tag{2.99}$$

若 $|\eta r_k| \le c$ 几乎处处成立，则截断 bias 满足

$$\left|\mathbb{E}[\widehat{L}_{J,m}] - \log Z_k\right| \le \frac{e^c|\eta|^{J+1}}{(J+1)!}\mathbb{E}\left[|r_k|^{J+1}\right]. \tag{2.100}$$

♡

证明 由 k-statistic 的无偏性，$\mathbb{E}[\widehat{\kappa}_j] = \kappa_j$。将其代入式 (2.95) 的前 J 项，第一式立即成立。有限阶样本 cumulant 是有限个样本乘积的 U-statistic 线性组合；在相应矩存在时，其方差为 $O(m^{-1})$，不同阶之间的协方差也为 $O(m^{-1})$，所以 $\operatorname{Var}(\widehat{L}_{J,m}) = O(m^{-1})$。最后，对 $e^{\eta r_k}$ 的 cumulant-generating function 在零点作 Taylor 展开，Taylor 余项的绝对值由 $e^c|\eta r_k|^{J+1}/(J+1)!$ 控制，取期望即得偏差上界。

对 OPD 的常用二阶实现，$J = 2$ 时可以直接使用样本均值和无偏样本方差：

$$\widehat{L}_{2,m}(s) = \eta\bar{r}_k(s) + \frac{\eta^2}{2}\widehat{\operatorname{Var}}(r_k(s,\cdot)). \tag{2.101}$$

它不再具有 log-of-mean 的 $O(m^{-1})$ Jensen bias；剩余 bias 是明确的 cumulant truncation bias。代价是需要估计方差，并且当 $\eta|r_k|$ 较大时，三阶及以上 cumulant 不能忽略。因此它适合 teacher/anchor 接近、r_k 集中的阶段，不适合重要性比率重尾的阶段。

Top-K 头部还可以进一步降低展开的尾部误差。令

$$Z_H = \sum_{v \in S_Z} \pi_k(v)^{1-\eta} T(v)^{\eta}, \qquad u(a) = \mathbf{1}\{a \notin S_Z\} \left(\frac{T(a)}{\pi_k(a)}\right)^{\eta}, \qquad \tau = \mathbb{E}_{\pi_k}[u(a)], \tag{2.102}$$

则 $Z_k = Z_H + \tau$。当 $\rho = \tau / Z_H < 1$ 时，

$$\log Z_k = \log Z_H + \sum_{\ell=1}^{\infty} \frac{(-1)^{\ell+1}}{\ell} \rho^{\ell}. \tag{2.103}$$

用 m 个尾部样本构造

$$\widehat{\tau^{\ell}} = \binom{m}{\ell}^{-1} \sum_{1 \le i_1 < \cdots < i_\ell \le m} \prod_{q=1}^{\ell} u(a_{i_q}), \qquad a_i \overset{\text{iid}}{\sim} \pi_k, \tag{2.104}$$

这是 τ^{ℓ} 的无偏 U-statistic。于是可定义

$$\widehat{L}_{K,J}(s) = \log Z_H + \sum_{\ell=1}^{J} \frac{(-1)^{\ell+1}}{\ell Z_H^{\ell}} \widehat{\tau^{\ell}}. \tag{2.105}$$

它的期望等于式 (2.103) 的前 J 项，且截断余项满足

$$\left| \mathbb{E}[\widehat{L}_{K,J}] - \log Z_k \right| \le \frac{\rho^{J+1}}{(J+1)(1-\rho)}. \tag{2.106}$$

这个估计器在 K 增大时更有意义：Z_H 增大、ρ 减小，二阶或三阶展开就能达到很小的确定性 truncation bias；$K = 0$ 时 $Z_H = 0$，应退回 cumulant 展开或直接使用正值的 $\log \widehat{Z}$ plug-in。实际实现中建议先用 $J = 2$，同时记录 $\widehat{\rho}$、plug-in 与展开估计的差异，用它判断是否进入重尾区域。

2602.04417 的合成图可以作为本节偏差–方差实验的模板。论文固定 $|\mathcal{V}| = 32000$，令 reference logits 为 $\mathcal{N}(0, I)$，当前策略 logits 为 $s\mathcal{N}(0, I)$，通过调整 s 使 $\sum_{j \in \mathrm{TopK}(\pi, 32)} \pi(j)$ 接近 $\{0.2, 0.5, 0.8, 0.9\}$。对 $K \in \{4, 8, 16, 32, 64, 128, 256\}$ 和 $B \in \{1, 2, 4, \ldots, 32768\}$，分别计算 sampled、纯截断和 tail-corrected Top-K 的 token-logit 真梯度与估计梯度，并绘制

$$\mathrm{RelRMSE} = \frac{\sqrt{\mathbb{E}\|\widehat{g} - g_{\mathrm{true}}\|_2^2}}{\|g_{\mathrm{true}}\|_2}. \tag{2.107}$$

交点就是论文所谓 critical sample size。官方仓库 https://github.com/LunjunZhang/ema-pg 公开了 `compute_memory_effici` K3^{++}/K4/K5 和 GPU top-K benchmark，但没有公开生成 `simulated_topk_kl_four_masses_v5.pdf` 的脚本；因此我们可以按上述协议在本项目中重建一份，并把 OPD 的 $\log Z_k$ plug-in、二阶 cumulant 和 Top-K 尾部展开作为额外曲线。图中应同时报告 value bias、gradient RelRMSE、尾部命中率和峰值显存，不能只画 KL 数值方差。

偏差–方差定理：从 KL 数值到最终 policy gradient

对一个 prefix 的任意估计器 $\widehat{q}$，最终关心的是带 score 的量 $\widehat{g} = \widehat{q} \nabla_\theta \log \pi_\theta$。其均方误差分解为

$$\mathbb{E}\|\widehat{g} - g\|^2 = \|\mathbb{E}[\widehat{g}] - g\|^2 + \operatorname{tr} \operatorname{Cov}(\widehat{g}). \tag{2.108}$$

因此，单独比较 $\widehat{\mathcal{K}}$ 的数值方差并不足够：一个有轻微截断偏差但尾部方差极低的估计器，可能比无偏但重尾的 sampled estimator 产生更小的梯度 MSE。2602.04417 的 Top-K 结论正是这个取舍：加入尾部校正保持无偏，代价是尾部采样方差；只保留头部则引入可控的截断偏差。

对 OPD 的 PMD-Part，$\log Z_k$ 的误差直接进入 residual，而 residual 又乘以 score。若使用 $\widehat{c}_k = \log \widehat{Z}_k$，令 $\delta_Z = \widehat{c}_k - \log Z_k$，则单 prefix 的梯度误差包含

$$\Delta g_Z = \delta_Z \, \mathbb{E}_{v \sim \pi_k} [\nabla_\theta \log \pi_\theta(v \mid s)] \tag{2.109}$$

以及 δ_Z 与 sampled score 的协方差项。完整词表下 score 均值可以被精确求和，前一项严格为零；sampled-token 下它只是在期望上为零，有限 batch 会把 $\log Z_k$ 的标量误差放大成随机梯度噪声。故 PMD-Part 对 partition 估计的要求比 BPO/PMD-Mean 更严格。

对同一 prefix 同时估计中心和 policy-gradient 权重时，还要考虑协方差：若 $\widehat{c}$ 与 score 使用同一枚 token，$\mathbb{E}[\widehat{c}\widehat{g}]$ 一般不等于 $\mathbb{E}[\widehat{c}]\mathbb{E}[\widehat{g}]$。采用独立的 auxiliary next-token 样本估计中心，或使用 leave-one-out center，可以消除这类

自耦合偏差；代价是额外的 token 抽样和少量 log-prob 存储。跨 prefix 聚合只能降低总体均值方差，不能把不同条件分布下的样本变成同一 conditional center。

最后，prefix 覆盖误差与 token 估计误差应分开记录。即使 token-level estimator 在给定 s 上无偏，rollout 只访问由 π_k 诱导的有限 prefix 多重集，仍有 $\widehat{d}_k - d_k$ 的 outer 测度误差。增加 Top-K 或 auxiliary samples 只降低条件 token 方差，不能修复 prefix coverage；增加 rollout 数量或重新采样 outer batch 才能降低这一项。实验日志应至少分别保存：prefix 数量与重复率、KL/partition 的 batch 均值和方差、尾部采样次数、梯度范数与峰值显存。

缓存上，CPU/NVMe 只需保存 token IDs、mask、response mask、anchor/teacher 的 action log-prob 和可选的 top-K 摘要；student log-prob 每个 inner step 重算。保存完整 logits 的代价是 $O(BH|\mathcal{V}|)$，保存 top-K 摘要是 $O(BHK)$。以 $|\mathcal{V}| = 150{,}000$、FP16 为例，一个 prefix-token 的完整 logits 约 300 kB，8192 token 单序列约 2.46 GB；因此不能把全词表 logits 放进 replay buffer。GPU 只保留当前 microbatch 的 student 激活和当前 token 块 logits，并在块处理后释放。当前 OPD 最稳妥的首版路径是缓存 anchor/ teacher action log-prob，用额外 anchor next-token 样本估计两个 KL 中心；PMD-Part 只在 $\eta = 1$ 或已验证 $\log Z_k$ 误差足够小时启用，再用 top-K 实验比较中心方差、$\log Z_k$ 偏差和峰值显存。

Algorithm 5 OPD full-vocabulary outer–inner optimization

Semantics: 每个 outer step 用 π_k rollout，固定 anchor 做 N 个 inner policy-gradient step，再同步得到 π_{k+1}

Require: prompt distribution $\mathcal{D}$, teacher π_T, initial student $\pi_0 = \pi_{\theta_{0,0}}$, outer steps K, rollout batch size B, horizon H, method M, η, inner steps N, inner learning rate schedule $\{\alpha_{k,n}\}$, sync mode $\mathrm{Sync} \in \{\mathrm{hard}, \mathrm{soft}\}$, soft-sync weight $\rho \in (0, 1]$

Ensure: final policy π_K and parameters θ_K

for $k = 0, \dots, K-1$ **do**
  $\mathcal{B}_k \leftarrow \varnothing$ ▷ $\mathcal{B}_k$ is a multiset; repeated prefixes keep their multiplicity
  for $i = 1, \dots, B$ **do**
    sample prompt $x_i \sim \mathcal{D}$
    generate $y_i = (a_{i,1}, \dots, a_{i,\tau_i})$ with $a_{i,t} \sim \pi_k(\cdot \mid s_{i,t})$, $s_{i,t} = (x_i, a_{i,<t})$
    $\mathcal{B}_k \leftarrow \mathcal{B}_k \uplus \{s_{i,t} : 1 \le t \le \tau_i \wedge H\}$
  end for
  define $\widehat{d}_k$ as the empirical distribution assigning each occurrence in $\mathcal{B}_k$ equal mass
  $\theta_{k,0} \leftarrow \theta_k$ ▷ initialize the inner student from the current outer policy
  for $n = 0, \dots, N-1$ **do**
    query $\log \pi_T(v \mid s)$, $\log \pi_k(v \mid s)$ and $\log \pi_{k,n}(v \mid s)$ for every occurrence $s \in \mathcal{B}_k$ and $v \in \mathcal{V}$
    $\log Z_k(s) \leftarrow \log \left(\sum_{v \in \mathcal{V}} \exp\left((1-\eta) \log \pi_k(v \mid s) + \eta \log T(v \mid s) \right) \right)$
    $C_k^T(s) \leftarrow \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_T(\cdot \mid s))$
    $C_{k,n}^\theta(s) \leftarrow \mathrm{KL}(\pi_k(\cdot \mid s) \| \pi_{k,n}(\cdot \mid s))$
    if $M = \mathrm{Part}$ **then**
      $G_{k,n} \leftarrow \mathbb{E}_{s \sim \widehat{d}_k} \mathbb{E}_{v \sim \pi_k} \left[\mathrm{stopgrad}\left(\log \frac{\pi_{k,n}}{\pi_k} - \eta \log \frac{\pi_T}{\pi_k} + \log Z_k \right) \nabla_{\theta_{k,n}} \log \pi_{k,n} \right]$
    else if $M = \mathrm{Mean}$ **then**
      $G_{k,n} \leftarrow \mathbb{E}_{s \sim \widehat{d}_k} \mathbb{E}_{v \sim \pi_k} \left[\mathrm{stopgrad}\left(\log \frac{\pi_{k,n}}{\pi_k} + C_{k,n}^\theta - \eta \left(\log \frac{\pi_T}{\pi_k} + C_k^T \right) \right) \nabla_{\theta_{k,n}} \log \pi_{k,n} \right]$
    else if $M = \mathrm{BPO}$ **then**
      $G_{k,n} \leftarrow -\eta^{-1} \mathbb{E}_{s \sim \widehat{d}_k} \mathbb{E}_{v \sim \pi_k} \left[\mathrm{stopgrad}\left(\eta \left(\log \frac{\pi_T}{\pi_k} + C_k^T \right) - \left(\log \frac{\pi_{k,n}}{\pi_k} + C_{k,n}^\theta \right) \right) \nabla_{\theta_{k,n}} \log \pi_{k,n} \right]$
    else if $M = \mathrm{MDPO}$ **then**
      $G_{k,n} \leftarrow -\mathbb{E}_{s \sim \widehat{d}_k} \mathbb{E}_{v \sim \pi_{k,n}} \left[\mathrm{stopgrad}\left(\log \frac{\pi_T}{\pi_k} - \eta^{-1} \log \frac{\pi_{k,n}}{\pi_k} \right) \nabla_{\theta_{k,n}} \log \pi_{k,n} \right]$
    end if
    $\theta_{k,n+1} \leftarrow \mathrm{OptimizerStep}(\theta_{k,n}, G_{k,n}; \alpha_{k,n})$ ▷ expectations are implemented by exact sums or MC averages
  end for
  if $\mathrm{Sync} = \mathrm{hard}$ **then**
    $\theta_{k+1} \leftarrow \theta_{k,N}$ and $\pi_{k+1} \leftarrow \pi_{\theta_{k+1}}$
  else
    $\pi_{k+1}(\cdot \mid s) \leftarrow (1-\rho)\pi_k(\cdot \mid s) + \rho \pi_{\theta_{k,N}}(\cdot \mid s)$ for every prefix s
    choose θ_{k+1} to represent π_{k+1} ▷ in parameter-EMA implementations, set $\theta_{k+1} = (1-\rho)\theta_k + \rho\theta_{k,N}$
  end if
end for
return (π_K, θ_K)

算法中的同步发生在整个 inner loop 结束之后。因而在固定 k 的所有 N 次更新中，rollout 测度、anchor ratio π_k/T 以及所有 mirror target 都保持不变；只有 student 参数 $\theta_{k,n}$ 变化。hard sync 令下一轮 anchor 完全等于 inner 末端 student，soft sync 则令下一轮 anchor 是旧 anchor 与 inner 末端 student 的凸组合。完成同步后丢弃 $\widehat{d}_k$，使用新的 π_{k+1} 重新 rollout，而不是继续复用旧 rollout。若 inner loop 没有收敛，$\pi_{\theta_{k,N}}$ 只是当前固定 mirror 子问题的有限步近似解；outer 动力学仍由上述同步映射严格定义。

只有 sampled next token：无完整词表时的估计路径

如果每个 prefix 只有 rollout 中的下一个 token $a \sim \pi_k(\cdot \mid s)$，仍然可以无偏观测 $r_k(s,a)$，但不能从一个样本无偏得到 $\log Z_k(s)$：先估计 Z_k 再取对数会产生 plug-in bias。因此 sampled-token 路径不应把 PMD-Part 的 exact $\log Z_k$ 假装已知。可行选择如下。

第一，使用 BPO 或 PMD-Mean，以同一个 prefix 的多条 sampled actions 估计 conditional center；它们不需要显式的 $\log Z_k$。第二，使用 MDPO 的 action-sampled objective，并用 K4/K3^{++} 估计 KL 项；这要求保留 student/anchor 的 sampled log-prob。第三，如果只有一条 action，却仍想做 PMD-Part，只能使用外部 baseline、跨 batch center 或 self-normalized $\widehat{\log Z}$，并在理论和日志中标记其 bias。

对单个 sampled token，PMD-Part 的可实现 loss 是带 baseline 的近似

$$\widehat{\ell}_{\mathrm{Part}} = \frac{1}{2}\big[\eta(r_k(s,a) - b(s)) - U_\theta(s,a)\big]^2,$$

它只有在 $b(s) = \log Z_k(s)/\eta$ 时才等于 exact residual；任意其他 baseline 会留下一个 prefix-dependent constant，因而改变 PMD-Part 的有限参数投影。BPO 的中心化 residual 则可用同 prefix 的 K 个 sampled tokens 构造，$K = 1$ 时必须使用跨样本或 frozen center。

Algorithm 6 OPD sampled-token inner update
Semantics: 每个 prefix 只访问 rollout 的下一个 token

Require: frozen anchor π_k, teacher T, rollout pairs (s_i, a_i), method M, center size K, η
Ensure: updated student parameters θ

for each prefix s_i **do**
  read $\log T(a_i \mid s_i)$ and $\log \pi_k(a_i \mid s_i)$
  $r_i \leftarrow \log T(a_i \mid s_i) - \log \pi_k(a_i \mid s_i)$
  if $M = \mathrm{BPO}$ or $M = \mathrm{Mean}$ **then**
    obtain K actions from independent same-prefix rollouts, or use a frozen cross-batch center
    compute leave-one-out center of r and U_θ; keep the center's student gradient
    update with the corresponding centered residual loss
  else if $M = \mathrm{MDPO}$ **then**
    form $R_i = \exp(\log \pi_\theta(a_i \mid s_i) - \mathrm{stopgrad}(\log \pi_k(a_i \mid s_i)))$
    use $R_i r_i - \eta^{-1}\widehat{\mathrm{KL}}_i$ with K4/K3^{++} and retain correct autograd paths
  else if $M = \mathrm{Part}$ **then**
    estimate or load a prefix baseline $\widehat{\log Z_i}$; record its bias source
    update $\frac{1}{2}[\eta r_i - \widehat{\log Z_i} - U_\theta(s_i, a_i)]^2$
  end if
end for
update θ while keeping π_k and T frozen
return θ

完整 vocabulary 与 sampled-token 两条路径的区别是信息论上的：前者能精确知道整个 categorical mirror target，后者只能无偏知道在 anchor 下抽到的一个 action 的 reward。两者在无限 samples、无函数类误差且 center/partition 估计一致时收敛到同一个 token fixed point；有限 batch 下，full-vocabulary 的主要误差是参数优化和 prefix coverage，sampled-token 额外承担 reward、center、KL ratio 和 prefix reuse 的估计方差。

第三章 KL 估计量、无偏性与方差

3.1 K4 的无偏性

固定 history，记 $p = \pi_\theta(\cdot \mid s)$、$q = \mu_k(\cdot \mid s)$，并从 p 采样 a。定义

$$w(a) = \frac{q(a)}{p(a)}, \qquad r_\theta(a) = \frac{p(a)}{\mathrm{stopgrad}(p(a))}.$$

数值上 $r_\theta = 1$，但其导数为 $\nabla \log p(a)$。

定理 3.1 (K4 value and gradient)

若 $p \ll q$ 且二阶矩有限，则

$$\mathbb{E}_{a\sim p}[r_\theta(a)(-\log w(a))] = \mathrm{KL}(p\|q),$$

并且自动微分意义下

$$\mathbb{E}_{a\sim p}[\nabla_\theta\{r_\theta(a)(-\log w(a))\}] = \nabla_\theta \mathrm{KL}(p\|q).$$

♡

证明 数值 value 中 $r_\theta = 1$，所以第一式是

$$\mathbb{E}_p[-\log(q/p)] = \sum_a p(a)\log(p(a)/q(a)).$$

对 stop-gradient 构造求导时，$-\log w = \log p - \log q$ 的 derivative 与 r_θ 的 derivative 共同给出

$$\nabla_\theta\{r_\theta(-\log w)\} = \nabla_\theta \log p(a)\,[\log p(a) - \log q(a)] + \nabla_\theta \log p(a).$$

最后一项在 p 下期望为零，第一项正是 KL 的 score-function derivative。 □

K1 的数值也无偏，但其 autograd gradient 为零；K3 的 gradient 对应 $\mathrm{KL}(q\|p)$ 的方向；K2 梯度正确但 value 有偏。因此 BPO 的 KL 项应优先使用 K4、K3^{++} 或完整 vocabulary 计算。

3.2 固定 anchor 测度上的重要性校正

若工程上必须从 $q = \mu_k$ 采样，令 $\rho_\theta(a) = p(a)/q(a)$，并在积分权重上停止梯度。对于任意可积向量 h，

$$\mathbb{E}_q[\mathrm{stopgrad}(\rho_\theta)h(a)] = \mathbb{E}_p[h(a)].$$

因此 BPO 的固定测度估计量为

$$\widehat{g}_i = \mathrm{stopgrad}(\rho_i)\left[r_i - \frac{1}{\eta}\widehat{k}_{4,i}\right] g_i, \qquad a_i \sim q.$$

在 p/q 的二阶矩有限时，它无偏；其单样本方差满足

$$\mathbb{E}_q\|\widehat{g}_i\|^2 \le C^2\mathbb{E}_q[\rho_\theta^2] = C^2\big(1 + \chi^2(p\|q)\big), \tag{3.1}$$

其中 C 上界 reward、K4 项和 score 的乘积。故 inner 走远以后，固定 anchor 的估计方差由 $\chi^2(p\|q)$ 控制；这正是必须记录 current-anchor divergence 的原因。

3.3 Top-K 与完整词表的关系

如果保存当前策略和 anchor 的 top-K logits，完整 reverse KL 可以拆成

$$\sum_{a\in Q_K} p(a)\log\frac{p(a)}{q(a)} + \sum_{a\notin Q_K} p(a)\log\frac{p(a)}{q(a)}.$$

第一项可精确计算；第二项不能被简单删除，否则得到截断 KL 而非完整 KL。2602.04417 的 Top-K 估计量在尾部使用 masked sampled K4：若采样 token 不在 Q_K，加入

$$\mathbf{1}(a \notin Q_K)\ \mathrm{stopgrad}\left(\frac{p(a)}{\pi_{\mathrm{sampling}}(a)}\right) r_\theta(a)(-\log w(a)).$$

它同时保持 value 和 gradient 无偏。对本项目而言，第一版小实验不使用 top-K reward，而先验证 full-vocabulary oracle 和 sampled K4 两条路径；否则无法判断误差来自 mirror target 还是 tail estimator。

3.4 有限 inner 更新的误差

设 exact token target 为 p_k^+，inner 算法在固定 s 上得到 $p_{k,m}$。定义 total variation error

$$e_{k,m}(s) = \frac{1}{2}\|p_{k,m}(\cdot \mid s) - p_k^+(\cdot \mid s)\|_1.$$

若 loss gradient 是 L-smooth，且使用 unbiased gradient with variance at most σ^2/B，标准 projected SGD 给出

$$\frac{1}{M}\sum_{m=0}^{M-1} \mathbb{E}\|\nabla \mathcal{L}(\theta_m)\|^2 \le \frac{2(\mathcal{L}_0 - \mathcal{L}_*)}{\alpha M} + \frac{L\alpha\sigma^2}{B}.$$

如果使用固定 anchor 而 current policy 逐渐远离它，则 σ^2 需要替换为含 $1 + \chi^2(p_{k,m}\|\mu_k)$ 的上界。因而 inner 做得越久，不一定越接近 exact target：优化误差下降的同时，off-policy estimator variance 会上升。

第四章 Outer 同步与有限 inner 的动力学

4.1 Hard sync 的精确动力学

先考虑每个 history 的 teacher 分布 T 不随 outer 改变，并且 inner 精确收敛到式 (1.3)。hard sync 定义为

$$\mu_k = \pi_k, \qquad \pi_{k+1} = \frac{\pi_k^{1-\eta} T^{\eta}}{Z_k}.$$

定理 4.1 (Hard-sync geometric interpolation)

若 $0 < \eta \le 1$ 且初始策略与 T 互相绝对连续，则

$$\pi_k(a \mid s) = \frac{\pi_0(a \mid s)^{(1-\eta)^k} T(a \mid s)^{1-(1-\eta)^k}}{\sum_b \pi_0(b \mid s)^{(1-\eta)^k} T(b \mid s)^{1-(1-\eta)^k}}. \tag{4.1}$$

并且

$$\log \frac{\pi_k(a \mid s)}{T(a \mid s)} = (1-\eta)^k \log \frac{\pi_0(a \mid s)}{T(a \mid s)} - \log C_k(s),$$

其中 $C_k(s)$ 是归一化常数。$\eta = 1$ 时一个 exact inner 将策略直接变成 teacher；$0 < \eta < 1$ 时每一轮只消除比例 η 的 log-density mismatch。

♡

证明 归纳证明。$k = 0$ 显然成立。假设式 (4.1) 成立，则

$$\pi_{k+1} \propto \pi_k^{1-\eta} T^{\eta} \propto \pi_0^{(1-\eta)^{k+1}} T^{(1-\eta)(1-(1-\eta)^k)+\eta}.$$

指数合并为 $1-(1-\eta)^{k+1}$，归一化后得到结论。 □

推论 4.1 (Outer contraction)

在任意固定 s 上，unnormalized log-ratio 的 contraction factor 是 $1-\eta$。若 log-ratio 初始振幅不超过 B，则归一化后 total variation 满足

$$\mathrm{TV}(\pi_k, T) \le \frac{1}{2}\left(e^{2B(1-\eta)^k} - 1\right).$$

该界说明小 η 不是免费加稳定性：它把每轮变化缩小，同时把达到相同 teacher proximity 所需的 outer steps 增加到 $O(\eta^{-1}\log(1/\varepsilon))$。

♡

4.2 有限 inner 与 stale target

实际第 k 轮只运行 M_k 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi^{+}_{k+1}(a \mid s)}\right| \le \varepsilon_k$$

在归一化前成立。则归一化后

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi^{+}_{k+1}) \le \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.2}$$

令 $d_k = \mathrm{TV}(\pi_k, T)$，由 triangle inequality 和 hard-sync contraction 得

$$d_{k+1} \le (1-\eta) d_k + \delta_k, \qquad \delta_k = \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.3}$$

因此

$$d_K \le (1-\eta)^K d_0 + \sum_{j=0}^{K-1} (1-\eta)^{K-1-j} \delta_j.$$

有限 inner 误差不会被简单地“下一轮 rollout”消失；它会以几何权重累积。若 $\delta_j \le \bar{\delta}$，稳态误差上界为 $\bar{\delta}/\eta$。

4.3 Soft sync 的耦合动力学

若 anchor 使用 EMA，令

$$\mu_{k+1} = \lambda\mu_k + (1-\lambda)\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \mu_k^{1-\eta} T^{\eta}.$$

忽略归一化扰动并在线性 log-density 坐标中写 $z_k = \log \mu_k - \log T$，得到近似递推

$$z_{k+1} \approx [\lambda + (1-\lambda)(1-\eta)]z_k = [1-(1-\lambda)\eta]z_k.$$

所以 EMA 同时把 outer contraction 从 $1-\eta$ 改成 $1-(1-\lambda)\eta$。当 λ 接近 1，anchor 漂移非常慢，训练稳定但 teacher tracking 速度下降；这不是 inner 学习率的效果，而是 outer target 的真实动力学。

4.4 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 ρ_k 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，ρ_{k+1} 改变，必须额外记录 coverage drift：

$$\Delta_k = \mathrm{TV}(\rho_{k+1}, \rho_k).$$

若 token loss 在所有 history 上有上界 C，则访问测度改变给目标梯度带来至多 $2C\Delta_k$ 的偏差。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

第五章 可枚举 Token 实验与实现边界

5.1 实验设置

实验脚本位于 `experiments/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\mu = (0.62, 0.23, 0.10, 0.05), \qquad T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略开始，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。这样可以单独检查 token-level inner 的数学对象。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整 categorical objective；MDPO 使用 exact categorical Fisher preconditioner。

5.2 结果

表 5.1 报告 400 个 inner updates 后与 exact target 的 total variation 距离和 KL。BPO、MDPO 达到机器精度；PMD-Part、PMD-Mean 使用固定 learning rate，因此保留小的优化误差，降低 learning rate 或继续更新后继续下降。

表 5.1: 固定测度 token inner 的可枚举实验。

η	方法	$\mathrm{TV}(p, p^+)$	$\mathrm{KL}(p\|p^+)$
0.25	PMD-Part	1.11e-3	6.79e-6
0.25	PMD-Mean	1.25e-3	8.30e-6
0.25	BPO	2.16×10^{-15}	-5.35×10^{-17}
0.25	MDPO	1.11×10^{-16}	9.34×10^{-17}
0.50	PMD-Part	2.65e-3	2.54e-5
0.50	PMD-Mean	4.71e-3	6.85e-5
0.50	BPO	9.54×10^{-13}	5.44×10^{-17}
0.50	MDPO	1.25×10^{-16}	3.14×10^{-17}
0.80	PMD-Part	2.97e-3	2.65e-5
0.80	PMD-Mean	1.12e-2	2.73e-4
0.80	BPO	4.15×10^{-7}	7.20×10^{-13}
0.80	MDPO	1.80×10^{-16}	-7.73×10^{-17}

实验验证了三个实现结论。第一，四个方法的 exact fixed point 相同；差别在于 residual、policy-gradient estimator 和 Fisher geometry。第二，BPO 必须把 KL 作为带正确梯度的项；K4 可以在不保存完整词表时实现这一点。第三，η 改变的是 mirror target 的位置：η 越大，target 越接近 teacher；它不能代替 inner optimizer learning rate。

5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
2. 对随机 p, q，用大量样本检查 K4 value 与 exact $\mathrm{KL}(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
3. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
4. 检查固定 anchor 采样的 importance correction 在 p/q 接近一时无偏；
5. 人为增加 inner steps，确认 current-anchor χ^2 和估计方差同时上升；
6. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `uv run --with torch python experiments/toy_tok` 生成，结果保存在 `experiments/toy_token_inner.csv`。独立的 `experiments/test_kl_estimators.py` 使用

200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 5.6×10^{-5}，gradient 的 ell_2 误差为 1.5×10^{-3}。

参考资料

本文 KL 估计量的记号与 K3^{++}、K4、K5、Top-k 估计量来自科研`/pmd-theory/2602.04417_zh_CN/example_paper.tex`；One-Shot-OPD 的实现审计见科研`/pmd-theory/MirrorOPD/source_audit/One-Shot-OPD/`。