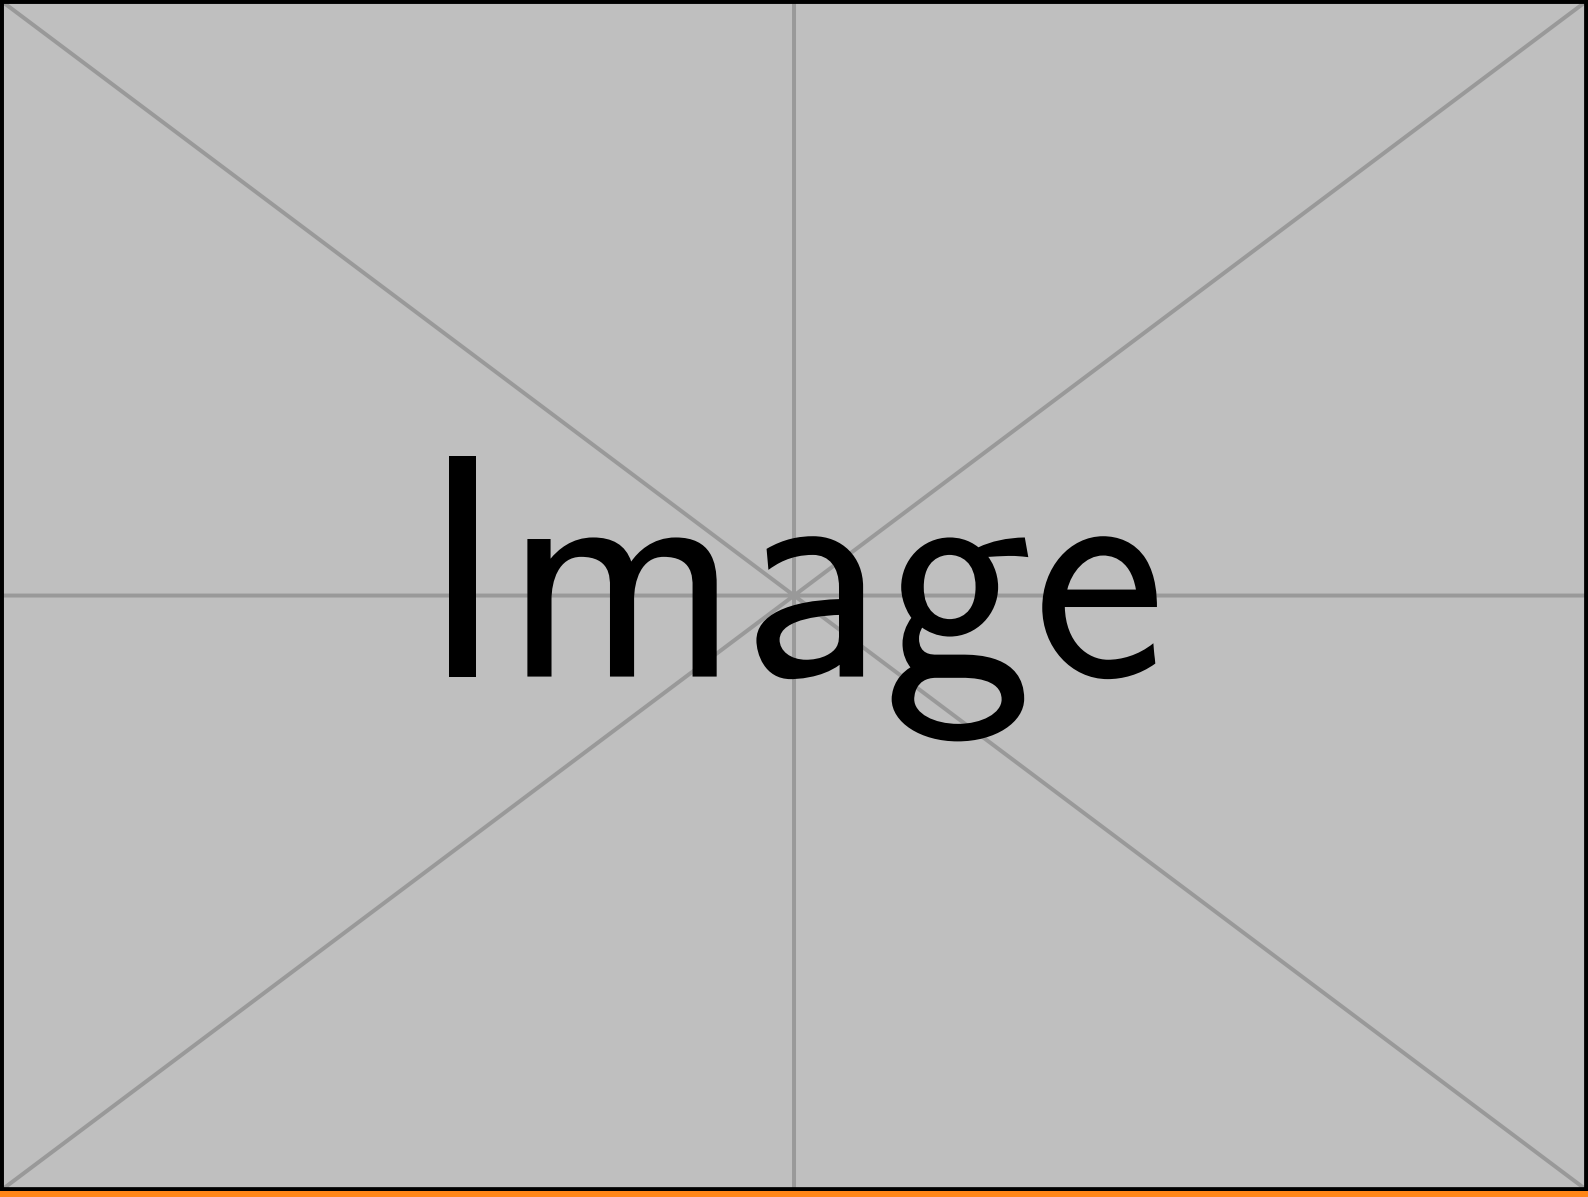


固定测度下的 Token 级 MirrorOPD

作者：MirrorOPD Research Notes

时间：2026 年 10 月 8 日

目录

第一章 固定测度的 Token 级优化问题 **1**

1.1 外层同步与内层对象 1

1.2 共同闭式解 1

1.3 固定测度下的三个等价表述 2

1.4 参数化策略的投影 2

第二章 四种 Token-level Inner 算法 **3**

2.1 PMD-Part：完整 partition 的残差回归 3

2.2 PMD-Mean：anchor 测度下的中心化 3

2.3 BPO：固定测度上的 KL 正则化梯度 3

2.4 MDPO：Fisher 几何下的同一子问题 4

第三章 KL 估计量、无偏性与方差 **5**

3.1 K4 的无偏性 5

3.2 固定 anchor 测度上的重要性校正 5

3.3 Top-K 与完整词表的关系 5

3.4 有限 inner 更新的误差 6

第四章 Outer 同步与有限 inner 的动力学 **7**

4.1 Hard sync 的精确动力学 7

4.2 有限 inner 与 stale target 7

4.3 Soft sync 的耦合动力学 8

4.4 访问测度固定的含义 8

第五章 可枚举 Token 实验与实现边界 **9**

5.1 实验设置 9

5.2 结果 9

5.3 正式 LLM 实验前必须通过的检查 9

第一章 固定测度的 Token 级优化问题

1.1 外层同步与内层对象

第 k 个 outer step 开始时，学生策略、anchor 和教师分别记为

$$\pi_k(\cdot \mid s), \qquad \mu_k(\cdot \mid s), \qquad T(\cdot \mid s).$$

hard sync 时 $\mu_k = \pi_k$；soft sync 时 μ_k 是学生参数的 EMA。一个 token history $s = (x, y_{<t})$ 在本章内被冻结。外层采样只负责产生一批 history；inner 不再改变该批 history 的访问测度，也不重新计算教师目标。

定义教师相对 anchor 的 token reward

$$r_k(s,a) = \log T(a \mid s) - \log \mu_k(a \mid s).$$

我们研究的 inner 子问题是

$$\max_{p \in \Delta(\mathcal{V})} \mathcal{J}_{k,s}(p) = \mathbb{E}_{a\sim p}[r_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p\|\mu_k), \qquad \eta > 0. \tag{1.1}$$

这里的 p 是当前 history 上的下一个 token 分布，不是整条 response 的分布。访问测度固定只意味着 s 不随 inner 更新；它不意味着优化变量 p 必须等于采样分布 μ_k。

1.2 共同闭式解

令

$$Z_k(s) = \sum_{a\in\mathcal{V}} \mu_k(a \mid s)\exp(\eta r_k(s,a)).$$

由于 $r_k = \log T - \log \mu_k$，有

$$Z_k(s) = \sum_a \mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}. \tag{1.2}$$

定理 1.1 (Token mirror target)

若 $\mu_k(a \mid s) > 0$ 时 $T(a \mid s) > 0$，则式 (1.1) 的唯一最大点为

$$p_k^+(a \mid s) = \frac{\mu_k(a \mid s)\exp(\eta r_k(s,a))}{Z_k(s)} = \frac{\mu_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}. \tag{1.3}$$

并且对任意 p，

$$\mathcal{J}_{k,s}(p) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\,\mathrm{KL}(p\|p_k^+). \tag{1.4}$$

♡

证明 由式 (1.3)，

$$\log p_k^+(a \mid s) = \log \mu_k(a \mid s) + \eta r_k(s,a) - \log Z_k(s).$$

因此

$$\mathrm{KL}(p\|p_k^+) = \sum_a p(a \mid s)\left[\log \frac{p(a \mid s)}{\mu_k(a \mid s)} - \eta r_k(s,a) + \log Z_k(s)\right]$$

$$= \mathrm{KL}(p\|\mu_k) - \eta \mathbb{E}_p[r_k] + \log Z_k(s).$$

移项得到式 (1.4)。KL 非负且仅在 $p = p_k^+$ 时为零，所以最大点唯一。 □

推论 1.1 (几何插值与极限)

当 $\eta = 0$ 时 $p_k^+ = \mu_k$ 的一阶极限成立；当 $\eta = 1$ 时 $p_k^+ = T$；当 $0 < \eta < 1$ 时，logits 满足

$$\log p_k^+ = (1-\eta)\log \mu_k + \eta \log T - \log Z_k.$$

因此 η 是 token-level teacher interpolation，而不是 inner optimizer 的学习率。

1.3 固定测度下的三个等价表述

定义 $m_k(s) = \mathbb{E}_{a\sim\mu_k}[r_k(s,a)]$。由 KL 定义，

$$m_k(s) = -\,\mathrm{KL}(\mu_k(\cdot \mid s) \| T(\cdot \mid s)). \tag{1.5}$$

将 reward 换成 $r_k - m_k$ 只改变 partition 的常数：

$$\mathbb{E}_{\mu_k}[e^{\eta(r_k - m_k)}] = e^{-\eta m_k} Z_k,$$

所以闭式分布 p_k^+ 不变。这是 PMD-Part 与 PMD-Mean 共享固定点的原因。

若定义 $u_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \mu_k(a \mid s)$，则 exact regression residual 为

$$q_{\mathrm{part}}(s,a;\theta) = u_\theta(s,a) - \eta r_k(s,a) + \log Z_k(s). \tag{1.6}$$

PMD-Mean 使用

$$q_{\mathrm{mean}}(s,a;\theta) = u_\theta(s,a) - \eta[r_k(s,a) - m_k(s)]. \tag{1.7}$$

二者的零点都等价于 $\pi_\theta = p_k^+$，但有限样本中 $\log Z_k$ 与 m_k 的估计方差不同。

1.4 参数化策略的投影

实际神经网络只能表示 $\{\pi_\theta\}$。固定 history 测度 $\rho_k(s)$ 后，PMD-Part 的总体 inner loss 定义为

$$\mathcal{L}_{\mathrm{part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim\rho_k, a\sim\mu_k}\left[q_{\mathrm{part}}(s,a;\theta)^2\right]. \tag{1.8}$$

若模型在每个 history 上可以实现式 (1.3)，则全局最小值为零；否则最小值是 anchor history 测度下的函数类投影误差。inner steps 增加只能逼近该投影，不能消除模型表达误差或 history coverage 误差。

第二章 四种 Token-level Inner 算法

2.1 PMD-Part：完整 partition 的残差回归

在固定 s 上，令 $a \sim \mu_k$. PMD-Part 最小化式 (1.8)。其 score-function 梯度为

$$-\nabla_\theta \mathcal{L}_{\text{part}} = \mathbb{E}_{\mu_k}\left[(\eta r_k - \log Z_k - u_\theta)\,\nabla_\theta \log \pi_\theta(a \mid s)\right]. \tag{2.1}$$

注意 $\log Z_k$、r_k 和 $\log \mu_k$ 在 inner 内停止梯度。若 action 是从 replay 测度 β 采样，则乘上

$$w_{\theta/\beta}(s,a) = \frac{\pi_\theta(a \mid s)}{\beta(a \mid s)}$$

才能把梯度还原到 π_θ 测度；若只想优化固定 replay projection，则不乘该权重。

Algorithm 1 固定测度 PMD-Part

Require: frozen anchor μ_k, teacher T, history batch s_i, η

1: **for** each s_i **do**
2: $\log Z_i \leftarrow \operatorname{logsumexp}_a((1-\eta)\log \mu_k(a \mid s_i) + \eta \log T(a \mid s_i))$
3: sample $a_i \sim \mu_k(\cdot \mid s_i)$ and compute $r_i = \log T(a_i \mid s_i) - \log \mu_k(a_i \mid s_i)$
4: $q_i \leftarrow \eta r_i - \log Z_i - \log \pi_\theta(a_i \mid s_i) + \log \mu_k(a_i \mid s_i)$
5: **end for**
6: update θ by minimizing $\frac{1}{2B}\sum_i q_i^2$

2.2 PMD-Mean：anchor 测度下的中心化

PMD-Mean使用 $m_k(s) = \mathbb{E}_{\mu_k} r_k(s,a)$，并在两边都去除 anchor 测度下的 action-independent 均值。令

$$\bar{u}_\theta(s) = \mathbb{E}_{\mu_k}[u_\theta(s,a)], \qquad q_{\text{mean}} = (u_\theta - \bar{u}_\theta) - \eta(r_k - m_k).$$

这相当于在 quotient space $u \sim u + c(s)$ 上回归。对固定 s，若 m_k 精确，则

$$q_{\text{mean}} = 0 \iff u_\theta - \bar{u}_\theta = \eta(r_k - m_k).$$

将中心化等式与 $u_\theta = \eta r_k - \log Z_k$ 比较即可恢复同一个 target；这里不要求 $\eta m_k = \log Z_k$。有限参数回归的条件数和噪声则与 PMD-Part 不同。

当每个 history 有 K 条独立 anchor action 时，使用 leave-one-out center

$$\widehat{m}_{-j}(s) = \frac{1}{K-1}\sum_{\ell \neq j} r_k(s, a_\ell)$$

可以避免中心与当前 score 的协方差偏差。直接使用同一批样本的均值会产生因子 $(K-1)/K$ 的梯度收缩。

2.3 BPO：固定测度上的 KL 正则化梯度

BPO在本章中定义为直接优化共同目标 (1.1)，但不回归整条 log-ratio，而是使用 policy-gradient 形式：

$$g_{\text{BPO}}(s) = \mathbb{E}_{a \sim p_\theta}\left[\left(r_k(s,a) - \frac{1}{\eta}\log \frac{p_\theta(a \mid s)}{\mu_k(a \mid s)}\right)\nabla_\theta \log p_\theta(a \mid s)\right]. \tag{2.2}$$

这是 $\nabla_\theta \mathcal{J}_{k,s}(p_\theta)$ 的精确形式；加任意 action-independent baseline 不改变梯度。

固定测度实现从 μ_k 采样，令 $w_\theta = p_\theta/\mu_k$，则

$$g_{\text{BPO}}(s) = \mathbb{E}_{a \sim \mu_k}\left[\operatorname{sg}(w_\theta)\left(r_k - \frac{1}{\eta}\log w_\theta\right)\nabla_\theta \log p_\theta(a \mid s)\right]. \tag{2.3}$$

这里的 $\operatorname{sg}(w_\theta)$ 只负责改变积分测度；score 本身保留梯度。

为了不枚举词表，使用 2602.04417 中的 K4 估计量。对 $a \sim p_\theta$，设 $w = \mu_k(a)/p_\theta(a)$、$r_\theta = p_\theta(a)/\operatorname{sg}(p_\theta(a))$，则

$$\widehat{\mathrm{KL}}_{\mathrm{K4}} = r_\theta[-\log w] \tag{2.4}$$

在数值上无偏估计 $\mathrm{KL}(p_\theta\|\mu_k)$，其自动微分梯度也无偏估计该 KL 的梯度。固定 μ_k 采样时，再乘以 $\operatorname{sg}(p_\theta/\mu_k)$ 做 action-measure correction。K1 只有无偏 value 而没有正确的 gradient；K3 的 gradient 对应相反方向的 KL，不能在这里直接使用。

Algorithm 2 固定测度 BPO-K4

Require: frozen μ_k, T, token histories s_i, η

for each sampled $a_i \sim \mu_k$ **do**
  $r_i \leftarrow \log T(a_i \mid s_i) - \log \mu_k(a_i \mid s_i)$
  $w_i \leftarrow \exp(\log \pi_\theta(a_i \mid s_i) - \log \mu_k(a_i \mid s_i))$
  $k_i \leftarrow \operatorname{sg}(w_i)\, r_{\theta,i}[-\log(\mu_k(a_i \mid s_i)/\pi_\theta(a_i \mid s_i))]$
  maximize $\operatorname{sg}(w_i) r_i - k_i/\eta$ with automatic differentiation
end for

2.4 MDPO：Fisher 几何下的同一子问题

MDPO不改变 target，而改变 inner 的更新几何。令

$$F_\theta(s) = \mathbb{E}_{a\sim\mu_k}\left[\operatorname{sg}(w_\theta) g_\theta(s,a) g_\theta(s,a)^\top\right]$$

为 anchor-measure 下的 Fisher 矩阵，g_θ 为式 (2.3) 的梯度。MDPO 的自然梯度步是

$$\theta^+ = \theta + \alpha F_\theta(s)^\dagger g_\theta(s). \tag{2.5}$$

在 tabular categorical policy 的概率坐标中，$\alpha = 1$ 且使用 exact gradient 时，该步等价于 mirror step 的一阶坐标表示；在神经网络参数中，它只是对共同目标的 Fisher-preconditioned 近似，因此需要 inner line search 或 trust-region cap。

命题 2.1 (共同固定点)

若词表支持满足条件，且使用 exact partition/K4 gradient、函数类能够表示目标，则 PMD-Part、PMD-Mean、BPO-K4 和 MDPO 的共同 stationary distribution 都是 p_k^+。

证明 PMD-Part 由平方 residual 为零得到式 (1.3)。PMD-Mean 只改变 action-independent 常数，归一化恢复同一常数。BPO-K4 是共同目标的无偏梯度；严格凹的 KL 正则目标只有一个 stationary distribution。MDPO 使用同一梯度的正定 Fisher 预条件，因而不改变零点。 □

第三章 KL 估计量、无偏性与方差

3.1 K4 的无偏性

固定 history，记 $p = \pi_\theta(\cdot \mid s)$、$q = \mu_k(\cdot \mid s)$，并从 p 采样 a。定义

$$w(a) = \frac{q(a)}{p(a)}, \qquad r_\theta(a) = \frac{p(a)}{\mathrm{stopgrad}(p(a))}.$$

数值上 $r_\theta = 1$，但其导数为 $\nabla \log p(a)$。

定理 3.1 (K4 value and gradient)

若 $p \ll q$ 且二阶矩有限，则

$$\mathbb{E}_{a\sim p}[r_\theta(a)(-\log w(a))] = \mathrm{KL}(p\|q),$$

并且自动微分意义下

$$\mathbb{E}_{a\sim p}[\nabla_\theta\{r_\theta(a)(-\log w(a))\}] = \nabla_\theta \mathrm{KL}(p\|q).$$

♡

证明 数值 value 中 $r_\theta = 1$，所以第一式是

$$\mathbb{E}_p[-\log(q/p)] = \sum_a p(a)\log(p(a)/q(a)).$$

对 stop-gradient 构造求导时，$-\log w = \log p - \log q$ 的 derivative 与 r_θ 的 derivative 共同给出

$$\nabla_\theta\{r_\theta(-\log w)\} = \nabla_\theta \log p(a)\,[\log p(a) - \log q(a)] + \nabla_\theta \log p(a).$$

最后一项在 p 下期望为零，第一项正是 KL 的 score-function derivative。 □

K1 的数值也无偏，但其 autograd gradient 为零；K3 的 gradient 对应 $\mathrm{KL}(q\|p)$ 的方向；K2 梯度正确但 value 有偏。因此 BPO 的 KL 项应优先使用 K4、K3^{++} 或完整 vocabulary 计算。

3.2 固定 anchor 测度上的重要性校正

若工程上必须从 $q = \mu_k$ 采样，令 $\rho_\theta(a) = p(a)/q(a)$，并在积分权重上停止梯度。对于任意可积向量 h，

$$\mathbb{E}_q[\mathrm{stopgrad}(\rho_\theta)h(a)] = \mathbb{E}_p[h(a)].$$

因此 BPO 的固定测度估计量为

$$\widehat{g}_i = \mathrm{stopgrad}(\rho_i)\left[r_i - \frac{1}{\eta}\widehat{k}_{4,i}\right] g_i, \qquad a_i \sim q.$$

在 p/q 的二阶矩有限时，它无偏；其单样本方差满足

$$\mathbb{E}_q\|\widehat{g}_i\|^2 \le C^2\mathbb{E}_q[\rho_\theta^2] = C^2\big(1 + \chi^2(p\|q)\big), \tag{3.1}$$

其中 C 上界 reward、K4 项和 score 的乘积。故 inner 走远以后，固定 anchor 的估计方差由 $\chi^2(p\|q)$ 控制；这正是必须记录 current-anchor divergence 的原因。

3.3 Top-K 与完整词表的关系

如果保存当前策略和 anchor 的 top-K logits，完整 reverse KL 可以拆成

$$\sum_{a\in Q_K} p(a)\log\frac{p(a)}{q(a)} + \sum_{a\notin Q_K} p(a)\log\frac{p(a)}{q(a)}.$$

第一项可精确计算；第二项不能被简单删除，否则得到截断 KL 而非完整 KL。2602.04417 的 Top-K 估计量在尾部使用 masked sampled K4：若采样 token 不在 Q_K，加入

$$\mathbf{1}(a \notin Q_K)\ \mathrm{stopgrad}\left(\frac{p(a)}{\pi_{\mathrm{sampling}}(a)}\right) r_\theta(a)(-\log w(a)).$$

它同时保持 value 和 gradient 无偏。对本项目而言，第一版小实验不使用 top-K reward，而先验证 full-vocabulary oracle 和 sampled K4 两条路径；否则无法判断误差来自 mirror target 还是 tail estimator。

3.4 有限 inner 更新的误差

设 exact token target 为 p_k^+，inner 算法在固定 s 上得到 $p_{k,m}$。定义 total variation error

$$e_{k,m}(s) = \frac{1}{2}\|p_{k,m}(\cdot \mid s) - p_k^+(\cdot \mid s)\|_1.$$

若 loss gradient 是 L-smooth，且使用 unbiased gradient with variance at most σ^2/B，标准 projected SGD 给出

$$\frac{1}{M}\sum_{m=0}^{M-1} \mathbb{E}\|\nabla \mathcal{L}(\theta_m)\|^2 \le \frac{2(\mathcal{L}_0 - \mathcal{L}_*)}{\alpha M} + \frac{L\alpha\sigma^2}{B}.$$

如果使用固定 anchor 而 current policy 逐渐远离它，则 σ^2 需要替换为含 $1 + \chi^2(p_{k,m}\|\mu_k)$ 的上界。因而 inner 做得越久，不一定越接近 exact target：优化误差下降的同时，off-policy estimator variance 会上升。

第四章 Outer 同步与有限 inner 的动力学

4.1 Hard sync 的精确动力学

先考虑每个 history 的 teacher 分布 T 不随 outer 改变，并且 inner 精确收敛到式 (1.3)。hard sync 定义为

$$\mu_k = \pi_k, \qquad \pi_{k+1} = \frac{\pi_k^{1-\eta} T^{\eta}}{Z_k}.$$

定理 4.1 (Hard-sync geometric interpolation)

若 $0 < \eta \le 1$ 且初始策略与 T 互相绝对连续，则

$$\pi_k(a \mid s) = \frac{\pi_0(a \mid s)^{(1-\eta)^k} T(a \mid s)^{1-(1-\eta)^k}}{\sum_b \pi_0(b \mid s)^{(1-\eta)^k} T(b \mid s)^{1-(1-\eta)^k}}. \tag{4.1}$$

并且

$$\log \frac{\pi_k(a \mid s)}{T(a \mid s)} = (1-\eta)^k \log \frac{\pi_0(a \mid s)}{T(a \mid s)} - \log C_k(s),$$

其中 $C_k(s)$ 是归一化常数。$\eta = 1$ 时一个 exact inner 将策略直接变成 teacher；$0 < \eta < 1$ 时每一轮只消除比例 η 的 log-density mismatch。

♡

证明 归纳证明。$k = 0$ 显然成立。假设式 (4.1) 成立，则

$$\pi_{k+1} \propto \pi_k^{1-\eta} T^{\eta} \propto \pi_0^{(1-\eta)^{k+1}} T^{(1-\eta)(1-(1-\eta)^k)+\eta}.$$

指数合并为 $1-(1-\eta)^{k+1}$，归一化后得到结论。 □

推论 4.1 (Outer contraction)

在任意固定 s 上，unnormalized log-ratio 的 contraction factor 是 $1-\eta$。若 log-ratio 初始振幅不超过 B，则归一化后 total variation 满足

$$\mathrm{TV}(\pi_k, T) \le \frac{1}{2}\left(e^{2B(1-\eta)^k} - 1\right).$$

该界说明小 η 不是免费加稳定性：它把每轮变化缩小，同时把达到相同 teacher proximity 所需的 outer steps 增加到 $O(\eta^{-1}\log(1/\varepsilon))$。

♡

4.2 有限 inner 与 stale target

实际第 k 轮只运行 M_k 个 inner steps，得到 $\widehat{\pi}_{k+1}$。假设在每个 history 上有 log-density 误差

$$\left|\log \frac{\widehat{\pi}_{k+1}(a \mid s)}{\pi^{+}_{k+1}(a \mid s)}\right| \le \varepsilon_k$$

在归一化前成立。则归一化后

$$\mathrm{TV}(\widehat{\pi}_{k+1}, \pi^{+}_{k+1}) \le \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.2}$$

令 $d_k = \mathrm{TV}(\pi_k, T)$，由 triangle inequality 和 hard-sync contraction 得

$$d_{k+1} \le (1-\eta) d_k + \delta_k, \qquad \delta_k = \frac{1}{2}(e^{2\varepsilon_k} - 1). \tag{4.3}$$

因此

$$d_K \le (1-\eta)^K d_0 + \sum_{j=0}^{K-1} (1-\eta)^{K-1-j} \delta_j.$$

有限 inner 误差不会被简单地“下一轮 rollout”消失；它会以几何权重累积。若 $\delta_j \le \bar{\delta}$，稳态误差上界为 $\bar{\delta}/\eta$。

4.3 Soft sync 的耦合动力学

若 anchor 使用 EMA，令

$$\mu_{k+1} = \lambda\mu_k + (1-\lambda)\widehat{\pi}_{k+1}$$

表示概率空间中的近似 soft sync。精确 inner 目标是

$$\widehat{\pi}_{k+1} \propto \mu_k^{1-\eta} T^{\eta}.$$

忽略归一化扰动并在线性 log-density 坐标中写 $z_k = \log \mu_k - \log T$，得到近似递推

$$z_{k+1} \approx [\lambda + (1-\lambda)(1-\eta)]z_k = [1-(1-\lambda)\eta]z_k.$$

所以 EMA 同时把 outer contraction 从 $1-\eta$ 改成 $1-(1-\lambda)\eta$。当 λ 接近 1，anchor 漂移非常慢，训练稳定但 teacher tracking 速度下降；这不是 inner 学习率的效果，而是 outer target 的真实动力学。

4.4 访问测度固定的含义

本章所有递推都是逐 history 的 token distribution 递推。真实 LLM 中 history 集合由 ρ_k 产生；只要 inner 内固定该集合，以上结论适用于 conditional token target。outer rollout 更新后，ρ_{k+1} 改变，必须额外记录 coverage drift：

$$\Delta_k = \mathrm{TV}(\rho_{k+1}, \rho_k).$$

若 token loss 在所有 history 上有上界 C，则访问测度改变给目标梯度带来至多 $2C\Delta_k$ 的偏差。因而“固定测度下求解 token 子问题”和“outer 重新 rollout”是两个严格分开的步骤。

第五章 可枚举 Token 实验与实现边界

5.1 实验设置

实验脚本位于 `experiments/toy_token_inner.py`。它只包含一个固定 history 和四个 token：

$$\mu = (0.62, 0.23, 0.10, 0.05), \qquad T = (0.08, 0.17, 0.25, 0.50).$$

每个方法从同一个初始策略开始，完整枚举 vocabulary，不使用 rollout，不使用 sequence-level reward。这样可以单独检查 token-level inner 的数学对象。PMD-Part 和 PMD-Mean 用 exact weighted squared residual；BPO 使用完整 categorical objective；MDPO 使用 exact categorical Fisher preconditioner。

5.2 结果

表 5.1 报告 400 个 inner updates 后与 exact target 的 total variation 距离和 KL。BPO、MDPO 达到机器精度；PMD-Part、PMD-Mean 使用固定 learning rate，因此保留小的优化误差，降低 learning rate 或继续更新后继续下降。

表 5.1: 固定测度 token inner 的可枚举实验。

η	方法	$\mathrm{TV}(p, p^+)$	$\mathrm{KL}(p\|p^+)$
0.25	PMD-Part	1.11e-3	6.79e-6
0.25	PMD-Mean	1.25e-3	8.30e-6
0.25	BPO	2.16×10^{-15}	-5.35×10^{-17}
0.25	MDPO	1.11×10^{-16}	9.34×10^{-17}
0.50	PMD-Part	2.65e-3	2.54e-5
0.50	PMD-Mean	4.71e-3	6.85e-5
0.50	BPO	9.54×10^{-13}	5.44×10^{-17}
0.50	MDPO	1.25×10^{-16}	3.14×10^{-17}
0.80	PMD-Part	2.97e-3	2.65e-5
0.80	PMD-Mean	1.12e-2	2.73e-4
0.80	BPO	4.15×10^{-7}	7.20×10^{-13}
0.80	MDPO	1.80×10^{-16}	-7.73×10^{-17}

实验验证了三个实现结论。第一，四个方法的 exact fixed point 相同；差别在于 residual、policy-gradient estimator 和 Fisher geometry。第二，BPO 必须把 KL 作为带正确梯度的项；K4 可以在不保存完整词表时实现这一点。第三，η 改变的是 mirror target 的位置：η 越大，target 越接近 teacher；它不能代替 inner optimizer learning rate。

5.3 正式 LLM 实验前必须通过的检查

在 Pythia-14M/70M 上运行前，代码应先逐项通过以下 oracle tests：

1. 对随机 categorical logits，检查 PMD-Part 的 `logsumexp` target 与显式求和一致；
2. 对随机 p, q，用大量样本检查 K4 value 与 exact $\mathrm{KL}(p\|q)$ 的误差按 $O(B^{-1/2})$ 下降；
3. 用 autograd finite difference 检查 K4 gradient，而不是只检查 value；
4. 检查固定 anchor 采样的 importance correction 在 p/q 接近一时无偏；
5. 人为增加 inner steps，确认 current-anchor χ^2 和估计方差同时上升；
6. hard sync 后重新 rollout，确认新一轮 residual 使用新的 anchor，而不是上一轮缓存的 log-prob。

这些检查完成前不运行大型模型 sweep。当前仓库中的 toy 输出由 `uv run --with torch python experiments/toy_tok` 生成，结果保存在 `experiments/toy_token_inner.csv`。独立的 `experiments/test_kl_estimators.py` 使用

200,000 个 token 样本检查 K4 的 value 与 autograd gradient；本次运行的绝对 value 误差为 5.6×10^{-5}，gradient 的 ell_2 误差为 1.5×10^{-3}。

参考资料

本文 KL 估计量的记号与 K3^{++}、K4、K5、Top-k 估计量来自科研`/pmd-theory/2602.04417_zh_CN/example_paper.tex`；One-Shot-OPD 的实现审计见科研`/pmd-theory/MirrorOPD/source_audit/One-Shot-OPD/`。