从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward . . . 1
1.2 KL 镜像最优解 . . . 1
1.3 即时 reward 与完整序列 reward . . . 2

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean、BPO 与 MDPO **3**
2.1 共同的 token-level mirror 子问题 . . . 3
2.1.1 为什么优势函数的行为均值为零 . . . 3
2.2 四种算法的逐步推导 . . . 4
2.2.1 PMD-Part：回归完整的最优 log-ratio . . . 4
2.2.2 MDPO：直接优化带 KL 正则的镜像目标 . . . 4
2.2.3 PMD-Mean：中心化 target 加归一化投影 . . . 4
2.2.4 BPO：对同一最优性方程做中心化 residual 回归 . . . 5
2.2.5 PMD-Mean 与 BPO 都中心化，但投影对象不同 . . . 6
2.3 OPD 的 inner–outer mirror 流程：教师并非每步都被完全拟合 . . . 7
2.3.1 一个 outer step 的精确 mirror 解 . . . 7
2.3.2 OPD token reward 的来源与序列层解释 . . . 7
2.3.3 同一个 OPD mirror step 的四种 inner 实例化 . . . 8
2.3.4 inner 求解与 outer 更新的区别 . . . 10
2.3.5 为什么 inner 需要多步：从精确 KL 几何到 Natural Gradient . . . 11
2.3.6 OPD 的 off-policy prefix 复用 . . . 15
2.4 共享零点、不同梯度的定理 . . . 15

第三章 梯度的偏差与方差 **17**
3.1 估计对象必须先固定 . . . 17
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 . . . 17
3.3 PMD-Part 的投影偏差与 BPO 的中心化方差 . . . 18

第四章 实现与参数比较 **20**
4.1 理论对象与实际代码 . . . 20
4.2 BPO 论文的训练预算 . . . 20
4.3 OpenKimi/PMD 的训练预算 . . . 20
4.4 经典 MDPO 的训练预算与 IS . . . 20
4.5 比较时应报告的指标 . . . 21

第五章 结论与 MirrorOPD 的边界 **22**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean、BPO 与 MDPO

2.1 共同的 token-level mirror 子问题

固定 prefix s，行为策略记为 $\mu(a \mid s)$，候选学生策略记为 $\pi_\theta(a \mid s)$，并定义

$$u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\mu(a \mid s)}, \qquad g_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s).$$

统一用 $\eta > 0$ 表示 Natural Gradient 的学习率。给定 token 信号 $f(s,a)$，四种方法都从同一个镜像子问题开始：

$$\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{2.1}$$

定义

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{\eta f(s,a)}].$$

对任意候选分布 p，直接展开 KL 得到

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \eta \mathbb{E}_p[f] + \log Z_f(s), \end{aligned}$$

其中

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{Z_f(s)}.$$

整理后，镜像目标满足

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+). \tag{2.2}$$

因此唯一最优策略是 π^+，其最优 log-ratio 为

$$u^+(s,a) = \log \frac{\pi^+(a \mid s)}{\mu(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.3}$$

2.1.1 为什么优势函数的行为均值为零

条件 $\mathbb{E}_\mu[f(s,a) \mid s] = 0$ 不是任意 reward 的性质。若 $f = A^\mu$ 是行为策略的优势函数，则

$$A^\mu(s,a) = Q^\mu(s,a) - V^\mu(s), \qquad V^\mu(s) = \mathbb{E}_{a\sim\mu}[Q^\mu(s,a) \mid s],$$

从而

$$\begin{aligned} \mathbb{E}_\mu[A^\mu(s,a) \mid s] &= \mathbb{E}_\mu[Q^\mu(s,a) \mid s] - V^\mu(s) \\ &= 0. \end{aligned}$$

若 f 是即时 reward、教师分数或一般 OPD 信号，则必须把中心化作为显式定义。令

$$\bar{f}(s) = \mathbb{E}_\mu[f(s,a) \mid s], \qquad \widetilde{f}(s,a) = f(s,a) - \bar{f}(s).$$

减去只依赖 prefix 的常数不改变 Gibbs 策略，因为

$$\frac{\mu(a \mid s) e^{\eta \widetilde{f}(s,a)}}{\mathbb{E}_\mu[e^{\eta \widetilde{f}(s,\cdot)} \mid s]} = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{\mathbb{E}_\mu[e^{\eta f(s,\cdot)} \mid s]}.$$

后文在 BPO 和 PMD-Mean 中使用 $\widetilde{f}$；PMD-Part 直接保留精确的 $\log Z_f(s)$。

2.2 四种算法的逐步推导

2.2.1 PMD-Part：回归完整的最优 log-ratio

把式(2.3) 当作 supervised target，定义

$$h(s,a) = \eta f(s,a) - \log Z_f(s), \qquad q_\theta(s,a) = h(s,a) - u_\theta(s,a).$$

PMD-Part 损失和下降方向分别为

$$\mathcal{L}_{\text{Part}} = \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[q_\theta(s,a)^2], \tag{2.4}$$

$$-\nabla_\theta \mathcal{L}_{\text{Part}} = \mathbb{E}_{d_\mu,\mu}[q_\theta(s,a) g_\theta(s,a)]. \tag{2.5}$$

给定 batch $\{(s_i,a_i)\}_{i=1}^B$，其中 $a_i \sim \mu(\cdot \mid s_i)$，实际代码使用

$$\widehat{\mathcal{L}}_{\text{Part}} = \frac{1}{2B}\sum_{i=1}^{B}\left(\log \pi_\theta(a_i \mid s_i) - \log \mu(a_i \mid s_i) - h_i\right)^2, \quad \widehat{G}_{\text{Part}} = \frac{1}{B}\sum_i (h_i - u_i) g_i, \tag{2.6}$$

其中 $h_i = \eta f_i - \log Z_f(s_i)$、$u_i = \log \pi_\theta(a_i \mid s_i) - \log \mu(a_i \mid s_i)$，并对 h_i 停止梯度。若不能精确枚举 Z_f，可用同一 prefix 的 K 个行为 action 估计 $\widehat{Z}_f(s) = K^{-1}\sum_{j=1}^K \exp(\eta f(s,a_j))$；此时 target 估计误差会进入回归偏差。这里的 target 常数 $\log Z_f(s)$ 固定了 action-independent 方向。

2.2.2 MDPO：直接优化带 KL 正则的镜像目标

MDPO保留式(2.1) 的原始目标，不先构造 log-ratio target。对固定 prefix，定义

$$\mathcal{J}_{\text{MDPO}}(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \frac{1}{\eta}\,\text{KL}\left(\pi_\theta(\cdot \mid s) \| \mu(\cdot \mid s)\right). \tag{2.7}$$

令 $\rho_\theta(s,a) = \pi_\theta(a \mid s)/\mu(a \mid s)$。若可以枚举词表，KL 项直接计算为

$$\text{KL}(\pi_\theta \| \mu) = \sum_a \pi_\theta(a \mid s) \log \rho_\theta(s,a). \tag{2.8}$$

若训练样本来自 $a_i \sim \mu(\cdot \mid s_i)$，则每个样本的可计算标量为

$$\widehat{j}_i(\theta) = \rho_i f_i - \frac{1}{\eta}\rho_i \log \rho_i, \qquad \rho_i = \exp\left(\log \pi_\theta(a_i \mid s_i) - \log \mu(a_i \mid s_i)\right). \tag{2.9}$$

对 f_i、μ 和行为样本停止梯度，batch ascent 方向为

$$\widehat{G}_{\text{MDPO}} = \frac{1}{B}\sum_{i=1}^{B}\rho_i\left(f_i - \frac{1}{\eta}\log \rho_i\right) g_i, \qquad g_i = \nabla_\theta \log \pi_\theta(a_i \mid s_i). \tag{2.10}$$

这里 ρ_i 是 action-level importance ratio；如果 prefix 也来自 off-policy replay，还需在样本外乘 $W_{<t_i}$。MDPO 因而是四种方法中唯一直接对镜像目标做 ascent 的 inner，其他三种先构造 regression residual。

2.2.3 PMD-Mean：中心化 target 加归一化投影

PMD-Mean不显式回归 $\log Z_f$，而令

$$g_{\text{Mean}}(s,a) = \eta \widetilde{f}(s,a)$$

并求解

$$\min_u \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[(u - g_{\text{Mean}})^2] \quad \text{s.t.} \quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}] = 1. \tag{2.11}$$

固定 prefix 后，写出拉格朗日函数

$$\mathcal{J}(u,\lambda) = \frac{1}{2}\sum_a \mu_a (u_a - g_a)^2 + \lambda\left(\sum_a \mu_a e^{u_a} - 1\right).$$

因为 $\mu_a > 0$，一阶条件为

$$u_a - g_a + \lambda e^{u_a} = 0.$$

令 $v_a = g_a - u_a$，则

$$v_a e^{v_a} = \lambda e^{g_a}.$$

由 Lambert-W 的定义 $W(z)e^{W(z)} = z$，得到

$$u^{+}_{\mathrm{Mean}}(s,a) = g_{\mathrm{Mean}}(s,a) - W\left(\lambda(s)e^{g_{\mathrm{Mean}}(s,a)}\right), \tag{2.12}$$

其中 $\lambda(s)$ 由归一化约束唯一确定。PMD-Mean 是投影问题；除特殊情形外，式(2.12) 不等于精确 Gibbs log-ratio。

2.2.3.0.1 PMD-Mean 的 batch 估计量。 在每个 prefix 采 K 个 action，记 $r_{ij} = \log(T(a_{ij} \mid s_i)/\mu(a_{ij} \mid s_i))$，则

$$\widehat{\bar{r}}_i = \frac{1}{K}\sum_{j=1}^{K} r_{ij}, \qquad \widehat{\tilde{r}}_{ij} = r_{ij} - \widehat{\bar{r}}_i. \tag{2.13}$$

对第 i 个 prefix 的第 j 个样本，回归目标为 $\eta\widehat{\tilde{r}}_{ij}$，经验损失为

$$\widehat{\mathcal{L}}_{\mathrm{Mean}} = \frac{1}{2BK}\sum_{i=1}^{B}\sum_{j=1}^{K}\left(u_{ij} - \eta\widehat{\tilde{r}}_{ij}\right)^2, \qquad u_{ij} = \log\frac{\pi_\theta(a_{ij} \mid s_i)}{\mu(a_{ij} \mid s_i)}. \tag{2.14}$$

若使用完整 vocabulary，则把样本均值替换为 $\sum_a \mu(a \mid s_i)r(s_i,a)$；若只使用单个 action，中心化项不可由该样本无偏估计，必须使用额外 action、教师全分布或 control variate。

2.2.4 BPO：对同一最优性方程做中心化 residual 回归

先定义 $b_\theta(s,a) = \eta f(s,a) - u_\theta(s,a)$。令

$$\bar{b}_\theta(s) = \mathbb{E}_{a\sim\mu}[b_\theta(s,a) \mid s].$$

BPO的 residual 是

$$\delta_\theta(s,a) = b_\theta(s,a) - \bar{b}_\theta(s). \tag{2.15}$$

若使用中心化信号 $\widetilde{f}$，则

$$\delta_\theta = \eta\widetilde{f} - u_\theta + \mathbb{E}_\mu[u_\theta \mid s], \qquad \mathbb{E}_\mu[\delta_\theta \mid s] = 0.$$

完整 reverse-KL 的导数给出

$$\nabla_\theta\delta_\theta(s,a) = -\left(g_\theta(s,a) - \bar{g}_\theta(s)\right), \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

所以未线性化 BPO 损失

$$\mathcal{L}_{\mathrm{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)^2] \tag{2.16}$$

的下降方向为

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)(g_\theta(s,a) - \bar{g}_\theta(s))]. \tag{2.17}$$

给定每个 prefix 的 K 个行为 action，BPO 的经验估计量可以写成

$$\widehat{\mathcal{L}}_{\mathrm{BPO}} = \frac{1}{2\eta BK}\sum_{i=1}^{B}\sum_{j=1}^{K} widehatdelta_{ij}^2, \qquad \widehat{G}_{\mathrm{BPO}} = \frac{1}{BK}\sum_{i=1}^{B}\sum_{j=1}^{K}\widehat{\delta}_{ij}\left(g_{ij} - \widehat{\bar{g}}_i\right), \tag{2.18}$$

其中

$$\widehat{\bar{g}}_i = \frac{1}{K}\sum_{j=1}^{K} g_{ij}, \qquad \widehat{\delta}_{ij} = \eta f_{ij} - u_{ij} - \frac{1}{K}\sum_{\ell=1}^{K}(\eta f_{i\ell} - u_{i\ell}).$$

同一 prefix 内的 action 集合用于估计行为测度下的中心化项；只有一个 action 时，$\widehat{\bar{g}}_i$ 与 residual 均值不能由该条样本本身可靠估计。

2.2.5 PMD-Mean 与 BPO 都中心化，但投影对象不同

两种方法都可以写出一个中心化的信号 $\widetilde{f}$，但中心化发生在不同的优化问题中。PMD-Mean先把精确最优 log-ratio

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s)$$

替换为可观测的中心化 target $\eta\widetilde{f}(s,a)$，然后在满足 $\mathbb{E}_\mu[e^u \mid s] = 1$ 的函数集合上做平方距离投影。它的残差是

$$r_{\text{Mean}}(s,a) = \eta\widetilde{f}(s,a) - u_\theta(s,a),$$

并没有把当前策略的 u_θ 再次中心化。

BPO 使用的是同一个镜像最优性方程的 centered residual。展开式(2.15) 可得

$$\delta_\theta(s,a) = \eta f(s,a) - u_\theta(s,a) - \mathbb{E}_\mu[\eta f(s,\cdot) - u_\theta(s,\cdot) \mid s].$$

若 f 已经满足 $\mathbb{E}_\mu[f \mid s] = 0$，这变为

$$\delta_\theta(s,a) = \eta f(s,a) - u_\theta(s,a) + \mathbb{E}_\mu[u_\theta(s,\cdot) \mid s].$$

因此二者的 residual 差为

$$\delta_\theta - r_{\text{Mean}} = \mathbb{E}_\mu[u_\theta(s,\cdot) \mid s]$$

（在 f 已中心化时）。这个差是只依赖 prefix 的常数，策略在精确解处可以通过归一化吸收它；但是在参数空间进行有限步回归时，它会改变梯度，因为 PMD-Mean 使用 g_θ，而未线性化 BPO 对完整 reverse-KL 求导后使用 $g_\theta - \bar{g}_\theta$。所以“都出现 $\widetilde{f}$”只说明它们共享同一个 action-independent 不可辨识方向，并不意味着两个损失或梯度相同。

命题 2.1 (PMD-Mean 与 BPO 的等价条件)

固定一个 prefix，并假设 $\mathbb{E}_\mu[f \mid s] = 0$。若同时满足

$$\mathbb{E}_\mu[u_\theta \mid s] = 0, \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s] = 0,$$

则 PMD-Mean 的 residual 与 BPO residual 相同，且两者的下降方向相同。策略归一化只给出 $\mathbb{E}_{\pi_\theta}[g_\theta] = 0$，而不是所需的 $\mathbb{E}_\mu[g_\theta] = 0$；同样，$\mathbb{E}_\mu[u_\theta \mid s] = 0$ 也不是归一化约束的结果。因此在行为测度 μ 下，二者通常只共享精确零点而不共享有限步梯度。

证明 在 $\mathbb{E}_\mu[f \mid s] = 0$ 下，前面的恒等式给出

$$\delta_\theta - r_{\text{Mean}} = \mathbb{E}_\mu[u_\theta \mid s].$$

若该均值为零，则 residual 相同。PMD-Mean 的下降方向为 $\mathbb{E}_\mu[r_{\text{Mean}} g_\theta]$；BPO 的下降方向由式(2.17) 给出。若再有 $\bar{g}_\theta = 0$，则

$$\mathbb{E}_\mu[\delta_\theta(g_\theta - \bar{g}_\theta)] = \mathbb{E}_\mu[r_{\text{Mean}} g_\theta],$$

故两者相同。反之，只要任一 action-independent 项没有被这两个条件消除，有限参数更新就会产生梯度差异。

2.3 OPD 的 inner–outer mirror 流程：教师并非每步都被完全拟合

本节把 OPD 写成一个明确的 outer–inner 算法。固定教师策略 $T(a \mid s)$，令第 k 次 outer 迭代开始时的学生策略为 $\pi_k(a \mid s)$。假设在教师有正概率的 action 上，学生也有正概率，即 $T(\cdot \mid s) \ll \pi_k(\cdot \mid s)$。OPD 的逐 token 信号取为当前学生到教师的 log-ratio

$$f_k(s,a) = \log \frac{T(a \mid s)}{\pi_k(a \mid s)}. \tag{2.19}$$

这里的 reward 依赖 outer 迭代编号 k；它不是一个固定的、一次性定义的 r_T。它衡量教师相对于当前学生在 prefix s 下对 action a 的局部偏好。

2.3.1 一个 outer step 的精确 mirror 解

给定 π_k 和 f_k，第 k 次 mirror 子问题为

$$\pi^\star_{k+1} = \arg\max_{p \ll \pi_k} \left\{ \mathbb{E}_{a\sim p}[f_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}\left(p \| \pi_k(\cdot \mid s)\right) \right\}, \qquad 0 < \eta \le 1. \tag{2.20}$$

把 f_k 代入 Gibbs 解，得到

$$\pi^\star_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)\exp\left(\eta \log \frac{T(a|s)}{\pi_k(a|s)}\right)}{Z_k(s)} \tag{2.21}$$

$$= \frac{\pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}, \tag{2.22}$$

其中

$$Z_k(s) = \sum_a \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}. \tag{2.23}$$

因此，$\eta = 1$ 时 $\pi^\star_{k+1} = T$，一次 mirror step 直接到教师；$0 < \eta < 1$ 时得到学生和教师在 log-probability 空间的几何插值。该中间分布不是额外启发式，而是式(2.20) 的精确解。

定理 2.1 (OPD mirror step 的几何中间分布)

在有限 action space 和 $T(\cdot \mid s) \ll \pi_k(\cdot \mid s)$ 下，式(2.20) 的唯一解是式(2.22)。特别地，$\eta = 1$ 时一步到达教师；$0 < \eta < 1$ 时该更新保持在学生与教师之间，并满足 $\pi^\star_{k+1} \ll \pi_k$。

♡

证明 将 $f_k = \log(T/\pi_k)$ 代入镜像目标，并忽略与 p 无关的项，有

$$\mathbb{E}_p[f_k] - \frac{1}{\eta}\,\mathrm{KL}(p\|\pi_k) = -\frac{1}{\eta}\mathbb{E}_p\left[\log p - (1-\eta)\log \pi_k - \eta \log T\right].$$

令 $q_k(a \mid s) = \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}$，并令 $Z_k = \sum_a q_k(a \mid s)$。则上式等于

$$\frac{1}{\eta}\log Z_k - \frac{1}{\eta}\,\mathrm{KL}(p\|q_k/Z_k).$$

KL 非负且仅在 $p = q_k/Z_k$ 时取零，因此得到唯一解。$\eta = 1$ 时 $q_k = T$ 且 $Z_k = 1$；当 $0 < \eta < 1$ 时，q_k 对两种分布的 log 概率作凸组合，且由支持假设满足绝对连续性。

2.3.2 OPD token reward 的来源与序列层解释

OPD中的教师通常能在给定 prefix $s_t = (x, a_{<t})$ 时返回下一个 token 的条件分布 $T(a_t \mid s_t)$。学生在同一个 prefix 上给出 $\pi_k(a_t \mid s_t)$。两者的逐 token 对数似然差定义为

$$r_k(s_t, a_t) = \log T(a_t \mid s_t) - \log \pi_k(a_t \mid s_t). \tag{2.24}$$

这个定义只使用教师和学生分布，不引入外部 reward。它也不是人为指定的常数，因为对一条完整序列 $y = (a_1, \dots, a_H)$ 有

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \sum_{t=1}^{H} \log \frac{T(a_t \mid s_t)}{\pi_k(a_t \mid s_t)} \tag{2.25}$$

$$= \log \frac{T(y \mid x)}{\pi_k(y \mid x)}. \tag{2.26}$$

因此 token reward 是序列级 teacher–student log-ratio 的一个无损分解。它把一个序列信号分摊到教师已经访问到的每个 prefix 上；它没有把序列目标替换成与未来无关的即时 reward。若优化的是完整序列目标，式(2.26) 的后续 token 贡献仍然通过 return 或 soft Q 进入 prefix 的训练权重。

命题 2.2 (OPD reward 的镜像最优性)

固定 prefix s 和行为策略 π_k。令 r_k 如式(2.24)，则

$$\pi_k(a \mid s) \exp\big(\eta r_k(s,a)\big) = \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}.$$

所以以 r_k 为 token 信号的 KL mirror 子问题，其最优分布必然是学生和教师的几何中间分布，而不是预先假设的教师分布。

证明 将式(2.24) 代入左侧：

$$\pi_k(a \mid s) \exp\left(\eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)}\right) = \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}.$$

对 action 求和得到归一化常数 $Z_k(s)$，再应用定理 1.1 即得结论。

2.3.3 同一个 OPD mirror step 的四种 inner 实例化

令

$$u_k^\star(s,a) = \log \frac{\pi_{k+1}^\star(a \mid s)}{\pi_k(a \mid s)} = \eta r_k(s,a) - \log Z_k(s),$$

其中

$$r_k(s,a) = \log \frac{T(a \mid s)}{\pi_k(a \mid s)}, \qquad Z_k(s) = \sum_{a'} \pi_k(a' \mid s)^{1-\eta} T(a' \mid s)^{\eta}.$$

因此三个量都可以完全写成

$$u_k^\star(s,a) = \eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)} - \log \sum_{a'} \pi_k(a' \mid s)^{1-\eta} T(a' \mid s)^{\eta}, \qquad u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}. \tag{2.27}$$

下面四种方法的差异只在于如何用有限样本和参数化模型逼近这个同一个 $u_k^\star$。

2.3.3.0.1 PMD-Part 的 OPD inner。 若教师能够返回完整 token 分布，就可以直接计算

$$h_k(s,a) = \eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)} - \log \sum_{a'} \pi_k(a' \mid s)^{1-\eta} T(a' \mid s)^{\eta}.$$

在 replay prefix 上最小化

$$\mathcal{L}_{k,\mathrm{Part}}(\theta) = \frac{1}{2} \mathbb{E}_{s \sim d_b,\, a \sim \pi_k} \left[\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)} - \eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)} + \log \sum_{a'} \pi_k(a' \mid s)^{1-\eta} T(a' \mid s)^{\eta} \right]^2. \tag{2.28}$$

停止 target 梯度后，

$$-\nabla_\theta \mathcal{L}_{k,\mathrm{Part}} = \mathbb{E}_{d_b, \pi_k} \left[h_k(s,a) - u_\theta(s,a) \right] g_\theta(s,a). \tag{2.29}$$

在 tabular、全 action 覆盖且使用真实 Z_k 的情形，零损失等价于 $\pi_\theta = \pi_{k+1}^\star$。共享参数或 prefix 覆盖不足时，得到的是 replay 测度下的投影，不能把零训练误差解释成所有 prefix 上的教师拟合。

2.3.3.0.2 PMD-Mean 的 OPD inner。 当 $Z_k(s)$ 不方便计算时，先构造行为测度下的中心化信号

$$\widetilde{r}_k(s,a) = \log \frac{T(a \mid s)}{\pi_k(a \mid s)} - \sum_{a'} \pi_k(a' \mid s) \log \frac{T(a' \mid s)}{\pi_k(a' \mid s)}.$$

再令 $\widetilde{h}_k(s,a) = \eta \widetilde{r}_k(s,a)$，求解

$$\min_\theta \frac{1}{2} \mathbb{E}_{d_b,\pi_k} \left[\log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)} - \eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)} + \eta \sum_{a'} \pi_k(a' \mid s) \log \frac{T(a' \mid s)}{\pi_k(a' \mid s)} \right]^2 \quad \text{s.t.} \quad \sum_a \pi_k(a \mid s) \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)} = 1. \tag{2.30}$$

约束是必要的：$u_\theta = \log(\pi_\theta/\pi_k)$ 必须满足

$$\mathbb{E}_{\pi_k}[e^{u_\theta} \mid s] = \sum_a \pi_\theta(a \mid s) = 1.$$

在函数空间中，式(2.30) 是中心化 target 到这个非线性约束集合的投影；其 KKT 方程和 Lambert-W 解已经在式(2.12) 中给出。只有当中心化 target 本身满足该约束时，PMD-Mean 才直接等于精确 Gibbs log-ratio。

2.3.3.0.3 BPO 的 OPD inner。 BPO 不显式估计 $\log Z_k$，而在每个 prefix 上把 residual 投影到行为测度的零均值子空间：

$$\delta_{k,\theta}(s,a) = \eta \log \frac{T(a \mid s)}{\pi_k(a \mid s)} - \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)} - \eta \sum_{a'} \pi_k(a' \mid s) \log \frac{T(a' \mid s)}{\pi_k(a' \mid s)} + \sum_{a'} \pi_k(a' \mid s) \log \frac{\pi_\theta(a' \mid s)}{\pi_k(a' \mid s)}. \tag{2.31}$$

$$\mathcal{L}_{k,\mathrm{BPO}}(\theta) = \frac{1}{2\eta} \mathbb{E}_{d_b,\pi_k} \left[\delta_{k,\theta}(s,a)^2 \right]. \tag{2.32}$$

对完整 reverse-KL 项求导得到

$$-\eta \nabla_\theta \mathcal{L}_{k,\mathrm{BPO}} = \mathbb{E}_{d_b,\pi_k} \left[\delta_{k,\theta}(s,a) \left(g_\theta(s,a) - \bar{g}_\theta(s) \right) \right], \tag{2.33}$$

其中方括号表示标量 residual 与向量 score 的乘积，

$$\delta_{k,\theta}(s,a) \left(g_\theta(s,a) - \bar{g}_\theta(s) \right), \qquad \bar{g}_\theta(s) = \mathbb{E}_{\pi_k}[g_\theta(s,a) \mid s].$$

若 $\delta_{k,\theta} = 0$，则

$$u_\theta(s,a) = \eta r_k(s,a) + c_k(s)$$

对某个 action-independent 常数 $c_k(s)$ 成立。归一化约束进一步给出

$$1 = \mathbb{E}_{\pi_k}[e^{u_\theta} \mid s] = e^{c_k(s)} Z_k(s), \qquad c_k(s) = -\log Z_k(s),$$

所以 BPO 的精确零点也是 $u_k^\star$。这说明 BPO 与 PMD-Part 的最优策略相同，但其有限步梯度仍因中心化 score 而不同。

2.3.3.0.4 MDPO 的 OPD inner。 MDPO 不回归 $u_k^\star$，而直接在冻结的 π_k 上优化 mirror objective：

$$\mathcal{J}_{k,\mathrm{MDPO}}(\theta) = \mathbb{E}_{s \sim d_b} \left[\mathbb{E}_{a \sim \pi_\theta(\cdot \mid s)}[r_k(s,a)] - \frac{1}{\eta} \mathrm{KL}(\pi_\theta(\cdot \mid s) \| \pi_k(\cdot \mid s)) \right]. \tag{2.34}$$

若能够访问完整 vocabulary logits，KL 可以逐 token 精确计算：

$$\mathrm{KL}(\pi_\theta \| \pi_k) = \sum_a \pi_\theta(a \mid s) \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}.$$

若只有 $a \sim \pi_k$ 的 replay action，则令

$$\rho_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)},$$

用 action importance sampling 得到可直接实现的估计量

$$\widehat{\mathcal{J}}_{k,\mathrm{MDPO}}(\theta) = \mathbb{E}_{s \sim d_b,\, a \sim \pi_k} \left[\rho_\theta(s,a) r_k(s,a) - \frac{1}{\eta} \rho_\theta(s,a) \log \rho_\theta(s,a) \right]. \tag{2.35}$$

停止 r_k、π_k 和 replay 权重的梯度后，其 ascent 方向为

$$\nabla_\theta \widehat{\mathcal{J}}_{k,\mathrm{MDPO}} = \mathbb{E}_{d_b,\pi_k}\left[\rho_\theta(s,a)\left(r_k(s,a) - \frac{1}{\eta}\log\rho_\theta(s,a)\right) g_\theta(s,a)\right]. \tag{2.36}$$

推导中额外出现的 $-\rho_\theta/\eta$ 项乘以 g_θ 后，利用

$$\mathbb{E}_{\pi_\theta}[g_\theta \mid s] = 0$$

消失，因而式(2.36)是完整 reverse-KL 目标的梯度，而非把 KL 当作常数的近似。MDPO 的 inner 误差由 $\mathcal{J}_{k,\mathrm{MDPO}}(\theta)$ 的优化 gap 或

$$\mathrm{KL}(\pi_\theta \| \pi^\star_{k+1})$$

监控；它通常需要固定 π_k 在同一 replay batch 上执行多次更新。

定理 2.2 (四种 OPD inner 的精确零点)

在有限 action space、$\pi_k(a \mid s) > 0$ 且函数类能够表示任意 log-ratio 的条件下，PMD-Part、PMD-Mean、未线性化 BPO 和 MDPO 的精确零点都对应

$$\pi_\theta(\cdot \mid s) = \pi^\star_{k+1}(\cdot \mid s).$$

它们的有限样本或有限参数更新不同，来自投影测度、target 常数的处理、score 是否中心化以及 MDPO 的 action ratio，而不是来自不同的 token-level mirror 最优解。

证明 PMD-Part 的结论由 $u_\theta = h_k = u^\star_k$ 直接得到。BPO 的零点由上面的 residual 方程给出；归一化唯一确定 $c_k = -\log Z_k$，从而 $u_\theta = u^\star_k$。PMD-Mean 的可行集包含所有满足 $\mathbb{E}_{\pi_k}[e^u \mid s] = 1$ 的 log-ratio；当中心化 target 可实现且投影残差为零时，它也得到同一 $u^\star_k$。对 MDPO，式(2.34)正是式(2.20)的参数化版本，利用 KL 分解可写成

$$\mathcal{J}_{k,\mathrm{MDPO}}(\theta) = \frac{1}{\eta}\log Z_k(s) - \frac{1}{\eta}\mathrm{KL}(\pi_\theta \| \pi^\star_{k+1}),$$

所以唯一最大点为 $\pi_\theta = \pi^\star_{k+1}$。若中心化 target 不可行或模型类受限，PMD-Mean 的解是约束集合上的投影，此时只能保证投影误差而不能保证精确 Gibbs 解。

2.3.4 inner 求解与 outer 更新的区别

式(2.20)是 outer 第 k 步要解决的目标，不能把它和参数优化步数混为一谈。实际学生只能表示 π_θ，因此固定行为策略 π_k 后，inner 优化是在同一批 prefix 上最小化

$$\mathcal{L}_k(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_{\mathrm{replay}},\, a\sim\pi_k(\cdot|s)}\left[\log\frac{\pi^\star_{k+1}(a \mid s)}{\pi_k(a \mid s)} - \log\frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right]^2. \tag{2.37}$$

若 inner 被精确求解，得到 $\pi_\theta = \pi^\star_{k+1}$；若只做有限次 SGD，得到的是近似解 $\widehat{\pi}_{k+1}$，其误差会进入 outer 迭代的误差项。因而一个完整的 outer step 是：冻结 π_k，构造 f_k，用 replay 中丰富的 prefix 近似 d_{π_k} 或其覆盖测度，进行若干 inner 更新，得到 $\widehat{\pi}_{k+1}$，然后令 $\pi_{k+1} \leftarrow \widehat{\pi}_{k+1}$ 并重新采样或继续积累数据。

命题 2.3 (有限 inner 误差的 projective outer 递推)

对每个 prefix 定义 log-ratio 振幅

$$\Delta_k(s) = \max_a \log\frac{\pi_k(a \mid s)}{T(a \mid s)} - \min_a \log\frac{\pi_k(a \mid s)}{T(a \mid s)}.$$

若精确 mirror 解被有限 inner 优化替换为 $\widehat{\pi}_{k+1}$，定义其 projective 误差为 $\zeta_k(s)$，使得

$$\Delta(\widehat{\pi}_{k+1}, T; s) \le (1-\eta)\Delta_k(s) + \zeta_k(s).$$

则

$$\Delta_{k+1}(s) \le (1-\eta)\Delta_k(s) + \zeta_k(s). \tag{2.38}$$

因此若 $\limsup_k \zeta_k(s) \le \zeta_\infty(s)$，则

$$\limsup_{k\to\infty} \Delta_k(s) \le \frac{\zeta_\infty(s)}{\eta}.$$

证明 精确 mirror 解满足式(2.39)。有限 inner 误差的定义直接给出三角型递推式(2.38)。递推展开后，初始项按 $(1-\eta)^k$ 衰减，误差项由几何级数控制：

$$\sum_{j=0}^{k-1}(1-\eta)^j \zeta_{k-1-j}(s) \le \frac{\sup_{j\ge k_0}\zeta_j(s)}{\eta} + o(1).$$

取上极限即得结论。

2.3.4.0.1 关于 L_1 距离。 上述 projective 递推是无条件成立的；若进一步假设所有迭代满足 $m \le \pi_k(a \mid s)/T(a \mid s) \le M$，则归一化和有限 action space 将 projective 误差连续地转化为 L_1 误差，从而得到相应的 L_1 几何收敛界。没有这样的概率比上下界时，不能直接把 $1-\eta$ 写成任意 L_1 距离的收缩系数。令

$$\Delta_k(s) = \max_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \min_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)},$$

则精确满足

$$\Delta_{k+1}(s) = (1-\eta)\Delta_k(s). \tag{2.39}$$

由 $\mathbb{E}_T[\pi_k/T] = 1$，$\Delta_k \to 0$ 蕴含 $\pi_k \to T$。文中的 L_1 递推应理解为在概率比有统一上下界时的推论；否则应优先使用式(2.39)。

2.3.5 为什么 inner 需要多步：从精确 KL 几何到 Natural Gradient

前面的 mirror 解是在策略分布空间中定义的，而实际训练变量是神经网络参数 θ。因此需要把“固定一个 outer target 后的 inner 优化”从分布空间搬到参数空间。下面先不假设局部二次模型，而是从 softmax 参数化和 KL 的定义逐步展开。

固定一个 prefix s，令 $z_\theta(s) \in \mathbb{R}^{|\mathcal{A}|}$ 为学生 logits，$\pi_\theta(\cdot \mid s) = \mathrm{softmax}(z_\theta(s))$。在第 k 个 outer step 中冻结 π_k 和 r_k，把 inner 的镜像目标写成最小化形式

$$\mathcal{J}_k(\theta) = -\mathbb{E}_{s,a}[r_k(s,a)] + \frac{1}{\eta}\mathbb{E}_s[\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s))], \tag{2.40}$$

其中 $\mathbb{E}_{s,a}$ 的 action 测度可以是 π_θ、π_k 或 replay 加权测度；下文的局部曲率只要求该测度固定且具有有限二阶矩。

2.3.5.0.1 第一步：logit 空间的 KL 一阶项消失。 令 $\delta z = z_\theta - z_{\theta_k}$，其中 $\pi_{\theta_k} = \pi_k$。对固定的行为分布 $q = \pi_k$ 定义

$$K(z) = \mathrm{KL}(\mathrm{softmax}(z)\|q).$$

直接对 softmax 的 log-partition 展开：

$$K(z_k + \delta z) = \sum_a p_a \log p_a - \sum_a p_a \log q_a, \qquad p = \mathrm{softmax}(z_k + \delta z).$$

因为 $p = \pi_k = q$ 时 KL 取全局最小值，$\nabla_z K(z_k) = 0$。进一步使用

$$\frac{\partial p_a}{\partial z_b} = p_a(\mathbf{1}\{a=b\} - p_b)$$

可得 Hessian

$$\nabla_z^2 K(z_k) = F_k(s) = \mathrm{Diag}(\pi_k) - \pi_k\pi_k^\top. \tag{2.41}$$

F_k 是 categorical policy 的 Fisher 矩阵，半正定且零空间由所有常数 logit 平移张成。因此

$$\mathrm{KL}(\pi_\theta\|\pi_k) = \frac{1}{2}\delta z^\top F_k \delta z + R_{\mathrm{KL}}(\delta z), \qquad |R_{\mathrm{KL}}(\delta z)| \le C_{\mathrm{KL}}\|\delta z\|^3 \tag{2.42}$$

在 logits 位于有界集合时成立。这个三阶余项来自 softmax 的三阶导数有界，而不是额外的二元 KL 假设。

2.3.5.0.2 第二步：reward 项的一阶展开。 令

$$\ell_k(\theta) = -\mathbb{E}_{s,a}[r_k(s,a)]$$

表示最小化目标中的 reward 部分。假设 ℓ_k 在 θ_k 邻域内二阶可微，则

$$\ell_k(\theta_k + \Delta\theta) = \ell_k(\theta_k) - b_k^\top \Delta\theta + R_r(\Delta\theta), \qquad b_k = \mathbb{E}_{s,a}[r_k(s,a)\nabla_\theta \log \pi_{\theta_k}(a \mid s)], \tag{2.43}$$

并且 $|R_r(\Delta\theta)| \le C_r\|\Delta\theta\|^2$。这里 b_k 是固定 outer target 在当前学生处的 policy-gradient 方向；如果使用 PMD-Part 或 BPO 的回归 loss，则 b_k 被相应的 regression score 替代，但 KL 曲率项相同。

2.3.5.0.3 第三步：从 logits Jacobian 得到参数空间曲率。 令

$$J_k(s) = \left.\frac{\partial z_\theta(s)}{\partial \theta}\right|_{\theta=\theta_k}.$$

由

$$\delta z = J_k(s)\Delta\theta + R_z(\Delta\theta), \qquad \|R_z(\Delta\theta)\| \le C_z\|\Delta\theta\|^2,$$

把式(2.42) 代入式(2.40)，得到

$$\mathbb{E}_s\,\mathrm{KL}(\pi_\theta\|\pi_k) = \frac{1}{2}\Delta\theta^\top A_k \Delta\theta + R_{\mathrm{par}}(\Delta\theta), \qquad A_k = \mathbb{E}_s[J_k(s)^\top F_k(s) J_k(s)], \tag{2.44}$$

其中 $|R_{\mathrm{par}}(\Delta\theta)| \le C\|\Delta\theta\|^3$。因此式(2.45) 不是直接假设，而是式(2.44) 与式(2.43) 合并后，在 $\Delta\theta$ 足够小时的二阶主项：

$$\mathcal{J}_k(\theta_k + \Delta\theta) = \mathcal{J}_k(\theta_k) + \frac{1}{2\eta}\Delta\theta^\top A_k \Delta\theta - b_k^\top \Delta\theta + R_k(\Delta\theta). \tag{2.45}$$

命题 2.4 (局部曲率的正半定性与不可辨识方向)

A_k 对称半正定。若某个参数方向 v 满足 $J_k(s)v$ 对所有 replay prefix 都是常数 logit 平移，则 $A_k v = 0$；该方向不改变策略分布，因而 KL 不能为它提供曲率。若在商空间上 $A_k \succeq mI$，则镜像 inner 目标在该商空间局部强凸。

证明 对任意 v，

$$v^\top A_k v = \mathbb{E}_s[(J_k(s)v)^\top F_k(s)(J_k(s)v)] \ge 0$$

由 $F_k \succeq 0$ 成立。F_k 的零空间正是常数向量方向，所以 $J_k(s)v$ 为常数时对应二次型为零。去除这些不改变策略的参数方向后，若最小特征值至少为 $m > 0$，则二次项给出局部强凸性。

Mirror Descent 与普通梯度的离散动力学

在 tabular prefix、教师分布固定且 inner 可以精确求解的情形，mirror outer 更新是

$$\pi_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)\exp(\eta f_k(s,a))}{\sum_{a'}\pi_k(a' \mid s)\exp(\eta f_k(s,a'))}.$$

对任意固定的 f_k，当 $\eta \to 0$ 时展开分子和分母：

$$\pi_{k+1}(a \mid s) = \pi_k(a \mid s)\left[1 + \eta\left(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]\right)\right] + O(\eta^2). \tag{2.46}$$

右侧的一阶项

$$\pi_k(a \mid s)\left(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]\right)$$

正是 Fisher–Rao 度量下 $\mathbb{E}_\pi[f_k]$ 的 Natural Gradient。于是 mirror step 与 Natural Gradient 的关系是：Natural Gradient 是 mirror step 在 $\eta = 0$ 处的一阶 Euler 近似；有限 η 时，mirror step 还保留了指数归一化和正性约束，不能被普通加法更新完全替代。

对 OPD 的 $f_k = \log(T/\pi_k)$，可以把这一关系写得更具体。定义

$$\rho_k(a \mid s) = \log \frac{\pi_k(a \mid s)}{T(a \mid s)}.$$

精确 mirror 更新满足

$$\rho_{k+1}(a \mid s) = (1-\eta)\rho_k(a \mid s) - \log Z_k(s).$$

因此任意两个 action 的 log-ratio 差满足

$$\rho_{k+1}(a \mid s) - \rho_{k+1}(a' \mid s) = (1-\eta)\left[\rho_k(a \mid s) - \rho_k(a' \mid s)\right]. \tag{2.47}$$

这给出精确的 projective 收缩率 $1-\eta$，不需要局部二次近似。

相比之下，若直接在概率单纯形上使用未预条件的 Euclidean policy-gradient Euler 步，得到

$$\pi^{\mathrm{E}}_{k+1}(a \mid s) = \pi_k(a \mid s)\left[1 + \alpha\left(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]\right)\right]. \tag{2.48}$$

为了保持每个 action 的概率非负，必须额外满足

$$1 + \alpha\left(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]\right) \geq 0 \quad \text{对所有} a.$$

这个限制依赖当前 reward 的最大幅度；当 teacher/student ratio 很尖锐时，可行步长会变得很小。式(2.48) 只有在 $\alpha = \eta$ 且忽略 $O(\eta^2)$ 项时才与式(2.46) 相同，有限步时没有式(2.47) 的精确收缩性质。

定理 2.3 (OPD 中 mirror outer 与 Natural Gradient 的等价边界)

在固定 prefix、可表示的 tabular policy 和精确 Fisher 矩阵条件下，mirror outer step 与 Natural Gradient 满足：

1. 分布空间的一阶等价：式(2.46) 的一阶项等于 Fisher–Rao Natural Gradient；
2. 参数空间的局部等价：若 π_θ 在 θ_k 附近可微，且使用 A_k 的精确逆，则

$$\theta^{\mathrm{NG}}_{k+1} = \theta_k + \eta A_k^\dagger b_k + O(\eta^2)$$

与 mirror 解的参数表示一致到一阶；

3. 有限步不等价：mirror 更新是指数族闭式解，Natural Gradient 是参数空间的线性步；除非策略族对该指数更新封闭，否则二者在 $O(\eta^2)$ 项开始不同。

♡

证明 第一点由式(2.46) 直接得到。第二点中，局部目标的梯度为 $-b_k$，KL Hessian 为 A_k/η，因此局部最优位移满足 $\Delta\theta = \eta A_k^\dagger b_k$；这正是 Natural Gradient 的 Fisher 预条件方向。第三点来自指数更新的二阶项：

$$\pi_{k+1} = \pi_k + \eta\ \mathrm{grad}_{\mathrm{FR}}\,\mathbb{E}_{\pi_k}[f_k] + O(\eta^2),$$

而参数 Natural Gradient 的 Euler 步只保留一阶项。一般神经网络策略族不对指数映射封闭，所以不能把有限步 Natural Gradient 视为精确 mirror step。

有限 inner 步的收敛条件

定义局部主模型

$$Q_k(\Delta\theta) = \frac{1}{2\eta}\Delta\theta^{\mathsf{T}} A_k \Delta\theta - b_k^{\mathsf{T}}\Delta\theta.$$

若 b_k 属于 A_k 的值域，则其最小范数解为

$$\Delta\theta_k^\star = \eta A_k^\dagger b_k.$$

使用普通梯度下降、步长 $\gamma > 0$：

$$\Delta\theta_{m+1} = \Delta\theta_m - \gamma\nabla Q_k(\Delta\theta_m) = (I - \gamma A_k/\eta)\Delta\theta_m + \gamma b_k. \tag{2.49}$$

定理 2.4 (由 KL 曲率推出的 inner 线性收敛)

设 A_k 在商空间上的特征值属于 $[m_k, M_k]$，且 $0 < m_k \le M_k$。若

$$0 < \gamma < \frac{2\eta}{M_k},$$

则式(2.49) 收敛到 $\Delta\theta_k^\star$，并满足

$$\|\Delta\theta_m - \Delta\theta_k^\star\|_{A_k} \le q_k^m \|\Delta\theta_0 - \Delta\theta_k^\star\|_{A_k}, \qquad q_k = \max_{\lambda\in[m_k,M_k]} \left|1 - \frac{\gamma\lambda}{\eta}\right| < 1.$$

特别地，取 $\gamma = 2\eta/(m_k + M_k)$ 时，

$$q_k = \frac{M_k - m_k}{M_k + m_k} = \frac{\kappa_k - 1}{\kappa_k + 1}, \qquad \kappa_k = M_k/m_k.$$

♡

证明 令 $e_m = \Delta\theta_m - \Delta\theta_k^\star$。由式(2.49)，

$$e_{m+1} = (I - \gamma A_k/\eta) e_m.$$

在 A_k 的特征方向 λ 上，误差乘以 $1 - \gamma\lambda/\eta$。给定步长条件，所有这些因子的绝对值都小于 1，因此得到 q_k^m 的界。令两个端点方向的绝对收缩率相等即可得到最优固定步长和最后的条件数表达式。

真实 inner 目标还包含余项 R_k。若其梯度在半径 r 的邻域满足

$$\|\nabla R_k(\Delta\theta)\| \le L_k \|\Delta\theta\|^2,$$

并且 r 足够小使得 $L_k r \le m_k/(2\eta)$，则真实 Hessian 的特征值仍落在

$$[m_k/(2\eta),\ M_k/\eta + L_k r]$$

内。于是标准强凸光滑函数的梯度下降结论仍成立，只是收缩率由上述扩大后的光谱区间决定。这给出了“inner 需要做到局部收敛”的明确条件：步长必须由 KL/Fisher 曲率控制，且迭代必须停留在二阶展开有效的信赖域内。

Natural Gradient 的来源与作用

普通梯度在参数坐标中使用 A_k 的谱，病态方向的收敛速度由 κ_k 决定。Natural Gradient 以 Fisher 度量约束一次更新：

$$\min_{\Delta\theta} \ -b_k^\top \Delta\theta \quad \text{s.t.} \quad \frac{1}{2}\Delta\theta^\top A_k \Delta\theta \le \frac{\eta}{2}. \tag{2.50}$$

拉格朗日一阶条件给出

$$\Delta\theta_{\mathrm{NG}} = c\, A_k^\dagger b_k,$$

其中常数 c 由 trust-region 半径确定。若直接取 $\Delta\theta = \eta A_k^\dagger b_k$，它正是局部二次模型的最小点；实际算法用 Fisher 近似 $\widehat{A}_k$、阻尼 λI 和有限 inner 步，因此得到的是近似自然梯度，而不是理论上无条件的一步收敛。

命题 2.5 (Natural Gradient 对参数重参数化的不变性)

设 $\vartheta = \phi(\theta)$ 是局部可逆的光滑重参数化，且 Fisher 矩阵按张量变换规则变换。则更新方向

$$\mathcal{F}_\theta^\dagger \nabla_\theta \mathcal{J}_k$$

与在 ϑ 坐标中计算后映射回 θ 的方向一致；普通梯度 $\nabla_\theta \mathcal{J}_k$ 一般不具备该性质。

♠

证明 令 $B = \partial\vartheta/\partial\theta$。梯度变换为 $\nabla_\theta \mathcal{J} = B^\top \nabla_\vartheta \mathcal{J}$，Fisher 变换为 $\mathcal{F}_\theta = B^\top \mathcal{F}_\vartheta B$。在可逆子空间上代入并使用伪逆的相应变换，得到

$$\mathcal{F}_\theta^\dagger \nabla_\theta \mathcal{J} = B^{-1} \mathcal{F}_\vartheta^\dagger \nabla_\vartheta \mathcal{J}.$$

普通梯度只含 $B^\top$，因此会随坐标尺度改变。

这解释了 MDPO 和 EffOPD 中的两个实现判断。只在 θ_k 处做一次梯度步时，KL 的一阶梯度为零，trust-region 曲率尚未进入更新；固定 π_k 并执行多次 inner 更新，才能逼近式(2.40)。Natural Gradient 进一步把步长按照 A_k

的几何尺度归一化，但它仍然需要信赖域、阻尼和有限 inner 预算来处理模型非线性与 Fisher 估计误差。

2.3.5.0.4 几何中间分布与算术 proximal teacher 的区别。 式(2.22) 给出的 $\pi_k^{1-\eta}T^\eta/Z_k$ 是 KL 镜像子问题的精确解，因此在 log-probability 空间插值。TOP-D 中的算术 teacher

$$\widetilde{T}_\eta = (1-\eta)\pi_k + \eta T$$

是另一个用于控制 log-ratio 方差的 teacher operator。它同样产生 student 与 teacher 之间的中间分布，但不等价于 KL mirror 解；前者改变 target teacher，后者改变 proximal 优化问题的解。

2.3.6 OPD 的 off-policy prefix 复用

OPD的优势在于教师可以在学生访问到的 prefix 上提供稠密 token 信号。设 replay 测度为 d_b，只要 $d_{\pi_k} \ll d_b$，outer mirror 目标可以写成

$$\mathbb{E}_{s\sim d_{\pi_k}}[\ell_k(s)] = \mathbb{E}_{s\sim d_b}\left[W_{<t}(s)\ell_k(s)\right], \qquad W_{<t}(s) = \frac{d_{\pi_k}(s)}{d_b(s)}. \tag{2.51}$$

PMD-Part、PMD-Mean 和 BPO 在 action 层都可用 $a \sim \pi_k(\cdot \mid s)$ 的样本完成回归，不需要额外 action-level IS；off-policy 的主要问题转移到 prefix 访问测度 $W_{<t}$。若把 d_b 当作固定投影测度而不做 $W_{<t}$，得到的是 replay 加权的近似 mirror step，而非严格的 d_{π_k} 加权 outer 目标。这正是 OPD 可以利用状态丰富性、同时需要报告访问测度偏差的地方。

2.4 共享零点、不同梯度的定理

命题 2.6 (四种方法的共享零点)

在有限 action space、$\mu(a \mid s) > 0$ 且策略归一化成立时，PMD-Part、PMD-Mean、未线性化 BPO 与 MDPO 在精确 Gibbs 策略 π^+ 处达到零 residual。PMD-Mean 在其中心化 target 可实现并满足归一化约束时达到同一策略；一般情况下它给出约束集合上的欧氏投影。

证明 PMD-Part 由 $u_\theta = h$ 直接得到 $u_\theta = u^+$。对 BPO，若 $\delta_\theta = 0$，则 $u_\theta = \eta f - C(s)$，其中 $C(s)$ 与 action 无关。归一化给出

$$1 = \mathbb{E}_\mu[e^{u_\theta} \mid s] = e^{-C(s)}\mathbb{E}_\mu[e^{\eta f} \mid s] = e^{-C(s)}Z_f(s),$$

所以 $C(s) = \log Z_f(s)$，即 $u_\theta = u^+$。PMD-Mean 在 target 可实现并满足归一化约束时也取到该策略；不可实现时，它取的是约束集合上的欧氏投影。

定理 2.5 (未线性化 BPO 与 PMD-Part 的梯度差异)

令 $q_\theta = h - u_\theta$，并令

$$c_\theta(s) = \log Z_f(s) + \mathbb{E}_\mu[u_\theta(s,a) \mid s], \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

则 $\delta_\theta = q_\theta + c_\theta$，且

$$-\eta\nabla\mathcal{L}_{\mathrm{BPO}} = -\nabla\mathcal{L}_{\mathrm{Part}} + \mathbb{E}_{s\sim d_\mu}[c_\theta(s)\bar{g}_\theta(s)]. \tag{2.52}$$

因此二者共享零点，但一般不具有相同的梯度场；只有 $c_\theta(s)\bar{g}_\theta(s) = 0$ 对 d_μ-几乎处处成立时才相同。

证明 由 $q_\theta = \eta f - \log Z_f - u_\theta$，而 BPO 使用 $\delta_\theta = \eta f - u_\theta + \mathbb{E}_\mu[u_\theta \mid s]$，相减得到 $\delta_\theta = q_\theta + c_\theta$。另一方面，

$\mathbb{E}_\mu[\delta_\theta \mid s] = 0$，所以

$$\begin{aligned} -\eta \nabla \mathcal{L}_{\mathrm{BPO}} &= \mathbb{E}[\delta_\theta (g_\theta - \bar{g}_\theta)] \\ &= \mathbb{E}[\delta_\theta g_\theta] \\ &= \mathbb{E}[(q_\theta + c_\theta) g_\theta] \\ &= \mathbb{E}[q_\theta g_\theta] + \mathbb{E}[c_\theta \bar{g}_\theta]. \end{aligned}$$

第一项正是 $-\nabla \mathcal{L}_{\mathrm{Part}}$，得到式(2.52)。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu,\mu}[(u_\theta - h)^2], \tag{3.8}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu}\,\mathrm{Var}_{a\sim\mu}[u_\theta(a) - \eta f(a)]. \tag{3.9}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s)\sum_a \nabla\pi(a \mid s)A^\mu(s,a) + \sum_s d_\pi(s)\sum_a \nabla\pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.10}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.11}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.12}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.13}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.