从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward 1
1.2 KL 镜像最优解 1
1.3 即时 reward 与完整序列 reward 2

第二章 统一的 token-level Mirror Descent 与 OPD 实例化 **3**
2.1 共同的 mirror 子问题与精确解 3
2.2 四种 inner 的统一推导 4
2.2.1 PMD-Part：回归完整 Gibbs log-ratio 4
2.2.2 PMD-Mean：中心化 target 与归一化约束 4
2.2.3 BPO：中心化最优性 residual 4
2.2.4 MDPO：直接优化 mirror objective 5
2.3 OPD：从 teacher log-ratio 到 outer–inner 算法 5
2.4 四种 OPD inner 的可执行估计量 6
2.5 Inner 误差、outer 更新与 Natural Gradient 7
2.6 访问测度的最小必要说明 8

第三章 梯度的偏差与方差 **9**
3.1 估计对象必须先固定 9
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 9
3.3 PMD-Part 的投影偏差与 BPO 的中心化方差 10

第四章 实现与参数比较 **12**
4.1 理论对象与实际代码 12
4.2 BPO 论文的训练预算 12
4.3 OpenKimi/PMD 的训练预算 12
4.4 经典 MDPO 的训练预算与 IS 12
4.5 比较时应报告的指标 13

第五章 结论与 MirrorOPD 的边界 **14**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章只使用一套符号。固定第 k 个 outer step 的 anchor policy π_k，候选 student policy 记为 π_θ，teacher policy 记为 T。自然梯度步长统一记为 $\eta > 0$。prefix 记为 s，下一个 token 记为 a，所有条件分布均省略 s 时会在公式中明确补回。四种 inner 的区别只来自求解同一个 mirror 子问题的方式；它们不对应四个不同的 token-level 最优策略。

2.1 共同的 mirror 子问题与精确解

给定固定 prefix s 和 token 信号 $f(s,a)$，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s))\,. \tag{2.1}$$

镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。定义

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^+(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^+(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\big(p\big\|\pi_k^+(\cdot \mid s)\big)\,. \tag{2.4}$$

♡

证明 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^+(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p\|\pi_k^+) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^+$ 时取零，因此最优解唯一。

定义 2.1 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

♣

命题 2.1 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.1) 的最优分布。

♠

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 四种 inner 的统一推导

下面固定一个 prefix，令

$$\ell^T(a) = \log T(a \mid s), \qquad \ell^k(a) = \log \pi_k(a \mid s), \qquad \ell^\theta(a) = \log \pi_\theta(a \mid s).$$

训练时只对 ℓ^θ 反向传播；teacher、anchor、目标常数和所有估计的 KL 都停止梯度。

2.2.1 PMD-Part：回归完整 Gibbs log-ratio

定义显式 target

$$H_k(s,a) = \eta f(s,a) - \log Z_f(s), \qquad U_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \pi_k(a \mid s).$$

PMD-Part 在 anchor 测度下最小化

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k,\, a\sim\pi_k}\left[U_\theta(s,a) - H_k(s,a)\right]^2. \tag{2.5}$$

对 target 停止梯度，链式法则给出

$$-\nabla_\theta \mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_k,\pi_k}\left[H_k(s,a) - U_\theta(s,a)\right]\nabla_\theta \log \pi_\theta(a \mid s). \tag{2.6}$$

这一步是普通的 log-ratio regression；它没有把 KL 视为常数，也没有使用 action-level importance ratio。

2.2.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \ \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.7}$$

约束正是 $\sum_a \pi_\theta(a \mid s) = 1$ 在 log-ratio 坐标中的表达。若把词表上的函数值写为 U_a 和 $G_a = \eta\widetilde{f}_k(s,a)$，拉格朗日函数为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda\left(\sum_a \pi_k(a \mid s)e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda e^{G_a}$，所以

$$U_a = G_a - W\left(\lambda e^{G_a}\right), \tag{2.8}$$

其中 λ 由归一化约束唯一确定。PMD-Mean 因而是中心化 target 在指数归一化集合上的投影；只有当中心化 target 自身满足该约束时，投影才等于精确 Gibbs log-ratio。

2.2.3 BPO：中心化最优性 residual

BPO 不显式回归 $\log Z_f$，而将同一个最优性方程的 action-independent 部分消去。定义

$$D_\theta(s,a) = \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{v\sim\pi_k}[\eta f(s,v) - U_\theta(s,v) \mid s]. \tag{2.9}$$

直接展开可得

$$D_\theta(s,a) = \eta\widetilde{f}_k(s,a) - U_\theta(s,a) + \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v) \mid s].$$

未线性化 BPO 的损失为

$$\mathcal{L}_{\mathrm{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[D_\theta(s,a)^2]. \tag{2.10}$$

由于

$$\nabla_\theta \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v)] = \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s)],$$

所以

$$-\eta\nabla_\theta \mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_k,\pi_k}\left[D_\theta(s,a)\left(\nabla_\theta \log \pi_\theta(a \mid s) - \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s) \mid s]\right)\right]. \tag{2.11}$$

BPO 的 score centering 来自对当前 student–anchor KL 的精确求导；它不是因为先对 reward 做了一个近似。

2.2.4 MDPO：直接优化 mirror objective

MDPO 直接最大化式(2.1) 的参数化版本：

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \frac{1}{\eta}\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.12}$$

完整词表时 KL 是

$$\mathrm{KL}(\pi_\theta\|\pi_k) = \sum_a \pi_\theta(a \mid s)\left[\log \pi_\theta(a \mid s) - \log \pi_k(a \mid s)\right]. \tag{2.13}$$

若 action 从 anchor 采样，定义 $R_\theta(s,a) = \exp(\ell^\theta(a) - \ell^k(a))$，则 action-level IS 形式为

$$\widehat{\mathcal{J}}_{\mathrm{MDPO}} = \mathbb{E}_{a\sim\pi_k}\left[R_\theta(s,a)f(s,a) - \frac{1}{\eta}R_\theta(s,a)\log R_\theta(s,a)\right]. \tag{2.14}$$

其 ascent direction 为

$$\nabla_\theta \mathcal{J}_{\mathrm{MDPO}} = \mathbb{E}_{\pi_k}\left[R_\theta(s,a)\left(f(s,a) - \frac{1}{\eta}\log R_\theta(s,a)\right)\nabla_\theta \log \pi_\theta(a \mid s)\right]. \tag{2.15}$$

额外的 $-R_\theta/\eta$ 项乘以 score 后，在完整 action 求和中因 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$ 消失。MDPO 因而直接优化 mirror objective，其他三种方法优化的是由同一最优性方程构造的 regression objective。

定理 2.2 (四种 inner 的共同精确解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、PMD-Mean、未线性化 BPO 和 MDPO 都以式(2.3) 为精确解。PMD-Mean 的结论要求其投影 target 可实现；参数化 student 或有限样本时，四者得到的是不同的投影或优化误差。

♡

证明 PMD-Part 在零损失处满足 $U_\theta = \eta f - \log Z_f$，于是得到式(2.3)。BPO 的零 residual 只确定 $U_\theta = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_\theta}] = 1$ 得 $C(s) = \log Z_f(s)$。PMD-Mean 若中心化 target 属于归一化约束集合，则其平方投影残差为零，并由中心化不变性得到同一策略。MDPO 由式(2.4) 直接得到唯一最大点。

2.3 OPD：从 teacher log-ratio 到 outer–inner 算法

OPD不引入额外的外部 reward，而在第 k 个 outer step 使用 teacher 与当前 anchor 的局部 log-ratio：

$$r_k(s,a) = \log T(a \mid s) - \log \pi_k(a \mid s). \tag{2.16}$$

它是序列 log-ratio 的逐 token 分解：

$$\sum_{t=1}^{H} r_k(s_t,a_t) = \log T(y \mid x) - \log \pi_k(y \mid x). \tag{2.17}$$

因此 r_k 是对 teacher–student 序列差异的无损分摊，不是一个与 prefix 无关的固定终端 reward。

定义 2.2 (OPD mirror target)

将 $f = r_k$ 代入式(2.3)，定义

$$\pi^\star_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)^{1-\eta}T(a \mid s)^\eta}{Z_k(s)}, \qquad Z_k(s) = \sum_v \pi_k(v \mid s)^{1-\eta}T(v \mid s)^\eta. \tag{2.18}$$

♣

定理 2.3 (OPD mirror step 的几何收敛)

若 $0 < \eta \le 1$，则精确 outer 更新满足

$$\log \frac{\pi^\star_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta) \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \log Z_k(s). \tag{2.19}$$

因此任意两个 action 的 log-ratio 差满足

$$\max_a \log \frac{\pi^\star_{k+1}(a \mid s)}{T(a \mid s)} - \min_a \log \frac{\pi^\star_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta)\Delta_k(s).$$

$\eta = 1$ 时一步得到 T；$0 < \eta < 1$ 时 projective 误差按 $1-\eta$ 几何衰减。

♡

证明 由式(2.18)，

$$\log \frac{\pi^\star_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta) \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \log Z_k(s).$$

减去任意两个 action 的等式，归一化常数抵消，得到 projective 递推。

2.4 四种 OPD inner 的可执行估计量

对第 i 个训练 prefix s_i，采样 K 个 anchor token $y_{ij} \sim \pi_k(\cdot \mid s_i)$，记录

$$\ell^T_{ij} = \log T(y_{ij} \mid s_i), \qquad \ell^k_{ij} = \log \pi_k(y_{ij} \mid s_i), \qquad \ell^\theta_{ij} = \log \pi_\theta(y_{ij} \mid s_i). \tag{2.20}$$

完整词表 logits 给出

$$D^{kT}_i = \sum_v \pi_k(v \mid s_i)[\log \pi_k(v \mid s_i) - \log T(v \mid s_i)], \quad D^{k\theta}_i = \sum_v \pi_k(v \mid s_i)[\log \pi_k(v \mid s_i) - \log \pi_\theta(v \mid s_i)]. \tag{2.21}$$

如果没有完整词表求和，可用同一 prefix 的 sampled estimates

$$\widehat{D}^{kT}_i = K^{-1} \sum_j (\ell^k_{ij} - \ell^T_{ij}), \qquad \widehat{D}^{k\theta}_i = K^{-1} \sum_j (\ell^k_{ij} - \ell^\theta_{ij}),$$

并停止中心量的梯度。以下所有式子都可以逐项实现。

2.4.0.0.1 PMD-Part。

$$\widehat{\mathcal{L}}_{k,\mathrm{Part}} = \frac{1}{2BK} \sum_{i,j} \left[\ell^\theta_{ij} - \ell^k_{ij} - \eta(\ell^T_{ij} - \ell^k_{ij}) + \log Z_k(s_i)\right]^2. \tag{2.22}$$

$$-\widehat{\nabla}\mathcal{L}_{k,\mathrm{Part}} = \frac{1}{BK} \sum_{i,j} \left[\eta(\ell^T_{ij} - \ell^k_{ij}) - \ell^\theta_{ij} + \ell^k_{ij} - \log Z_k(s_i)\right] \nabla_\theta \log \pi_\theta(y_{ij} \mid s_i). \tag{2.23}$$

2.4.0.0.2 PMD-Mean。

$$\widehat{\mathcal{L}}_{k,\mathrm{Mean}} = \frac{1}{2BK} \sum_{i,j} \left[\ell^\theta_{ij} - \ell^k_{ij} - \eta(\ell^T_{ij} - \ell^k_{ij} + D^{kT}_i)\right]^2, \tag{2.24}$$

$$-\widehat{\nabla}\mathcal{L}_{k,\mathrm{Mean}} = \frac{1}{BK} \sum_{i,j} \left[\eta(\ell^T_{ij} - \ell^k_{ij} + D^{kT}_i) - \ell^\theta_{ij} + \ell^k_{ij}\right] \nabla_\theta \log \pi_\theta(y_{ij} \mid s_i). \tag{2.25}$$

2.4.0.0.3 BPO。

$$\widehat{\delta}_{ij} = \eta(\ell^T_{ij} - \ell^k_{ij} + D^{kT}_i) - \left(\ell^\theta_{ij} - \ell^k_{ij} + D^{k\theta}_i\right). \tag{2.26}$$

$$\widehat{\mathcal{L}}_{k,\mathrm{BPO}} = \frac{1}{2\eta BK} \sum_{i,j} \widehat{\delta}^2_{ij}, \tag{2.27}$$

$$-\eta\widehat{\nabla}\mathcal{L}_{k,\mathrm{BPO}} = \frac{1}{BK} \sum_{i,j} \widehat{\delta}_{ij} \left[\nabla_\theta \log \pi_\theta(y_{ij} \mid s_i) - \sum_v \pi_k(v \mid s_i) \nabla_\theta \log \pi_\theta(v \mid s_i)\right]. \tag{2.28}$$

实际 sampled 实现把第二项替换为 $K^{-1}\sum_{\ell}\nabla_\theta \log \pi_\theta(y_{i\ell} \mid s_i)$，并把 $D_i^{k\theta}$ 替换为停止梯度的 $\widehat{D}_i^{k\theta}$。

2.4.0.0.4 MDPO。 令 $R_{ij}^\theta = \exp(\ell_{ij}^\theta - \ell_{ij}^k)$。anchor token 样本上的 objective 与 ascent estimator 分别为

$$\widehat{\mathcal{J}}_{k,\mathrm{MDPO}} = \frac{1}{BK}\sum_{i,j} R_{ij}^\theta \left[(\ell_{ij}^T - \ell_{ij}^k) - \frac{1}{\eta}(\ell_{ij}^\theta - \ell_{ij}^k)\right], \tag{2.29}$$

$$\widehat{\nabla}\mathcal{J}_{k,\mathrm{MDPO}} = \frac{1}{BK}\sum_{i,j} R_{ij}^\theta \left[(\ell_{ij}^T - \ell_{ij}^k) - \frac{1}{\eta}(\ell_{ij}^\theta - \ell_{ij}^k)\right] \nabla_\theta \log \pi_\theta(y_{ij} \mid s_i). \tag{2.30}$$

命题 2.2 (PMD-Mean、BPO 与 PMD-Part 的差异)

三者共享式(2.3) 的精确零点，但有限步梯度一般不同。PMD-Mean 使用 $\eta\widetilde{f}_k - U_\theta$ 乘以 ordinary student score；BPO 使用

$$D_\theta = \eta\widetilde{f}_k - U_\theta + \mathbb{E}_{\pi_k}[U_\theta]$$

乘以 centered student score。二者只有在

$$\mathbb{E}_{\pi_k}[U_\theta] = 0, \qquad \mathbb{E}_{\pi_k}[\nabla \log \pi_\theta] = 0$$

同时成立时才给出相同梯度。

证明 将 D_θ 与 PMD-Mean residual 相减得到

$$D_\theta - (\eta\widetilde{f}_k - U_\theta) = \mathbb{E}_{\pi_k}[U_\theta].$$

BPO 的 score 由 D_θ 对 student 参数求导产生，正好是 ordinary score 减去其 anchor 均值。代入两式并展开，差异由上述两个 action-independent 项的乘积给出；它们并非由策略归一化自动消失，因为归一化只保证 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$。

2.5 Inner 误差、outer 更新与 Natural Gradient

一个 outer step 先冻结 π_k 和 teacher T，再用上面的任一 inner objective 更新 student 参数 M 次，最后令 $\pi_{k+1} = \pi_{\theta_M}$。$M$ 是优化预算，不等于数学上的精确收敛；精确解是式(2.18)。

命题 2.3 (有限 inner 误差的 outer 递推)

令 $\Delta_k(s)$ 为式(2.19) 左侧的 projective 振幅。若第 k 步 inner 产生的 student 满足

$$\Delta_{k+1}(s) \le (1-\eta)\Delta_k(s) + \varepsilon_k(s),$$

则

$$\Delta_k(s) \le (1-\eta)^k \Delta_0(s) + \sum_{j=0}^{k-1}(1-\eta)^j \varepsilon_{k-1-j}(s).$$

若 $\sup_k \varepsilon_k(s) \le \bar{\varepsilon}(s)$，则

$$\limsup_{k\to\infty} \Delta_k(s) \le \bar{\varepsilon}(s)/\eta.$$

证明 对递推式反复代入即可得到有限 k 的展开。几何级数满足 $\sum_{j\ge 0}(1-\eta)^j = 1/\eta$，取上极限得到结论。

在参数空间，mirror objective 的 KL 项在 θ_k 附近具有 Fisher 曲率。若 $z_\theta(s)$ 是 student logits，$F_k(s) = \mathrm{Diag}(\pi_k) - \pi_k\pi_k^\top$，则

$$\mathrm{KL}(\pi_\theta \| \pi_k) = \frac{1}{2}\Delta z^\top F_k \Delta z + O(\|\Delta z\|^3).$$

因此在信赖域足够小且使用 Fisher 预条件时，mirror outer step 的一阶参数更新是 natural-gradient step；普通 SGD 只沿欧氏坐标梯度移动，步长会随参数化和分布熵改变，而 natural gradient 按局部 KL 几何校准。这里的等价性是局部一阶等价，不意味着任意 AdamW 训练都等于精确 mirror update。

2.6 访问测度的最小必要说明

上面的 inner 公式默认 prefix 按 d_{π_k} 采样。若训练数据来自另一个 replay prefix measure ν，定义 Radon–Nikodym 权重

$$\Omega_k(s) = \frac{d_{\pi_k}(s)}{d_\nu(s)}.$$

对任何只依赖当前 (s, a) 的 inner integrand $Y(s, a)$，有

$$\mathbb{E}_{s\sim d_{\pi_k},\, a\sim\pi_k}[Y(s,a)] = \mathbb{E}_{s\sim d_\nu,\, a\sim\pi_k}[\Omega_k(s)Y(s,a)]. \tag{2.31}$$

这说明 prefix 权重只负责把访问测度从 replay 移回 anchor；它不改变四种 inner 的 token-level 公式。对于局部 OPD reward，不需要额外乘后缀权重；只有当目标改成终端序列 return 时，才应重新推导完整的 sequence importance sampling。

注本章把 replay 的访问信息统一写成目标 prefix 测度 d_{π_k}、数据 prefix 测度 d_ν 及其比值 Ω_k；该比值只修正 prefix 访问测度，与 MDPO 的 action ratio 分开定义。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu,\mu}[(u_\theta - h)^2], \tag{3.8}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu}\,\mathrm{Var}_{a\sim\mu}[u_\theta(a) - \eta f(a)]. \tag{3.9}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s)\sum_a \nabla\pi(a \mid s)A^\mu(s,a) + \sum_s d_\pi(s)\sum_a \nabla\pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.10}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.11}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.12}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.13}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.