从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward 1
1.2 KL 镜像最优解 1
1.3 即时 reward 与完整序列 reward 2

第二章 四种方法从最优解出发的推导 **3**
2.1 共同起点：同一个镜像子问题如何产生两个 residual 3
2.2 PMD-Part：回归最优 log-ratio 4
2.3 PMD-Mean：中心化回归与 Lambert-W 4
2.4 MDPO：直接优化 KL 正则化目标 5
2.5 BPO：从 token 最优性到实际 PG surrogate 5

第三章 梯度的偏差与方差 **7**
3.1 估计对象必须先固定 7
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 7
3.3 未线性化 BPO：与 PMD-Part 的梯度差异定理 8
3.4 为什么同为 token-level 仍然不等价 9
3.5 PMD-Part 的投影偏差与 BPO 的中心化方差 10

第四章 实现与参数比较 **12**
4.1 理论对象与实际代码 12
4.2 BPO 论文的训练预算 12
4.3 OpenKimi/PMD 的训练预算 12
4.4 经典 MDPO 的训练预算与 IS 12
4.5 比较时应报告的指标 13

第五章 结论与 MirrorOPD 的边界 **14**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 四种方法从最优解出发的推导

2.1 共同起点：同一个镜像子问题如何产生两个 residual

固定 prefix s，把行为策略简写为 $\mu(a)$，把候选策略简写为 $\pi(a)$，并令 $u(a) = \log(\pi(a)/\mu(a))$。统一采用 Natural Gradient 学习率 η，镜像子问题为

$$\max_{p \ll \mu} \left\{ \mathbb{E}_p[f] - \frac{1}{\eta} \mathrm{KL}(p\|\mu) \right\}. \tag{2.1}$$

对任意 p，定义

$$Z_f = \mathbb{E}_\mu[e^{\eta f}], \qquad \pi^+(a) = \frac{\mu(a)e^{\eta f(a)}}{Z_f}.$$

与定理 1.1 相同的 KL 分解给出

$$\mathbb{E}_p[f] - \frac{1}{\eta} \mathrm{KL}(p\|\mu) = \frac{1}{\eta} \log Z_f - \frac{1}{\eta} \mathrm{KL}(p\|\pi^+).$$

因此最优策略满足

$$u^+(a) = \log \frac{\pi^+(a)}{\mu(a)} = \eta f(a) - \log Z_f. \tag{2.2}$$

这一步是 PMD-Part 与 BPO 的共同起点，尚未引入任何线性化、clip 或重要性采样。

PMD-Part 直接把式(2.2) 当作逐 action 的回归方程。定义

$$q(a) := u^+(a) - u(a) = \underbrace{\eta f(a) - \log Z_f}_{h(a)} - u(a). \tag{2.3}$$

所以 PMD-Part 的平方损失就是 $q(a)^2/2$ 的行为测度平均。

BPO 采用同一个最优性方程的“常数消除”形式。令

$$b(a) := \eta f(a) - u(a).$$

在行为优势满足 $\mathbb{E}_\mu[f] = 0$ 时，

$$\begin{aligned} \mathbb{E}_\mu[b] &= \eta \mathbb{E}_\mu[f] - \mathbb{E}_\mu[u] \\ &= -\mathbb{E}_\mu[u] \\ &= \mathrm{KL}(\mu\|\pi). \end{aligned}$$

于是 BPO 的 centered residual 是

$$\delta(a) := b(a) - \mathbb{E}_\mu[b] = \eta f(a) - u(a) - \mathrm{KL}(\mu\|\pi) = \eta f(a) - u(a) + \mathbb{E}_\mu[u]. \tag{2.4}$$

它等价于把同一个最优性方程中的 action-independent 常数先减去行为均值。

两种 residual 的零点仍然相同。若 $\delta(a) = 0$ 对所有有正行为概率的 action 成立，则 $u(a) = \eta f(a) - C$，其中 C 与 action 无关。策略归一化要求

$$1 = \mathbb{E}_\mu[e^u] = e^{-C} \mathbb{E}_\mu[e^{\eta f}] = e^{-C} Z_f,$$

所以 $C = \log Z_f$，从而 $u = u^+$。反过来，若 $u = u^+$，则 $b(a) = \log Z_f$ 为常数，故 $\delta(a) = 0$。因此 BPO 和 PMD-Part 由同一个镜像最优解出发，并共享同一个可实现零点；它们的差别只出现在对这个最优性方程采用的残差和参数梯度上。

2.2 PMD-Part：回归最优 log-ratio

定义 $u_\theta(s,a) = \log \pi_\theta(a \mid s)/\mu(a \mid s)$，并令

$$h(s,a) = \eta f(s,a) - \log Z_f(s).$$

PMD-Part 在行为测度下回归精确最优性方程：

$$\mathcal{L}_{\mathrm{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_\mu,\, a\sim\mu}\left[u_\theta(s,a) - h(s,a)\right]^2. \tag{2.5}$$

把 target h 和行为策略视为固定，记 $g_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s)$，则

$$-\nabla_\theta \mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{d_\mu \mu}\left[(h - u_\theta) g_\theta\right]. \tag{2.6}$$

命题 2.1 (PMD-Part 的零点)

在无限容量、正访问权重和满 action support 下，$\mathcal{L}_{\mathrm{Part}} = 0$ 当且仅当 $\pi_\theta(\cdot \mid s) = \pi^+(\cdot \mid s)$ 对 d_μ-几乎处处的 prefix 成立。

证明 平方损失为非负数。它为零当且仅当 $u_\theta = h$ 在行为测度下几乎处处成立。指数化并使用式(1.3) 即得 $\pi_\theta = \pi^+$。反向蕴含显然成立。

PMD-Part 的重要性质是目标中没有 ratio 权重; ratio 只出现在被拟合的 log-ratio 中。因此它避免了直接 policy gradient 的乘法重尾，但有限模型下它优化的是 d_μ 加权的投影。

2.3 PMD-Mean：中心化回归与 Lambert-W

令

$$\bar{f}(s) = \mathbb{E}_{a\sim\mu}[f(s,a) \mid s], \qquad g(s,a) = \eta\left(f(s,a) - \bar{f}(s)\right).$$

PMD-Mean不显式估计 $\log Z_f(s)$，而求解

$$\min_u \ \frac{1}{2}\mathbb{E}_{s\sim d_\mu, a\sim\mu}[(u-g)^2] \quad \text{s.t.} \quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}] = 1 \quad \forall s. \tag{2.7}$$

约束是策略归一化，而不是可省略的附加条件。

定理 2.1 (PMD-Mean 的逐 prefix 解)

在有限 action space、$\mu(a \mid s) > 0$ 和可行条件下，式(2.7) 的 KKT 解满足

$$u^+(s,a) = g(s,a) - W\left(\lambda(s) e^{g(s,a)}\right), \tag{2.8}$$

其中 $\lambda(s) \geq 0$ 由 $\mathbb{E}_\mu[e^{u^+(s,\cdot)} \mid s] = 1$ 唯一确定。

证明 固定 prefix s，记行为概率为 $\mu_a = \mu(a \mid s)$，并把 $g_a = g(s,a)$。由于 action space 有限且 $\mu_a > 0$，该问题是严格凸目标加凸归一化约束；因此满足 KKT 条件的解就是唯一全局解。其拉格朗日函数为

$$\mathcal{J}(u,\lambda) = \frac{1}{2}\sum_a \mu_a (u_a - g_a)^2 + \lambda\left(\sum_a \mu_a e^{u_a} - 1\right).$$

对每个 u_a 求偏导，并利用 $\mu_a > 0$，得到

$$0 = \frac{1}{\mu_a}\frac{\partial \mathcal{J}}{\partial u_a} = u_a - g_a + \lambda e^{u_a}.$$

令 $v_a = g_a - u_a$，则 $u_a - g_a = -v_a$，代入上式并乘以 e^{v_a}：

$$v_a = \lambda e^{g_a - v_a} \quad \Longleftrightarrow \quad v_a e^{v_a} = \lambda e^{g_a}.$$

Lambert-W 函数由 $W(z)e^{W(z)} = z$ 定义，所以

$$v_a = W(\lambda e^{g_a}), \qquad u_a = g_a - W(\lambda e^{g_a}),$$

这就是式(2.8)。剩下的乘子由归一化方程确定。令

$$H(\lambda) = \sum_a \mu_a \exp\left(g_a - W(\lambda e^{g_a})\right).$$

对 $\lambda \geq 0$，每个 $W(\lambda e^{g_a})$ 随 λ 单调增加，因此 H 连续单调下降；可行条件保证存在 λ 使 $H(\lambda) = 1$。严格凸性保证该乘子对应的 u 唯一。

PMD-Part 的修正项 $\log Z_f(s)$ 对 action 是常数，PMD-Mean 的 Lambert-W 项依赖 action。两者只有在退化或额外近似下才相同；它们可以拥有相同的排序和单调改进性质，但不是同一个 mirror subproblem 的两个无偏实现。

2.4 MDPO：直接优化 KL 正则化目标

MDPO直接对式(1.1) 的目标做参数优化。令

$$F_s(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(\pi_\theta\|\mu).$$

对 θ 求导时，先将 KL 写成

$$\mathrm{KL}(\pi_\theta\|\mu) = \mathbb{E}_{a\sim\pi_\theta}[\log\rho_\theta].$$

对第一项使用 score identity，对第二项使用乘积法则：

$$\begin{aligned}\nabla_\theta\mathbb{E}_{\pi_\theta}[f] &= \mathbb{E}_{\pi_\theta}[f g_\theta],\\ \nabla_\theta\mathbb{E}_{\pi_\theta}[\log\rho_\theta] &= \mathbb{E}_{\pi_\theta}[g_\theta\log\rho_\theta] + \mathbb{E}_{\pi_\theta}[\nabla_\theta\log\rho_\theta]\\ &= \mathbb{E}_{\pi_\theta}[g_\theta\log\rho_\theta] + \mathbb{E}_{\pi_\theta}[g_\theta] = \mathbb{E}_{\pi_\theta}[g_\theta\log\rho_\theta],\end{aligned}$$

因为 μ 不依赖 θ，所以 $\nabla_\theta\log\rho_\theta = g_\theta$，且归一化恒等式给出 $\mathbb{E}_{\pi_\theta}[g_\theta] = 0$。因此

$$\nabla F_s = \mathbb{E}_{a\sim\pi}\left[\left(f(s,a) - \frac{1}{\eta}\log\rho_\theta(s,a)\right) g_\theta(s,a)\right]. \tag{2.9}$$

其中 $\rho_\theta = \pi_\theta/\mu$。若样本来自行为策略，则

$$\nabla F_s = \mathbb{E}_{a\sim\mu}\left[\rho_\theta(s,a)\left(f(s,a) - \frac{1}{\eta}\log\rho_\theta(s,a)\right) g_\theta(s,a)\right]. \tag{2.10}$$

这就是 MDPO 中的 action-level IS。若状态也来自 replay 的 d_μ，而目标是 d_π 下的 occupancy 目标，还需要 prefix ratio；经典实现通常把状态测度固定为 replay/rollout 测度，因而没有完整解决 state-distribution mismatch。

命题 2.2 (MDPO 梯度与 PMD-Part 回归梯度的零点一致、方向不一致)

MDPO 的梯度式(2.10) 与 PMD-Part 梯度式(2.6) 在精确镜像解处都为零，但一般不相等。♠

证明 在镜像解处，$\log\rho = \eta f - \log Z_f$，故式(2.9) 为最优目标的驻点；PMD-Part 的 residual $h - u$ 逐点为零。离开镜像解时，MDPO 被积函数包含 ρ_θ 和 $f - \frac{1}{\eta}\log\rho_\theta$，PMD-Part 被积函数只有 $h - u_\theta$，两者测度和残差均不同。

2.5 BPO：从 token 最优性到实际 PG surrogate

BPO 的 token-level PMD 起点与式(1.1) 相同，使用 $f = A^\mu$。在终端奖励情形，论文先定义 token residual

$$d_\pi(s_t,a_t) = \eta A^\mu(s_t,a_t) - \left[\log\frac{\pi(a_t\mid s_t)}{\mu(a_t\mid s_t)} + \mathrm{KL}(\mu(\cdot\mid s_t)\|\pi(\cdot\mid s_t))\right]. \tag{2.11}$$

该 residual 在 $a_t \sim \mu(\cdot\mid s_t)$ 下条件均值为零。BPO 将沿轨迹的 residual 累加成平方回归目标，并证明其零点与 PMD 解一致。

理论上先对 residual 平方损失求梯度；本文件不把 BPO 的 clip、二元 KL 近似或具体 mismatch weight 纳入推导。对逐 prefix 的 token-level residual，完整 reverse KL 的导数是

$$\nabla_\theta\left[\log\rho(a) + \mathrm{KL}(\mu\|\pi)\right] = g(a) - \mathbb{E}_\mu[g(a)]. \tag{2.12}$$

因此 BPO 的未线性化梯度天然包含行为测度下的 score centering；下一章证明它与 PMD-Part 的差异恰好是一个 action-independent 常数乘以行为 score 均值。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 未线性化 BPO：与 PMD-Part 的梯度差异定理

BPO的逐 prefix 残差（取 $f = A^\mu$，故 $\mathbb{E}_\mu[f \mid s] = 0$）写成

$$\delta(a) = \eta f(a) - u(a) - \mathrm{KL}(\mu\|\pi). \tag{3.8}$$

因为 $\mathrm{KL}(\mu\|\pi) = -\mathbb{E}_\mu[u]$，有 $\mathbb{E}_\mu[\delta] = 0$。理论 BPO 损失为

$$\mathcal{L}_{\mathrm{BPO}}^{\mathrm{tok}} = \frac{1}{2\eta}\mathbb{E}_\mu[\delta(a)^2]. \tag{3.9}$$

对完整 reverse KL 求导时

$$\nabla_\theta\,\mathrm{KL}(\mu\|\pi) = -\mathbb{E}_\mu[g(a)] = -\bar{g}, \qquad \bar{g} := \mathbb{E}_\mu[g(a)], \tag{3.10}$$

从而

$$\nabla_\theta\delta(a) = -(g(a) - \bar{g}). \tag{3.11}$$

定理 3.2 (未线性化 BPO 与 PMD-Part 的精确梯度差异)

设 $f = A^\mu$ 满足 $\mathbb{E}_\mu[f \mid s] = 0$，$\log Z_f$ 使用精确配分函数，target、μ 与访问测度均停止梯度。定义

$$h(a) = \eta f(a) - \log Z_f, \qquad q(a) = h(a) - u(a). \tag{3.12}$$

则

$$\delta(a) = q(a) + c_s, \qquad c_s = \log Z_f + \mathbb{E}_\mu[u], \tag{3.13}$$

且

$$-\eta\nabla\mathcal{L}_{\mathrm{BPO}}^{\mathrm{tok}} = \mathbb{E}_\mu[\delta(g-\bar{g})] = \mathbb{E}_\mu[qg] + c_s\bar{g} = -\nabla\mathcal{L}_{\mathrm{Part}}^{(\eta)} + c_s\bar{g}, \tag{3.14}$$

其中 $\bar{g} = \mathbb{E}_\mu[g]$，$\mathcal{L}_{\mathrm{Part}}^{(\eta)} = \frac{1}{2}\mathbb{E}_\mu[q^2]$ 是把温度写成 $1/\eta$ 的 PMD-Part 损失。因此二者的梯度相同当且仅当 $c_s\bar{g} = 0$；一般情况下并不相同。

证明 先把两个残差都写成同一组基本量。由于 f 是行为优势，$\mathbb{E}_\mu[f] = 0$；又因为 $u = \log(\pi/\mu)$，有

$$\mathrm{KL}(\mu\|\pi) = \mathbb{E}_\mu\left[\log\frac{\mu}{\pi}\right] = -\mathbb{E}_\mu[u].$$

所以 BPO 残差逐点为

$$\delta = \eta f - u - \mathrm{KL}(\mu\|\pi) = \eta f - u + \mathbb{E}_\mu[u].$$

PMD-Part 残差是 $q = \eta f - \log Z_f - u$，两式相减得到

$$\delta - q = \log Z_f + \mathbb{E}_\mu[u] = c_s.$$

这里 c_s 只依赖 prefix s，不依赖 action a。同时

$$\mathbb{E}_\mu[\delta] = \eta\mathbb{E}_\mu[f] - \mathbb{E}_\mu[u] + \mathbb{E}_\mu[u] = 0.$$

接着对平方损失求导。因为 target、行为策略和访问测度停止梯度，只有 δ 依赖 θ，故

$$\nabla_\theta\mathcal{L}_{\mathrm{BPO}}^{\mathrm{tok}} = \frac{1}{\eta}\mathbb{E}_\mu[\delta\nabla_\theta\delta].$$

对式(3.8) 求导，并使用 $\nabla_\theta u = g$ 与 $\nabla_\theta\,\mathrm{KL}(\mu\|\pi) = -\bar{g}$，得到

$$\nabla_\theta\delta = -g + \bar{g} = -(g-\bar{g}).$$

因此

$$\begin{aligned}
-\eta\nabla\mathcal{L}_{\mathrm{BPO}}^{\mathrm{tok}} &= \mathbb{E}_\mu[\delta(g-\bar{g})] \\
&= \mathbb{E}_\mu[\delta g] - \mathbb{E}_\mu[\delta]\bar{g} \\
&= \mathbb{E}_\mu[\delta g] \\
&= \mathbb{E}_\mu[(q+c_s)g] \\
&= \mathbb{E}_\mu[qg] + c_s\mathbb{E}_\mu[g] \\
&= \mathbb{E}_\mu[qg] + c_s\bar{g}.
\end{aligned}$$

另一方面，PMD-Part 的损失为 $\mathcal{L}_{\mathrm{Part}}^{(\eta)} = \frac{1}{2}\mathbb{E}_\mu[q^2]$，所以 $-\nabla\mathcal{L}_{\mathrm{Part}}^{(\eta)} = \mathbb{E}_\mu[qg]$。代入即可得到式(3.14)。注意这里用到的是残差的行为测度均值 $\mathbb{E}_\mu[\delta] = 0$；不能把 $\mathbb{E}_\mu[g]$ 误写成零。score 的零均值恒等式是 $\mathbb{E}_\pi[g] = 0$，因为 score 是相对于候选策略而非行为策略取期望。

二者只在 $c_s\bar{g} = 0$ 时退化为相同梯度，例如锚点 $\pi = \mu$、可实现根处，或参数化恰好使 $\bar{g} = 0$。一般离开锚点后，BPO 的 score centering 会留下 $c_s\bar{g}$ 这一额外项。若 f 不是优势而有非零行为均值，必须先把 f 中心化，否则 residual 与 PMD-Part 的 target 不再只差常数。若把 reverse KL 近似成二元项、停止其梯度、加入 clip 或使用不精确的 Z_f，式(3.14) 也不再成立，只能视为近似 PG surrogate。

3.4 为什么同为 token-level 仍然不等价

token-level只说明二者都在固定 prefix s 上处理条件分布；它没有规定必须使用同一个参数空间度量。PMD-Part 回归的是带有确定常数项 $-\log Z_f(s)$ 的完整 log-ratio：

$$q(a) = \underbrace{\eta f(a) - \log Z_f(s)}_{h(a)} - u(a).$$

因此它的平方损失直接惩罚 action-independent 的常数误差，梯度为 $\mathbb{E}_\mu[qg]$。BPO 使用的是 reverse-KL 中心化后的 residual：

$$\delta(a) = \eta f(a) - u(a) + \mathbb{E}_\mu[u] = q(a) + c_s, \qquad c_s = \log Z_f(s) + \mathbb{E}_\mu[u].$$

BPO 的目标只关心 $u(a) - \eta f(a)$ 在行为 action 测度下的中心化部分，因而沿着所有 action 同时平移 u 的方向不会产生同样的惩罚。

真正产生梯度差异的是对 BPO reverse KL 的求导。逐点求导给出

$$\nabla_\theta \delta(a) = -(g(a) - \bar{g}), \qquad \bar{g} = \mathbb{E}_\mu[g].$$

代入平方损失后，残差的行为均值为零，于是

$$-\eta \nabla \mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_\mu[\delta(g - \bar{g})] = \mathbb{E}_\mu[\delta g] = \mathbb{E}_\mu[qg] + c_s \bar{g}.$$

PMD-Part 从一开始就把 $\log Z_f$ 当作固定 target 常数，不会产生 $c_s\bar{g}$ 这一项。换句话说，差异不是来自 token-level 与 sequence-level 的访问测度，也不是来自 clip 或线性化；它来自两个平方回归问题对 action-independent 方向的处理不同，以及 BPO 对 reverse KL 求导产生的行为 score centering。

两者仍然共享同一个可实现根：在 $u = h$ 时，$q = 0$、$c_s = 0$ 且 $\delta = 0$。共享根只说明最优解一致，不说明离开根以后向量场一致。以二动作 logit 参数化为例，若 $\mu(1) = m$、$\pi_\theta(1) = p$，则

$$g(1) = 1 - p, \qquad g(0) = -p, qquad \bar{g} = m - p.$$

只要 $p \neq m$ 且 $c_s \neq 0$，就有 $c_s\bar{g} \neq 0$，BPO 和 PMD-Part 的更新方向严格不同。这一差异即使在有限 action、精确配分函数和完整 reverse KL 下仍然存在。

3.5 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta \in \Pi} \mathbb{E}_{d_\mu, \mu}[(u_\theta - h)^2], \tag{3.15}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta \in \Pi} \mathbb{E}_{d_\mu} \mathrm{Var}_{a \sim \mu}[u_\theta(a) - \eta f(a)]. \tag{3.16}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s) \sum_a \nabla \pi(a \mid s) A^\mu(s,a) + \sum_s d_\pi(s) \sum_a \nabla \pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.17}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。 ♠

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.18}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把

序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.19}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.20}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.