从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方残差回归出发，在当前策略点附近线性化，再把梯度实现为带 mismatch weight 的 per-token policy-gradient surrogate。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归和 BPO 的截断权重降低方差却产生投影或截断偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward 1
1.2 KL 镜像最优解 1
1.3 即时 reward 与完整序列 reward 2

第二章 四种方法从最优解出发的推导 **3**
2.1 PMD-Part：回归最优 log-ratio 3
2.2 PMD-Mean：中心化回归与 Lambert-W 3
2.3 MDPO：直接优化 KL 正则化目标 4
2.4 BPO：从 token 最优性到实际 PG surrogate 4

第三章 梯度的偏差与方差 **5**
3.1 三个梯度估计器 5
3.2 prefix IS 的位置 5

第四章 实现与参数比较 **6**
4.1 理论对象与实际代码 6
4.2 BPO 论文的训练预算 6
4.3 OpenKimi/PMD 的训练预算 6
4.4 经典 MDPO 的训练预算与 IS 6
4.5 比较时应报告的指标 7

第五章 结论与 MirrorOPD 的边界 **8**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s=(x,a_{<t})$，词表动作为 a，行为策略为 $\mu(a\mid s)$，待更新学生策略为 $\pi_\theta(a\mid s)$。以下所有结论都在

$$\pi_\theta(\cdot\mid s)\ll\mu(\cdot\mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s)>0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定温度 $\tau>0$，token-level PMD子问题为

$$\pi^+(\cdot\mid s)=\arg\max_{p\ll\mu(\cdot|s)}\left\{\mathbb{E}_{a\sim p}[f(s,a)]-\tau\,\mathrm{KL}(p\|\mu(\cdot\mid s))\right\}. \tag{1.1}$$

令

$$Z_f(s)=\mathbb{E}_{a\sim\mu(\cdot|s)}\exp\left(\frac{f(s,a)}{\tau}\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0<Z_f(s)<\infty$，式(1.1) 的唯一解为

$$\pi^+(a\mid s)=\frac{\mu(a\mid s)\exp(f(s,a)/\tau)}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a)=\log(\pi^+/\mu)$ 满足

$$u^+(s,a)=\frac{f(s,a)}{\tau}-\log Z_f(s). \tag{1.3}$$

♡

证明 由式(1.2)，有

$$\log\pi^+(a\mid s)=\log\mu(a\mid s)+f(s,a)/\tau-\log Z_f(s).$$

代入 KL 得

$$\mathrm{KL}(p\|\pi^+)=\mathrm{KL}(p\|\mu)-\frac{1}{\tau}\mathbb{E}_p[f]+\log Z_f(s).$$

整理得到

$$\mathbb{E}_p[f]-\tau\,\mathrm{KL}(p\|\mu)=\tau\log Z_f(s)-\tau\,\mathrm{KL}(p\|\pi^+).$$

KL 非负且仅在 $p=\pi^+$ 时为零，故解唯一。

推论 1.1 (优势形式)

若 $f=A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot)\mid s]=0$，则

$$\pi^+(a\mid s)=\mu(a\mid s)\exp(A^\mu(s,a)/\tau)/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s)=1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

♡

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^{\mu}(s_t, a_t) = r_t(s_t, a_t) + \mathbb{E}_{\mu}\left[\sum_{k>t} r_k(s_k, a_k) \mid s_t, a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 四种方法从最优解出发的推导

2.1 PMD-Part：回归最优 log-ratio

定义 $u_\theta(s,a)=\log \pi_\theta(a\mid s)/\mu(a\mid s)$，并令

$$h(s,a)=f(s,a)/\tau-\log Z_f(s).$$

PMD-Part在行为测度下回归精确最优性方程：

$$\mathcal{L}_{\mathrm{Part}}(\theta)=\frac{1}{2}\mathbb{E}_{s\sim d_\mu,\,a\sim\mu}\left[u_\theta(s,a)-h(s,a)\right]^2. \tag{2.1}$$

把 target h 和行为策略视为固定，记 $g_\theta(s,a)=\nabla_\theta \log \pi_\theta(a\mid s)$，则

$$-\nabla_\theta \mathcal{L}_{\mathrm{Part}}=\mathbb{E}_{d_\mu\mu}\left[(h-u_\theta)g_\theta\right]. \tag{2.2}$$

命题 2.1 (PMD-Part 的零点)

在无限容量、正访问权重和满 action support 下，$\mathcal{L}_{\mathrm{Part}}=0$ 当且仅当 $\pi_\theta(\cdot\mid s)=\pi^+(\cdot\mid s)$ 对 d_μ-几乎处处的 prefix 成立。

证明 平方损失为非负数。它为零当且仅当 $u_\theta=h$ 在行为测度下几乎处处成立。指数化并使用式(1.3)即得 $\pi_\theta=\pi^+$。反向蕴含显然成立。

PMD-Part 的重要性质是目标中没有 ratio 权重；ratio 只出现在被拟合的 log-ratio 中。因此它避免了直接 policy gradient 的乘法重尾，但有限模型下它优化的是 d_μ 加权的投影。

2.2 PMD-Mean：中心化回归与 Lambert-W

令

$$\bar f(s)=\mathbb{E}_{a\sim\mu}[f(s,a)\mid s],\qquad g(s,a)=\frac{f(s,a)-\bar f(s)}{\tau}.$$

PMD-Mean不显式估计 $\log Z_f(s)$，而求解

$$\min_u \ \frac{1}{2}\mathbb{E}_{s\sim d_\mu,a\sim\mu}[(u-g)^2]\quad \text{s.t.}\quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}]=1\quad \forall s. \tag{2.3}$$

约束是策略归一化，而不是可省略的附加条件。

定理 2.1 (PMD-Mean 的逐 prefix 解)

在有限 action space、$\mu(a\mid s)>0$ 和可行条件下，式(2.3)的 KKT 解满足

$$u^+(s,a)=g(s,a)-W\left(\lambda(s)e^{g(s,a)}\right), \tag{2.4}$$

其中 $\lambda(s)\ge 0$ 由 $\mathbb{E}_\mu[e^{u^+(s,\cdot)}\mid s]=1$ 唯一确定。

证明 对固定 s 加入约束乘子，拉格朗日函数为

$$\frac{1}{2}\mathbb{E}_\mu[(u-g)^2]+\lambda(s)(\mathbb{E}_\mu[e^u]-1).$$

逐 action 的一阶条件是 $u-g+\lambda e^u=0$。令 $v=g-u$，则 $ve^v=\lambda e^g$，所以 $v=W(\lambda e^g)$，得到式(2.4)。归一化条件确定 λ；当 $\lambda\ge 0$ 时左侧随 λ 单调下降，故解唯一。

PMD-Part 的修正项 $\log Z_f(s)$ 对 action 是常数，PMD-Mean 的 Lambert-W 项依赖 action。两者只有在退化或额外近似下才相同；它们可以拥有相同的排序和单调改进性质，但不是同一个 mirror subproblem 的两个无偏实现。

2.3 MDPO：直接优化 KL 正则化目标

MDPO直接对式(1.1) 的目标做参数优化。令

$$F_s(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \tau\,\mathrm{KL}(\pi_\theta\|\mu).$$

对 θ 求导，利用 $\mathbb{E}_\pi[g_\theta] = 0$，得到

$$\nabla F_s = \mathbb{E}_{a\sim\pi}\left[\left(f(s,a) - \tau\log\rho_\theta(s,a)\right) g_\theta(s,a)\right], \tag{2.5}$$

其中 $\rho_\theta = \pi_\theta/\mu$。若样本来自行为策略，则

$$\nabla F_s = \mathbb{E}_{a\sim\mu}\left[\rho_\theta(s,a)\left(f(s,a) - \tau\log\rho_\theta(s,a)\right) g_\theta(s,a)\right]. \tag{2.6}$$

这就是 MDPO 中的 action-level IS。若状态也来自 replay 的 d_μ，而目标是 d_π 下的 occupancy 目标，还需要 prefix ratio；经典实现通常把状态测度固定为 replay/rollout 测度，因而没有完整解决 state-distribution mismatch。

命题 2.2 (MDPO 梯度与 PMD-Part 回归梯度的零点一致、方向不一致)

MDPO 的梯度式(2.6) 与 PMD-Part 梯度式(2.2) 在精确镜像解处都为零，但一般不相等。

证明 在镜像解处，$\log\rho = f/\tau - \log Z_f$，故式(2.5) 为最优目标的驻点；PMD-Part 的 residual $h - u$ 逐点为零。离开镜像解时，MDPO 被积函数包含 ρ_θ 和 $f - \tau\log\rho_\theta$，PMD-Part 被积函数只有 $h - u_\theta$，两者测度和残差均不同。

2.4 BPO：从 token 最优性到实际 PG surrogate

BPO 的 token-level PMD 起点与式(1.1) 相同，使用 $f = A^\mu$。在终端奖励情形，论文先定义 token residual

$$d_\pi(s_t,a_t) = \eta A^\mu(s_t,a_t) - \left[\log\frac{\pi(a_t\mid s_t)}{\mu(a_t\mid s_t)} + \mathrm{KL}(\mu(\cdot\mid s_t)\|\pi(\cdot\mid s_t))\right]. \tag{2.7}$$

该 residual 在 $a_t\sim\mu(\cdot\mid s_t)$ 下条件均值为零。BPO 将沿轨迹的 residual 累加成平方回归目标，并证明其零点与 PMD 解一致。

实际算法没有把式(2.7) 的平方损失做 inner convergence。论文在 $\pi = \mu$ 处线性化，使用组内 reward mean/std 估计初始 value 和缩放因子，再以二元 KL 近似逆向 KL，得到

$$\nabla\mathcal{L}_{i,t}^{\mathrm{BPO}} \approx -A_i M_{i,t}\min(\widetilde{w}_{i,t}, C)\nabla\log\pi(a_{i,t}\mid s_{i,t}), \tag{2.8}$$

其中

$$\widetilde{w}_{i,t} = \frac{1+\epsilon-\mu(a_{i,t}\mid s_{i,t})}{1+\epsilon-\pi(a_{i,t}\mid s_{i,t})}. \tag{2.9}$$

因此 BPO 最终训练的是 PG 形式的 surrogate；回归是理论构造和梯度来源，而不是独立的第二阶段优化器。

第三章 梯度的偏差与方差

3.1 三个梯度估计器

固定 prefix，设 $g = \nabla \log \pi_\theta(a \mid s)$，$\rho = \pi_\theta/\mu$，并定义 $c = f - \tau \log \rho$。MDPO 的无偏行为测度估计器为

$$\widehat{G}_{\mathrm{MDPO}} = \rho c g, \qquad \mathbb{E}_\mu[\widehat{G}_{\mathrm{MDPO}}] = \nabla F_s.$$

PMD-Part 的回归估计器为

$$\widehat{G}_{\mathrm{Part}} = (h - u_\theta) g,$$

它在 target 固定且回归残差正确时收敛到镜像解，但一般不是 ∇F_s 的无偏估计。BPO 的实际估计器为

$$\widehat{G}_{\mathrm{BPO}} = -AM \min(\widetilde{w}, C) g.$$

由于 M 和截断依赖当前 ratio，它也一般是 surrogate 的有偏估计器。

定理 3.1 (IS 梯度的二阶矩上界)

若 $\|g\| \le G$ 且 $|c| \le C_f$，则

$$\mathbb{E}_\mu[\|\widehat{G}_{\mathrm{MDPO}}\|^2] \le G^2 C_f^2 \mathbb{E}_\mu[\rho^2]. \tag{3.1}$$

因此其方差满足 $\mathrm{Var}(\widehat{G}_{\mathrm{MDPO}}) \le G^2 C_f^2 \mathbb{E}_\mu[\rho^2]$；当 ratio 重尾或 support 接近失败时，该上界迅速变大。

证明 逐样本有 $\|\rho c g\|^2 \le \rho^2 C_f^2 G^2$。取行为期望并使用 $\mathrm{Var}(X) \le \mathbb{E}[\|X\|^2]$ 即得。

命题 3.1 (有界 mismatch weight 的方差与截断偏差)

若 $0 \le M \le 1$ 且 $0 \le \min(\widetilde{w}, C) \le C$，$|A| \le C_A$，$\|g\| \le G$，则

$$\mathbb{E}[\|\widehat{G}_{\mathrm{BPO}}\|^2] \le C_A^2 C^2 G^2.$$

相对于未截断的 surrogate 梯度 $G_0 = -AM\widetilde{w}g$，截断引入的 bias 满足

$$\left\| \mathbb{E}[\widehat{G}_{\mathrm{BPO}} - G_0] \right\| \le C_A G \mathbb{E}[(\widetilde{w} - C)_+].$$

证明 第一式由逐样本范数上界直接得到。第二式使用三角不等式以及 $|\min(\widetilde{w}, C) - \widetilde{w}| = (\widetilde{w} - C)_+$。

注 [偏差方差位置] MDPO 的 action IS 主要承担测度校正，理想情况下无偏但方差可能很大。PMD-Part 去掉了梯度外部 ratio，代价是离开镜像根时不再等于原始 KL 目标梯度，并且受到 d_μ 加权投影影响。PMD-Mean 额外用均值替代 log-partition，产生几何投影偏差。BPO 的 mismatch weight 比标准 ratio 更温和，并通过平滑、mask 和截断控制方差，但因此不再是原始 PMD 梯度的无偏估计。

3.2 prefix IS 的位置

若数据来自 $d_\mu(s)\mu(a \mid s)$，而要无偏估计目标 occupancy 下的量，则完整权重为

$$\frac{d_\pi(s)}{d_\mu(s)} \frac{\pi(a \mid s)}{\mu(a \mid s)} = W_{<t} \rho_t.$$

PMD-Part、PMD-Mean 和 BPO 的条件回归形式通常只使用 d_μ 访问的 prefix，因此没有显式 $W_{<t}$；这不是一般 off-policy 无偏性，而是把目标定义为行为测度下的 pointwise regression。若在有限容量下用 prefix IS 改变投影权重，必须同时承担 $W_{<t}$ 的方差和 support 风险。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = f/\tau - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \tau\,\mathrm{KL}(\pi\|\mu)$	$\rho(f - \tau\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression 的局部线性化	per-token $A\,M\min(\widetilde{w}, C)\nabla\log\pi$	线性化、二元 KL、截断产生 bias，权重受控

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、BPO mismatch weight 的截断比例，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient，BPO 是平方 residual 回归经过局部线性化和二元 KL 化简后的 per-token PG surrogate。它们在理想条件下可以共享相同的零点，但训练过程中的梯度、访问测度、偏差和方差不同。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.