从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward . . . 1
1.2 KL 镜像最优解 . . . 1
1.3 即时 reward 与完整序列 reward . . . 2

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean 与 BPO **3**
2.1 共同的 token-level mirror 子问题 . . . 3
2.1.1 为什么优势函数的行为均值为零 . . . 3
2.2 三种算法的逐步推导 . . . 4
2.2.1 PMD-Part：回归完整的最优 log-ratio . . . 4
2.2.2 PMD-Mean：中心化 target 加归一化投影 . . . 4
2.2.3 BPO：对同一最优性方程做中心化 residual 回归 . . . 4
2.2.4 PMD-Mean 与 BPO 都中心化，但投影对象不同 . . . 5
2.3 OPD 的 inner–outer mirror 流程：教师并非每步都被完全拟合 . . . 6
2.3.1 一个 outer step 的精确 mirror 解 . . . 6
2.3.2 inner 求解与 outer 更新的区别 . . . 6
2.3.3 为什么 inner 需要多步：局部曲率与 Natural Gradient . . . 7
2.3.4 OPD 的 off-policy prefix 复用 . . . 8
2.4 直接优化镜像目标：MDPO . . . 9
2.5 共享零点、不同梯度的定理 . . . 9

第三章 梯度的偏差与方差 **10**
3.1 估计对象必须先固定 . . . 10
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 . . . 10
3.3 PMD-Part 的投影偏差与 BPO 的中心化方差 . . . 11

第四章 实现与参数比较 **13**
4.1 理论对象与实际代码 . . . 13
4.2 BPO 论文的训练预算 . . . 13
4.3 OpenKimi/PMD 的训练预算 . . . 13
4.4 经典 MDPO 的训练预算与 IS . . . 13
4.5 比较时应报告的指标 . . . 14

第五章 结论与 MirrorOPD 的边界 **15**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean 与 BPO

2.1 共同的 token-level mirror 子问题

固定 prefix s，行为策略记为 $\mu(a \mid s)$，候选学生策略记为 $\pi_\theta(a \mid s)$，并定义

$$u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\mu(a \mid s)}, \qquad g_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s).$$

统一用 $\eta > 0$ 表示 Natural Gradient 的学习率。给定 token 信号 $f(s,a)$，三种方法都从同一个镜像子问题开始：

$$\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{2.1}$$

定义

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{\eta f(s,a)}].$$

对任意候选分布 p，直接展开 KL 得到

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p \left[\log \frac{p}{\mu} - \eta f + \log Z_f(s) \right] \\ &= \mathrm{KL}(p\|\mu) - \eta \mathbb{E}_p[f] + \log Z_f(s), \end{aligned}$$

其中

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{Z_f(s)}.$$

整理后，镜像目标满足

$$\mathbb{E}_p[f] - \frac{1}{\eta} \mathrm{KL}(p\|\mu) = \frac{1}{\eta} \log Z_f(s) - \frac{1}{\eta} \mathrm{KL}(p\|\pi^+). \tag{2.2}$$

因此唯一最优策略是 π^+，其最优 log-ratio 为

$$u^+(s,a) = \log \frac{\pi^+(a \mid s)}{\mu(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.3}$$

2.1.1 为什么优势函数的行为均值为零

条件 $\mathbb{E}_\mu[f(s,a) \mid s] = 0$ 不是任意 reward 的性质。若 $f = A^\mu$ 是行为策略的优势函数，则

$$A^\mu(s,a) = Q^\mu(s,a) - V^\mu(s), \qquad V^\mu(s) = \mathbb{E}_{a\sim\mu}[Q^\mu(s,a) \mid s],$$

从而

$$\begin{aligned} \mathbb{E}_\mu[A^\mu(s,a) \mid s] &= \mathbb{E}_\mu[Q^\mu(s,a) \mid s] - V^\mu(s) \\ &= 0. \end{aligned}$$

若 f 是即时 reward、教师分数或一般 OPD 信号，则必须把中心化作为显式定义。令

$$\bar{f}(s) = \mathbb{E}_\mu[f(s,a) \mid s], \qquad \widetilde{f}(s,a) = f(s,a) - \bar{f}(s).$$

减去只依赖 prefix 的常数不改变 Gibbs 策略，因为

$$\frac{\mu(a \mid s) e^{\eta \widetilde{f}(s,a)}}{\mathbb{E}_\mu[e^{\eta \widetilde{f}(s,\cdot)} \mid s]} = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{\mathbb{E}_\mu[e^{\eta f(s,\cdot)} \mid s]}.$$

后文在 BPO 和 PMD-Mean 中使用 $\widetilde{f}$；PMD-Part 直接保留精确的 $\log Z_f(s)$。

2.2 三种算法的逐步推导

2.2.1 PMD-Part：回归完整的最优 log-ratio

把式(2.3) 当作 supervised target，定义

$$h(s,a) = \eta f(s,a) - \log Z_f(s), \qquad q_\theta(s,a) = h(s,a) - u_\theta(s,a).$$

PMD-Part 损失和下降方向分别为

$$\mathcal{L}_{\text{Part}} = \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[q_\theta(s,a)^2], \tag{2.4}$$

$$-\nabla_\theta \mathcal{L}_{\text{Part}} = \mathbb{E}_{d_\mu,\mu}[q_\theta(s,a) g_\theta(s,a)]. \tag{2.5}$$

这里的 target 常数 $\log Z_f(s)$ 固定了 action-independent 方向。

2.2.2 PMD-Mean：中心化 target 加归一化投影

PMD-Mean不显式回归 $\log Z_f$，而令

$$g_{\text{Mean}}(s,a) = \eta \widetilde{f}(s,a)$$

并求解

$$\min_u \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[(u - g_{\text{Mean}})^2] \quad \text{s.t.} \quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}] = 1. \tag{2.6}$$

固定 prefix 后，写出拉格朗日函数

$$\mathcal{J}(u,\lambda) = \frac{1}{2}\sum_a \mu_a (u_a - g_a)^2 + \lambda\left(\sum_a \mu_a e^{u_a} - 1\right).$$

因为 $\mu_a > 0$，一阶条件为

$$u_a - g_a + \lambda e^{u_a} = 0.$$

令 $v_a = g_a - u_a$，则

$$v_a e^{v_a} = \lambda e^{g_a}.$$

由 Lambert-W 的定义 $W(z)e^{W(z)} = z$，得到

$$u^+_{\text{Mean}}(s,a) = g_{\text{Mean}}(s,a) - W\left(\lambda(s) e^{g_{\text{Mean}}(s,a)}\right), \tag{2.7}$$

其中 $\lambda(s)$ 由归一化约束唯一确定。PMD-Mean 是投影问题；除特殊情形外，式(2.7) 不等于精确 Gibbs log-ratio。

2.2.3 BPO：对同一最优性方程做中心化 residual 回归

先定义 $b_\theta(s,a) = \eta f(s,a) - u_\theta(s,a)$。令

$$\bar{b}_\theta(s) = \mathbb{E}_{a\sim\mu}[b_\theta(s,a) \mid s].$$

BPO的 residual 是

$$\delta_\theta(s,a) = b_\theta(s,a) - \bar{b}_\theta(s). \tag{2.8}$$

若使用中心化信号 $\widetilde{f}$，则

$$\delta_\theta = \eta\widetilde{f} - u_\theta + \mathbb{E}_\mu[u_\theta \mid s], \qquad \mathbb{E}_\mu[\delta_\theta \mid s] = 0.$$

完整 reverse-KL 的导数给出

$$\nabla_\theta \delta_\theta(s,a) = -\left(g_\theta(s,a) - \bar{g}_\theta(s)\right), \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

所以未线性化 BPO 损失

$$\mathcal{L}_{\text{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)^2] \tag{2.9}$$

的下降方向为

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)(g_\theta(s,a) - \bar{g}_\theta(s))]. \tag{2.10}$$

2.2.4 PMD-Mean 与 BPO 都中心化，但投影对象不同

两种方法都可以写出一个中心化的信号 $\widetilde{f}$，但中心化发生在不同的优化问题中。PMD-Mean先把精确最优 log-ratio

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s)$$

替换为可观测的中心化 target $\eta\widetilde{f}(s,a)$，然后在满足 $\mathbb{E}_\mu[e^u \mid s] = 1$ 的函数集合上做平方距离投影。它的残差是

$$r_{\mathrm{Mean}}(s,a) = \eta\widetilde{f}(s,a) - u_\theta(s,a),$$

并没有把当前策略的 u_θ 再次中心化。

BPO 使用的是同一个镜像最优性方程的 centered residual。展开式(2.8) 可得

$$\delta_\theta(s,a) = \eta f(s,a) - u_\theta(s,a) - \mathbb{E}_\mu[\eta f(s,\cdot) - u_\theta(s,\cdot) \mid s].$$

若 f 已经满足 $\mathbb{E}_\mu[f \mid s] = 0$，这变为

$$\delta_\theta(s,a) = \eta f(s,a) - u_\theta(s,a) + \mathbb{E}_\mu[u_\theta(s,\cdot) \mid s].$$

因此二者的 residual 差为

$$\delta_\theta - r_{\mathrm{Mean}} = \mathbb{E}_\mu[u_\theta(s,\cdot) \mid s]$$

（在 f 已中心化时）。这个差是只依赖 prefix 的常数，策略在精确解处可以通过归一化吸收它；但是在参数空间进行有限步回归时，它会改变梯度，因为 PMD-Mean 使用 g_θ，而未线性化 BPO 对完整 reverse-KL 求导后使用 $g_\theta - \bar{g}_\theta$。所以“都出现 $\widetilde{f}$”只说明它们共享同一个 action-independent 不可辨识方向，并不意味着两个损失或梯度相同。

命题 2.1 (PMD-Mean 与 BPO 的等价条件)

固定一个 prefix，并假设 $\mathbb{E}_\mu[f \mid s] = 0$。若同时满足

$$\mathbb{E}_\mu[u_\theta \mid s] = 0, \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s] = 0,$$

则 PMD-Mean 的 residual 与 BPO residual 相同，且两者的下降方向相同。策略归一化只给出 $\mathbb{E}_{\pi_\theta}[g_\theta] = 0$，而不是所需的 $\mathbb{E}_\mu[g_\theta] = 0$；同样，$\mathbb{E}_\mu[u_\theta \mid s] = 0$ 也不是归一化约束的结果。因此在行为测度 μ 下，二者通常只共享精确零点而不共享有限步梯度。

证明 在 $\mathbb{E}_\mu[f \mid s] = 0$ 下，前面的恒等式给出

$$\delta_\theta - r_{\mathrm{Mean}} = \mathbb{E}_\mu[u_\theta \mid s].$$

若该均值为零，则 residual 相同。PMD-Mean 的下降方向为 $\mathbb{E}_\mu[r_{\mathrm{Mean}}g_\theta]$；BPO 的下降方向由式(2.10) 给出。若再有 $\bar{g}_\theta = 0$，则

$$\mathbb{E}_\mu[\delta_\theta(g_\theta - \bar{g}_\theta)] = \mathbb{E}_\mu[r_{\mathrm{Mean}}g_\theta],$$

故两者相同。反之，只要任一 action-independent 项没有被这两个条件消除，有限参数更新就会产生梯度差异。

2.3 OPD 的 inner–outer mirror 流程：教师并非每步都被完全拟合

本节把 OPD 写成一个明确的 outer–inner 算法。固定教师策略 $T(a \mid s)$，令第 k 次 outer 迭代开始时的学生策略为 $\pi_k(a \mid s)$。假设在教师有正概率的 action 上，学生也有正概率，即 $T(\cdot \mid s) \ll \pi_k(\cdot \mid s)$。OPD 的逐 token 信号取为当前学生到教师的 log-ratio

$$f_k(s,a) = \log \frac{T(a \mid s)}{\pi_k(a \mid s)}. \tag{2.11}$$

这里的 reward 依赖 outer 迭代编号 k；它不是一个固定的、一次性定义的 r_T。它衡量教师相对于当前学生在 prefix s 下对 action a 的局部偏好。

2.3.1 一个 outer step 的精确 mirror 解

给定 π_k 和 f_k，第 k 次 mirror 子问题为

$$\pi^\star_{k+1} = \arg\max_{p \ll \pi_k} \left\{ \mathbb{E}_{a\sim p}[f_k(s,a)] - \frac{1}{\eta}\,\mathrm{KL}\left(p \| \pi_k(\cdot \mid s)\right) \right\}, \qquad 0 < \eta \le 1. \tag{2.12}$$

把 f_k 代入 Gibbs 解，得到

$$\pi^\star_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)\exp\left(\eta \log \frac{T(a|s)}{\pi_k(a|s)}\right)}{Z_k(s)} \tag{2.13}$$

$$= \frac{\pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}, \tag{2.14}$$

其中

$$Z_k(s) = \sum_a \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}. \tag{2.15}$$

因此，$\eta = 1$ 时 $\pi^\star_{k+1} = T$，一次 mirror step 直接到教师；$0 < \eta < 1$ 时得到学生和教师在 log-probability 空间的几何插值。该中间分布不是额外启发式，而是式(2.12) 的精确解。

定理 2.1 (OPD mirror step 的几何中间分布)

在有限 action space 和 $T(\cdot \mid s) \ll \pi_k(\cdot \mid s)$ 下，式(2.12) 的唯一解是式(2.14)。特别地，$\eta = 1$ 时一步到达教师；$0 < \eta < 1$ 时该更新保持在学生与教师之间，并满足 $\pi^\star_{k+1} \ll \pi_k$。

♡

证明 将 $f_k = \log(T/\pi_k)$ 代入镜像目标，并忽略与 p 无关的项，有

$$\mathbb{E}_p[f_k] - \frac{1}{\eta}\,\mathrm{KL}(p\|\pi_k) = -\frac{1}{\eta}\mathbb{E}_p\left[\log p - (1-\eta)\log \pi_k - \eta \log T\right].$$

令 $q_k(a \mid s) = \pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}$，并令 $Z_k = \sum_a q_k(a \mid s)$。则上式等于

$$\frac{1}{\eta}\log Z_k - \frac{1}{\eta}\,\mathrm{KL}(p\|q_k/Z_k).$$

KL 非负且仅在 $p = q_k/Z_k$ 时取零，因此得到唯一解。$\eta = 1$ 时 $q_k = T$ 且 $Z_k = 1$；当 $0 < \eta < 1$ 时，q_k 对两种分布的 log 概率作凸组合，且由支持假设满足绝对连续性。

2.3.2 inner 求解与 outer 更新的区别

式(2.12) 是 outer 第 k 步要解决的目标，不能把它和参数优化步数混为一谈。实际学生只能表示 π_θ，因此固定行为策略 π_k 后，inner 优化是在同一批 prefix 上最小化

$$\mathcal{L}_k(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_{\mathrm{replay}},\, a\sim\pi_k(\cdot|s)}\left[\log \frac{\pi^\star_{k+1}(a \mid s)}{\pi_k(a \mid s)} - \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\right]^2. \tag{2.16}$$

若 inner 被精确求解，得到 $\pi_\theta = \pi^\star_{k+1}$；若只做有限次 SGD，得到的是近似解 $\widehat{\pi}_{k+1}$，其误差会进入 outer 迭代的误差项。因而一个完整的 outer step 是：冻结 π_k，构造 f_k，用 replay 中丰富的 prefix 近似 d_{π_k} 或其覆盖测度，进

行若干 inner 更新，得到 $\widehat{\pi}_{k+1}$，然后令 $\pi_{k+1} \leftarrow \widehat{\pi}_{k+1}$ 并重新采样或继续积累数据。

命题 2.2 (有限 inner 误差的 projective outer 递推)

对每个 prefix 定义 log-ratio 振幅

$$\Delta_k(s) = \max_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \min_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)}.$$

若精确 mirror 解被有限 inner 优化替换为 $\widehat{\pi}_{k+1}$，定义其 projective 误差为 $\zeta_k(s)$，使得

$$\Delta(\widehat{\pi}_{k+1}, T; s) \le (1-\eta)\Delta_k(s) + \zeta_k(s).$$

则

$$\Delta_{k+1}(s) \le (1-\eta)\Delta_k(s) + \zeta_k(s). \tag{2.17}$$

因此若 $\limsup_k \zeta_k(s) \le \zeta_\infty(s)$，则

$$\limsup_{k\to\infty} \Delta_k(s) \le \frac{\zeta_\infty(s)}{\eta}.$$

证明 精确 mirror 解满足式(2.18)。有限 inner 误差的定义直接给出三角型递推式(2.17)。递推展开后，初始项按 $(1-\eta)^k$ 衰减，误差项由几何级数控制：

$$\sum_{j=0}^{k-1}(1-\eta)^j \zeta_{k-1-j}(s) \le \frac{\sup_{j\ge k_0}\zeta_j(s)}{\eta} + o(1).$$

取上极限即得结论。

2.3.2.0.1 关于 L_1 距离。 上述 projective 递推是无条件成立的；若进一步假设所有迭代满足 $m \le \pi_k(a \mid s)/T(a \mid s) \le M$，则归一化和有限 action space 将 projective 误差连续地转化为 L_1 误差，从而得到相应的 L_1 几何收敛界。没有这样的概率比上下界时，不能直接把 $1-\eta$ 写成任意 L_1 距离的收缩系数。令

$$\Delta_k(s) = \max_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \min_a \log \frac{\pi_k(a \mid s)}{T(a \mid s)},$$

则精确满足

$$\Delta_{k+1}(s) = (1-\eta)\Delta_k(s). \tag{2.18}$$

由 $\mathbb{E}_T[\pi_k/T] = 1$，$\Delta_k \to 0$ 蕴含 $\pi_k \to T$。文中的 L_1 递推应理解为在概率比有统一上下界时的推论；否则应优先使用式(2.18)。

2.3.3 为什么 inner 需要多步：局部曲率与 Natural Gradient

把固定 outer step 的回归或镜像目标限制到参数化策略附近。令 $\Delta\theta$ 表示相对当前参数的增量，$J(s,a)$ 表示 logit 对参数的 Jacobian，$\mathcal{F}(s)$ 表示当前策略的 Fisher 矩阵。对 KL 项作二阶展开，并把 reward 项作一阶展开，可以得到局部二次模型

$$\mathcal{Q}(\Delta\theta) = \frac{1}{2}\Delta\theta^\top A \Delta\theta - b^\top \Delta\theta + C, \qquad A = \mathbb{E}_{s,a}\left[J(s,a)^\top \mathcal{F}(s) J(s,a)\right]. \tag{2.19}$$

这里 b 是镜像目标在当前参数处的 score 方向，A 是把策略空间 KL 曲率拉回参数空间后的矩阵。它解释了为什么“inner 做到收敛”与“做一次参数梯度”是两件不同的事。

定理 2.2 (局部二次模型下的 inner 梯度下降速度)

假设 A 对称半正定，并在其正特征值子空间上正定。对

$$\Delta\theta_{m+1} = \Delta\theta_m - \gamma\nabla\mathcal{Q}(\Delta\theta_m) = (I - \gamma A)\Delta\theta_m + \gamma b$$

取 $0 < \gamma < 2/\lambda_{\max}(A)$。则在 A 的正特征值子空间上，迭代收敛到 $\Delta\theta^\star = A^\dagger b$，并且误差满足

$$\|\Delta\theta_m - \Delta\theta^\star\|_A \le \left(\max_{\lambda_i(A)>0} |1-\gamma\lambda_i(A)|\right)^m \|\Delta\theta_0 - \Delta\theta^\star\|_A.$$

若 $\lambda^+_{\min}(A)$ 很小，则最慢方向的收缩率接近 $1-\gamma\lambda^+_{\min}(A)$；其步数由条件数 $\kappa(A) = \lambda_{\max}(A)/\lambda^+_{\min}(A)$ 控制。

证明 一阶条件为 $\nabla\mathcal{Q}(\Delta\theta) = A\Delta\theta - b$。由于 A 对称，可取正交特征分解 $A = U\Lambda U^\top$。在正特征值子空间中，令 $e_m = \Delta\theta_m - \Delta\theta^\star$，则

$$e_{m+1} = (I - \gamma A)e_m.$$

在第 i 个特征方向上，

$$e_{m+1,i} = (1-\gamma\lambda_i)e_{m,i}.$$

条件 $0 < \gamma < 2/\lambda_{\max}(A)$ 等价于所有正特征值满足 $|1-\gamma\lambda_i| < 1$。因此

$$\|e_m\|_A^2 = \sum_{\lambda_i>0} \lambda_i(1-\gamma\lambda_i)^{2m} e_{0,i}^2 \le \left(\max_{\lambda_i>0}|1-\gamma\lambda_i|\right)^{2m} \|e_0\|_A^2.$$

开平方即得结论。零特征值方向不由局部目标确定，使用 Moore–Penrose 逆得到最小范数代表元 $A^\dagger b$。

Natural Gradient 用 Fisher 预条件器把更新写成

$$\Delta\theta_{m+1} = \Delta\theta_m - \gamma\mathcal{F}_\theta^\dagger \nabla_\theta \mathcal{Q}(\Delta\theta_m).$$

当 $\mathcal{F}_\theta$ 与 A 的主要病态方向一致时，它会压平不同参数坐标的尺度；理想的 $A^\dagger$ 预条件器在二次模型上可一步到达 $\Delta\theta^\star$。实际 Natural Gradient 通常只使用 Fisher 的近似，因此得到的是改善条件数而不是普遍的一步收敛。AdamW 的逐坐标二阶矩也不等价于 Fisher 逆，因而没有同样的几何不变性保证。

经典 MDPO 的关键实现结论正是这一点：若在 θ_k 处只做一次梯度步，$\mathrm{KL}(\pi_\theta\|\pi_k)$ 在 $\theta = \theta_k$ 的一阶梯度为零，该步退化为普通 policy gradient，尚未体现 trust-region 的曲率；固定旧策略并进行多次 inner 更新，才会真正逼近式(2.1) 的镜像解。因而本文的 outer step 定义为“固定 π_k 后把 inner 子问题优化到给定误差”，而不是把一次 SGD 更新误称为一次收敛的 mirror step。

2.3.3.0.1 几何中间分布与算术 proximal teacher 的区别。 式(2.14) 给出的 $\pi_k^{1-\eta}T^\eta/Z_k$ 是 KL 镜像子问题的精确解，因此在 log-probability 空间插值。TOP-D 中的算术 teacher

$$\widetilde{T}_\eta = (1-\eta)\pi_k + \eta T$$

是另一个用于控制 log-ratio 方差的 teacher operator。它同样产生 student 与 teacher 之间的中间分布，但不等价于 KL mirror 解；前者改变 target teacher，后者改变 proximal 优化问题的解。

2.3.4 OPD 的 off-policy prefix 复用

OPD的优势在于教师可以在学生访问到的 prefix 上提供稠密 token 信号。设 replay 测度为 d_b，只要 $d_{\pi_k} \ll d_b$，outer mirror 目标可以写成

$$\mathbb{E}_{s\sim d_{\pi_k}}[\ell_k(s)] = \mathbb{E}_{s\sim d_b}\left[W_{<t}(s)\ell_k(s)\right], \qquad W_{<t}(s) = \frac{d_{\pi_k}(s)}{d_b(s)}. \tag{2.20}$$

PMD-Part、PMD-Mean 和 BPO 在 action 层都可用 $a \sim \pi_k(\cdot \mid s)$ 的样本完成回归，不需要额外 action-level IS；off-policy 的主要问题转移到 prefix 访问测度 $W_{<t}$。若把 d_b 当作固定投影测度而不做 $W_{<t}$，得到的是 replay 加权的近似 mirror step，而非严格的 d_{π_k} 加权 outer 目标。这正是 OPD 可以利用状态丰富性、同时需要报告访问测度偏差的地方。

2.4 直接优化镜像目标：MDPO

直接对镜像目标

$$F_s(\theta) = \mathbb{E}_{\pi_\theta}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(\pi_\theta \| \mu) \tag{2.21}$$

做梯度上升。令 $\rho_\theta = \pi_\theta/\mu$，则

$$\nabla F_s(\theta) = \mathbb{E}_{a\sim\pi_\theta}\left[\left(f(s,a) - \frac{1}{\eta}\log\rho_\theta(s,a)\right) g_\theta(s,a)\right] = \mathbb{E}_{a\sim\mu}\left[\rho_\theta(s,a)\left(f - \frac{1}{\eta}\log\rho_\theta\right) g_\theta\right]. \tag{2.22}$$

MDPO 与三种回归方法共享同一 Gibbs 驻点，但显式保留 action-level importance ratio。

2.5 共享零点、不同梯度的定理

命题 2.3 (三种方法的共享零点)

在有限 action space、$\mu(a \mid s) > 0$ 且策略归一化成立时，PMD-Part 与未线性化 BPO 在精确 Gibbs 策略 π^+ 处达到零 residual。PMD-Mean 在其中心化 target 可实现并满足归一化约束时达到同一策略；一般情况下它给出约束集合上的欧氏投影。

证明 PMD-Part 由 $u_\theta = h$ 直接得到 $u_\theta = u^+$。对 BPO，若 $\delta_\theta = 0$，则 $u_\theta = \eta f - C(s)$，其中 $C(s)$ 与 action 无关。归一化给出

$$1 = \mathbb{E}_\mu[e^{u_\theta} \mid s] = e^{-C(s)}\mathbb{E}_\mu[e^{\eta f} \mid s] = e^{-C(s)} Z_f(s),$$

所以 $C(s) = \log Z_f(s)$，即 $u_\theta = u^+$。PMD-Mean 在 target 可实现并满足归一化约束时也取到该策略；不可实现时，它取的是约束集合上的欧氏投影。

定理 2.3 (未线性化 BPO 与 PMD-Part 的梯度差异)

令 $q_\theta = h - u_\theta$，并令

$$c_\theta(s) = \log Z_f(s) + \mathbb{E}_\mu[u_\theta(s,a) \mid s], \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

则 $\delta_\theta = q_\theta + c_\theta$，且

$$-\eta\nabla\mathcal{L}_{\mathrm{BPO}} = -\nabla\mathcal{L}_{\mathrm{Part}} + \mathbb{E}_{s\sim d_\mu}[c_\theta(s)\bar{g}_\theta(s)]. \tag{2.23}$$

因此二者共享零点，但一般不具有相同的梯度场；只有 $c_\theta(s)\bar{g}_\theta(s) = 0$ 对 d_μ-几乎处处成立时才相同。

证明 由 $q_\theta = \eta f - \log Z_f - u_\theta$，而 BPO 使用 $\delta_\theta = \eta f - u_\theta + \mathbb{E}_\mu[u_\theta \mid s]$，相减得到 $\delta_\theta = q_\theta + c_\theta$。另一方面，$\mathbb{E}_\mu[\delta_\theta \mid s] = 0$，所以

$$\begin{aligned} -\eta\nabla\mathcal{L}_{\mathrm{BPO}} &= \mathbb{E}[\delta_\theta(g_\theta - \bar{g}_\theta)] \\ &= \mathbb{E}[\delta_\theta g_\theta] \\ &= \mathbb{E}[(q_\theta + c_\theta) g_\theta] \\ &= \mathbb{E}[q_\theta g_\theta] + \mathbb{E}[c_\theta \bar{g}_\theta]. \end{aligned}$$

第一项正是 $-\nabla\mathcal{L}_{\mathrm{Part}}$，得到式(2.23)。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu,\mu}[(u_\theta - h)^2], \tag{3.8}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu}\,\mathrm{Var}_{a\sim\mu}[u_\theta(a) - \eta f(a)]. \tag{3.9}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s)\sum_a \nabla\pi(a \mid s)A^\mu(s,a) + \sum_s d_\pi(s)\sum_a \nabla\pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.10}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.11}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.12}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.13}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.