从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**
1.1 Prefix、行为策略与局部 reward 1
1.2 KL 镜像最优解 1
1.3 即时 reward 与完整序列 reward 2

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean 与 BPO **3**
2.1 共同的 token-level mirror 子问题 3
2.1.1 为什么优势函数的行为均值为零 3
2.2 三种算法的逐步推导 4
2.2.1 PMD-Part：回归完整的最优 log-ratio 4
2.2.2 PMD-Mean：中心化 target 加归一化投影 4
2.2.3 BPO：对同一最优性方程做中心化 residual 回归 4
2.3 OPD 的具体化：从教师分布反推 token reward 5
2.4 直接优化镜像目标：MDPO 6
2.5 共享零点、不同梯度的定理 6

第三章 梯度的偏差与方差 **7**
3.1 估计对象必须先固定 7
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 7
3.3 PMD-Part 的投影偏差与 BPO 的中心化方差 8

第四章 实现与参数比较 **10**
4.1 理论对象与实际代码 10
4.2 BPO 论文的训练预算 10
4.3 OpenKimi/PMD 的训练预算 10
4.4 经典 MDPO 的训练预算与 IS 10
4.5 比较时应报告的指标 11

第五章 结论与 MirrorOPD 的边界 **12**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 从同一个最优化问题推导 PMD-Part、PMD-Mean 与 BPO

2.1 共同的 token-level mirror 子问题

固定 prefix s，行为策略记为 $\mu(a \mid s)$，候选学生策略记为 $\pi_\theta(a \mid s)$，并定义

$$u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\mu(a \mid s)}, \qquad g_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s).$$

统一用 $\eta > 0$ 表示 Natural Gradient 的学习率。给定 token 信号 $f(s,a)$，三种方法都从同一个镜像子问题开始：

$$\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{2.1}$$

定义

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{\eta f(s,a)}].$$

对任意候选分布 p，直接展开 KL 得到

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p \left[\log \frac{p}{\mu} - \eta f + \log Z_f(s) \right] \\ &= \mathrm{KL}(p\|\mu) - \eta \mathbb{E}_p[f] + \log Z_f(s), \end{aligned}$$

其中

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{Z_f(s)}.$$

整理后，镜像目标满足

$$\mathbb{E}_p[f] - \frac{1}{\eta} \mathrm{KL}(p\|\mu) = \frac{1}{\eta} \log Z_f(s) - \frac{1}{\eta} \mathrm{KL}(p\|\pi^+). \tag{2.2}$$

因此唯一最优策略是 π^+，其最优 log-ratio 为

$$u^+(s,a) = \log \frac{\pi^+(a \mid s)}{\mu(a \mid s)} = \eta f(s,a) - \log Z_f(s). \tag{2.3}$$

2.1.1 为什么优势函数的行为均值为零

条件 $\mathbb{E}_\mu[f(s,a) \mid s] = 0$ 不是任意 reward 的性质。若 $f = A^\mu$ 是行为策略的优势函数，则

$$A^\mu(s,a) = Q^\mu(s,a) - V^\mu(s), \qquad V^\mu(s) = \mathbb{E}_{a\sim\mu}[Q^\mu(s,a) \mid s],$$

从而

$$\begin{aligned} \mathbb{E}_\mu[A^\mu(s,a) \mid s] &= \mathbb{E}_\mu[Q^\mu(s,a) \mid s] - V^\mu(s) \\ &= 0. \end{aligned}$$

若 f 是即时 reward、教师分数或一般 OPD 信号，则必须把中心化作为显式定义。令

$$\bar{f}(s) = \mathbb{E}_\mu[f(s,a) \mid s], \qquad \widetilde{f}(s,a) = f(s,a) - \bar{f}(s).$$

减去只依赖 prefix 的常数不改变 Gibbs 策略，因为

$$\frac{\mu(a \mid s) e^{\eta \widetilde{f}(s,a)}}{\mathbb{E}_\mu[e^{\eta \widetilde{f}(s,\cdot)} \mid s]} = \frac{\mu(a \mid s) e^{\eta f(s,a)}}{\mathbb{E}_\mu[e^{\eta f(s,\cdot)} \mid s]}.$$

后文在 BPO 和 PMD-Mean 中使用 $\widetilde{f}$；PMD-Part 直接保留精确的 $\log Z_f(s)$。

2.2 三种算法的逐步推导

2.2.1 PMD-Part：回归完整的最优 log-ratio

把式(2.3) 当作 supervised target，定义

$$h(s,a) = \eta f(s,a) - \log Z_f(s), \qquad q_\theta(s,a) = h(s,a) - u_\theta(s,a).$$

PMD-Part 损失和下降方向分别为

$$\mathcal{L}_{\text{Part}} = \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[q_\theta(s,a)^2], \tag{2.4}$$

$$-\nabla_\theta \mathcal{L}_{\text{Part}} = \mathbb{E}_{d_\mu,\mu}[q_\theta(s,a) g_\theta(s,a)]. \tag{2.5}$$

这里的 target 常数 $\log Z_f(s)$ 固定了 action-independent 方向。

2.2.2 PMD-Mean：中心化 target 加归一化投影

PMD-Mean不显式回归 $\log Z_f$，而令

$$g_{\text{Mean}}(s,a) = \eta \widetilde{f}(s,a)$$

并求解

$$\min_u \frac{1}{2}\mathbb{E}_{d_\mu,\mu}[(u - g_{\text{Mean}})^2] \quad \text{s.t.} \quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}] = 1. \tag{2.6}$$

固定 prefix 后，写出拉格朗日函数

$$\mathcal{J}(u,\lambda) = \frac{1}{2}\sum_a \mu_a (u_a - g_a)^2 + \lambda\left(\sum_a \mu_a e^{u_a} - 1\right).$$

因为 $\mu_a > 0$，一阶条件为

$$u_a - g_a + \lambda e^{u_a} = 0.$$

令 $v_a = g_a - u_a$，则

$$v_a e^{v_a} = \lambda e^{g_a}.$$

由 Lambert-W 的定义 $W(z)e^{W(z)} = z$，得到

$$u^+_{\text{Mean}}(s,a) = g_{\text{Mean}}(s,a) - W\left(\lambda(s) e^{g_{\text{Mean}}(s,a)}\right), \tag{2.7}$$

其中 $\lambda(s)$ 由归一化约束唯一确定。PMD-Mean 是投影问题；除特殊情形外，式(2.7) 不等于精确 Gibbs log-ratio。

2.2.3 BPO：对同一最优性方程做中心化 residual 回归

先定义 $b_\theta(s,a) = \eta f(s,a) - u_\theta(s,a)$。令

$$\bar{b}_\theta(s) = \mathbb{E}_{a\sim\mu}[b_\theta(s,a) \mid s].$$

BPO的 residual 是

$$\delta_\theta(s,a) = b_\theta(s,a) - \bar{b}_\theta(s). \tag{2.8}$$

若使用中心化信号 $\widetilde{f}$，则

$$\delta_\theta = \eta\widetilde{f} - u_\theta + \mathbb{E}_\mu[u_\theta \mid s], \qquad \mathbb{E}_\mu[\delta_\theta \mid s] = 0.$$

完整 reverse-KL 的导数给出

$$\nabla_\theta \delta_\theta(s,a) = -\left(g_\theta(s,a) - \bar{g}_\theta(s)\right), \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

所以未线性化 BPO 损失

$$\mathcal{L}_{\text{BPO}} = \frac{1}{2\eta}\mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)^2] \tag{2.9}$$

的下降方向为

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_\mu,\mu}[\delta_\theta(s,a)(g_\theta(s,a) - \bar{g}_\theta(s))]. \tag{2.10}$$

2.3 OPD 的具体化：从教师分布反推 token reward

OPD 的教师通常直接给出下一个 token 的条件分布，而不是已经中心化的优势函数。令教师分布为 $T(a \mid s)$，行为策略为 $\mu(a \mid s)$，并假设 $T(\cdot \mid s) \ll \mu(\cdot \mid s)$。要求镜像子问题的最优策略恰好等于教师，即 $\pi^+(\cdot \mid s) = T(\cdot \mid s)$。由式(2.3) 反解可取

$$r_T(s,a) = \frac{1}{\eta}\log\frac{T(a \mid s)}{\mu(a \mid s)} + c(s), \tag{2.11}$$

其中 $c(s)$ 是只依赖 prefix 的任意常数。取 $c(s) = 0$ 时，

$$\begin{aligned} Z_{r_T}(s) &= \mathbb{E}_\mu\left[\exp\left(\eta r_T(s,a)\right) \mid s\right] \\ &= \mathbb{E}_\mu\left[\frac{T(a \mid s)}{\mu(a \mid s)} \mid s\right] = 1. \end{aligned}$$

因此

$$\frac{\mu(a \mid s)e^{\eta r_T(s,a)}}{Z_{r_T}(s)} = T(a \mid s). \tag{2.12}$$

这说明 OPD 的 token reward 可以直接取教师与行为策略的 log-ratio；它是使教师分布成为 KL 镜像问题精确解的反推构造。若还存在外部 token reward r_{ext}，取

$$r_{\mathrm{OPD}}(s,a) = r_{\mathrm{ext}}(s,a) + \frac{1}{\eta}\log\frac{T(a \mid s)}{\mu(a \mid s)} \tag{2.13}$$

可得

$$\pi^+(a \mid s) = \frac{T(a \mid s)e^{\eta r_{\mathrm{ext}}(s,a)}}{\mathbb{E}_{a'\sim T(\cdot|s)}[e^{\eta r_{\mathrm{ext}}(s,a')}]}. \tag{2.14}$$

将 r_T 代入三种算法即可得到 OPD 实例化。PMD-Part 的 target、损失和下降方向为

$$h_T(s,a) = \eta r_T(s,a) - \log Z_{r_T}(s) = \log\frac{T(a \mid s)}{\mu(a \mid s)}, \tag{2.15}$$

$$\mathcal{L}^{\mathrm{OPD}}_{\mathrm{Part}} = \frac{1}{2}\mathbb{E}_{d_\mu,\mu}\left[\left(u_\theta - \log\frac{T}{\mu}\right)^2\right], \tag{2.16}$$

$$-\nabla\mathcal{L}^{\mathrm{OPD}}_{\mathrm{Part}} = \mathbb{E}_{d_\mu,\mu}\left[\left(\log\frac{T}{\mu} - u_\theta\right)g_\theta\right]. \tag{2.17}$$

PMD-Mean 使用行为均值去掉未知的 prefix 常数。定义

$$g_T(s,a) = \eta\left(r_T(s,a) - \mathbb{E}_\mu[r_T(s,a) \mid s]\right) = \log\frac{T(a \mid s)}{\mu(a \mid s)} - \mathbb{E}_\mu\left[\log\frac{T}{\mu} \mid s\right]. \tag{2.18}$$

将 g_T 代入式(2.6)，再通过 Lambert-W 乘子恢复归一化。中心化只移除 prefix 常数，不改变教师 Gibbs 策略。

BPO 使用同一个 OPD reward 的中心化 residual：

$$\delta_T(s,a) = \eta\left(r_T(s,a) - \mathbb{E}_\mu[r_T \mid s]\right) - u_\theta(s,a) + \mathbb{E}_\mu[u_\theta \mid s]. \tag{2.19}$$

其未线性化下降方向为

$$-\eta\nabla\mathcal{L}^{\mathrm{OPD}}_{\mathrm{BPO}} = \mathbb{E}_{d_\mu,\mu}\left[\delta_T(s,a)\left(g_\theta(s,a) - \mathbb{E}_\mu[g_\theta \mid s]\right)\right]. \tag{2.20}$$

在 T 的完整 logits 可得时，式(2.11) 是逐 token 的精确信号；从有限采样近似教师分布时，才会额外引入 reward 和 log-ratio 的估计误差。

2.4 直接优化镜像目标：MDPO

直接对镜像目标

$$F_s(\theta) = \mathbb{E}_{\pi_\theta}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(\pi_\theta \| \mu) \tag{2.21}$$

做梯度上升。令 $\rho_\theta = \pi_\theta/\mu$，则

$$\nabla F_s(\theta) = \mathbb{E}_{a\sim\pi_\theta}\left[\left(f(s,a) - \frac{1}{\eta}\log\rho_\theta(s,a)\right) g_\theta(s,a)\right] = \mathbb{E}_{a\sim\mu}\left[\rho_\theta(s,a)\left(f - \frac{1}{\eta}\log\rho_\theta\right) g_\theta\right]. \tag{2.22}$$

MDPO 与三种回归方法共享同一 Gibbs 驻点，但显式保留 action-level importance ratio。

2.5 共享零点、不同梯度的定理

命题 2.1 (三种方法的共享零点)

在有限 action space、$\mu(a \mid s) > 0$ 且策略归一化成立时，PMD-Part 与未线性化 BPO 在精确 Gibbs 策略 π^+ 处达到零 residual。PMD-Mean 在其中心化 target 可实现并满足归一化约束时达到同一策略；一般情况下它给出约束集合上的欧氏投影。

证明 PMD-Part 由 $u_\theta = h$ 直接得到 $u_\theta = u^+$。对 BPO，若 $\delta_\theta = 0$，则 $u_\theta = \eta f - C(s)$，其中 $C(s)$ 与 action 无关。归一化给出

$$1 = \mathbb{E}_\mu[e^{u_\theta} \mid s] = e^{-C(s)}\mathbb{E}_\mu[e^{\eta f} \mid s] = e^{-C(s)} Z_f(s),$$

所以 $C(s) = \log Z_f(s)$，即 $u_\theta = u^+$。PMD-Mean 在 target 可实现并满足归一化约束时也取到该策略；不可实现时，它取的是约束集合上的欧氏投影。

定理 2.1 (未线性化 BPO 与 PMD-Part 的梯度差异)

令 $q_\theta = h - u_\theta$，并令

$$c_\theta(s) = \log Z_f(s) + \mathbb{E}_\mu[u_\theta(s,a) \mid s], \qquad \bar{g}_\theta(s) = \mathbb{E}_\mu[g_\theta(s,a) \mid s].$$

则 $\delta_\theta = q_\theta + c_\theta$，且

$$-\eta\nabla\mathcal{L}_{\mathrm{BPO}} = -\nabla\mathcal{L}_{\mathrm{Part}} + \mathbb{E}_{s\sim d_\mu}[c_\theta(s)\bar{g}_\theta(s)]. \tag{2.23}$$

因此二者共享零点，但一般不具有相同的梯度场；只有 $c_\theta(s)\bar{g}_\theta(s) = 0$ 对 d_μ-几乎处处成立时才相同。

证明 由 $q_\theta = \eta f - \log Z_f - u_\theta$，而 BPO 使用 $\delta_\theta = \eta f - u_\theta + \mathbb{E}_\mu[u_\theta \mid s]$，相减得到 $\delta_\theta = q_\theta + c_\theta$。另一方面，$\mathbb{E}_\mu[\delta_\theta \mid s] = 0$，所以

$$\begin{aligned} -\eta\nabla\mathcal{L}_{\mathrm{BPO}} &= \mathbb{E}[\delta_\theta(g_\theta - \bar{g}_\theta)] \\ &= \mathbb{E}[\delta_\theta g_\theta] \\ &= \mathbb{E}[(q_\theta + c_\theta) g_\theta] \\ &= \mathbb{E}[q_\theta g_\theta] + \mathbb{E}[c_\theta \bar{g}_\theta]. \end{aligned}$$

第一项正是 $-\nabla\mathcal{L}_{\mathrm{Part}}$，得到式(2.23)。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu,\mu}[(u_\theta - h)^2], \tag{3.8}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu}\,\mathrm{Var}_{a\sim\mu}[u_\theta(a) - \eta f(a)]. \tag{3.9}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s)\sum_a \nabla\pi(a \mid s)A^\mu(s,a) + \sum_s d_\pi(s)\sum_a \nabla\pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.10}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.11}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.12}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.13}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.