从 PMD 与 BPO 到 MirrorOPD：访问测度、回归投影与策略梯度

对 token-level 与 sequence-level 镜像更新的统一推导

摘要

本文固定一个有限时域自回归生成问题，系统推导 sequence-level Policy Mirror Descent（PMD）、token-level PMD/Bellman Policy Optimization（BPO）以及 score centering 之间的关系。核心结论有三点。第一，token-level 与 sequence-level 的差异首先是访问测度和软价值定义的差异；只有使用与序列配分函数一致的软 Q，两者的精确闭式解才一致。第二，直接对 KL 正则化目标做策略梯度与通过最优性残差回归寻找镜像目标，通常不是同一个离开当前策略点的更新；它们在精确镜像解处共享零点，在 on-policy 积分且忽略采样测度导数等特殊条件下才可能呈现相同的一阶形式。第三，BPO 残差中的反向 KL 项确实产生了 score centering，但这是一种由最优性方程导出的中心化，不等于恢复被去掉的 importance sampling ratio。本文暂不推导 OPD 的 off-policy 修正算法，只把后续 MirrorOPD 的数学边界写清楚。

目录

摘要 **ii**

第一章 问题、记号与两个镜像子问题 **1**
1.1 有限时域自回归生成模型 . . . 1
1.2 序列级 PMD . . . 1
1.3 token-level PMD 与 BPO 子问题 . . . 2

第二章 访问测度：为什么 token-level 与 sequence-level 不应直接混称 **3**
2.1 序列解的条件分解 . . . 3
2.2 访问测度的三个层次 . . . 3
2.3 一个两步反例 . . . 4

第三章 从最优策略回归到直接策略梯度 **5**
3.1 序列级目标的直接策略梯度 . . . 5
3.2 PMD-Part 回归的精确梯度 . . . 5
3.3 token-level BPO 的直接 PG 与残差回归 . . . 6
3.4 BPO 的直接 PG 形式 . . . 6
3.5 PMD-Mean：均值近似与隐式正则化 . . . 7

第四章 score centering、优势中心化与 BPO 的关系 **9**
4.1 优势函数中心化 . . . 9
4.2 BPO 中的两种中心化不要混淆 . . . 9

第五章 BPO 的 prefix 访问测度与 token-level PMD 构造 **10**
5.1 BPO 为什么通常不需要 prefix importance sampling . . . 10
5.2 Prefix-level PMD-Part . . . 10
5.3 Prefix-level PMD-Mean 与 Lambert-W 投影 . . . 11
5.4 一个可操作的区分 . . . 11

第六章 官方实现的 inner steps 与实际收敛证据 **12**
6.1 判断标准 . . . 12
6.2 OpenKimi/PMD 的实现 . . . 12
6.3 经典 MDPO 的 on-policy 实现 . . . 12
6.4 经典 MDPO 的 off-policy 实现 . . . 13
6.5 对实验设计的含义 . . . 13

第七章 结论与后续 MirrorOPD 的边界 **14**
7.1 对三个问题的直接回答 . . . 14
7.2 后续推导必须保留的区分 . . . 14

第一章 问题、记号与两个镜像子问题

1.1 有限时域自回归生成模型

给定上下文 x，模型生成长度为 T 的序列 $y = (a_1, \dots, a_T)$。第 t 步的 prefix 为

$$s_t = (x, a_{<t}), \qquad a_t \sim \pi(\cdot \mid s_t).$$

为简化记号，以下将完整序列概率写成

$$\pi(y \mid x) = \prod_{t=1}^{T} \pi(a_t \mid s_t).$$

行为策略记作 μ，候选学生策略记作 π，并定义 token ratio

$$\rho_t = \frac{\pi(a_t \mid s_t)}{\mu(a_t \mid s_t)}, \qquad W_T(y) = \frac{\pi(y \mid x)}{\mu(y \mid x)} = \prod_{t=1}^{T} \rho_t.$$

所有 KL 和 ratio 都要求在相应的绝对连续性条件下定义。若 $\mu(a \mid s) = 0$ 而 $\pi(a \mid s) > 0$，则 sequence-level ratio 不存在；这不是数值问题，而是 support 条件失败。

令 $R(y)$ 为完整响应的回报。为了把序列级和逐 token 目标放在同一尺度，定义

$$J(\pi) = \mathbb{E}_{y \sim \pi}[R(y)].$$

在上下文固定时，状态分布 $d_\pi(s)$ 表示在策略 π 下访问 prefix s 的期望次数；有限时域下它可以是未归一化的 occupancy，满足 $\sum_s d_\pi(s) = T$。

1.2 序列级 PMD

从行为策略 μ 出发的 KL 镜像子问题为

$$\pi^{+}_{\mathrm{seq}} = \arg\max_{\pi \ll \mu} \left\{ J(\pi) - \tau \, \mathrm{KL}(\pi \| \mu) \right\}, \qquad \tau > 0. \tag{1.1}$$

这里的 KL 是完整响应分布的 KL：

$$\mathrm{KL}(\pi \| \mu) = \mathbb{E}_{y \sim \pi} \left[\log \frac{\pi(y \mid x)}{\mu(y \mid x)} \right].$$

引理 1.1 (序列级 Gibbs 解)

令

$$Z_0(x) = \mathbb{E}_{y \sim \mu} \left[\exp\left(\frac{R(y)}{\tau} \right) \right].$$

若 $0 < Z_0(x) < \infty$，则式(1.1) 的唯一解为

$$\pi^{+}_{\mathrm{seq}}(y \mid x) = \frac{\mu(y \mid x) \exp(R(y)/\tau)}{Z_0(x)}. \tag{1.2}$$

并且对任意 $\pi \ll \mu$，有

$$J(\pi) - \tau \, \mathrm{KL}(\pi \| \mu) = \tau \log Z_0(x) - \tau \, \mathrm{KL}(\pi \| \pi^{+}_{\mathrm{seq}}). \tag{1.3}$$

♡

证明 由式(1.2)，

$$\log \pi^{+}_{\mathrm{seq}}(y \mid x) = \log \mu(y \mid x) + \frac{R(y)}{\tau} - \log Z_0(x).$$

将其代入 $\mathrm{KL}(\pi\|\pi^{+}_{\mathrm{seq}})$，得到

$$\begin{aligned}\mathrm{KL}(\pi\|\pi^{+}_{\mathrm{seq}}) &= \mathbb{E}_{\pi}\left[\log\frac{\pi}{\mu} - \frac{R}{\tau} + \log Z_0\right] \\ &= \mathrm{KL}(\pi\|\mu) - \frac{J(\pi)}{\tau} + \log Z_0.\end{aligned}$$

移项即得式(1.3)。KL 非负且仅在 $\pi = \pi^{+}_{\mathrm{seq}}$ 时取零，因此唯一性成立。

1.3 token-level PMD 与 BPO 子问题

对每个 prefix s，给定一个相对于行为策略中心化的 action score $A(s,a)$，满足

$$\mathbb{E}_{a\sim\mu(\cdot|s)}[A(s,a)] = 0. \tag{1.4}$$

逐状态 KL 镜像子问题为

$$\pi^{+}_{\mathrm{tok}}(\cdot\mid s) = \arg\max_{p\ll\mu(\cdot|s)}\left\{\mathbb{E}_{a\sim p}[A(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p\|\mu(\cdot\mid s))\right\}. \tag{1.5}$$

其中 $\eta > 0$ 是 inverse temperature。其闭式解为

$$\pi^{+}_{\mathrm{tok}}(a\mid s) = \frac{\mu(a\mid s)\exp(\eta A(s,a))}{Z_A(s)}, \qquad Z_A(s) = \mathbb{E}_{\mu(\cdot|s)}[e^{\eta A(s,\cdot)}]. \tag{1.6}$$

BPO 可以理解为：把式(1.5) 的逐状态最优性条件沿行为轨迹写成一个轨迹残差，再用平方损失拟合该残差为零。这里的 “token-level” 指镜像子问题按条件分布 $p(\cdot\mid s)$ 解耦；它不意味着完整生成目标一定只包含当前 token 的回报。

第二章 访问测度：为什么 token-level 与 sequence-level 不应直接混称

2.1 序列解的条件分解

定义从 prefix s_t 出发的条件软配分函数

$$Z_t(s_t) = \mathbb{E}_{y_{t:T}\sim\mu(\cdot|s_t)}\left[\exp\left(\frac{R(y)}{\tau}\right)\middle| s_t\right], \tag{2.1}$$

其中 $Z_1(x) = Z_0(x)$。对任意合法 transition $s_{t+1} = s_t a_t$，条件化式(1.2) 可得

$$\pi^+_{\text{seq}}(a_t \mid s_t) = \mu(a_t \mid s_t)\frac{Z_{t+1}(s_{t+1})}{Z_t(s_t)}. \tag{2.2}$$

因此定义软 Q 和软 V：

$$Q^\tau_\mu(s_t, a_t) = \tau \log Z_{t+1}(s_{t+1}), \tag{2.3}$$

$$V^\tau_\mu(s_t) = \tau \log Z_t(s_t), \tag{2.4}$$

$$A^\tau_\mu(s_t, a_t) = Q^\tau_\mu(s_t, a_t) - V^\tau_\mu(s_t). \tag{2.5}$$

则式(2.2) 等价于

$$\pi^+_{\text{seq}}(a_t \mid s_t) = \mu(a_t \mid s_t)\exp\left(\frac{A^\tau_\mu(s_t, a_t)}{\tau}\right). \tag{2.6}$$

这里 $\mathbb{E}_\mu[\exp(A^\tau_\mu/\tau) \mid s_t] = 1$，所以不需要再写一个局部归一化常数。

命题 2.1 (精确等价的必要条件)

在无限容量、精确软 Q、确定性 prefix tree 和相同终止边界下，sequence-level PMD 的闭式解与逐状态 PMD 的闭式解相同。若 token-level 方法使用普通硬优势 A^μ，或者使用独立的局部 reward-to-go 而没有软 continuation value，则一般只有在特殊条件下相同。

证明 用 $A = A^\tau_\mu$ 和 $\eta = 1/\tau$ 代入式(1.6)，由 $Z_A(s) = 1$ 得到式(2.6)。这说明逐状态解正好是序列解的条件分布。

反之，若采用任意 $\widetilde{A}$，则逐状态解的条件 ratio 为

$$\frac{\pi^+_{\text{tok}}(a \mid s)}{\mu(a \mid s)} = \frac{e^{\eta\widetilde{A}(s,a)}}{\mathbb{E}_\mu[e^{\eta\widetilde{A}(s,\cdot)} \mid s]}.$$

它与式(2.2) 相同，当且仅当 $\eta\widetilde{A}(s,a)$ 与 $A^\tau_\mu(s,a)/\tau$ 只相差一个与 a 无关的状态常数。普通硬优势没有包含 $\log Z_{t+1}(sa)$ 的 continuation term，因此通常不满足该条件。

2.2 访问测度的三个层次

需要把三个经常被合并的测度分开：

1. **全局最优策略的测度**。式(1.1) 的第一项在 π 下积分，完整 KL 也在 π 下积分；它的驻点自然携带 d_π。
2. **行为数据的访问测度**。BPO 或残差回归通常在 $s \sim d_\mu$、$a \sim \mu(\cdot \mid s)$ 下训练。它可以逐点识别一个满支撑的条件最优解，但不会凭空提供 $d_\pi(s) = 0$ 的 prefix 监督。
3. **参数化模型的优化测度**。当 $\pi = \pi_\theta$ 不能同时实现所有状态上的闭式解时，平方回归的梯度由 d_μ 加权；即使理论上每个状态解相同，有限容量下哪些状态被优先拟合仍由访问测度决定。

定理 2.1 (正权重下的点 wise 不变性与函数逼近偏差)

设每个状态上的目标条件分布 $p^+(\cdot \mid s)$ 唯一，且 $w(s) > 0$ 对所有被考虑状态成立。对于无约束的条件策略族，

$$\arg\min_{p} \sum_{s} w(s)\,\mathrm{KL}(p(\cdot \mid s) \| p^+(\cdot \mid s))$$

与 $w(s)$ 无关，均为 p^+。但对受限参数族 p_θ，最小值和梯度一般依赖 w；若存在未覆盖状态 $w(s) = 0$，其条件分布完全不可识别。

证明 无约束时目标是各状态 KL 的非负加权和；每一项都能同时取零，因此唯一解为逐状态的 p^+。受限参数族中不能逐项取零，权重改变各项残差在总体目标中的相对重要性，因而改变投影点。若 $w(s) = 0$，该状态不出现在目标中，任意条件分布都给出相同损失。

注因此“最终最优解可能一样”需要注明模型容量、support 和 score 的条件。即便闭式解相同，token-level 的训练梯度仍由 d_μ 加权，而 sequence-level PG 则由 d_π 加权；两者在有限 batch、有限容量和 replay 下会产生不同的学习轨迹。

2.3 一个两步反例

考虑两步树：第一步有 $a \in \{L, R\}$，第二步只在 R 后有两个 action。令 $R(L) = 0$，而 $R(R, u) = 1$、$R(R, v) = 0$。即使 μ 在 R 后几乎不采样到 u，sequence PMD 的条件解仍由 R 后的完整 continuation 配分函数决定；若 token-level 方法只用在 d_μ 下估计的局部硬 advantage，第二步稀有 prefix 的 target 几乎没有梯度，第一步也无法准确获得“进入 R 会带来后续软价值”的信息。

这个反例不否认逐状态闭式解的存在。它说明：局部最优问题的解耦依赖于已经知道正确的 Q；访问测度决定的是我们能否估计这个 Q、能否把它投影到共享参数以及能否覆盖稀有 prefix。sequence-level 的全局配分函数和 token-level 的局部回归在有限数据下承担不同的统计任务。

第三章 从最优策略回归到直接策略梯度

3.1 序列级目标的直接策略梯度

令 $\rho(y)=\pi(y)/\mu(y)$。对

$$F_{\mathrm{seq}}(\pi)=\mathbb{E}_{\pi}[R]-\tau\,\mathrm{KL}(\pi\|\mu)$$

求参数梯度。因为 $\log\rho(y)=\log\pi(y)-\log\mu(y)$，且 μ 固定，有

$$\nabla_\theta F_{\mathrm{seq}}(\pi_\theta)=\mathbb{E}_{y\sim\pi_\theta}\left[(R(y)-\tau\log\rho(y))\,\nabla_\theta\log\pi_\theta(y)\right]. \tag{3.1}$$

推导中出现的 $-\tau\mathbb{E}_\pi[\nabla\log\pi]$ 为零。换成行为数据后，式(3.1) 为

$$\nabla_\theta F_{\mathrm{seq}}=\mathbb{E}_{y\sim\mu}\left[W_T(y)\,(R(y)-\tau\log W_T(y))\sum_{t=1}^{T}g_t(y)\right],\quad g_t=\nabla_\theta\log\pi_\theta(a_t\mid s_t). \tag{3.2}$$

这是直接对正则化目标做 ascent 的 PG。其主要困难是 $W_T=\prod_t\rho_t$ 的重尾，而不是 $\log W_T$ 的线性累积本身。

3.2 PMD-Part 回归的精确梯度

定义序列最优性残差

$$\delta_{\mathrm{seq}}(y;\pi)=\frac{R(y)}{\tau}-\log W_T(y)-\log Z_0(x). \tag{3.3}$$

PMD-Part 用行为测度下的平方回归

$$\mathcal{L}_{\mathrm{part}}(\pi)=\frac{1}{2}\mathbb{E}_{y\sim\mu}[\delta_{\mathrm{seq}}(y;\pi)^2]. \tag{3.4}$$

设

$$c(y)=R(y)-\tau\log W_T(y)-\tau\log Z_0(x).$$

因为 $\nabla\delta_{\mathrm{seq}}=-\nabla\log W_T=-\sum_t g_t$，有

$$-\tau\nabla_\theta\mathcal{L}_{\mathrm{part}}=\mathbb{E}_\mu\left[c(y)\sum_t g_t(y)\right]. \tag{3.5}$$

命题 3.1 (回归梯度与直接 PG 的关系)

除非 $W_T(y)$ 为常数，或者处在精确镜像解 $\pi=\pi^{+}_{\mathrm{seq}}$，式(3.5) 与式(3.2) 一般不相同。二者共享相同的零点，但不共享一般的离开点方向。

证明 把式(3.2) 写成行为测度：其被积函数是 $W_T(y)c_0(y)g(y)$，其中 $c_0=R-\tau\log W_T$。回归梯度的被积函数是 $c(y)g(y)$，其中 $c=c_0-\tau\log Z_0$。常数项在直接 PG 中因 $\mathbb{E}_\pi[g]=0$ 消失，但在行为测度下 $\mathbb{E}_\mu[g]$ 一般不为零；更重要的是回归项没有 W_T。因此一般不等。

在精确镜像解处，$\log W_T=R/\tau-\log Z_0$，所以 $c(y)=0$，回归梯度为零；直接 PG 也因该策略最大化式(1.1) 而为零。若 W_T 在所有样本上为同一个常数，则两种测度只差一个常数，方向可以退化为相同。

注 [为什么还要回归] 回归不是对同一个标量目标换一种写法，而是在解一个更容易从行为数据估计的最优性方程：

$$\log\pi^{+}(y)-\log\mu(y)=R(y)/\tau-\log Z_0.$$

它把乘性 ratio 从梯度权重中移到对数残差中。代价是：离开根点时它不再是原始 KL 正则化目标的无偏梯度；它优化的是“到镜像解的投影误差”，而非每一步都保持原目标的 ascent 方向。

3.3 token-level BPO 的直接 PG 与残差回归

固定状态 s，记 $h(a) = \eta A(s,a)$、$\rho(a) = \pi(a \mid s)/\mu(a \mid s)$，并令

$$K(\pi) = \mathrm{KL}(\mu(\cdot \mid s) \| \pi(\cdot \mid s)) = \mathbb{E}_\mu[-\log \rho(a)].$$

由于 $\mathbb{E}_\mu[A] = 0$，有

$$\mathbb{E}_\mu[h(a) - \log \rho(a)] = K(\pi). \tag{3.6}$$

BPO 的局部残差写成

$$\delta_s(a) = h(a) - \log \rho(a) - K(\pi). \tag{3.7}$$

由式(3.6)，$\mathbb{E}_\mu[\delta_s] = 0$ 对任意 π 都成立。镜像解满足

$$\log \rho^+(a) = h(a) - \log Z_A(s), \qquad K(\pi^+) = \log Z_A(s),$$

故 $\delta_s(a) = 0$。

相应的局部 BPO 回归损失为

$$\mathcal{L}_s(\pi) = \frac{1}{2\eta} \mathbb{E}_{a\sim\mu}[\delta_s(a)^2]. \tag{3.8}$$

命题 3.2 (BPO 残差的 score centering)

令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$，$\bar{g} = \mathbb{E}_\mu[g]$。若对 $K(\pi)$ 完整求导，则

$$\nabla_\theta K(\pi) = -\mathbb{E}_\mu[g] = -\bar{g}, \tag{3.9}$$

且

$$-\eta \nabla_\theta \mathcal{L}_s = \mathbb{E}_\mu\left[\delta_s(a)\big(g(a) - \bar{g}\big)\right]. \tag{3.10}$$

因此 $-\mathrm{KL}(\mu\|\pi)$ 项在求导时把 raw score g 变成了行为测度下的中心化 score $g - \mathbb{E}_\mu[g]$。

证明 由 $K = \mathbb{E}_\mu[\log \mu - \log \pi]$，行为策略固定，式(3.9) 直接成立。又有

$$\nabla_\theta \delta_s(a) = -g(a) - \nabla K = -g(a) + \bar{g}.$$

对式(3.8) 求导，得到

$$\nabla \mathcal{L}_s = \frac{1}{\eta} \mathbb{E}_\mu[\delta_s(-g + \bar{g})].$$

乘以 $-\eta$ 即得式(3.10)。

注 [score centering 不等于 IS correction] 式(3.10) 的中心化来自 $\mathrm{KL}(\mu\|\pi)$ 对候选策略参数的导数。它消除了行为测度下 score 的均值，但没有把 $\mathbb{E}_\mu$ 变成 $\mathbb{E}_\pi$；因此它不能单独恢复式(3.2) 或 token-level 直接 PG 中的 ρ。中心化解决的是 baseline/score 的几何问题，IS 解决的是积分测度问题。

3.4 BPO 的直接 PG 形式

对局部 KL 正则目标

$$G_s(\pi) = \mathbb{E}_{a\sim\pi}[A(s,a)] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu) \tag{3.11}$$

求导，得到

$$\nabla G_s = \mathbb{E}_{a\sim\pi}\left[\left(A(s,a) - \frac{1}{\eta}\log \rho(a)\right) g(a)\right] = \mathbb{E}_{a\sim\mu}\left[\rho(a)\left(A(s,a) - \frac{1}{\eta}\log \rho(a)\right) g(a)\right]. \tag{3.12}$$

式(3.12) 是局部 KL 正则化目标的真实 PG。与式(3.10) 比较：

- 直接 PG 使用 $\rho(a)$ 改变积分测度，并使用 forward KL $\mathrm{KL}(\pi\|\mu)$ 的 log-ratio；
- BPO 回归使用行为测度下的中心化残差 δ_s，其根与闭式镜像解一致，但一般不等于直接 PG；

- 当 $\pi = \pi^+$ 时，$\delta_s = 0$ 且 $\nabla G_s = 0$，所以两者在驻点一致。

命题 3.3 (何时可以说“形式一致”)

如果“形式一致”只指两种方法具有相同的精确目标策略和相同的零点，则 PMD-Part 与 BPO 回归都满足。若“形式一致”指每个训练点的随机梯度逐样本相等，则一般不满足；需要额外的 ratio 加权、特殊参数化或恰好位于镜像解。

证明 前者由式(1.2)、(1.6) 和残差为零条件直接得到。后者则由式(3.2) 与(3.5)、式(3.12) 与(3.10) 的被积函数不同得到。

3.5 PMD-Mean：均值近似与隐式正则化

PMD-Part的序列级目标使用精确的配分函数：若 $u(y) = \log(\pi(y)/\mu(y))$，则其理想回归目标为

$$u^\star_{\text{part}}(y) = \frac{R(y)}{\tau} - \log Z_0(x).$$

PMD-Mean 用行为策略下的均值奖励替代未知的 $\tau \log Z_0$。令

$$\bar{R} = \mathbb{E}_\mu[R], \qquad \Delta(y) = R(y) - \bar{R}, qquad g(y) = \frac{\Delta(y)}{\tau},$$

其总体平方损失可写为

$$\mathcal{L}_{\text{mean}}(\pi) = \frac{1}{2}\mathbb{E}_{y\sim\mu}\left[\left(\log\frac{\pi(y)}{\mu(y)} - g(y)\right)^2\right], \qquad \mathbb{E}_\mu\left[\frac{\pi}{\mu}\right] = 1. \tag{3.13}$$

这里的归一化约束是策略单纯形约束；它不能被从回归问题中删去。否则逐样本令 $u = g$ 通常不会满足 $\mathbb{E}_\mu[e^u] = 1$。

命题 3.4 (PMD-Mean 的 Lambert-W 驻点)

假设 $\mu(y) > 0$，且 $\mathbb{E}_\mu[e^g] < \infty$。若 π^+_{mean} 是式(3.13) 的全局极小点，则存在唯一的 $\lambda \geq 0$，使得

$$u^+(y) = g(y) - W\left(\lambda e^{g(y)}\right), \qquad \pi^+_{\text{mean}}(y) = \mu(y)e^{u^+(y)}, \tag{3.14}$$

其中 W 是满足 $W(z)e^{W(z)} = z$ 的 Lambert-W 主分支，λ 由 $\mathbb{E}_\mu[e^{u^+}] = 1$ 确定。

证明 对 u 加入归一化约束，拉格朗日函数为

$$\mathscr{L}(u, \lambda) = \frac{1}{2}\mathbb{E}_\mu[(u-g)^2] + \lambda\left(\mathbb{E}_\mu[e^u] - 1\right).$$

逐点的一阶条件是

$$u(y) - g(y) + \lambda e^{u(y)} = 0. \tag{3.15}$$

将 $v(y) = g(y) - u(y)$ 代入，得到

$$v(y)e^{v(y)} = \lambda e^{g(y)},$$

故 $v(y) = W(\lambda e^{g(y)})$，即式(3.14)。又因为 $\mathbb{E}_\mu[g] = 0$，对式(3.15) 取期望并使用 $\mathbb{E}_\mu[e^u] = 1$，得 $\mathbb{E}_\mu[u] = -\lambda$。Jensen 不等式给出 $\mathbb{E}_\mu[u] \leq \log \mathbb{E}_\mu[e^u] = 0$，所以 $\lambda \geq 0$。当 $\lambda \geq 0$ 时，主分支上的 W 单调递增，归一化方程左端随 λ 严格递减（除非 g 几乎处处为常数），因此解唯一。

这个解与标准 PMD-Part 的 Gibbs 解有实质差异。PMD-Part 给出

$$u^+_{\text{part}}(y) = g(y) - \log \mathbb{E}_\mu[e^g],$$

其中校正项是与 y 无关的常数；PMD-Mean 的校正项 $W(\lambda e^{g(y)})$ 随奖励变化。只有在退化情形 g 为常数，或者在局部近似中把 Lambert-W 项视作常数，二者才重合。因此 PMD-Mean 不是标准 KL 镜像子问题的另一种无偏求解，而是先用均值构造回归方程，再在策略单纯形上投影所得到的不同更新。

命题 3.5 (PMD-Mean 的单调改进)

在命题 3.4 的条件下，PMD-Mean 更新满足

$$\mathbb{E}_{\pi^+_{\text{mean}}}[R] \geq \mathbb{E}_{\mu}[R]. \tag{3.16}$$

若 R 在行为测度下非退化且 $\lambda > 0$，不等式严格成立。

证明 令 $q(y) = \pi^+_{\text{mean}}(y)/\mu(y) = e^{u^+(y)}$。由式(3.14) 以及

$$\frac{\partial u^+}{\partial g} = \frac{1}{1 + W(\lambda e^g)} > 0,$$

q 是 g、从而也是 R 的严格递增函数。归一化约束给出 $\mathbb{E}_{\mu}[q] = 1$，于是

$$\begin{aligned}\mathbb{E}_{\pi^+_{\text{mean}}}[R] - \mathbb{E}_{\mu}[R] &= \mathbb{E}_{\mu}[(q-1)R] = \operatorname{Cov}_{\mu}(q, R) \\ &= \frac{1}{2}\mathbb{E}_{Y,Y'\sim\mu}\left[(q(Y) - q(Y'))(R(Y) - R(Y'))\right] \geq 0.\end{aligned}$$

最后一个不等式来自两个同向单调函数的乘积非负；若 R 非退化且 q 严格递增，则正概率集合上严格为正。

PMD-Mean因而保留了镜像更新的排序和单调改进性质，但它改变了每个奖励层级的策略比例。对本轮问题而言，这个例子把“回归最优性方程”和“直接最大化 $R - \tau\,\mathrm{KL}$”的差异展示得更清楚：PMD-Part 的残差根是 Gibbs 解，PMD-Mean 的残差根是 Lambert-W 解，二者都能作为行为数据下的稳定回归目标，却只有前者逐点对应标准 KL 正则化目标。

第四章 score centering、优势中心化与 BPO 的关系

4.1 优势函数中心化

给定行为策略下的 action value $Q^\mu(s,a)$，定义

$$V^\mu(s)=\mathbb{E}_{a\sim\mu(\cdot|s)}[Q^\mu(s,a)],\qquad A^\mu(s,a)=Q^\mu(s,a)-V^\mu(s).$$

于是 $\mathbb{E}_\mu[A^\mu\mid s]=0$。对任意只依赖状态的 baseline $b(s)$，

$$\mathbb{E}_\mu[Q^\mu(s,a)-b(s)]=V^\mu(s)-b(s).$$

所以只有取 $b(s)=V^\mu(s)$ 时，score/advantage 才在行为动作测度下中心化。

引理 4.1 (中心化对真实 PG 的不变性)

对任意状态函数 $b(s)$，在目标策略动作测度下

$$\mathbb{E}_{a\sim\pi(\cdot|s)}[b(s)\nabla_\theta\log\pi(a\mid s)]=0.$$

因此在 on-policy PG 中，Q 与 $A=Q-b(s)$ 给出相同的期望梯度。若样本来自 μ 而没有 ratio，替换 baseline 仍不改变测度偏差。

证明 对固定 s，

$$\mathbb{E}_{a\sim\pi}[\nabla\log\pi(a\mid s)]=\sum_a\nabla\pi(a\mid s)=\nabla 1=0.$$

乘以与 a 无关的 $b(s)$ 即得结论。第二句是因为 baseline 只改变被积函数，不改变样本分布。

4.2 BPO 中的两种中心化不要混淆

BPO相关推导里至少有两种中心化：

1. $Q\to A=Q-V^\mu$：中心化 reward/advantage，使 $\mathbb{E}_\mu[A]=0$，从而局部指数 target 的配分函数和残差恒等式更简洁。
2. $g\to g-\mathbb{E}_\mu[g]$：对 $K=\mathrm{KL}(\mu\|\pi)$ 求导产生的 score centering，见式(3.10)。

第一种是信号的中心化，第二种是参数 score 的中心化。它们都使用行为测度，但数学对象不同，不能把第二种解释成完整的 off-policy correction。

命题 4.1 (BPO 残差已经包含中心化，但包含的是什么)

在精确的局部 BPO 残差(3.7) 中，$K=\mathrm{KL}(\mu\|\pi)$ 使 $\mathbb{E}_\mu[\delta_s]=0$，其参数梯度使 score 变成 $g-\mathbb{E}_\mu[g]$。因此 BPO 确实内含 score-centering；但它没有内含 sequence IS，也没有消除 d_μ 对有限容量回归的加权作用。

证明 第一句是式(3.6) 的直接推论，第二句是命题 3.2。最后两句分别由式(3.12) 中的 ratio 和定理 2.1 说明。

第五章 BPO 的 prefix 访问测度与 token-level PMD 构造

5.1 BPO 为什么通常不需要 prefix importance sampling

令 s 表示一个 prefix，$d_\mu(s)$ 表示行为轨迹对它的访问测度。BPO 的核心监督对象是固定 s 后的条件最优性方程，而不是直接估计目标策略下的序列期望。以 token-level PMD 为例，若 action score $A(s,a)$ 已知，理想条件 target 为

$$u^+(s,a) = \log \frac{\pi^+(a \mid s)}{\mu(a \mid s)} = \frac{A(s,a)}{\tau} - \log Z_A(s), \qquad Z_A(s) = \mathbb{E}_{a\sim\mu(\cdot|s)}\left[e^{A(s,a)/\tau}\right]. \tag{5.1}$$

考虑行为数据上的平方回归

$$\mathcal{L}_w(u) = \frac{1}{2}\sum_s w(s)\mathbb{E}_{a\sim\mu(\cdot|s)}\left[u(s,a) - u^+(s,a)\right]^2, \qquad w(s) = d_\mu(s). \tag{5.2}$$

对一个不受参数共享约束的条件函数 u，每个 s 的一阶条件都是

$$u(s,a) = u^+(s,a) \quad \mu\text{-a.s.},$$

只要 $w(s) > 0$。因此把 $w(s)$ 换成 $d_\pi(s)$ 或任意严格正的权重不会改变 pointwise 解。prefix ratio

$$W_{<t} = \prod_{k<t} \frac{\pi(a_k \mid s_k)}{\mu(a_k \mid s_k)} = \frac{d_\pi(s_t)}{d_\mu(s_t)} \tag{5.3}$$

在确定性 prefix tree 且同一初始上下文下成立；它只会把式(5.2) 的 $w(s)$ 换成目标访问测度。因此，对条件 target 的识别没有必要额外乘 $W_{<t}$。

这不是一般的 off-policy 无偏性结论。若目标是

$$\mathbb{E}_{s\sim d_\pi, a\sim\pi}[f(s,a)],$$

而数据来自 $d_\mu\mu$，则无偏估计仍然需要 $W_{<t}\rho_t$。BPO 省略 prefix IS 的逻辑是先把目标改写成行为测度下的逐状态回归，再利用条件最优解的 pointwise 唯一性。它要求 $d_\mu(s) > 0$ 覆盖所有需要的 prefix，以及 $\mu(a \mid s) > 0$ 覆盖 target 的动作。对共享参数 u_θ，实际最小化的是

$$\arg\min_\theta \sum_s d_\mu(s)\ell_s(\theta),$$

当模型不能同时实现全部 $u^+(s,\cdot)$ 时，d_μ 会改变投影点；当某个 prefix 没有访问时，该 prefix 的 target 完全不可识别。

5.2 Prefix-level PMD-Part

由式(2.6)，sequence PMD 在 prefix s 上的精确 conditional target 使用 continuation soft advantage：

$$A^\tau_\mu(s,a) = \tau \log Z_{t+1}(sa) - \tau \log Z_t(s). \tag{5.4}$$

令

$$u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\mu(a \mid s)}.$$

则可定义 token-level PMD-Part 损失

$$\mathcal{L}_{\text{tok-Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_\mu, a\sim\mu(\cdot|s)}\left[u_\theta(s,a) - \frac{A^\tau_\mu(s,a)}{\tau}\right]^2. \tag{5.5}$$

因为 $\mathbb{E}_\mu[\exp(A^\tau_\mu/\tau) \mid s] = 1$，式(5.5) 的 target 已经包含局部归一化常数。若使用任意未归一化的 action score A，则等价写成

$$u^+_{\text{Part}}(s,a) = \frac{A(s,a)}{\tau} - \log Z_A(s).$$

在无限容量、满 support 和精确 A_μ^τ 下，该回归逐 prefix 恢复 sequence PMD 的条件分布。加入 $W_{<t}$ 只改变 prefix 的训练权重；只有在希望优化目标 occupancy 下的加权投影、或直接估计目标策略期望时才有统计上的目的。

5.3 Prefix-level PMD-Mean 与 Lambert-W 投影

令

$$\Delta(s,a) = Q(s,a) - \mathbb{E}_{a'\sim\mu(\cdot|s)}[Q(s,a')], \qquad g(s,a) = \frac{\Delta(s,a)}{\tau}.$$

逐 prefix 的 PMD-Mean 可定义为

$$\min_u \ \frac{1}{2}\mathbb{E}_{s\sim d_\mu, a\sim\mu(\cdot|s)}\left[u(s,a) - g(s,a)\right]^2 \quad \text{s.t.} \quad \mathbb{E}_{a\sim\mu(\cdot|s)}[e^{u(s,a)}] = 1 \quad \forall s. \tag{5.6}$$

约束来自 $\pi(a \mid s) = \mu(a \mid s)e^{u(s,a)}$ 的归一化，不能直接令 $u = g$。对固定 s 加入乘子 $\lambda(s)$，逐点 KKT 条件为

$$u(s,a) - g(s,a) + \lambda(s)e^{u(s,a)} = 0.$$

所以

$$u^+(s,a) = g(s,a) - W\left(\lambda(s)e^{g(s,a)}\right), \tag{5.7}$$

其中 $\lambda(s) \geq 0$ 由该 prefix 的归一化方程确定。这个构造与序列 PMD-Mean 的 Lambert-W 投影逐状态对应。它不等于标准 KL mirror subproblem 的 Gibbs 解：PMD-Part 的修正是对所有 action 相同的 $\log Z_A(s)$，PMD-Mean 的修正随 $g(s,a)$ 变化。

在模型容量无限且每个 prefix 被正权重访问时，$d_\mu(s)$ 仍不改变式(5.7) 的逐状态解。有限模型、有限样本和稀有 prefix 下，行为测度会改变回归投影及其方差；此时 prefix IS 可以作为加权投影选择，但同时引入乘积 ratio 的重尾和 support 风险。

5.4 一个可操作的区分

因此，“BPO不用 prefix IS” 应理解为一个关于条件回归的命题：在固定 prefix 后，行为动作分布提供了估计局部 target 所需的积分测度，prefix 的外层权重只影响哪些状态被拟合。它不能推出三件更强的结论：不能推出行为 occupancy 等于学生 occupancy；不能推出目标策略下的序列回报估计无偏；也不能保证共享参数模型在有限训练预算下得到目标 occupancy 的最佳投影。

第六章 官方实现的 inner steps 与实际收敛证据

6.1 判断标准

一个 outer step 是否使镜像子问题“收敛”，至少需要区分三个量：固定 rollout batch 上的子问题目标是否继续下降，最优性残差的范数是否接近零，以及 anchor 策略与拟合策略之间的 KL gap 是否达到预定容差。仅记录一次 loss 或执行固定次数的 Adam/SGD 更新，不能证明子问题已经达到闭式 PMD 解。下文把仓库中实际执行的梯度次数称为 inner budget，不把它称为 convergence steps。

6.2 OpenKimi/PMD 的实现

OpenKimi的 PMD loss 明确选择 sequence aggregation（官方仓库列于文末）。官方实现先对一条 response 的所有 token 求和：

$$\log W_T = \sum_t \left(\log \pi_\theta(a_t \mid s_t) - \log \pi_{\text{old}}(a_t \mid s_t)\right), \tag{6.1}$$

然后把同一个 sequence log-ratio broadcast 到该 response 的每个 token。其平方残差实现为

$$\ell_t = \frac{1}{2}\tau_t \left(\log W_T - \frac{A_t}{\tau_t}\right)^2,$$

并可额外按 response length 缩放。因此该代码的反向传播在 token 参数上发生，但 PMD target 的 ratio 仍是 sequence-level；它不能作为逐 prefix PMD-Part 的实现。

Qwen2.5-7B math recipe 将 `PPO_EPOCHS=1`、`train_batch_size=512` 和 `actor.ppo_mini_batch_size=32` 固定写入启动脚本。一个 global step 生成一批 rollout，随后调用一次 actor update；在静态 batch 的理想计数下，这是一个 actor epoch、约 $512/32 = 16$ 个 mini-batch 梯度更新。动态 token batch、序列并行和分布式切分会改变实际 mini-batch 数，但不会把它变成按残差阈值停止的 inner loop。脚本的 `trainer.total_training_steps=3000` 是 outer rollout/update 次数上限，`total_epochs=15` 是数据迭代上限。

仓库现有代码会记录 PMD ratio 范围、loss、KL 等训练指标，并把日志送到 console/WandB；公开 clone 中没有每个 outer step 的 inner residual 曲线、子问题 duality gap 或按容差停止记录。因此可以核实“每步做一轮固定预算的近似回归”，不能据此声称“每个 outer step 的 PMD 子问题已经收敛”。

6.3 经典 MDPO 的 on-policy 实现

经典 MDPO 仓库的 on-policy 代码（官方仓库列于文末）把 `sgd_steps` 作为固定超参数。默认构造函数中 `sgd_steps=5`；MuJoCo 运行脚本使用同一参数，README 推荐示例把它设为 10。每个 outer batch 先由 old policy 采样，随后对同一个 batch 执行

`for _ in range(sgd_steps):` 一次 policy optimizer update.

值函数另有 `vf_iters`（脚本常用 5），不应计入 policy mirror subproblem 的 inner steps。代码在循环结束后刷新 old/new anchor，但没有计算 PMD 子问题的残差容差、目标函数 gap 或自适应停止条件；`sgd_steps=10` 是计算预算和经验超参数，不是理论收敛步数。

6.4 经典 MDPO 的 off-policy 实现

off-policy版本需要特别区分 README 与当前源码。README 示例暴露 `--sgd_steps=1000`，看起来像是每个 outer step 做 1000 步。然而训练循环中实际写成

```
for grad_step in range(1):
```

而原本的
textttint(self.gradient_steps) 被注释。因而每个满足
texttttrain_freq 且 replay buffer 可采样的 train event 实际只执行一次 actor/critic gradient update。`gradient_steps` 在当前实现中主要控制 target/anchor policy 的同步周期，而不是 inner optimizer 的循环次数。仓库没有公开的、可复核的 inner residual 或 mirror-subproblem gap 日志，所以该实现同样不能被描述为每个 outer step 求解到收敛。

6.5 对实验设计的含义

若要在 MirrorOPD 实验中声称“一个 outer step 近似求解了镜像子问题”，应至少保存固定 rollout batch 上的以下曲线：$k \mapsto \mathcal{L}^{(k)}_{\text{mirror}}$、$k \mapsto \|u_\theta - u^+\|_2$（或可计算的 Bellman residual）、$k \mapsto \mathrm{KL}(\pi_\theta \| \pi_{\text{anchor}})$，以及在停止时的 gradient norm。没有闭式 target 时，报告固定 inner budget 与这些诊断曲线，才能把“训练了一轮”与“子问题收敛”分开。对于稀有 prefix，还应同时报告 d_μ 的覆盖率和 prefix ratio 的有效样本量；否则增加 inner steps 只会更充分地拟合被行为测度看见的部分。

第七章 结论与后续 MirrorOPD 的边界

7.1 对三个问题的直接回答

问题 1. token-level 与 sequence-level 是否因访问测度不同而不同?

是。精确 sequence PMD 的条件解可以写成 token 形式，但其中的 score 必须是包含 continuation soft value 的 A^{τ}_{μ}。BPO 使用行为 prefix 测度下的逐状态残差，理论闭式解在满支撑、无限容量且 score 正确时可以与 sequence 解一致；在有限数据、有限容量、硬 advantage、replay 或 prefix coverage 不足时，访问测度会改变估计误差和投影点。

问题 2. 为什么回归最优策略，而不是直接最大化 $R - \tau\,\mathrm{KL}$?

直接 PG 是原 KL 正则化目标的 ascent，行为数据下必须携带 W_T 或 token ratio。PMD-Part/BPO 回归是在行为测度下求解镜像最优性方程，把 ratio 的乘法影响变成 log-ratio 的加法残差。它们在精确镜像策略处共享零点，但一般不共享每一步 PG 方向；回归方法的优势是方差和 support 处理，代价是离开根点时不再是原目标的无偏 ascent。

问题 3. 现在是否应当直接推导 OPD off-policy 算法?

暂不应把它和本轮基础推导混在一起。下一步需要先固定采用 sequence-level 还是 prefix-level 的目标、teacher score 是硬 Q/A 还是 continuation soft Q/A、以及 KL 系数如何定义。KL 系数改变指数 target 的温度和教师加权分布；随后才适合参考信任区域策略蒸馏中的系数调度，分别控制 target 的几何距离和学生优化步长。

7.2 后续推导必须保留的区分

后续 MirrorOPD 推导至少要显式记录：

1. sequence-level target 的归一化常数与 continuation soft value；
2. prefix-level target 使用的访问测度 d_{μ} 及其 support/coverage 条件；
3. direct PG 中的 W_T、$W_{<t}$、ρ_t 与 $W_{>t}$ 分工；
4. $Q \to A$ 的 reward centering 与 $g \to g - \mathbb{E}_{\mu}[g]$ 的 score centering；
5. 回归残差的 stop-gradient 位置，以及它是否被当作原始目标的 ascent 方向；
6. KL 前系数、target temperature、实际 Fisher/Natural Gradient 步长三者的独立作用。

本文到此只完成 PMD/BPO 的测度与梯度基础，不声称已经给出 OPD 的 off-policy correction 算法。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] Xie et al. *Trust Region Policy Distillation*. NeurIPS 2026.