从 token-level 最优解统一推导 PMD、BPO 与 MDPO

梯度、重要性采样、偏差方差与实现比较

摘要

本文从固定 prefix 上的 KL 镜像子问题出发，统一写出 PMD-Part、PMD-Mean、BPO 与 MDPO 的优化目标、精确最优解和参数梯度。主线结论是：PMD-Part 的闭式 target 是 Gibbs 分布；PMD-Mean 是带单纯形约束的 Lambert-W 投影；MDPO 直接优化 KL 正则化目标，梯度中保留 action importance ratio；BPO 从平方 residual 回归出发；本稿保留完整 reverse-KL 导数并分析其中心化 score 梯度，不把后续线性化、二元 KL 或工程权重作为理论前提。四者可以共享同一个 token-level 最优策略，但离开最优点后的梯度并不相同。重要性采样降低测度偏差却引入 ratio 方差，回归型方法则承担访问测度下的投影偏差。最后核对 OpenKimi、经典 MDPO 和 BPO 论文源码，区分固定 inner budget 与真正的子问题收敛。

目录

摘要 **ii**

第一章 统一的 token-level 镜像子问题 **1**

1.1 Prefix、行为策略与局部 reward . . . 1
1.2 KL 镜像最优解 . . . 1
1.3 即时 reward 与完整序列 reward . . . 2

第二章 统一的 token-level Mirror Descent 与 OPD 实例化 **3**

2.1 共同的 mirror 子问题与精确解 . . . 3
2.2 从镜像最优性方程到四种可训练目标 . . . 4
2.3 四种 inner 的统一推导 . . . 5
2.3.1 PMD-Part：回归完整 Gibbs log-ratio . . . 5
2.3.2 PMD-Mean：中心化 target 与归一化约束 . . . 5
2.3.3 BPO：中心化最优性 residual . . . 6
2.3.4 MDPO：直接优化 mirror objective . . . 6
2.4 OPD：从 teacher log-ratio 到 outer–inner 算法 . . . 7
2.5 四种 inner 的可执行估计量、无偏性与方差 . . . 8
2.5.1 统一的单样本和批量方差公式 . . . 8
2.5.2 PMD-Part：完整 log-ratio target 的回归估计 . . . 9
2.5.3 PMD-Mean：中心化 target 与归一化约束 . . . 10
2.5.4 BPO：完整中心化 score 的有限样本估计 . . . 10
2.5.5 MDPO：action ratio、Top-k KL 与完整梯度 . . . 11
2.6 inner 算法的选择：理论与工程折中 . . . 12
2.6.1 可执行的 outer–inner 流程 . . . 12
2.7 OPD 的 outer 规划与 inner 容差 . . . 13
2.7.1 精确 outer 收缩与有限 inner 误差 . . . 13
2.7.2 inner 的 Natural Gradient 收敛与步长系数 . . . 13
2.8 Natural Gradient 与 inner 收敛 . . . 14

第三章 梯度的偏差与方差 **19**

3.1 估计对象必须先固定 . . . 19
3.2 MDPO：无偏但承担 action-ratio 的二阶矩 . . . 19
3.3 PMD-Part 的投影偏差与 BPO 的中心化方差 . . . 20

第四章 实现与参数比较 **22**

4.1 理论对象与实际代码 . . . 22
4.2 BPO 论文的训练预算 . . . 22
4.3 OpenKimi/PMD 的训练预算 . . . 22
4.4 经典 MDPO 的训练预算与 IS . . . 22
4.5 比较时应报告的指标 . . . 23

第五章 结论与 MirrorOPD 的边界 **24**

第一章 统一的 token-level 镜像子问题

1.1 Prefix、行为策略与局部 reward

固定一个 prefix $s = (x, a_{<t})$，词表动作为 a，行为策略为 $\mu(a \mid s)$，待更新学生策略为 $\pi_\theta(a \mid s)$。以下所有结论都在

$$\pi_\theta(\cdot \mid s) \ll \mu(\cdot \mid s)$$

的 support 条件下成立。记局部监督信号为 $f(s,a)$；它可以是即时 per-token reward、优势 $A^\mu(s,a)$，也可以是包含未来 reward 的 soft Q。

设 $d_\mu(s)$ 是行为轨迹访问 prefix 的测度。若一个条件 target 在每个 prefix 上可以独立实现，则 $d_\mu(s) > 0$ 只决定该 prefix 在总体训练损失中的权重；如果模型共享参数、数据有限或存在未覆盖 prefix，它会改变投影点和估计方差。

1.2 KL 镜像最优解

给定 Natural Gradient 学习率 $\eta > 0$，token-level PMD 子问题为

$$\pi^+(\cdot \mid s) = \arg\max_{p \ll \mu(\cdot|s)} \left\{ \mathbb{E}_{a\sim p}[f(s,a)] - \frac{1}{\eta} \mathrm{KL}(p \| \mu(\cdot \mid s)) \right\}. \tag{1.1}$$

令

$$Z_f(s) = \mathbb{E}_{a\sim\mu(\cdot|s)} \exp\left(\eta f(s,a)\right).$$

定理 1.1 (Token-level Gibbs 解)

若 $0 < Z_f(s) < \infty$，式(1.1) 的唯一解为

$$\pi^+(a \mid s) = \frac{\mu(a \mid s) \exp(\eta f(s,a))}{Z_f(s)}. \tag{1.2}$$

等价地，$u^+(s,a) = \log(\pi^+/\mu)$ 满足

$$u^+(s,a) = \eta f(s,a) - \log Z_f(s). \tag{1.3}$$

♡

证明 先检查式(1.2) 确实定义了概率分布。由于 $Z_f(s)$ 是有限正数，

$$\sum_a \pi^+(a \mid s) = \frac{1}{Z_f(s)} \sum_a \mu(a \mid s) e^{\eta f(s,a)} = 1.$$

并且 $\pi^+(a \mid s) > 0$ 只可能发生在 $\mu(a \mid s) > 0$ 的 action 上，所以 $\pi^+ \ll \mu$。对任意满足 $p \ll \mu$ 的候选分布，由定义逐项展开可得

$$\begin{aligned} \mathrm{KL}(p\|\pi^+) &= \mathbb{E}_p\left[\log \frac{p}{\pi^+}\right] \\ &= \mathbb{E}_p\left[\log \frac{p}{\mu} - \eta f + \log Z_f(s)\right] \\ &= \mathrm{KL}(p\|\mu) - \frac{1}{\eta}\mathbb{E}_p[f] + \log Z_f(s). \end{aligned}$$

将等式两边乘以 $-1/\eta$ 并整理，得到目标恒等式

$$\mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\mathrm{KL}(p\|\pi^+).$$

KL 散度满足 $\mathrm{KL}(p\|\pi^+) \geq 0$，且等号当且仅当 $p = \pi^+$ 几乎处处成立。因此任意候选分布的目标值都不超过 $\frac{1}{\eta}\log Z_f(s)$，而 $p = \pi^+$ 达到该上界，故它是唯一最优解。

推论 1.1 (优势形式)

若 $f = A^\mu$ 且 $\mathbb{E}_\mu[A^\mu(s,\cdot) \mid s] = 0$，则

$$\pi^+(a \mid s) = \mu(a \mid s)\exp(\eta A^\mu(s,a))/Z_A(s).$$

若 A^μ 是与序列 PMD 一致的 soft advantage，则 $Z_A(s) = 1$；若它是硬 reward advantage，$Z_A(s)$ 一般不等于 1。

1.3 即时 reward 与完整序列 reward

若 $f(s,a) = r_t(s,a)$，式(1.1) 是局部 token reward 的镜像更新。若完整目标是

$$R(y) = \sum_{t=1}^{T} r_t(s_t, a_t),$$

则与 sequence-level PMD 一致的 token score 必须是

$$Q^\mu(s_t,a_t) = r_t(s_t,a_t) + \mathbb{E}_\mu\left[\sum_{k>t} r_k(s_k,a_k) \mid s_t,a_t\right],$$

再取相应 soft advantage。直接把 r_t 放进式(1.2) 会得到局部目标，而不是完整序列目标。per-token reward 消除了终端奖励的稀疏性，却没有消除 future reward 对全局最优条件分布的作用。

第二章 统一的 token-level Mirror Descent 与 OPD 实例化

本章只使用一套序列建模符号。给定 prompt x，student 生成 rollout $y_{1:H}$；第 t 个 token 的历史为 $s_t = (x, y_{<t})$。固定第 k 个 outer step 的 anchor policy π_k，候选 student policy 记为 π_θ，teacher policy 记为 T，自然梯度步长统一记为 $\eta > 0$。s_t 只表示 rollout 的条件历史，训练样本始终是一条完整的 prompt–rollout；四种 inner 的区别只来自求解同一个 mirror 子问题的方式。

2.1 共同的 mirror 子问题与精确解

给定固定历史 s 和 token 信号 $f(s,a)$，定义

$$\mathcal{M}_s(p; f, \pi_k) = \mathbb{E}_{a\sim p(\cdot|s)}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(p(\cdot \mid s)\|\pi_k(\cdot \mid s))\,. \tag{2.1}$$

镜像子问题是在所有满足 $p \ll \pi_k$ 的概率分布上最大化 $\mathcal{M}_s$。定义

$$Z_f(s) = \sum_{v\in\mathcal{V}} \pi_k(v \mid s)\exp\big(\eta f(s,v)\big). \tag{2.2}$$

定理 2.1 (KL mirror 子问题的 Gibbs 解)

在有限词表、$Z_f(s) < \infty$ 且 $\pi_k(v \mid s) > 0$ 的条件下，式(2.1) 的唯一解是

$$\pi_k^+(v \mid s) = \frac{\pi_k(v \mid s)e^{\eta f(s,v)}}{Z_f(s)}, \qquad \log\frac{\pi_k^+(v \mid s)}{\pi_k(v \mid s)} = \eta f(s,v) - \log Z_f(s). \tag{2.3}$$

对任意候选 p，还有精确分解

$$\mathcal{M}_s(p; f, \pi_k) = \frac{1}{\eta}\log Z_f(s) - \frac{1}{\eta}\,\mathrm{KL}\big(p\big\|\pi_k^+(\cdot \mid s)\big)\,. \tag{2.4}$$

♡

证明 由式(2.3)，有

$$\log\frac{p(v \mid s)}{\pi_k^+(v \mid s)} = \log\frac{p(v \mid s)}{\pi_k(v \mid s)} - \eta f(s,v) + \log Z_f(s).$$

对 v 按 p 求期望，得到

$$\mathrm{KL}(p\|\pi_k^+) = \mathrm{KL}(p\|\pi_k) - \eta\mathbb{E}_p[f] + \log Z_f(s).$$

移项即得式(2.4)。KL 非负且仅在 $p = \pi_k^+$ 时取零，因此最优解唯一。

定义 2.1 (中心化 token 信号)

对任意 f 定义 anchor 条件均值和中心化信号

$$\bar{f}_k(s) = \mathbb{E}_{a\sim\pi_k}[f(s,a) \mid s], \qquad \widetilde{f}_k(s,a) = f(s,a) - \bar{f}_k(s).$$

若 $f = A^{\pi_k}$ 是 anchor 的优势函数，则 $\bar{f}_k(s) = 0$ 是优势函数定义推出的恒等式；对一般 teacher score 或 OPD log-ratio，$\bar{f}_k(s) = 0$ 不是自动成立的假设。

♣

命题 2.1 (中心化不改变 mirror 最优策略)

用 $\widetilde{f}_k$ 替代 f 不改变式(2.1) 的最优分布。

♠

证明 因为 $\bar{f}_k(s)$ 与 action 无关，

$$\pi_k(v \mid s)e^{\eta\widetilde{f}_k(s,v)} = e^{-\eta\bar{f}_k(s)}\pi_k(v \mid s)e^{\eta f(s,v)}.$$

分子和归一化常数同时乘以同一个因子 $e^{-\eta\bar{f}_k(s)}$，归一化后的分布不变。

2.2 从镜像最优性方程到四种可训练目标

定理 2.1 给出的不是一个抽象的分布结论，而是一个可以被监督学习近似的逐 token 方程。把式(2.3) 移项，得到

$$\log \pi_k^+(a \mid s) - \log \pi_k(a \mid s) = \eta f(s,a) - \log Z_f(s). \tag{2.5}$$

左侧是 candidate student 相对于冻结 anchor 的 log-ratio，右侧只由冻结的 token signal 和归一化常数决定。令

$$U_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \pi_k(a \mid s), \qquad H_k(s,a) = \eta f(s,a) - \log Z_f(s),$$

则求解 mirror 子问题在参数化策略类中的直接替代，就是在训练测度下让 U_θ 拟合 H_k：

$$\min_\theta \ \mathbb{E}\left[(U_\theta - H_k)^2\right]. \tag{2.6}$$

因此 PMD-Part 的平方损失不是额外假设，而是把镜像最优性方程变成参数化模型可优化的投影问题。对式(2.6) 求导，使用

$$\nabla_\theta U_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s),$$

立即得到式(2.11)。

PMD-Mean 来自同一个方程的中心化。由于 $\log Z_f(s)$ 只依赖 s，对 anchor action 取条件均值时

$$\mathbb{E}_{\pi_k}[H_k(s,a) \mid s] = \eta \mathbb{E}_{\pi_k}[f(s,a) \mid s] - \log Z_f(s).$$

减去该均值后，未知的 $\log Z_f$ 消失，得到

$$H_k(s,a) - \mathbb{E}_{\pi_k}[H_k(s,\cdot) \mid s] = \eta \widetilde{f}_k(s,a). \tag{2.7}$$

这解释了 PMD-Mean 的 target 来源。它不能只回归中心化 target，还必须保留 $U_\theta = \log(\pi_\theta/\pi_k)$ 的概率归一化约束；否则相差一个依赖历史的常数的所有 log-ratio 都会被视为同一个解。

BPO 再对式(2.5) 两边作同样的中心化，但中心化的是 residual：

$$D_\theta(s,a) = \left[\eta f(s,a) - U_\theta(s,a)\right] - \mathbb{E}_{\pi_k}\left[\eta f(s,\cdot) - U_\theta(s,\cdot) \mid s\right]. \tag{2.8}$$

当 $D_\theta = 0$ 时，只能先推出 $U_\theta = \eta f - C(s)$；概率归一化再唯一确定 $C(s) = \log Z_f(s)$。这就是 BPO 与 PMD-Part 共享精确零点、但有限参数更新不同的原因。BPO 的 score centering 并非预先加入的 baseline，而是对 $\mathbb{E}_{\pi_k}[U_\theta]$ 求导后必然产生的项。

MDPO 则不把式(2.5) 改写成回归，而直接对原始 mirror objective 求最大化。由式(2.4)，对任意参数化 student 有

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \frac{1}{\eta} \log Z_f(s) - \frac{1}{\eta} \mathrm{KL}\big(\pi_\theta(\cdot \mid s) \big\| \pi_k^+(\cdot \mid s)\big). \tag{2.9}$$

所以 MDPO 的 inner 是在直接最小化 student 与 Gibbs target 的 reverse KL gap；PMD-Part、PMD-Mean 和 BPO 则是在不同坐标和不同投影测度下最小化该最优性方程的平方残差。

命题 2.2 (平方回归的投影含义)

若 student 函数类不能表示 H_k，PMD-Part 的精确 inner 解是 H_k 在函数类诱导的 $L_2(d_{\pi_k}\pi_k)$ 几何下的投影；若训练样本的历史访问测度改为 m，投影也相应变为 $L_2(m\pi_k)$。因此 inner loss 为零只在 target 可表示且训练测度覆盖目标测度时才意味着精确 mirror 解。

证明 平方损失是 Hilbert 空间中的正交投影问题。对任意可行扰动 v，最优点 $U^\star$ 满足

$$\mathbb{E}_{m,\pi_k}[(U^\star - H_k)v] = 0.$$

这正是 H_k 到可行函数集合的正交投影条件。若 H_k 属于该集合，投影残差为零；否则残差由函数类和测度共同决定。

2.3 四种 inner 的统一推导

下面固定一个历史，令

$$\ell^T(a) = \log T(a \mid s), \qquad \ell^k(a) = \log \pi_k(a \mid s), \qquad \ell^\theta(a) = \log \pi_\theta(a \mid s).$$

训练时只对 ℓ^θ 反向传播；teacher、anchor、目标常数和所有估计的 KL 都停止梯度。

2.3.1 PMD-Part：回归完整 Gibbs log-ratio

定义显式 target

$$H_k(s,a) = \eta f(s,a) - \log Z_f(s), \qquad U_\theta(s,a) = \log \pi_\theta(a \mid s) - \log \pi_k(a \mid s).$$

PMD-Part 在 anchor 测度下最小化

$$\mathcal{L}_{\text{Part}}(\theta) = \frac{1}{2}\mathbb{E}_{s\sim d_k,\, a\sim\pi_k}\left[U_\theta(s,a) - H_k(s,a)\right]^2. \tag{2.10}$$

对 target 停止梯度，链式法则给出

$$-\nabla_\theta \mathcal{L}_{\text{Part}} = \mathbb{E}_{d_k,\pi_k}\left[H_k(s,a) - U_\theta(s,a)\right]\nabla_\theta \log \pi_\theta(a \mid s). \tag{2.11}$$

这一步是普通的 log-ratio regression；它没有把 KL 视为常数，也没有使用 action-level importance ratio。

2.3.2 PMD-Mean：中心化 target 与归一化约束

由定义可得

$$\mathbb{E}_{a\sim\pi_k}[f(s,a)] = \bar{f}_k(s), \qquad \mathbb{E}_{a\sim\pi_k}[\widetilde{f}_k(s,a)] = 0.$$

PMD-Mean用 $\eta\widetilde{f}_k$ 作为回归 target，并要求 student log-ratio 满足归一化约束

$$\min_U \ \frac{1}{2}\mathbb{E}_{\pi_k}\left[(U - \eta\widetilde{f}_k)^2 \mid s\right] \quad \text{s.t.} \quad \mathbb{E}_{\pi_k}[e^U \mid s] = 1. \tag{2.12}$$

约束正是 $\sum_a \pi_\theta(a \mid s) = 1$ 在 log-ratio 坐标中的表达。若把词表上的函数值写为 U_a 和 $G_a = \eta\widetilde{f}_k(s,a)$，拉格朗日函数为

$$\mathscr{L}(U,\lambda) = \frac{1}{2}\sum_a \pi_k(a \mid s)(U_a - G_a)^2 + \lambda\left(\sum_a \pi_k(a \mid s)e^{U_a} - 1\right).$$

一阶条件为

$$U_a - G_a + \lambda e^{U_a} = 0.$$

令 $V_a = G_a - U_a$，则 $V_a e^{V_a} = \lambda e^{G_a}$，所以

$$U_a = G_a - W\left(\lambda e^{G_a}\right), \tag{2.13}$$

其中 λ 由归一化约束唯一确定。为说明唯一性，定义

$$\Phi(\lambda) = \sum_a \pi_k(a \mid s)\exp\left(G_a - W(\lambda e^{G_a})\right), qquad\lambda \geq 0.$$

Lambert–W 在非负轴上单调递增，因此每一项随 λ 单调递减；当 $\lambda = 0$ 时 $\Phi(0) = \sum_a \pi_k(a \mid s)e^{G_a}$，而 $\lambda \to \infty$ 时 $\Phi(\lambda) \to 0$。只要中心化 target 不已经满足 $\Phi(0) = 1$，方程 $\Phi(\lambda) = 1$ 有唯一正根；若 $\Phi(0) = 1$，则 $\lambda = 0$，得到 $U_a = G_a$。因此 PMD-Mean 是中心化 target 在指数归一化集合上的投影。特别地，精确 Gibbs 解的 log-ratio 为

$$U_a^\star = \eta f(s,a) - \log Z_f(s), \qquad U_a^\star - \eta\widetilde{f}_k(s,a) = \eta\bar{f}_k(s) - \log Z_f(s),$$

它与 action 无关，且自动满足 $\sum_a \pi_k(a \mid s)e^{U_a^\star} = 1$；这说明 PMD-Mean 恢复的是同一个 Gibbs 分布，而不是把 $\log Z_f$ 任意设为零。

2.3.3 BPO：中心化最优性 residual

BPO 不显式回归 $\log Z_f$，而将同一个最优性方程的 action-independent 部分消去。定义

$$D_\theta(s,a) = \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{v\sim\pi_k}[\eta f(s,v) - U_\theta(s,v) \mid s]. \tag{2.14}$$

直接展开可得

$$D_\theta(s,a) = \eta \widetilde{f}_k(s,a) - U_\theta(s,a) + \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v) \mid s].$$

未线性化 BPO 的损失为

$$\mathcal{L}_{\mathrm{BPO}}(\theta) = \frac{1}{2\eta}\mathbb{E}_{d_k,\pi_k}[D_\theta(s,a)^2]. \tag{2.15}$$

由于

$$\nabla_\theta \mathbb{E}_{v\sim\pi_k}[U_\theta(s,v)] = \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s)],$$

所以

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = \mathbb{E}_{d_k,\pi_k}\left[D_\theta(s,a)\left(\nabla_\theta \log \pi_\theta(a \mid s) - \mathbb{E}_{v\sim\pi_k}[\nabla_\theta \log \pi_\theta(v \mid s) \mid s]\right)\right]. \tag{2.16}$$

BPO 的 score centering 来自对当前 student–anchor KL 的精确求导；它不是因为先对 reward 做了一个近似。

2.3.4 MDPO：直接优化 mirror objective

MDPO 直接最大化式(2.1) 的参数化版本：

$$\mathcal{J}_{\mathrm{MDPO}}(\theta) = \mathbb{E}_{a\sim\pi_\theta}[f(s,a)] - \frac{1}{\eta}\,\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s)). \tag{2.17}$$

完整词表时 KL 是

$$\mathrm{KL}(\pi_\theta\|\pi_k) = \sum_a \pi_\theta(a \mid s)\left[\log \pi_\theta(a \mid s) - \log \pi_k(a \mid s)\right]. \tag{2.18}$$

若 action 从 anchor 采样，定义 $R_\theta(s,a) = \exp(\ell^\theta(a) - \ell^k(a))$，则 action-level IS 形式为

$$\widehat{\mathcal{J}}_{\mathrm{MDPO}} = \mathbb{E}_{a\sim\pi_k}\left[R_\theta(s,a)f(s,a) - \frac{1}{\eta}R_\theta(s,a)\log R_\theta(s,a)\right]. \tag{2.19}$$

其 ascent direction 为

$$\nabla_\theta\mathcal{J}_{\mathrm{MDPO}} = \mathbb{E}_{\pi_k}\left[R_\theta(s,a)\left(f(s,a) - \frac{1}{\eta}\log R_\theta(s,a)\right)\nabla_\theta \log \pi_\theta(a \mid s)\right]. \tag{2.20}$$

额外的 $-R_\theta/\eta$ 项乘以 score 后，在完整 action 求和中因 $\mathbb{E}_{\pi_\theta}[\nabla \log \pi_\theta] = 0$ 消失。MDPO 因而直接优化 mirror objective，其他三种方法优化的是由同一最优性方程构造的 regression objective。

定理 2.2 (四种 inner 的共同精确解)

在 tabular policy、完整 action 支持和精确词表期望下，PMD-Part、PMD-Mean、未线性化 BPO 和 MDPO 都以式(2.3) 为精确解。PMD-Mean 的结论要求其投影 target 可实现；参数化 student 或有限样本时，四者得到的是不同的投影或优化误差。

证明 PMD-Part 在零损失处满足 $U_\theta = \eta f - \log Z_f$，于是得到式(2.3)。BPO 的零 residual 只确定 $U_\theta = \eta f - C(s)$；代入 $\mathbb{E}_{\pi_k}[e^{U_\theta}] = 1$ 得 $C(s) = \log Z_f(s)$。PMD-Mean 若中心化 target 属于归一化约束集合，则其平方投影残差为零，并由中心化不变性得到同一策略。MDPO 由式(2.4) 直接得到唯一最大点。

命题 2.3 (未线性化 BPO 与 PMD-Part 的梯度差异)

固定一个历史 s，令

$$q(s,a) = \eta f(s,a) - \log Z_f(s) - U_\theta(s,a), \qquad c(s) = \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] - \eta\mathbb{E}_{\pi_k}[f(s,\cdot) \mid s]. \tag{2.21}$$

则未线性化 BPO residual 满足 $D_\theta = q + c$，并且

$$-\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} = -\nabla_\theta\mathcal{L}_{\mathrm{Part}} + c(s)\,\mathbb{E}_{a\sim\pi_k}[\nabla_\theta \log \pi_\theta(a \mid s) \mid s]. \tag{2.22}$$

因此两者在精确镜像解处都有零梯度，但在一般参数点不相同。它们只有在 $c(s)\,\mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$ 时才给出相同的方向。

证明 从 PMD-Part 的最优性残差出发，先把 BPO 的中心化式逐项展开：

$$\begin{aligned} D_\theta(s,a) &= \eta f(s,a) - U_\theta(s,a) - \mathbb{E}_{\pi_k}[\eta f(s,\cdot) - U_\theta(s,\cdot) \mid s] \\ &= \eta f(s,a) - \log Z_f(s) - U_\theta(s,a) + \log Z_f(s) + \mathbb{E}_{\pi_k}[U_\theta(s,\cdot) \mid s] \\ &= q(s,a) + c(s). \end{aligned}$$

由定义，$\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$。BPO 的精确梯度为

$$\begin{aligned} -\eta\nabla_\theta\mathcal{L}_{\mathrm{BPO}} &= \mathbb{E}_{\pi_k}\left[D_\theta\,(g_\theta - \bar{g}_\theta) \mid s\right], \\ g_\theta(a) &= \nabla_\theta \log \pi_\theta(a \mid s), \qquad \bar{g}_\theta = \mathbb{E}_{\pi_k}[g_\theta \mid s]. \end{aligned}$$

代入 $D_\theta = q + c$，并使用 $\mathbb{E}_{\pi_k}[D_\theta \mid s] = 0$，可得

$$\begin{aligned} \mathbb{E}_{\pi_k}[D_\theta(g_\theta - \bar{g}_\theta) \mid s] &= \mathbb{E}_{\pi_k}[(q+c)g_\theta \mid s] - \mathbb{E}_{\pi_k}[D_\theta \mid s]\bar{g}_\theta \\ &= \mathbb{E}_{\pi_k}[qg_\theta \mid s] + c(s)\bar{g}_\theta. \end{aligned}$$

而 PMD-Part 的梯度式为 $-\nabla_\theta\mathcal{L}_{\mathrm{Part}} = \mathbb{E}_{\pi_k}[qg_\theta \mid s]$，故式(2.22) 成立。若 $q = 0$，则由归一化约束有 $c = 0$，两边同时为零；离开该点时 c 通常非零，差异项保留。

这个命题说明“都在 token level”只保证它们面对同一个局部镜像根，不保证优化轨迹相同。PMD-Part 回归完整的 action-dependent log-ratio，并把 $\log Z_f$ 当作固定 target；BPO 先消去 action-independent 常数，再对当前 student 的归一化项求导，因此多出 centered score。若使用的参数化使 $\mathbb{E}_{\pi_k}[\nabla_\theta \log \pi_\theta] = 0$（例如采样测度与当前 student 一致，或在特定 tabular 点上），差异项才会消失。

2.4 OPD：从 teacher log-ratio 到 outer–inner 算法

OPD的一个训练样本先采样 prompt $x \sim \mathcal{D}_X$，再从第 k 个 anchor policy 采样一整条 response rollout $y_{1:H} \sim \pi_k(\cdot \mid x)$。因此样本的联合概率是

$$p_k(x, y_{1:H}) = \mathcal{D}_X(x) \prod_{t=1}^{H} \pi_k(y_t \mid x, y_{<t}).$$

这里的 $y_{<t}$ 只出现在条件概率中；优化和统计的基本单位是一条完整的 prompt–rollout，prompt token 只提供条件，不参加 response loss。teacher 和 student 在这条相同 rollout 上逐 token forward，得到 $T(\cdot \mid x, y_{<t})$、$\pi_k(\cdot \mid x, y_{<t})$ 和候选 $\pi_\theta(\cdot \mid x, y_{<t})$。

OPD 不引入额外的外部 reward，而在第 k 个 outer step 使用 teacher 与当前 anchor 的局部 log-ratio：

$$r_k(s,a) = \log T(a \mid s) - \log \pi_k(a \mid s). \tag{2.23}$$

它是序列 log-ratio 的逐 token 分解：

$$\sum_{t=1}^{H} r_k(s_t, a_t) = \log T(y \mid x) - \log \pi_k(y \mid x). \tag{2.24}$$

因此 r_k 是对 teacher–student 序列差异的无损分摊，不是一个与历史无关的固定终端 reward。

定义 2.2 (OPD mirror target)

将 $f = r_k$ 代入式(2.3)，定义

$$\pi^{\star}_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}, \qquad Z_k(s) = \sum_v \pi_k(v \mid s)^{1-\eta} T(v \mid s)^{\eta}. \tag{2.25}$$

♣

定理 2.3 (OPD mirror step 的几何收敛)

若 $0 < \eta \le 1$，则精确 outer 更新满足

$$\log \frac{\pi^{\star}_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta) \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \log Z_k(s). \tag{2.26}$$

因此任意两个 action 的 log-ratio 差满足

$$\max_a \log \frac{\pi^{\star}_{k+1}(a \mid s)}{T(a \mid s)} - \min_a \log \frac{\pi^{\star}_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta)\Delta_k(s).$$

$\eta = 1$ 时一步得到 T；$0 < \eta < 1$ 时 projective 误差按 $1-\eta$ 几何衰减。

♡

证明 由式(2.25)，

$$\log \frac{\pi^{\star}_{k+1}(a \mid s)}{T(a \mid s)} = (1-\eta) \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \log Z_k(s).$$

减去任意两个 action 的等式，归一化常数抵消，得到 projective 递推。

2.5 四种 inner 的可执行估计量、无偏性与方差

本节把四种 inner 写成可以直接实现的随机估计量。所有公式都在第 k 个 outer step 内理解：π_k、教师 T、token reward r_k 和 replay action 测度 β 冻结，只有学生参数 θ 更新。记

$$g_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s), \qquad u_\theta(s,a) = \log \frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)},$$

并假设策略支持满足：只要目标分布在 (s,a) 上有正概率，$\pi_k(a \mid s)$ 与 $\beta(a \mid s)$ 就均为正。对任意向量估计量 X，令

$$\mathrm{Var}(X) = \mathbb{E}\|X - \mathbb{E}X\|_2^2 = \mathbb{E}\|X\|_2^2 - \|\mathbb{E}X\|_2^2.$$

一个 batch 先采样 prompt $x_i \sim \mathcal{D}_X$，再从第 k 个 anchor policy 采样完整 rollout

$$y_{i,1:H_i} \sim \prod_{t=1}^{H_i} \pi_k(y_{i,t} \mid x_i, y_{i,<t}).$$

记 $s_{i,t} = (x_i, y_{i,<t})$，并令 $\mathcal{I} = \{(i,t) : 1 \le t \le H_i\}$ 为 response token 的索引集合。下文固定历史 s 的条件期望均指这个 prompt–rollout 联合测度；若样本来自 replay，则用 β 表示实际采样的 token action 测度。

2.5.1 统一的单样本和批量方差公式

先考虑固定历史 s。设目标 action 测度为 $\nu(\cdot \mid s)$，而实际采样 action 测度为 $\beta(\cdot \mid s)$。如果目标梯度可以写成

$$G_s = \mathbb{E}_{a \sim \nu}[Y(s,a)],$$

用 B 个条件独立样本 $Y_1, \dots, Y_B$ 的平均值

$$\widehat{G}_s = \frac{1}{B} \sum_{i=1}^{B} Y_i$$

满足

$$\mathbb{E}[\widehat{G}_s] = G_s, \qquad \mathbb{E}\|\widehat{G}_s - G_s\|_2^2 = \frac{1}{B}\mathrm{Var}(Y). \tag{2.27}$$

这说明增加 batch size 只能降低抽样方差，不能消除由错误访问测度、错误的归一化常数或函数类投影造成的系统偏差。

若样本来自 β 而目标 action 测度是 ν，定义

$$\omega_{\nu/\beta}(s,a)=\frac{\nu(a\mid s)}{\beta(a\mid s)}.$$

只要 $\mathbb{E}_\beta[\omega_{\nu/\beta}\|Y\|_2]<\infty$，则

$$G_s=\mathbb{E}_{a\sim\beta}[\omega_{\nu/\beta}(s,a)Y(s,a)],$$

因此 $\omega_{\nu/\beta}Y$ 是无偏估计量。其方差由二阶矩控制：若 $\|Y\|_2\le C_Y$，则

$$\mathbb{E}_\beta\|\omega_{\nu/\beta}Y\|_2^2\le C_Y^2\,\mathbb{E}_\beta[\omega_{\nu/\beta}^2]=C_Y^2\big(1+\chi^2(\nu\|\beta)\big). \tag{2.28}$$

因此 action-level IS 的代价由 $1+\chi^2(\nu\|\beta)$ 给出，而不是由 ratio 的均值给出；后者恒等于 1，不能反映方差。

当历史也来自 replay 时，目标状态测度为 d_{π_k}，定义

$$W_{<t}^k=\prod_{j<t}\frac{\pi_k(y_j\mid s_j)}{\beta(y_j\mid s_j)}.$$

对局部信号 Y_t，严格的估计量为 $W_{<t}^kY_t$。若 $\|Y_t\|_2\le C_Y$ 且每个历史的条件 action ratio 满足

$$\mathbb{E}_\beta\left[\left(\frac{\pi_k(a\mid s)}{\beta(a\mid s)}\right)^2\middle|s\right]\le 1+\chi^2_{\max},$$

则递推得到

$$\mathbb{E}_\beta[(W_{<t}^k)^2]\le(1+\chi^2_{\max})^{t-1},\qquad \mathbb{E}_\beta\|W_{<t}^kY_t\|_2^2\le C_Y^2(1+\chi^2_{\max})^{t-1}. \tag{2.29}$$

这就是长历史上方差随时间增长的来源。它与 token-level inner 是否使用 regression 无关，只由访问测度校正决定。

命题 2.4 (投影误差与抽样方差的正交分解)

设目标梯度为 G，算法实际在函数类 $\mathcal{F}$ 和采样测度 m 下优化，函数类投影给出的梯度为 $G_{\mathcal{F},m}$。令 $\widehat{G}_B$ 是该投影梯度的无偏 batch 估计量，则

$$\mathbb{E}\|\widehat{G}_B-G\|_2^2=\|G_{\mathcal{F},m}-G\|_2^2+\frac{1}{B}\operatorname{Var}(Y_{\mathcal{F},m}).$$

证明 写成 $\widehat{G}_B-G=(\widehat{G}_B-G_{\mathcal{F},m})+(G_{\mathcal{F},m}-G)$。第一项的期望为零，故交叉项期望为零；再用式(2.27) 即得结论。第一项是不可由加大 batch 消除的 projection/measure bias，第二项才是 Monte Carlo variance。

2.5.2 PMD-Part：完整 log-ratio target 的回归估计

PMD-Part的单样本 residual 和梯度分别为

$$q_{k,\theta}(s,a)=h_k(s,a)-u_\theta(s,a),\qquad Y_{\mathrm{Part}}(s,a)=q_{k,\theta}(s,a)g_\theta(s,a),$$

其中

$$h_k(s,a)=\eta r_k(s,a)-\log Z_k(s),\qquad Z_k(s)=\mathbb{E}_{a\sim\pi_k}\left[e^{\eta r_k(s,a)}\right].$$

若 $(s,a)\sim d_{\pi_k}\pi_k$，则

$$-\nabla_\theta\mathcal{L}_{\mathrm{Part}}=\mathbb{E}[q_{k,\theta}g_\theta].$$

在 replay 上的严格无偏估计量是

$$\widehat{G}_{\mathrm{Part}}=\frac{1}{B}\sum_{i=1}^{B}W_{<t_i}^k\frac{\pi_k(a_i\mid s_i)}{\beta(a_i\mid s_i)}q_{k,\theta}(s_i,a_i)g_\theta(s_i,a_i). \tag{2.30}$$

若 action 已按 π_k 采样，只保留历史 weight；若把 replay 测度本身作为训练目标，则去掉 $W_{<t_i}^k$ 得到 replay-projection 梯度。

对于真实 Z_k，式(2.30) 在支持和二阶矩条件下无偏，且

$$\mathrm{MSE}(\widehat{G}_{\mathrm{Part}}) = \frac{1}{B}\,\mathrm{Var}_{d_{\pi_k},\pi_k}(q_{k,\theta}g_\theta)$$

在 on-policy 历史下成立。工程上常用 M 个 action 样本估计 Z_k：

$$\widehat{Z}_{k,M}(s) = \frac{1}{M}\sum_{j=1}^{M} e^{\eta r_k(s,a_j)}, \qquad a_j \sim \pi_k(\cdot \mid s).$$

由于 log 是凹函数，

$$\mathbb{E}[\log \widehat{Z}_{k,M}(s)] \le \log Z_k(s),$$

所以 $-\log \widehat{Z}_{k,M}$ 对 $-\log Z_k$ 产生向上的有限样本偏差。若 $X = e^{\eta r_k}$ 有有限方差，二阶 delta method 给出

$$\mathbb{E}[\log \widehat{Z}_{k,M}] = \log Z_k - \frac{\mathrm{Var}(X)}{2MZ_k^2} + O(M^{-2}), \qquad \mathrm{Var}(\log \widehat{Z}_{k,M}) = \frac{\mathrm{Var}(X)}{MZ_k^2} + O(M^{-2}). \tag{2.31}$$

因此 PMD-Part 的主要额外误差来自 $\log Z$ 的 plug-in，而不是回归梯度本身。

2.5.3 PMD-Mean：中心化 target 与归一化约束

令

$$r_{k,0}(s,a) = r_k(s,a) - \bar{r}_k(s), \qquad \bar{r}_k(s) = \mathbb{E}_{\pi_k}[r_k(s,a)].$$

PMD-Mean使用目标 $\eta r_{k,0}$，并在函数空间中施加

$$\mathbb{E}_{\pi_k}[e^{u_\theta(s,a)} \mid s] = 1.$$

对一个历史采 K 个 action，定义

$$\widehat{\bar{r}}_{k,i} = \frac{1}{K}\sum_{j=1}^{K} r_k(s_i,a_{ij}), \qquad \widehat{Y}_{ij}^{\mathrm{Mean}} = \left[\eta(r_k(s_i,a_{ij}) - \widehat{\bar{r}}_{k,i}) - u_\theta(s_i,a_{ij})\right] g_\theta(s_i,a_{ij}).$$

如果把中心和当前 action 用独立样本计算，则 $\mathbb{E}[\widehat{\bar{r}}_{k,i} \mid s_i] = \bar{r}_k(s_i)$，从而该估计量对中心化 PMD-Mean 梯度无偏。若中心和当前 action 共用同一组 K 样本，标量中心本身仍无偏，但它与 $g_\theta(s_i,a_{ij})$ 相关，导致有限 K 的乘积估计量出现协方差项：

$$\mathbb{E}\left[(r_j - \widehat{\bar{r}})g_j \mid s\right] = \mathbb{E}[(r-\bar{r})g \mid s] - \frac{1}{K}\,\mathrm{Cov}_{\pi_k}(r,g \mid s). \tag{2.32}$$

一个简单的修正是 leave-one-out center：

$$\widehat{\bar{r}}_{-j} = \frac{1}{K-1}\sum_{\ell \ne j} r_\ell, \qquad K > 1.$$

此时 $\widehat{\bar{r}}_{-j}$ 与 a_j 条件独立，故对应的 product estimator 无偏。其方差包含

$$\mathrm{Var}(\widehat{\bar{r}}_{-j} \mid s) = \frac{\mathrm{Var}_{\pi_k}(r \mid s)}{K-1},$$

因此 K 增大可以降低 center noise，但不能消除 model projection bias。

2.5.4 BPO：完整中心化 score 的有限样本估计

令

$$d_{k,\theta}(s,a) = \eta r_k(s,a) - u_\theta(s,a), \qquad \bar{d}_{k,\theta}(s) = \mathbb{E}_{\pi_k}[d_{k,\theta}(s,a)],$$

则未线性化 BPO 的精确梯度可写为

$$G_{\mathrm{BPO}}(s) = \mathbb{E}_{\pi_k}\left[(d_{k,\theta} - \bar{d}_{k,\theta})(g_\theta - \bar{g}_\theta) \mid s\right], \qquad \bar{g}_\theta = \mathbb{E}_{\pi_k}[g_\theta \mid s].$$

用同一历史的 K 个 action 直接计算样本中心：

$$\widehat{d}_{ij} = d_{ij} - \frac{1}{K}\sum_{\ell=1}^{K} d_{i\ell}, \qquad \widehat{g}_{ij} = g_{ij} - \frac{1}{K}\sum_{\ell=1}^{K} g_{i\ell}.$$

则

$$\widehat{G}_{\mathrm{BPO},i} = \frac{1}{K}\sum_{j=1}^{K} \widehat{d}_{ij}\widehat{g}_{ij} \tag{2.33}$$

是一个样本协方差。条件于历史，i.i.d. 样本给出精确恒等式

$$\mathbb{E}[\widehat{G}_{\mathrm{BPO},i} \mid s_i] = \frac{K-1}{K} G_{\mathrm{BPO}}(s_i). \tag{2.34}$$

因此共用中心时，BPO 的梯度有一个明确的 $-(1/K)$ shrinkage bias；乘以 $K/(K-1)$ 可消除该 bias，但会放大方差。等价地，可以使用一个 action 计算中心、另一个独立 action 计算 residual 和 score。对向量 $\widehat{dg}$，若四阶矩有限，其 batch variance 仍按 $1/B$ 缩放；K 只减少每个历史的条件协方差。

证明 记 $X_j = d_j - \bar{d}$、$Y_j = g_j - \bar{g}$。样本中心化恒等式为

$$\frac{1}{K}\sum_j (d_j - \bar{d}_K)(g_j - \bar{g}_K) = \frac{1}{K}\sum_j X_j Y_j - \left(\frac{1}{K}\sum_j X_j\right)\left(\frac{1}{K}\sum_j Y_j\right).$$

第一项期望为 $\mathbb{E}[XY]$，第二项期望为 $K^{-1}\mathbb{E}[XY]$，因为不同样本的交叉项均为零，故得到式(2.34)。

2.5.5 MDPO：action ratio、Top-k KL 与完整梯度

固定历史后，MDPO的梯度为

$$G_{\mathrm{MDPO}}(s) = \mathbb{E}_{a\sim\pi_\theta}\left[c_{k,\theta}(s,a) g_\theta(s,a)\right], \quad c_{k,\theta} = r_k - \frac{1}{\eta}\log\frac{\pi_\theta}{\pi_k}.$$

若 replay action 来自 β，单样本无偏估计量为

$$X_{\mathrm{MDPO}}(s,a) = \frac{\pi_\theta(a \mid s)}{\beta(a \mid s)} c_{k,\theta}(s,a) g_\theta(s,a), \qquad a \sim \beta(\cdot \mid s). \tag{2.35}$$

若状态也需从 d_β 换成 d_{π_k}，再乘 $W_{<t}^k$。在 $\|c_{k,\theta} g_\theta\| \le C$ 时，二阶矩满足

$$\mathbb{E}_\beta \|X_{\mathrm{MDPO}}\|^2 \le C^2\big(1 + \chi^2(\pi_\theta \| \beta)\big).$$

当 token vocabulary logits 可访问时，可以用 Top-k 估计 reverse KL 而不截断尾部。取任意 head 集 $S(s)$（Top-K 只是降低方差的选择），令 $P = \pi_\theta(\cdot \mid s)$、$Q = \pi_k(\cdot \mid s)$，并从 $a \sim P$ 采一个尾部样本。记 $r_\theta(a) = P_a / \mathrm{sg}(P_a)$，前向值为 1 但反向传播保留 P_a 的 score 梯度。定义

$$\widehat{D}_K(P\|Q) = \sum_{j\in S} P_j \log\frac{P_j}{Q_j} + \mathbf{1}\{a \notin S\}\, r(a)\, \mathrm{sg}\left(-\log\frac{Q_a}{P_a}\right), \tag{2.36}$$

第一项是 head 的精确 reverse KL；第二项的期望为

$$\sum_{a\notin S} P_a \frac{Q_a}{P_a}\log\frac{P_a}{Q_a} = \sum_{a\notin S} Q_a \log\frac{P_a}{Q_a},$$

与第一项相加得到 $\mathrm{KL}(P\|Q)$。对 θ 求梯度时，head 使用精确梯度，tail 使用停止梯度的 ratio 和 score；逐项展开可得其期望等于 $\nabla_\theta \mathrm{KL}(P\|Q)$。因此 Top-k 估计量同时满足

$$\mathbb{E}[\widehat{D}_K] = \mathrm{KL}(P\|Q), \qquad \mathbb{E}[\nabla_\theta \widehat{D}_K] = \nabla_\theta \mathrm{KL}(P\|Q).$$

若完全截断 tail，第二个等式右侧少掉 tail 梯度，产生不可由 batch size 消除的 bias。Top-k 的方差仅来自 tail Bernoulli 和 tail action；随着 head mass 增大，tail 二阶矩通常下降。

命题 2.5 (四种 inner 的无偏条件)

在 target、anchor 和 reward 都停止梯度，策略支持覆盖成立，且所有相关一阶和二阶矩有限时：

(i) PMD-Part 在使用真实 Z_k、正确历史/action ratio 时无偏；用 $\widehat{Z}$ 时产生式(2.31) 的 plug-in bias。

(ii) PMD-Mean 在中心估计与当前 action 独立，或使用 leave-one-out center 时无偏；同样本 center 产生式(2.32) 的 covariance bias。

(iii) BPO 的同历史样本协方差估计量带有 $(K-1)/K$ shrinkage；乘以 $K/(K-1)$ 或使用独立中心后无

偏。

(iv) MDPO 的 action-level IS 估计量无偏；历史 ratio 用于把 replay occupancy 换成 d_{π_k}，不能用 full suffix ratio 代替。

2.6 inner 算法的选择：理论与工程折中

四种方法共享同一个 token-level mirror root，但它们需要的模型访问、随机量和 off-policy 修正不同。对 OPD，教师通常能够在已访问历史上返回 logits，学生也能够返回同一历史的 logits；这个事实决定了默认方案应优先利用 logit 信息，而不是把整个 token 分布重新当作黑盒采样器。

PMD-Part 是默认 inner。 它直接回归

$$u_\theta(s,a) \approx h_k(s,a) = \eta r_k(s,a) - \log Z_k(s),$$

梯度是标量 residual 与 score 的乘积，不需要 action-level IS（action 按 π_k 采样时）。Z_k 可以用全词表 log-sum-exp 精确计算；词表太大时，式(2.36) 提供了 head exact plus tail sample 的无偏替代。它的主要偏差来源只有参数函数类投影和 $\widehat{\log Z}$ 的 plug-in，而不是中心估计与 score 的乘积偏差。因此在 OPD 有 teacher logits、能够缓存 top-K logits 时，PMD-Part 的实现最短，诊断指标也最直接：监控 $\|u_\theta - h_k\|^2$ 和 mirror KL。

MDPO 是需要直接优化时的备选。 MDPO 不构造 h_k，而直接最大化 reward 减 reverse KL。它适合 teacher reward 不便逐 action 回归、但可以稳定计算 candidate policy ratio 的场景。代价是每一个 replay action 都带有 π_θ/β，历史复用还要带 $W_{<t}^k$；二阶矩随 action ratio 和历史 ratio 同时增长。Top-k KL 可以把 reverse-KL 的词表求和代价降到 $O(K)$，但不能消除 action IS 本身的方差。工程上应把 MDPO 放在 PMD-Part 之后作为 ablation 或在 teacher logits 不完整时使用。

PMD-Mean 适合不计算配分函数的实现。 它只需要估计 $\bar{r}_k(s)$，但必须维护

$$\mathbb{E}_{\pi_k}[e^{u_\theta} \mid s] = 1$$

这一非线性约束。若使用同一组 action 同时计算中心和 residual，会出现式(2.32) 的 covariance bias；leave-one-out 或独立中心可以修复无偏性，却提高每个历史的采样成本。它适合作为不具备完整 vocabulary logits、但能在同一历史采多次 action 的实现。

BPO 适合做低方差中心化对照。 BPO 的 centered score 去除了 action-independent baseline，理论上能降低梯度方差；但 token-level 实现至少需要每个历史的两个 action，直接使用 K 个样本时还有式(2.34) 的 $(K-1)/K$ shrinkage。BPO 还需要对 residual 和 score 同时做中心化，调试时难以区分 reward noise、中心估计误差和模型投影误差。因而它更适合在 PMD-Part 已经跑通后验证中心化是否带来实际方差收益，而不适合作为第一版 OPD inner。

综合而言，建议的工程顺序是：**PMD-Part + Top-k KL** 作为主算法，**MDPO + Top-k reverse KL** 作为直接目标基线，PMD-Mean 和 BPO 作为分别检验“去掉配分函数”和“中心化 score”作用的对照。四者都应使用相同的历史 replay、相同的 $W_{<t}^k$ 选项和相同的 inner stopping rule，这样差异才归因于 inner 几何而不是访问测度。

2.6.1 可执行的 outer–inner 流程

第 k 个 outer step 的实现顺序如下。先冻结 π_k 和 teacher T，在 replay 历史上计算 $r_k = \log T - \log \pi_k$，并缓存学生、teacher 的 top-$K$ logits。然后选择一种 inner：PMD-Part 回归 h_k，PMD-Mean 回归中心化 reward，BPO 回归中心化 residual，MDPO 使用 action-ratio mirror ascent。每次 inner update 都在同一冻结 target 上进行；当估

计的 mirror gap、log-ratio residual 或 held-out KL 降到 ε_k 后，才把所得学生记为 π_{k+1} 并刷新 teacher。这样 outer 的 teacher 不会在 inner 尚未稳定时移动，避免把两个时间尺度混成一个 optimizer trajectory。

2.7 OPD 的 outer 规划与 inner 容差

一个 outer step 应当把 teacher、anchor 和 inner 优化严格分开。第 k 步先冻结学生 π_k，由 teacher 产生

$$r_k(s,a) = \log \frac{T(a \mid s)}{\pi_k(a \mid s)}.$$

随后定义镜像目标

$$\pi^{\star}_{k+1}(a \mid s) = \frac{\pi_k(a \mid s) e^{\eta r_k(s,a)}}{Z_k(s)} = \frac{\pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{Z_k(s)}.$$

在 $0 < \eta \le 1$ 时，它是 student 与 teacher 的几何中间分布；$\eta = 1$ 才是一步到 teacher。实际算法先固定这个 target，再用四种 inner 之一得到近似参数 π_{k+1}，最后才进入下一次 teacher refresh。

2.7.1 精确 outer 收缩与有限 inner 误差

定义同一历史上任意两个 action 的 projective log-ratio

$$\Delta_k(s; a, a') = \log \frac{\pi_k(a \mid s)}{T(a \mid s)} - \log \frac{\pi_k(a' \mid s)}{T(a' \mid s)}.$$

精确 mirror update 满足

$$\Delta_{k+1}(s; a, a') = (1-\eta)\Delta_k(s; a, a'). \tag{2.37}$$

若 inner 产生的 logit/projection error 为 $e_k(s,a)$，且其 projective oscillation 满足

$$\operatorname{osc}_s(e_k) = \max_a e_k(s,a) - \min_a e_k(s,a) \le \varepsilon_k,$$

则

$$\operatorname{osc}_s(\rho_{k+1}) \le (1-\eta)\operatorname{osc}_s(\rho_k) + \varepsilon_k, \qquad \rho_k = \log(\pi_k/T). \tag{2.38}$$

迭代展开为

$$\operatorname{osc}_s(\rho_K) \le (1-\eta)^K \operatorname{osc}_s(\rho_0) + \sum_{j=0}^{K-1} (1-\eta)^{K-1-j} \varepsilon_j.$$

若 $\varepsilon_j \le \bar{\varepsilon}$，渐近误差不超过 $\bar{\varepsilon}/\eta$。因此 outer 目标误差为 δ_{out} 时，应把每个 inner 的 projective error 控制在

$$\varepsilon_k \lesssim \eta\, \delta_{\text{out}}.$$

这给出了停止条件，而不是预先规定一个与 η 无关的 optimizer step 数。

2.7.2 inner 的 Natural Gradient 收敛与步长系数

在第 k 步的局部参数模型中，令 A_k 是 replay 历史上的 Fisher 曲率，特征值属于 $[m_k, M_k]$。普通梯度对

$$Q_k(\Delta) = \frac{1}{2\eta}\Delta^{\mathsf{T}} A_k \Delta - b_k^{\mathsf{T}}\Delta$$

做步长为 γ 的更新，其误差传播矩阵为

$$E_{k,\eta} = I - \frac{\gamma}{\eta}A_k, \qquad q_k(\eta,\gamma) = \max\left\{\left|1 - \frac{\gamma m_k}{\eta}\right|, \left|1 - \frac{\gamma M_k}{\eta}\right|\right\}.$$

收敛要求 $0 < \gamma < 2\eta/M_k$，并且达到 inner 误差 ϵ 至少需要

$$N_{\text{in}} \ge \frac{\log(\epsilon_0/\epsilon)}{-\log q_k(\eta,\gamma)}. \tag{2.39}$$

若把实际 optimizer step 按比例设为 $\gamma = \eta\widetilde{\gamma}$，则

$$q_k = \max\{|1 - \widetilde{\gamma} m_k|, |1 - \widetilde{\gamma} M_k|\},$$

收敛率与 η 一阶解耦；最优固定步长为

$$\widetilde{\gamma}^\star = \frac{2}{m_k + M_k}, \qquad q_k^\star = \frac{M_k - m_k}{M_k + m_k}.$$

若 γ 不随 η 缩放，则 η 越小，γ/η 越大，可能越快也可能越过稳定区间；η 越大，γ/η 越小，inner 收敛变慢。这个结论解释了为什么 Natural Gradient 的学习率应与 mirror 系数联动，而不是在所有 outer step 使用固定的 AdamW learning rate。

outer 与 inner 的总成本还受目标移动量影响。对 $0 < \eta \ll 1$，

$$\mathrm{KL}(\pi_{k+1}^\star \| \pi_k) = O(\eta^2), \qquad \mathrm{osc}(u_k^\star) = O(\eta),$$

所以小 η 每个 outer target 更近，通常需要更少的 inner updates 才达到绝对参数误差；但 outer 收缩率 $1 - \eta$ 变慢，需要 $O(\eta^{-1}\log(1/\delta_{\mathrm{out}}))$ 个 outer steps。大 η 减少 outer 次数，却放大单次 target 位移、ratio 和 regression residual 的二阶矩；当 $\eta > 1$ 时，式(2.37) 进入符号翻转区间，$1 < \eta < 2$ 仍有 projective 绝对收缩但会振荡，$\eta \geq 2$ 不再收缩。因此工程默认应取 $0 < \eta \leq 1$，并用 inner mirror gap 或 KL 停止，而不是固定 inner step 数。

MDPO 的完整词表实现。 前文已经给出 action-level IS 版本。若 teacher、anchor 和 student 都能输出完整词表分布，MDPO 也可以直接计算

$$\sum_{v \in \mathcal{V}} \pi_\theta(v \mid s_i)\,[\log T(v \mid s_i) - \log \pi_k(v \mid s_i)] - \frac{1}{\eta} \sum_{v \in \mathcal{V}} \pi_\theta(v \mid s_i) \log \frac{\pi_\theta(v \mid s_i)}{\pi_k(v \mid s_i)}.$$

这是一条对每个历史的可微 KL objective；它不需要显式的 sampled action ratio。工程实现通常将第二项写成 logits 上的 reverse-KL penalty，或使用 token-level sampled-KL estimator。只有当数据由 replay action 测度 β 产生、而目标 expectation 属于当前 anchor 历史测度时，才需要额外的 ω_i^k；action-level ρ_{ij}^θ 与历史-level ω_i^k 负责两个不同的测度变换。

2.8 Natural Gradient 与 inner 收敛

前面的 mirror 解是在策略分布空间中定义的，而实际训练变量是神经网络参数 θ。因此需要把“固定一个 outer target 后的 inner 优化”从分布空间搬到参数空间。下面先不假设局部二次模型，而是从 softmax 参数化和 KL 的定义逐步展开。

固定一个历史 s，令 $z_\theta(s) \in \mathbb{R}^{|\mathcal{A}|}$ 为学生 logits，$\pi_\theta(\cdot \mid s) = \mathrm{softmax}(z_\theta(s))$。在第 k 个 outer step 中冻结 π_k 和 r_k，把 inner 的镜像目标写成最小化形式

$$\mathcal{J}_k(\theta) = -\mathbb{E}_{s,a}[r_k(s,a)] + \frac{1}{\eta}\mathbb{E}_s[\mathrm{KL}(\pi_\theta(\cdot \mid s) \| \pi_k(\cdot \mid s))], \tag{2.40}$$

其中 $\mathbb{E}_{s,a}$ 的 action 测度可以是 π_θ、π_k 或 replay 加权测度；下文的局部曲率只要求该测度固定且具有有限二阶矩。

第一步：logit 空间的 KL 一阶项消失。 令 $\delta z = z_\theta - z_{\theta_k}$，其中 $\pi_{\theta_k} = \pi_k$。对固定的行为分布 $q = \pi_k$ 定义

$$K(z) = \mathrm{KL}(\mathrm{softmax}(z) \| q).$$

直接对 softmax 的 log-partition 展开：

$$K(z_k + \delta z) = \sum_a p_a \log p_a - \sum_a p_a \log q_a, \qquad p = \mathrm{softmax}(z_k + \delta z).$$

因为 $p = \pi_k = q$ 时 KL 取全局最小值，$\nabla_z K(z_k) = 0$。进一步使用

$$\frac{\partial p_a}{\partial z_b} = p_a(\mathbf{1}\{a = b\} - p_b)$$

可得 Hessian

$$\nabla_z^2 K(z_k) = F_k(s) = \mathrm{Diag}(\pi_k) - \pi_k \pi_k^\mathsf{T}. \tag{2.41}$$

F_k 是 categorical policy 的 Fisher 矩阵，半正定且零空间由所有常数 logit 平移张成。因此

$$\mathrm{KL}(\pi_\theta \| \pi_k) = \frac{1}{2} \delta z^\mathsf{T} F_k \delta z + R_{\mathrm{KL}}(\delta z), \qquad |R_{\mathrm{KL}}(\delta z)| \le C_{\mathrm{KL}} \|\delta z\|^3 \tag{2.42}$$

在 logits 位于有界集合时成立。这个三阶余项来自 softmax 的三阶导数有界，而不是额外的二元 KL 假设。

第二步：reward 项的一阶展开。 令

$$\ell_k(\theta) = -\mathbb{E}_{s,a}[r_k(s,a)]$$

表示最小化目标中的 reward 部分。假设 ℓ_k 在 θ_k 邻域内二阶可微，则

$$\ell_k(\theta_k + \Delta\theta) = \ell_k(\theta_k) - b_k^\mathsf{T} \Delta\theta + R_r(\Delta\theta), \qquad b_k = \mathbb{E}_{s,a}[r_k(s,a) \nabla_\theta \log \pi_{\theta_k}(a \mid s)], \tag{2.43}$$

并且 $|R_r(\Delta\theta)| \le C_r \|\Delta\theta\|^2$。这里 b_k 是固定 outer target 在当前学生处的 policy-gradient 方向；如果使用 PMD-Part 或 BPO 的回归 loss，则 b_k 被相应的 regression score 替代，但 KL 曲率项相同。

第三步：从 logits Jacobian 得到参数空间曲率。 令

$$J_k(s) = \left. \frac{\partial z_\theta(s)}{\partial \theta} \right|_{\theta=\theta_k}.$$

由

$$\delta z = J_k(s) \Delta\theta + R_z(\Delta\theta), \qquad \|R_z(\Delta\theta)\| \le C_z \|\Delta\theta\|^2,$$

把式(2.42) 代入式(2.40)，得到

$$\mathbb{E}_s \, \mathrm{KL}(\pi_\theta \| \pi_k) = \frac{1}{2} \Delta\theta^\mathsf{T} A_k \Delta\theta + R_{\mathrm{par}}(\Delta\theta), \qquad A_k = \mathbb{E}_s[J_k(s)^\mathsf{T} F_k(s) J_k(s)], \tag{2.44}$$

其中 $|R_{\mathrm{par}}(\Delta\theta)| \le C \|\Delta\theta\|^3$。因此式(2.45) 不是直接假设，而是式(2.44) 与式(2.43) 合并后，在 $\Delta\theta$ 足够小时的二阶主项：

$$\mathcal{J}_k(\theta_k + \Delta\theta) = \mathcal{J}_k(\theta_k) + \frac{1}{2\eta} \Delta\theta^\mathsf{T} A_k \Delta\theta - b_k^\mathsf{T} \Delta\theta + R_k(\Delta\theta). \tag{2.45}$$

命题 2.6 (局部曲率的正半定性与不可辨识方向)

A_k 对称半正定。若某个参数方向 v 满足 $J_k(s)v$ 对所有 replay 历史都是常数 logit 平移，则 $A_k v = 0$；该方向不改变策略分布，因而 KL 不能为它提供曲率。若在商空间上 $A_k \succeq mI$，则镜像 inner 目标在该商空间局部强凸。

证明 对任意 v，

$$v^\mathsf{T} A_k v = \mathbb{E}_s[(J_k(s)v)^\mathsf{T} F_k(s) (J_k(s)v)] \ge 0$$

由 $F_k \succeq 0$ 成立。F_k 的零空间正是常数向量方向，所以 $J_k(s)v$ 为常数时对应二次型为零。去除这些不改变策略的参数方向后，若最小特征值至少为 $m > 0$，则二次项给出局部强凸性。

Mirror Descent 与普通梯度的离散动力学

在 tabular 历史、教师分布固定且 inner 可以精确求解的情形，mirror outer 更新是

$$\pi_{k+1}(a \mid s) = \frac{\pi_k(a \mid s) \exp(\eta f_k(s,a))}{\sum_{a'} \pi_k(a' \mid s) \exp(\eta f_k(s,a'))}.$$

对任意固定的 f_k，当 $\eta \to 0$ 时展开分子和分母：

$$\pi_{k+1}(a \mid s) = \pi_k(a \mid s) \left[1 + \eta \left(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]\right)\right] + O(\eta^2). \tag{2.46}$$

右侧的一阶项

$$\pi_k(a \mid s)\,(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s])$$

正是 Fisher–Rao 度量下 $\mathbb{E}_\pi[f_k]$ 的 Natural Gradient。于是 mirror step 与 Natural Gradient 的关系是：Natural Gradient 是 mirror step 在 $\eta = 0$ 处的一阶 Euler 近似；有限 η 时，mirror step 还保留了指数归一化和正性约束，不能被普通加法更新完全替代。

对 OPD 的 $f_k = \log(T/\pi_k)$，可以把这一关系写得更具体。定义

$$\rho_k(a \mid s) = \log \frac{\pi_k(a \mid s)}{T(a \mid s)}.$$

精确 mirror 更新满足

$$\rho_{k+1}(a \mid s) = (1-\eta)\rho_k(a \mid s) - \log Z_k(s).$$

因此任意两个 action 的 log-ratio 差满足

$$\rho_{k+1}(a \mid s) - \rho_{k+1}(a' \mid s) = (1-\eta)\,[\rho_k(a \mid s) - \rho_k(a' \mid s)]\,. \tag{2.47}$$

这给出精确的 projective 收缩率 $1-\eta$，不需要局部二次近似。

相比之下，若直接在概率单纯形上使用未预条件的 Euclidean policy-gradient Euler 步，得到

$$\pi^{\mathrm{E}}_{k+1}(a \mid s) = \pi_k(a \mid s)\,[1 + \alpha\,(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s])]\,. \tag{2.48}$$

为了保持每个 action 的概率非负，必须额外满足

$$1 + \alpha\,(f_k(s,a) - \mathbb{E}_{\pi_k}[f_k \mid s]) \geq 0 \quad \text{对所有} a.$$

这个限制依赖当前 reward 的最大幅度；当 teacher/student ratio 很尖锐时，可行步长会变得很小。式(2.48) 只有在 $\alpha = \eta$ 且忽略 $O(\eta^2)$ 项时才与式(2.46) 相同，有限步时没有式(2.47) 的精确收缩性质。

定理 2.4 (OPD 中 mirror outer 与 Natural Gradient 的等价边界)

在固定历史、可表示的 tabular policy 和精确 Fisher 矩阵条件下，mirror outer step 与 Natural Gradient 满足：

1. 分布空间的一阶等价：式(2.46) 的一阶项等于 Fisher–Rao Natural Gradient；
2. 参数空间的局部等价：若 π_θ 在 θ_k 附近可微，且使用 A_k 的精确逆，则

   $$\theta^{\mathrm{NG}}_{k+1} = \theta_k + \eta A_k^{\dagger} b_k + O(\eta^2)$$

   与 mirror 解的参数表示一致到一阶；
3. 有限步不等价：mirror 更新是指数族闭式解，Natural Gradient 是参数空间的线性步；除非策略族对该指数更新封闭，否则二者在 $O(\eta^2)$ 项开始不同。

♡

证明 第一点由式(2.46) 直接得到。第二点中，局部目标的梯度为 $-b_k$，KL Hessian 为 A_k/η，因此局部最优位移满足 $\Delta\theta = \eta A_k^{\dagger} b_k$；这正是 Natural Gradient 的 Fisher 预条件方向。第三点来自指数更新的二阶项：

$$\pi_{k+1} = \pi_k + \eta\ \mathrm{grad}_{\mathrm{FR}}\,\mathbb{E}_{\pi_k}[f_k] + O(\eta^2),$$

而参数 Natural Gradient 的 Euler 步只保留一阶项。一般神经网络策略族不对指数映射封闭，所以不能把有限步 Natural Gradient 视为精确 mirror step。

有限 inner 步的收敛条件

定义局部主模型

$$Q_k(\Delta\theta) = \frac{1}{2\eta}\Delta\theta^{\mathsf{T}} A_k \Delta\theta - b_k^{\mathsf{T}}\Delta\theta.$$

若 b_k 属于 A_k 的值域，则其最小范数解为

$$\Delta\theta_k^{\star} = \eta A_k^{\dagger} b_k.$$

使用普通梯度下降、步长 $\gamma > 0$：

$$\Delta\theta_{m+1} = \Delta\theta_m - \gamma \nabla Q_k(\Delta\theta_m) = (I - \gamma A_k/\eta)\Delta\theta_m + \gamma b_k. \tag{2.49}$$

定理 2.5 (由 KL 曲率推出的 inner 线性收敛)

设 A_k 在商空间上的特征值属于 $[m_k, M_k]$，且 $0 < m_k \le M_k$。若

$$0 < \gamma < \frac{2\eta}{M_k},$$

则式(2.49) 收敛到 $\Delta\theta_k^\star$，并满足

$$\|\Delta\theta_m - \Delta\theta_k^\star\|_{A_k} \le q_k^m \|\Delta\theta_0 - \Delta\theta_k^\star\|_{A_k}, \qquad q_k = \max_{\lambda\in[m_k,M_k]} \left|1 - \frac{\gamma\lambda}{\eta}\right| < 1.$$

特别地，取 $\gamma = 2\eta/(m_k + M_k)$ 时，

$$q_k = \frac{M_k - m_k}{M_k + m_k} = \frac{\kappa_k - 1}{\kappa_k + 1}, \qquad \kappa_k = M_k/m_k.$$

♡

证明 令 $e_m = \Delta\theta_m - \Delta\theta_k^\star$。由式(2.49)，

$$e_{m+1} = (I - \gamma A_k/\eta) e_m.$$

在 A_k 的特征方向 λ 上，误差乘以 $1 - \gamma\lambda/\eta$。给定步长条件，所有这些因子的绝对值都小于 1，因此得到 q_k^m 的界。令两个端点方向的绝对收缩率相等即可得到最优固定步长和最后的条件数表达式。

真实 inner 目标还包含余项 R_k。若其梯度在半径 r 的邻域满足

$$\|\nabla R_k(\Delta\theta)\| \le L_k \|\Delta\theta\|^2,$$

并且 r 足够小使得 $L_k r \le m_k/(2\eta)$，则真实 Hessian 的特征值仍落在

$$[m_k/(2\eta),\ M_k/\eta + L_k r]$$

内。于是标准强凸光滑函数的梯度下降结论仍成立，只是收缩率由上述扩大后的光谱区间决定。这给出了“inner 需要做到局部收敛”的明确条件：步长必须由 KL/Fisher 曲率控制，且迭代必须停留在二阶展开有效的信赖域内。

Natural Gradient 的来源与作用

普通梯度在参数坐标中使用 A_k 的谱，病态方向的收敛速度由 κ_k 决定。Natural Gradient 以 Fisher 度量约束一次更新：

$$\min_{\Delta\theta} \ -b_k^\top \Delta\theta \quad \text{s.t.} \quad \frac{1}{2}\Delta\theta^\top A_k \Delta\theta \le \frac{\eta}{2}. \tag{2.50}$$

拉格朗日一阶条件给出

$$\Delta\theta_{\mathrm{NG}} = c\, A_k^\dagger b_k,$$

其中常数 c 由 trust-region 半径确定。若直接取 $\Delta\theta = \eta A_k^\dagger b_k$，它正是局部二次模型的最小点；实际算法用 Fisher 近似 $\widehat{A}_k$、阻尼 λI 和有限 inner 步，因此得到的是近似自然梯度，而不是理论上无条件的一步收敛。

命题 2.7 (Natural Gradient 对参数重参数化的不变性)

设 $\vartheta = \phi(\theta)$ 是局部可逆的光滑重参数化，且 Fisher 矩阵按张量变换规则变换。则更新方向

$$\mathcal{F}_\theta^\dagger \nabla_\theta \mathcal{J}_k$$

与在 ϑ 坐标中计算后映射回 θ 的方向一致；普通梯度 $\nabla_\theta \mathcal{J}_k$ 一般不具备该性质。

♠

证明 令 $B = \partial\vartheta/\partial\theta$。梯度变换为 $\nabla_\theta \mathcal{J} = B^\top \nabla_\vartheta \mathcal{J}$，Fisher 变换为 $\mathcal{F}_\theta = B^\top \mathcal{F}_\vartheta B$。在可逆子空间上代入并使用伪逆的相应变换，得到

$$\mathcal{F}_\theta^\dagger \nabla_\theta \mathcal{J} = B^{-1} \mathcal{F}_\vartheta^\dagger \nabla_\vartheta \mathcal{J}.$$

普通梯度只含 $B^\top$，因此会随坐标尺度改变。

这解释了 MDPO 和 EffOPD 中的两个实现判断。只在 θ_k 处做一次梯度步时，KL 的一阶梯度为零，trust-region 曲率尚未进入更新；固定 π_k 并执行多次 inner 更新，才能逼近式(2.40)。Natural Gradient 进一步把步长按照 A_k 的几何尺度归一化，但它仍然需要信赖域、阻尼和有限 inner 预算来处理模型非线性与 Fisher 估计误差。

几何中间分布与算术 proximal teacher 的区别。 式(2.25) 给出的 $\pi_k^{1-\eta}T^{\eta}/Z_k$ 是 KL 镜像子问题的精确解，因此在 log-probability 空间插值。TOP-D 中的算术 teacher

$$\widetilde{T}_{\eta} = (1-\eta)\pi_k + \eta T$$

是另一个用于控制 log-ratio 方差的 teacher operator。它同样产生 student 与 teacher 之间的中间分布，但不等价于 KL mirror 解；前者改变 target teacher，后者改变 proximal 优化问题的解。

第三章 梯度的偏差与方差

3.1 估计对象必须先固定

固定 prefix s，令 $g(a) = \nabla_\theta \log \pi_\theta(a \mid s)$、$u(a) = \log(\pi_\theta(a \mid s)/\mu(a \mid s))$，并令 $\rho(a) = e^{u(a)}$。以下区分三个不同的随机量：

(i) 直接 KL 镜像目标的梯度 ∇F_s；

(ii) 行为测度下回归损失的梯度 $-\nabla \mathcal{L}_{\text{Part}}$；

(iii) BPO 的逐 prefix 残差损失梯度。

三者在精确镜像解处共享零点，但只有第一个是 F_s 的梯度。偏差必须相对于明确的目标定义；把行为测度下的回归梯度称为 “无偏 off-policy policy gradient” 会混淆两个目标。

3.2 MDPO：无偏但承担 action-ratio 的二阶矩

令 $c(a) = f(s,a) - \frac{1}{\eta}u(a)$。MDPO的单样本估计量为

$$\widehat{G}_{\text{MDPO}} = \rho(a)c(a)g(a), \qquad a \sim \mu(\cdot \mid s), \tag{3.1}$$

并且在 $\pi \ll \mu$、$\mathbb{E}_\mu[\rho\|cg\|] < \infty$ 时

$$\mathbb{E}_\mu[\widehat{G}_{\text{MDPO}}] = \mathbb{E}_\pi[cg] = \nabla F_s. \tag{3.2}$$

因此 action-level IS 本身不产生偏差；若 prefix 来自 d_μ 而目标要求 d_π，还必须乘 $W_{<t} = d_\pi(s_t)/d_\mu(s_t)$。这两个密度比修正的是不同测度。

定理 3.1 (MDPO 梯度的精确偏差–方差分解)

设 $G = \mathbb{E}_\mu[\rho cg]$，批量大小为 n，并假设 $\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] < \infty$。则样本均值 $\widehat{G}_n$ 满足

$$\text{Bias}(\widehat{G}_n) = 0, \tag{3.3}$$

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \frac{1}{n}\left(\mathbb{E}_\mu[\rho^2 c^2 \|g\|^2] - \|G\|^2\right). \tag{3.4}$$

若 $\|g\| \le B_g$、$|c| \le B_c$，则

$$\operatorname{tr}\text{Cov}(\widehat{G}_n) \le \frac{B_g^2 B_c^2}{n}(1 + \chi^2(\pi\|\mu)). \tag{3.5}$$

♡

证明 令

$$X_i = \rho(a_i)c(a_i)g(a_i), \qquad a_i \overset{\text{i.i.d.}}{\sim} \mu, \qquad \widehat{G}_n = \frac{1}{n}\sum_{i=1}^n X_i.$$

由 support 条件，$\rho = \pi/\mu$ 在 μ-几乎处处有定义。换测度恒等式给出

$$\begin{aligned}\mathbb{E}_\mu[X_i] &= \sum_a \mu(a)\frac{\pi(a)}{\mu(a)}c(a)g(a) \\ &= \sum_a \pi(a)c(a)g(a) = \mathbb{E}_\pi[cg] = G.\end{aligned}$$

因此 $\mathbb{E}[\widehat{G}_n] = n^{-1}\sum_i \mathbb{E}[X_i] = G$，样本均值的偏差严格为零。再令 $Y_i = X_i - G$。独立性和 $\mathbb{E}[Y_i] = 0$ 消掉交叉

项，故

$$\mathbb{E}\|\widehat{G}_n - G\|^2 = \mathbb{E}\left\|\frac{1}{n}\sum_i Y_i\right\|^2 = \frac{1}{n^2}\sum_i \mathbb{E}\|Y_i\|^2 = \frac{1}{n}\left(\mathbb{E}\|X_1\|^2 - \|G\|^2\right).$$

这就是向量均方误差公式。最后，若 $\|g\| \le B_g$ 且 $|c| \le B_c$，则

$$\mathbb{E}_\mu\|X_1\|^2 \le B_g^2 B_c^2 \mathbb{E}_\mu[\rho^2] = B_g^2 B_c^2\big(1 + \chi^2(\pi\|\mu)\big),$$

其中最后一个等号来自 $\chi^2(\pi\|\mu) = \mathbb{E}_\mu[(\rho-1)^2] = \mathbb{E}_\mu[\rho^2] - 1$。去掉非负项 $\|G\|^2$ 即得到协方差迹的上界。

在自回归序列中，$W_{\le t} = \prod_{k\le t}\rho_k$ 的二阶矩可以逐步展开。给定 prefix $y_{<t}$，有

$$\mathbb{E}_\mu[\rho_t^2 \mid y_{<t}] = \sum_a \mu(a \mid y_{<t})\left(\frac{\pi(a \mid y_{<t})}{\mu(a \mid y_{<t})}\right)^2 = 1 + \chi^2\big(\pi(\cdot \mid y_{<t})\|\mu(\cdot \mid y_{<t})\big).$$

因为 $W_{\le t} = W_{<t}\rho_t$，塔式法则给出

$$\begin{aligned}\mathbb{E}_\mu[W_{\le t}^2] &= \mathbb{E}_\mu\left[W_{<t}^2 \mathbb{E}_\mu[\rho_t^2 \mid y_{<t}]\right] \\ &= \mathbb{E}_\mu\left[W_{<t}^2\left(1 + \chi^2(s_t)\right)\right].\end{aligned}$$

若所有可达 prefix 都满足 $c_{\mathrm{lo}} \le \chi^2(s) \le c_{\mathrm{hi}}$，则递推归纳得到

$$(1 + c_{\mathrm{lo}})^t \le \mathbb{E}_\mu[W_{\le t}^2] \le (1 + c_{\mathrm{hi}})^t. \tag{3.6}$$

这给出了 prefix IS 方差随修正长度增长的明确阶数。

再考虑完整权重 $W = W_{\le t}W_{>t}$。在条件 $y_{\le t}$ 下，后缀权重的均值为一：$\mathbb{E}[W_{>t} \mid y_{\le t}] = 1$，因此 $\mathbb{E}[W \mid y_{\le t}] = W_{\le t}$。全方差公式于是给出

$$\begin{aligned}\mathrm{Var}(W) &= \mathrm{Var}(\mathbb{E}[W \mid y_{\le t}]) + \mathbb{E}[\mathrm{Var}(W \mid y_{\le t})] \\ &= \mathrm{Var}(W_{\le t}) + \mathbb{E}[W_{\le t}^2\,\mathrm{Var}(W_{>t} \mid y_{\le t})].\end{aligned} \tag{3.7}$$

第二项非负；只要 prefix 之后存在策略比率不恒等于一的可达状态，它就严格为正。这说明后缀权重只能增加方差，不能抵消 prefix 权重已经产生的方差。

3.3 PMD-Part 的投影偏差与 BPO 的中心化方差

设策略类受限为 Π。PMD-Part的 population 解为

$$\theta^*_{\mathrm{Part}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu,\mu}[(u_\theta - h)^2], \tag{3.8}$$

而 BPO 的逐 prefix 解为

$$\theta^*_{\mathrm{BPO}} = \arg\min_{\theta\in\Pi} \mathbb{E}_{d_\mu}\,\mathrm{Var}_{a\sim\mu}[u_\theta(a) - \eta f(a)]. \tag{3.9}$$

二者在可实现时拥有同一零点；不可实现时，BPO 不惩罚 action-independent 的误差，因此它允许更大的常数方向自由度，而 PMD-Part 通过精确的 $\log Z_f$ 固定该常数。共享参数网络下，d_μ 同时决定状态间投影误差如何分配。

命题 3.1 (prefix IS 的偏差–方差阶梯)

对终端或未来回报 R，行为样本下的 token-level 不加前缀权重估计量，其期望与目标策略梯度的差可分解为

$$\sum_s (d_\pi - d_\mu)(s)\sum_a \nabla\pi(a \mid s)A^\mu(s,a) + \sum_s d_\pi(s)\sum_a \nabla\pi(a \mid s)(A^\pi - A^\mu)(s,a). \tag{3.10}$$

乘 $W_{<t}$ 后第一项恰好消失；再乘后缀 $W_{>t}$ 才能修正第二项，但其额外方差正是式(3.7) 的第二项。

证明 第一项来自把 d_π 替换为 d_μ，第二项来自把 A^π 替换为可估计的 A^μ。前缀密度比将行为 prefix 测度换成 d_π，所以只消掉第一项；后缀比率不改变已经使用的优势估计，却引入条件二阶矩，故只能修正价值滞后而不能降低方差。

注 [可加残差为何能绕开乘积] 若信号写成逐 token 鞅差之和 $D = \sum_t D_t$，且 $\mathbb{E}[D_t \mid s_t] = 0$，则交叉项消失并有

$$\mathbb{E}[D^2] = \sum_t \mathbb{E}[D_t^2]. \tag{3.11}$$

这正是离策略修正文档中“可加泛函的换测度界”的核心：回归型 PMD/BPO 利用逐点最优性或中心化残差，把序列乘积权重替换成逐步二阶量；代价是目标从真策略梯度改成行为测度下的投影问题。

命题 3.2 (可加 BPO 残差的损失估计方差)

设轨迹残差可写成 $\delta = \sum_{t=1}^{T} e_t$，其中 e_t 是关于 prefix 过滤的鞅差，且 $|e_t| \le B_e$。则

$$\mathbb{E}[\delta^2] = \sum_{t=1}^{T} \mathbb{E}[e_t^2], \qquad \mathbb{E}[\delta^4] \le T^2 B_e^2 \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.12}$$

对 n 条独立轨迹的平方残差损失估计量 $\widehat{\mathcal{L}} = n^{-1} \sum_i \delta_i^2/(2\eta)$，有

$$\mathrm{Var}(\widehat{\mathcal{L}}) \le \frac{T^2 B_e^2}{4\eta^2 n} \sum_{t=1}^{T} \mathbb{E}[e_t^2]. \tag{3.13}$$

因此中心化残差的统计方差按 token 二阶量相加，而不是按 sequence ratio 的二阶矩相乘。

证明 鞅差正交给出第一式。由 Cauchy–Schwarz，$\delta^2 = (\sum_t e_t)^2 \le T \sum_t e_t^2 \le T^2 B_e^2$，故 $\delta^4 \le T^2 B_e^2 \delta^2$。独立样本均值的方差为单样本方差除以 n，再用 $\mathrm{Var}(\delta^2) \le \mathbb{E}[\delta^4]$ 即得结论。

第四章 实现与参数比较

4.1 理论对象与实际代码

表 4.1: PMD、MDPO 与 BPO 的目标和实现差异

方法	理论更新	梯度/权重	主要偏差方差来源
PMD-Part	回归 $u^+ = \eta f - \log Z_f$	行为测度下 residual score，无外部 IS	有限模型投影偏差；通常低于 IS 的 ratio 方差
PMD-Mean	中心化平方回归加 $\mathbb{E}_\mu[e^u] = 1$	Lambert-W 投影梯度	均值和投影近似偏差；无乘积 IS
MDPO	直接最大化 $\mathbb{E}_\pi[f] - \frac{1}{\eta}\mathrm{KL}(\pi\|\mu)$	$\rho(f - \frac{1}{\eta}\log\rho)\nabla\log\pi$	action IS 无偏但二阶矩随 $\mathbb{E}_\mu[\rho^2]$ 增长
BPO	residual regression（本文件分析未线性化形式）	$\delta(g - \bar{g})$，包含 score centering	d_μ 投影偏差与回归统计方差

4.2 BPO 论文的训练预算

BPO论文源码的主实验写明：每个 training step 先生成 256 个 prompt、每个 prompt 16 个 response，共 4096 条 response；再划分为 8 个、每个 512 条 response 的 mini-batch，执行 8 次 optimizer updates。主实验运行 400 个 training steps，即 3200 次 optimizer updates；附录消融运行 1000 个 training steps。论文没有按 residual norm 或 mirror-subproblem gap 停止的 inner loop，因此这些是固定更新预算，不是子问题收敛步数。

4.3 OpenKimi/PMD 的训练预算

OpenKimi的 PMD loss 默认先对完整 response 的 token log-ratio 求和，再把 sequence log-ratio broadcast 到 response 内 token。

Qwen2.5-7B math recipe 设置 ‘PPO_EPOCHS=1‘、‘train_batch_size=512‘、‘actor.ppo_mini_batch_size=32‘，所以静态 batch 下每个 outer step 约有 $512/32 = 16$ 个 mini-batch 更新。代码没有 inner residual stopping 或 PMD gap 检验；‘total_training_steps=3000‘ 是 outer steps 上限。

4.4 经典 MDPO 的训练预算与 IS

经典 MDPO on-policy 代码默认 ‘sgd_steps=5‘，MuJoCo README 的推荐示例使用 10。一个 rollout batch 固定后，对同一批数据重复执行该数量的 policy optimizer updates，再刷新 old/new anchor；没有根据 mirror residual 自适应停止。

off-policy 代码的 README 暴露 ‘sgd_steps=1000‘，但当前训练循环实际写为 ‘for grad_step in range(1)‘，原本的 ‘int(self.gradient_steps)‘ 被注释。因此每个 train event 实际只执行一次 actor/critic update；‘gradient_steps‘ 主要影响 target/anchor policy 同步周期。实现使用 replay 状态测度和 action-level policy gradient，不能解释为完整的 prefix-IS 求解。

4.5 比较时应报告的指标

为了比较四种方法，实验至少应固定同一 rollout batch，并记录：每个 inner update 的 mirror loss、log-ratio residual norm、$\mathrm{KL}(\pi_\theta \| \mu)$、梯度范数、ratio 的均值与二阶矩、中心化 residual 的条件方差，以及 prefix coverage。这样才能区分“做了更多 optimizer steps”和“真正接近 token-level mirror optimum”。

第五章 结论与 MirrorOPD 的边界

从同一个 token-level Gibbs 最优解出发，PMD-Part 是精确 log-ratio 回归，PMD-Mean 是中心化回归后的 Lambert-W 投影，MDPO 是带 action IS 的直接 KL 正则化 policy gradient。BPO 的完整 reverse-KL 平方 residual 在未线性化时产生中心化 score 梯度；它与 PMD-Part 共享可实现时的最优点，但一般相差 $c_s\bar{g}$，因此不能把二者的梯度直接视为相同。线性化、二元 KL 化简和工程截断属于后续近似，本文件没有把它们作为理论等价的前提。

本文件暂不推导 OPD 的完整 off-policy correction 或 KL 系数调度。后续 MirrorOPD 需要先选择局部即时 reward 目标还是完整加性回报目标，再决定是否引入 prefix IS、是否采用 Part/Mean 投影，以及如何用 Natural Gradient 控制学生策略与教师策略的距离。

Bibliography

[1] Tomar et al. *Mirror Descent Policy Optimization*. arXiv:2005.09814, 2020.

[2] Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. arXiv:2602.05933, 2026.

[3] Song et al. *Bellman Policy Optimization*. arXiv:2609.15987, 2026.

[4] OpenKimi contributors. *OpenKimi: PMD and RL post-training implementation*. GitHub repository, 2026. https://github.com/horizon-llm/OpenKimi.

[5] Tomar et al. *Mirror Descent Policy Optimization*: official implementation. GitHub repository, 2020. https://github.com/manantomar/Mirror-Descent-Policy-Optimization.