MirrorOPD 统一理论

镜像下降与策略蒸馏的动力学

Natural-GD、外层同步、EMA 锚点与 TOP-D

2026 年 10 月 7 日

目录

第一章 问题、对象与统一结论 **1**
1.1 三层对象 . . . 1
1.2 精确分布动力学的起点 . . . 1
1.3 从局部结论到完整算法的条件 . . . 1
1.4 符号、时钟与比较对象 . . . 1
1.5 两动作例子贯穿整个推导 . . . 2
1.6 正文的论证依赖 . . . 2

第二章 镜像下降的几何、策略改进与参数求解 **3**
2.1 Bregman 散度与镜像子问题 . . . 3
2.2 负熵镜像与 Gibbs 变分恒等式 . . . 4
2.3 PMD 与 Bellman 策略改进 . . . 5
2.4 MDPO 的 on-policy 与 off-policy pipeline . . . 6
2.5 Fisher 几何与自然梯度 . . . 7
2.6 文献谱系与 OPD 的接口 . . . 9

第三章 OPD 的目标、残差与访问测度 **10**
3.1 固定 prefix 的镜像问题 . . . 10
3.2 中心化残差的零点 . . . 10
3.3 序列级与逐状态级镜像 . . . 11
3.4 历史、动作与未来比率 . . . 11
3.5 覆盖反例与一步 teacher 投影 . . . 12

第四章 有限 inner 求解、outer 同步与步长 **13**
4.1 以振幅定义误差 . . . 13
4.2 提前同步后重新 rollout . . . 13
4.3 固定 anchor 的参数局部模型 . . . 14
4.4 Hard、delayed 与逐步同步 . . . 14
4.5 KL budget 与可变步长 . . . 14

第五章 EMA 锚点与 OPD 的联合动力学 **16**
5.1 两个策略状态、三种时钟 . . . 16
5.2 准稳态滞后定理及其边界 . . . 17
5.3 teacher 误差与滞后的联合收敛 . . . 19
5.4 延迟 EMA 的事件级复合算子 . . . 21
5.5 具有全局定理的几何 soft sync . . . 21
5.6 Top-k KL 与噪声动力学 . . . 23
5.7 同步与参数设计的理论结论 . . . 24

第六章 TOP-D、MirrorOPD 与 vanilla OPD **25**
6.1 外部近端 teacher 与内部权重 . . . 25
6.2 算术混合与几何 mirror 的方向 . . . 26
6.3 全概率空间的 token 梯度方差界 . . . 26

6.4 小权重的学习速度与标准化 28
6.5 算术近端算子的收敛 28
6.6 有限时域访问测度与性能下界 29
6.7 MirrorOPD 可继承的结论 32
6.8 vanilla OPD 的极限、反例与结论 32
6.9 PMD-mean：同一小步长下的不同回归目标 33
6.10 两种方法的收益与组合条件 36

第七章 从局部几何到方差与性能保证 **37**
7.1 projective 距离如何约束 KL 37
7.2 访问误差对回归目标的影响 37
7.3 OPD 的条件方差界 37
7.4 有限 horizon 下的性能差 38
7.5 teacher 几何与真实性能的桥梁 39

第八章 算法实现与可证伪实验 **40**
8.1 把外层目标与内层优化器分开实现 40
8.2 Fisher 距离控制与数值求解 40
8.3 与理论匹配的停止条件 40
8.4 四项研究假设及其反证 41
8.5 实验矩阵与公平预算 41

第九章 文献关系与研究贡献的边界 **43**
9.1 镜像几何、策略改进与参数投影 43
9.2 离策略优化的三种分工 43
9.3 LLM 后训练中的镜像目标 44
9.4 OPD 的目标与访问分布 44
9.5 直接重叠工作与本书的增量 44
9.6 阅读路径 45

参考文献 **46**

第一章 问题、对象与统一结论

本书研究一个明确的算法结构：在第 k 个 outer step 用当前策略 π_k 采样或校正访问测度，构造教师相对当前策略的信号，然后在固定 anchor 上进行若干 inner 更新，最后把 student 同步为 π_{k+1}。研究重点是同步顺序、镜像步长 η、Natural-GD 近似以及 EMA anchor 对动力学的改变。

1.1 三层对象

给定 prompt 或状态 s，记动作空间为有限集合 $\mathcal{A}$，学生策略为 π, teacher 为 T，行为策略或 outer anchor 为 μ。需要区分三个层次：

1. **分布层**：在 simplex 上求解 KL 镜像子问题，得到精确的目标分布；
2. **参数层**：用神经网络和有限 inner steps 逼近该目标，产生投影误差；
3. **访问测度层**：rollout 只覆盖实际到达的 prefix，决定分布层结论能否汇总为 sequence-level 结论。

若把三层混为一层，就会错误地把“inner loss 已收敛”当成“全局策略已经等于 teacher”，也会把固定的 η 误解成固定的 rollout 数据。正确的 outer pipeline 是

$$\pi_k \longrightarrow \text{rollout 或 replay 校正} \longrightarrow \text{冻结}(\pi_k, T, r_k) \longrightarrow \text{inner solve} \longrightarrow \pi_{k+1} \longrightarrow \text{重新采样}.$$

1.2 精确分布动力学的起点

在固定 prefix、共同 support 和精确分布优化的条件下，OPD 的镜像目标为

$$p^{\star}_{k+1}(a \mid s) = \frac{\pi_k(a \mid s)^{1-\eta} T(a \mid s)^{\eta}}{\sum_b \pi_k(b \mid s)^{1-\eta} T(b \mid s)^{\eta}}.$$

因此 $\eta = 1$ 是一次 teacher 投影，$0 < \eta < 1$ 是 teacher 与 anchor 的几何插值。令 $\rho_k = \log(\pi_k/T)$，则去掉归一化常数后

$$\rho_{k+1}(a \mid s) - \rho_{k+1}(a' \mid s) = (1-\eta)\big(\rho_k(a \mid s) - \rho_k(a' \mid s)\big).$$

这给出精确的 projective contraction，而不是参数空间中未经说明的普通线性插值。

有限 inner steps 时，实际迭代多出一个投影误差。若该误差在 projective 范数下为 ε_k，则

$$\Delta_{k+1} \le (1-\eta)\Delta_k + \varepsilon_k, \qquad \limsup_k \Delta_k \le \frac{\sup_k \varepsilon_k}{\eta}$$

（常数 η 且误差有界）。故减小 η 会增加 outer 收敛步数，也会放大固定 inner 误差的稳态影响。

1.3 从局部结论到完整算法的条件

上述结论需要共同 support、有限 log-ratio 和正确的 prefix 测度。vanilla OPD 若只用一批旧 rollout、丢弃 anchor 依赖、又不控制 teacher support，则没有无条件的全局收敛、单调真实回报或有限方差结论。可证明的路线是先证明局部 Gibbs 与 projective 结果，再加入 inner 误差、occupancy mismatch、teacher 误差和采样噪声。

1.4 符号、时钟与比较对象

固定 η 是每次 outer 都采用同一个近端强度。rollout 是否更新则由采样时钟决定；η 的数值没有定义采样时钟。在一次 outer 内把固定子问题求至收敛，得到 $G_\eta(\pi_k)$；hard sync 后下一次目标为 $G_\eta(\pi_{k+1})$。因此训练不是在 π_0 的同一批数据上永远重复同一个子问题。MDPO 的 on-policy 与 off-policy 实现还有不同的同步频率，第二章逐项说明。

符号	含义
$s, a, \mathcal{A}, H$	prefix、token、有限动作集合、response的有限最大长度。
$T, p_\theta, b, \bar{\pi}$	teacher、actor、生成数据的 behavior、镜像 anchor。
k, m, j	outer iteration、该 outer 内的 inner update、EMA 更新事件。
$\eta, \tau = \eta^{-1}$	镜像步长与其逆温度；学习率另用 α 或 γ。
ν, d_p, d_b	固定训练 prefix 测度、actor 和 behavior 的访问测度。
$G_\eta(b), \varepsilon_k$	精确镜像目标、实际 inner 解对该目标的误差。
$F, \epsilon_{\mathrm{NG}}$	参数 Fisher、inner 实际移动的 KL 半径。
$\beta, h, T_{\mathrm{ema}}$	EMA 正则强度、一次同步保留旧 anchor 的系数、同步周期；第 5 章明确与论文原记号的转换。

1.5 两动作例子贯穿整个推导

令 $b = (1/2, 1/2)$、$T = (4/5, 1/5)$。teacher的 odds 为 4，行为 odds 为 1，故镜像目标的 odds 是 4^η。当 $\eta = 1/2$ 时，第一次精确 outer 解为 $(2/3, 1/3)$，第二次精确解的 odds 为 $4^{3/4}$。经过 k 次精确 hard sync，odds 为

$$\frac{p_k(1)}{p_k(2)} = 4^{1-(1-\eta)^k}.$$

inner 未收敛时，设第 k 次 log-odds 求解误差为 e_k，则

$$z_{k+1} = (1-\eta) z_k + e_k, \qquad z_k = \log \frac{p_k(1)}{p_k(2)} - \log 4.$$

这条标量式解释首轮误差怎样被后续 outer 衰减，也解释反复产生同向求解误差为何形成地板。第 4 章将它推广到多动作、变步长和有限 inner 次数。

$\eta = 1$ 时精确目标一次等于 T，但参数训练只把 actor 推向这个目标。未访问 prefix、不充分 inner 求解或不可表示的 teacher 都会留下误差。这里的“到 teacher”是分布优化的解，不能把它等同于一次参数梯度更新。

1.6 正文的论证依赖

第二章从 Bregman 三点恒等式推到 PMD、MDPO 与 Natural-GD。第三章用 Gibbs 变分式定义 MirrorOPD，并证明中心化残差与局部目标的关系，然后区分 sequence 与 prefix 测度。第四章研究 hard sync、finite inner 和 η，先给精确动力学，再逐项加入误差。第五章保留 EMA 原论文的参数和时钟，分别分析 anchor 滞后与 actor 收敛。第六章完整展开 TOP-D 的定理证明并比较 vanilla OPD 和 PMD-mean。第七章从概率距离与测度误差导出方差、性能下界及其附加条件。第八章将这些命题转成可检验算法和实验；第九章说明与前序工作的关系。

所有“全局”结论都注明其量化范围：固定 prefix、全部有限 prefix 树，或神经网络验证集合。对固定 teacher 的蒸馏收敛与对真实环境奖励的策略改进分别证明。这样每个结论可以沿着明确的假设追溯到一个实际训练对象。

第二章 镜像下降的几何、策略改进与参数求解

镜像下降先在概率分布空间中定义目标；策略镜像下降（policy mirror descent，PMD）把目标接到当前策略的价值函数；参数化优化器再把目标映射到神经网络能够表达的策略。自然梯度（natural gradient，NG）描述第三层中的局部距离几何。本章分别建立这些对象，使后续能够明确说明一个 outer step 完成了什么，以及有限 inner steps 留下了什么误差。

2.1 Bregman 散度与镜像子问题

2.1.1 势函数和三点恒等式

设 $\mathcal{C}$ 是凸集合，h 在包含其相对内部的区域可微、严格凸。由 h 生成的 Bregman 散度为

$$D_h(x,y)=h(x)-h(y)-\langle\nabla h(y),x-y\rangle. \tag{2.1}$$

凸性给出 $D_h(x,y)\geq 0$；严格凸性给出等号当且仅当 $x=y$。它通常不对称，也不满足三角不等式。镜像下降只需要用它度量候选点偏离旧迭代点的代价。

引理 2.1 (Bregman 三点恒等式)

在势函数可微区域，对任意 x,y,z 有

$$\langle\nabla h(x)-\nabla h(y),z-x\rangle=D_h(z,y)-D_h(z,x)-D_h(x,y). \tag{2.2}$$

证明 分别展开右边：

$$\begin{aligned}D_h(z,y)&=h(z)-h(y)-\langle\nabla h(y),z-y\rangle,\\ D_h(z,x)&=h(z)-h(x)-\langle\nabla h(x),z-x\rangle,\\ D_h(x,y)&=h(x)-h(y)-\langle\nabla h(y),x-y\rangle.\end{aligned}$$

相减后函数值全部抵消，$\nabla h(y)$ 的两项合并为

$$-\langle\nabla h(y),z-y\rangle+\langle\nabla h(y),x-y\rangle=-\langle\nabla h(y),z-x\rangle.$$

加上剩余的 $\langle\nabla h(x),z-x\rangle$，得到结论。

最小化方向的镜像步定义为

$$x^+=\arg\min_{u\in\mathcal{C}}\{\eta\langle g,u\rangle+D_h(u,x)\},\qquad \eta>0. \tag{2.3}$$

g 是当前目标梯度或其估计。η 控制目标分布相对参考点的移动，而 inner 参数优化器学习率控制求解过程，二者有不同语义。

命题 2.1 (镜像步的三点不等式)

若解存在且 h 在 x^+ 可微，则任意 $u\in\mathcal{C}$ 满足

$$\eta\langle g,x^+-u\rangle\leq D_h(u,x)-D_h(u,x^+)-D_h(x^+,x). \tag{2.4}$$

证明 凸子问题的一阶最优性条件为

$$\langle\eta g+\nabla h(x^+)-\nabla h(x),u-x^+\rangle\geq 0.$$

移项得

$$\eta\langle g,x^+-u\rangle\leq\langle\nabla h(x^+)-\nabla h(x),u-x^+\rangle.$$

在引理 2.1 中取 $(x,y,z)=(x^+,x,u)$ 即得结论。

这条估计使相邻轮次的散度能够望远镜相消。其证明没有使用 MDP 结构，因此它先是通用凸优化工具，随后才被接到策略改进上。

2.1.2 凸目标的平均误差界

定理 2.1 (凸镜像下降的误差界)

设 ϕ 为凸函数，$g_k \in \partial\phi(x_k)$，$\|g_k\|_* \le G$，并且

$$D_h(u,v) \ge \frac{\sigma}{2}\|u-v\|^2, \qquad \sigma > 0.$$

用固定 $\eta > 0$ 执行镜像步。对最优解 x^* 和 $K \ge 1$，有

$$\phi\left(\frac{1}{K}\sum_{k=0}^{K-1} x_k\right) - \phi(x^*) \le \frac{D_h(x^*, x_0)}{K\eta} + \frac{\eta G^2}{2\sigma}. \tag{2.5}$$

♡

证明 由子梯度不等式和三点估计，

$$\begin{aligned}\eta[\phi(x_k) - \phi(x^*)] &\le \eta\langle g_k, x_k - x_{k+1}\rangle + \eta\langle g_k, x_{k+1} - x^*\rangle \\ &\le D_h(x^*, x_k) - D_h(x^*, x_{k+1}) - D_h(x_{k+1}, x_k) + \eta G\|x_k - x_{k+1}\|.\end{aligned}$$

令 $r = \|x_k - x_{k+1}\|$，则

$$-\frac{\sigma}{2}r^2 + \eta G r = -\frac{\sigma}{2}\left(r - \frac{\eta G}{\sigma}\right)^2 + \frac{\eta^2 G^2}{2\sigma} \le \frac{\eta^2 G^2}{2\sigma}.$$

对 k 求和，散度项相消，得到

$$\eta\sum_{k=0}^{K-1}[\phi(x_k) - \phi(x^*)] \le D_h(x^*, x_0) - D_h(x^*, x_K) + \frac{K\eta^2 G^2}{2\sigma}.$$

删除非正项，除以 $K\eta$，再用凸性处理迭代平均即可。

固定步长意味着 η 不随 k 改变，梯度、参考点和每轮数据依然更新。策略参数目标一般非凸；PMD 的全局分析利用 Bellman 结构，不能直接把本定理中的 x 换成 Transformer 参数。

2.2 负熵镜像与 Gibbs 变分恒等式

在概率单纯形上取负熵 $h(p) = \sum_a p(a)\log p(a)$。对严格正的 q，$\nabla h(q)_a = \log q(a) + 1$。利用概率总和为 1，有

$$D_h(p,q) = \sum_a p(a)\log\frac{p(a)}{q(a)} = \mathrm{KL}(p\|q).$$

若 q 有零概率，候选必须限制在 $\mathrm{supp}(q)$ 上；否则散度为无穷大。

固定状态 s，暂时省略 s，设 anchor 为 μ，冻结信号为 f。镜像步长 η 与温度 τ 的关系为 $\eta = 1/\tau$：

$$J_\mu(p) = \mathbb{E}_p[f] - \frac{1}{\eta}\mathrm{KL}(p\|\mu), \qquad p^+ = \arg\max_{p \ll \mu} J_\mu(p). \tag{2.6}$$

定理 2.2 (Gibbs 解和精确目标差)

设动作集合有限、$\eta > 0$、f 在 $\mathrm{supp}(\mu)$ 上有限。定义

$$Z = \sum_a \mu(a)e^{\eta f(a)}, \qquad p^*(a) = \frac{\mu(a)e^{\eta f(a)}}{Z}.$$

则 p^* 为唯一最大化解。任意 $p \ll \mu$ 满足

$$J_\mu(p) = \frac{\log Z}{\eta} - \frac{1}{\eta}\mathrm{KL}(p\|p^*), \qquad J_\mu(p^*) - J_\mu(p) = \frac{1}{\eta}\mathrm{KL}(p\|p^*). \tag{2.7}$$

♡

证明 有限动作和有限信号保证 $0 < Z < \infty$。p^* 非负、总和为 1，并与 μ 有相同 support。由定义逐动作有

$$\log \frac{p(a)}{p^*(a)} = \log \frac{p(a)}{\mu(a)} - \eta f(a) + \log Z.$$

在 p 下求期望，得到

$$\mathrm{KL}(p\|p^*) = \mathrm{KL}(p\|\mu) - \eta \mathbb{E}_p[f] + \log Z.$$

整理得式(2.7)。KL 非负且仅在 $p = p^*$ 时为零，故唯一最优性和目标差同时成立。

拉格朗日方法给出的内点条件为

$$f(a) - \frac{1}{\eta}\left(\log \frac{p(a)}{\mu(a)} + 1\right) + \lambda = 0.$$

消去乘子同样得到 Gibbs 形式。变分恒等式额外给出全局最优性及目标差与 KL 的精确对应，因而适合分析有限 inner 求解误差。

将 f 减去动作无关的常数 $c(s)$ 不改变 target，因为分子分母同时乘 $e^{-\eta c(s)}$。因此 Q^μ 和 $A^\mu = Q^\mu - V^\mu$ 给出同一状态级 target。均值为零却不意味着配分函数为 1：若 $\mathbb{E}_\mu f = 0$，Jensen 不等式给出 $Z \geq 1$，非恒定信号时严格大于 1。

2.3 PMD 与 Bellman 策略改进

2.3.1 精确无正则镜像步

考虑有限状态、有限动作、折扣 $\gamma \in [0, 1)$ 的 MDP，采用奖励最大化约定。动作价值 $Q^\pi(s, a)$ 表示先执行 a、随后遵循 π 的期望折扣回报，且

$$V^\pi(s) = \langle Q^\pi(s, \cdot), \pi(\cdot \mid s)\rangle, \qquad A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

一轮精确 KL-PMD 为

$$\pi_{k+1}(\cdot \mid s) = \arg\max_p \left\{ \langle Q^{\pi_k}(s, \cdot), p\rangle - \frac{1}{\eta_k} \mathrm{KL}(p\|\pi_k(\cdot \mid s)) \right\}. \tag{2.8}$$

表格、严格正旧策略和精确价值函数条件下，每个状态由 Gibbs 公式独立更新。算法本身没有必须运行到收敛的数值 inner loop；inner loop 来自近似表示或近似价值评估。

命题 2.2 (精确 PMD 的一轮策略改进)

精确执行式(2.8) 时，每个状态满足

$$\langle A^{\pi_k}, \pi_{k+1}\rangle \geq \frac{1}{\eta_k} \mathrm{KL}(\pi_{k+1}\|\pi_k) \geq 0,$$

并且逐状态有 $V^{\pi_{k+1}} \geq V^{\pi_k}$。

证明 将 π_k 本身作为可行候选，最优性给出

$$\langle Q^{\pi_k}, \pi_{k+1} - \pi_k\rangle \geq \frac{1}{\eta_k} \mathrm{KL}(\pi_{k+1}\|\pi_k).$$

左边恰等于 $\langle A^{\pi_k}, \pi_{k+1}\rangle$。将这个非负状态向量记为 b，新策略的转移矩阵记为 P_{k+1}。两条 Bellman 方程相减得

$$V^{\pi_{k+1}} - V^{\pi_k} = b + \gamma P_{k+1}(V^{\pi_{k+1}} - V^{\pi_k}).$$

从而

$$V^{\pi_{k+1}} - V^{\pi_k} = (I - \gamma P_{k+1})^{-1} b = \sum_{j=0}^{\infty} \gamma^j P_{k+1}^j b \geq 0.$$

级数在 $\gamma < 1$ 时收敛，每项非负，结论成立。

本证明使用当前策略的完整动作价值。将信号换成即时 token reward 或教师 log-ratio 后，Gibbs 定理依然有效，Bellman 改进部分则需要另行建立信号与价值的关系。

2.3.2 一般正则项的三点估计

这一小节采用代价最小化约定，设 q_k 为当前动作代价，Ω_s 为凸策略正则项。子问题为

$$p^+ = \arg\min_p \{\eta[\langle q_k, p\rangle + \Omega_s(p)] + D_h(p, p_k)\}.$$

若 Ω_s 相对于 h 为 μ 强凸，即对 $v \in \partial\Omega_s(p^+)$ 有

$$\Omega_s(p) \geq \Omega_s(p^+) + \langle v, p - p^+\rangle + \mu D_h(p, p^+),$$

则有

$$\eta[\langle q_k, p^+ - p\rangle + \Omega_s(p^+) - \Omega_s(p)] \leq D_h(p, p_k) - (1 + \eta\mu)D_h(p, p^+) - D_h(p^+, p_k). \tag{2.9}$$

证明时先用一阶条件和三点恒等式控制 $\eta\langle q_k + v, p^+ - p\rangle$。再由强凸性得到

$$\Omega_s(p^+) - \Omega_s(p) \leq \langle v, p^+ - p\rangle - \mu D_h(p, p^+).$$

将后一式乘以 η，与前一式合并，即得到额外的 $-\eta\mu D_h(p, p^+)$。

Lan 的 PMD 分析把状态级估计与正则化 Bellman 方程、占用测度结合，在规定步长与正则条件下得到全局速率。原文固定步长线性收敛定理有强凸条件；一般凸情形和 approximate PMD 使用各自的构造与参数。正则化 PMD 文献还单独处理不精确价值评估和不精确策略更新。式(2.9) 是本书直接证明的代数工具，不能据此宣称任意神经 OPD 满足论文的全局定理。[32, 77]

2.3.3 固定步长与每轮刷新

精确 PMD 每轮先给定 π_k，评估 Q^{π_k}；固定这两个输入，逐状态执行 prox map；得到 π_{k+1} 后重新评估新策略的动作价值。常数 $\eta_k = \eta$ 固定系数，旧策略和动作价值仍随 outer 更新。随机估计每轮的对象仍是 Q^{π_k}。永久复用 π_0 的价值估计，就变成固定 surrogate 上的优化，改变了策略迭代的对象。

2.4 MDPO 的 on-policy 与 off-policy pipeline

2.4.1 On-policy：固定参考策略的多步求解

Tomar等人的 MDPO 用参数化策略近似求解旧访问测度下的镜像子问题。其 on-policy 目标为 [71]

$$\Psi_k(\theta) = \mathbb{E}_{s\sim d_{\pi_k}}\left[\mathbb{E}_{a\sim\pi_\theta} A^{\pi_k}(s, a) - \frac{1}{t_k}\mathrm{KL}(\pi_\theta(\cdot \mid s)\|\pi_k(\cdot \mid s))\right]. \tag{2.10}$$

这里保留原文步长符号 t_k。它是 prox 系数，与参数优化器学习率不同。用旧策略数据估计第一项时，写成

$$\mathbb{E}_{s\sim d_{\pi_k}, a\sim\pi_k}\left[\frac{\pi_\theta(a \mid s)}{\pi_k(a \mid s)}\widehat{A}_k(s, a)\right].$$

这个动作比率校正固定状态下的动作期望；状态测度仍为 d_{π_k}，与原来的 surrogate 一致。

原文 Algorithm 1 的更新次序是：

1. 用当前 π_k 生成新的 rollout，计算 return 与优势，并更新价值网络。
2. 保存 old-policy 参数 θ_k，将 candidate 初始化为 $\theta_{k,0} = \theta_k$。
3. 固定 rollout、优势与 old-policy copy，对 Ψ_k 执行 m 次 SGD。
4. 令 $\theta_{k+1} = \theta_{k,m}$，刷新 old copy，再进行下一轮 rollout。

原文连续控制实验比较了不同 m，on-policy 采用 $m = 10$。这是实验中的近似求解预算，不是 outer 次数，也不是 LLM 的通用停止标准。

命题 2.3 (Anchor 处 KL 的梯度为零)

对 support 固定、可微且允许交换求导与求和的概率族，定义 $K_k(\theta) = \mathrm{KL}(\pi_\theta \| \pi_{\theta_k})$，则

$$\nabla K_k(\theta_k) = 0.$$

从 θ_k 开始仅做一次普通显式梯度上升，KL 惩罚不影响该次一阶方向。

证明 逐项求导得

$$\nabla K_k(\theta) = \sum_a \nabla \pi_\theta(a) \left(\log \frac{\pi_\theta(a)}{\pi_{\theta_k}(a)} + 1 \right).$$

在 θ_k 处括号为 1，故

$$\nabla K_k(\theta_k) = \nabla \sum_a \pi_\theta(a)\big|_{\theta_k} = 0.$$

连续密度把求和换成积分即可。显式一步更新中的惩罚梯度因此为零。

这一结论针对一阶更新：二阶信赖域法仍可在 anchor 处使用 KL 曲率。普通 SGD 后续步骤因为离开了 anchor，KL 梯度开始生效。若每步都同步 anchor，梯度归零会反复出现，与固定子问题的多步求解产生不同动力学。

2.4.2 Off-policy：replay 状态与重新采样的动作

MDPO的 off-policy 推导从 replay buffer 取状态，近似较均匀的状态采样；原文明确说明这不是真正均匀分布。其 actor 子问题为

$$\mathbb{E}_{s\sim\mathcal{D}} \left[\mathbb{E}_{a\sim\pi_\theta} Q_{\psi,k}(s,a) - \frac{1}{t_k} \mathrm{KL}(\pi_\theta \| \pi_k)(s) \right].$$

连续动作通过 $a = \tilde{a}_\theta(\epsilon, s)$ 重参数化，等价 actor 损失为

$$\mathbb{E}_{s\sim\mathcal{D},\epsilon}[\log \pi_\theta(\tilde{a}_\theta \mid s) - \log \pi_k(\tilde{a}_\theta \mid s) - t_k Q_{\psi,k}(s, \tilde{a}_\theta)].$$

actor 动作由 candidate 重新采样，因此这里没有使用 replay 存下来的行为动作再乘 IS 比率。replay transition 用于 TD critic 学习，critic 误差与 replay 状态覆盖仍需单独控制。

原文 Algorithm 2 描述固定 old policy 的多步 SGD。实际 off-policy 实验为效率每次只做一个 actor 梯度更新，将 old copy 保留 m 次更新后再同步，从而模拟多步求解。论文报告其 off-policy 实验采用 $m = 1000$；此处 m 是 old copy 的更新周期，不能与 on-policy 的 $m = 10$ 直接比较。

MDPO 和 soft actor-critic（SAC）的差别来自 anchor：前者的 Boltzmann target 为 $\pi_k \exp(t_k Q)$，后者的熵正则目标相当于相对均匀基准测度的 Boltzmann 分布。它们都做 KL 投影，一个保留历史策略 reference，一个使用熵正则基准。相同的投影名称没有消除算法状态的差别。

2.5 Fisher 几何与自然梯度

2.5.1 KL 展开和可辨识子空间

固定状态测度 d，设策略族严格正、三次连续可微。定义 score 与 Fisher：

$$u_\theta(s,a) = \nabla_\theta \log \pi_\theta(a \mid s), \qquad F_d(\theta) = \mathbb{E}_{d,\pi_\theta}[u_\theta u_\theta^\top].$$

概率归一化求导给出 $\mathbb{E}_{\pi_\theta} u_\theta = 0$，再求导得

$$\mathbb{E}_{\pi_\theta} \nabla^2 \log \pi_\theta = -\mathbb{E}_{\pi_\theta}[u_\theta u_\theta^\top].$$

展开新策略 log-prob，旧到新 KL 为

$$\begin{aligned} \mathbb{E}_d \mathrm{KL}(\pi_\theta \| \pi_{\theta+\delta}) &= -\mathbb{E}_{d,\pi_\theta}[u_\theta^\top \delta + \tfrac{1}{2}\delta^\top \nabla^2 \log \pi_\theta \, \delta] + O(\|\delta\|^3) \\ &= \tfrac{1}{2}\delta^\top F_d(\theta)\delta + O(\|\delta\|^3). \end{aligned}$$

新到旧 KL 有相同二阶项，但高阶项一般不同。若还改变状态测度，就需要分析额外的测度变化。

Fisher 的核表示当前覆盖测度下没有一阶概率变化的参数方向。在去掉这些方向的商空间求解，或使用广义逆 $F^\dagger$。必须要求 $g \in \mathrm{range}(F)$；否则梯度有非零零空间分量，仅用 Fisher 半径不能限制该分量，线性目标会无界。

命题 2.4 (Fisher 信赖域的解)

设 F 半正定，$0 \neq g \in \mathrm{range}(F)$。在商空间最大化 $g^\top \delta$ 且约束 $\delta^\top F \delta/2 \le \varepsilon$，解为

$$\delta^* = \sqrt{\frac{2\varepsilon}{g^\top F^\dagger g}} F^\dagger g.$$

惩罚问题 $\max_\delta\{g^\top\delta - \delta^\top F\delta/(2\eta)\}$ 的最小范数解为 $\eta F^\dagger g$。

证明 在正特征值子空间令 $w = F^{1/2}\delta$、$v = F^{\dagger/2}g$。目标等于 $v^\top w$，约束变成 $\|w\|^2 \le 2\varepsilon$。Cauchy–Schwarz 的上界在 $w = \sqrt{2\varepsilon}v/\|v\|$ 取得，逆变换得第一式。惩罚问题的一阶条件为 $g - F\delta/\eta = 0$，给出第二式。最小范数选择把零空间分量设为零。

这连接 Amari 的信息几何、Kakade 的自然策略梯度和 TRPO 的局部信赖域更新：步长按分布变化度量。阻尼、采样 Fisher 和线性求解残差会改变实际距离，需要检查真实 KL。[5, 30, 65]

2.5.2 Softmax gauge 下的有限步精确恒等式

令独立 logits $z \in \mathbb{R}^{|\mathcal{A}|}$，$p = \mathrm{softmax}(z)$。Jacobian 与 logits Fisher 都为

$$C(p) = \mathrm{diag}(p) - pp^\top.$$

因 $\mathrm{softmax}(z + c\mathbf{1}) = \mathrm{softmax}(z)$，有 $C(p)\mathbf{1} = 0$。严格正 p 下其核恰为 $\mathrm{span}\{\mathbf{1}\}$。这称为 logits 的 gauge 自由度。

冻结信号向量 f，设 $J(z) = p^\top f$，则 $\nabla_z J = C(p)f$。自然梯度为

$$C(p)^\dagger \nabla_z J = C(p)^\dagger C(p) f = f - \frac{\mathbf{1}^\top f}{|\mathcal{A}|}\mathbf{1}.$$

显式自然梯度 logits 步因此给出

$$p^+ = \mathrm{softmax}(z + \eta f), \qquad p^+(a) = \frac{p(a)e^{\eta f(a)}}{\sum_b p(b)e^{\eta f(b)}}.$$

这是有限 η 的精确 Gibbs mirror map，常数 gauge 自动消失。因此“一切自然梯度都只与小步镜像下降等价”的表述过强；独立 tabular softmax 对冻结线性信号存在这个有限步恒等式。

该恒等式针对 anchor 处冻结线性目标的一次更新，不意味着固定 KL 正则子问题上的任意自然梯度算法一步收敛。共享参数网络的 logits 无法逐状态独立移动，参数 Fisher 只能把方向投影到模型切空间。

2.5.3 一般参数化的局部近端模型

设 logits Jacobian 为 $J_k(s)$，$\Delta = \theta - \theta_k$，固定测度 d_k 下

$$F_k = \mathbb{E}_{d_k}[J_k(s)^\top C(\pi_k(\cdot \mid s))J_k(s)], \qquad b_k = \nabla_\theta \mathbb{E}_{d_k,\pi_\theta} f_k\big|_{\theta_k}.$$

信号目标保留一阶、KL 保留二阶，得到局部模型

$$\max_\Delta\{b_k^\top\Delta - \Delta^\top F_k\Delta/(2\eta)\}.$$

其解 $\eta F_k^\dagger b_k$ 是一般参数族中 mirror 更新的局部表示。真实信号目标也有 Hessian：在 $\Delta = O(\eta)$ 且导数有界时，其影响为更高阶；固定较大 η 时不能删除该项后把二次模型当作全局目标。

分布 target 是否可表示、inner 优化器如何求解、局部曲率是否稳定，是三个独立条件。普通 SGD 和 Adam 不直接计算 Fisher 逆；MDPO 多步优化的 endpoint 能逼近镜像子问题，并不说明每个 optimizer step 都是自然梯度。后续分析将二次模型的谱收缩与真实概率残差分开。

2.6 文献谱系与 OPD 的接口

Beck–Teboulle提供 Bregman prox 和三点估计；信息几何与自然策略梯度提供 KL 的局部 Fisher 度量；TRPO 用半径约束实现局部信赖域；MDPO 用固定旧策略的多步优化逼近镜像子问题；PMD 全局理论利用 Bellman 结构。它们按数学对象连接，不能简化成同一个优化器名称。[5, 7, 30, 32, 65, 71, 77]

一般参数化 PMD 研究可表示性条件，homotopic PMD 调整正则强度，lookahead、block PMD 与 learned mirror maps 改变更新位置或势函数，随机镜像下降及 Bregman Gradient Policy Optimization 研究随机估计和非凸驻点。Bregman Gradient Policy Optimization 的作者为 Huang、Gao 与 Huang；其参数化驻点保证与 tabular PMD 的最优策略保证属于不同对象。GPOMDP 属于策略梯度估计器谱系，也不能直接据其名称归为自然梯度算法。

REPS、Maximum a Posteriori Policy Optimisation（MPO）和 Guided Policy Search 的共同接口是先构造指数倾斜分布，再投影到参数策略。这里的 MPO 指策略优化方法，偏好混合后处理中的同名缩写属于另一工作。它们启发把镜像温度和学生 Fisher 半径分开，分别控制 target 偏离 anchor 与学生追赶 target 的实际步长。[3]

本章提供三个可直接使用的接口：Gibbs 恒等式确定目标及精确目标差；三点不等式确定固定 anchor 的近端几何；Fisher 公式确定参数空间的局部求解方向。下一章把教师 log-ratio 代入这些接口，建立 OPD 特有的精确收缩。环境回报、访问覆盖与 off-policy 方差还需要各自的信号和测度条件。

第三章 OPD 的目标、残差与访问测度

3.1 固定 prefix 的镜像问题

令 ν 为固定 prefix 测度，b 为行为策略，T 为教师。在有限词表上假设 $b(a \mid s), T(a \mid s) > 0$，定义停止梯度的信号

$$r_b(s,a) = \log T(a \mid s) - \log b(a \mid s), \qquad \Psi_{b,\eta}(p;s) = \langle p, r_b \rangle - \eta^{-1} \mathrm{KL}(p \| b).$$

镜像温度为 $\tau = 1/\eta$；参数 optimizer learning rate 另记为 γ。

定理 3.1 (变分恒等式与唯一目标)

设 $\eta > 0$，并定义

$$G_\eta(b)(a \mid s) = \frac{b(a \mid s)^{1-\eta} T(a \mid s)^\eta}{Z_b(s,\eta)}, \quad Z_b(s,\eta) = \sum_a b(a \mid s)^{1-\eta} T(a \mid s)^\eta.$$

则

$$\Psi_{b,\eta}(p;s) = \eta^{-1} \log Z_b(s,\eta) - \eta^{-1} \mathrm{KL}(p \| G_\eta(b)).$$

唯一最优解为 $G_\eta(b)$。 ♡

证明 逐项取对数得 $\log G_\eta(b) = \log b + \eta r_b - \log Z_b$。因此

$$\begin{aligned} \mathrm{KL}(p \| G_\eta(b)) &= \sum_a p(a)[\log p(a) - \log b(a) - \eta r_b(a) + \log Z_b] \\ &= \mathrm{KL}(p \| b) - \eta \langle p, r_b \rangle + \log Z_b. \end{aligned}$$

移项得到恒等式。由 $-\log u \geq 1 - u$，取 $u = G_\eta(b)(a)/p(a)$ 并对 p 求和，得到 KL 非负性。等号要求 $p = G_\eta(b)$。

$\eta = 1$ 时 $\Psi_{b,1}(p) = -\mathrm{KL}(p \| T)$，anchor 项精确抵消。$\eta < 1$ 保留 anchor；$\eta > 1$ 在 log-prob 坐标外推。$b(a) = 0$ 时 KL 近端禁止 $p(a) > 0$；$T(a) = 0$ 时信号负无穷。这两类 support 问题需要单独处理，不能由无限 inner budget 消除。

3.2 中心化残差的零点

定义

$$h_b = r_b - \mathbb{E}_b r_b = r_b + \mathrm{KL}(b \| T), \qquad \delta_p = \eta h_b - \log(p/b) - \mathrm{KL}(b \| p).$$

因为 $\mathbb{E}_b \log(p/b) = -\mathrm{KL}(b \| p)$，所以 $\mathbb{E}_b \delta_p = 0$。回归目标为

$$L_{\mathrm{res}}(p) = \mathbb{E}_{s \sim \nu, a \sim b}[\delta_p(s,a)^2].$$

定理 3.2 (残差与镜像目标的等价零点)

若所有受训 prefix 上 b 为正且策略族可表示 $G_\eta(b)$，$L_{\mathrm{res}} = 0$ 当且仅当 $p = G_\eta(b)$，以 ν-几乎处处为准。 ♡

证明 令 $q = G_\eta(b)$，则

$$\log(q/b) = \eta r_b - \log Z_b, \qquad \mathrm{KL}(b \| q) = -\eta \mathbb{E}_b r_b + \log Z_b.$$

代入得

$$\delta_q = \eta(r_b - \mathbb{E}_b r_b) - (\eta r_b - \log Z_b) - (-\eta \mathbb{E}_b r_b + \log Z_b) = 0.$$

反向，非负平方的积分为零意味着 $\delta_p = 0$。于是 $\log(p/b) = \eta h_b - c(s)$，其中 $c(s) = \mathrm{KL}(b \| p)$。指数化并归一化，得到 $p \propto b e^{\eta h_b} = b e^{\eta r_b}$。

同一零点不意味着同一投影。有限策略族中，reverse KL、forward KL的加权最大似然、平方 log-ratio 残差会产生不同最优参数；非凸驻点也不能由零点定理排除。PMD-mean 用行为均值替代配分函数的具体损失，会引入隐式正则化和 Lambert-W 驻点结构，不能概括为“所有中心化目标都与 exact PMD 同解”。BPO 的 Bellman 残差还要保留未来价值与终局信号。

3.3 序列级与逐状态级镜像

序列级镜像把整个响应 y 当成动作：

$$P^+(y \mid x) = B(y \mid x)e^{\eta R(x,y)}/Z(x).$$

在确定性自回归树上，定义 continuation partition function

$$Z(s) = \mathbb{E}_{y_{\geq t}\sim B(\cdot|s)}[e^{\eta R(x,y)}], \quad Z(s_{\text{terminal}}) = e^{\eta R(x,y)}.$$

条件期望给出 $Z(s) = \sum_a b(a \mid s)Z(sa)$。故

$$p^+(a \mid s) = b(a \mid s)\frac{Z(sa)}{Z(s)}.$$

其概率和为一，且沿序列相乘得到

$$\prod_t \frac{p^+(a_t \mid s_t)}{b(a_t \mid s_t)} = \prod_t \frac{Z(s_{t+1})}{Z(s_t)} = \frac{e^{\eta R(x,y)}}{Z(x)}.$$

这里包含后缀软价值。直接在每个 prefix 用即时 $\log T - \log b$ 做几何插值一般不同于序列几何插值；即使 $R = \log(T(y)/B(y))$，后者的条件策略仍含 continuation normalization。逐状态 PMD 用真实 $A^b(s,a)$ 时具有政策改进语义；teacher log-ratio 没有自动成为环境优势。

3.4 历史、动作与未来比率

令 d_t^π 为第 t 步的 prefix 分布，$d^\pi = \sum_t d_t^\pi$ 为未归一化 occupancy，$\ell_\pi = \mathbb{E}_\pi|y|$ 为其总质量。对当前 integrand $f(s_t,a_t)$，目标密度为 $d_t^\pi(s)\pi(a \mid s)$。行为数据为 $d_t^b(s)b(a \mid s)$ 时需要

$$\Omega_t(s)\rho_t(s,a) = \frac{d_t^\pi(s)}{d_t^b(s)}\frac{\pi(a \mid s)}{b(a \mid s)}.$$

自回归树历史唯一时 $\Omega_t = \prod_{i<t}\rho_i$。完整词表 expectation 已经消除 action Monte Carlo，不再需要 action ratio。平方残差的目标本来在固定 (ν, b) 下，故不需要 student sequence IS，但它不自动成为当前 on-policy sequence objective 的无偏估计。

定理 3.3 (历史校正的条件方差优势)

假设所有比率存在且平方可积，$W = \prod_{i=1}^H \rho_i$，$W_{\leq t} = \prod_{i\leq t}\rho_i$，$f_t$ 对 (s_t,a_t) 可测，则

$$\mathbb{E}_b[Wf_t \mid s_t,a_t] = W_{\leq t}f_t, \qquad \mathrm{Var}_b(W_{\leq t}f_t) \leq \mathrm{Var}_b(Wf_t).$$

♡

证明 目标与行为使用相同环境转移。给定历史与当前动作，未来比率对行为后缀积分为一，因为目标后缀概率归一化；$W_{\leq t}$ 在自回归树上对当前历史可测。所以第一式成立。总方差公式

$$\mathrm{Var}(X) = \mathrm{Var}(\mathbb{E}[X \mid \mathcal{G}]) + \mathbb{E}\,\mathrm{Var}(X \mid \mathcal{G})$$

取 $X = Wf_t$ 和 $\mathcal{G} = \sigma(s_t,a_t)$ 即得第二式。

因此完整无偏 suffix ratio 并不会必然改变纯 prefix integrand 的期望，但会加入不必要的条件方差。重复校正、截断或改变停止梯度语义才会引入额外偏差。短窗口 IS 是偏差与方差折中，不能用“无序列 IS”来宣称零偏差。若 $|\log\rho_i| \leq B$，则 W 最坏可达 e^{HB}，而 $\log W = \sum_i \log\rho_i$ 的幅度至多 HB；这解释了残差回归的数值优势，但仍须控制 score 与样本二阶矩。

3.5 覆盖反例与一步 teacher 投影

考虑两步树，第一步为 L, R，训练数据只包含 L 分支。受训 prefix 的 teacher KL 可以降为零，而 R 分支条件策略任意。当第一步更新令 R 更常被访问，第二轮 rollout 才暴露旧 batch 未约束的误差。所以 $\eta = 1$ 只在完整覆盖、可实现性、正确 logits 和全局 inner 求解同时成立时，才能推出全局 $\pi = T$。有限参数情况下正确极限是

$$\theta^\star \in \arg\min_\theta \mathbb{E}_{s\sim\nu}\, \mathrm{KL}(\pi_\theta(\cdot \mid s) \| T(\cdot \mid s)).$$

重新 rollout 更新的是访问测度，并不能用无限次旧 batch 优化代替。

第四章 有限 inner 求解、outer 同步与步长

4.1 以振幅定义误差

固定 teacher，定义

$$d_{\mathrm{proj}}(p,q)=\operatorname{osc}_a \log\frac{p(a)}{q(a)},\qquad \operatorname{osc}_a u=\max_a u(a)-\min_a u(a).$$

这是严格正概率 simplex 上的 Hilbert projective 距离。加动作无关常数不改变振幅；三角不等式来自 $\operatorname{osc}(u+v)\le \operatorname{osc} u+\operatorname{osc} v$。若 $\operatorname{osc}\log(p/q)=0$，则 $p=cq$，归一化要求 $c=1$。采用这个定义后，inner 误差项前面没有额外系数 2。

定理 4.1 (exact outer 与所有步长区间)

固定 $T>0$，令 $p_{k+1}=G_{\eta_k}(p_k)$。则

$$\Delta_{k+1}=|1-\eta_k|\Delta_k,\qquad \Delta_k=d_{\mathrm{proj}}(p_k,T).$$

对常数步长，$0<\eta<1$ 同向收敛，$\eta=1$ 一步投影，$1<\eta<2$ 差分交替收敛，$\eta=2$ 振幅不变。$\eta>2$ 且 $p_0\neq T$ 时振幅发散。

证明 由 Gibbs 公式，

$$\log\frac{p_{k+1}(a)}{T(a)}=(1-\eta_k)\log\frac{p_k(a)}{T(a)}-\log Z_k.$$

对任意动作对相减，$\log Z_k$ 消失。对实数 c，$\operatorname{osc}(cu)=|c|\operatorname{osc} u$，代入即得恒等式。$\Delta_k\to 0$ 推出 $p_k\to T$：令 $u_a=p_k(a)/T(a)$，归一化 $\sum_a T(a)u_a=1$ 要求 $\min u\le 1\le\max u$，故 $|\log u_a|\le\Delta_k$，每个坐标收敛。

4.2 提前同步后重新 rollout

第 k 轮 exact target 为 $q_{k+1}=G_{\eta_k}(p_k)$，实际 student 为 p_{k+1}，误差定义为

$$\varepsilon_k=d_{\mathrm{proj}}(p_{k+1},q_{k+1}).$$

下一轮保存的是实际 p_{k+1}，信号为 $\log T-\log p_{k+1}$，目标为 $G_{\eta_{k+1}}(p_{k+1})$，不会继续优化旧 target。

定理 4.2 (非精确 outer 的误差传播)

若 $0<\eta_k\le 1$，则

$$\Delta_K\le P_{0,K}\Delta_0+\sum_{j=0}^{K-1}P_{j+1,K}\varepsilon_j,\qquad P_{i,K}=\prod_{\ell=i}^{K-1}(1-\eta_\ell).$$

常数 η 且 $\varepsilon_k\le\bar\varepsilon$ 时 $\limsup_K\Delta_K\le\bar\varepsilon/\eta$。常数 $\eta>0$ 且 $\varepsilon_k\to 0$ 时 $\Delta_K\to 0$。

证明 由三角不等式，

$$\Delta_{k+1}\le d_{\mathrm{proj}}(p_{k+1},q_{k+1})+d_{\mathrm{proj}}(q_{k+1},T)=\varepsilon_k+(1-\eta_k)\Delta_k.$$

代入前一轮，再逐轮展开，得到乘积加权式。常数步长下几何级数和为 $\sum_{j=0}^{K-1}(1-\eta)^j=[1-(1-\eta)^K]/\eta$。证明误差趋零时，任取 $a>0$，选择 N 使 $j\ge N$ 时 $\varepsilon_j\le a\eta$。有限个 $j<N$ 的项随 K 衰减为零，剩余尾和至多为 a；令 $a\downarrow 0$ 完成证明。

第一轮没收敛的影响是 $P_{1,K}\varepsilon_0$，会被后续正确更新逐渐遗忘。新 rollout 噪声与未访问 prefix 的误差仍进入新的 ε_k。该递推需要逐 prefix 的误差控制，不由单个 batch 平均 loss 自动推出。

4.3 固定 anchor 的参数局部模型

令 logits Jacobian 为 $J_k(s)$，categorical Fisher 为 $C_k(s) = \mathrm{diag}(p_k) - p_k p_k^\top$，固定训练测度下

$$A_k = \mathbb{E}_s[J_k(s)^\top C_k(s) J_k(s)], \qquad Q_k(\delta) = \frac{1}{2\eta_k}\delta^\top A_k \delta - b_k^\top \delta.$$

这是把 reward 项一阶线性化、KL 项二阶展开后的模型，不是一般真实目标完整 Hessian；真实 reward Hessian 会增加 $O(\|\delta\|^2)$ 项。在可辨识商空间 A_k 的谱位于 $[m_k, L_k]$，最优位移为 $\delta_k^\star = \eta_k A_k^{-1} b_k$。

定理 4.3 (局部 GD 与 Natural-GD 的 inner 精度)

普通 GD 使用 $0 < \gamma < 2\eta_k/L_k$，则

$$\|e_M\|_{A_k} \le q_k^M \|e_0\|_{A_k}, \qquad q_k = \max_{\lambda \in [m_k, L_k]} |1 - \gamma\lambda/\eta_k|.$$

最优常数步长为 $2\eta_k/(m_k + L_k)$，对应 $q_k = (L_k - m_k)/(L_k + m_k)$。预条件步 $\delta_{m+1} = \delta_m - \gamma A_k^{-1}\nabla Q_k(\delta_m)$ 满足 $e_{m+1} = (1 - \gamma/\eta_k)e_m$，$\gamma = \eta_k$ 时一步解模型。

证明 最优性给出 $A_k\delta_k^\star = \eta_k b_k$，故

$$e_{m+1} = (I - \gamma A_k/\eta_k)e_m.$$

用正交矩阵对角化 $A_k = U\Lambda U^\top$，

$$\|e_{m+1}\|_{A_k}^2 = \sum_i \lambda_i (1 - \gamma\lambda_i/\eta_k)^2 (U^\top e_m)_i^2 \le q_k^2 \|e_m\|_{A_k}^2.$$

递推得到第一式。端点绝对乘子相等时最坏谱半径最小，解 $1 - \gamma m_k/\eta_k = -(1 - \gamma L_k/\eta_k)$ 得最优步长。预条件时直接消去 A_k，得到标量乘子。

病态 Fisher 增加 inner 数量。实际 Natural-GD 用 damping 或采样 Fisher，需分析 $P^{1/2}A_k P^{1/2}$ 的谱；伪逆只在 b_k 位于像空间且去掉 gauge 后有效。

若在局部邻域有 $d_{\mathrm{proj}}(\pi_\theta, \pi_{\theta'}) \le C_k\|\theta - \theta'\|_{A_k}$，才可将参数 inner 误差转为

$$\varepsilon_k \le C_k q_k^{M_k} \|\delta_k^\star\|_{A_k} + C_{\mathrm{nl}}\|\delta_k^\star\|^2 + \varepsilon_k^{\mathrm{sampling}} + \varepsilon_k^{\mathrm{representation}}.$$

增大 M_k 只能减少第一项。$\eta = 1$ 时 target 始终是 teacher，有限 inner 多轮收敛来自求解器收缩，重新 rollout 负责修正覆盖。

4.4 Hard、delayed 与逐步同步

Hard sync在 batch 边界复制 student，并冻结 r_k, T, p_k 直到 inner 结束，这是主算法。停止条件应控制到本轮 target 的误差。若要求 $\varepsilon_k \le c\eta_k^2$，常数步长稳态偏差为 $O(\eta_k)$；若只要求 $\varepsilon_k \le c\eta_k$，稳态上界为 $O(1)$。因此更小步长不自动提高精度。

Delayed sync 保持旧 anchor $\bar{p}$ 跨多批次。固定 teacher 时有精确 target 比较

$$d_{\mathrm{proj}}(G_\eta(p), G_\eta(\bar{p})) = |1 - \eta|\, d_{\mathrm{proj}}(p, \bar{p}).$$

这量只度量 target drift；rollout distribution mismatch 还需另算。若每个 optimizer step 都同步，旧 KL 在初始化点的一阶梯度反复为零。将这些更新解释成固定子问题的 inner solve 会破坏定理假设；若每步都解新的 exact 微小 mirror step，则是另一个有更多 outer 的算法。

4.5 KL budget 与可变步长

令 $r = \log(T/b)$，$A(\eta) = \log \mathbb{E}_b e^{\eta r}$，则 $A' = \mathbb{E}_{G_\eta(b)} r$、$A'' = \mathrm{Var}_{G_\eta(b)}\, r$。

定理 4.4 (镜像路径 KL 的单调性)

$$D(\eta) = \mathrm{KL}(G_\eta(b)\|b) = \eta A'(\eta) - A(\eta), \qquad D'(\eta) = \eta A''(\eta) \geq 0.$$

若 $b \neq T$，有限共同 support 下 D 在 $\eta > 0$ 严格递增。

♡

证明 归一化权重对 η 求导为 $\partial_\eta p_\eta(a) = p_\eta(a)[r(a) - \mathbb{E}_{p_\eta} r]$，所以 $A'' = \mathbb{E}r^2 - (\mathbb{E}r)^2$。代入 KL 表达式求导，$A'$ 相消。$b \neq T$ 时 r 非常数，正权重方差严格为正。

预算 $\delta \in (0, \mathrm{KL}(T\|b))$ 在 $(0,1)$ 唯一可解；预算大于该端点时应取 $\eta = 1$，不能声称区间内总有解。对固定 prefix，Taylor 展开

$$D(\eta) = \frac{\eta^2}{2}\mathrm{Var}_b(r) + O(\eta^3), \qquad \eta \simeq \sqrt{\frac{2\delta}{\widehat{\mathrm{Var}}_b(r) + \epsilon_{\mathrm{var}}}}.$$

全局共享 η 可用 ν 平均 KL 或高分位预算，但二者保障不同。对 sampled actions，需要置信余量；单个经验方差不能排除未采样的尖锐动作。

推论 4.1 (递减步长与 vanishing relative error)

若 $0 < \eta_k < 1$、$\sum_k \eta_k = \infty$ 且 $\varepsilon_k/\eta_k \to 0$，则 $\Delta_k \to 0$。

♡

证明 乘积满足 $P_{N,K} \leq e^{-\sum_{k=N}^{K-1}\eta_k} \to 0$。任给 $a > 0$，选 N 使 $\varepsilon_k \leq a\eta_k$（$k \geq N$）。递推为 $\Delta_{k+1} - a \leq (1-\eta_k)(\Delta_k - a)$，所以 $\limsup \Delta_k \leq a$。令 $a \downarrow 0$。

仅要求 $\varepsilon_k \to 0$ 对递减 η_k 不够；如 $\varepsilon_k = c\eta_k$ 会留下半径 c。固定小步长达到 ϵ 的 outer 数量约为 $\eta^{-1}\log(\Delta_0/\epsilon)$，应连同 rollout 成本和 inner 残差共同比较。

第五章 EMA 锚点与 OPD 的联合动力学

5.1 两个策略状态、三种时钟

hard sync在 outer 边界把训练后的 actor 完整复制为下一轮 reference。指数移动平均（exponential moving average，EMA）保存一个独立的参数状态，因此 actor、rollout policy 和 KL anchor 必须分别记号。设 actor 参数为 θ_t，EMA 参数为 ϕ_t，固定 teacher 为 T，并写

$$p_t = \pi_{\theta_t}, \qquad q_t = \pi_{\phi_t}, \qquad \delta_t = \theta_t - \phi_t.$$

rollout policy 是 batch 开始时保存的 actor 副本 π_{old}。它用于采样和重要性比率；q_t 用于 KL 正则化。二者具有不同的更新时钟。

本章保留 actor 学习率 $\alpha > 0$，额外 EMA–KL 系数 $\beta \geq 0$，EMA 保留系数 $h = \eta_{\text{ema}} \in [0, 1)$，MirrorOPD 步长 $\eta = \eta_{\text{opd}} \in (0, 1]$。$h$ 是旧 anchor 的保留比例，$1 - h$ 是新 actor 的混入比例。T_{ema} 表示两次 anchor 更新之间的 rollout iteration 数；每个 iteration 的 inner update 数记为 Λ。

5.1.1 原论文的理论时序与实现时序

EMA Policy Gradient论文的局部动力学使用更新前 actor：[78]

$$\theta_{t+1} = \theta_t + \alpha \left[g_t - \beta \nabla_\theta \, \mathrm{KL}(\pi_\theta \| \pi_{\phi_t}) \big|_{\theta_t} \right], \tag{5.1}$$

$$\phi_{t+1} = h\phi_t + (1 - h)\theta_t. \tag{5.2}$$

这里 t 是 actor step 的时钟。推导滞后递推时必须保留 θ_t，否则稳定矩阵会改变。

论文算法框先采样 rollout，再执行 Λ 次 actor 更新，在 $t \bmod T_{\text{ema}} = 0$ 时用已经更新后的 actor 做一次 EMA。这里 t 是 rollout iteration 的时钟。若每轮 Λ 固定，两个 EMA 事件之间共有 $N = T_{\text{ema}}\Lambda$ 次 actor 更新。算法框与单步理论方程的差别包括同步时机和同步频率，后文分别推导。

5.1.2 替换 reference 与新增 KL

将 MirrorOPD reference 替换为 q，定义固定 anchor 的奖励与基础目标

$$r_q(a) = \log T(a) - \log q(a), \tag{5.3}$$

$$\Psi_q(p) = \mathbb{E}_{a \sim p}[r_q(a)] - \eta^{-1} \, \mathrm{KL}(p \| q). \tag{5.4}$$

只做这种替换时，最优策略是 $G_\eta(q)$。若在基础目标之外新增 $-\beta \, \mathrm{KL}(p \| q)$，总目标变为

$$\Psi_{q,\beta}(p) = \mathbb{E}_p[r_q] - c \, \mathrm{KL}(p \| q), \qquad c = \eta^{-1} + \beta. \tag{5.5}$$

新增 KL 改变总目标的最优解，不能解释为仅减缓有限 inner steps，却保持 exact target 不变。

定理 5.1 (额外同 anchor KL 的 exact target)

在有限动作集上假设 $q(a) > 0$、$T(a) > 0$。令

$$\gamma = \frac{1}{c} = \frac{\eta}{1 + \beta\eta}.$$

目标(5.5)的唯一最优解与最优性缺口为

$$p^*_{q,\beta}(a) = \frac{q(a)^{1-\gamma}T(a)^{\gamma}}{Z_\gamma(q)} = G_\gamma(q)(a), \tag{5.6}$$

$$Z_\gamma(q) = \sum_b q(b)^{1-\gamma}T(b)^{\gamma}, \tag{5.7}$$

$$\Psi_{q,\beta}(p^*_{q,\beta}) - \Psi_{q,\beta}(p) = c\,\mathrm{KL}(p\|p^*_{q,\beta}). \tag{5.8}$$

♡

证明 将 $\log p^* = (1-\gamma)\log q + \gamma \log T - \log Z_\gamma$ 代入 KL：

$$\begin{aligned}
-c\,\mathrm{KL}(p\|p^*) &= -c\sum_a p(a)\log p(a) + c(1-\gamma)\sum_a p(a)\log q(a) \\
&\quad + c\gamma\sum_a p(a)\log T(a) - c\log Z_\gamma \\
&= -c\sum_a p(a)\log p(a) + (c-1)\sum_a p(a)\log q(a) \\
&\quad + \sum_a p(a)\log T(a) - c\log Z_\gamma \\
&= \Psi_{q,\beta}(p) - c\log Z_\gamma.
\end{aligned}$$

所以 $\Psi_{q,\beta}(p) = c\log Z_\gamma - c\,\mathrm{KL}(p\|p^*)$。KL 非负且仅在 $p = p^*$ 时为零，给出唯一最优解及缺口公式。

当 $\eta = 1$、$\beta = 0$ 时，fixed-anchor exact target 是 T。当 $\eta = 1$、$\beta > 0$ 时，$\gamma = 1/(1+\beta) < 1$，target 是 q 与 T 的几何插值。

如果 MirrorOPD reference 为 q，新增 EMA–KL 指向另一个 anchor u，总目标为

$$\mathbb{E}_p \log(T/q) - \eta^{-1}\,\mathrm{KL}(p\|q) - \beta\,\mathrm{KL}(p\|u).$$

按同样的展开，其 exact target 为

$$p^*(a) \;\propto\; T(a)^{1/c} q(a)^{(\eta^{-1}-1)/c} u(a)^{\beta/c}.$$

两个 anchor 的区分直接进入 target。若新增项使用 forward KL $\mathrm{KL}(u\|p)$，导数包含 $-u(a)/p(a)$，上述几何闭式解不再适用。

5.2 准稳态滞后定理及其边界

5.2.1 Fisher 近似

设策略族在当前邻域三阶可微，固定状态测度下的 Fisher 矩阵为

$$F_\theta = \mathbb{E}_s \mathbb{E}_{a\sim\pi_\theta(\cdot|s)}[\nabla_\theta \log \pi_\theta(a \mid s) \nabla_\theta \log \pi_\theta(a \mid s)^\top].$$

固定 ϕ 求导的局部展开是

$$\mathrm{KL}(\pi_\theta\|\pi_\phi) = \tfrac{1}{2}(\theta-\phi)^\top F(\theta-\phi) + O(\|\theta-\phi\|^3), \tag{5.9}$$

$$\nabla_\theta\,\mathrm{KL}(\pi_\theta\|\pi_\phi) = F(\theta-\phi) + O(\|\theta-\phi\|^2). \tag{5.10}$$

下面的线性递推是冻结 Fisher 后局部模型的精确结论。非线性策略只有在轨迹留在展开邻域、余项受控时才继承局部结论。

定理 5.2 (更新前 EMA 的滞后递推与准稳态闭式)

在线性模型(5.1)–(5.2)中，

$$\delta_{t+1} = (hI - \alpha\beta F_t)\delta_t + \alpha g_t.$$

如果窗口内 $F_t = F$、$g_t = g$，定义

$$D = hI - \alpha\beta F, \qquad S_k = \sum_{j=0}^{k-1} D^j, \qquad U_k = \sum_{j=0}^{k-1} S_j.$$

则

$$\delta_{t+k} = D^k \delta_t + \alpha S_k g, \tag{5.11}$$

$$\theta_{t+k} = \theta_t - \alpha\beta F S_k \delta_t + (\alpha k I - \alpha^2 \beta F U_k) g. \tag{5.12}$$

由于 $I - D = (1-h)I + \alpha\beta F \succ 0$，还成立

$$S_k = (I - D^k)(I - D)^{-1}, \qquad U_k = (kI - S_k)(I - D)^{-1}.$$

♡

证明 用 actor 更新减去 anchor 更新：

$$\begin{aligned}\delta_{t+1} &= \theta_t + \alpha g_t - \alpha\beta F_t \delta_t - h\phi_t - (1-h)\theta_t \\ &= h\delta_t - \alpha\beta F_t \delta_t + \alpha g_t.\end{aligned}$$

冻结系数后展开 k 次，得到 $D^k\delta_t + \alpha\sum_{j=0}^{k-1} D^j g$。再将 actor 增量求和：

$$\begin{aligned}\theta_{t+k} - \theta_t &= \sum_{j=0}^{k-1} (\alpha g - \alpha\beta F \delta_{t+j}) \\ &= \alpha k g - \alpha\beta F \sum_{j=0}^{k-1} (D^j \delta_t + \alpha S_j g),\end{aligned}$$

给出(5.12)。等比求和恒等式 $(I-D)S_k = I - D^k$ 给出 S_k，再次求和给出

$$U_k = \sum_{j=0}^{k-1} (I - D^j)(I-D)^{-1} = (kI - S_k)(I-D)^{-1}.$$

$F \succeq 0$、$h < 1$ 保证 $I - D \succ 0$，所以逆矩阵存在。

定理 5.3 (滞后稳定性、振荡与稳态速度)

设 $F \succeq 0$，λ_i 为其特征值，$\chi_i = h - \alpha\beta\lambda_i$。则

$$\delta_{t+k}^{(i)} = \chi_i^k \delta_t^{(i)} + \alpha \frac{1 - \chi_i^k}{1 - \chi_i} g^{(i)}.$$

滞后相对于准稳态渐近稳定的充要条件为

$$\alpha\beta\lambda_{\max} < 1 + h.$$

稳定时，滞后极限与 actor 渐近增量是

$$\delta_*^{(i)} = \frac{\alpha g^{(i)}}{1 - h + \alpha\beta\lambda_i}, \tag{5.13}$$

$$\lim_{k\to\infty} (\theta_{t+k+1}^{(i)} - \theta_{t+k}^{(i)}) = \frac{\alpha(1-h)}{1 - h + \alpha\beta\lambda_i} g^{(i)}. \tag{5.14}$$

♡

证明 投影到 F 的正交特征基，得到标量递推 $d_{j+1} = \chi_i d_j + \alpha g^{(i)}$，等比求和给出闭式。瞬态衰减等价于 $|\chi_i| < 1$。因 $\chi_i \le h < 1$，只需 $h - \alpha\beta\lambda_i > -1$；对所有方向取最大特征值得到条件。

当 $0 \le \alpha\beta\lambda_i \le h$ 时，$\chi_i \in [0, 1)$，与稳态的偏差不发生符号翻转。当 $h < \alpha\beta\lambda_i < 1 + h$ 时，$\chi_i \in (-1, 0)$，偏差交替衰减。边界上乘子为 -1，非零瞬态保持幅度；超过边界时幅度增长。边界应称为失去渐近稳定，而非一律指数发散。

稳定时令 $k \to \infty$ 得到 $\delta_*^{(i)}$，代入 actor 的 $\alpha g^{(i)} - \alpha\beta\lambda_i \delta_*^{(i)}$，合并分母得到速度公式。

该定理允许 $\beta = 0$ 和 Fisher 零特征值，此时 $\chi_i = h$，滞后仍然稳定。稳定条件没有额外的严格正下界。固定非零 g 时 actor 仍以非零速度前进，所以 lag 稳定不等价于 actor 收敛，更不等价于到达 teacher。

准稳态公式给出 EMA 减慢更新的准确条件：固定 g 时，$\beta\lambda_i > 0$ 的 actor 方向，其渐近速度乘以

$$\frac{1-h}{1-h+\alpha\beta\lambda_i} < 1.$$

这是固定梯度局部模型的速度比较；梯度噪声、允许步长和曲率随策略改变时，不能据此宣称 EMA 在所有训练预算下都更慢。

5.3 teacher 误差与滞后的联合收敛

5.3.1 固定局部目标

设可表示目标参数为 θ^*，actor误差 $e_t = \theta_t - \theta^*$。若基础上升梯度在目标附近为 $g_t = -Ae_t + \xi_t$，$A \succ 0$，更新前 EMA 联合系统是

$$z_{t+1} = Mz_t + \alpha B\xi_t, \quad z_t = \begin{bmatrix} e_t \\ \delta_t \end{bmatrix}, \quad B = \begin{bmatrix} I \\ I \end{bmatrix}, \quad M = \begin{bmatrix} I - \alpha A & -\alpha\beta F \\ -\alpha A & hI - \alpha\beta F \end{bmatrix}. \tag{5.15}$$

上升梯度的单调性符号为 $\langle g(e), e\rangle \le -m\|e\|^2$；损失下降梯度才使用正号。

定理 5.4 (共同特征模态的精确 Jury 条件)

假设 A, F 对称可交换，$A \succ 0$、$F \succeq 0$。在共同特征方向写

$$a_i = \alpha\lambda_i(A) > 0, \qquad b_i = \alpha\beta\lambda_i(F) \ge 0.$$

系统(5.15)渐近稳定的充要条件是每个方向满足

$$a_i + \frac{2b_i}{1+h} < 2. \tag{5.16}$$

♡

证明 对称可交换矩阵可同时正交对角化，第 i 个方向的矩阵为

$$M_i = \begin{bmatrix} 1-a_i & -b_i \\ -a_i & h-b_i \end{bmatrix}.$$

迹与行列式分别为

$$\tau_i = 1 + h - a_i - b_i, \qquad d_i = (1-a_i)(h-b_i) - a_ib_i = h(1-a_i) - b_i.$$

特征多项式是 $x^2 - \tau_i x + d_i$。实二阶多项式根严格位于单位圆内的 Jury 条件是

$$1 - \tau_i + d_i > 0, \quad 1 + \tau_i + d_i > 0, \quad 1 - d_i > 0.$$

可直接验证这一条件：实根时前两式分别排除穿越 $+1$、-1，并结合 $d_i < 1$ 排除两根同时位于圆外；共轭根时 d_i 是模的平方，第三式控制其模。逐项代入得

$$1 - \tau_i + d_i = a_i(1-h) > 0,$$
$$1 + \tau_i + d_i = 2(1+h) - (1+h)a_i - 2b_i,$$
$$1 - d_i = 1 - h + ha_i + b_i > 0.$$

第一、第三式自动成立；第二式除以 $1+h$ 恰为(5.16)。

当 A, F 不可交换时，应检查完整块矩阵的谱半径，逐模态条件不再是充要条件。仅检查 lag 会漏掉 teacher 误差到 lag 的反馈。例如 $\beta = 0$ 时 lag 条件总成立，actor 仍要求 $0 < \alpha\lambda_i(A) < 2$。

5.3.2 移动 MirrorOPD anchor

固定目标模型与 MirrorOPD 的移动 anchor 不同：$G_\gamma(q_t)$ 随 q_t 移动。在 teacher 附近取可辨识局部坐标，令 $v_t = \phi_t - \theta^*$、$e_t = \theta_t - \theta^*$，冻结共同 Fisher 为 F。利用

$$\mathbb{E}_p \log(T/q) = \mathrm{KL}(p\|q) - \mathrm{KL}(p\|T),$$

实际总目标精确改写为

$$\Psi_{q_t,\beta}(p) = -\,\mathrm{KL}(p\|T) - (c-1)\,\mathrm{KL}(p\|q_t).$$

局部二次展开给出

$$\Psi_{q_t,\beta}(\pi_{\theta_t}) \simeq -\tfrac{1}{2}e_t^\top F e_t - \tfrac{c-1}{2}(e_t - v_t)^\top F(e_t - v_t).$$

因此总梯度为 $-F[e_t + (c-1)\delta_t]$，联合系统为

$$\begin{bmatrix} e_{t+1} \\ \delta_{t+1} \end{bmatrix} = \begin{bmatrix} I - \alpha F & -\alpha(c-1)F \\ -\alpha F & hI - \alpha(c-1)F \end{bmatrix} \begin{bmatrix} e_t \\ \delta_t \end{bmatrix}. \tag{5.17}$$

推论 5.1 (EMA–MirrorOPD 局部 teacher 收敛条件)

在上述二次模型中，若 $F \succ 0$、$\eta \in (0,1]$、$\beta \geq 0$，则(5.17)收敛到 $(e,\delta) = (0,0)$ 的充要条件为

$$0 < \alpha\lambda_i(F) < \frac{2(1+h)}{2c+h-1} \quad \text{对所有} i, \qquad c = \eta^{-1} + \beta.$$

♡

证明 $c - 1 \geq 0$。在定理 5.4 中取 $a_i = \alpha\lambda_i(F)$、$b_i = \alpha(c-1)\lambda_i(F)$，得到

$$\alpha\lambda_i(F)\left(1 + \frac{2(c-1)}{1+h}\right) < 2.$$

括号合并为 $(2c+h-1)/(1+h)$，整理即得。若 F 奇异，结论只作用于正特征值对应的策略变化方向，零特征方向的参数可保持初值。

使用冻结 F^{-1} 的 Natural GD 时，所有正 Fisher 模态的 $\alpha\lambda_i(F)$ 替换为 α，消除局部条件数对步长上界的影响，但保留 c, h 与同步时序的耦合。

5.3.3 非正规矩阵与扰动速率

定理 5.5 (稳定联合系统的扰动界)

设固定矩阵 M 满足 $\rho(M) < 1$，$z_{t+1} = Mz_t + b_t$。对任意 $r \in (\rho(M), 1)$，存在 $C_r < \infty$，使

$$\|z_k\| \leq C_r r^k \|z_0\| + C_r \sum_{j=0}^{k-1} r^{k-1-j}\|b_j\|.$$

若 $\limsup_j \|b_j\| \leq \bar{b}$，则 $\limsup_k \|z_k\| \leq C_r\bar{b}/(1-r)$。

♡

证明 递推展开为 $z_k = M^k z_0 + \sum_{j=0}^{k-1} M^{k-1-j} b_j$。Jordan 分解中，大小为 ℓ 的块产生至多 $k^{\ell-1}|\lambda|^{k-\ell+1}$ 的项。因 $|\lambda| < r$，几何衰减吸收有限次多项式，存在 C_r 使 $\|M^k\| \leq C_r r^k$，三角不等式给出首式。

给定 $\varepsilon > 0$，取 J 使 $j \geq J$ 时 $\|b_j\| \leq \bar{b} + \varepsilon$。有限项 $j < J$ 随 k 衰减为零，其余求和至多 $(\bar{b}+\varepsilon)/(1-r)$。取上极限，再令 $\varepsilon \downarrow 0$ 得到第二式。

一般不能把 r 改成 $\rho(M)$。例如 $M = \begin{bmatrix} \rho & 1 \\ 0 & \rho \end{bmatrix}$，$0 < \rho < 1$ 时，M^k 的右上角为 $k\rho^{k-1}$，不存在固定 C 使所有 k 满足 $\|M^k\| \leq C\rho^k$。可对角化或正规矩阵具有更强的界，但需要列出假设。

若局部目标 ϑ_t 漂移，令 $e_t = \theta_t - \vartheta_t$，额外输入为

$$b_t = \alpha \begin{bmatrix} I \\ I \end{bmatrix} \xi_t + \begin{bmatrix} \vartheta_t - \vartheta_{t+1} \\ 0 \end{bmatrix}.$$

目标漂移只直接进入 e 方程，δ 中的目标平移相消。定理 5.5 分别控制采样误差、有限 inner 求解误差和目标漂移。

5.4 延迟 EMA 的事件级复合算子

5.4.1 固定 anchor 窗口与同步时序

一个 anchor 事件之间 ϕ 固定。先冻结 F, g，令 $L = I - \alpha\beta F$，窗口长度为 N 次 actor 更新，则

$$\delta_j^- = L^j \delta_0 + \alpha \sum_{i=0}^{j-1} L^i g, \qquad \theta_j = \phi + \delta_j^-, \quad 0 \le j \le N.$$

h 在窗口内部没有出现。若末端使用更新后 actor，则

$$\phi^+ = h\phi + (1-h)\theta_N, \tag{5.18}$$

$$\delta^+ = h\delta_N^- = hL^N\delta_0 + h\alpha \sum_{i=0}^{N-1} L^i g. \tag{5.19}$$

若使用最后一次 actor 更新前的参数，则

$$\phi^+ = h\phi + (1-h)\theta_{N-1}, \tag{5.20}$$

$$\delta^+ = \delta_N^- - (1-h)\delta_{N-1}^- = (hI - \alpha\beta F)\delta_{N-1}^- + \alpha g. \tag{5.21}$$

这些公式直接由 $\delta^+ = \theta_N - \phi^+$ 得到。$N = 1$ 时，两种时序分别产生 $h(I - \alpha\beta F)$ 与 $hI - \alpha\beta F$，稳定乘子已经不同。

在论文算法中，$N = T_{\text{ema}}\Lambda$ 仅在每轮 inner 数固定时成立。rollout 刷新改变 g 和状态测度，固定系数闭式应替换为逐步矩阵乘积与输入求和。延迟更新只在事件边界应用一次 h，不能替换为逐 actor step EMA 中的 h^N。

5.4.2 完整 teacher 误差的 block 矩阵

对同一局部 MirrorOPD 总目标，窗口内状态 (e, v) 满足

$$\begin{bmatrix} e_{j+1} \\ v_{j+1} \end{bmatrix} = K \begin{bmatrix} e_j \\ v_j \end{bmatrix}, \qquad K = \begin{bmatrix} I - \alpha c F & \alpha(c-1)F \\ 0 & I \end{bmatrix}.$$

更新后同步矩阵为

$$S = \begin{bmatrix} I & 0 \\ (1-h)I & hI \end{bmatrix}, \qquad M_{\text{block}} = SK^N.$$

因此包含全部参数的事件级判据是 $\rho(SK^{T_{\text{ema}}\Lambda}) < 1$。在共同 Fisher 模态上记

$$\ell_i = 1 - \alpha c \lambda_i, \qquad w_i = \frac{c-1}{c}(1 - \ell_i^N).$$

等比求和给出

$$K_i^N = \begin{bmatrix} \ell_i^N & w_i \\ 0 & 1 \end{bmatrix}, \qquad M_{\text{block},i} = \begin{bmatrix} \ell_i^N & w_i \\ (1-h)\ell_i^N & h + (1-h)w_i \end{bmatrix}.$$

将迹 $\ell_i^N + h + (1-h)w_i$ 与行列式 $h\ell_i^N$ 代入 Jury 三条件即可检查。该条件同时包含 actor 窗口和同步事件；单独的 lag 条件无法替代。

5.5 具有全局定理的几何 soft sync

5.5.1 更新后几何同步

在概率的对数坐标定义几何同步

$$\mathcal{S}_h(q,p)(a) = \frac{q(a)^h p(a)^{1-h}}{\sum_b q(b)^h p(b)^{1-h}}.$$

它对 logits 或 log-probability 作线性插值再归一化。定义

$$d_{\mathrm{proj}}(p,T)=\operatorname{osc}_a \log\frac{p(a)}{T(a)},\qquad \operatorname{osc} f=\max_a f(a)-\min_a f(a).$$

定理 5.6 (exact actor 后几何同步的外层收缩)

在正有限动作分布上执行

$$p_{k+1}=G_\gamma(q_k),\qquad q_{k+1}=\mathcal{S}_h(q_k,p_{k+1}),\qquad \gamma=\frac{\eta}{1+\beta\eta}.$$

则

$$q_{k+1}=G_{(1-h)\gamma}(q_k), \tag{5.22}$$

$$d_{\mathrm{proj}}(q_{k+1},T)=[1-(1-h)\gamma]d_{\mathrm{proj}}(q_k,T), \tag{5.23}$$

$$d_{\mathrm{proj}}(p_{k+1},T)=(1-\gamma)d_{\mathrm{proj}}(q_k,T). \tag{5.24}$$

♡

证明 代入 $p_{k+1}\propto q_k^{1-\gamma}T^\gamma$，归一化常数相消，得到

$$q_{k+1}\propto q_k^h(q_k^{1-\gamma}T^\gamma)^{1-h}=q_k^{1-(1-h)\gamma}T^{(1-h)\gamma}.$$

对任意 $\tau\in[0,1]$，

$$\log\frac{G_\tau(q)(a)}{T(a)}=(1-\tau)\log\frac{q(a)}{T(a)}-\log Z_\tau(q).$$

振幅消去归一化常数，得到 $d_{\mathrm{proj}}(G_\tau(q),T)=(1-\tau)d_{\mathrm{proj}}(q,T)$。分别取 $\tau=(1-h)\gamma$、$\tau=\gamma$ 即得。

hard sync是 $h=0$，anchor 收缩因子为 $1-\gamma$。固定 $\gamma>0$ 时，$h>0$ 严格增大该因子，因此在 exact、同等 outer 预算下 anchor 的确学得更慢。$\gamma=1$ 时 actor 每轮直接等于 teacher，anchor 仍以因子 h 接近 teacher；评价 actor 与评价 anchor 会得到不同答案。

有限 inner solve 的对数误差写成

$$\log p_{k+1}(a)=\log G_\gamma(q_k)(a)+\varepsilon_{k+1}(a)-C_{k+1}.$$

若 $\operatorname{osc}\varepsilon_{k+1}\le e_{k+1}$，代入几何同步并取振幅得到

$$d_{\mathrm{proj}}(q_{k+1},T)\le[1-(1-h)\gamma]d_{\mathrm{proj}}(q_k,T)+(1-h)e_{k+1}.$$

当 $e_k\le\bar e$ 时，等比求和给出距离上极限 $\bar e/\gamma$。soft sync 同时减弱理想推进与求解误差注入，故在此确定性最坏情形界里 h 不改善误差地板。

5.5.2 更新前几何同步的一步延迟

若 $p_{k+1}=G_\gamma(q_k)$，但同步用 p_k，即 $q_{k+1}=\mathcal{S}_h(q_k,p_k)$，选基准动作 a_0 定义

$$x_k(a)=\log\frac{p_k(a)T(a_0)}{p_k(a_0)T(a)},\qquad y_k(a)=\log\frac{q_k(a)T(a_0)}{q_k(a_0)T(a)}.$$

归一化常数消去，每个动作方向满足

$$\begin{bmatrix}x_{k+1}\\ y_{k+1}\end{bmatrix}=\begin{bmatrix}0 & 1-\gamma\\ 1-h & h\end{bmatrix}\begin{bmatrix}x_k\\ y_k\end{bmatrix}.$$

其特征根为

$$r_\pm=\frac{h\pm\sqrt{h^2+4(1-h)(1-\gamma)}}{2}.$$

$0<\gamma\le1$、$h<1$ 时，$r_+<1$ 且 $|r_-|\le r_+$：判别式平方根小于 $2-h$ 恰好等价于 $\gamma>0$。故系统收敛，负根解释一步延迟的交替分量。$h=0,\gamma=1$ 时矩阵平方为零，有限两步归零。此速率区别于更新后同步的 $1-(1-h)\gamma$。

5.5.3 参数 EMA 的非等价性

参数 EMA 是 $\phi^+ = h\phi + (1-h)\theta$。只有固定状态 logits 对参数仿射时，才有

$$\pi_{\phi^+} = \mathcal{S}_h(\pi_\phi, \pi_\theta).$$

神经网络 logits 一般不对所有权重仿射。反例取二分类策略 $\pi_\theta(1) = \mathrm{sigmoid}(\theta^2)$，$\phi = -1$、$\theta = 1$、$h = 1/2$。端点策略相同，几何同步保持它；参数 EMA 给出 $\phi^+ = 0$，概率为 $1/2$，不同于端点的 $\mathrm{sigmoid}(1)$。

若 logits 映射二阶可微且 $\theta - \phi$ 小，Taylor 展开给出

$$z_{h\phi+(1-h)\theta} = hz_\phi + (1-h)z_\theta + O(\|\theta - \phi\|^2).$$

二者在局部一阶对应，精确 projective 定理属于几何同步。二阶偏差可作为扰动控制，不能直接删去。

5.6 Top-k KL 与噪声动力学

5.6.1 无偏尾部校正

EMA-PG在指定 token 集合 A 上精确计算部分 KL，再对尾部采样校正。固定状态、参数与集合，记 $p = \pi_\theta$、$q = \pi_\phi$、采样分布 μ。假设 $p(a) > 0$ 时 $\mu(a) > 0$，reverse KL 值估计为

$$\widehat{K} = \sum_{a\in A} p(a) \log \frac{p(a)}{q(a)} + \mathbf{1}\{Y \notin A\} \frac{p(Y)}{\mu(Y)} \log \frac{p(Y)}{q(Y)}, \quad Y \sim \mu.$$

逐项取期望，得到

$$\mathbb{E}_\mu \widehat{K} = \sum_{a\in A} p(a) \log \frac{p(a)}{q(a)} + \sum_{a\notin A} p(a) \log \frac{p(a)}{q(a)} = \mathrm{KL}(p\|q).$$

梯度还需要正确停止梯度与 score-function 项。真实梯度为

$$\begin{aligned}\nabla_\theta \mathrm{KL}(p\|q) &= \sum_a p(a)\nabla_\theta \log p(a) \left(\log \frac{p(a)}{q(a)} + 1\right) \\ &= \sum_a p(a)\nabla_\theta \log p(a) \log \frac{p(a)}{q(a)},\end{aligned}$$

最后一步使用 score 均值为零。若精确子集直接求 KL 的梯度，其 $+1$ 项须保留在同样拆分的尾部估计中；若子集直接计算上式的 score 求和，则子集与尾部都按去掉 $+1$ 的形式计算。两种一致拆分都无偏，混合两种形式会遗漏子集概率质量的导数。

集合在求导中固定、尾部校正完整、重要性权重不裁剪，是无偏条件。实际裁剪重要性权重或丢弃尾部会引入偏差。仅说明完整词表 K4 无偏，仍不足以证明它与直接自动微分的精确头部拼接后无偏，因为尾部掩码改变了 score 基线的均值。

命题 5.1 (精确 KL 头部与 K4 尾部的梯度偏差)

固定集合 A，精确头部按通常方式自动微分，尾部采用 K4 score 梯度且使用完整未裁剪的重要性校正，则总估计的梯度偏差为

$$\mathbb{E}[\widehat{\nabla K}] - \nabla \mathrm{KL}(p\|q) = \nabla \sum_{a\in A} p(a).$$

因此，论文 reverse Top-k KL 算法框所写的这种拼接，仅在右侧为零或另有基线校正时才满足梯度无偏。♠

证明 记 $s(a) = \nabla \log p(a)$、$l(a) = \log[p(a)/q(a)]$。精确头部梯度为 $\sum_{a\in A} p(a)s(a)[l(a)+1]$，K4 尾部梯度期望为 $\sum_{a\notin A} p(a)s(a)l(a)$。两者相加等于

$$\sum_a p(a)s(a)l(a) + \sum_{a\in A} p(a)s(a) = \nabla \mathrm{KL}(p\|q) + \nabla \sum_{a\in A} p(a).$$

完整词表的 $\sum_a p(a)s(a) = 0$ 不能用在只包含尾部的和式上。

二分类例子取 $p(1)=\mathrm{sigmoid}(\theta)$、$A=\{1\}$，并在某一点令 $q=p$。真实 KL 梯度为零；K4 尾部也为零，而精确头部梯度为 $p(1)[1-p(1)]>0$。这给出与 teacher 差距为零时仍产生梯度的直接反例。

一种同时保持值与梯度无偏的修正是将尾部 surrogate 写成

$$\widehat{K}_{\mathrm{tail}}^{\mathrm{corr}}=\mathbf{1}\{Y\notin A\}\,\mathrm{stopgrad}\left(\frac{p(Y)}{\mu(Y)}\right)[r_Y\,\mathrm{stopgrad}(l(Y)+1)-1],\qquad r_Y=\frac{p(Y)}{\mathrm{stopgrad}(p(Y))}.$$

在前向值上 $r_Y=1$，括号等于 $l(Y)$，所以值保持原来的尾部估计；自动微分梯度是 $s(Y)[l(Y)+1]$ 乘重要性校正，正好补齐精确头部采用的拆分。另一种修正是头部也用停止梯度的 score surrogate，头尾一起去掉 $+1$。两种选择必须与实现逐项核对。

5.6.2 均值递推与均方地板

定理 5.7 (固定线性滞后模型的均方界)

设 $D=hI-\alpha\beta F$，$q_D=\|D\|_2<1$。噪声满足

$$\mathbb{E}[\xi_t\mid\mathcal{F}_t]=0,\qquad\mathbb{E}[\|\xi_t\|^2\mid\mathcal{F}_t]\le\sigma^2.$$

在 $\delta_{t+1}=D\delta_t+\alpha g+\alpha\xi_t$ 中，令 $\delta_*=(I-D)^{-1}\alpha g$，则

$$\mathbb{E}\|\delta_t-\delta_*\|^2\le q_D^{2t}\mathbb{E}\|\delta_0-\delta_*\|^2+\frac{\alpha^2\sigma^2(1-q_D^{2t})}{1-q_D^2}.$$

♡

证明 令 $u_t=\delta_t-\delta_*$，稳态方程给出 $u_{t+1}=Du_t+\alpha\xi_t$。条件交叉项为

$$\mathbb{E}[\langle Du_t,\xi_t\rangle\mid\mathcal{F}_t]=\langle Du_t,\mathbb{E}[\xi_t\mid\mathcal{F}_t]\rangle=0.$$

故 $\mathbb{E}\|u_{t+1}\|^2\le q_D^2\mathbb{E}\|u_t\|^2+\alpha^2\sigma^2$。展开递推、求等比和得到结论。

一般联合矩阵 M 非正规时，使用 C_r、$r>\rho(M)$。输入 $\alpha B\xi_t$、确定初值及鞅差噪声给出

$$\mathbb{E}\|z_t\|^2\le C_r^2r^{2t}\|z_0\|^2+\frac{\alpha^2C_r^2\|B\|^2\sigma^2(1-r^{2t})}{1-r^2}.$$

其证明由线性递推展开、不同时间鞅差交叉项为零以及矩阵幂界组成。无偏 Top-k KL 保持固定线性模型的条件均值递推，改变噪声协方差。非线性系统中方差改变未来状态分布，不能扩张成整条随机训练轨迹的无条件均值完全相同。

5.7 同步与参数设计的理论结论

以 teacher tracking 为核心的 MirrorOPD，hard sync 提供独立的 outer reference 和清楚的 exact mirror 收缩率，应作为基准。引入 anchor 平滑、额外 KL 或参数平均后，需要本章的联合系统及事件算子。

η 决定基础 mirror target；新增 β 将有效步长改为 $\gamma=\eta/(1+\beta\eta)$；$\alpha$ 决定 finite inner 求解速度和离散稳定性；h 决定 anchor 追踪速度；T_{ema} 与 Λ 决定固定 anchor 期间累计的 actor 更新数。这些参数在稳定性上耦合，也不能全部合并为一个有效学习率。

检查应与实现时序一致：逐 actor step 更新前 EMA 使用定理 5.4 或推论 5.1；多个 inner steps 后同步使用 SK^N；logit 几何同步使用定理 5.6。参数 EMA 还需检查局部近似误差、状态测度变化与 teacher 不可表示的影响。

EMA 的 exact anchor 推进比 hard sync 慢，已由精确收缩因子证明。实际价值应通过稳定预算与噪声预算评估：是否允许更大的 α，是否减小训练波动，是否缓解 reference 突变。改善需要额外条件或实验证据；lag 稳定定理本身只说明 actor 与 anchor 的距离如何演化。

第六章 TOP-D、MirrorOPD 与 vanilla OPD

前几章研究了以 KL 为近端项的几何更新。本章研究另一条稳定蒸馏的路径：先在概率空间中构造一个靠近 student 的 teacher，再用冻结行为策略的数据执行多轮内部训练。信任区域策略蒸馏（Trust Region Policy Distillation，TOP-D）[75] 采用这条路径。它与 MirrorOPD 都区分 outer 和 inner，但控制的是不同的数学量。TOP-D 的算术混合控制负向 log-ratio 尾部；MirrorOPD 的 KL 子问题产生几何混合，并控制 projective log-ratio 误差。

本章从真实训练流程确定哪些量固定，再证明 TOP-D 的方差、算子收敛与有限时域性能下界。每个定理同时说明其对象：token 梯度、理想分布算子或固定 reward MDP。最后将这些条件应用到 MirrorOPD 和 vanilla OPD，区分可继承的结论与需要重新证明的结论。

6.1 外部近端 teacher 与内部权重

6.1.1 算术混合及 reward 变换

记固定 teacher 为 T，第 k 个 outer 的行为策略为 π_k。TOP-D 对每个 prefix s 定义

$$U_{k,\alpha}(a \mid s) = (1-\alpha)\pi_k(a \mid s) + \alpha T(a \mid s), \qquad 0 < \alpha < 1. \tag{6.1}$$

该分布已归一化，不需要配分函数。teacher ratio 和蒸馏 reward 为

$$\rho_k = \frac{T(a \mid s)}{\pi_k(a \mid s)}, \qquad \widetilde{r}_{k,\alpha}(s,a) = \log \frac{U_{k,\alpha}(a \mid s)}{\pi_k(a \mid s)} = \log(1 - \alpha + \alpha\rho_k). \tag{6.2}$$

若已有 vanilla log-ratio $r_k = \log \rho_k$，实现只需计算 $\log(1 - \alpha + \alpha e^{r_k})$。可以使用 log-sum-exp 避免指数溢出；不需要额外运行第三个 teacher 网络。

对任意 $\rho \geq 0$，有

$$\log(1 - \alpha + \alpha\rho) \geq \log(1 - \alpha). \tag{6.3}$$

当 teacher 给 student 经常采样的 token 极小概率时，vanilla reward 可以趋于负无穷，而 TOP-D 将惩罚限制在有限下界。正向 reward 仍可任意大，因为 ρ 可以任意大。后面的二阶矩定理利用采样概率对大正向 reward 的衰减作用，不假设 reward 双侧有界。

6.1.2 一轮完整的 TOP-D 训练

原论文 Algorithm 1 的动作顺序是：

1. outer 开始时复制参数，得到冻结行为策略 $\pi_k = \pi_{\theta_{\text{old}}}$，并采样 prompt batch。
2. 对每个 prompt 从 π_k 生成 G 个 response，记录采样 token 的 old-policy log-prob 和 teacher log-prob。
3. 计算式(6.2)的 reward，再计算 return 和组内 token advantage。
4. 在同一批轨迹上执行 E 个内部 epoch。更新 student 参数，保留 old policy、数据、reward、return 和 advantage。
5. 将最终 student 作为 π_{k+1}，进入下一 outer，重新复制行为策略并 rollout。

原文采用即时 reward 加长度归一化的未来 reward。对长度 L_i 的第 i 个 response，

$$\widetilde{R}_t^i = \widetilde{r}_t^i + \frac{1}{L_i - t} \sum_{j=t+1}^{L_i} \widetilde{r}_j^i, \qquad t < L_i. \tag{6.4}$$

终止位置必须定义 $\widetilde{R}_{L_i}^i = \widetilde{r}_{L_i}^i$，避免空和除以零。组内统计量由同一 prompt 的所有有效 response token 计算，得到

$$\widehat{A}_t^i = (\widetilde{R}_t^i - \mu_k)/\sigma_k.$$

实现还需要规定零方差组的回退和分母稳定项。这些选择影响小 α 的极限行为。

内部目标采用 PPO 形式。令

$$w_t^i(\theta) = \frac{\pi_\theta(a_t^i \mid s_t^i)}{\pi_k(a_t^i \mid s_t^i)}, \qquad N_k = \sum_i L_i,$$

则 batch 目标为

$$\widehat{L}_k(\theta) = \frac{1}{N_k} \sum_{i,t} \min\{w_t^i(\theta)\widehat{A}_t^i, \mathrm{clip}(w_t^i(\theta), 1-\epsilon, 1+\epsilon)\widehat{A}_t^i\}. \tag{6.5}$$

这里两种 ratio 必须分开：$\rho_k = T/\pi_k$ 构造 reward，在 batch 内固定；$w(\theta) = \pi_\theta/\pi_k$ 用于内部重要性加权，随参数变化。PPO clip 作用于后者，不是 teacher ratio 的截断。

所以，TOP-D 的外部混合系数 α 是超参数，近端 teacher、reward 与 advantage 在一个 outer 内固定，在下一个 outer 随 π_k 刷新。内部 ratio 和 clipping 状态则在参数更新后改变。固定 α 不等于一直训练第一批数据，也不等于所有权重固定。

6.2 算术混合与几何 mirror 的方向

MirrorOPD的精确 token target 为

$$G_\eta(p)(a) = \frac{p(a)^{1-\eta}T(a)^\eta}{Z(\eta)}, \qquad Z(\eta) = \sum_b p(b)^{1-\eta}T(b)^\eta. \tag{6.6}$$

固定 prefix，TOP-D target 的位移为 $\alpha(T-p)$。几何 target 在零步长处的导数却为

$$\left.\frac{\mathrm{d}G_\eta(p)(a)}{\mathrm{d}\eta}\right|_{\eta=0} = p(a)\left[\log\frac{T(a)}{p(a)} - \mathbb{E}_p \log\frac{T}{p}\right]. \tag{6.7}$$

这两个向量一般不同。单独令 α, η 很小，不足以让它们具有相同一阶方向。

若 teacher 和 student 本身接近，写 $T(a) = p(a)(1+u_a)$，其中 $\sum_a p(a)u_a = 0$。当 $\max_a |u_a|$ 小时，

$$\log(T(a)/p(a)) = u_a - \tfrac{1}{2}u_a^2 + O(u_a^3).$$

代入式(6.7)，导数等于

$$p(a)u_a + O(p(a)\max_b |u_b|^2) = T(a) - p(a) + O(p(a)\max_b |u_b|^2).$$

两种方向只在 teacher/student 分歧也小的条件下局部接近。容量差距大、ratio 尖锐时不能省掉这个条件。

原论文也讨论了 log-prob 插值：未归一化地设置 $\log\widetilde{T} = (1-\alpha)\log p + \alpha \log T$，得到 reward $\alpha\log(T/p)$。正确归一化还需要减去 $\log Z$；该常数在单 prefix 上是 action-independent baseline。缩放后的负尾仍无统一下界。几何更新的价值来自 KL 近端结构与 projective 收缩，不能套用 TOP-D 的负向平滑证明。

6.3 全概率空间的 token 梯度方差界

6.3.1 定理对象与完整证明

对随机向量 g，定义 $\mathrm{Var}(g) = \mathbb{E}\|g - \mathbb{E}g\|_2^2 = \mathrm{tr}\,\mathrm{Cov}(g)$。TOP-D的方差定理针对一个 on-policy token 的原始 score-reward 估计量。累积 return、随机组内标准化、内部 importance ratio 和 PPO 分段梯度没有自动包含在该结论中。

定理 6.1 (TOP-D 原始 token 方差界)

词表 $\mathcal{V}$ 有限。给定 prefix，令 $p(a) = \pi_\theta(a \mid s) > 0$、$q(a) = T(a \mid s) \geq 0$，两者为概率分布。假设相关 prefix、action 和参数上有 $\|\nabla_\theta \log \pi_\theta(a \mid s)\|_2 \leq M$。固定 $0 < \alpha < 1$，从 $a \sim p$ 采样，定义

$$\widetilde{g} = \nabla_\theta \log \pi_\theta(a \mid s)\log(1 - \alpha + \alpha q(a)/p(a)).$$

则任意 prefix 分布下都有

$$\mathrm{Var}(\widetilde{g}) \le M^2|\mathcal{V}|\max\{\log^2(1-\alpha), C^\star\alpha\}. \tag{6.8}$$

其中 $t^\star \in (2, e^2)$ 是 $\log t = 2(1-1/t)$ 在 $t>1$ 的唯一非平凡根，$C^\star = (\log t^\star)^2/(t^\star-1)$。不需要 ratio 上界或统一 support floor。

♡

证明 由方差恒等式，

$$\mathrm{Var}(\widetilde{g}) = \mathbb{E}\|\widetilde{g}\|_2^2 - \|\mathbb{E}\widetilde{g}\|_2^2 \le \mathbb{E}\|\widetilde{g}\|_2^2.$$

score 上界将问题化为 reward 二阶矩：

$$\mathbb{E}[\|\widetilde{g}\|_2^2 \mid s] \le M^2 \sum_a p(a)\log^2(1-\alpha+\alpha q(a)/p(a)). \tag{6.9}$$

对单个 action 记 $p=p(a), q=q(a)$，令 $h(p,q) = p\log^2(1-\alpha+\alpha q/p)$。

第一种情况是 $q<p$。此时 $1-\alpha \le 1-\alpha+\alpha q/p < 1$，因此

$$h(p,q) \le p\log^2(1-\alpha) \le \log^2(1-\alpha). \tag{6.10}$$

允许 $q=0$，因为 $\alpha<1$ 保证 log 有限。

第二种情况是 $q \ge p$。此时 log 非负，使用 $q \le 1$ 得到

$$h(p,q) \le p\log^2(1-\alpha+\alpha/p) \le p\log^2(1+\alpha/p).$$

令 $u=1/p$，右侧为 $f(u) = \log^2(1+\alpha u)/u$。将实际区间 $u \ge 1$ 放宽为 $u>0$ 不会破坏上界。直接求导：

$$f'(u) = \frac{\log(1+\alpha u)}{u^2}\left[\frac{2\alpha u}{1+\alpha u} - \log(1+\alpha u)\right].$$

令 $t = 1+\alpha u > 1$，驻点条件为 $w(t)=0$，其中

$$w(t) = \log t - 2(1-1/t), \qquad w'(t) = (t-2)/t^2.$$

w 在 $(1,2)$ 严格递减、在 $(2,\infty)$ 严格递增；并且

$$w(1)=0, \quad w(2) = \log 2 - 1 < 0, \quad w(e^2) = 2e^{-2} > 0.$$

介值定理与严格单调性给出唯一 $t^\star \in (2,e^2)$。f' 在该根之前为正、之后为负，故 $u^\star = (t^\star-1)/\alpha$ 是全局最大点。代回得

$$f(u) \le f(u^\star) = \alpha\frac{(\log t^\star)^2}{t^\star-1} = C^\star\alpha. \tag{6.11}$$

端点极限 $f(u)\to 0$ 当 $u\downarrow 0$ 或 $u\to\infty$ 也核实了最大值性质。

两种情况合并，每个 action 的 h 至多为 $B_\alpha = \max\{\log^2(1-\alpha), C^\star\alpha\}$。有限词表求和给出 $\mathbb{E}[\widetilde{r}_\alpha^2 \mid s] \le |\mathcal{V}|B_\alpha$。代入式(6.9)，对 prefix 取期望，再使用方差不超过二阶矩，得到结论。

6.3.2 利用归一化得到更紧的界

命题 6.1 (不含词表因子的二阶矩界)

在上一组假设下，每个 prefix 有

$$\mathbb{E}[\widetilde{r}_\alpha^2 \mid s] \le \log^2(1-\alpha) + C^\star\alpha\,\mathrm{TV}(p,q) \le \log^2(1-\alpha) + C^\star\alpha. \tag{6.12}$$

梯度方差至多为右侧乘以 M^2 后对 prefix 取期望。

♠

证明 负向区域保留式(6.10)中的 p，得到

$$\sum_{q<p} h(p,q) \le \log^2(1-\alpha)\sum_{q<p} p \le \log^2(1-\alpha).$$

正向区域令 $t = 1 + \alpha(q-p)/p > 1$，则

$$p \log^2 t = \alpha(q-p)\frac{\log^2 t}{t-1} \le C^\star \alpha(q-p).$$

这里 $\sup_{t>1} \log^2 t/(t-1) = C^\star$ 由同一驻点分析得到。$q = p$ 时贡献为零。概率归一化给出

$$\sum_{q>p}(q-p) = \tfrac{1}{2}\sum_a |q(a)-p(a)| = \mathrm{TV}(p,q).$$

合并两区并用 $\mathrm{TV} \le 1$，即得二阶矩界。梯度控制沿用上一证明。

该命题是对原论文界的进一步推导。两个界都不要求 ratio 上界。$\alpha \downarrow 0$ 时统一界为 $O(\alpha)$；$\alpha \uparrow 1$ 时负向项发散。这表示 vanilla 极限失去统一控制机制，不表示每个固定 teacher/student 实例的方差都发散。

6.4 小权重的学习速度与标准化

固定一个 prefix 的分布并令 $\rho = q/p$。对有限 ρ，

$$\log(1 + \alpha(\rho-1)) = \alpha(\rho-1) - \tfrac{1}{2}\alpha^2(\rho-1)^2 + O(\alpha^3). \tag{6.13}$$

有限词表且 $p > 0$ 时可逐 action 求和，所以未经归一化的期望梯度满足

$$\mathbb{E}_p[\nabla \log p\, \widetilde{r}_\alpha] = \alpha \sum_a \nabla p(a)(q(a)/p(a) - 1) + O(\alpha^2) \tag{6.14}$$

$$= \alpha \sum_a q(a) \nabla \log p(a) + O(\alpha^2). \tag{6.15}$$

最后一步使用 $\sum_a \nabla p(a) = 0$。局部主项是 teacher 对数似然方向，幅度按 α 缩小。不调整 optimizer 或预算时，小 α 会减小原始更新信号。

该 Taylor 展开不是对全部概率分布一致的展开：极小 $p(a)$ 可以让 ρ 达到 $1/\alpha$ 或更大。若随机 prefix 没有相应矩条件，不能交换展开与期望。这解释了固定实例常有 $O(\alpha^2)$ 二阶矩，而统一方差界为 $O(\alpha)$。

标准化改变尺度结论。若整个组的 return 乘以同一个 $c > 0$，且没有分母稳定项，则

$$\frac{cR - c\mu}{c\sigma} = \frac{R-\mu}{\sigma}.$$

整体 reward 缩小不会自动令标准化 advantage 缩小。TOP-D 的非线性变换还改变 token 相对权重，尤其限制强负向 signal，不能只用纯缩放解释。

有限 batch 的随机 μ, σ 使原始 token 方差定理不能直接用于标准化梯度。纯尺度缩小时，理想标准化精确抵消尺度，不能仅凭 σ 变小断言归一化噪声必然增加。若使用稳定分母，有

$$\widehat{A}_c = \frac{c(R-\mu)}{\sqrt{c^2\sigma^2 + \varepsilon^2}}.$$

当 $c\sigma \gg \varepsilon$，尺度近似抵消；当 $c\sigma \ll \varepsilon$，advantage 近似按 c 缩小。组内方差接近零、固定数值误差与稳定项都需单独分析。学习速度应同时比较原始 reward、advantage、梯度和实际策略 KL。

6.5 算术近端算子的收敛

固定 teacher，并定义 $\mathcal{A}_\alpha(p) = (1-\alpha)p + \alpha T$。选择与 k 无关的 prefix 分布 μ，定义

$$d_\mu(p,q) = \mathbb{E}_{s\sim\mu}\|p(\cdot \mid s) - q(\cdot \mid s)\|_1.$$

同一证明适用于 prompt 上的完整 response 分布，但 token 条件分布的算术混合一般不同于完整 response 分布的算术混合。定理应用前必须固定层级和度量。

定理 6.2 (TOP-D 算子有限步与渐近误差界)

固定 T 与 $0<\alpha\le 1$。实际策略 p_{k+1} 的近端误差为 $e_k = d_\mu(p_{k+1}, \mathcal{A}_\alpha(p_k))$。则

$$d_\mu(p_K, T) \le (1-\alpha)^K d_\mu(p_0, T) + \sum_{j=0}^{K-1} (1-\alpha)^{K-1-j} e_j. \tag{6.16}$$

若 $\limsup_k e_k \le e_\infty$，则 $\limsup_K d_\mu(p_K, T) \le e_\infty/\alpha$。精确迭代满足 $p_K = T + (1-\alpha)^K (p_0 - T)$。 ♡

证明 三角不等式与算术恒等式给出

$$\begin{aligned} d_\mu(p_{k+1}, T) &\le e_k + d_\mu(\mathcal{A}_\alpha(p_k), T) \\ &= e_k + \mathbb{E}_\mu \|(1-\alpha)(p_k - T)\|_1 \\ &= e_k + (1-\alpha) d_\mu(p_k, T). \end{aligned}$$

令 $D_k = d_\mu(p_k, T)$、$b = 1-\alpha$。逐次代入为

$$D_1 \le bD_0 + e_0, \quad D_2 \le b^2 D_0 + be_0 + e_1.$$

若式(6.16)对 K 成立，则

$$D_{K+1} \le bD_K + e_K \le b^{K+1} D_0 + \sum_{j=0}^{K} b^{K-j} e_j.$$

归纳法给出全部有限步界。

当 $0<\alpha<1$，任取 $\delta>0$，极限上确界条件给出 N，使 $e_j \le e_\infty + \delta$ 对所有 $j \ge N$ 成立。拆分误差和：

$$\sum_{j<K} b^{K-1-j} e_j = \sum_{j<N} b^{K-1-j} e_j + \sum_{j=N}^{K-1} b^{K-1-j} e_j.$$

第一项只有有限个数，每项随 K 趋零；第二项至多为

$$(e_\infty + \delta) \sum_{m=0}^{K-1-N} b^m \le (e_\infty + \delta)/\alpha.$$

初始项也趋零。先取极限上确界，再令 $\delta \downarrow 0$，得到渐近界。$\alpha = 1$ 时单步递推为 $D_{k+1} \le e_k$，同样成立。精确迭代时 $p_{k+1} - T = b(p_k - T)$，归纳得到最后的分布恒等式。

该定理属于算术分布算子，并未证明特定 SGD、Adam 或 PPO 能令 $e_k \to 0$。优化、参数表示、采样与访问测度误差都包含在 e_k 中。小 α 既降低原始 reward 尾部风险，也使收缩变慢，并把持续误差放大为 e_∞/α。其结构类似 MirrorOPD 的 $\bar{\varepsilon}/\eta$，但度量不同。

推论 6.1 (内部 KL 证书)

若 $\mathbb{E}_\mu \mathrm{KL}(p_{k+1} \| \mathcal{A}_\alpha(p_k)) \le \delta_k^2/2$，则 $e_k \le \delta_k$。 ♡

证明 逐 prefix 用 Pinsker，再对平方根用 Jensen，得到

$$e_k \le \mathbb{E}_\mu \sqrt{2\,\mathrm{KL}(p_{k+1} \| \mathcal{A}_\alpha(p_k))} \le \sqrt{2\mathbb{E}_\mu \,\mathrm{KL}(p_{k+1} \| \mathcal{A}_\alpha(p_k))} \le \delta_k.$$

证书要求 KL 与 e_k 使用相同度量。只测当前 rollout KL 时，还需覆盖或重要性校正，才能推出全部目标 prefix 的误差界。共享参数下一个 prefix 的改进也可能伴随另一个 prefix 的退化。

6.6 有限时域访问测度与性能下界

6.6.1 固定 reward 与归一化

考虑相同初始 prompt 分布、相同转移和固定 reward $r(s,a)$ 的 MDP。所有策略在至多 H 个 action 后终止。吸收状态记为 $s_\perp$，reward 为零，所有策略在该状态采用同一虚拟 action。时间纳入状态，以免混淆不同时间的

价值函数。

瞬态访问测度和长度为

$$d^p(s)=\sum_{t=1}^{H}\Pr_p(s_t=s),\quad \ell_p=\sum_{s\neq s_\perp}d^p(s)=\mathbb{E}_pL,\quad \bar{d}^p=d^p/\ell_p. \tag{6.17}$$

$\bar{d}^p$ 只在瞬态状态上定义，且要求 $\ell_p>0$。性能记作 $J_r(p)=\mathbb{E}_p\sum_{t=1}^{L}r(s_t,a_t)$，避免与 mirror 步长 η 混用。固定基准 p，其同 reward 价值函数定义优势 $A_r^p=Q_r^p-V_r^p$。对候选 q 定义

$$f_{p,q}(s)=\mathbb{E}_{a\sim q}A_r^p(s,a), \tag{6.18}$$

$$\zeta_{r,p}(q)=J_r(p)+\sum_{s\neq s_\perp}d^p(s)f_{p,q}(s), \tag{6.19}$$

$$\xi_{p,q}=\sup_{s\neq s_\perp}|f_{p,q}(s)|<\infty. \tag{6.20}$$

有界有限时域 reward 足以保证 ξ 有限。定理的 reward 不随候选策略变化。

引理 6.1 (有限时域性能差异恒等式)

$J_r(q)-J_r(p)=\sum_{s\neq s_\perp}d^q(s)f_{p,q}(s)$。

♡

证明 由 Bellman 定义，

$$A_r^p(s_t,a_t)=r(s_t,a_t)+\mathbb{E}[V_r^p(s_{t+1})\mid s_t,a_t]-V_r^p(s_t).$$

沿 q 的轨迹取期望并求和，条件全期望和望远镜消去给出

$$\mathbb{E}_q\sum_{t=1}^{H}A_r^p(s_t,a_t)=J_r(q)+\mathbb{E}_qV_r^p(s_{H+1})-\mathbb{E}V_r^p(s_1)=J_r(q)-J_r(p).$$

终止价值为零，初始分布相同。另一方面，按访问测度展开左侧，正好为 $\sum_s d^q(s)f_{p,q}(s)$，得到恒等式。

引理 6.2 (访问测度漂移)

任意 p,q 满足

$$\|d^q-d^p\|_1\le 2H\sum_{s\neq s_\perp}d^p(s)\,\mathrm{TV}(q(\cdot\mid s),p(\cdot\mid s)). \tag{6.21}$$

左侧只对瞬态状态求和。

♡

证明 记 ν_t^p,ν_t^q 为包含吸收状态的完整边缘分布。初始分布相同，故 $\nu_1^p=\nu_1^q$。固定 $t>1$，构造混合分布 P_i：前 i 个 action 使用 p，之后直至第 $t-1$ 个 action 使用 q，$i=0,\dots,t-1$。于是 $P_0(s_t)=\nu_t^q$，$P_{t-1}(s_t)=\nu_t^p$。

相邻 P_i,P_{i-1} 在第 i 个 action 前都使用 p，故共同状态边缘为 ν_i^p；第 i 个 action 分别使用 p,q，之后的转移与策略又相同。记共同 future Markov 核为 $K_{i,t}(\cdot\mid s,a)$，则

$$P_i(s_t\in\cdot)-P_{i-1}(s_t\in\cdot)=\sum_s\nu_i^p(s)\sum_a[p(a\mid s)-q(a\mid s)]K_{i,t}(\cdot\mid s,a).$$

取 L^1 范数，使用核总质量为一，得到

$$\begin{aligned}\|P_i(s_t)-P_{i-1}(s_t)\|_1&\le\sum_s\nu_i^p(s)\sum_a|p(a\mid s)-q(a\mid s)|\\&=2\mathbb{E}_{\nu_i^p}\,\mathrm{TV}(p,q).\end{aligned}$$

该数据处理步骤对随机环境也成立，自回归确定性 prefix 转移只是特例。对混合分布望远镜求和，有

$$\|\nu_t^q-\nu_t^p\|_1\le 2\sum_{i=1}^{t-1}\mathbb{E}_{\nu_i^p}\,\mathrm{TV}(p,q).$$

限制到瞬态状态不会增大范数。再按时间求和并交换次序：

$$\begin{aligned}\|d^q - d^p\|_1 &\le \sum_{t=2}^{H} \|\nu_t^q - \nu_t^p\|_1 \\ &\le 2\sum_{t=2}^{H}\sum_{i=1}^{t-1} \mathbb{E}_{\nu_i^p}\,\mathrm{TV}(p,q) \\ &= 2\sum_{i=1}^{H-1}(H-i)\mathbb{E}_{\nu_i^p}\,\mathrm{TV}(p,q) \\ &\le 2H\sum_{i=1}^{H} \mathbb{E}_{\nu_i^p}\,\mathrm{TV}(p,q) \\ &= 2H\sum_{s\neq s_\perp} d^p(s)\,\mathrm{TV}(p(\cdot\mid s), q(\cdot\mid s)).\end{aligned}$$

最后使用吸收状态上两策略相同，TV 为零。

定理 6.3 (TOP-D 使用的有限时域性能下界)

在上述固定 reward 与有限 horizon 条件下，

$$J_r(q) \ge \zeta_{r,p}(q) - 2\xi_{p,q}H\ell_p\mathbb{E}_{\bar{d}^p}\,\mathrm{TV}(q(\cdot\mid s), p(\cdot\mid s)). \tag{6.22}$$

♡

证明 性能差异恒等式减去 surrogate 定义，得到

$$J_r(q) - \zeta_{r,p}(q) = \sum_{s\neq s_\perp}[d^q(s) - d^p(s)]f_{p,q}(s).$$

取绝对值并使用 $|f_{p,q}| \le \xi_{p,q}$，得到

$$|J_r(q) - \zeta_{r,p}(q)| \le \xi_{p,q}\|d^q - d^p\|_1.$$

代入访问测度漂移引理，再用 $d^p = \ell_p\bar{d}^p$，得到

$$|J_r(q) - \zeta_{r,p}(q)| \le 2\xi_{p,q}H\ell_p\mathbb{E}_{\bar{d}^p}\,\mathrm{TV}(q,p).$$

取绝对误差不等式的负向一侧，即得下界。

记下界右侧为 $\mathcal{M}_{r,p}(q)$。由于 $\mathbb{E}_p A_r^p = 0$，有 $\mathcal{M}_{r,p}(p) = J_r(p)$。候选更新若满足 $\mathcal{M}_{r,p}(q) \ge J_r(p)$，就保证真实固定 reward 回报不降。这是充分条件，有限样本 PPO clipped surrogate 的若干优化步不会自动满足它。PPO clip 也不是全状态 TV 或 KL 硬约束。采样 advantage、长度改造 return 和随机组内 baseline 与真实 A_r^p 的差异需另行控制。

6.6.2 固定 reward 回报与蒸馏 KL 的区别

TOP-D在一个 outer 冻结 $U_{k,\alpha}$、π_k 后，其 reward 为 $\tilde{r}_k = \log U_{k,\alpha} - \log\pi_k$，可代入上一性能定理。该 reward 不随内部 student q 变化。以完整序列为例，令 P_q, P_U, P_{π_k} 为相应 token 策略诱导的 response 分布。共同 support 且 KL 有限时，链式 log-prob 给出

$$J_{\tilde{r}_k}(q) = \mathbb{E}_{P_q}\log(P_U/P_{\pi_k}) \tag{6.23}$$

$$= -\,\mathrm{KL}(P_q\|P_U) + \mathrm{KL}(P_q\|P_{\pi_k}). \tag{6.24}$$

所以增加固定 reward 回报包含接近 teacher 和远离旧策略的两项，不能单凭该回报增加推出逆 KL 减小。若明确优化

$$J_{\tilde{r}_k}(q) - \mathrm{KL}(P_q\|P_{\pi_k}) = -\,\mathrm{KL}(P_q\|P_U),$$

或直接优化目标 KL，才有精确等价性。使用 student 自身的 $\log q$ 构造 reward 又是另一种动态。

原论文将性能下界、内部优化与 KL 证书串成解释框架。严格成立的逻辑链是：实际优化若达到 KL 证书，则算子误差受控；实际策略若提升真实性能下界，则固定 reward 回报单调。达到证书和提升下界仍是条件，empirical

clipped objective 本身没有消除它们。

6.7 MirrorOPD 可继承的结论

MirrorOPD使用 $\log(G_\eta(p)/T) = (1-\eta)\log(p/T) - \log Z$，对 action 取振幅后消去归一化常数。TOP-D 使用 $\mathcal{A}_\alpha(p) - T = (1-\alpha)(p-T)$。二者都有几何衰减及持续误差放大，但一个是 projective log-ratio 度量，一个是 L^1 度量。度量转换需要 support 条件，不能只令 $\alpha = \eta$ 就互换定理。

命题 6.2 (有 support floor 时的 log-ratio 方差界)

若 $\pi_k(a \mid s), T(a \mid s) \geq p_{\min} > 0$，score 范数不超过 M，则任意采样分布下

$$g = \nabla_\theta \log \pi_\theta(a \mid s) \log(T(a \mid s)/\pi_k(a \mid s))$$

满足 $\mathrm{Var}(g) \leq M^2 \log^2(1/p_{\min})$。

证明 两概率都属于 $[p_{\min}, 1]$，所以 $p_{\min} \leq T/\pi_k \leq 1/p_{\min}$。取 log 后有 $|\log(T/\pi_k)| \leq \log(1/p_{\min})$。逐样本梯度平方范数至多为 $M^2 \log^2(1/p_{\min})$；取期望并用方差不超过二阶矩即得结论。

该条件比 TOP-D 的方差假设强。仅缩小 η 不会为 $\eta \log(T/\pi_k)$ 创造全局负下界；原始二阶矩若无限，乘以固定正数后仍无限。support floor、reward clipping 和其他尾部条件分别改变假设或算法，应分别说明。

MirrorOPD 在 outer 内固定 $r_k = \log T - \log \pi_k$，取 $p = \pi_k$，可直接应用有限时域性能下界：

$$J_{r_k}(q) \geq J_{r_k}(\pi_k) + \ell_k \mathbb{E}_{\bar{d}^{\pi_k}, q} A^{\pi_k}_{r_k} - 2\xi_k H \ell_k \mathbb{E}_{\bar{d}^{\pi_k}} \mathrm{TV}(q, \pi_k).$$

优势必须来自同一固定 reward MDP。即时 token log-ratio 一般不同于含未来项的优势；若用即时 signal，需要限定为 token 局部目标或控制遗漏未来优势的误差。

下一 outer 的 anchor 和 reward 都刷新，故不同 outer 的 J_{r_k} 是不同函数。可以逐 outer 使用固定 reward 下界，但不能将它们串成同一回报的单调链。全局 teacher 匹配由算子收敛定理说明；外部任务性能需另建立 teacher 与任务质量的关系。

6.8 vanilla OPD 的极限、反例与结论

6.8.1 三个不同的对象

vanilla OPD至少包含三个应分别分析的对象：

1. TOP-D 的 $\alpha = 1$ reward 极限：$\log(T/\pi_k)$，失去负向平滑边界，内部仍可保留 frozen-old-policy PPO 结构。
2. MirrorOPD 的 $\eta = 1$ 精确子问题：$\mathbb{E}_q \log(T/\pi_k) - \mathrm{KL}(q\|\pi_k) = -\mathrm{KL}(q\|T)$。全分布、全覆盖且精确求解时，一轮到 teacher。
3. 神经网络的有限次 SGD/Adam：参数族受限、prefix 采样有限、inner 未必最优、optimizer 有状态，轨迹不等于精确分布算子。

把 vanilla reward 放入训练代码不等于执行精确近端更新。$\eta = 1$ 的闭式解确定子问题终点，不能替代 inner 误差和访问覆盖分析。

命题 6.3 (有限词表、有界 score 仍不足以统一控制 vanilla 方差)

存在二元词表、严格正 teacher 与有界 softmax score，使 vanilla 梯度方差在一族 teacher 上任意大。

证明 单 prefix 上令 $p_\theta(1) = e^\theta/(1+e^\theta)$，$p_\theta(2) = 1/(1+e^\theta)$。在 $\theta = 0$，两概率为 $1/2$，score 为 $1/2, -1/2$，范数始终不超过一。对 $L > \log 2$ 取

$$T_L(1) = e^{-L}, \qquad T_L(2) = 1 - e^{-L}.$$

teacher 两概率均正。reward 为 $r_1 = \log(2e^{-L})$、$r_2 = \log(2(1-e^{-L}))$；梯度等概率取 $g_1 = r_1/2$、$g_2 = -r_2/2$。两点等概率变量方差为 $(g_1-g_2)^2/4$，于是

$$\mathrm{Var}(g) = \frac{1}{16}(r_1+r_2)^2 = \frac{1}{16}[\log(4e^{-L}(1-e^{-L}))]^2 \longrightarrow \infty.$$

每个固定 L 的方差仍有限；反例证明全部合法 teacher 上不存在只依赖词表与 score 的一致上界。

6.8.2 teacher 收敛与任务 reward

匹配 teacher 与任务准确率提升是不同结论。单步二元任务取 $R(1)=1, R(2)=0$。初始 student 对 action 1 的概率为 0.9，teacher 为 0.2。精确算术与几何迭代都趋于 teacher，任务回报却从 0.9 降到 0.2。这是蒸馏目标与外部 reward 的关系，不能由优化定理排除。

若完整序列 reward 满足 $0 \le R(x,y) \le R_{\max}$，TV 对偶界给出

$$|J_R(p) - J_R(T)| \le R_{\max}\mathbb{E}_x\,\mathrm{TV}(P_p(\cdot\mid x), P_T(\cdot\mid x)).$$

证明可将带符号测度 $P_p - P_T$ 分为正负两部分；两部分总质量各为 TV，积分 $[0, R_{\max}]$ 中的函数后，绝对差至多为 $R_{\max}$ TV。再用 Pinsker 和 Jensen，得到

$$J_R(p) \ge J_R(T) - R_{\max}\sqrt{\tfrac{1}{2}\mathbb{E}_x\,\mathrm{KL}(P_p\|P_T)}.$$

这是相对 teacher 的性能下界，既不保证每步单调，也不保证 teacher 优于初始 student。将 rollout token KL 换成序列 KL 还需链式 KL 与正确的 student 访问测度。

6.9 PMD-mean：同一小步长下的不同回归目标

算术平滑、几何近端更新和均值基线回归是三种不同操作。PMD-mean论文 [76] 说明，把精确 log-partition 换成行为 reward 均值，会改变总体最优解；无限数据不能消除这项算法差异。下面在固定 prefix 或固定 prompt 的有限动作空间中重建该结论。动作可以是 token，也可以是完整 response，但同一推导中必须保持层级不变。

6.9.1 精确 target、均值 target 与中心化 residual

设行为分布 $b(a) > 0$，固定信号 $r(a)$，令

$$h(a) = r(a) - \mathbb{E}_b r, \qquad \mathbb{E}_b h = 0, \qquad \eta > 0.$$

原论文正则化参数为 τ，本书统一用 $\eta = 1/\tau$。精确 KL mirror target 和它的 log-ratio 为

$$q_{\mathrm{part}}(a) = \frac{b(a)e^{\eta h(a)}}{A}, \qquad A = \mathbb{E}_b e^{\eta h}, \qquad u_{\mathrm{part}}(a) = \eta h(a) - \log A. \tag{6.25}$$

用精确 u_{part} 做平方回归，其总体最小 loss 为零，并恢复该 target。

PMD-mean 则删除 $\log A$，拟合 ηh。记候选 q 的 $u(a) = \log(q(a)/b(a))$，得到

$$L_{\mathrm{mean}}(q) = \tfrac{1}{2}\mathbb{E}_b[u(a) - \eta h(a)]^2, \qquad \mathbb{E}_b e^u = 1. \tag{6.26}$$

当 h 非常数时，Jensen 严格不等式给出 $A > 1$，所以 $u = \eta h$ 不满足归一化。平方回归被迫在无法精确拟合的目标与概率约束间折中。

精确中心化 residual 是另一种 loss：

$$D_q(a) = \eta h(a) - u(a) - \mathrm{KL}(b\|q) = \eta h(a) - u(a) + \mathbb{E}_b u, \qquad L_{\mathrm{cent}}(q) = \tfrac{1}{2}\mathbb{E}_b D_q^2. \tag{6.27}$$

这里 $\mathrm{KL}(b\|q)$ 必须随候选 q 计算，并参与相应优化定义。它不是将精确 log-partition 用固定 reward 均值替代。对 q_{part}，有 $\mathrm{KL}(b\|q_{\mathrm{part}}) = \log A$，故 $D_{q_{\mathrm{part}}} = 0$。

命题 6.4 (中心化 residual 恢复精确 mirror target)

有限动作、$b > 0$ 时，L_{cent} 的唯一分布最优解为 q_{part}，最小值为零。在全部自由 logits 参数化中，所有驻点都对应这个分布。

证明 零 residual 条件是 $u - \mathbb{E}_b u = \eta h$。因此 $u = \eta h + c$，归一化要求 $e^c A = 1$，即 $c = -\log A$，得到唯一 q_{part}。平方 loss 非负，所以它是全局最优解。

为证明没有额外驻点，定义零均值坐标 $v = u - \mathbb{E}_b u$。任意 $\mathbb{E}_b v = 0$ 的有限向量，都唯一对应归一化分布

$$q_v(a) = \frac{b(a)e^{v(a)}}{\mathbb{E}_b e^v}.$$

反过来每个正分布都对应该零均值坐标，所以这是正单纯形与零均值线性空间之间的光滑一一映射。在此坐标下

$$L_{\text{cent}}(q_v) = \tfrac{1}{2}\mathbb{E}_b(v - \eta h)^2.$$

对任意零均值扰动 z，方向导数为 $\mathbb{E}_b[(v - \eta h)z]$。由于 $v - \eta h$ 也零均值，若所有导数为零，可取 $z = v - \eta h$，得到 $\mathbb{E}_b(v - \eta h)^2 = 0$。$b > 0$ 强制 $v = \eta h$，即唯一 target。全部自由 logits 只增加一个无效常数方向，不增加新的分布驻点。

该驻点结论依赖完整分布参数化。神经网络参数族、采样 KL 或对 KL 项停止梯度，都需要另分析。特别是 stop-gradient 版本虽然在精确 target 上 residual 仍为零，其全部驻点与真实平方 loss 的导数不再由上面的坐标证明保证。

6.9.2 PMD-mean 的 Lambert-W 解

定理 6.4 (PMD-mean 总体解及归一化常数)

有限动作、$b > 0$ 和 $\mathbb{E}_b h = 0$ 下，式(6.26)有唯一总体最优分布

$$q_{\text{mean}}(a) = b(a)\exp\{\eta h(a) - W(\kappa e^{\eta h(a)})\}, \tag{6.28}$$

其中 W 为非负实数上的 Lambert-W 主分支，即 $W(z)e^{W(z)} = z$。唯一 $\kappa \geq 0$ 由归一化决定。若 h 非常数，$\kappa > 0$；若 $h = 0$，则 $\kappa = 0$ 且 $q_{\text{mean}} = b$。令 $A = \mathbb{E}_b e^{\eta h}$、$B = \mathbb{E}_b e^{2\eta h}$，则

$$\frac{A(A-1)}{B} \leq \kappa \leq \log A. \tag{6.29}$$

原论文乘子 λ 与此处的关系是 $\kappa = \lambda/\tau^2 = \lambda\eta^2$。

证明 在 log-ratio 坐标中，引入归一化乘子：

$$\mathcal{L}(u, \kappa) = \tfrac{1}{2}\sum_a b(a)[u(a) - \eta h(a)]^2 + \kappa\left(\sum_a b(a)e^{u(a)} - 1\right).$$

逐 action 求导，并除以正数 $b(a)$，得到

$$u(a) - \eta h(a) + \kappa e^{u(a)} = 0. \tag{6.30}$$

令 $w_a = \eta h(a) - u(a)$，则 $w_a = \kappa e^{u(a)}$，所以

$$w_a e^{w_a} = \kappa e^{\eta h(a)}, \qquad w_a = W(\kappa e^{\eta h(a)}).$$

代回得到式(6.28)。

现在证明存在性、唯一性和全局最优性，而不仅给出形式驻点。定义

$$F(\kappa) = \sum_a b(a)\exp\{\eta h(a) - W(\kappa e^{\eta h(a)})\}.$$

由于 W 严格递增，F 连续且严格递减。$F(0) = A \geq 1$；当 $\kappa \to \infty$，每个 summand 趋零，故 $F(\kappa) \to 0$。所以存在唯一非负 κ 使 $F(\kappa) = 1$。h 非常数时 Jensen 给出 $A > 1$，根严格正；$h = 0$ 时根为零。

固定这一非负乘子，$\mathcal{L}$ 关于 u 的 Hessian 为对角矩阵

$$\frac{\partial^2 \mathcal{L}}{\partial u(a)^2} = b(a)(1+\kappa e^{u(a)}) > 0.$$

因此驻点是无约束拉格朗日函数的唯一全局最小点。所有满足归一化的 u 上，乘子项为零，$\mathcal{L} = L_{\text{mean}}$。驻点本身可行，所以它也是约束问题唯一全局最小点。这一步避免把非凸的指数等式约束误当作凸约束。

为证明乘子界，先设 $\kappa > 0$。利用 $e^{-W(z)} = W(z)/z$ 和归一化，有

$$\kappa = \mathbb{E}_b W(\kappa e^{\eta h}). \tag{6.31}$$

W 在非负区间递增且凹，Jensen 给出 $\kappa \le W(\kappa A)$。对两边施加递增函数 $w \mapsto we^w$，得到

$$\kappa e^{\kappa} \le \kappa A, \qquad \kappa \le \log A.$$

另一方面 $W(z) \ge z/(1+z)$。该性质可由 $z = we^w$ 验证：$w \ge z/(1+z)$ 等价于 $1 \ge (1-w)e^w$，后者在 $w \ge 0$ 上成立，因为右侧导数为 $-we^w \le 0$。

设 $X = e^{\eta h}$，则式(6.31)与 Cauchy–Schwarz 给出

$$\begin{aligned}\kappa &\ge \mathbb{E}_b \frac{\kappa X}{1+\kappa X} \\ &\ge \frac{(\mathbb{E}_b \kappa X)^2}{\mathbb{E}_b[\kappa X(1+\kappa X)]} = \frac{\kappa A^2}{A+\kappa B}.\end{aligned}$$

除以 κ 并整理，得到 $\kappa \ge A(A-1)/B$。$\kappa = 0$ 时 $A = B = 1$，两界亦成立。

6.9.3 隐式 KL–χ^2 正则化的逐步等价证明

命题 6.5 (PMD-mean 的混合正则化子问题)

上一最优分布也唯一最大化

$$\mathbb{E}_q h - \frac{1}{\eta}\,\mathrm{KL}(q\|b) - \frac{\kappa}{2\eta}\chi^2(q\|b), \qquad \chi^2(q\|b) = \sum_a b(a)(q(a)/b(a)-1)^2. \tag{6.32}$$

系数 κ 是由回归问题及归一化自适应确定的，不是另一个任意选择的固定超参数。

证明 在分布变量 q 中，该目标的 Hessian 为对角矩阵，逐项为

$$-\frac{1}{\eta q(a)} - \frac{\kappa}{\eta b(a)} < 0.$$

所以目标严格凹。带归一化乘子 ν 的一阶条件为

$$h(a) - \frac{1}{\eta}(\log(q(a)/b(a)) + 1) - \frac{\kappa}{\eta}(q(a)/b(a) - 1) + \nu = 0.$$

代入 $u = \log(q/b)$ 并乘以 η，得

$$\eta h(a) - u(a) - 1 - \kappa(e^{u(a)} - 1) + \eta\nu = 0.$$

PMD-mean 的驻点条件(6.30)给出 $\eta h - u - \kappa e^u = 0$。选择 $\eta\nu = 1 - \kappa$，上面的混合目标一阶条件逐 action 成立。该分布满足归一化且严格正，严格凹性保证它是唯一最优解。

这说明 PMD-mean 的保守性来自额外惩罚大概率比率的 χ^2 项，而不是把精确几何步长换成一个更小常数。精确中心化 residual 没有这项总体偏差；它恢复的是原始 KL 子问题。两者在有限样本中仍会有各自的估计误差。

6.9.4 小 η 的相似性与总体误差的区别

有限动作固定 h 时，利用 $\mathbb{E}_b h = 0$ 展开得

$$A = 1 + \frac{\eta^2}{2}\mathbb{E}_b h^2 + O(\eta^3), \qquad B = 1 + 2\eta^2 \mathbb{E}_b h^2 + O(\eta^3).$$

上下界(6.29)于是夹出

$$\kappa = \frac{\eta^2}{2}\,\mathrm{Var}_b(h) + O(\eta^3).$$

用 $W(z) = z + O(z^2)$，得到

$$u_{\text{mean}}(a) = \eta h(a) - \kappa e^{\eta h(a)} + O(\kappa^2)$$
$$= \eta h(a) - \frac{\eta^2}{2} \operatorname{Var}_b(h) + O(\eta^3).$$

精确 target 也有 $u_{\text{part}} = \eta h - \log A = \eta h - \eta^2 \operatorname{Var}_b(h)/2 + O(\eta^3)$。所以小步长下两者到二阶一致，差异从更高阶开始；有限 η 时 Lambert-W 的 action-dependent 校正不同于常数 $\log A$。

在 OPD 中取 $r = \log(T/b)$，则 $h = \log(T/b) + \mathrm{KL}(b\|T)$。精确中心化 residual 的 target 是 $b^{1-\eta}T^{\eta}/Z$；PMD-mean 回归的 target 是式(6.28)，仍有额外 χ^2 正则化。即使 $\eta = 1$，后者也一般不是 teacher；前者则精确为 teacher。因此“小 η 下相似”与“使用同一个算法”有不同含义。

均值 target 与最优 log-ratio 的差异属于总体目标近似。为区分这种差异与求解误差，定义

$$u^* = \log(q_{\text{mean}}/b).$$

对任何正分布 q，平方展开和驻点条件给出精确恒等式

$$L_{\text{mean}}(q) - L_{\text{mean}}(q_{\text{mean}}) = \tfrac{1}{2}\mathbb{E}_b(u - u^*)^2 + \mathbb{E}_b[(u^* - \eta h)(u - u^*)] \tag{6.33}$$
$$= \tfrac{1}{2}\mathbb{E}_b(u - u^*)^2 - \kappa \mathbb{E}_{q_{\text{mean}}}(u - u^*) \tag{6.34}$$
$$= \tfrac{1}{2}\mathbb{E}_b(u - u^*)^2 + \kappa\, \mathrm{KL}(q_{\text{mean}}\|q). \tag{6.35}$$

因此总体 excess loss 趋于零会使最优策略的 log-ratio 回归误差趋零。有限样本 ERM 在一致性条件下可恢复 PMD-mean 的总体 target；它仍与精确 KL target 不同。原论文 refined analysis 正是利用这类恒等式，将统计误差与目标近似造成的算法差异分开。

6.10 两种方法的收益与组合条件

TOP-D的算术 target 提供原始 on-policy token 梯度的全概率空间二阶矩界。冻结 old policy 与 batch 允许多 epoch 数据复用，PPO ratio 机制控制某些采样方向的内部更新。后两项的全局保证仍需真实优势、采样误差和实际策略漂移控制。

MirrorOPD 的 KL 子问题提供唯一 Gibbs target、精确 projective 收缩和可展开的 inner 误差递推。它也能在 outer 内冻结行为策略并复用数据。几何收缩不会自动消除 log-ratio 负尾，算术 reward 的方差定理也不会自动推出几何收缩。

若将 TOP-D 平滑 reward 放入 KL mirror 子问题，target 会变为

$$q^+(a \mid s) \propto \pi_k(a \mid s) \left(1 - \alpha + \alpha \frac{T(a \mid s)}{\pi_k(a \mid s)}\right)^{\eta}.$$

$\eta = 1$ 时它正好是算术混合；$0 < \eta < 1$ 时是旧策略到算术近端 teacher 的几何插值。该算法具有 α, η 双参数动力学，需对新算子重新证明收敛，并对实际估计量证明方差。将两套已有定理并排写出不能替代这一证明。

第七章 从局部几何到方差与性能保证

7.1 projective 距离如何约束 KL

引理 7.1 (从振幅到概率距离)

令 $D = d_{\mathrm{proj}}(p, q)$。则每个动作满足 $|\log(p(a)/q(a))| \le D$，且

$$\mathrm{KL}(p\|q) \le D, \qquad \mathrm{KL}(q\|p) \le D, \qquad \mathrm{TV}(p, q) \le \frac{1}{2}(e^D - 1).$$

♡

证明 设 $u_a = \log(p(a)/q(a))$。由 $\sum_a q(a)e^{u_a} = 1$，$\min_a u_a \le 0 \le \max_a u_a$。于是区间长度 D 控制所有 $|u_a|$。对 p 或 q 求期望给出两条 KL 上界。又

$$2\,\mathrm{TV}(p, q) = \sum_a q(a)|e^{u_a} - 1| \le \max\{e^D - 1, 1 - e^{-D}\} = e^D - 1.$$

该引理把 outer 振幅递推转成 KL 和概率误差，但其方向不能随意反转。一个很稀有动作上的巨大 log-ratio 可只有很小的平均 KL，故平均 target KL 不能自动替代最大 projective residual。

7.2 访问误差对回归目标的影响

定理 7.1 (固定 prefix 测度替换误差)

对有界 integrand $|\ell(s)| \le B$，若 $\nu, \widetilde{\nu}$ 为概率分布，则

$$|\mathbb{E}_\nu \ell - \mathbb{E}_{\widetilde{\nu}} \ell| \le 2B\,\mathrm{TV}(\nu, \widetilde{\nu}).$$

若 $\nu \ll \widetilde{\nu}$ 且 $w = \mathrm{d}\nu/\mathrm{d}\widetilde{\nu}$，

$$\mathbb{E}_{\widetilde{\nu}}[w\ell] = \mathbb{E}_\nu \ell.$$

若 $w \le C$，则 $\mathbb{E}_{\widetilde{\nu}}[(w\ell)^2] \le C\mathbb{E}_\nu[\ell^2]$。

♡

证明 第一式由 $|\sum_s (\nu(s) - \widetilde{\nu}(s))\ell(s)| \le B\sum_s |\nu(s) - \widetilde{\nu}(s)|$。第二式按 Radon–Nikodym 定义变换积分。第三式逐点使用 $w^2 \le Cw$，然后应用第二式。

这给出 replay 的完整账目：丢掉 w 有测度偏差，保留 w 有二阶矩代价，没有 support 则 w 不存在。采用历史 ratio 或短窗口，需按目标 integrand 证明其校正语义；不存在一个统一的“无 IS 因而无偏”定理。

7.3 OPD 的条件方差界

对随机向量采用 $\mathrm{Var}(g) = \mathbb{E}\|g - \mathbb{E}g\|_2^2$。

定理 7.2 (支持下界与 raw OPD 方差)

假设对全部被训练 prefix 和动作，$T(a \mid s), b(a \mid s) \ge p_{\min} > 0$，且 $\|\nabla_\theta \log \pi_\theta(a \mid s)\| \le M$。令

$$g = \nabla_\theta \log \pi_\theta(a \mid s) \log \frac{T(a \mid s)}{b(a \mid s)}.$$

无论 action 使用哪个概率分布采样，都有

$$\mathrm{Var}(g) \le M^2 \log^2(1/p_{\min}).$$

若信号乘 η，右端相应乘 η^2。

♡

证明 由 $p_{\min} \le T, b \le 1$，

$$p_{\min} \le T/b \le 1/p_{\min}, \quad |\log(T/b)| \le \log(1/p_{\min}).$$

逐样本 $\|g\|^2$ 因而不超过右端。恒等式 $\mathrm{Var}(g) = \mathbb{E}\|g\|^2 - \|\mathbb{E}g\|^2 \le \mathbb{E}\|g\|^2$ 完成证明。

固定有限词表且 teacher 有统一正下界时，对 on-policy $\log(T/\pi)$ 还可利用 $\sum_a \pi(a)\log^2\pi(a)$ 的有限上界，不必强制 student floor；上一定理是更容易诊断的充分条件，不是所有有限方差的必要条件。跨 prefix 的 teacher log-prob 没有统一下界、response return 很长、或 score 不受控时，则没有跨问题的统一 raw OPD 常数。η 降低信号幅度，并不独自修复这些 support 与尾部问题。

7.4 有限 horizon 下的性能差

固定 MDP reward r，horizon 不超过 H，终止后进入零奖励吸收状态。令 $V_t^\pi, Q_t^\pi, A_t^\pi$ 含时间索引，状态中可显式包含 t。定义 $J_r(\pi) = \mathbb{E}_\pi \sum_{t=1}^H r_t$。

引理 7.2 (有限 horizon performance difference)

$$J_r(p) - J_r(b) = \sum_{t=1}^{H} \mathbb{E}_{s_t \sim d_t^p, a_t \sim p}[A_t^b(s_t, a_t)].$$

♡

证明 Bellman 方程给出 $A_t^b(s,a) = r_t(s,a) + \mathbb{E}[V_{t+1}^b(s') \mid s,a] - V_t^b(s)$。沿 p 轨迹求和并用塔式期望，

$$\mathbb{E}_p \sum_t A_t^b = \mathbb{E}_p \sum_t r_t + \mathbb{E}_p[V_{H+1}^b(s_{H+1}) - V_1^b(s_1)].$$

末端价值为零，prompt 初始分布对所有策略相同，初始价值期望为 $J_r(b)$，得到结论。

定理 7.3 (固定 reward 的 surrogate 下界)

定义

$$f_t(s) = \mathbb{E}_{a\sim p} A_t^b(s,a), \quad \xi = \max_{t,s} |f_t(s)|, \quad \zeta_b(p) = J_r(b) + \sum_t \mathbb{E}_{d_t^b} f_t.$$

则

$$J_r(p) \ge \zeta_b(p) - 2H \sum_{i=1}^{H} \mathbb{E}_{s_i \sim d_i^b}[\xi \ \mathrm{TV}(p(\cdot \mid s_i), b(\cdot \mid s_i))].$$

未归一化 occupancy 总质量为 ℓ_b 时，可写成 $2H\xi\ell_b \mathbb{E}_{d^b/\ell_b} \mathrm{TV}(p,b)$。

♡

证明 由引理加减行为 occupancy 的优势期望，

$$|J_r(p) - \zeta_b(p)| \le \xi \sum_{t=1}^{H} \|d_t^p - d_t^b\|_1.$$

为了界定第 t 步差异，构造混合轨迹：第一个使用全部 p，随后逐个把前 i 个 action policy 换为 b。相邻两条轨迹在第 i 步之前均使用 b，所以该步状态分布为 d_i^b；第 i 步后两者使用相同 p kernel。Markov kernel 对 L^1 不扩张，故相邻轨迹的第 t 步状态差至多为 $2\mathbb{E}_{d_i^b} \mathrm{TV}(p,b)$。对 $i < t$ 望远镜求和，

$$\|d_t^p - d_t^b\|_1 \le 2 \sum_{i=1}^{t-1} \mathbb{E}_{d_i^b} \mathrm{TV}(p,b).$$

再交换 t, i 次序，

$$\sum_t \|d_t^p - d_t^b\|_1 \le 2 \sum_{i=1}^{H-1} (H-i) \mathbb{E}_{d_i^b} \mathrm{TV}(p,b) \le 2H \sum_i \mathbb{E}_{d_i^b} \mathrm{TV}(p,b).$$

代回并取下界。可变长度用终止吸收状态处理，吸收后的 action 分布相同，故 TV 为零，最终 occupancy 可限制在活跃 prefix。

7.5 teacher 几何与真实性能的桥梁

固定 outer reward $r_k = \log T - \log b$ 时，上述定理适用于 J_{r_k}，但它和环境 reward R 一般不同。在每个 prefix 的 Gibbs 解只能保证其自身局部 surrogate：

$$\langle G_\eta(b) - b, r_k \rangle \geq \eta^{-1}\,\mathrm{KL}(G_\eta(b)\|b) \geq 0.$$

该式由将最优解目标与候选 b 的目标值（其近端 KL 为零）比较得到，并不证明 J_R 增加。

若真实优势满足 $A_R^b(s,a) = c\,r_k(s,a) + u(s) + e(s,a)$，$c > 0$，且 $|e(s,a)| \leq \epsilon_A$，对两个 action 分布 p, b 作差消去 $u(s)$ 后

$$\mathbb{E}_p A_R^b - \mathbb{E}_b A_R^b \geq c\langle p - b, r_k \rangle - 2\epsilon_A\,\mathrm{TV}(p,b).$$

这里 $\mathbb{E}_b A_R^b = 0$。因此要从 teacher 信号推出真实性能，必须把这个误差、projection 误差与 occupancy 罚项同时放进下界。

若 $T = be^{\lambda A_R^b}/Z$，则 $r_k = \lambda A_R^b - \log Z$，差分中常数消失。这是可以严格桥接的特殊情况；任意教师能力强于学生不构成此假设。例如一个动作真实奖励为一、另一个为零，而 teacher 对后者概率更高，student 向 teacher 收缩的同时真实回报下降。几何收敛和真实任务性能必须分别报告。

第八章 算法实现与可证伪实验

8.1 把外层目标与内层优化器分开实现

实现采用四个独立对象：行为版本 b_k、镜像 anchor $\bar{\pi}_k$、当前 actor p_θ、固定教师 T。在 hard sync 且 fresh rollout 的基准中，前两个对象数值相同；在 replay、delayed sync 或 EMA 中，它们一般不同。每条 response 保存生成版本、prompt、prefix、行为 log-prob 和采样配置。anchor log-prob 必须用本轮冻结的 anchor 重算；行为 log-prob 只有在明确的测度校正项中使用。温度、top-p、截断和 EOS 处理改变真实采样分布，保存模型 softmax log-prob 不能替代保存截断后分布。

每个 outer step 的顺序为：先同步本轮 anchor，随后采样或组合 replay，计算并停止梯度的教师信号，最后在该固定子问题上做 inner 更新。一旦同步 anchor，旧残差的零点也随之移动，必须重新计算 $\log T - \log \bar{\pi}_k$。只更新参数副本而继续复用旧 reward，得到的是另一条动力学。EMA 则必须指定在 actor 更新前还是更新后执行，以及周期按 minibatch、rollout 还是 outer step 计数。这些选择直接进入第 5 章的矩阵，无法用同一个“同步率”概括。

优化器状态也需要固定语义。保留 Adam 动量会使下一轮的首个 inner 更新依赖上一轮目标。清空动量给出更接近独立近端求解的基准，保留动量给出带记忆的求解器；两种实现应各自命名并记录。理论中 q^M 的收缩率对应固定二次模型的梯度下降，不能直接赋给任意 Adam 设置。

8.2 Fisher 距离控制与数值求解

令 g 为当前镜像 surrogate 的参数梯度，F 为同一 prefix 测度下的 Fisher 矩阵。求解阻尼系统

$$(F + \lambda I)d = g, \qquad \lambda > 0.$$

共轭梯度无需显式存储矩阵，可用 Fisher-vector product 计算每次迭代。当目标是最大化 surrogate，候选更新写成

$$\Delta\theta = \sqrt{\frac{2\epsilon_{\mathrm{NG}}}{d^\top F d}}\, d.$$

若 $d^\top F d = 0$，停止该方向更新；该分母为零表明所估 Fisher 无法识别此方向，继续放大步长没有几何依据。阻尼系统与距离归一化使用的矩阵不同，因此不能将分母随意替换为 $g^\top d$。无阻尼且精确求解时，两者相等；有阻尼时

$$g^\top d = d^\top F d + \lambda \|d\|^2.$$

以冻结 batch 的实际 $\mathrm{KL}(p_{\theta+\Delta\theta} \| p_\theta)$ 验证二阶预测，超预算时回溯缩短步长。这控制的是 inner 求解路径；η 控制镜像目标的位置。固定 η、改变 ϵ_{NG}，理论零点不变；固定几何半径、改变 η，零点改变。有限训练预算下，两者都会改变最终 student，因此应同时报告目标位置和追赶误差。

8.3 与理论匹配的停止条件

对于 tabular 全支持基准，可以直接计算

$$E_k = \sup_s \mathrm{osc}_a \log \frac{p_{k,M}(a \mid s)}{G_{\eta_k}(\bar{\pi}_k)(a \mid s)}.$$

按 $E_k \le c\eta_k$ 停止，控制固定误差地板；要得到逐渐精确的 teacher 收敛，则要求 $E_k/\eta_k \to 0$。神经网络中只能在验证 prefix 集合估计该量，不能将有限集合的最大值当成所有 prefix 的最大值。同时报告训练 residual、验证 target KL、深度分层覆盖率，识别过拟合和缺少访问的状态。

平方残差均值、梯度范数和 projective 误差具有不同量纲。若残差平方的阈值随 η_k^2 缩放，还需要 support 下界和范数转换常数，才能推出 $E_k = O(\eta_k)$。简单地让 loss 小于一个固定数字，在小 η 时会让求解误差支配镜像信号。

8.4 四项研究假设及其反证

8.4.1 残差回归与序列 IS 的方差

在相同 replay、相同 student、相同目标和相同 token 预算下，比较序列 IS 梯度与最优性残差梯度的二阶矩。第 3 章的条件期望结论只保证可用 Rao–Blackwell 化删除无关的 suffix 权重；残差回归改变优化目标，方差更小必须通过估计器分析和实验共同检验。按 response 长度报告梯度 trace、最大样本贡献与有效样本量

$$\mathrm{ESS} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}.$$

较小方差同时伴随较大偏差时，应报告两者和最终目标误差，不能只展示 ESS。

8.4.2 局部目标与序列目标的长期影响

在 dense teacher log-ratio 和 sparse verifier reward 两个 regime 分别比较。逐 prefix 的几何 teacher 插值有局部闭式解，完整序列 Gibbs 还包含 continuation partition function。因此在 sparse reward 下，局部化后的 value 或 advantage 误差必须单独测量。对相同 prompt 测试浅层和深层 prefix，并记录 suffix 成功率；若局部 KL 下降而深层成功率恶化，说明局部目标与长程 credit 的差异主导结果。

8.4.3 镜像步长与实际几何步长的可分辨性

先固定 η 扫描 ϵ_{NG}，再固定半径扫描 η。记录目标分布、实际 inner KL、target KL 与更新次数。当足够多 inner 更新后不同半径仍给出不同零点，应检查投影容量、测度变化和停止梯度实现。预测 KL 与实际 KL 长期不符，则 Fisher 估计或局部二阶近似不适合作为控制器。

8.4.4 旧数据的覆盖与测度误差

使用 fresh-only、replay-only 和 mixed-prefix 三组数据，保持教师和 anchor log-prob 重算一致。先在完整 tabular support 中隔离纯测度效应，再在有限神经网络中加入未访问 prefix。第 7 章给出有界 integrand 的测度替换误差；零残差共享解并不意味着有限参数投影与测度无关。当 coverage 相同而 replay 性能仍明显下降，应测量加权投影误差、行为概率记录和版本漂移，不能预先归因为 coverage。

8.5 实验矩阵与公平预算

实验轴	设置与对应判据
目标	SFT、vanilla reverse-KL OPD、sequence PMD-part、PMD-mean、BPO、prefix MirrorOPD；每项明确优化目标和 prefix 测度。
数据	fresh rollout、1/4/16/64 版本滞后、不同 replay 混合比例；同时报告 wall time 与有效 token。
测度修正	无 IS、action IS、per-decision IS、sequence IS、残差回归；区分无偏修正与换目标。
inner 求解	Adam、KL 回溯、Fisher/NG；比较固定更新数、固定 token 数与同 residual 三种预算。
镜像强度	$\eta \in \{0.1, 0.3, 0.5, 0.7, 1\}$；另保留原温度网格 $\tau \in \{0.25, 0.5, 1, 2, 4\}$，其中 $\eta = \tau^{-1} > 1$ 标注为外推区间。
同步	hard、delayed、参数 EMA、logit EMA；记录实际同步周期、EMA 系数及 pre/post-update 顺序。
信号	dense teacher、终局 verifier、advantage regression；教师质量与支持下界作为独立轴。
诊断	reward、pass@k、双向 KL、Fisher 距离、ESS、$\mathbb{E}[(\log W)^2]$、梯度 trace、prefix coverage、inner residual 和 actor–anchor lag。

先在有限动作、有限前缀树上实现精确求解和有限 inner 更新。精确 hard sync 的振幅曲线应满足 $D_k = |1-\eta|^k D_0$，$\eta = 1$ 在一次全支持投影后为零。有固定 inner 误差时应出现 $O(\varepsilon/\eta)$ 地板；EMA 模态应吻合矩阵谱半径及稳定边界。这一步检验数学模型与代码语义一致，再进入神经网络容量和采样误差实验。

最终比较使用相同总 teacher 查询数、生成 token 数和训练 token 数，并独立报告 wall time。较小 η 所需 outer 次数增加，不能用“每轮更稳”直接推出总训练更快。EMA 需要用发散率、可用 actor 步长和达到同一 target KL 的成本证明收益；仅展示较平滑 loss 曲线不足以说明收益。

第九章 文献关系与研究贡献的边界

9.1 镜像几何、策略改进与参数投影

负熵镜像下降、自然梯度和信赖域分别描述分布的有限近端步、参数的瞬时方向和可接受的移动范围。Beck–Teboulle的凸分析给出 Bregman 三点不等式，Amari 的信息几何给出 Fisher 度量，Kakade 将自然梯度用于策略优化。这些对象在第 2 章通过同一局部二次展开联系起来；神经网络参数更新与精确分布镜像步的差别由可表示性和高阶项决定。Natural Actor-Critic、TRPO 与 Guided Policy Search 是将这些几何结构接入采样、critic 和参数拟合的直接前序 [5, 7, 23, 30, 53, 65]。

PMD 的核心理论问题是反复更新 advantage 或 Q 后，整个控制问题的值函数怎样改进。精确 PMD 的最优速率、regularized PMD、一般参数化 PMD、homotopic PMD、lookahead、学习镜像映射、block 更新和随机镜像下降分别改变了精确性、正则项、策略类、访问顺序和 oracle 噪声 [1, 10, 24, 32, 33, 51, 55, 56, 77]。它们的 convergence theorem 不能只凭“都用了 KL”搬到 OPD：OPD 的 $\log T - \log b$ 一般不是环境 advantage。本书因此先证明固定教师的 projective 收缩，再在第 7 章单独给出 advantage 一致性条件下的性能界。

探索、bounded advantage 与平均回报的分析补充了不同的适用条件 [25, 38, 43, 52, 54]。若把原始教师 log-ratio 截断成 bounded advantage，可得到更直接的二阶矩控制，但截断改变了 Gibbs target。这应被视为明确的目标修改，并用未截断目标误差衡量偏差。随机 mirror descent 的方差缩减、Hessian-aided 自然梯度和递归 policy gradient 可以改进 oracle 估计 [22, 64, 73]；它们不能恢复行为数据从未覆盖的 prefix。

9.2 离策略优化的三种分工

9.2.1 访问分布上的优化

Relative Entropy Policy Search（REPS）对 occupancy 分布施加相对熵限制，Bellman 流约束将不同状态连起来 [60]。固定 prefix 的 token 更新没有这组全局流约束，因此即使局部目标也是指数倾斜，也不能把 occupancy 层的保证直接移植过来。OptiDICE 一类 occupancy correction 方法与这个问题同属访问测度路线；它们的比率对象应与 action likelihood ratio 分开。

Dynamic Mirror Descent MPC、Supported Trust Region Optimization 与 Beyond State-Wise Mirror Descent 分别提供动态规划、支持约束和参数化离线优化的相关视角 [9, 57, 68]。本书对应的问题是：replay 测度下的投影与当前访问测度下的投影是否共享解，及有限容量时相差多少。第 3 章的共同零点条件和第 7 章的测度替换界分别回答这两层问题。

9.2.2 目标构造与拟合分开

MPO的 E-step 构造指数倾斜目标，M-step 用 forward KL 或加权最大似然拟合参数策略，并可另加 old-policy trust region[3]。RE-MPO、AWR、V-MPO 与较早的 reward-weighted regression 都提供了“奖励决定目标、监督学习负责投影”的实现路线 [4, 59, 61, 72]。这个分工使镜像温度和 student 的移动半径拥有独立接口。反向 KL 投影、正向 KL 投影和残差回归在完整可表示且精确求解时可共享目标；在有限策略类中，其最优投影一般不同。

Cautious Policy Programming 根据性能下界选择候选策略的混合比例 [13]。这种算术混合与 KL 镜像几何插值对应不同曲线，可作为性能门控基线，但不能与 η 同名后宣称数学等价。

9.2.3 估计器校正与回归换目标

精确 sequence IS 修正联合轨迹期望，per-decision IS 利用条件期望删除 suffix 权重，action IS 只修正当前动作分布。残差回归把训练目标改为最优性条件的平方，其零点可与 Gibbs 解相同。这四个对象应分别写出期望测

度、被积函数和所需支持条件。“没有乘序列权重”只是一条实现事实，不能推出对原始 on-policy policy gradient 无偏。

9.3 LLM 后训练中的镜像目标

Kimi k1.5的策略优化配方、PMD-mean、BPO 和 Reference-Sampled Boltzmann Projection 分别把策略近端更新、配分函数近似、Bellman 残差和参考采样投影带入 LLM 后训练 [8, 31, 58, 76]。PMD-mean 将 log-partition 替换为均值后，优化的驻点方程改变；第 6 章据此区分精确中心化残差与近似配分函数目标。小 η 的局部展开可以相近，不能由此推出有限步目标相同。

偏好对齐中的 optimistic online mirror descent、Nash learning、iterative Nash policy optimization、magnetic preference optimization 和 online preference optimization 研究随反馈或对手改变的分布更新 [26, 27, 29, 35, 40]。固定教师 OPD 的收缩证明依赖共同不动点 T；当教师随时间变化，应加入 target drift，或改用静态、动态 regret。在线 KL 正则化的 regret 分析和 Banach–Bregman 随机迭代框架为这种扩展提供相关理论入口 [2, 34]。

KL 放在 value estimation、梯度目标、old-policy anchor 或未来过程奖励中，其作用不同 [21, 44, 62]。DistiLLM 的分布匹配与 mixing diverse preference alignment 的多来源目标组合，也应与访问测度校正分开 [16, 39]。本书的记号始终保留 teacher、behavior、anchor、actor 四个角色，以免将这些目标压成一个“KL 系数”。

9.4 OPD 的目标与访问分布

MiniLLM、GKD、Thinking Machines的 on-policy distillation 与 on-policy context distillation 强调 student 所访问的 prefix 对训练分布的影响 [36, 47–49]。BOND 的 best-of-N 蒸馏则先通过候选选择改变 target[11]。候选选择、教师 token 分布和固定真实回报定义了不同的投影对象，性能比较必须交代哪一个发生变化。

VESPO、OAPL、MInTRL 与 TOP-D 提供序列优化、离策略学习、干预和 teacher trust region 的直接近邻 [37, 42, 74, 75]。TOP-D 使用算术混合教师来限制 reward tails，MirrorOPD 用几何 target 定义近端零点。第 6 章完整推导两种权重的界与小步方向，因此比较的重点是尾部控制、最终教师偏差和有限步轨迹。

Many Faces、OPD Geometry、Revisiting OPD 与 Position Bias 提供关于蒸馏目标、几何、估计路径和位置效应的相关讨论 [45, 46, 63, 70]。Distribution-Aligned Sequence Distillation、reasoning-prefix distillation 与 Near-Policy Distillation 则把分布对齐、prefix 选择和近策略数据作为独立设计轴 [17, 20, 41]。AOPD、ROPD、SOD 与 Flow-OPD 这些原笔记中的方法线索仍对应异步、鲁棒、逐步和生成过程蒸馏的比较方向；在没有精确算法定义时，本书不为这些简称赋予共同定理。

9.5 直接重叠工作与本书的增量

Least Square Policy Distillation（LSPD）直接覆盖了 OPD 的 RL 解释、最小二乘蒸馏与离策略复用的研究交集 [6]。DDO-RM 的 distribution-level policy improvement、CataOPD 的 teacher 引导、TGPO 的大差异策略优化以及 OPD with verifiable reward 又分别覆盖目标构造、可达轨迹和 dense-plus-sparse reward[12, 14, 50, 69]。因此“将镜像下降用于 OPD”不能单独构成首次贡献声明。

Entropy-Aware OPD、EasyOPD、SEED、POPO、Self-Distilled Policy Gradient 与 Distilled Reinforcement Learning 继续拓展熵控制、工程接口、自演化和自蒸馏路线 [15, 18, 19, 28, 66, 67]。本书保留这些比较对象，但定理围绕明确的算子与测度表述，避免从方法名字推断已有或缺失的保证。

本书能够精确陈述的工作是：给出固定教师的局部 Gibbs 算子及序列条件分布差别；证明未充分 inner 求解后的 outer 误差传播；保留 η、actor 步长、EMA 强度与更新顺序分析同步动力学；将 target 构造、参数求解和访问测度分别纳入可证明条件；通过同预算实验检验方差和最终性能之间的关系。这些数学结果的贡献边界由所写假设决定，文献新颖性还需针对对应原论文逐项比较。

9.6 阅读路径

先阅读 MD、Natural Policy Gradient、MDPO 与 PMD，配合第 2 章区分分布步与参数步。随后阅读一般参数化、homotopic 和 lookahead PMD，理解哪些保证需要精确 oracle。第三组阅读 PMD-mean、BPO、MPO 与参考采样 Boltzmann 投影，配合第 3 章比较驻点与测度。最后阅读 EMA Policy Gradient、TOP-D 及访问分布相关 OPD 工作，配合第 4–8 章研究同步和实验。

参考文献

[1] *A Novel Framework for Policy Mirror Descent with General Parameterization and Linear Convergence*. 2023. URL: https://arxiv.org/abs/2301.13139.

[2] *A Universal Banach–Bregman Framework for Stochastic Iterations*. 2025. URL: https://arxiv.org/abs/2509.14216.

[3] Abbas Abdolmaleki et al. *Maximum a Posteriori Policy Optimisation*. 2018. URL: https://arxiv.org/abs/1806.06920.

[4] *Advantage-Weighted Regression: Simple and Scalable Off-Policy Reinforcement Learning*. 2019. URL: https://arxiv.org/abs/1910.00177.

[5] Shun-ichi Amari. *Natural Gradient Works Efficiently in Learning*. 1998. URL: https://doi.org/10.1162/089976698300017746.

[6] *An RL View of OPD: Least Square Policy Distillation for Sample-Efficient LLM Reasoning*. 2026. URL: https://arxiv.org/abs/2609.35505.

[7] Amir Beck and Marc Teboulle. *Mirror descent and nonlinear projected subgradient methods for convex optimization*. 2003. URL: https://doi.org/10.1016/S0167-6377(02)00231-6.

[8] *Bellman Policy Optimization*. 2026. URL: https://arxiv.org/abs/2609.15987.

[9] *Beyond State-Wise Mirror Descent: Offline Policy Optimization with Parametric Policies*. 2026. URL: https://arxiv.org/abs/2602.23811.

[10] *Block Policy Mirror Descent*. 2022. URL: https://arxiv.org/abs/2201.05756.

[11] *BOND: Aligning LLMs with Best-of-N Distillation*. 2024. URL: https://openreview.net/forum?id=0tAXMiSufG.

[12] *CataOPD: Catalytic On-Policy Distillation for Large Language Model Reasoning*. 2026. URL: https://arxiv.org/abs/2609.29518.

[13] *Cautious Policy Programming*. 2023. URL: https://doi.org/10.1007/s10994-023-06368-z.

[14] *DDO-RM: Distribution-Level Policy Improvement after Reward Learning*. 2026. URL: https://arxiv.org/abs/2604.11119.

[15] *Distilled Reinforcement Learning for LLM Post-training*. 2026. URL: https://arxiv.org/abs/2607.17247.

[16] *DistiLLM: Towards Streamlined Distillation for Large Language Models*. 2024. URL: https://arxiv.org/abs/2402.03898.

[17] *Distribution-Aligned Sequence Distillation*. 2026. URL: https://arxiv.org/abs/2601.09088.

[18] *EasyOPD: An Easy-to-use On-Policy Distillation Framework for Large Language Models*. 2026. URL: https://arxiv.org/abs/2607.11012.

[19] *Entropy-Aware On-Policy Distillation of Language Models*. 2026. URL: https://arxiv.org/abs/2603.07079.

[20] *Fast and Effective On-policy Distillation from Reasoning Prefixes*. 2026. URL: https://arxiv.org/abs/2602.15260.

[21] *Future-KL Regularized GRPO: Process-Level Credit Assignment from f-Divergence Regularization*. 2026. URL: https://arxiv.org/abs/2601.10201.

[22] *Global Convergence of Natural Policy Gradient with Hessian-Aided Momentum Variance Reduction*. 2024. URL: https://arxiv.org/abs/2401.01084.

[23] *Guided Policy Search as Approximate Mirror Descent*. 2016. URL: https://arxiv.org/abs/1607.04614.

[24] *Homotopic Policy Mirror Descent*. 2022. URL: https://arxiv.org/abs/2201.09457.

[25] Feihu Huang, Shangqian Gao, and Heng Huang. *Bregman Gradient Policy Optimization*. 2021. URL: https://arxiv.org/abs/2106.12112.

[26] *Human Alignment of Large Language Models through Online Preference Optimisation*. 2024. URL: https://arxiv.org/abs/2403.08635.

[27] *Improving LLM General Preference Alignment via Optimistic Online Mirror Descent*. 2025. URL: https://openreview.net/forum?id=kZstGANG8D.

[28] *Improving Reasoning Ability via Asynchronous On-Policy Self-Distillation under Positive Rollouts*. 2026. URL: https://arxiv.org/abs/2605.06650.

[29] *Iterative Nash Policy Optimization*. 2024. URL: https://arxiv.org/abs/2407.00617.

[30] Sham M. Kakade. *A Natural Policy Gradient*. 2001. URL: https://www.cs.berkeley.edu/~pabbeel/cs287-fa13/readings/kakade-natural-policy-gradient-2001.pdf.

[31] *Kimi k1.5: Scaling Reinforcement Learning with LLMs*. 2025. URL: https://arxiv.org/abs/2501.12599.

[32] Guanghui Lan. *Policy Mirror Descent for Reinforcement Learning: Linear Convergence, New Sampling Complexity, and Generalized Problem Classes*. 2023. URL: https://doi.org/10.1007/s10107-022-01816-5.

[33] *Learning Mirror Maps in Policy Mirror Descent*. 2024. URL: https://arxiv.org/abs/2402.05187.

[34] *Logarithmic Regret for Online KL-Regularized Reinforcement Learning*. 2025. URL: https://arxiv.org/abs/2502.07460.

[35] *Magnetic Preference Optimization*. 2024. URL: https://arxiv.org/abs/2410.16714.

[36] *MiniLLM: Knowledge Distillation of Large Language Models*. 2023. URL: https://arxiv.org/abs/2306.08543.

[37] *MInTRL: Off-Policy Intervention Can Boost On-Policy RL*. 2026. URL: https://arxiv.org/abs/2609.12419.

[38] *Mirror Descent Actor Critic via Bounded Advantage Learning*. 2025. URL: https://arxiv.org/abs/2502.03854.

[39] *MPO: An Efficient Post-Processing Framework for Mixing Diverse Preference Alignment*. 2025. URL: https://arxiv.org/abs/2502.18699.

[40] *Nash Learning from Human Feedback*. 2023. URL: https://arxiv.org/abs/2312.00886.

[41] *Near-Policy Distillation*. 2026. URL: https://arxiv.org/abs/2605.05940.

[42] *OAPL: LLMs Can Learn to Reason via Off-Policy RL*. 2026. URL: https://arxiv.org/abs/2602.19362.

[43] *On the Convergence of Natural Policy Gradient and Mirror Descent-Like Policy Methods for Average-Reward MDPs*. 2023. URL: https://doi.org/10.1109/CDC49753.2023.10383691.

[44] *On the Design of KL-Regularized Policy Gradient Algorithms for LLM Reasoning*. 2025. URL: https://arxiv.org/abs/2505.17508.

[45] *On the Geometry of On-Policy Distillation*. 2026. URL: https://arxiv.org/abs/2606.07082.

[46] *On the Position Bias of On-Policy Distillation*. 2026. URL: https://arxiv.org/abs/2606.22600.

[47] *On-Policy Context Distillation*. 2026. URL: https://arxiv.org/abs/2602.12275.

[48] *On-Policy Distillation*. 2025. URL: https://thinkingmachines.ai/blog/on-policy-distillation/.

[49] *On-Policy Distillation of Language Models*. 2023. URL: https://arxiv.org/abs/2306.13649.

[50] *On-policy Distillation with Verifiable Reward*. 2026. URL: https://arxiv.org/abs/2608.24696.

[51] *Optimal Convergence Rate for Exact Policy Mirror Descent in Discounted Markov Decision Processes*. 2023. URL: https://arxiv.org/abs/2302.11381.

[52] *Optimistic Natural Policy Gradient: A Simple Efficient Policy Optimization Framework for Online RL*. 2023. URL: https://arxiv.org/abs/2305.11032.

[53] Jan Peters and Stefan Schaal. *Natural Actor-Critic*. 2008. URL: https://doi.org/10.1016/j.neunet.2007.12.002.

[54] *Policy Mirror Descent Inherently Explores Action Space*. 2025. URL: https://doi.org/10.1137/23M1560215.

[55] *Policy Mirror Descent with Lookahead*. 2024. URL: https://arxiv.org/abs/2403.14156.

[56] *Policy Optimization with Stochastic Mirror Descent*. 2022. URL: https://doi.org/10.1609/aaai.v36i8.20863.

[57] *Policy Search using Dynamic Mirror Descent MPC for Model Free Off Policy RL*. 2021. URL: https://arxiv.org/abs/2110.12239.

[58] *Reference-Sampled Boltzmann Projection for KL-Regularized RLVR*. 2026. URL: https://arxiv.org/abs/2605.02469.

[59] *Reinforcement Learning by Reward-Weighted Regression for Operational Space Control*. 2007. URL: https://doi.org/10.1145/1273496.1273590.

[60] *Relative Entropy Policy Search*. 2010. URL: https://doi.org/10.1609/aaai.v24i1.7727.

[61] *Relative Entropy Regularized Policy Iteration*. 2018. URL: https://arxiv.org/abs/1812.02256.

[62] *Rethinking KL Regularization in RLHF: From Value Estimation to Gradient Optimization*. 2025. URL: https://arxiv.org/abs/2510.01555.

[63] *Revisiting On-Policy Distillation*. 2026. URL: https://arxiv.org/abs/2603.25562.

[64] *Sample-Efficient Policy Gradient Methods with Recursive Variance Reduction*. 2019. URL: https://arxiv.org/abs/1909.08610.

[65] John Schulman et al. *Trust Region Policy Optimization*. 2015. URL: https://arxiv.org/abs/1502.05477.

[66] *SEED: Self-Evolving On-Policy Distillation for Agentic Reinforcement Learning*. 2026. URL: https://arxiv.org/abs/2607.14777.

[67] *Self-Distilled Policy Gradient*. 2026. URL: https://arxiv.org/abs/2606.04036.

[68] *Supported Trust Region Optimization for Offline Reinforcement Learning*. 2023. URL: https://openreview.net/forum?id=F6gApN2CVs.

[69] *Teacher-Guided Policy Optimization for On-Policy Reasoning Distillation under Large Policy Divergence*. 2026. URL: https://arxiv.org/abs/2605.13230.

[70] *The Many Faces of On-Policy Distillation*. 2026. URL: https://arxiv.org/abs/2605.11182.

[71] Manan Tomar et al. *Mirror Descent Policy Optimization*. 2020. URL: https://arxiv.org/abs/2005.09814.

[72] *V-MPO: On-Policy Maximum a Posteriori Policy Optimization for Discrete and Continuous Control*. 2019. URL: https://arxiv.org/abs/1909.12238.

[73] *Variance Reduction on General Adaptive Stochastic Mirror Descent*. 2022. URL: https://doi.org/10.1007/s10994-022-06227-3.

[74] *VESPO: Variational Sequence-Level Soft Policy Optimization for Stable Off-Policy LLM Training*. 2026. URL: https://arxiv.org/abs/2602.10693.

[75] Zhengpeng Xie et al. *Trust Region Policy Distillation*. 2026. URL: https://arxiv.org/abs/2607.04751.

[76] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. URL: https://arxiv.org/abs/2602.05933.

[77] Wenhao Zhan et al. *Policy Mirror Descent for Regularized Reinforcement Learning: A Generalized Framework with Linear Convergence*. 2021. URL: https://arxiv.org/abs/2105.11066.

[78] Lunjun Zhang and Jimmy Ba. *EMA Policy Gradient*. 2026. URL: https://arxiv.org/abs/2602.04417.