MirrorOPD 核心推导

目标教师、内层拟合与参数性质

从加权散度最优化到 (κ, η) 镜像更新

正文阅读版；证明扩展见同源完整稿

MirrorOPD Research Notes

2026 年 10 月 15 日

阅读约定

本文研究固定前缀测度下的条件分布优化。每轮外层先冻结学生锚点，再由锚点与教师构造目标分布；内层用共享参数学生拟合这个目标，结束后刷新锚点。正文给出这条链上的定义、核心证明与适用条件；附录展开信息访问、估计、优化几何和多轮动力学。

镜像下降（Mirror Descent，MD）在概率空间通过局部线性目标与 Bregman 正则定义更新。本文沿用来源中的 MDPO、BPO、PMD-Part、PMD-Mean 名称，依次表示镜像目标优化、中心化残差回归、完整最优性方程回归和均值近似回归；第 3 章给出它们的精确定义。

精确分布更新、总体拟合目标、有限样本估计和神经网络参数更新是四个层次。定理在哪一层成立，就在哪一层表述。完整词表求和消除条件动作积分误差，仍保留前缀覆盖与模型表示误差。本文的解析结论不直接给出任务正确率排序。

记号	固定含义
$T, q_k, p_{k,n}$	教师、第 k 轮冻结锚点、第 n 步内层学生
m_k	该轮由最优化问题定义的目标教师
κ, η	目标形状、教师插值权重；正文取 $0 \le \kappa \le 1$, $0 < \eta < 1$
$\alpha_{\mathrm{opt}}, \tau$	参数优化器学习率、固定 $J_{\kappa,\eta}$ 后另选的镜像步长
$F_k, J_{\kappa,\eta}, L_k$	重心目标、教师目标、内层拟合损失
$A, f = \eta A, K_T$	标准化教师信号、指数中的信号、冻结教师中心
$C_q h = h - \mathbb{E}_q h$	按同一前缀的锚点分布中心化
$d_k, \widehat{d}_k$	总体、经验前缀访问测度
K_{head}, M, N	头部动作数、同前缀辅助动作数、内层步数

所有对数均为自然对数。$\mathrm{TV}(P,Q) = \frac{1}{2}\sum_a |P_a - Q_a|$；平方 Hellinger 距离固定为 $H^2(P,Q) = \sum_a (\sqrt{P_a} - \sqrt{Q_a})^2$，不带 $1/2$。向量方差表示协方差矩阵的迹。正文省略前缀条件时，所有分布仍条件于同一个前缀。

附录按数学依赖组织：A 给出测度和基础工具；B 完整识别教师目标；C 处理内层投影和优化；D 分析形状与矩；E 处理积分信息与估计；F 将中心估计接回拟合；G 分析外层误差与序列边界；H 比较 TOP-D 的目标教师。短阅读版与完整稿使用同一份正文源码。

目录

第一章 加权最优化与目标教师 **1**

1.1 每轮外层的最优化问题 1

1.2 唯一解与拟合误差 1

1.3 三个代表形状 2

第二章 教师目标与精确镜像更新 **3**

2.1 由目标分布识别教师信号 3

2.2 下降保证与参数角色 3

2.3 散度、教师目标与中心 4

第三章 固定目标教师的内层拟合 **5**

3.1 最优性方程与四种损失 5

3.2 精确梯度与采样测度 5

3.3 接入前缀与外层同步 6

第四章 形状与插值强度的性质 **7**

4.1 路径、覆盖与局部速度 7

4.2 监督尾部与方差阈值 7

4.3 平方根点的作用与限制 7

第五章 有限拟合与外层进展 **9**

5.1 从本轮拟合到教师接近度 9

5.2 拟合误差证书 9

5.3 有效保证的条件 9

参考文献 **10**

第一章 加权最优化与目标教师

1.1 每轮外层的最优化问题

固定一个前缀，词表 $\mathcal{V}$ 有限，$|\mathcal{V}| \geq 2$。教师 T 与本轮冻结学生 $q = q_k$ 都严格为正且归一化。先允许每个前缀的候选分布独立变化；参数化约束在第 3 章引入。令 Δ 为闭概率单纯形，Δ° 为其内部。

采用如下幂散度约定[1]：

$$D_\kappa(P\|Q) = \frac{1 - \sum_a P_a^\kappa Q_a^{1-\kappa}}{\kappa(1-\kappa)}, \qquad 0 < \kappa < 1. \tag{1.1}$$

两个连续端点为 $D_0(P\|Q) = \mathrm{KL}(Q\|P)$、$D_1(P\|Q) = \mathrm{KL}(P\|Q)$。因此以教师为第一自变量时，$\kappa = 0$ 给出学生逆向 KL，$\kappa = 1$ 给出学生正向 KL。

从一开始引入形状 $\kappa \in [0,1]$ 和教师权重 $\eta \in (0,1)$：

$$\boxed{m_k = \arg\min_{p \in \Delta} F_k(p), \qquad F_k(p) = (1-\eta) D_\kappa(q_k\|p) + \eta D_\kappa(T\|p).} \tag{1.2}$$

这个问题同时惩罚偏离锚点和偏离教师。η 指定两者的权重，κ 指定散度形状。所得 m_k 称为本轮目标教师；实际回复仍可由 q_k 生成。

1.2 唯一解与拟合误差

定理 1.1 (归一化幂均值目标)

对 $0 < \kappa \leq 1$，定义

$$h_a = [(1-\eta) q_a^\kappa + \eta T_a^\kappa]^{1/\kappa}, \qquad Z = \sum_a h_a, \qquad m_a = h_a / Z. \tag{1.3}$$

它是式 (1.2) 的唯一解。$\kappa = 0$ 的连续端点为 $m_a = q_a^{1-\eta} T_a^\eta / Z$。当 $0 < \kappa < 1$ 时，

$$F(p) - F(m) = Z^\kappa D_\kappa(m\|p). \tag{1.4}$$

端点 $\kappa = 0, 1$ 的超额损失分别为 $\mathrm{KL}(p\|m)$、$\mathrm{KL}(m\|p)$。 ♡

证明 令 $S_a = (1-\eta) q_a^\kappa + \eta T_a^\kappa$。对内点 p，

$$F(p) = \frac{1 - \sum_a S_a p_a^{1-\kappa}}{\kappa(1-\kappa)}, \quad \partial_{p_a} F = -\frac{S_a}{\kappa} p_a^{-\kappa}, \quad \partial^2_{p_a} F = S_a p_a^{-\kappa-1} > 0. \tag{1.5}$$

加入约束乘子 ν，一阶条件为 $S_a p_a^{-\kappa} = \kappa\nu$，归一化即得 $p = m$。为同时覆盖边界并证明全局唯一性，利用 $S_a = Z^\kappa m_a^\kappa$ 直接写出

$$F(p) = \frac{1 - Z^\kappa}{\kappa(1-\kappa)} + Z^\kappa D_\kappa(m\|p). \tag{1.6}$$

Hölder 不等式给出 $\sum_a m_a^\kappa p_a^{1-\kappa} \leq 1$，等号要求两个归一化向量相同；边界上也只有 $p = m$ 可以取等。因此得到唯一解与超额损失。

在 $\kappa = 0$ 时，展开加权 KL 得 $F(p) = \mathrm{KL}(p\|m) - \log Z$。在 $\kappa = 1$ 时，令 $m = (1-\eta)q + \eta T$，逐项相减得

$$F(p) - F(m) = \sum_a m_a \log(m_a / p_a). \tag{1.7}$$

两端的 KL 非负性给出相同的唯一性结论。最后对 q_a^κ, T_a^κ 在零处展开，得到 $\log h_a \to (1-\eta)\log q_a + \eta \log T_a$，证明连续端点。

---

[1] Andrzej Cichocki and Shun-ichi Amari. "Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities". In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

幂均值重心属于已有的 α 散度模型汇合框架[2]。本文使用它组织外层目标、内层投影与误差分析。最优化问题与拟合误差的精确关系是式 (1.4)，不只是一条最优点相同的结论。

1.3 三个代表形状

$$
\begin{aligned}
m_{0,\eta} &\propto q^{1-\eta} T^{\eta}, \\
m_{1/2,\eta} &\propto [(1-\eta)\sqrt{q} + \eta\sqrt{T}]^2, \\
m_{1,\eta} &= (1-\eta) q + \eta T.
\end{aligned}
\tag{1.8}
$$

几何端点在 log-odds 坐标中走直线；算术端点在概率坐标中走直线；平方根点在平方根概率单位球面上走短弧。η 对平方根点通常不是弧长比例。所有形状在 $\eta = 0, 1$ 分别到达 q, T，端点通过连续延拓理解。

只有算术端点的归一化常数恒为一。一般情况下不能删除 Z，也不能把幂均值目标当成概率的算术加权。其几何、覆盖界与多教师推广见完整稿附录 B、完整稿附录 D。

[2] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

第二章 教师目标与精确镜像更新

2.1 由目标分布识别教师信号

为解释外层在优化哪个教师目标，定义概率比函数

$$A_{\kappa,\eta}(x)=\begin{cases}\dfrac{\log(1-\eta+\eta x^{\kappa})}{\kappa\eta}, & \kappa>0,\\ \log x, & \kappa=0,\end{cases}\qquad f_a=\eta A_{\kappa,\eta}(T_a/q_a). \tag{2.1}$$

则 $q_a e^{f_a}=h_a$，目标教师写为 $m_a=q_a e^{f_a}/Z$。整个内层中 q,T,f,Z 冻结。

本轮重心目标 F_k 的最小点是 m_k。下面定义一个不依赖锚点、最小点为原教师 T 的目标。两个函数的作用不同。

定理 2.1 (教师目标的构造与镜像解释)

定义

$$\omega_{\kappa,\eta}(x)=x\int_1^x\frac{A_{\kappa,\eta}(u)}{u^2}\,du,\qquad J_{\kappa,\eta}(p;T)=\sum_a p_a\omega_{\kappa,\eta}(T_a/p_a). \tag{2.2}$$

则 $J\ge 0$，且在概率单纯形上唯一零点为 $p=T$。在正正交象限中，

$$\partial_{p_a}J(p;T)=-A_{\kappa,\eta}(T_a/p_a). \tag{2.3}$$

对 J 在 q 处执行步长 η 的负熵镜像下降，恰好得到目标教师：

$$\boxed{m=\arg\min_{p\in\Delta}\left\{\langle\nabla J(q;T),p-q\rangle+\eta^{-1}\,\mathrm{KL}(p\|q)\right\}.} \tag{2.4}$$

♡

证明 对积分求导，

$$\omega'(x)=\int_1^x A(u)u^{-2}\,du+A(x)/x, \tag{2.5}$$

$$\omega(x)-x\omega'(x)=-A(x), \tag{2.6}$$

$$\omega''(x)=A'(x)/x=\frac{x^{\kappa-2}}{1-\eta+\eta x^{\kappa}}>0. \tag{2.7}$$

最后一式在 $\kappa=0$ 时取 x^{-2}。由 $A(1)=0$，有 $\omega(1)=\omega'(1)=0$，所以严格凸的 ω 只在一处取零。正权重求和给出 $J\ge 0$，且 $J=0$ 要求 $T_a/p_a=1$ 对每个 a 成立。链式法则给出

$$\partial_{p_a}[p_a\omega(T_a/p_a)]=\omega(x)-x\omega'(x)=-A(x). \tag{2.8}$$

式 (2.4) 的一阶条件为 $-A(T_a/q_a)+\eta^{-1}[\log(p_a/q_a)+1]+\nu=0$。消去公共乘子并归一化，即得 $p_a\propto q_a e^{\eta A(T_a/q_a)}$。KL 正则严格凸，故解唯一。

2.2 下降保证与参数角色

负熵势记为 $\Phi(p)=\sum_a p_a\log p_a$。令 $x_a=T_a/p_a$，则

$$\nabla^2 J(p;T)=\mathrm{diag}\left(\frac{1}{p_a}\frac{x_a^{\kappa}}{1-\eta+\eta x_a^{\kappa}}\right)\preceq\eta^{-1}\nabla^2\Phi(p). \tag{2.9}$$

沿线段积分 Hessian，得到相对光滑不等式

$$J(p)\le J(q)+\langle\nabla J(q),p-q\rangle+\eta^{-1}\,\mathrm{KL}(p\|q). \tag{2.10}$$

镜像最优性条件与 $m-q$ 作内积，给出

$$\langle\nabla J(q),m-q\rangle=-\eta^{-1}[\mathrm{KL}(m\|q)+\mathrm{KL}(q\|m)]. \tag{2.11}$$

所以 $J(q)-J(m)\geq\eta^{-1}\,\mathrm{KL}(q\|m)$，非平凡精确更新严格下降。对同一条件分布反复精确刷新，三点恒等式进一步给出

$$J(q_K;T)\leq\frac{\mathrm{KL}(T\|q_0)}{\eta K}. \tag{2.12}$$

完整望远镜求和、边界排除和可变镜像步长证明见完整稿附录 B。

在整个递推中固定 κ,η,T，$J_{\kappa,\eta}$ 才是同一个函数。改变 η 一般同时改变目标形状和镜像步长。若要保持 J 不变而调整步长，应另用 τ，更新 $p^+\propto q\exp[\tau A_{\kappa,\eta}(T/q)]$。参数优化器的学习率 α_{opt} 又是第三个量。

2.3 散度、教师目标与中心

三个容易混用的对象分别是

$$D_\kappa(T\|p),\qquad J_{\kappa,\eta}(p;T),\qquad K_T(q,T)=-\mathbb{E}_q A_{\kappa,\eta}(T/q). \tag{2.13}$$

它们依次用于定义重心、解释精确镜像更新、中心化本轮监督。K_T 在内层冻结。端点关系为

$$J_{0,\eta}(p;T)=\mathrm{KL}(p\|T),\quad \lim_{\eta\downarrow0}J_{\kappa,\eta}(p;T)=D_\kappa(T\|p),\quad \lim_{\eta\uparrow1}J_{\kappa,\eta}(p;T)=\mathrm{KL}(p\|T). \tag{2.14}$$

当 $\kappa=1$、$0<\eta<1$，J 是归一化加权 JS，而 $D_1(T\|p)$ 是正向 KL。有限步幂均值一般不是对固定 D_κ 做同一步长的熵镜像下降；两者在小步极限才一阶一致。

第三章 固定目标教师的内层拟合

3.1 最优性方程与四种损失

本轮固定 q, T, m 与 $f = \eta A(T/q)$，当前学生为 $p = p_\theta$。记

$$U_a = \log(p_a/q_a), \qquad G = C_q f, \qquad K_S = \mathrm{KL}(q\|p) = -\mathbb{E}_q U, \qquad K_T = -\mathbb{E}_q A. \tag{3.1}$$

目标教师满足 $U^\star = f - \log Z$。将该方程转成可训练目标，有以下四种方式：

$$L_{\mathrm{MDPO}}(p) = \frac{1}{\eta}\{\mathrm{KL}(p\|q) - \mathbb{E}_p f\} = \frac{1}{\eta}\mathrm{KL}(p\|m) - \frac{\log Z}{\eta}, \tag{3.2}$$

$$L_{\mathrm{Part}}(p) = \frac{1}{2}\mathbb{E}_q(U - f + \log Z)^2, \tag{3.3}$$

$$L_{\mathrm{BPO}}(p) = \frac{1}{2\eta}\mathbb{E}_q[C_q(U-f)]^2 = \frac{1}{2\eta}\mathrm{Var}_q \log(p/m), \tag{3.4}$$

$$L_{\mathrm{Mean}}(p) = \frac{1}{2}\mathbb{E}_q(U - G)^2. \tag{3.5}$$

MDPO 保留原镜像子问题；Part 回归完整的对数比方程；BPO 回归中心化后的方程；Mean 用 $\mathbb{E}_q f$ 近似 $\log Z$。Mean 的定义与 PMD-mean 原始分析一致，整体损失尺度在此统一[1]。

命题 3.1 (共同目标与 Mean 的偏离)

在完整支持、精确期望和可实现的分布类中，MDPO、Part、BPO 的唯一最优分布均为 m。若 f 非恒定，Mean 的最优分布一般不等于 m。

证明 MDPO 的结论由式 (3.2) 的 KL 分解给出。Part 的零损失要求 $\log(p/m) = 0$。BPO 的零损失要求 $\log(p/m)$ 在全部动作上为常数，归一化再强制常数为零。

Mean 满足约束 $\mathbb{E}_q e^U = 1$，其拉格朗日一阶条件是

$$U_a - G_a + \lambda e^{U_a} = 0. \tag{3.6}$$

Gibbs 解满足 $U_a = G_a - \Delta$，其中 $\Delta = \log \mathbb{E}_q e^G > 0$。代入后要求 $\lambda e^{G_a - \Delta} = \Delta$ 对所有 a 成立；非恒定 G 使其不可能。Mean 的存在唯一性及 Lambert-W 解见完整稿附录 C。

Mean 与 BPO 的差异还可精确写成

$$L_{\mathrm{Mean}} = \eta L_{\mathrm{BPO}} + \frac{1}{2}K_S^2. \tag{3.7}$$

因为 $U - G = C_q(U - f) - K_S$，而第一项的 q 均值为零，平方交叉项消失。额外的 $K_S^2/2$ 改变最优分布与梯度；它不能当成不影响优化的常数。

3.2 精确梯度与采样测度

令 $\psi_a = \nabla_\theta \log p_\theta(a)$、$\bar\psi_q = \mathbb{E}_q\psi$，则 $\mathbb{E}_p\psi = 0$，但 $\bar\psi_q$ 通常不为零。定义

$$R_P = U - f + \log Z, \quad R_M = U - G, \quad R_B = C_q(U-f) = U + K_S - \eta(A + K_T). \tag{3.8}$$

直接求导得到

$$\nabla L_{\mathrm{Part}} = \mathbb{E}_q[R_P\psi], \qquad \nabla L_{\mathrm{Mean}} = \mathbb{E}_q[R_M\psi], \tag{3.9}$$

$$\nabla L_{\mathrm{BPO}} = \eta^{-1}\mathbb{E}_q[R_B(\psi - \bar\psi_q)] = \eta^{-1}\mathbb{E}_q[R_B\psi], \tag{3.10}$$

$$\nabla L_{\mathrm{MDPO}} = \eta^{-1}\mathbb{E}_p[(U-f)\psi] = \eta^{-1}\mathbb{E}_q[(p/q)(U-f)\psi]. \tag{3.11}$$

[1] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.

BPO 第二个等号使用 $\mathbb{E}_q R_B = 0$；MDPO 删除常数项使用 $\mathbb{E}_p \psi = 0$。这两次抵消发生在不同测度下。

完整词表求和时，可直接对真实损失求导。使用解析 score 形式时，把整个系数停止梯度，再乘以 $\log p_\theta(a)$，实现上述向量。这个代理标量的数值不等于真实损失。Part、Mean、BPO 的动作测度是 q，MDPO 的动作测度是 p；从 q 采样 MDPO 时需乘 p/q。

在 $p = q$ 处，BPO 和 MDPO 的梯度相同，Part、Mean 的梯度等于它们的 η 倍。离开锚点后，损失的度量、中心与测度不同，不能用起点相等推断整个轨迹相等。

3.3 接入前缀与外层同步

恢复条件变量 s，内层实际优化

$$\mathcal{L}_k(\theta) = \mathbb{E}_{s \sim d_k} L_k(p_\theta(\cdot \mid s)). \tag{3.12}$$

d_k 在本轮冻结；有限 rollout 用经验测度 $\widehat{d}_k$ 代替。教师信号 f, K_T 整轮冻结，学生中心 K_S 随每次参数更新重算。每个前缀的一条实际动作观测，不等于该前缀全部动作的期望；辅助动作抽样与新增完整回复是两种不同操作。

Algorithm 1 固定前缀的 MirrorOPD

Semantics: 根据条件目标重构；动作期望使用完整词表

Require: teacher T, initial student θ_0, $\kappa \in [0, 1]$, $0 < \eta < 1$, finite budgets K, N

for $k = 0, \ldots, K-1$ **do**
  $q_k \leftarrow p_{\theta_k}$; freeze q_k
  sample prompts and one response per prompt from q_k with full action support
  form $\widehat{d}_k$ from valid response tokens, including EOS
  if the batch has no valid response tokens **then**
    terminate with an invalid-batch error
  end if
  cache frozen $f_k = \mathrm{stopgrad}(\eta A_{\kappa,\eta}(T/q_k))$ and required teacher integrals
  $\theta_{k,0} \leftarrow \theta_k$
  for $n = 0, \ldots, N-1$ **do**
    recompute $p_{\theta_{k,n}}$ and all student-dependent integrals
    $g_{k,n} \leftarrow \nabla_\theta \mathbb{E}_{\widehat{d}_k} L_k(p_{\theta_{k,n}})$
    $\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  $\theta_{k+1} \leftarrow \theta_{k,N}$; discard the old rollout for the next outer
end for
return θ_K

算法以普通梯度下降明确更新语义。替换为其他优化器时，目标定义保持不变，数值轨迹需另行分析。共享参数可能无法同时表示所有 $m_k(\cdot \mid s)$；此时三种具有相同自由分布解的方法，也可能具有不同的受限投影。

第四章 形状与插值强度的性质

4.1 路径、覆盖与局部速度

固定 q, T 时，η 从零增加到一，把目标教师从锚点移向教师。对固定 κ，任意凸生成散度 $D_\varphi(m_{\kappa,\eta}\|q)$ 随 η 非减；不同 κ 下，相同 η 不代表相同距离。其交点证明见完整稿附录 D。

正形状有一个分布无关的覆盖保证：

$$m_a \geq (1-\eta)^{1/\kappa} q_a + \eta^{1/\kappa} T_a, \qquad 0 < \kappa \leq 1. \tag{4.1}$$

证明使用 $h_a \leq (1-\eta)q_a + \eta T_a$，故 $Z \leq 1$；以及 $(x+y)^{1/\kappa} \geq x^{1/\kappa} + y^{1/\kappa}$。于是 $m_a = h_a/Z \geq h_a$ 给出下界。几何端点没有统一的正教师覆盖系数。

对固定严格正分布，小步展开为

$$m_a = q_a + \eta v_{\kappa,a} + O(\eta^2), \qquad v_{\kappa,a} = \frac{q_a}{\kappa}\left[(T_a/q_a)^\kappa - \mathbb{E}_q(T/q)^\kappa\right]. \tag{4.2}$$

$\kappa = 0$ 时取连续极限 $v_{0,a} = q_a C_q \log(T_a/q_a)$。这是 $D_\kappa(T\|q)$ 在 Fisher 度量下的负自然梯度。形状改变高维方向，不能通常由一个学习率缩放替代。

4.2 监督尾部与方差阈值

当 $\kappa > 0, \eta < 1$ 时，

$$A_{\kappa,\eta}(x) \geq -c_{\kappa,\eta}, \qquad c_{\kappa,\eta} = -\frac{\log(1-\eta)}{\kappa\eta}. \tag{4.3}$$

正尾部仍无逐点统一上界，但在 q 下利用 $\mathbb{E}_q(T/q) = 1$ 可以控制矩。令 $V_{\kappa,\eta} = \mathrm{Var}_q\, A_{\kappa,\eta}(T/q)$。对每个固定正 $\eta < 1$ 和 $\kappa > 0$，V 在所有有限正概率分布上有统一有限上界。

更强的小步问题需要另一个结论：

$$\sup_{q,T} V_{\kappa,\eta} = \Theta_\kappa\left(\eta^{\min\{2,1/\kappa\}-2}\right), \qquad \eta \downarrow 0, \quad \kappa > 0. \tag{4.4}$$

所以保持统一小步方差有界的区间为 $0 < \kappa \leq 1/2$。几何端点对任意固定正 η 都没有分布无关界。这里上确界允许分布随 η 改变；固定一对正分布时，每种形状的小步极限都有限。

对 $0 < \kappa \leq 1/2$，还有误差相关界

$$V_{\kappa,\eta} \leq \frac{D_\kappa(T\|q)}{\kappa(1-\eta)^2} \leq \frac{K_T}{\kappa(1-\kappa)(1-\eta)^2}. \tag{4.5}$$

若 score 范数统一不超过 S，中心化教师梯度的协方差迹不超过 S^2V。标量监督方差与完整参数梯度方差由这个额外条件连接；精确均值中心本身不保证 score 梯度的方差最小。

4.3 平方根点的作用与限制

令 $a = \sum_v \sqrt{q_v T_v}$、$w = 1-\eta$。平方根目标满足

$$\sqrt{m} = \frac{w\sqrt{q} + \eta\sqrt{T}}{\sqrt{Z}}, \qquad Z = w^2 + \eta^2 + 2w\eta a. \tag{4.6}$$

因为 $Z \leq 1$，

$$\sum_v \sqrt{m_v T_v} = \frac{wa+\eta}{\sqrt{Z}} \geq wa + \eta, \quad H^2(m,T) \leq (1-\eta)H^2(q,T). \tag{4.7}$$

这是精确分布更新的全局收缩。所有形状在固定正教师附近却共享

$$m_{\kappa,\eta}(T+\delta, T) = T + (1-\eta)\delta + O(\|\delta\|^2). \tag{4.8}$$

因此平方根的全局 Hellinger 保证不代表更好的局部一阶概率收缩率。

平方根点唯一最小化小步监督方差相对于自身教师散度的最坏比值；若改为最小化绝对最坏方差，最优形状约为 0.441928。两种准则的推导在完整稿附录 D。固定 q, η 时，BPO 的独立 logits Hessian 为

$$\nabla_z^2 L_{\mathrm{BPO}} = \eta^{-1}[\mathrm{diag}(q) - qq^\top], \tag{4.9}$$

其中不含 κ。形状改变目标和初始残差，不能由此宣称改善该二次问题的条件数。

第五章 有限拟合与外层进展

5.1 从本轮拟合到教师接近度

定理 5.1 (重心进展恒等式)

对任意候选 p，令 $c_\kappa = Z^\kappa$，端点 $\kappa = 0, 1$ 取 $c_\kappa = 1$，则

$$\eta[D_\kappa(T\|q) - D_\kappa(T\|p)] = (1-\eta)D_\kappa(q\|p) + c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]. \tag{5.1}$$

因此 $D_\kappa(m\|p) \le D_\kappa(m\|q)$ 是教师散度非增的充分条件。精确更新 $p = m$ 在 $q \neq T$ 时严格改善。 ♡

证明 重心定义给出 $F(q) = \eta D_\kappa(T\|q)$。另一方面，定理 1.1 给出 $F(q) - F(p) = c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]$。代入 $F(p)$ 并移项得到恒等式。条件成立时右侧两项非负。若 $p = m$ 且 $q \neq T$，则 $m \neq q$，右侧第一项严格为正。

精确幂均值更新还有更强性质：它同时降低所有凸生成的教师 f-散度。证明使用概率比的共同交点，见完整稿附录 D。有限 inner 降低某个拟合损失却不足以自动继承这一性质。

5.2 拟合误差证书

MDPO 的超额损失 δ 精确对应 $\mathrm{KL}(p\|m) = \eta\delta$，由 Pinsker 不等式得到 $\mathrm{TV}(p, m) \le \sqrt{\eta\delta/2}$。BPO 控制的是按 q 加权的对数比方差。若另有 $q_a \ge q_{\min} > 0$，则

$$d_H(p, m) := \operatorname{osc}_a \log(p_a/m_a) \le 2\sqrt{\eta L_{\mathrm{BPO}}/q_{\min}}, \quad \mathrm{TV}(p, m) \le \tanh[d_H(p, m)/4]. \tag{5.2}$$

最小锚点概率极小时，这个证书可能很弱；推导与锐 TV 界见完整稿附录 A、完整稿附录 G。

这种限制确实会发生。取

$$q = (0.4999995, 0.4999995, 10^{-6}), \quad T = (0.8, 0.199999, 10^{-6}), \quad \kappa = \tfrac{1}{2}, \quad \eta = 0.3, \tag{5.3}$$

并令 $p \propto m \exp(0, 0, 12)$。直接求和得到

$$L_{\mathrm{BPO}}(q) \simeq 0.062277, \quad L_{\mathrm{BPO}}(p) \simeq 0.000240, \quad \mathrm{KL}(q\|T) \simeq 0.223145, \quad \mathrm{KL}(p\|T) \simeq 1.654219. \tag{5.4}$$

稀有动作的对数误差在 q 下权重很小，却可以改变归一化后的学生质量。因此需要区分 loss 下降与目标教师拟合证书。

5.3 有效保证的条件

从 q 出发，使用精确锚点 Fisher 预条件的 BPO 产生理想路径

$$p_\xi \propto q \exp(\xi f), \qquad 0 \le \xi \le 1. \tag{5.5}$$

沿这条路径，所有凸生成的教师散度非增。该结论依赖路径、完整期望与自由 logits；普通神经网络优化器不自动位于这条路径上，证明见完整稿附录 C。

固定教师的精确外层收敛，允许通过输出误差递推扩展到近似拟合。应先由内层损失、中心误差和表示限制建立输出误差，再分析多轮累积；梯度估计的方差不能直接替代输出误差。

最后，正文的目标是固定前缀测度下的条件目标。完整序列 KL 使用随策略变化的访问权重；条件 KL 逐前缀下降，也可能同时让学生更频繁进入误差较大的分支。序列反例、后缀价值修正和同步边界见完整稿附录 G。TOP-D 的目标教师由算术端点精确恢复，其收缩与方差性质见完整稿附录 H。

参考文献

[1] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

[2] Andrzej Cichocki and Shun-ichi Amari. “Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities”. In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

[3] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.