MirrorOPD 核心推导

目标教师、内层拟合与参数性质

从镜像子问题、优势信号到加权教师与目标 J

正文阅读版；证明扩展见同源完整稿

MirrorOPD Research Notes

2026 年 10 月 15 日

阅读约定

本文从每轮外层的 Mirror Descent 子问题出发，依次定义冻结信号 f 与 advantage，求出加权教师 m 的显式表达式，再反推产生该镜像方向的教师目标 J。前三章完成这条推导；第四章介绍 inner 如何拟合已经确定的 m，第五、六章分析参数性质与有限拟合。附录对每项独立结论先陈述命题与条件，再给完整证明。

镜像下降（Mirror Descent，MD）在概率空间通过局部线性目标与 Bregman 正则定义更新。本文沿用来源中的 MDPO、BPO、PMD-Part、PMD-Mean 名称，依次表示镜像目标优化、中心化残差回归、完整最优性方程回归和均值近似回归；第 4 章给出它们的精确定义。

精确分布更新、总体拟合目标、有限样本估计和神经网络参数更新是四个层次。定理在哪一层成立，就在哪一层表述。完整词表求和消除条件动作积分误差，仍保留前缀覆盖与模型表示误差。本文的解析结论不直接给出任务正确率排序。

记号	固定含义
$T, q_k, p_{k,n}$	教师、第 k 轮冻结锚点、第 n 步内层学生
m_k	该轮由最优化问题定义的目标教师
κ, η	目标形状、教师插值权重；正文取 $0 \le \kappa \le 1$, $0 < \eta < 1$
$\alpha_{\mathrm{opt}}, \tau$	参数优化器学习率、固定 $J_{\kappa,\eta}$ 后另选的镜像步长
$F_k, J_{\kappa,\eta}, L_k$	重心目标、教师目标、内层拟合损失
$f, A = f/\eta, K_T$	冻结信号、标准化教师信号、冻结教师中心
$\mathcal{A}_k = C_q A$	本轮零条件均值的 advantage；$g_k = -\mathcal{A}_k$
$C_q h = h - \mathbb{E}_q h$	按同一前缀的锚点分布中心化
$d_k, \widehat{d}_k$	总体、经验前缀访问测度
K_{head}, M, N	头部动作数、同前缀辅助动作数、内层步数

所有对数均为自然对数。$\mathrm{TV}(P,Q) = \frac{1}{2}\sum_a |P_a - Q_a|$；平方 Hellinger 距离固定为 $H^2(P,Q) = \sum_a (\sqrt{P_a} - \sqrt{Q_a})^2$，不带 $1/2$。向量方差表示协方差矩阵的迹。正文省略前缀条件时，所有分布仍条件于同一个前缀。

附录按数学依赖组织：A 给出测度和基础工具；B 完整识别教师目标；C 处理内层投影和优化；D 分析形状与矩；E 处理积分信息与估计；F 将中心估计接回拟合；G 分析外层误差与序列边界；H 比较 TOP-D 的目标教师。短阅读版与完整稿使用同一份正文源码。

目录

第一章 Mirror Descent 与冻结监督 **1**
1.1 每轮外层的镜像下降问题 1
1.2 信号 f 与 advantage 1

第二章 加权教师的显式解 **2**
2.1 从镜像子问题到 Gibbs 分布 2
2.2 代入信号得到归一化幂均值 2
2.3 代表形状与归一化 3

第三章 从教师信号反推出目标 J **4**
3.1 目标梯度需要满足的关系 4
3.2 积分构造与严格凸性 4
3.3 下降保证与 J 的端点 5
3.4 加权散度重心的等价解释 5

第四章 固定目标教师的内层拟合 **6**
4.1 最优性方程与四种损失 6
4.2 精确梯度与采样测度 6
4.3 接入前缀与外层同步 7

第五章 形状与插值强度的性质 **8**
5.1 路径、覆盖与局部速度 8
5.2 监督尾部与方差阈值 8
5.3 平方根点的作用与限制 8

第六章 有限拟合与外层进展 **10**
6.1 从本轮拟合到教师接近度 10
6.2 拟合误差证书 10
6.3 有效保证的条件 10

参考文献 **11**

第一章 Mirror Descent 与冻结监督

1.1 每轮外层的镜像下降问题

固定一个前缀，有限词表上的教师 T 与本轮学生锚点 $q = q_k$ 严格为正且归一化。令 Δ 为概率单纯形，取形状参数 $\kappa \in [0,1]$、镜像步长 $\eta \in (0,1)$。这一轮先在分布空间求解

$$\boxed{m_k = \arg\min_{p\in\Delta} \left\{ \langle g_k, p - q_k\rangle + \frac{1}{\eta}\,\mathrm{KL}(p\|q_k) \right\}.} \tag{1.1}$$

这是负熵几何下的镜像下降（Mirror Descent，MD）子问题。g_k 是整轮冻结的梯度代表；下面通过教师信号指定它，再于第 3 章推导产生这个梯度的教师目标 J。

负熵势为 $\Phi(p) = \sum_a p_a \log p_a$。其 Bregman 散度逐项展开为

$$D_\Phi(p,q) = \Phi(p) - \Phi(q) - \langle \nabla\Phi(q), p - q\rangle \tag{1.2}$$

$$= \sum_a p_a \log(p_a/q_a) - \sum_a (p_a - q_a) = \mathrm{KL}(p\|q). \tag{1.3}$$

因此式 (1.1) 的第二项来自负熵镜像几何。κ 将进入 g_k 的教师信号；η 同时出现在信号族与镜像正则中。它们都不同于后面参数优化器的学习率。

1.2 信号 f 与 advantage

记冻结的教师–锚点概率比与对数比为

$$\rho_a = T_a/q_a, \qquad r_a = \log \rho_a. \tag{1.4}$$

对给定的 κ, η，定义冻结信号

$$f_{\kappa,\eta}(r) = \begin{cases} \kappa^{-1}\log(1 - \eta + \eta e^{\kappa r}), & \kappa > 0, \\ \eta r, & \kappa = 0, \end{cases} \qquad f_a = f_{\kappa,\eta}(r_a). \tag{1.5}$$

这个定义指定了要学习的方向。镜像下降子问题规定更新几何，本身不唯一决定教师信号的形式。

为了明确步长尺度，再定义标准化信号 $A_{\kappa,\eta}$、冻结中心 K_T，以及按锚点中心化的优势信号（advantage）$\mathcal{A}_k$：

$$A_{\kappa,\eta}(x) = \frac{f_{\kappa,\eta}(\log x)}{\eta}, \qquad x > 0, \tag{1.6}$$

$$K_T(q,T) = -\mathbb{E}_q A_{\kappa,\eta}(T/q), \tag{1.7}$$

$$\mathcal{A}_k(a) = A_{\kappa,\eta}(T_a/q_a) + K_T = \frac{f_a - \mathbb{E}_q f}{\eta}. \tag{1.8}$$

于是 $\mathbb{E}_q \mathcal{A}_k = 0$。本文的 advantage 是固定前缀上的中心化教师信号；此处不额外引入序列价值函数。$f, A, \mathcal{A}_k, K_T$ 均由本轮冻结的 q_k, T 计算，内层不随当前学生改变。

现在令 $g_k = -\mathcal{A}_k$。去掉与候选 p 无关的常数，镜像子问题等价于

$$\boxed{m_k = \arg\max_{p\in\Delta} \left\{ \mathbb{E}_p \mathcal{A}_k - \frac{1}{\eta}\,\mathrm{KL}(p\|q_k) \right\}.} \tag{1.9}$$

代入 $\mathcal{A}_k = (f - \mathbb{E}_q f)/\eta$，得到另一个完全等价的形式：

$$m_k = \arg\min_{p\in\Delta} \frac{1}{\eta}\left\{ \mathrm{KL}(p\|q_k) - \mathbb{E}_p f \right\}. \tag{1.10}$$

因为 $\mathbb{E}_q f$ 与动作、候选分布都无关，中心化只改变目标值的常数。下一章从这个最优化问题求出 m_k 的归一化表达式。

第二章 加权教师的显式解

2.1 从镜像子问题到 Gibbs 分布

定理 2.1 (镜像子问题的唯一目标教师)

给定有限词表上的正锚点 q、有限冻结信号 f 和 $\eta>0$，式 (1.10) 的唯一解为

$$m_a=\frac{q_a e^{f_a}}{Z},\qquad Z=\sum_b q_b e^{f_b},\qquad \log(m_a/q_a)=f_a-\log Z. \tag{2.1}$$

若 $\mathcal{A}=(f-\mathbb{E}_q f)/\eta$，则同一分布也写成

$$m_a=\frac{q_a e^{\eta\mathcal{A}_a}}{Z_{\mathcal{A}}},\qquad Z_{\mathcal{A}}=e^{-\mathbb{E}_q f}Z. \tag{2.2}$$

对任意 $p\in\Delta$，镜像损失具有精确分解

$$\frac{\mathrm{KL}(p\|q)-\mathbb{E}_p f}{\eta}=\frac{\mathrm{KL}(p\|m)-\log Z}{\eta}. \tag{2.3}$$

♡

证明 对概率归一化加入乘子 ν，内点一阶条件为

$$\frac{\log(p_a/q_a)+1-f_a}{\eta}+\nu=0. \tag{2.4}$$

因此 $p_a=q_a e^{f_a}e^{-1-\eta\nu}$。求和等于一，便得到式 (2.1)。再利用

$$\log(p_a/m_a)=\log(p_a/q_a)-f_a+\log Z, \tag{2.5}$$

按 p 求和，即得式 (2.3)。KL 非负且仅在两分布相等时为零，所以该内点解也是闭单纯形上的唯一全局解。

中心化后，$e^{\eta\mathcal{A}_a}=e^{f_a-\mathbb{E}_q f}$。分子与配分函数同乘 $e^{-\mathbb{E}_q f}$，因此归一化分布不变。

2.2 代入信号得到归一化幂均值

将第一章定义的 $f_{\kappa,\eta}$ 代入。对 $\kappa>0$，

$$q_a e^{f_a}=q_a\left[1-\eta+\eta(T_a/q_a)^{\kappa}\right]^{1/\kappa} \tag{2.6}$$

$$=\left[(1-\eta)q_a^{\kappa}+\eta T_a^{\kappa}\right]^{1/\kappa}. \tag{2.7}$$

因此每轮要拟合的加权教师是

$$\boxed{m_{\kappa,\eta}(a;q,T)=\frac{\left[(1-\eta)q_a^{\kappa}+\eta T_a^{\kappa}\right]^{1/\kappa}}{\sum_b\left[(1-\eta)q_b^{\kappa}+\eta T_b^{\kappa}\right]^{1/\kappa}}.} \tag{2.8}$$

记分子为 h_a，则 $Z=\sum_a h_a$。这一步从镜像最优性条件推出显式目标；m 在整轮内层中冻结，实际学生 $p_{k,n}$ 用有限次更新逼近它。

在几何端点 $\kappa=0$，直接代入 $f_a=\eta\log(T_a/q_a)$，得到

$$m_{0,\eta}(a)=\frac{q_a^{1-\eta}T_a^{\eta}}{\sum_b q_b^{1-\eta}T_b^{\eta}}. \tag{2.9}$$

它也是式 (2.8) 的连续极限：对固定正分布，$q_a^{\kappa}=1+\kappa\log q_a+O(\kappa^2)$，同样展开 T_a^{κ}，再对加权和取对数、除以 κ，得到 $(1-\eta)\log q_a+\eta\log T_a+O(\kappa)$。

2.3 代表形状与归一化

$$
\begin{aligned}
m_{0,\eta} &\propto q^{1-\eta} T^{\eta}, \\
m_{1/2,\eta}(a) &= \frac{[(1-\eta)\sqrt{q_a} + \eta\sqrt{T_a}]^2}{(1-\eta)^2 + \eta^2 + 2\eta(1-\eta)\sum_b \sqrt{q_b T_b}}, \\
m_{1,\eta} &= (1-\eta)q + \eta T.
\end{aligned}
\tag{2.10}
$$

几何端点在 log-odds 坐标中作加权；平方根点先加权平方根概率再归一化；算术端点直接加权概率，且 $Z = 1$。所有形状在 $\eta \downarrow 0$ 时回到 q，在 $\eta \uparrow 1$ 时到达 T。

至此，镜像子问题、教师信号、advantage 和加权教师都有了明确表达式。下一章保留同一个信号，推导一个以 T 为最优点的教师目标 $J_{\kappa,\eta}$，说明该镜像步究竟下降什么函数。

第三章 从教师信号反推出目标 J

3.1 目标梯度需要满足的关系

第一章用 $g_k=-\mathcal{A}_k$ 指定了镜像方向。由于 $\mathcal{A}_k=A_{\kappa,\eta}(T/q_k)+K_T$，这个向量与 $-A_{\kappa,\eta}(T/q_k)$ 只相差公共常数。对任意可行概率差 $p-q_k$，常数项的内积为零。因此寻找教师目标时，只需满足

$$\partial_{p_a} J_{\kappa,\eta}(p;T)=-A_{\kappa,\eta}(T_a/p_a). \tag{3.1}$$

现在的 p 是定义全局条件目标的变量；它与只在本轮取值的锚点 q_k 分开。目标一旦由 κ,η,T 确定，就不再依赖本轮锚点。

3.2 积分构造与严格凸性

在可分离的散度形式中寻找

$$J_{\kappa,\eta}(p;T)=\sum_a p_a\omega_{\kappa,\eta}(T_a/p_a). \tag{3.2}$$

令 $x=T_a/p_a$，链式法则给出

$$\partial_{p_a}[p_a\omega(x)]=\omega(x)-x\omega'(x). \tag{3.3}$$

所以所需生成函数满足 $\omega-x\omega'=-A$，等价于 $(\omega/x)'=A(x)/x^2$。选取规范化条件 $\omega(1)=0$，积分得到

$$\boxed{\omega_{\kappa,\eta}(x)=x\int_1^x\frac{A_{\kappa,\eta}(u)}{u^2}\,du,\qquad J_{\kappa,\eta}(p;T)=\sum_a p_a\omega_{\kappa,\eta}(T_a/p_a).} \tag{3.4}$$

定理 3.1 (该镜像步对应的教师目标)

对固定 $\kappa\in[0,1]$、$0<\eta<1$ 和正教师 T，式 (3.4) 的生成函数满足 $\omega(1)=\omega'(1)=0$、$\omega''(x)>0$。目标 J 非负、在正单纯形上的唯一最优点为 T，并满足式 (3.1)。第一章的镜像子问题因而等价于

$$m_k=\arg\min_{p\in\Delta}\left\{\langle\nabla J_{\kappa,\eta}(q_k;T),p-q_k\rangle+\eta^{-1}\,\mathrm{KL}(p\|q_k)\right\}, \tag{3.5}$$

其精确解就是第二章的 $m_{\kappa,\eta}$。♡

证明 对积分式求导：

$$\omega'(x)=\int_1^x A(u)u^{-2}\,du+A(x)/x, \tag{3.6}$$

$$\omega(x)-x\omega'(x)=-A(x), \tag{3.7}$$

$$\omega''(x)=\frac{A'(x)}{x}=\frac{x^{\kappa-2}}{1-\eta+\eta x^{\kappa}}>0. \tag{3.8}$$

在 $\kappa=0$ 时最后一式取 x^{-2}。$A(1)=0$ 给出 $\omega'(1)=0$。严格凸性使 ω 在一处唯一取最小值零，所以正权重和 J 仅在每个 $T_a/p_a=1$ 时为零。透视函数的 Hessian 对角元为 $x_aA'(x_a)/p_a>0$，故 J 也严格凸。

梯度由第二个等式与链式法则得到。在 q_k 处，

$$g_k=-\mathcal{A}_k=\nabla J(q_k;T)-K_T\mathbf{1}. \tag{3.9}$$

两梯度代表与 $p-q_k$ 的内积相同，因此产生同一个镜像问题；其解已由定理 2.1 求出。

3.3 下降保证与 J 的端点

令 $\Phi(p)=\sum_a p_a\log p_a$、$x_a=T_a/p_a$。由上述 Hessian，

$$\nabla^2 J(p;T)=\operatorname{diag}\left(\frac{1}{p_a}\frac{x_a^\kappa}{1-\eta+\eta x_a^\kappa}\right)\preceq \eta^{-1}\nabla^2\Phi(p). \tag{3.10}$$

沿线段积分并使用镜像最优性条件，得到

$$J(q;T)-J(m;T)\geq \eta^{-1}\,\mathrm{KL}(q\|m). \tag{3.11}$$

对同一条件分布反复精确刷新锚点，进一步有

$$J(q_K;T)\leq \frac{\mathrm{KL}(T\|q_0)}{\eta K}. \tag{3.12}$$

完整下降、三点恒等式和收敛证明见完整稿附录 B。

这组教师目标在端点满足

$$J_{0,\eta}(p;T)=\mathrm{KL}(p\|T), \tag{3.13}$$

$$\lim_{\eta\downarrow 0} J_{\kappa,\eta}(p;T)=D_\kappa(T\|p), \tag{3.14}$$

$$J_{1,\eta}(p;T)=\frac{\mathrm{JS}_\eta(p,T)}{\eta(1-\eta)},\qquad \lim_{\eta\uparrow 1} J_{\kappa,\eta}(p;T)=\mathrm{KL}(p\|T). \tag{3.15}$$

这里 $\mathrm{JS}_\eta(p,T)=(1-\eta)\,\mathrm{KL}(p\|M_p)+\eta\,\mathrm{KL}(T\|M_p)$，$M_p=(1-\eta)p+\eta T$。每个固定 κ,η 定义一个 J；改变 η 一般也改变目标。若在同一个 J 上单独调整镜像步长，应另用 τ，保留信号 $A_{\kappa,\eta}$ 并更新 $p^+\propto qe^{\tau A_{\kappa,\eta}(T/q)}$。

3.4 加权散度重心的等价解释

已经由镜像问题得到的 m，还具有一个用于误差分析的重心解释。定义幂散度[1]

$$D_\kappa(P\|Q)=\frac{1-\sum_a P_a^\kappa Q_a^{1-\kappa}}{\kappa(1-\kappa)},\quad D_0(P\|Q)=\mathrm{KL}(Q\|P),\quad D_1(P\|Q)=\mathrm{KL}(P\|Q). \tag{3.16}$$

该归一化幂均值也是加权散度问题的唯一解[2]：

$$m=\arg\min_{p\in\Delta} F_k(p),\qquad F_k(p)=(1-\eta)D_\kappa(q_k\|p)+\eta D_\kappa(T\|p). \tag{3.17}$$

其超额损失为

$$F_k(p)-F_k(m)=Z^\kappa D_\kappa(m\|p),\qquad 0<\kappa<1. \tag{3.18}$$

两个端点分别为 $\mathrm{KL}(p\|m)$ 与 $\mathrm{KL}(m\|p)$。完整定理及证明见完整稿附录 B。F_k 的最优点是本轮 m_k，$J_{\kappa,\eta}$ 的最优点是原教师 T；后面的 inner 损失用于将参数化学生拟合到已经确定的 m_k。

[1] Andrzej Cichocki and Shun-ichi Amari. “Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities”. In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

[2] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

第四章 固定目标教师的内层拟合

4.1 最优性方程与四种损失

前三章已从镜像子问题得到信号、advantage、目标教师 m 及其教师目标 J。内层固定 q, T, m 与 $f = \eta A(T/q)$，只优化当前学生 $p = p_\theta$。记

$$U_a = \log(p_a/q_a), \qquad G = C_q f = \eta \mathcal{A}_k, \qquad K_S = \mathrm{KL}(q\|p) = -\mathbb{E}_q U, \qquad K_T = -\mathbb{E}_q A. \tag{4.1}$$

目标教师满足 $U^\star = f - \log Z$。将该方程转成可训练目标，有以下四种方式：

$$L_{\mathrm{MDPO}}(p) = \frac{1}{\eta}\{\mathrm{KL}(p\|q) - \mathbb{E}_p f\} = \frac{1}{\eta}\,\mathrm{KL}(p\|m) - \frac{\log Z}{\eta}, \tag{4.2}$$

$$L_{\mathrm{Part}}(p) = \frac{1}{2}\mathbb{E}_q(U - f + \log Z)^2, \tag{4.3}$$

$$L_{\mathrm{BPO}}(p) = \frac{1}{2\eta}\mathbb{E}_q[C_q(U - f)]^2 = \frac{1}{2\eta}\,\mathrm{Var}_q \log(p/m), \tag{4.4}$$

$$L_{\mathrm{Mean}}(p) = \frac{1}{2}\mathbb{E}_q(U - G)^2. \tag{4.5}$$

MDPO 保留原镜像子问题；Part 回归完整的对数比方程；BPO 回归中心化后的方程；Mean 用 $\mathbb{E}_q f$ 近似 $\log Z$。Mean 的定义与 PMD-mean 原始分析一致，整体损失尺度在此统一[1]。

命题 4.1 (共同目标与 Mean 的偏离)

在完整支持、精确期望和可实现的分布类中，MDPO、Part、BPO 的唯一最优分布均为 m。若 f 非恒定，Mean 的最优分布一般不等于 m。

证明 MDPO 的结论由式 (4.2) 的 KL 分解给出。Part 的零损失要求 $\log(p/m) = 0$。BPO 的零损失要求 $\log(p/m)$ 在全部动作上为常数，归一化再强制常数为零。

Mean 满足约束 $\mathbb{E}_q e^U = 1$，其拉格朗日一阶条件是

$$U_a - G_a + \lambda e^{U_a} = 0. \tag{4.6}$$

Gibbs 解满足 $U_a = G_a - \Delta$，其中 $\Delta = \log \mathbb{E}_q e^G > 0$。代入后要求 $\lambda e^{G_a - \Delta} = \Delta$ 对所有 a 成立；非恒定 G 使其不可能。Mean 的存在唯一性及 Lambert-W 解见完整稿附录 C。

Mean 与 BPO 的差异还可精确写成

$$L_{\mathrm{Mean}} = \eta L_{\mathrm{BPO}} + \frac{1}{2}K_S^2. \tag{4.7}$$

因为 $U - G = C_q(U - f) - K_S$，而第一项的 q 均值为零，平方交叉项消失。额外的 $K_S^2/2$ 改变最优分布与梯度；它不能当成不影响优化的常数。

4.2 精确梯度与采样测度

令 $\psi_a = \nabla_\theta \log p_\theta(a)$、$\bar{\psi}_q = \mathbb{E}_q \psi$，则 $\mathbb{E}_p \psi = 0$，但 $\bar{\psi}_q$ 通常不为零。定义

$$R_P = U - f + \log Z, \quad R_M = U - G, \quad R_B = C_q(U - f) = U + K_S - \eta \mathcal{A}_k = U + K_S - \eta(A + K_T). \tag{4.8}$$

[1] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.

直接求导得到

$$\nabla L_{\mathrm{Part}} = \mathbb{E}_q[R_P\psi], \qquad \nabla L_{\mathrm{Mean}} = \mathbb{E}_q[R_M\psi], \tag{4.9}$$

$$\nabla L_{\mathrm{BPO}} = \eta^{-1}\mathbb{E}_q[R_B(\psi - \bar{\psi}_q)] = \eta^{-1}\mathbb{E}_q[R_B\psi], \tag{4.10}$$

$$\nabla L_{\mathrm{MDPO}} = \eta^{-1}\mathbb{E}_p[(U-f)\psi] = \eta^{-1}\mathbb{E}_q[(p/q)(U-f)\psi]. \tag{4.11}$$

BPO 第二个等号使用 $\mathbb{E}_q R_B = 0$；MDPO 删除常数项使用 $\mathbb{E}_p\psi = 0$。这两次抵消发生在不同测度下。

完整词表求和时，可直接对真实损失求导。使用解析 score 形式时，把整个系数停止梯度，再乘以 $\log p_\theta(a)$，实现上述向量。这个代理标量的数值不等于真实损失。Part、Mean、BPO 的动作测度是 q，MDPO 的动作测度是 p；从 q 采样 MDPO 时需乘 p/q。

在 $p = q$ 处，BPO 和 MDPO 的梯度相同，Part、Mean 的梯度等于它们的 η 倍。离开锚点后，损失的度量、中心与测度不同，不能用起点相等推断整个轨迹相等。

4.3 接入前缀与外层同步

恢复条件变量 s，内层实际优化

$$\mathcal{L}_k(\theta) = \mathbb{E}_{s\sim d_k} L_k(p_\theta(\cdot \mid s)). \tag{4.12}$$

d_k 在本轮冻结；有限 rollout 用经验测度 $\widehat{d}_k$ 代替。教师信号 f, K_T 整轮冻结，学生中心 K_S 随每次参数更新重算。每个前缀的一条实际动作观测，不等于该前缀全部动作的期望；辅助动作抽样与新增完整回复是两种不同操作。

Algorithm 1 固定前缀的 MirrorOPD

Semantics: 根据条件目标重构；动作期望使用完整词表

Require: teacher T, initial student θ_0, $\kappa \in [0,1]$, $0 < \eta < 1$, finite budgets K, N

for $k = 0, \dots, K-1$ **do**
  $q_k \leftarrow p_{\theta_k}$; freeze q_k
  sample prompts and one response per prompt from q_k with full action support
  form $\widehat{d}_k$ from valid response tokens, including EOS
  if the batch has no valid response tokens **then**
    terminate with an invalid-batch error
  end if
  cache frozen $f_k = \mathrm{stopgrad}(\eta A_{\kappa,\eta}(T/q_k))$ and required teacher integrals
  $\theta_{k,0} \leftarrow \theta_k$
  for $n = 0, \dots, N-1$ **do**
    recompute $p_{\theta_{k,n}}$ and all student-dependent integrals
    $g_{k,n} \leftarrow \nabla_\theta \mathbb{E}_{\widehat{d}_k} L_k(p_{\theta_{k,n}})$
    $\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  $\theta_{k+1} \leftarrow \theta_{k,N}$; discard the old rollout for the next outer
end for
return θ_K

算法以普通梯度下降明确更新语义。替换为其他优化器时，目标定义保持不变，数值轨迹需另行分析。共享参数可能无法同时表示所有 $m_k(\cdot \mid s)$；此时三种具有相同自由分布解的方法，也可能具有不同的受限投影。

第五章 形状与插值强度的性质

5.1 路径、覆盖与局部速度

固定 q, T 时，η 从零增加到一，把目标教师从锚点移向教师。对固定 κ，任意凸生成散度 $D_\varphi(m_{\kappa,\eta}\|q)$ 随 η 非减；不同 κ 下，相同 η 不代表相同距离。其交点证明见完整稿附录 D。

正形状有一个分布无关的覆盖保证：

$$m_a \geq (1-\eta)^{1/\kappa} q_a + \eta^{1/\kappa} T_a, \qquad 0 < \kappa \leq 1. \tag{5.1}$$

证明使用 $h_a \leq (1-\eta)q_a + \eta T_a$，故 $Z \leq 1$；以及 $(x+y)^{1/\kappa} \geq x^{1/\kappa} + y^{1/\kappa}$。于是 $m_a = h_a/Z \geq h_a$ 给出下界。几何端点没有统一的正教师覆盖系数。

对固定严格正分布，小步展开为

$$m_a = q_a + \eta v_{\kappa,a} + O(\eta^2), \qquad v_{\kappa,a} = \frac{q_a}{\kappa}\left[(T_a/q_a)^\kappa - \mathbb{E}_q(T/q)^\kappa\right]. \tag{5.2}$$

$\kappa = 0$ 时取连续极限 $v_{0,a} = q_a C_q \log(T_a/q_a)$。这是 $D_\kappa(T\|q)$ 在 Fisher 度量下的负自然梯度。形状改变高维方向，不能通常由一个学习率缩放替代。

5.2 监督尾部与方差阈值

当 $\kappa > 0, \eta < 1$ 时，

$$A_{\kappa,\eta}(x) \geq -c_{\kappa,\eta}, \qquad c_{\kappa,\eta} = -\frac{\log(1-\eta)}{\kappa\eta}. \tag{5.3}$$

正尾部仍无逐点统一上界，但在 q 下利用 $\mathbb{E}_q(T/q) = 1$ 可以控制矩。令 $V_{\kappa,\eta} = \mathrm{Var}_q\, A_{\kappa,\eta}(T/q)$。对每个固定正 $\eta < 1$ 和 $\kappa > 0$，V 在所有有限正概率分布上有统一有限上界。

更强的小步问题需要另一个结论：

$$\sup_{q,T} V_{\kappa,\eta} = \Theta_\kappa\left(\eta^{\min\{2,1/\kappa\}-2}\right), \qquad \eta \downarrow 0, \quad \kappa > 0. \tag{5.4}$$

所以保持统一小步方差有界的区间为 $0 < \kappa \leq 1/2$。几何端点对任意固定正 η 都没有分布无关界。这里上确界允许分布随 η 改变；固定一对正分布时，每种形状的小步极限都有限。

对 $0 < \kappa \leq 1/2$，还有误差相关界

$$V_{\kappa,\eta} \leq \frac{D_\kappa(T\|q)}{\kappa(1-\eta)^2} \leq \frac{K_T}{\kappa(1-\kappa)(1-\eta)^2}. \tag{5.5}$$

若 score 范数统一不超过 S，中心化教师梯度的协方差迹不超过 $S^2 V$。标量监督方差与完整参数梯度方差由这个额外条件连接；精确均值中心本身不保证 score 梯度的方差最小。

5.3 平方根点的作用与限制

令 $a = \sum_v \sqrt{q_v T_v}$、$w = 1 - \eta$。平方根目标满足

$$\sqrt{m} = \frac{w\sqrt{q} + \eta\sqrt{T}}{\sqrt{Z}}, \qquad Z = w^2 + \eta^2 + 2w\eta a. \tag{5.6}$$

因为 $Z \leq 1$，

$$\sum_v \sqrt{m_v T_v} = \frac{wa + \eta}{\sqrt{Z}} \geq wa + \eta, \quad H^2(m,T) \leq (1-\eta)H^2(q,T). \tag{5.7}$$

这是精确分布更新的全局收缩。所有形状在固定正教师附近却共享

$$m_{\kappa,\eta}(T + \delta, T) = T + (1-\eta)\delta + O(\|\delta\|^2). \tag{5.8}$$

因此平方根的全局 Hellinger 保证不代表更好的局部一阶概率收缩率。

平方根点唯一最小化小步监督方差相对于自身教师散度的最坏比值；若改为最小化绝对最坏方差，最优形状约为 0.441928。两种准则的推导在完整稿附录 D。固定 q, η 时，BPO 的独立 logits Hessian 为

$$\nabla_z^2 L_{\mathrm{BPO}} = \eta^{-1}[\mathrm{diag}(q) - qq^\top], \tag{5.9}$$

其中不含 κ。形状改变目标和初始残差，不能由此宣称改善该二次问题的条件数。

第六章 有限拟合与外层进展

6.1 从本轮拟合到教师接近度

定理 6.1 (重心进展恒等式)

对任意候选 p，令 $c_\kappa = Z^\kappa$，端点 $\kappa = 0, 1$ 取 $c_\kappa = 1$，则

$$\eta[D_\kappa(T\|q) - D_\kappa(T\|p)] = (1-\eta)D_\kappa(q\|p) + c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]. \tag{6.1}$$

因此 $D_\kappa(m\|p) \le D_\kappa(m\|q)$ 是教师散度非增的充分条件。精确更新 $p = m$ 在 $q \neq T$ 时严格改善。

证明 重心定义给出 $F(q) = \eta D_\kappa(T\|q)$。另一方面，式 (3.18) 及其端点给出 $F(q) - F(p) = c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]$。代入 $F(p)$ 并移项得到恒等式。条件成立时右侧两项非负。若 $p = m$ 且 $q \neq T$，则 $m \neq q$，右侧第一项严格为正。

精确幂均值更新还有更强性质：它同时降低所有凸生成的教师 f-散度。证明使用概率比的共同交点，见完整稿附录 D。有限 inner 降低某个拟合损失却不足以自动继承这一性质。

6.2 拟合误差证书

MDPO 的超额损失 δ 精确对应 $\mathrm{KL}(p\|m) = \eta\delta$，由 Pinsker 不等式得到 $\mathrm{TV}(p, m) \le \sqrt{\eta\delta/2}$。BPO 控制的是按 q 加权的对数比方差。若另有 $q_a \ge q_{\min} > 0$，则

$$d_H(p, m) := \operatorname{osc}_a \log(p_a/m_a) \le 2\sqrt{\eta L_{\mathrm{BPO}}/q_{\min}}, \quad \mathrm{TV}(p, m) \le \tanh[d_H(p, m)/4]. \tag{6.2}$$

最小锚点概率极小时，这个证书可能很弱；推导与锐 TV 界见完整稿附录 A、完整稿附录 G。

这种限制确实会发生。取

$$q = (0.4999995, 0.4999995, 10^{-6}), \quad T = (0.8, 0.199999, 10^{-6}), \quad \kappa = \tfrac{1}{2}, \quad \eta = 0.3, \tag{6.3}$$

并令 $p \propto m \exp(0, 0, 12)$。直接求和得到

$$L_{\mathrm{BPO}}(q) \simeq 0.062277, \quad L_{\mathrm{BPO}}(p) \simeq 0.000240, \quad \mathrm{KL}(q\|T) \simeq 0.223145, \quad \mathrm{KL}(p\|T) \simeq 1.654219. \tag{6.4}$$

稀有动作的对数误差在 q 下权重很小，却可以改变归一化后的学生质量。因此需要区分 loss 下降与目标教师拟合证书。

6.3 有效保证的条件

从 q 出发，使用精确锚点 Fisher 预条件的 BPO 产生理想路径

$$p_\xi \propto q \exp(\xi f), \qquad 0 \le \xi \le 1. \tag{6.5}$$

沿这条路径，所有凸生成的教师散度非增。该结论依赖路径、完整期望与自由 logits；普通神经网络优化器不自动位于这条路径上，证明见完整稿附录 C。

固定教师的精确外层收敛，允许通过输出误差递推扩展到近似拟合。应先由内层损失、中心误差和表示限制建立输出误差，再分析多轮累积；梯度估计的方差不能直接替代输出误差。

最后，正文的目标是固定前缀测度下的条件目标。完整序列 KL 使用随策略变化的访问权重；条件 KL 逐前缀下降，也可能同时让学生更频繁进入误差较大的分支。序列反例、后缀价值修正和同步边界见完整稿附录 G。TOP-D 的目标教师由算术端点精确恢复，其收缩与方差性质见完整稿附录 H。

参考文献

[1] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

[2] Andrzej Cichocki and Shun-ichi Amari. “Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities”. In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

[3] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.