MirrorOPD 核心推导

目标教师、内层拟合与参数性质

从加权散度最优化到 (κ, η) 镜像更新

正文与八组技术附录

MirrorOPD Research Notes

2026 年 10 月 15 日

阅读约定

本文研究固定前缀测度下的条件分布优化。每轮外层先冻结学生锚点，再由锚点与教师构造目标分布；内层用共享参数学生拟合这个目标，结束后刷新锚点。正文给出这条链上的定义、核心证明与适用条件；附录展开信息访问、估计、优化几何和多轮动力学。

镜像下降（Mirror Descent，MD）在概率空间通过局部线性目标与 Bregman 正则定义更新。本文沿用来源中的 MDPO、BPO、PMD-Part、PMD-Mean 名称，依次表示镜像目标优化、中心化残差回归、完整最优性方程回归和均值近似回归；第 3 章给出它们的精确定义。

精确分布更新、总体拟合目标、有限样本估计和神经网络参数更新是四个层次。定理在哪一层成立，就在哪一层表述。完整词表求和消除条件动作积分误差，仍保留前缀覆盖与模型表示误差。本文的解析结论不直接给出任务正确率排序。

记号	固定含义
$T, q_k, p_{k,n}$	教师、第 k 轮冻结锚点、第 n 步内层学生
m_k	该轮由最优化问题定义的目标教师
κ, η	目标形状、教师插值权重；正文取 $0 \le \kappa \le 1$, $0 < \eta < 1$
$\alpha_{\mathrm{opt}}, \tau$	参数优化器学习率、固定 $J_{\kappa,\eta}$ 后另选的镜像步长
$F_k, J_{\kappa,\eta}, L_k$	重心目标、教师目标、内层拟合损失
$A, f = \eta A, K_T$	标准化教师信号、指数中的信号、冻结教师中心
$C_q h = h - \mathbb{E}_q h$	按同一前缀的锚点分布中心化
$d_k, \widehat{d}_k$	总体、经验前缀访问测度
K_{head}, M, N	头部动作数、同前缀辅助动作数、内层步数

所有对数均为自然对数。$\mathrm{TV}(P,Q) = \frac{1}{2}\sum_a |P_a - Q_a|$；平方 Hellinger 距离固定为 $H^2(P,Q) = \sum_a (\sqrt{P_a} - \sqrt{Q_a})^2$，不带 $1/2$。向量方差表示协方差矩阵的迹。正文省略前缀条件时，所有分布仍条件于同一个前缀。

附录按数学依赖组织：A 给出测度和基础工具；B 完整识别教师目标；C 处理内层投影和优化；D 分析形状与矩；E 处理积分信息与估计；F 将中心估计接回拟合；G 分析外层误差与序列边界；H 比较 TOP-D 的目标教师。短阅读版与完整稿使用同一份正文源码。

目录

第一章 加权最优化与目标教师 **1**
1.1 每轮外层的最优化问题 1
1.2 唯一解与拟合误差 1
1.3 三个代表形状 2

第二章 教师目标与精确镜像更新 **3**
2.1 由目标分布识别教师信号 3
2.2 下降保证与参数角色 3
2.3 散度、教师目标与中心 4

第三章 固定目标教师的内层拟合 **5**
3.1 最优性方程与四种损失 5
3.2 精确梯度与采样测度 5
3.3 接入前缀与外层同步 6

第四章 形状与插值强度的性质 **7**
4.1 路径、覆盖与局部速度 7
4.2 监督尾部与方差阈值 7
4.3 平方根点的作用与限制 7

第五章 有限拟合与外层进展 **9**
5.1 从本轮拟合到教师接近度 9
5.2 拟合误差证书 9
5.3 有效保证的条件 9

附录 A 测度、归一化与基础工具 **10**
A.1 变长轨迹如何诱导条件目标 10
A.2 积分微分与支持条件 10
A.3 散度规范化与局部二阶项 11
A.4 中心化坐标与归一化恢复 11
A.5 从对数误差到概率距离 11

附录 B 重心、教师目标与镜像下降 **13**
B.1 密度比矩、散度与几何重加权 13
B.2 加权重心的两个端点与多教师形式 13
B.3 逆向构造的唯一性与通用信号 13
B.4 完整的下降与收敛推导 14
B.5 端点、JS 与曲率插值 14
B.6 统一有界性与教师中心 15
B.7 固定幂散度的镜像步与小步流 15

附录 C 内层投影与优化几何 **17**
C.1 统一坐标中的四种目标 17
C.2 Mean 的完整约束解 17

C.3 精确曲率与唯一驻点 . . . 18
C.4 受限表示改变投影 . . . 18
C.5 自由 logits 的收敛与理想路径 . . . 19
C.6 共享参数、拟合形状与条件 SGD . . . 19
C.7 与条件 OPD 基线的关系 . . . 20
C.8 标量步长能改变的部分 . . . 20

附录 D 形状、概率路径与监督矩 22
D.1 覆盖界与目标半径 . . . 22
D.2 精确目标同时改善凸生成散度 . . . 22
D.3 教师中心的性质 . . . 23
D.4 固定强度的矩界与小步阈值 . . . 23
D.5 误差相关方差与锐常数 . . . 24
D.6 绝对最坏方差的不同最优点 . . . 24
D.7 平方根流、局部速率与噪声可求和性 . . . 25

附录 E 信息访问与条件积分估计 26
E.1 四个积分对象与可观测信息 . . . 26
E.2 粗粒化、下界与不可识别性 . . . 26
E.3 精确积分加残差抽样 . . . 27
E.4 头尾估计器作为统一定理的实例 . . . 27
E.5 提案变化、分层采样与正向 KL . . . 28
E.6 数值估计与反传的独立核验 . . . 28
E.7 配分函数估计与可控展开 . . . 29

附录 F 条件中心与有限样本拟合 31
F.1 中心估计代入损失后的对象 . . . 31
F.2 无中心样本方差与 U-统计量 . . . 31
F.3 教师中心的有符号与非负估计 . . . 32
F.4 有界包络与头尾区间 . . . 32
F.5 中心误差、baseline 与更新场 . . . 33

附录 G 外层动力学、扰动与序列边界 34
G.1 幂均值的 escort 轨迹 . . . 34
G.2 几何端点的完整稳定区间 . . . 34
G.3 Mean 的单轮界与精确外层 . . . 35
G.4 Mean 的三次项与边界率 . . . 36
G.5 有限 inner 的误差接口 . . . 36
G.6 输出扰动、噪声与同步 . . . 37
G.7 共享参数的自然梯度投影 . . . 38
G.8 条件更新与完整序列 . . . 38

附录 H TOP-D 目标教师的退化与性质 39
H.1 参数对应与精确可达性 . . . 39
H.2 监督信号、中心与教师目标 . . . 39
H.3 覆盖与散度收缩 . . . 39
H.4 有限拟合的误差累积 . . . 40

H.5 方差定理的尺度对应 40
H.6 比较结论的作用范围 41

来源对应与复现 **42**

参考文献 **43**

第一章 加权最优化与目标教师

1.1 每轮外层的最优化问题

固定一个前缀，词表 $\mathcal{V}$ 有限，$|\mathcal{V}| \geq 2$。教师 T 与本轮冻结学生 $q = q_k$ 都严格为正且归一化。先允许每个前缀的候选分布独立变化；参数化约束在第 3 章引入。令 Δ 为闭概率单纯形，Δ° 为其内部。

采用如下幂散度约定[1]：

$$D_\kappa(P\|Q) = \frac{1 - \sum_a P_a^\kappa Q_a^{1-\kappa}}{\kappa(1-\kappa)}, \qquad 0 < \kappa < 1. \tag{1.1}$$

两个连续端点为 $D_0(P\|Q) = \mathrm{KL}(Q\|P)$、$D_1(P\|Q) = \mathrm{KL}(P\|Q)$。因此以教师为第一自变量时，$\kappa = 0$ 给出学生逆向 KL，$\kappa = 1$ 给出学生正向 KL。

从一开始引入形状 $\kappa \in [0,1]$ 和教师权重 $\eta \in (0,1)$：

$$\boxed{m_k = \arg\min_{p \in \Delta} F_k(p), \qquad F_k(p) = (1-\eta) D_\kappa(q_k\|p) + \eta D_\kappa(T\|p).} \tag{1.2}$$

这个问题同时惩罚偏离锚点和偏离教师。η 指定两者的权重，κ 指定散度形状。所得 m_k 称为本轮目标教师；实际回复仍可由 q_k 生成。

1.2 唯一解与拟合误差

定理 1.1 (归一化幂均值目标)

对 $0 < \kappa \leq 1$，定义

$$h_a = [(1-\eta) q_a^\kappa + \eta T_a^\kappa]^{1/\kappa}, \qquad Z = \sum_a h_a, \qquad m_a = h_a / Z. \tag{1.3}$$

它是式 (1.2) 的唯一解。$\kappa = 0$ 的连续端点为 $m_a = q_a^{1-\eta} T_a^\eta / Z$。当 $0 < \kappa < 1$ 时，

$$F(p) - F(m) = Z^\kappa D_\kappa(m\|p). \tag{1.4}$$

端点 $\kappa = 0, 1$ 的超额损失分别为 $\mathrm{KL}(p\|m)$、$\mathrm{KL}(m\|p)$。 ♡

证明 令 $S_a = (1-\eta) q_a^\kappa + \eta T_a^\kappa$。对内点 p，

$$F(p) = \frac{1 - \sum_a S_a p_a^{1-\kappa}}{\kappa(1-\kappa)}, \quad \partial_{p_a} F = -\frac{S_a}{\kappa} p_a^{-\kappa}, \quad \partial^2_{p_a} F = S_a p_a^{-\kappa-1} > 0. \tag{1.5}$$

加入约束乘子 ν，一阶条件为 $S_a p_a^{-\kappa} = \kappa\nu$，归一化即得 $p = m$。为同时覆盖边界并证明全局唯一性，利用 $S_a = Z^\kappa m_a^\kappa$ 直接写出

$$F(p) = \frac{1 - Z^\kappa}{\kappa(1-\kappa)} + Z^\kappa D_\kappa(m\|p). \tag{1.6}$$

Hölder 不等式给出 $\sum_a m_a^\kappa p_a^{1-\kappa} \leq 1$，等号要求两个归一化向量相同；边界上也只有 $p = m$ 可以取等。因此得到唯一解与超额损失。

在 $\kappa = 0$ 时，展开加权 KL 得 $F(p) = \mathrm{KL}(p\|m) - \log Z$。在 $\kappa = 1$ 时，令 $m = (1-\eta)q + \eta T$，逐项相减得

$$F(p) - F(m) = \sum_a m_a \log(m_a / p_a). \tag{1.7}$$

两端的 KL 非负性给出相同的唯一性结论。最后对 q_a^κ, T_a^κ 在零处展开，得到 $\log h_a \to (1-\eta)\log q_a + \eta \log T_a$，证明连续端点。

---

[1] Andrzej Cichocki and Shun-ichi Amari. "Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities". In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

幂均值重心属于已有的 α 散度模型汇合框架[2]。本文使用它组织外层目标、内层投影与误差分析。最优化问题与拟合误差的精确关系是式 (1.4)，不只是一条最优点相同的结论。

1.3 三个代表形状

$$
\begin{aligned}
m_{0,\eta} &\propto q^{1-\eta} T^{\eta}, \\
m_{1/2,\eta} &\propto [(1-\eta)\sqrt{q} + \eta\sqrt{T}]^2, \\
m_{1,\eta} &= (1-\eta) q + \eta T.
\end{aligned}
\tag{1.8}
$$

几何端点在 log-odds 坐标中走直线；算术端点在概率坐标中走直线；平方根点在平方根概率单位球面上走短弧。η 对平方根点通常不是弧长比例。所有形状在 $\eta = 0, 1$ 分别到达 q, T，端点通过连续延拓理解。

只有算术端点的归一化常数恒为一。一般情况下不能删除 Z，也不能把幂均值目标当成概率的算术加权。其几何、覆盖界与多教师推广见附录 B、附录 D。

[2] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

第二章 教师目标与精确镜像更新

2.1 由目标分布识别教师信号

为解释外层在优化哪个教师目标，定义概率比函数

$$A_{\kappa,\eta}(x)=\begin{cases}\dfrac{\log(1-\eta+\eta x^{\kappa})}{\kappa\eta}, & \kappa>0,\\ \log x, & \kappa=0,\end{cases}\qquad f_a=\eta A_{\kappa,\eta}(T_a/q_a). \tag{2.1}$$

则 $q_a e^{f_a}=h_a$，目标教师写为 $m_a=q_a e^{f_a}/Z$。整个内层中 q,T,f,Z 冻结。

本轮重心目标 F_k 的最小点是 m_k。下面定义一个不依赖锚点、最小点为原教师 T 的目标。两个函数的作用不同。

定理 2.1 (教师目标的构造与镜像解释)

定义

$$\omega_{\kappa,\eta}(x)=x\int_1^x\frac{A_{\kappa,\eta}(u)}{u^2}\,du,\qquad J_{\kappa,\eta}(p;T)=\sum_a p_a\omega_{\kappa,\eta}(T_a/p_a). \tag{2.2}$$

则 $J\ge 0$，且在概率单纯形上唯一零点为 $p=T$。在正正交象限中，

$$\partial_{p_a}J(p;T)=-A_{\kappa,\eta}(T_a/p_a). \tag{2.3}$$

对 J 在 q 处执行步长 η 的负熵镜像下降，恰好得到目标教师：

$$\boxed{m=\arg\min_{p\in\Delta}\left\{\langle\nabla J(q;T),p-q\rangle+\eta^{-1}\,\mathrm{KL}(p\|q)\right\}.} \tag{2.4}$$

♡

证明 对积分求导，

$$\omega'(x)=\int_1^x A(u)u^{-2}\,du+A(x)/x, \tag{2.5}$$

$$\omega(x)-x\omega'(x)=-A(x), \tag{2.6}$$

$$\omega''(x)=A'(x)/x=\frac{x^{\kappa-2}}{1-\eta+\eta x^{\kappa}}>0. \tag{2.7}$$

最后一式在 $\kappa=0$ 时取 x^{-2}。由 $A(1)=0$，有 $\omega(1)=\omega'(1)=0$，所以严格凸的 ω 只在一处取零。正权重求和给出 $J\ge 0$，且 $J=0$ 要求 $T_a/p_a=1$ 对每个 a 成立。链式法则给出

$$\partial_{p_a}[p_a\omega(T_a/p_a)]=\omega(x)-x\omega'(x)=-A(x). \tag{2.8}$$

式 (2.4) 的一阶条件为 $-A(T_a/q_a)+\eta^{-1}[\log(p_a/q_a)+1]+\nu=0$。消去公共乘子并归一化，即得 $p_a\propto q_a e^{\eta A(T_a/q_a)}$。KL 正则严格凸，故解唯一。

2.2 下降保证与参数角色

负熵势记为 $\Phi(p)=\sum_a p_a\log p_a$。令 $x_a=T_a/p_a$，则

$$\nabla^2 J(p;T)=\mathrm{diag}\left(\frac{1}{p_a}\frac{x_a^{\kappa}}{1-\eta+\eta x_a^{\kappa}}\right)\preceq\eta^{-1}\nabla^2\Phi(p). \tag{2.9}$$

沿线段积分 Hessian，得到相对光滑不等式

$$J(p)\le J(q)+\langle\nabla J(q),p-q\rangle+\eta^{-1}\,\mathrm{KL}(p\|q). \tag{2.10}$$

镜像最优性条件与 $m-q$ 作内积，给出

$$\langle\nabla J(q),m-q\rangle=-\eta^{-1}[\mathrm{KL}(m\|q)+\mathrm{KL}(q\|m)]. \tag{2.11}$$

所以 $J(q)-J(m)\geq\eta^{-1}\,\mathrm{KL}(q\|m)$，非平凡精确更新严格下降。对同一条件分布反复精确刷新，三点恒等式进一步给出

$$J(q_K;T)\leq\frac{\mathrm{KL}(T\|q_0)}{\eta K}. \tag{2.12}$$

完整望远镜求和、边界排除和可变镜像步长证明见附录 B。

在整个递推中固定 κ,η,T，$J_{\kappa,\eta}$ 才是同一个函数。改变 η 一般同时改变目标形状和镜像步长。若要保持 J 不变而调整步长，应另用 τ，更新 $p^+\propto q\exp[\tau A_{\kappa,\eta}(T/q)]$。参数优化器的学习率 α_{opt} 又是第三个量。

2.3 散度、教师目标与中心

三个容易混用的对象分别是

$$D_\kappa(T\|p),\qquad J_{\kappa,\eta}(p;T),\qquad K_T(q,T)=-\mathbb{E}_q A_{\kappa,\eta}(T/q). \tag{2.13}$$

它们依次用于定义重心、解释精确镜像更新、中心化本轮监督。K_T 在内层冻结。端点关系为

$$J_{0,\eta}(p;T)=\mathrm{KL}(p\|T),\quad \lim_{\eta\downarrow0}J_{\kappa,\eta}(p;T)=D_\kappa(T\|p),\quad \lim_{\eta\uparrow1}J_{\kappa,\eta}(p;T)=\mathrm{KL}(p\|T). \tag{2.14}$$

当 $\kappa=1$、$0<\eta<1$，J 是归一化加权 JS，而 $D_1(T\|p)$ 是正向 KL。有限步幂均值一般不是对固定 D_κ 做同一步长的熵镜像下降；两者在小步极限才一阶一致。

第三章 固定目标教师的内层拟合

3.1 最优性方程与四种损失

本轮固定 q, T, m 与 $f = \eta A(T/q)$，当前学生为 $p = p_\theta$。记

$$U_a = \log(p_a/q_a), \qquad G = C_q f, \qquad K_S = \mathrm{KL}(q\|p) = -\mathbb{E}_q U, \qquad K_T = -\mathbb{E}_q A. \tag{3.1}$$

目标教师满足 $U^\star = f - \log Z$。将该方程转成可训练目标，有以下四种方式：

$$L_{\mathrm{MDPO}}(p) = \frac{1}{\eta}\{\mathrm{KL}(p\|q) - \mathbb{E}_p f\} = \frac{1}{\eta}\mathrm{KL}(p\|m) - \frac{\log Z}{\eta}, \tag{3.2}$$

$$L_{\mathrm{Part}}(p) = \frac{1}{2}\mathbb{E}_q(U - f + \log Z)^2, \tag{3.3}$$

$$L_{\mathrm{BPO}}(p) = \frac{1}{2\eta}\mathbb{E}_q[C_q(U-f)]^2 = \frac{1}{2\eta}\mathrm{Var}_q \log(p/m), \tag{3.4}$$

$$L_{\mathrm{Mean}}(p) = \frac{1}{2}\mathbb{E}_q(U - G)^2. \tag{3.5}$$

MDPO 保留原镜像子问题；Part 回归完整的对数比方程；BPO 回归中心化后的方程；Mean 用 $\mathbb{E}_q f$ 近似 $\log Z$。Mean 的定义与 PMD-mean 原始分析一致，整体损失尺度在此统一[1]。

命题 3.1 (共同目标与 Mean 的偏离)

在完整支持、精确期望和可实现的分布类中，MDPO、Part、BPO 的唯一最优分布均为 m。若 f 非恒定，Mean 的最优分布一般不等于 m。

证明 MDPO 的结论由式 (3.2) 的 KL 分解给出。Part 的零损失要求 $\log(p/m) = 0$。BPO 的零损失要求 $\log(p/m)$ 在全部动作上为常数，归一化再强制常数为零。

Mean 满足约束 $\mathbb{E}_q e^U = 1$，其拉格朗日一阶条件是

$$U_a - G_a + \lambda e^{U_a} = 0. \tag{3.6}$$

Gibbs 解满足 $U_a = G_a - \Delta$，其中 $\Delta = \log \mathbb{E}_q e^G > 0$。代入后要求 $\lambda e^{G_a - \Delta} = \Delta$ 对所有 a 成立；非恒定 G 使其不可能。Mean 的存在唯一性及 Lambert-W 解见附录 C。

Mean 与 BPO 的差异还可精确写成

$$L_{\mathrm{Mean}} = \eta L_{\mathrm{BPO}} + \frac{1}{2}K_S^2. \tag{3.7}$$

因为 $U - G = C_q(U - f) - K_S$，而第一项的 q 均值为零，平方交叉项消失。额外的 $K_S^2/2$ 改变最优分布与梯度；它不能当成不影响优化的常数。

3.2 精确梯度与采样测度

令 $\psi_a = \nabla_\theta \log p_\theta(a)$、$\bar{\psi}_q = \mathbb{E}_q \psi$，则 $\mathbb{E}_p \psi = 0$，但 $\bar{\psi}_q$ 通常不为零。定义

$$R_P = U - f + \log Z, \quad R_M = U - G, \quad R_B = C_q(U - f) = U + K_S - \eta(A + K_T). \tag{3.8}$$

直接求导得到

$$\nabla L_{\mathrm{Part}} = \mathbb{E}_q[R_P \psi], \qquad \nabla L_{\mathrm{Mean}} = \mathbb{E}_q[R_M \psi], \tag{3.9}$$

$$\nabla L_{\mathrm{BPO}} = \eta^{-1}\mathbb{E}_q[R_B(\psi - \bar{\psi}_q)] = \eta^{-1}\mathbb{E}_q[R_B \psi], \tag{3.10}$$

$$\nabla L_{\mathrm{MDPO}} = \eta^{-1}\mathbb{E}_p[(U-f)\psi] = \eta^{-1}\mathbb{E}_q[(p/q)(U-f)\psi]. \tag{3.11}$$

[1] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.

BPO 第二个等号使用 $\mathbb{E}_q R_B = 0$；MDPO 删除常数项使用 $\mathbb{E}_p \psi = 0$。这两次抵消发生在不同测度下。

完整词表求和时，可直接对真实损失求导。使用解析 score 形式时，把整个系数停止梯度，再乘以 $\log p_\theta(a)$，实现上述向量。这个代理标量的数值不等于真实损失。Part、Mean、BPO 的动作测度是 q，MDPO 的动作测度是 p；从 q 采样 MDPO 时需乘 p/q。

在 $p = q$ 处，BPO 和 MDPO 的梯度相同，Part、Mean 的梯度等于它们的 η 倍。离开锚点后，损失的度量、中心与测度不同，不能用起点相等推断整个轨迹相等。

3.3 接入前缀与外层同步

恢复条件变量 s，内层实际优化

$$\mathcal{L}_k(\theta) = \mathbb{E}_{s \sim d_k} L_k(p_\theta(\cdot \mid s)). \tag{3.12}$$

d_k 在本轮冻结；有限 rollout 用经验测度 $\widehat{d}_k$ 代替。教师信号 f, K_T 整轮冻结，学生中心 K_S 随每次参数更新重算。每个前缀的一条实际动作观测，不等于该前缀全部动作的期望；辅助动作抽样与新增完整回复是两种不同操作。

Algorithm 1 固定前缀的 MirrorOPD

Semantics: 根据条件目标重构；动作期望使用完整词表

Require: teacher T, initial student θ_0, $\kappa \in [0, 1]$, $0 < \eta < 1$, finite budgets K, N

for $k = 0, \ldots, K-1$ **do**
  $q_k \leftarrow p_{\theta_k}$; freeze q_k
  sample prompts and one response per prompt from q_k with full action support
  form $\widehat{d}_k$ from valid response tokens, including EOS
  if the batch has no valid response tokens **then**
    terminate with an invalid-batch error
  end if
  cache frozen $f_k = \mathrm{stopgrad}(\eta A_{\kappa,\eta}(T/q_k))$ and required teacher integrals
  $\theta_{k,0} \leftarrow \theta_k$
  for $n = 0, \ldots, N-1$ **do**
    recompute $p_{\theta_{k,n}}$ and all student-dependent integrals
    $g_{k,n} \leftarrow \nabla_\theta \mathbb{E}_{\widehat{d}_k} L_k(p_{\theta_{k,n}})$
    $\theta_{k,n+1} \leftarrow \theta_{k,n} - \alpha_{k,n} g_{k,n}$
  end for
  $\theta_{k+1} \leftarrow \theta_{k,N}$; discard the old rollout for the next outer
end for
return θ_K

算法以普通梯度下降明确更新语义。替换为其他优化器时，目标定义保持不变，数值轨迹需另行分析。共享参数可能无法同时表示所有 $m_k(\cdot \mid s)$；此时三种具有相同自由分布解的方法，也可能具有不同的受限投影。

第四章 形状与插值强度的性质

4.1 路径、覆盖与局部速度

固定 q, T 时，η 从零增加到一，把目标教师从锚点移向教师。对固定 κ，任意凸生成散度 $D_\varphi(m_{\kappa,\eta}\|q)$ 随 η 非减；不同 κ 下，相同 η 不代表相同距离。其交点证明见附录 D。

正形状有一个分布无关的覆盖保证：

$$m_a \geq (1-\eta)^{1/\kappa} q_a + \eta^{1/\kappa} T_a, \qquad 0 < \kappa \leq 1. \tag{4.1}$$

证明使用 $h_a \leq (1-\eta)q_a + \eta T_a$，故 $Z \leq 1$；以及 $(x+y)^{1/\kappa} \geq x^{1/\kappa} + y^{1/\kappa}$。于是 $m_a = h_a/Z \geq h_a$ 给出下界。几何端点没有统一的正教师覆盖系数。

对固定严格正分布，小步展开为

$$m_a = q_a + \eta v_{\kappa,a} + O(\eta^2), \qquad v_{\kappa,a} = \frac{q_a}{\kappa}\left[(T_a/q_a)^\kappa - \mathbb{E}_q(T/q)^\kappa\right]. \tag{4.2}$$

$\kappa = 0$ 时取连续极限 $v_{0,a} = q_a C_q \log(T_a/q_a)$。这是 $D_\kappa(T\|q)$ 在 Fisher 度量下的负自然梯度。形状改变高维方向，不能通常由一个学习率缩放替代。

4.2 监督尾部与方差阈值

当 $\kappa > 0, \eta < 1$ 时，

$$A_{\kappa,\eta}(x) \geq -c_{\kappa,\eta}, \qquad c_{\kappa,\eta} = -\frac{\log(1-\eta)}{\kappa\eta}. \tag{4.3}$$

正尾部仍无逐点统一上界，但在 q 下利用 $\mathbb{E}_q(T/q) = 1$ 可以控制矩。令 $V_{\kappa,\eta} = \mathrm{Var}_q\, A_{\kappa,\eta}(T/q)$。对每个固定正 $\eta < 1$ 和 $\kappa > 0$，V 在所有有限正概率分布上有统一有限上界。

更强的小步问题需要另一个结论：

$$\sup_{q,T} V_{\kappa,\eta} = \Theta_\kappa\left(\eta^{\min\{2,1/\kappa\}-2}\right), \qquad \eta \downarrow 0, \quad \kappa > 0. \tag{4.4}$$

所以保持统一小步方差有界的区间为 $0 < \kappa \leq 1/2$。几何端点对任意固定正 η 都没有分布无关界。这里上确界允许分布随 η 改变；固定一对正分布时，每种形状的小步极限都有限。

对 $0 < \kappa \leq 1/2$，还有误差相关界

$$V_{\kappa,\eta} \leq \frac{D_\kappa(T\|q)}{\kappa(1-\eta)^2} \leq \frac{K_T}{\kappa(1-\kappa)(1-\eta)^2}. \tag{4.5}$$

若 score 范数统一不超过 S，中心化教师梯度的协方差迹不超过 $S^2 V$。标量监督方差与完整参数梯度方差由这个额外条件连接；精确均值中心本身不保证 score 梯度的方差最小。

4.3 平方根点的作用与限制

令 $a = \sum_v \sqrt{q_v T_v}$、$w = 1 - \eta$。平方根目标满足

$$\sqrt{m} = \frac{w\sqrt{q} + \eta\sqrt{T}}{\sqrt{Z}}, \qquad Z = w^2 + \eta^2 + 2w\eta a. \tag{4.6}$$

因为 $Z \leq 1$，

$$\sum_v \sqrt{m_v T_v} = \frac{wa + \eta}{\sqrt{Z}} \geq wa + \eta, \quad H^2(m,T) \leq (1-\eta)H^2(q,T). \tag{4.7}$$

这是精确分布更新的全局收缩。所有形状在固定正教师附近却共享

$$m_{\kappa,\eta}(T + \delta, T) = T + (1-\eta)\delta + O(\|\delta\|^2). \tag{4.8}$$

因此平方根的全局 Hellinger 保证不代表更好的局部一阶概率收缩率。

平方根点唯一最小化小步监督方差相对于自身教师散度的最坏比值；若改为最小化绝对最坏方差，最优形状约为 0.441928。两种准则的推导在附录 D。固定 q, η 时，BPO 的独立 logits Hessian 为

$$\nabla_z^2 L_{\mathrm{BPO}} = \eta^{-1}[\mathrm{diag}(q) - qq^\top], \tag{4.9}$$

其中不含 κ。形状改变目标和初始残差，不能由此宣称改善该二次问题的条件数。

第五章 有限拟合与外层进展

5.1 从本轮拟合到教师接近度

定理 5.1 (重心进展恒等式)

对任意候选 p，令 $c_\kappa = Z^\kappa$，端点 $\kappa = 0, 1$ 取 $c_\kappa = 1$，则

$$\eta[D_\kappa(T\|q) - D_\kappa(T\|p)] = (1-\eta)D_\kappa(q\|p) + c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]. \tag{5.1}$$

因此 $D_\kappa(m\|p) \le D_\kappa(m\|q)$ 是教师散度非增的充分条件。精确更新 $p = m$ 在 $q \neq T$ 时严格改善。

证明 重心定义给出 $F(q) = \eta D_\kappa(T\|q)$。另一方面，定理 1.1 给出 $F(q) - F(p) = c_\kappa[D_\kappa(m\|q) - D_\kappa(m\|p)]$。代入 $F(p)$ 并移项得到恒等式。条件成立时右侧两项非负。若 $p = m$ 且 $q \neq T$，则 $m \neq q$，右侧第一项严格为正。

精确幂均值更新还有更强性质：它同时降低所有凸生成的教师 f-散度。证明使用概率比的共同交点，见附录 D。有限 inner 降低某个拟合损失却不足以自动继承这一性质。

5.2 拟合误差证书

MDPO 的超额损失 δ 精确对应 $\mathrm{KL}(p\|m) = \eta\delta$，由 Pinsker 不等式得到 $\mathrm{TV}(p, m) \le \sqrt{\eta\delta/2}$。BPO 控制的是按 q 加权的对数比方差。若另有 $q_a \ge q_{\min} > 0$，则

$$d_H(p, m) := \operatorname{osc}_a \log(p_a/m_a) \le 2\sqrt{\eta L_{\mathrm{BPO}}/q_{\min}}, \quad \mathrm{TV}(p, m) \le \tanh[d_H(p, m)/4]. \tag{5.2}$$

最小锚点概率极小时，这个证书可能很弱；推导与锐 TV 界见附录 A、附录 G。

这种限制确实会发生。取

$$q = (0.4999995, 0.4999995, 10^{-6}), \quad T = (0.8, 0.199999, 10^{-6}), \quad \kappa = \tfrac{1}{2}, \quad \eta = 0.3, \tag{5.3}$$

并令 $p \propto m \exp(0, 0, 12)$。直接求和得到

$$L_{\mathrm{BPO}}(q) \simeq 0.062277, \quad L_{\mathrm{BPO}}(p) \simeq 0.000240, \quad \mathrm{KL}(q\|T) \simeq 0.223145, \quad \mathrm{KL}(p\|T) \simeq 1.654219. \tag{5.4}$$

稀有动作的对数误差在 q 下权重很小，却可以改变归一化后的学生质量。因此需要区分 loss 下降与目标教师拟合证书。

5.3 有效保证的条件

从 q 出发，使用精确锚点 Fisher 预条件的 BPO 产生理想路径

$$p_\xi \propto q \exp(\xi f), \qquad 0 \le \xi \le 1. \tag{5.5}$$

沿这条路径，所有凸生成的教师散度非增。该结论依赖路径、完整期望与自由 logits；普通神经网络优化器不自动位于这条路径上，证明见附录 C。

固定教师的精确外层收敛，允许通过输出误差递推扩展到近似拟合。应先由内层损失、中心误差和表示限制建立输出误差，再分析多轮累积；梯度估计的方差不能直接替代输出误差。

最后，正文的目标是固定前缀测度下的条件目标。完整序列 KL 使用随策略变化的访问权重；条件 KL 逐前缀下降，也可能同时让学生更频繁进入误差较大的分支。序列反例、后缀价值修正和同步边界见附录 G。TOP-D 的目标教师由算术端点精确恢复，其收缩与方差性质见附录 H。

附录 A 测度、归一化与基础工具

A.1 变长轨迹如何诱导条件目标

设提示 $x \sim \mathcal{D}$，锚点 q 生成轨迹，回复长度 H 包含 EOS，不包含提示与 padding。预算终止时保留已生成动作。假设 $0 < \mathbb{E}H < \infty$，定义

$$d_q(B) = \frac{\mathbb{E}_q \sum_{t\geq 1} \mathbf{1}\{t \leq H,\ s_t \in B\}}{\mathbb{E}_q H}. \tag{A.1}$$

这里 s_t 是抽取第 t 个动作之前的历史。存活事件 $\{t \leq H\}$ 关于这段历史可测。对于绝对可积的 h，塔式期望给出

$$\mathbb{E}_q \sum_{t\geq 1} \mathbf{1}\{t \leq H\} h(s_t, a_t) = \mathbb{E}_q \sum_{t\geq 1} \mathbf{1}\{t \leq H\} \sum_a q(a \mid s_t) h(s_t, a) \tag{A.2}$$

$$= \mathbb{E}_q H\ \mathbb{E}_{s\sim d_q, a\sim q(\cdot|s)} h(s, a). \tag{A.3}$$

第一步交换求和与期望由非负性或绝对可积性保证。因此总体前缀–动作测度是 $d_q q$。

对 B 条独立轨迹，全局 token 均值为

$$\widehat{I}_B = \frac{\sum_{i=1}^{B} \sum_{t=1}^{H_i} h(s_{it}, a_{it})}{\sum_{i=1}^{B} H_i}. \tag{A.4}$$

分子分母除以 B，分别由大数定律趋于对应期望；分母极限严格为正，所以比值一致收敛到 $\mathbb{E}_{d_q,q} h$。有限 B 时随机分母一般产生比率估计偏差。同一轨迹内的 token 相关，置信区间不能把全部 token 当成独立样本。

逐序列先除以 H_i 会改变测度。取初始两动作各以 $1/2$ 发生，动作一立即终止，动作二随后再生成一个确定 EOS。按 $1/H$ 加权后，初始两动作质量为 $1/2, 1/4$，条件概率成为 $2/3, 1/3$。这个权重依赖当前与未来动作，不能移出条件期望。

固定 batch 后，总有效 token 数 T 不依赖内层参数。若微批次互不相交，使用 $L_m = \mathsf{T}^{-1} \sum_{i\in\mathcal{B}_m} \ell_i$，则

$$\sum_m \nabla L_m = \mathsf{T}^{-1} \sum_i \nabla \ell_i. \tag{A.5}$$

每个微批次各自取均值时，需再乘 $|\mathcal{B}_m|/\mathsf{T}$。裁剪和优化器更新放在梯度累加以后，才保留这条线性恒等式。

A.2 积分微分与支持条件

默认有限词表上的概率严格为正。若允许零概率，$\mathrm{KL}(P\|Q)$ 有限至少要求 $P \ll Q$；重要性抽样则需要提案覆盖非零被积贡献。两项支持要求由不同对象决定。

令 p_θ 可微，$\psi_a = \nabla_\theta \log p_\theta(a)$。归一化给出

$$\mathbb{E}_p \psi = \sum_a \nabla p_\theta(a) = 0. \tag{A.6}$$

对参数依赖函数 h_θ，

$$\nabla_\theta \mathbb{E}_{p_\theta} h_\theta = \mathbb{E}_p[\nabla_\theta h_\theta + h_\theta \psi]. \tag{A.7}$$

固定采样索引的自动微分只产生第一项。冻结测度 q 下则有 $\nabla \mathbb{E}_q h_\theta = \mathbb{E}_q \nabla h_\theta$，且 $\mathbb{E}_q \psi$ 一般不为零。有限词表使逐项微分合法；连续空间需另行提供可交换微分与积分的支配条件。

A.3 散度规范化与局部二阶项

对凸函数 g，定义 $D_g(P\|Q)=\sum_a Q_a g(P_a/Q_a)$。加入线性项 $b(x-1)$ 不改变散度。采用 $g(1)=g'(1)=0$ 的规范化后，

$$g_\kappa(x)=\frac{\kappa x+1-\kappa-x^\kappa}{\kappa(1-\kappa)},\qquad g_\kappa''(x)=x^{\kappa-2}. \tag{A.8}$$

$g_0(x)=x-1-\log x$、$g_1(x)=x\log x-x+1$ 由洛必达法则得到。对偶关系由逐点恒等式 $xg_{1-\kappa}(1/x)=g_\kappa(x)$ 给出：

$$D_\kappa(P\|Q)=D_{1-\kappa}(Q\|P). \tag{A.9}$$

在 $\kappa=1/2$，$D_{1/2}(P\|Q)=4(1-\sum\sqrt{PQ})=2H^2(P,Q)$。

若 g 在一附近三阶可微，$g''(1)=1$，并且 $P=Q+\delta$、$\sum_a\delta_a=0$、$\max_a|\delta_a/Q_a|\to 0$，则

$$D_g(Q+\delta\|Q)=\frac12\sum_a\frac{\delta_a^2}{Q_a}+O\left(\sum_a\frac{|\delta_a|^3}{Q_a^2}\right). \tag{A.10}$$

证明是对 $g(1+\delta_a/Q_a)$ 逐项 Taylor 展开；常数和一次项消失，余项乘以 Q_a 后求和。这个共同 Fisher 二阶尺度不表示不同散度在远处相等。

A.4 中心化坐标与归一化恢复

固定 $q,m>0$。定义 $e=C_q\log(p/m)$，则 $\mathbb{E}_q e=0$。写 $\log(p/m)=e+c$，归一化给出 $e^c\mathbb{E}_m e^e=1$，故

$$p_a=m_a e^{e_a-\Lambda(e)},\qquad \Lambda(e)=\log\mathbb{E}_m e^e. \tag{A.11}$$

反过来，任何 $\mathbb{E}_q e=0$ 的有限向量经该式得到正分布，并恢复原 e。因此归一化分布与 q 中心化坐标一一对应。$\Lambda(e)$ 可以为负，因为中心化使用 q，配分函数使用 m。

欧氏中心坐标 $P_\perp v$ 使用 $P_\perp=I-\mathbf{1}\mathbf{1}^\top/|\mathcal{V}|$，而 $C_q v$ 使用 q。两者相差常数，代表同一个归一化自由度；它们的欧氏范数及所在子空间不能直接混用。

A.5 从对数误差到概率距离

引理 A.1 (加权误差控制跨度)

若 $q_i,q_j>0$，则

$$(v_i-v_j)^2\le(q_i^{-1}+q_j^{-1})\mathbb{E}_q v^2. \tag{A.12}$$

特别地，若 $q_a\ge q_{\min}>0$，则 $(\operatorname{osc} v)^2\le 2\mathbb{E}_q v^2/q_{\min}$。♡

证明 将差写为 $(\sqrt{q_i}v_i,\sqrt{q_j}v_j)\cdot(q_i^{-1/2},-q_j^{-1/2})$，应用 Cauchy–Schwarz，再把两个加权平方放大为全部平方和。选择最大与最小动作即得跨度界。

定理 A.1 (Hilbert 距离到 TV 的锐界)

对正概率分布，

$$\mathrm{TV}(p,q)\le\tanh\left(\frac{\operatorname{osc}\log(p/q)}{4}\right). \tag{A.13}$$

任意给定正跨度都有二元分布取等。♡

证明 令 $L=p/q$、$l=\min L$、$u=\max L$、$h=u/l=e^\delta$。$\mathbb{E}_q L=1$ 保证 $l\le 1\le u$。凸函数 $|L-1|$ 不超过端点

连线，所以

$$\mathrm{TV}(p,q) \le \frac{(u-1)(1-l)}{u-l} = \frac{h+1-hl-l^{-1}}{h-1} \le \frac{\sqrt{h}-1}{\sqrt{h}+1}. \tag{A.14}$$

最后一步使用 $hl + l^{-1} \ge 2\sqrt{h}$。取 L 的两值为 $e^{\delta/2}, e^{-\delta/2}$，在 q 下的概率为 $1/(1+e^{\delta/2})$ 和 $e^{\delta/2}/(1+e^{\delta/2})$。它们满足均值一，且弦线及算术–几何均值不等式同时取等。

另一个常用界是 Pinsker 不等式 $\mathrm{TV}(p,q) \le \sqrt{\mathrm{KL}(p\|q)/2}$。为给出常数，取 $B = \{a : p_a \ge q_a\}$，则 $p(B) - q(B) = \mathrm{TV}(p,q)$。log-sum 不等式把 KL 下界为二元 KL。固定 $v = q(B)$，函数

$$b(u) = u\log(u/v) + (1-u)\log[(1-u)/(1-v)] \tag{A.15}$$

满足 $b(v) = b'(v) = 0$、$b''(u) = 1/[u(1-u)] \ge 4$。在 v, u 之间积分两次，得到 $b(u) \ge 2(u-v)^2$。非平凡正支持情形中 $0 < v < 1$；距离为零时直接成立。

附录 B 重心、教师目标与镜像下降

B.1 密度比矩、散度与几何重加权

固定教师 T，当前学生 $p=p_\theta$，令 $\rho=T/p$，定义 $g(u)=\mathbb{E}_p\rho^u=\sum_a T_a^u p_a^{1-u}$。有限正支持下可逐项求导：

$$g(0)=g(1)=1,\quad g'(u)=\mathbb{E}_p[\rho^u\log\rho],\quad g''(u)=\mathbb{E}_p[\rho^u\log^2\rho]\geq 0. \tag{B.1}$$

两个端点斜率为 $g'(0)=-\mathrm{KL}(p\|T)$、$g'(1)=\mathrm{KL}(T\|p)$。因此 $D_\kappa(T\|p)=[1-g(\kappa)]/[\kappa(1-\kappa)]$ 在两个端点连续恢复对应 KL；严格凸性或 Hölder 给 $g(\kappa)<1$，除非 $p=T$。

对学生参数求导，T 冻结，概率项 $p_a^{1-\kappa}$ 的导数为 $(1-\kappa)p_a^{1-\kappa}\psi_a$。所以

$$-\nabla_\theta D_\kappa(T\|p)=\frac{1}{\kappa}\mathbb{E}_p[\rho^\kappa\psi]=\mathbb{E}_p\left[\frac{\rho^\kappa-1}{\kappa}\psi\right]. \tag{B.2}$$

第二式使用 $\mathbb{E}_p\psi=0$。$\kappa\downarrow 0$ 给逆向 KL 的 log-ratio 方向；$\kappa=1$ 给 $\mathbb{E}_T\psi$。令 $\pi_\kappa\propto T^\kappa p^{1-\kappa}$，相同梯度也写成 $g(\kappa)\mathbb{E}_{\pi_\kappa}\psi/\kappa$。这个几何重加权测度随当前学生变化，解释每次冻结测度后的局部最大似然方向。

在 $\kappa\downarrow 0$，$\pi_\kappa=p[1+\kappa C_p\log(T/p)]+O(\kappa^2)$，所以 $\mathbb{E}_{\pi_\kappa}\psi$ 的零阶项为零，一阶项与外部 $1/\kappa$ 抵消。这里的 π_κ 是梯度积分的测度，通常不等于重心问题的 $m_{\kappa,\eta}$；后者还包含独立的插值参数 η。

B.2 加权重心的两个端点与多教师形式

对 $\kappa=0$，令 $Z_0=\sum_a q_a^{1-\eta}T_a^\eta$。展开各对数可得

$$(1-\eta)\,\mathrm{KL}(p\|q)+\eta\,\mathrm{KL}(p\|T)=\mathrm{KL}(p\|m_{0,\eta})-\log Z_0. \tag{B.3}$$

对 $\kappa=1$，$m=(1-\eta)q+\eta T$，因此

$$(1-\eta)\,\mathrm{KL}(q\|p)+\eta\,\mathrm{KL}(T\|p) \tag{B.4}$$

$$=\mathrm{KL}(m\|p)+(1-\eta)\,\mathrm{KL}(q\|m)+\eta\,\mathrm{KL}(T\|m). \tag{B.5}$$

两式既确定最优分布，也确定有限误差应使用哪个 KL 方向。

对任意有限个正分布 $T^{(j)}$ 与非负权重 w_j、$\sum_j w_j=1$，令 $S_a=\sum_j w_j(T_a^{(j)})^\kappa$。正文证明逐项保持不变，得到

$$m_a=\frac{S_a^{1/\kappa}}{\sum_b S_b^{1/\kappa}},\qquad \sum_j w_j D_\kappa(T^{(j)}\|p)-\sum_j w_j D_\kappa(T^{(j)}\|m)=Z^\kappa D_\kappa(m\|p). \tag{B.6}$$

几何端点取 $m\propto\prod_j(T^{(j)})^{w_j}$，算术端点取加权概率和。锚点可作为一个分布加入。多教师重心并不意味着每个教师距离都下降；各教师目标可能冲突。

对 $0<\kappa<1$，重心目标在最优点的概率 Hessian 为 $Z^\kappa\,\mathrm{diag}(1/m)$。若参数化模型恰好实现 m，令概率 Jacobian 为 $B_\theta=\partial p/\partial\theta$，则

$$\nabla_\theta^2 F(p_\theta)\big|_{p=m}=Z^\kappa B_\theta^\top\,\mathrm{diag}(1/m)B_\theta. \tag{B.7}$$

链式法则的另一项为 $\sum_a(\partial F/\partial p_a)\nabla_\theta^2 p_a$；最优点的概率梯度是常数向量，该项由 $\sum_a p_a=1$ 消失。离开可实现最优点时不能删除这项。

B.3 逆向构造的唯一性与通用信号

若要求 $D_\omega(T\|p)$ 的逐坐标梯度是 $-A(T/p)$，透视函数求导强制 $\omega-x\omega'=-A$。于是

$$(\omega(x)/x)'=A(x)/x^2. \tag{B.8}$$

加上 $\omega(1)=0$ 唯一确定正文积分式；$A(1)=0$ 再保证 $\omega'(1)=0$。若只指定单纯形上的梯度，允许添加不改变散度的线性规范项；这里的规范化消除了该自由度。

更一般，若 $S(1)=0$、$S'(x)>0$，定义

$$\omega_S(x)=x\int_1^x S(u)u^{-2}\,du,\qquad J_S(p;T)=D_{\omega_S}(T\|p). \tag{B.9}$$

则 $\omega_S''=S'/x>0$、$\nabla_p J_S=-S(T/p)$，熵镜像步为 $p^+\propto qe^{\tau S(T/q)}$。若 $L_S=\sup_{x>0}xS'(x)<\infty$，则

$$\nabla_p^2 J_S=\operatorname{diag}[x_aS'(x_a)/p_a]\preceq L_S\nabla^2\Phi. \tag{B.10}$$

这证明相对光滑性。它本身不保证统一方差、可估计中心或有限神经网络拟合。

B.4 完整的下降与收敛推导

固定 κ,η,T，记 $J=J_{\kappa,\eta}$，另取 $0<\tau\le\eta$。p^+ 最小化 $\langle\nabla J(q),p-q\rangle+\mathrm{KL}(p\|q)/\tau$。一阶条件与概率差作内积，得

$$\langle\nabla J(q),p^+-q\rangle=-\tau^{-1}[\mathrm{KL}(p^+\|q)+\mathrm{KL}(q\|p^+)]. \tag{B.11}$$

将它代入相对光滑式：

$$J(q)-J(p^+)\ge\tau^{-1}\,\mathrm{KL}(q\|p^+)+(\tau^{-1}-\eta^{-1})\,\mathrm{KL}(p^+\|q). \tag{B.12}$$

凸性给出 $J(q)\le\langle\nabla J(q),q-T\rangle$，因为 $J(T)=0$。因此

$$J(p^+)\le\langle\nabla J(q),p^+-T\rangle+\eta^{-1}\,\mathrm{KL}(p^+\|q) \tag{B.13}$$

$$=\tau^{-1}[\mathrm{KL}(T\|q)-\mathrm{KL}(T\|p^+)]-(\tau^{-1}-\eta^{-1})\,\mathrm{KL}(p^+\|q). \tag{B.14}$$

第二行可直接核对：最优性条件使梯度与 $-\tau^{-1}\log(p^+/q)$ 相差常数，常数与 p^+-T 的内积为零；展开三个 KL 即得到该式。

每步重新计算信号并刷新 $q_{k+1}=p^+(q_k)$，对式 (B.14) 求和：

$$\sum_{k=0}^{K-1}\tau_kJ(q_{k+1})\le\mathrm{KL}(T\|q_0). \tag{B.15}$$

由式 (B.12)，$J(q_K)\le J(q_{k+1})$，故

$$J(q_K)\le\frac{\mathrm{KL}(T\|q_0)}{\sum_{k<K}\tau_k}. \tag{B.16}$$

固定正 τ 或 $\sum_k\tau_k=\infty$ 时目标趋于零。对 $\kappa=0$，KL 的连续延拓与唯一零点给出 $q_k\to T$。对 $\kappa>0$，还需排除边界极限。令

$$d_\infty=\int_1^\infty A(u)u^{-2}\,du. \tag{B.17}$$

$0<A(u)\le(\log u)/\eta$ 在 $u>1$ 上成立，故 $0<d_\infty\le1/\eta$。若某坐标 $p_a\to0$，则 $p_a\omega(T_a/p_a)\to T_ad_\infty>0$。因此目标趋零的序列不可能在边界聚集；内点零点唯一为 T，结合有限单纯形紧性得到整个序列收敛。

上述求和要求同一个 J。逐轮改变 η 或 κ 时，不能直接把各轮不同函数的下降式望远镜相消。固定前缀测度的正加权和保留推导；策略变化引起的访问测度刷新另见附录 G。

B.5 端点、JS 与曲率插值

在固定正 x 的紧积分区间上，

$$A_{0,\eta}(x)=\log x,\qquad\lim_{\eta\downarrow0}A_{\kappa,\eta}(x)=\frac{x^\kappa-1}{\kappa},\qquad\lim_{\eta\uparrow1}A_{\kappa,\eta}(x)=\log x. \tag{B.18}$$

分母在紧区间内有统一正下界，故可在 ω 的有限积分中取极限。对应二阶导数及在一处的两项规范化条件唯一确定生成函数，得到正文的三个 J 端点。

对 $\kappa=1$，令 $b=1-\eta$、$B=b+\eta x$。分部积分给出

$$\omega_{1,\eta}(x)=-\eta^{-1}\log B+x\int_1^x\frac{du}{u(b+\eta u)} \tag{B.19}$$

$$=\frac{x\log x}{b}-\left(\eta^{-1}+\frac{x}{b}\right)\log B=\frac{\eta x\log x-B\log B}{\eta b}. \tag{B.20}$$

代入 $x=T_a/p_a$ 并求和，记 $M_p=bp+\eta T$：

$$J_{1,\eta}(p;T)=\frac{\eta\,\mathrm{KL}(T\|p)-\mathrm{KL}(M_p\|p)}{\eta b} \tag{B.21}$$

$$=\frac{b\,\mathrm{KL}(p\|M_p)+\eta\,\mathrm{KL}(T\|M_p)}{\eta b}=\frac{\mathrm{JS}_\eta(p,T)}{\eta(1-\eta)}. \tag{B.22}$$

第二个等号由 $M_p=bp+\eta T$ 展开对数得到。一般 κ 的曲率满足

$$\frac{1}{\omega''_{\kappa,\eta}(x)}=(1-\eta)x^{2-\kappa}+\eta x^2=\frac{1-\eta}{g''_\kappa(x)}+\frac{\eta}{g''_0(x)}. \tag{B.23}$$

因此这里插值的是生成函数曲率的倒数，通常不是两个散度的线性组合。各生成函数均有 $\omega''(1)=1$，故不同 η 的目标也不能一般通过整体缩放互相替代。

B.6 统一有界性与教师中心

当 $\kappa>0,\eta<1$，令 $c=-\log(1-\eta)/(\kappa\eta)$。由 $A(x)\to-c$ 当 $x\downarrow0$，可得

$$\lim_{x\downarrow0}\omega(x)=c,\qquad\lim_{x\to\infty}\omega(x)/x=d_\infty. \tag{B.24}$$

第一式把积分拆为 $[x,b]$ 与 $[b,1]$：选小 b 使 $|A(u)+c|\le\epsilon$，前段误差不超过 $\epsilon x(1/x-1/b)$，后段乘 x 趋零。凸函数导数不超过无穷远渐近斜率，所以 $\omega(x)\le c+d_\infty x$。于是

$$0\le J(p;T)\le c+d_\infty. \tag{B.25}$$

取 $p=(\epsilon,1-\epsilon)$、$T=(1-\epsilon,\epsilon)$，两坐标分别趋于 d_∞,c，证明这是锐上确界。

教师中心有生成函数 $\phi(x)=x-1-A(x)$，因为 $\mathbb{E}_q(T/q-1)=0$：

$$K_T=D_\phi(T\|q). \tag{B.26}$$

计算得

$$\frac{\phi''(x)}{\omega''(x)}=1-\frac{\kappa(1-\eta)}{1-\eta+\eta x^\kappa}\in[1-\kappa,1]. \tag{B.27}$$

两生成函数在一处的值和一阶导数均为零。对二阶导数差积分两次，可知 $\phi-(1-\kappa)\omega$ 与 $\omega-\phi$ 均非负。因此

$$(1-\kappa)J(q;T)\le K_T\le J(q;T). \tag{B.28}$$

中心作为当前分布函数时，梯度为

$$\partial_{p_a}K_T(p,T)=-A(x_a)+\frac{x_a^\kappa}{1-\eta+\eta x_a^\kappa}-1. \tag{B.29}$$

额外项一般随动作变化，所以中心不是教师目标 J 的替代梯度。

B.7 固定幂散度的镜像步与小步流

若直接固定目标 $D_\kappa(T\|p)$，可取概率梯度代表 $(1-(T/p)^\kappa)/\kappa$。其步长 τ 的熵镜像解是

$$\widetilde{m}_a\propto q_a\exp\left[\frac{\tau}{\kappa}\left((T_a/q_a)^\kappa-1\right)\right]. \tag{B.30}$$

它与幂均值目标仅一阶一致。对后者展开 $h_a=q_a[1+\eta(\rho_a^\kappa-1)/\kappa+O(\eta^2)]$，除以其总和得到式 (4.2)。在 Fisher 内积 $\langle v,w\rangle_q=\sum_a v_aw_a/q_a$ 下，任意切向量 w 满足

$$\langle v_\kappa,w\rangle_q=-\sum_a w_a\,\partial_{q_a}D_\kappa(T\|q), \tag{B.31}$$

因为 $\sum_a w_a = 0$ 消去常数。连续流 $\dot{q} = v_\kappa$ 因而有

$$\frac{d}{dt} D_\kappa(T\|q) = -\|v_\kappa\|_q^2 = -\frac{\mathrm{Var}_q(\rho^\kappa)}{\kappa^2}. \tag{B.32}$$

这些展开固定正分布，余项不对任意极端密度比统一。

附录 C 内层投影与优化几何

C.1 统一坐标中的四种目标

固定 q, m, f，其中 $m \propto qe^f$。令 $G = C_q f$、$\Delta = \log Z - \mathbb{E}_q f = \mathrm{KL}(q\|m)$，采用附录 A 的 $e = C_q \log(p/m)$ 与 $\Lambda(e) = \log \mathbb{E}_m e^e$。则

$$U = G - \Delta + e - \Lambda(e), \qquad K_S = \Delta + \Lambda(e). \tag{C.1}$$

代入四种损失：

$$R_P = e - \Lambda, \qquad R_B = e, \qquad R_M = e - \Lambda - \Delta, \tag{C.2}$$

$$L_{\mathrm{Part}} = \tfrac{1}{2}\mathbb{E}_q e^2 + \tfrac{1}{2}\Lambda^2, \tag{C.3}$$

$$\eta L_{\mathrm{BPO}} = \tfrac{1}{2}\mathbb{E}_q e^2, \tag{C.4}$$

$$L_{\mathrm{Mean}} = \tfrac{1}{2}\mathbb{E}_q e^2 + \tfrac{1}{2}(\Lambda + \Delta)^2, \tag{C.5}$$

$$L_{\mathrm{MDPO}} = \eta^{-1}\,\mathrm{KL}(p(e)\|m) - \eta^{-1}\log Z. \tag{C.6}$$

三个平方分解使用 $\mathbb{E}_q e = 0$，没有忽略任何均值项。它们也给出

$$L_{\mathrm{Part}} = \eta L_{\mathrm{BPO}} + \tfrac{1}{2}(\Delta - K_S)^2, \quad L_{\mathrm{Mean}} = \eta L_{\mathrm{BPO}} + \tfrac{1}{2}K_S^2. \tag{C.7}$$

求导后，额外项分别为 $(K_S - \Delta)\nabla K_S$ 与 $K_S \nabla K_S$。在锚点 $K_S = 0$ 且 $\nabla K_S = 0$，这些差异暂时消失。

C.2 Mean 的完整约束解

Mean 优化 $\frac{1}{2}\mathbb{E}_q(U - G)^2$，约束为 $\mathbb{E}_q e^U = 1$。取拉格朗日函数

$$\mathscr{L}(U, \lambda) = \tfrac{1}{2}\mathbb{E}_q(U - G)^2 + \lambda(\mathbb{E}_q e^U - 1). \tag{C.8}$$

逐坐标一阶条件给出 $U_a - G_a + \lambda e^{U_a} = 0$。当 $\lambda \geq 0$ 时，解为

$$U_a = G_a - W_0(\lambda e^{G_a}), \tag{C.9}$$

其中 $W_0(x)e^{W_0(x)} = x$，取非负实主支。

定理 C.1 (Mean 全局解存在且唯一)

函数

$$\Psi(\lambda) = \sum_a q_a \exp[G_a - W_0(\lambda e^{G_a})] \tag{C.10}$$

在 $\lambda \geq 0$ 连续、严格递减，$\Psi(0) = \mathbb{E}_q e^G \geq 1$ 且 $\Psi(\lambda) \to 0$。故存在唯一 $\lambda \geq 0$ 使 $\Psi(\lambda) = 1$；由式 (C.9) 构造的分布是唯一全局最优解 p^{M}。此外

$$\lambda = \mathrm{KL}(q\|p^{\mathrm{M}}). \tag{C.11}$$

证明 W_0 在非负轴连续严格递增，所以每个求和项严格递减。Jensen 给出起点界，有限项分别趋零给出无穷远极限。若 G 非恒定，Jensen 严格，故根 $\lambda > 0$；若 $G = 0$，根为零。

固定这个乘子，$\nabla_U^2 \mathscr{L} = \mathrm{diag}[q_a(1 + \lambda e^{U_a})] \succ 0$，所以构造点唯一最小化整个欧氏空间上的 $\mathscr{L}$。在所有可行 U 上，乘子项为零；构造点又可行，所以它唯一最小化原目标。这一论证不需要指数等式约束集合凸。对 KKT 取 q 均值，$\mathbb{E}_q G = 0$、$\mathbb{E}_q e^U = 1$ 给出 $\mathbb{E}_q U + \lambda = 0$，即所述 KL 恒等式。

这个最优分布还唯一最大化

$$\mathbb{E}_p f - \mathrm{KL}(p\|q) - \frac{\lambda}{2}\chi^2(p\|q). \tag{C.12}$$

证明是其概率梯度为 $f-U-1-\lambda(p/q-1)$，在 Mean 解处由 KKT 化为动作无关常数；Hessian 为 $-\operatorname{diag}(1/p+\lambda/q)\prec 0$。这里 λ 由 Mean 解决定，并非预先独立选择的正则系数。

对任意正分布 p，还有精确超额损失分解

$$L_{\mathrm{Mean}}(p)-L_{\mathrm{Mean}}(p^{\mathrm{M}})=\tfrac{1}{2}\mathbb{E}_q\log^2(p/p^{\mathrm{M}})+\lambda\,\mathrm{KL}(p^{\mathrm{M}}\|p). \tag{C.13}$$

令 $v=U-U^\star$，平方展开的交叉项为 $\mathbb{E}_q v(U^\star-G)$。KKT 将它变成 $-\lambda\mathbb{E}_{p^{\mathrm{M}}}v=\lambda\,\mathrm{KL}(p^{\mathrm{M}}\|p)$，即得结论。

C.3 精确曲率与唯一驻点

以独立 logits z 表示 p，令 $Q_p=\operatorname{diag}(p)-pp^\top$，以 $\mathbf{e}_a$ 表示第 a 个坐标基向量，与中心化误差 e 区分。于是

$$\nabla_z\log p_a=\mathbf{e}_a-p,\qquad \nabla_z^2\log p_a=-Q_p. \tag{C.14}$$

对 Part 或 Mean 的残差 R，

$$\nabla_z\tfrac{1}{2}\mathbb{E}_qR^2=q\odot R-(\mathbb{E}_qR)p,\qquad \nabla_z^2\tfrac{1}{2}\mathbb{E}_qR^2=\mathbb{E}_q[(\mathbf{e}_a-p)(\mathbf{e}_a-p)^\top]-(\mathbb{E}_qR)Q_p. \tag{C.15}$$

在锚点，Mean 残差均值为零、Part 为 Δ，故

$$\nabla_z^2L_{\mathrm{Mean}}|_q=Q_q,\quad \nabla_z^2L_{\mathrm{Part}}|_q=(1-\Delta)Q_q,\quad \nabla_z^2L_{\mathrm{BPO}}=Q_q/\eta. \tag{C.16}$$

例如 $q=(1/2,1/2)$、$f=(2,-2)$，则 $\Delta=\log\cosh 2>1$，Part 在全部非常数方向有负曲率。

Part 仍只有一个有限内部驻点。记 $R=\log(p/m)$、$c=\mathbb{E}_qR$，驻点条件为 $q_aR_a=cp_a$。若 $c>0$，每个 $R_a>0$，于是每个 $p_a>m_a$，与归一化矛盾；若 $c<0$，同理每个 $p_a<m_a$ 也矛盾。故 $c=0$，正 q 强制 $R=0$。内部驻点唯一不等于任意优化器全局收敛。

MDPO 的完整二阶方向导数也可以写出，无需以未定义的残差项代替。固定 logit 方向 v，沿 $p_t\propto pe^{tv}$，令 $h=\log(p/m)$、$\bar v=\mathbb{E}_pv$。指数倾斜的微分恒等式为 $\frac{d}{dt}\mathbb{E}_{p_t}u=\mathrm{Cov}_{p_t}(u,v)$，若 u 依赖 t 再加 $\mathbb{E}_{p_t}\dot u$。因此

$$\frac{d}{dt}\,\mathrm{KL}(p_t\|m)\big|_0=\mathrm{Cov}_p(h,v), \tag{C.17}$$

$$\frac{d^2}{dt^2}\,\mathrm{KL}(p_t\|m)\big|_0=\mathrm{Var}_p(v)+\mathrm{Cov}_p\big(h,(v-\bar v)^2\big). \tag{C.18}$$

第二式中 $\dot h=v-\bar v$ 产生方差项；对协方差中的分布求导产生中心三阶混合矩。MDPO 的 Hessian 再除以 η。当 $p=m$ 时第二项为零；一般位置不能删除它。

在 $\mathbb{E}_qe=0$ 的坐标中，对 $\mathbb{E}_qv=0$ 的方向，

$$\nabla^2L_{\mathrm{Part}}[v,v]=\mathbb{E}_qv^2+\Lambda\,\mathrm{Var}_p\,v+(\mathbb{E}_pv)^2, \tag{C.19}$$

$$\nabla^2L_{\mathrm{Mean}}[v,v]=\mathbb{E}_qv^2+(\Lambda+\Delta)\,\mathrm{Var}_p\,v+(\mathbb{E}_pv)^2. \tag{C.20}$$

这是对 $\Lambda'=\mathbb{E}_pv$、$\Lambda''=\mathrm{Var}_p\,v$ 使用乘积法则的结果。

C.4 受限表示改变投影

取 $q=(1/3,1/3,1/3)$、$m=(0.1,0.7,0.2)$、$\eta=1$，学生族为 $p(z)=\mathrm{softmax}(z,0,0)$。令 $a=\log 0.1,b=\log 0.7,c=\log 0.2$。BPO 为 $\frac{1}{2}\mathrm{Var}_q(z-a,-b,-c)$，导数为 $\frac{2}{9}[z-a+(b+c)/2]$，故最优 $z_B=a-(b+c)/2$。

令 $u(z)=\mathbb{E}_q\log[p(z)/m]=z/3-\log(e^z+2)-(a+b+c)/3$，则 $L_{\mathrm{Part}}=L_{\mathrm{BPO}}+u^2/2$，所以

$$L'_{\mathrm{Part}}(z_B)=u(z_B)[1/3-p_1(z_B)]\simeq 0.03543884\neq 0. \tag{C.21}$$

两个目标在同一受限学生族中具有不同最优点。

BPO 与 MDPO 也可分离。取两个等权前缀，锚点第一动作概率分别为 $0.8,0.2$，共享相对 logit 位移 θ；目标相对位移取 $g_1=1,g_2=3$。BPO 的权重均为 0.16，故 $\theta_B=2$。MDPO 的驻点方程为

$$\sum_{i=1}^{2}p_{\theta,i}(1-p_{\theta,i})(\theta-g_i)=0. \tag{C.22}$$

在 $\theta = 2$，第一项权重约为 0.0316，第二项约为 0.2278，和非零。该方程是必要驻点条件，不把任意根直接称为唯一全局解。

C.5 自由 logits 的收敛与理想路径

令 $h = z - \log m$。中心化消去 softmax 配分函数，得到

$$L_{\mathrm{BPO}} = \frac{h^\top Q_q h}{2\eta}, \quad \nabla_z L_{\mathrm{BPO}} = \frac{Q_q h}{\eta}. \tag{C.23}$$

Q_q 的零空间为常数方向。在欧氏子空间 $\mathbf{1}^\perp$ 上，

$$q_{\min}\|v\|^2 \le v^\top Q_q v \le \tfrac{1}{2}\|v\|^2. \tag{C.24}$$

下界由 $\mathrm{Var}_q\, v = \min_c \sum_a q_a (v_a - c)^2 \ge q_{\min} \min_c \sum_a (v_a - c)^2$ 得到。上界由方差不超过分量范围平方的 $1/4$，以及 $(v_i - v_j)^2 \le 2\|v\|^2$ 得到。

普通梯度下降的每个非零谱方向乘以 $1 - \alpha_{\mathrm{opt}}\lambda_i/\eta$。对全部初值收敛的充要条件是

$$0 < \alpha_{\mathrm{opt}} < 2\eta/\lambda_{\max}(Q_q). \tag{C.25}$$

其中 $\alpha_{\mathrm{opt}} < 4\eta$ 是统一充分条件。

MDPO 的 logit 梯度为 $Q_p(z - \log m)/\eta$。正支持下 $Q_p^\dagger Q_p = P_\perp$；BPO 使用 $Q_q^\dagger$ 也得到同一投影。因此两种对应的精确自然梯度步都满足

$$P_\perp h^+ = (1-\gamma) P_\perp h, \quad p^+ \propto p^{1-\gamma} m^\gamma, \qquad \gamma = \alpha_{\mathrm{opt}}/\eta. \tag{C.26}$$

BPO 的 Fisher 冻结在 q，MDPO 的 Fisher 来自当前 p。从 $p_0 = q$ 出发，若 $0 < \gamma_j \le 1$，

$$p_n \propto q e^{\xi_n f}, \qquad \xi_n = 1 - \prod_{j<n}(1-\gamma_j), \qquad L_{\mathrm{BPO}}(p_n) = (1-\xi_n)^2 L_{\mathrm{BPO}}(q). \tag{C.27}$$

定理 C.2 (理想内层路径的教师散度进展)

对所有凸 φ、$\varphi(1) = 0$，沿 $p_\xi \propto q e^{\xi f}$、$0 \le \xi \le 1$，$D_\varphi(p_\xi \| T)$ 非增。 ♡

证明 令 $r = \log(T/q)$。$f(r)$ 递增且

$$f'(r) = \frac{\eta e^{\kappa r}}{1 - \eta + \eta e^{\kappa r}} \le 1 \tag{C.28}$$

（几何端点为 η）。因此 $u_\xi(r) = p_\xi/T = e^{-r + \xi f(r)}/Z_\xi$ 非增。可微凸 φ 的导数递增，故 $\varphi'(u_\xi(r))$ 非增。微分归一化密度：

$$\frac{d}{d\xi} D_\varphi(p_\xi \| T) = \mathrm{Cov}_{p_\xi}(\varphi'(u_\xi), f) \tag{C.29}$$

$$= \frac{1}{2} \sum_{a,b} p_{\xi,a} p_{\xi,b} [\varphi'(u_{\xi,a}) - \varphi'(u_{\xi,b})](f_a - f_b) \le 0. \tag{C.30}$$

每个乘积非正。有限正支持使所有 $u_{\xi,a}$ 位于紧正区间；对任意有限凸函数用光滑凸函数一致逼近，取极限保留非增结论。

C.6 共享参数、拟合形状与条件 SGD

一般网络 $z = z_\theta$ 的 Hessian 为

$$\nabla_\theta^2 L_{\mathrm{BPO}} = \eta^{-1} \left[B_\theta^\top Q_q B_\theta + \sum_a (Q_q h)_a \nabla_\theta^2 z_a \right]. \tag{C.31}$$

这里 $B_\theta = \partial z/\partial\theta$，即使冻结 Q_q，两项仍可变化。自由 logit 的凸性不自动传到参数空间。

也可固定目标 $m_{\kappa,\eta}$ 后另选拟合形状 β，优化 $D_\beta(m\|p)$。从当前学生采样，令 $x = m/p$、$a_\beta = \mathbb{E}_p x^\beta$，则

$$g_\beta(a) = \frac{a_\beta - x_a^\beta}{\beta}\psi_a, \qquad \mathbb{E}_p g_\beta = \nabla_\theta D_\beta(m\|p). \tag{C.32}$$

对 $0 < \beta \le 1/2$、$\|\psi_a\| \le S$，附录 D 的矩不等式给出 $\mathbb{E}_p\|g_\beta\|^2 \le S^2 D_\beta(m\|p)/\beta$。$\beta$ 控制拟合，κ 控制目标，不能混为一个最优形状判断。BPO 本身也满足

$$\mathbb{E}_q\|R_B\psi/\eta\|^2 \le (2S^2/\eta)L_{\mathrm{BPO}}. \tag{C.33}$$

设 L 在所有更新线段上为 L_{sm} 光滑，满足 PL 条件 $\|\nabla L\|^2 \ge 2\mu(L - L_\star)$，随机梯度条件无偏且 $\mathbb{E}[\|g\|^2 \mid \theta] \le CL$。对 $0 < \alpha \le \min\{1/\mu, 2\mu/(L_{\mathrm{sm}}C)\}$，光滑性给出

$$\mathbb{E}[L(\theta - \alpha g) \mid \theta] \le L - \alpha\|\nabla L\|^2 + \tfrac{1}{2}L_{\mathrm{sm}}\alpha^2 CL \tag{C.34}$$

$$\le L_\star + (1 - \mu\alpha)(L - L_\star) + \tfrac{1}{2}L_{\mathrm{sm}}C\alpha^2 L_\star. \tag{C.35}$$

取全期望并展开几何递推，得到

$$\mathbb{E}(L_N - L_\star) \le (1 - \mu\alpha)^N(L_0 - L_\star) + \frac{L_{\mathrm{sm}}C\alpha L_\star}{2\mu}[1 - (1 - \mu\alpha)^N]. \tag{C.36}$$

这是明确假设下的 SGD 结论。模型可实现时 $L_\star = 0$，该上界没有固定采样噪声底；数据复用、中心近似或其他优化器需要重新核对假设。

C.7 与条件 OPD 基线的关系

对当前学生–教师目标 $\mathrm{KL}(p\|T)$，令 $r^{\mathrm{cur}} = \log(T/p)$。其精确梯度及冻结锚点下的表示为

$$\nabla_\theta \mathrm{KL}(p\|T) = -\mathbb{E}_p[r^{\mathrm{cur}}\psi_p] = -\mathbb{E}_q[(p/q)r^{\mathrm{cur}}\psi_p]. \tag{C.37}$$

这个重要性比只改变当前前缀下的动作积分，不改变前缀访问测度。

几何端点取 $f = \eta\log(T/q)$，MDPO 恒等式为

$$L_{\mathrm{MDPO}} = \mathrm{KL}(p\|T) + (\eta^{-1} - 1)\,\mathrm{KL}(p\|q). \tag{C.38}$$

因此 $\eta = 1$ 时 MDPO 的总体目标处处等于条件 OPD。BPO 在该点仍使用 $\mathrm{Var}_q \log(p/T)/2$，Mean 还包含学生中心平方，二者只在特定位置与 OPD 有相同梯度或共同目标分布。

对固定几何 reward $r = \log(T/q)$，令 $\eta \to \infty$ 删除镜像正则，MDPO 目标趋于 $-\mathbb{E}_p r$，其最优分布支持在 r 的最大值集合，通常不等于 T。如果保持当前 OPD 目标，则 reward 必须随学生改为 $r^{\mathrm{cur}} = r - U$。两者只在初始化 $p = q$ 处相同。这里的无穷步长讨论仅适用于几何端点，不将正形状的混合权重扩展到概率区间之外。

C.8 标量步长能改变的部分

固定二次超额损失 $E = \frac{1}{2}e^\top He$，沿方向 d 更新时，

$$E(\theta - \alpha d) = E - \alpha A + \tfrac{1}{2}\alpha^2 B, \quad A = \nabla E^\top d, \quad B = d^\top H d. \tag{C.39}$$

若 $A > 0, B > 0$，最优步长 $\alpha_* = A/B$，最大相对下降为 $\rho_* = A^2/(2BE) \le 1$。最后一个界来自 H 半内积的 Cauchy–Schwarz。达到 $0 < \rho \le \rho_*$ 的较小正根为

$$\alpha_\rho = \frac{2\rho E}{A + \sqrt{A^2 - 2B\rho E}}. \tag{C.40}$$

若 $A \le 0$，任何正步长都不能降低这个二次目标；标量调度无法修复方向错误。

梯度流的谱表达为 $E(t) = \frac{1}{2}\sum_i \lambda_i e_i(0)^2 e^{-2\lambda_i t}$。以各项在总损失中的占比为 w_i，求导得

$$-\frac{d}{dt}\log E = 2\mathbb{E}_w\lambda, \qquad \frac{d}{dt}\left[-\frac{d}{dt}\log E\right] = -4\,\mathrm{Var}_w\,\lambda \le 0. \tag{C.41}$$

快方向先消失，使相对下降率变慢。精确线搜索在谱区间 $[l, u]$ 的最坏收缩因子仍为 $[(u - l)/(u + l)]^2$：由 $\lambda^2 \le (l + u)\lambda - lu$，最小化 $\mathbb{E}_w\lambda^2$ 上界所对应的比例可得 $\rho_* \ge 4lu/(l + u)^2$。

若固定谱端点已知，Chebyshev 步序 $\alpha_j = [c - d\cos((2j-1)\pi/(2N))]^{-1}$，其中 $c = (u+l)/2, d = (u-l)/2$，产生误差多项式 $T_N((c-\lambda)/d)/T_N(c/d)$，故

$$E_N \le 4\left(\frac{\sqrt{u/l}-1}{\sqrt{u/l}+1}\right)^{2N} E_0. \tag{C.42}$$

该恒等式由两侧多项式具有相同根和零点处归一化得到；$|T_N| \le 1$ 在 $[-1,1]$ 上，再用 $T_N(x) = (v^N + v^{-N})/2$ 得到界。$u = l$ 时单步 $\alpha = 1/l$ 即可。这个结论需要固定线性几何，且允许中间误差放大。

对 Adam，恒定 loss 缩放 $s > 0$ 在相同梯度历史和零初始状态下使一阶矩乘 s、二阶矩乘 s^2，故方向只把数值稳定项 ϵ 换为 ϵ/s；学习率乘 s 则直接改变参数步长。非恒定缩放还改变矩历史，不能用梯度流的时间重参数化解释。沿固定 Adam 方向作三点测量可由 $Q(0), Q(h), Q(2h)$ 恢复二次式的 A, B，但非线性网络中必须用实际目标值验收；一次试探不能重复更新优化器矩状态。

附录 D 形状、概率路径与监督矩

D.1 覆盖界与目标半径

对 $0<\kappa\le 1$，幂均值不等式给 $h_a\le(1-\eta)q_a+\eta T_a$，所以 $Z\le 1$。令 $r=1/\kappa\ge 1$，非负 x,y 满足 $(x+y)^r\ge x^r+y^r$；例如对固定 x，两侧之差对 y 的导数非负，且在 $y=0$ 为零。因此

$$(1-\eta)^{1/\kappa}+\eta^{1/\kappa}\le Z\le 1,\qquad m_a\ge(1-\eta)^{1/\kappa}q_a+\eta^{1/\kappa}T_a. \tag{D.1}$$

逐坐标取对数并按相应分布平均，得到

$$\mathrm{KL}(q\|m)\le-\kappa^{-1}\log(1-\eta),\quad \mathrm{KL}(T\|m)\le-\kappa^{-1}\log\eta. \tag{D.2}$$

固定教师的精确刷新 $q^+=m$ 还给后续概率比 $(T_a/q_a^+)^\kappa\le 1/\eta$，所以下一轮

$$-c_{\kappa,\eta}\le A_{\kappa,\eta}(T_a/q_a^+)\le\frac{\log(2-\eta)}{\kappa\eta}. \tag{D.3}$$

这个双侧界依赖精确刷新产生的覆盖；任意初始锚点只有单侧下界。

命题 D.1 (目标到锚点的半径)

固定 q,T,κ。对任意凸 φ、$\varphi(1)=0$，$D_\varphi(m_{\kappa,\eta}\|q)$ 随 $\eta\in[0,1]$ 非减。若 $q\ne T$ 且 φ 严格凸，内部严格递增。

证明 取 $0<\eta_1<\eta_2<1$，令 $\rho=T/q$、$u_i=m_{\eta_i}/q$。u_1 随 ρ 递增，而

$$\frac{m_{\eta_2}}{m_{\eta_1}}=\frac{Z_{\eta_1}}{Z_{\eta_2}}\left(\frac{1-\eta_2+\eta_2\rho^\kappa}{1-\eta_1+\eta_1\rho^\kappa}\right)^{1/\kappa} \tag{D.4}$$

也严格递增：括号对 ρ^κ 的导数为 $(\eta_2-\eta_1)/(1-\eta_1+\eta_1\rho^\kappa)^2>0$。几何端点的比值为常数乘 $\rho^{\eta_2-\eta_1}$。该比值在 m_{η_1} 下均值一，故存在交点 $\rho_\star$ 使比值等于一。

记 $u_\star=u_1(\rho_\star)$。低于交点时 $u_2\le u_1\le u_\star$，高于交点时 $u_2\ge u_1\ge u_\star$。取 $b\in\partial\varphi(u_\star)$，则 $\varphi(u)-bu$ 在 $u_\star$ 两侧向外非减，逐点得到 $\varphi(u_2)-bu_2\ge\varphi(u_1)-bu_1$。按 q 求和，因两组 u 的均值均为一，线性项抵消。严格凸与不同目标保证至少一项严格；端点由连续性得到。

D.2 精确目标同时改善凸生成散度

定理 D.1 (共同交点的散度进展)

对任意凸 φ、$\varphi(1)=0$，精确幂均值目标满足

$$D_\varphi(m\|T)\le D_\varphi(q\|T). \tag{D.5}$$

证明 写 $s_a=q_a/T_a$、$m_a=T_aG(s_a)/Z$，其中 $G(s)=[(1-\eta)s^\kappa+\eta]^{1/\kappa}$，几何端点为 $G(s)=s^{1-\eta}$。G 递增，$G(s)/s$ 递减，因为

$$\frac{d}{d\log s}\log[G(s)/s]=-\frac{\eta s^{-\kappa}}{1-\eta+\eta s^{-\kappa}}<0. \tag{D.6}$$

又有 $Z=\sum_a q_aG(s_a)/s_a$，所以存在 $s_\star$ 使 $G(s_\star)/s_\star=Z$。若 $s_a<s_\star$，则 $s_a\le G(s_a)/Z\le s_\star$；若 $s_a>s_\star$，不等号反向排列。取 φ 在 $s_\star$ 的次梯度 b，函数 $\varphi(s)-bs$ 向 $s_\star$ 移动时非增。逐项比较后按 T 求和，归一化消去线性项，得到结论。

这个更新还可由保持 T 的可逆 Markov 核表示。令 $\delta_a=m_a-q_a$，正质量接收集合为 L，输出集合为 H，总

转移量 $D=\sum_L \delta_a$。若 $D=0$ 取恒等核；否则对 $a\in L, b\in H$，定义

$$w_{ab}=w_{ba}=\frac{\delta_a(-\delta_b)}{D(s_b-s_a)},\qquad P_{ab}=w_{ab}/T_a, \tag{D.7}$$

其余非对角项为零，对角项补足行和。由共同交点，$\delta_a/T_a\le s_\star-s_a$、$(-\delta_b)/T_b\le s_b-s_\star$，故 $\sum_b w_{ab}\le T_a$、$\sum_a w_{ab}\le T_b$，核非负。详细平衡 $T_aP_{ab}=T_bP_{ba}$ 保证 $TP=T$；而接收坐标有 $(qP)_a-q_a=\sum_b w_{ab}(s_b-s_a)=\delta_a$，输出坐标同理，故 $qP=m$。这是数学表示，无需实际构造词表平方大小的矩阵。

D.3 教师中心的性质

写 $\rho=T/q$，则 $A(1)=0$、$A'>0$ 且 $A''\le 0$。Jensen 给出 $\mathbb{E}_qA(\rho)\le A(\mathbb{E}_q\rho)=0$；结合 $A\ge -c$，

$$0\le K_T=-\mathbb{E}_qA\le c_{\kappa,\eta}. \tag{D.8}$$

上界为锐上确界：取 $q=(\epsilon,1-\epsilon)$、$T=(1-\epsilon^2,\epsilon^2)$。常见动作的 $-A\to c$，稀有动作的贡献为 $O(\epsilon|\log\epsilon|)\to 0$。

固定概率比时，A 随 κ 非减：函数 $L(u)=\log(1-\eta+\eta e^{u\log\rho})$ 凸且 $L(0)=0$，故 $L(u)/u$ 在 $u>0$ 非减。另一方面，令 $y=1+\eta(\rho^\kappa-1)$，有

$$\partial_\eta A=\frac{1-y^{-1}-\log y}{\kappa\eta^2}\le 0. \tag{D.9}$$

不等式来自 $\log y\ge 1-y^{-1}$。因此 K_T 随 κ 非增，随 η 非减。标量方差没有由此得到同一排序。

小步极限及局部尺度分别为

$$\lim_{\eta\downarrow 0}K_T=\frac{1-\mathbb{E}_q\rho^\kappa}{\kappa}=(1-\kappa)D_\kappa(T\|q), \tag{D.10}$$

$$K_T=\frac{1-\kappa(1-\eta)}{2}\mathbb{E}_q(\rho-1)^2+O(\mathbb{E}_q|\rho-1|^3). \tag{D.11}$$

第一式对 $\kappa=1$ 取零；第二式要求所有比率一致趋近一。$\eta=1$ 时所有形状恢复 $A=\log\rho$ 与 $K_T=\mathrm{KL}(q\|T)$，统一有界性不再成立。

D.4 固定强度的矩界与小步阈值

定义 $C_\star=\sup_{u>0}\log^2(1+u)/u<\infty$。函数在零与无穷远都趋零，故上确界有限。对 $f=\eta A$，在 $\rho<1$ 上 $|f|\le|\log(1-\eta)|/\kappa$；在 $\rho\ge 1$ 上

$$0\le f\le\kappa^{-1}\log(1+\eta\rho^\kappa),\qquad f^2\le C_\star\eta\rho^\kappa/\kappa^2. \tag{D.12}$$

凹性给出 $\mathbb{E}_q\rho^\kappa\le 1$，所以

$$\mathbb{E}_qf^2\le\frac{\log^2(1-\eta)+C_\star\eta}{\kappa^2}. \tag{D.13}$$

标准化监督 A 的界需再除以 η^2。

定理 D.2 (小步矩阈值)

固定 $r\ge 1$、$0<\kappa\le 1$。在所有有限正概率分布上取上确界，有

$$\sup_{q,T}\mathbb{E}_q|A|^r=\Theta_{\kappa,r}(\eta^{\min\{r,1/\kappa\}-r}),\qquad \sup_{q,T}\mathbb{E}_q|C_qA|^r=\Theta_{\kappa,r}(\eta^{\min\{r,1/\kappa\}-r}) \tag{D.14}$$

当 $\eta\downarrow 0$。$\kappa=0$ 对任何正 η 都没有有限统一矩界。 ♡

证明 先估计 f。负区域为 $O_{\kappa,r}(\eta^r)$。若 $r\kappa\le 1$，用 $\log(1+x)\le x$ 和 $\mathbb{E}_q\rho^{r\kappa}\le 1$ 得正区域也是 $O(\eta^r)$。若 $r\kappa>1$，令 $s=1/\kappa<r$。函数 $\log^r(1+x)/x^s$ 在零处按 x^{r-s} 趋零，在无穷处也趋零，故有有限上界 $C_{r,s}$。于是

$$\mathbb{E}_q[|f|^r\mathbf{1}_{\rho\ge 1}]\le\kappa^{-r}C_{r,s}\eta^{1/\kappa}\mathbb{E}_q\rho=O(\eta^{1/\kappa}). \tag{D.15}$$

除以 η^r 得未中心化上界。由 $|X-\mathbb{E}X|^r\le 2^{r-1}(|X|^r+|\mathbb{E}X|^r)$ 及 Jensen，中心化矩不超过 $2^r\mathbb{E}|X|^r$。

当 $r\kappa \le 1$，任意固定不同的二元正分布使 $A \to (\rho^\kappa - 1)/\kappa$，其原始与中心化矩均为严格正常数，给出下界。当 $r\kappa > 1$，取 $q_1 = \eta^{1/\kappa}/2$、$T_1 = 1/2$。稀有动作有 $A_1 = \log(2-\eta)/(\kappa\eta)$，另一动作 $A_2 = O(1)$。所以 $q_1|A_1|^r = \Omega(\eta^{1/\kappa - r})$；中心化后的稀有值为 $(1-q_1)(A_1 - A_2)$，具有同阶贡献。几何端点取固定非退化 q，令一个教师概率趋零，即使中心化，正质量动作上的对数差也无界。

二阶矩阈值是 $\kappa \le 1/2$，四阶矩阈值是 $\kappa \le 1/4$。固定分布的小步 Taylor 展开不能替代这类允许分布随 η 改变的最坏情形论证。

D.5 误差相关方差与锐常数

令 $a_\kappa = \mathbb{E}_q \rho^\kappa$。当 $0 < \kappa \le 1/2$，函数 $h(x) = \log(1 - \eta + \eta x)/(\kappa\eta)$ 的 Lipschitz 常数不超过 $1/[\kappa(1-\eta)]$。独立同分布 X, X' 满足 $\operatorname{Var} h(X) = \frac{1}{2}\mathbb{E}[h(X) - h(X')]^2$，故

$$V_{\kappa,\eta} \le \frac{\operatorname{Var}_q(\rho^\kappa)}{\kappa^2(1-\eta)^2} \le \frac{1 - a_\kappa^2}{\kappa^2(1-\eta)^2}. \tag{D.16}$$

第二步用 $\mathbb{E}_q \rho^{2\kappa} \le 1$。

为得到与教师误差相关的界，令 $a(u) = \mathbb{E}_q \rho^u$。其二阶导数为 $\mathbb{E}_q[\rho^u \log^2 \rho] \ge 0$，所以对 $2\kappa \in [\kappa, 1]$，

$$a(2\kappa) \le \frac{1 - 2\kappa}{1 - \kappa} a(\kappa) + \frac{\kappa}{1 - \kappa}. \tag{D.17}$$

减去 $a(\kappa)^2$ 并因式分解：

$$\operatorname{Var}_q(\rho^\kappa) \le \frac{(1 - a_\kappa)[\kappa + (1-\kappa)a_\kappa]}{1 - \kappa} \le \frac{1 - a_\kappa}{1 - \kappa}. \tag{D.18}$$

代入散度定义得到式 (4.5)。最后一步利用 $\log(1 + \eta x) \le \eta x$ 得 $K_T \ge (1 - a_\kappa)/\kappa$。

在小步极限 $A^0_\kappa = (\rho^\kappa - 1)/\kappa$，

$$\sup_{q \ne T} \frac{\operatorname{Var}_q A^0_\kappa}{D_\kappa(T\|q)} = \frac{1}{\kappa}, \qquad \sup_{q \ne T} \frac{\operatorname{Var}_q A^0_\kappa}{K^0_T} = \frac{1}{\kappa(1-\kappa)}. \tag{D.19}$$

上界已证。锐性取 $q = (v, 1-v)$、$T = (v^2, 1 - v^2)$，此时 $\rho = (v, 1 + v)$。当 $v \downarrow 0$，

$$a_\kappa = 1 - (1-\kappa)v + o(v), \quad \operatorname{Var}_q A^0_\kappa = v/\kappa^2 + o(v), \quad D_\kappa = v/\kappa + o(v). \tag{D.20}$$

两比值逼近所列常数。对 $\kappa > 1/2$，取 $q = (v, 1-v), T = (1/2, 1/2)$，方差按 $v^{1-2\kappa}$ 发散；内部幂散度有界，$\kappa = 1$ 的 KL 只按 $\log(1/v)$ 增长。$\kappa = 0$ 用固定非对称 q 与趋零教师概率，方差按对数平方增长，而 KL 按一次对数增长。故相对准则的唯一最优点为 $\kappa = 1/2$。

D.6 绝对最坏方差的不同最优点

对 $0 < \kappa < 1/2$，令 $X = \rho^\kappa$、$r = 1/\kappa > 2$，则 $\mathbb{E}_q X^r = 1$。Hölder 给出

$$\mathbb{E}X^2 \le (\mathbb{E}X)^{(r-2)/(r-1)}. \tag{D.21}$$

具体地，将 $X^2 = X^{(r-2)/(r-1)}(X^r)^{1/(r-1)}$，取共轭指数 $(r-1)/(r-2)$ 与 $r - 1$ 即得。令 $a = \mathbb{E}X$、$\gamma = (1 - 2\kappa)/(1 - \kappa)$，则 $\operatorname{Var} X \le a^\gamma - a^2$。最大值处 $a^{2-\gamma} = \gamma/2$，得到

$$\sup_{q,T} \operatorname{Var} A^0_\kappa = C_{\mathrm{vel}}(\kappa) = \frac{b^{1-2\kappa}(1-b)}{\kappa^2}, \qquad b = \frac{1 - 2\kappa}{2(1-\kappa)}. \tag{D.22}$$

取 $q = (b, 1-b)$、$T \to (1, 0)$，Hölder 与驻点条件同时取等，证明锐性。$\kappa = 1/2$ 的上确界为四。对最优 b 使用包络求导，

$$\frac{d}{d\kappa} \log C_{\mathrm{vel}} = -2/\kappa - 2\log b. \tag{D.23}$$

唯一根满足 $\log[(1-2\kappa)/(2(1-\kappa))] = -1/\kappa$。左侧加 $1/\kappa$ 严格递减，端点分别趋于正、负无穷，故根唯一，数值为 $\kappa_\star \simeq 0.441928$。这个准则最小化绝对最坏方差，不等于相对误差准则，也不等于任务表现。

D.7 平方根流、局部速率与噪声可求和性

平方根点令 $a = \sum \sqrt{qT}$。小步 Fisher 速度满足 $\|v_{1/2}\|_q^2 = 4(1-a^2)$，且 $D_{1/2} = 4(1-a)$。因此沿连续自然梯度流，

$$\dot{a} = 1 - a^2, \qquad a(t) = \tanh[t + \operatorname{artanh} a(0)] \tag{D.24}$$

对 $q \neq T$ 成立；在 $q = T$ 处流恒定。又有 $\dot{D} = -(1+a)D$，故 $D(0)e^{-2t} \leq D(t) \leq D(0)e^{-t}$。离散精确更新的 Hellinger 收缩由正文式 (4.7) 证明。

固定 $T > 0$，写 $q = T + \epsilon h$、$\sum h = 0$、$S_h = \sum h_a^2/T_a$。两次二项式展开并除以归一化常数，得到

$$m_a = T_a + (1-\eta)\epsilon h_a + \frac{(\kappa-1)(1-\eta)\eta}{2}\epsilon^2\left(\frac{h_a^2}{T_a} - T_a S_h\right) + O(\epsilon^3). \tag{D.25}$$

未归一化展开中二阶项为 $(\kappa-1)(1-\eta)\eta\epsilon^2 h_a^2/(2T_a)$；其总和正是需要减去的归一化项。几何端点直接展开 $q^{1-\eta}T^{\eta}$ 给出相同结果。任何在一处二阶曲率为正的光滑 f-散度都满足局部比值 $(1-\eta)^2 + O(\epsilon)$。

最后，固定 $0 < \kappa \leq 1/2, \eta < 1$ 并精确刷新，式 (B.28) 与三点求和给出

$$\sum_{n=1}^{\infty} V_n \leq \frac{\mathrm{KL}(T\|q_0)}{\kappa(1-\kappa)(1-\eta)^2\eta}. \tag{D.26}$$

平方根点可用更直接的 Hellinger 界：

$$V_n \leq \frac{4H^2(q_n, T)}{(1-\eta)^2} \leq \frac{4(1-\eta)^n H^2(q_0, T)}{(1-\eta)^2}. \tag{D.27}$$

上界包络下降，不保证实际方差逐步单调；所有这些结论固定同一前缀、教师和参数。

附录 E 信息访问与条件积分估计

E.1 四个积分对象与可观测信息

本附录局部记当前学生为 $P = P_\theta$、冻结参考为 Q、动作提案为 β；三者职责不同。令 $\ell_a = \log(P_a/Q_a)$、$\psi_a = \nabla_\theta \log P_a$。双向 KL 及其梯度为

$$K = \mathbb{E}_P \ell, \quad g = \mathbb{E}_P[\ell\psi], \qquad K^{\mathrm{F}} = -\mathbb{E}_Q \ell, \quad g^{\mathrm{F}} = -\mathbb{E}_Q \psi. \tag{E.1}$$

g 的求导先产生 $\mathbb{E}_P[(\ell+1)\psi]$，再利用 $\mathbb{E}_P\psi = 0$。参考为锚点时可代入 $Q = q$；BPO 学生中心 $\mathrm{KL}(q\|p)$ 对应这里的正向积分。

完整词表概率允许精确有限求和。头部查询只给出集合 S 上的 Q_a 和尾部总质量；实际动作查询再给出该动作的一项概率。若 S 是教师真正的 Top-K_{head}，未知尾部还满足排名约束 $Q_a \le \min_{b\in S} Q_b$。接口是否确定某个量，应检查它在全部符合这些观测的分布上是否相同。

只保留桶质量时，不能恢复桶内形状。若实际动作落在尾部，其额外概率观测必须计入信息；也不能把一次尾部查询当成全部尾部已知。固定支持集的微分与每步重新选 Top-K 的程序是不同对象，以下推导均冻结分区。

E.2 粗粒化、下界与不可识别性

设 $\mathcal{C}$ 为词表分区，定义 $P_C = \sum_{a\in C} P_a$、$Q_C = \sum_{a\in C} Q_a$、$\ell_C = \log(P_C/Q_C)$、$P_a^C = P_a/P_C$、$Q_a^C = Q_a/Q_C$。逐点有

$$\ell_a = \ell_C + \log(P_a^C/Q_a^C). \tag{E.2}$$

乘 P_a，先桶内求和再跨桶求和，得到

$$\mathrm{KL}(P\|Q) = K_{\mathcal{C}} + \sum_C P_C \,\mathrm{KL}(P^C\|Q^C), \qquad K_{\mathcal{C}} = \sum_C P_C \ell_C. \tag{E.3}$$

交换 P, Q 给出正向版本。细化分区时，新旧粗化 KL 的差为每个旧桶内细桶标签 KL 的加权和，故非负。全 singleton 分区恢复完整值。

在只知道 Q_C 的信息类上，$K_{\mathcal{C}}$ 是完整 KL 的锐下包络，由 $Q_a = Q_C P_a^C$ 唯一达到；两个方向同时成立。加入真实 Top-K 排名后该构造可能不可行。例如 $P = (0.1, 0.8, 0.1)$，已知 $Q_1 = 0.4, Q_2 + Q_3 = 0.6$ 且动作一是 Top-1；质量约束最优构造给 $Q_2 = 8/15 > 0.4$，违反排名。因此 Tail-aware 仍是下界，但不必是完整信息类上的锐下界。

相同头部信息也不控制逆向 KL 上界。固定 $P = (0.4, 0.2, 0.4)$ 与 $Q_\epsilon = (0.7, \epsilon, 0.3-\epsilon)$、$0 < \epsilon < 0.15$，Top-1 和尾部质量完全相同，而 $0.2\log(0.2/\epsilon) \to \infty$。该反例依赖至少两个仍未知的尾部坐标。

记 $\bar\psi_C = \nabla \log P_C = \mathbb{E}_{P^C}\psi$。对粗化目标求导：

$$\nabla K_{\mathcal{C}} = \sum_C (\ell_C + 1)\nabla P_C = \sum_C P_C \ell_C \bar\psi_C, \tag{E.4}$$

$$g - \nabla K_{\mathcal{C}} = \sum_C P_C\{\mathrm{Cov}_{P^C}(\ell - \ell_C, \psi) + \mathrm{KL}(P^C\|Q^C)\bar\psi_C\}. \tag{E.5}$$

最后一步对桶内乘积期望分解。标量误差只含条件 KL，梯度误差还依赖 score 相关性；标量下界改善不推出梯度偏差范数单调改善。

E.3 精确积分加残差抽样

定理 E.1 (统一估计与协方差)

设目标 $I_\nu(h)=\sum_a \nu_a h_a$，$h_a$ 可为向量。选择可精确积分的代理 b_a，令 $R_a=h_a-b_a$。若 $\nu_a\|R_a\|>0$ 时 $\beta_a>0$，则对 $A\sim\beta$，

$$\widehat{I}=I_\nu(b)+\frac{\nu_A}{\beta_A}R_A \tag{E.6}$$

无偏，且

$$\mathrm{Cov}(\widehat{I})=\sum_{\beta_a>0}\frac{\nu_a^2}{\beta_a}R_aR_a^\top-I_\nu(R)I_\nu(R)^\top. \tag{E.7}$$

♡

证明 随机修正的均值为 $\sum_{\beta_a>0}\nu_aR_a=I_\nu(R)$，支持条件使缺失动作贡献为零；与确定积分相加即得目标。随机项外积的期望为式 (E.7) 的求和项，减去均值外积得到协方差。取迹得到向量方差，无偏性使其等于均方误差。M 个条件独立样本的平均协方差除以 M。

若确定积分有误差 δ，使用错误权重 $\widetilde{w}$ 或缺失支持 $\mathcal{D}^c$，偏差恰为

$$\delta+\sum_{a\in\mathcal{D}}(\beta_a\widetilde{w}_a-\nu_a)R_a-\sum_{a\notin\mathcal{D}}\nu_aR_a. \tag{E.8}$$

这是对实际期望与目标直接相减的结果。精确覆盖的零残差动作可以没有采样支持；未知残差则不能由有限权重恢复。

固定代理时，迹方差最优提案为

$$\beta_a^\star=\frac{\nu_a\|R_a\|}{\sum_b\nu_b\|R_b\|},\quad V_{\min}=\left(\sum_a\nu_a\|R_a\|\right)^2-\|I_\nu(R)\|^2. \tag{E.9}$$

证明对 $\sum_a[\nu_a\|R_a\|/\sqrt{\beta_a}]\sqrt{\beta_a}$ 用 Cauchy–Schwarz；取比例提案时等号成立。全部残差为零时直接返回确定积分。这个 oracle 提案通常需要未知尾部值，不能仅凭公式称其可实现。

若有多个已知积分控制 h_j，令 $X=(\nu_A/\beta_A)h_A$、$U_j=(\nu_A/\beta_A)h_{j,A}-I_\nu(h_j)$、$\Gamma_{ij}=\mathbb{E}\langle U_i,U_j\rangle$、$d_j=\mathbb{E}\langle U_j,X-\mathbb{E}X\rangle$。估计器 $X-\sum_j c_jU_j$ 的方差为

$$V_0-2c^\top d+c^\top\Gamma c. \tag{E.10}$$

若 $z\in\ker\Gamma$，则 $\sum_j z_jU_j=0$ 几乎处处，所以 $z^\top d=0$。因此 $d\in\mathrm{range}\,\Gamma$，最优系数为 $\Gamma^\dagger d+\ker\Gamma$，超额方差为 $(c-\Gamma^\dagger d)^\top\Gamma(c-\Gamma^\dagger d)$。这最小化协方差迹，不一般同时最小化每个方向。

E.4 头尾估计器作为统一定理的实例

令 $\tau_P=P(S^c)$、$\tau_Q=Q(S^c)$、$J_A=\mathbf{1}\{A\notin S\}$，并定义

$$H=\sum_{a\in S}P_a\ell_a,\quad l=\log(\tau_P/\tau_Q),\quad B=\tau_P\,\mathrm{KL}(P^{\mathrm{tail}}\|Q^{\mathrm{tail}}). \tag{E.11}$$

则 $K=H+\tau_Pl+B$。Truncated 返回 H，偏差为 $-\tau_Pl-B$；Tail-aware 返回 $H+\tau_Pl$，偏差为 $-B$；Normalized 返回

$$K_{\mathrm{norm}}=H/P_S+\log(Q_S/P_S), \tag{E.12}$$

它是头部条件分布的 KL。后者改变积分权重，不能当成只删除尾部项。

在 $A\sim P$ 下，标量控制族

$$\widehat{K}(c)=H+\tau_Pc+J_A(\ell_A-c) \tag{E.13}$$

无偏。设 $\mu_\ell=\mathbb{E}_{P^{\mathrm{tail}}}\ell$、$V_\ell=\mathrm{Var}_{P^{\mathrm{tail}}}\ell$，全方差公式给出

$$\mathrm{Var}\,\widehat{K}(c)=\tau_PV_\ell+P_S\tau_P(\mu_\ell-c)^2. \tag{E.14}$$

头部精确、尾部采样（Head-Exact Tail-Sampled，HETS）取 $c=0$，桶残差修正取 $c=l$，oracle 取 $c=\mu_\ell$。残差修正优于 HETS 当且仅当 $|\mu_\ell - l| < |\mu_\ell|$。

对梯度令 $h_g = \sum_S P_a \ell_a \psi_a$、$\mu_g = \mathbb{E}_{P^{\text{tail}}}(\ell\psi)$、$\bar{\psi}_{\text{tail}} = \nabla \log \tau_P$、$b_{\text{TA}} = l\bar{\psi}_{\text{tail}}$。统一向量控制为

$$\widehat{g}(b) = h_g + \tau_P b + J_A(\ell_A \psi_A - b), \tag{E.15}$$

$$\operatorname{Cov} \widehat{g}(b) = \tau_P \operatorname{Cov}_{\text{tail}}(\ell\psi) + P_S \tau_P (\mu_g - b)(\mu_g - b)^\top. \tag{E.16}$$

HETS 为 $b=0$，ResOPD 为 $b=b_{\text{TA}}$。常向量只改变头尾事件间的均值差，不改变尾部内部协方差。

再加入尾部条件零均值方向 $\chi_a = l(\psi_a - \bar{\psi}_{\text{tail}})$，定义

$$\widehat{g}(b,\vartheta) = h_g + \tau_P b + J_A(\ell_A \psi_A - b - \vartheta \chi_A). \tag{E.17}$$

尾部内部与事件控制正交，因为 $\mathbb{E}_{\text{tail}}\chi = 0$。因此最优 $b=\mu_g$，最优 $\vartheta = D_\chi / V_\chi$，其中

$$V_\chi = \mathbb{E}_{\text{tail}}\|\chi\|^2, \qquad D_\chi = \mathbb{E}_{\text{tail}}\langle \ell\psi - \mu_g, \chi\rangle. \tag{E.18}$$

配方给出精确代价

$$V(b,\vartheta) - V_{\min} = P_S \tau_P \|b - \mu_g\|^2 + \tau_P V_\chi (\vartheta - D_\chi/V_\chi)^2. \tag{E.19}$$

$V_\chi = 0$ 时内部控制不起作用。SC-TA 对应 $b=b_{\text{TA}}, \vartheta = 1$；它比 ResOPD 方差小当且仅当 $2D_\chi > V_\chi$。

即使头部精确，方差也不必比直接抽样小。对任意 integrand u，令 $I = \mathbb{E}_P u$、$H_u = \sum_S P_a u_a$，直接展开二阶矩：

$$\operatorname{Var}(u_A) - \operatorname{Var}(H_u + J_A u_A) = \sum_S P_a \|u_a\|^2 - 2\langle I, H_u\rangle + \|H_u\|^2. \tag{E.20}$$

右侧可负。数值反例 $P = (0.18, 0.819, 0.001)$、$Q = (0.08, 0.67, 0.25)$、$S = \{2\}$（按一开始编号），直接 log-ratio 方差约为 0.088913，HETS 为 0.129131。真实 Rao–Blackwell 化应取条件期望 $\mathbb{E}_P[\ell \mid C] = \ell_C + \mathrm{KL}(P^C \| Q^C)$；只知道桶质量时缺少第二项。

E.5 提案变化、分层采样与正向 KL

从 β 采样时，所有残差改为 $J_A(P_A/\beta_A)(h_A - b)$。二阶矩权重是 P^2/β，所以原有 on-policy 最优控制通常改变。令

$$W = \sum_{S^c} P_a^2/\beta_a, \quad U = \sum_{S^c} (P_a^2/\beta_a) h_a, \quad T_h = \sum_{S^c} P_a h_a, \tag{E.21}$$

展开关于 b 的二次式，最优 $b = (U - \tau_P T_h)/(W - \tau_P^2)$。若 $W = \tau_P^2$，Cauchy–Schwarz 等号要求 $\beta = P^{\text{tail}}$，控制项逐样本抵消。此时直接尾部条件采样的方差为 $\tau_P^2 \operatorname{Var}_{\text{tail}}(h)/M$，不超过同样本数的 on-policy 头尾估计方差。

更一般，分区内独立采样 M_C 次，方差为 $\sum_C P_C^2 \sigma_C^2 / M_C$。固定连续预算 $\sum_C M_C = M$，Cauchy–Schwarz 给出最优分配 $M_C \propto P_C \sigma_C$；零方差桶直接返回常值，整数预算需另行取整。控制拟合与评估共用随机动作时，$\mathbb{E}U = 0$ 不保证 $\mathbb{E}[c(A)U] = 0$；应条件化于独立校准数据，或使用交叉拟合并保留折间相关性。

正向 KL 使用同一积分定理取 $\nu = Q, h = -\ell$ 或 $-\psi$。令 $H^{\text{F}} = -\sum_S Q_a \ell_a$，则

$$K^{\text{F}} = H^{\text{F}} - \tau_Q l + \tau_Q \,\mathrm{KL}(Q^{\text{tail}} \| P^{\text{tail}}), \tag{E.22}$$

无偏标量控制为 $H^{\text{F}} + \tau_Q c + J_A(Q_A/\beta_A)(-\ell_A - c)$。其支持要求覆盖未知的 Q 尾部。直接微分粗化正向 KL 得 $-\sum_C Q_C \bar{\psi}_C$，其中 $\bar{\psi}_C$ 仍是 P^C 下的 score 均值。

E.6 数值估计与反传的独立核验

令 $A \sim P$，$\ell = \ell_A$，并定义 $c_A = P_\theta(A)/\operatorname{stopgrad}(P_\theta(A))$。固定动作求导有

$$\nabla \phi(\ell) = \phi'(\ell)\psi, \qquad \nabla[c_A \phi(\ell)] = [\phi(\ell) + \phi'(\ell)]\psi. \tag{E.23}$$

第二式的期望由式 (A.7) 恰好恢复积分导数。数值与反传分类如下，均先讨论无截断的解析对象：

程序	前向值	固定样本反传
K1	ℓ	ψ
K2	$\ell^2/2$	$\ell\psi$
K3	$e^{-\ell}+\ell-1$	$(1-e^{-\ell})\psi$
K4：$c_A\,\mathrm{stopgrad}(\ell)$	ℓ	$\ell\psi$
live K4：$c_A\ell$	ℓ	$(\ell+1)\psi$
K3^{++}：$c_A(e^{-\ell}+\ell-1)$	$e^{-\ell}+\ell-1$	$\ell\psi$

K1、K3 的数值对逆向 KL 无偏，因为 $\mathbb{E}_P e^{-\ell}=1$；K2 一般有偏，其反传却是逆向 KL 的无偏 score 梯度。K3 的裸反传期望是 $-\mathbb{E}_Q\psi$，对应正向 KL。K4 与 K3^{++} 的逐样本反传相同，前向方差不同。Top-K 和相应 score 构造的外部背景见 EMA-PG[1]；这里按明确公式区分命名。

若需要正向 KL 的数值与 score 反传同时匹配，可取

$$K5=-\,\mathrm{stopgrad}(e^{-\ell})\ell+\log P_A-\mathrm{stopgrad}(\log P_A). \tag{E.24}$$

其前向为 $-e^{-\ell}\ell$，期望为 K^{F}；反传为 $(1-e^{-\ell})\psi$，期望为 g^{F}。正支持和实际采样测度是这些恒等式的必要条件。

确定性头部数值的真实导数也应保留概率权重项。令 $d_S=\nabla P_S$，则

$$\nabla H=h_g+d_S,\quad \nabla(H+\tau_P l)=h_g-ld_S,\quad \nabla K_{\mathrm{norm}}=\frac{h_g}{P_S}-\frac{H}{P_S^2}d_S. \tag{E.25}$$

最后一式对商 H/P_S 求导并与 $-\log P_S$ 的导数抵消得到，分母明确为标量 P_S^2。

头尾 score 常数必须匹配：$h_g+\upsilon d_S+J_A(\ell_A+\upsilon)\psi_A$ 对任意固定 υ 无偏，因为 $\mathbb{E}_P J_A\psi_A=-d_S$。只在头部或尾部保留一个常数项，会分别留下 $\pm d_S$ 偏差。

可以用 $\mathrm{stopgrad}(F)+L-\mathrm{stopgrad}(L)$ 让前向显示 F、反向使用 L 的导数；这不意味着前向的普通导数就是更新场。HETS 与 ResOPD 的固定样本势分别为

$$H-P_S+\tfrac{1}{2}J_A\ell_A^2,\qquad K_{\mathrm{TA}}+\tfrac{1}{2}J_A(\ell_A^2-l^2). \tag{E.26}$$

SC-TA 的场 $\nabla K_{\mathrm{TA}}+J_A(\ell_A-l)\nabla\ell_A$ 一般非保守，其交叉偏导差是

$$-J_A[(\partial_i l)\psi_j-(\partial_j l)\psi_i]. \tag{E.27}$$

取三动作 softmax、$S=\{1\},A=2$，$(i,j)=(1,2)$ 时该差为 $P_1P_3/(1-P_1)>0$。总体期望仍可为真实梯度，因为参数依赖采样测度的导数补上了额外项。

E.7 配分函数估计与可控展开

固定 q,f，$Z=\mathbb{E}_q e^f$。精确头部加尾部样本均值无偏估计 Z，但若 $\widehat{Z}>0$、$\mathbb{E}|\log\widehat{Z}|<\infty$，Jensen 给

$$\mathbb{E}\log\widehat{Z}\le\log Z, \tag{E.28}$$

非退化时严格。这个结论只针对 plug-in，不排除其他信息条件下无偏估计 $\log Z$。例如有限词表完全覆盖事件 E 的概率 $c>0$ 已知时，$\mathbf{1}_E\log Z/c$ 是无偏构造，方差为 $(c^{-1}-1)(\log Z)^2$，但通常成本很高。

对固定有限正分布，设 $\widehat{Z}_M$ 是有界独立尾部变量的均值加确定头部，且有与 M 无关的正下界。令 $\epsilon=\widehat{Z}_M-Z$，尾部单样本方差为 V。则

$$\mathbb{E}\epsilon=0,\quad \mathbb{E}\epsilon^2=V/M,\quad \mathbb{E}\epsilon^4=O(M^{-2}),\quad \mathbb{E}|\epsilon|^3=O(M^{-3/2}). \tag{E.29}$$

第四矩展开仅留下四索引相同和两两配对项，分别为 $O(M)$、$O(M^2)$，除以 M^4 得结论；第三绝对矩由 Cauchy–

[1] Lunjun Zhang and Jimmy Ba. *EMA Policy Gradient: Taming Reinforcement Learning for LLMs with EMA Anchor and Top-k KL*. 2026. arXiv: 2602.04417v1.

Schwarz 控制。log 的三阶导数在统一正区间有界，因此全区间 Taylor 余项满足 $|R_3| \le C|\epsilon|^3$。取期望得到

$$\mathbb{E}\log \widehat{Z}_M - \log Z = -\frac{V}{2MZ^2} + O(M^{-3/2}). \tag{E.30}$$

方差中线性项贡献 $V/(MZ^2)$，其与二次项的交叉由第三矩控制，二次项平方由第四矩控制，故 $\operatorname{Var}\log \widehat{Z}_M = V/(MZ^2) + O(M^{-3/2})$。

几何信号 $f = \eta r$ 时可改用累积量展开。令 $\varphi(t) = \log \mathbb{E}_q e^{tr}$，指数倾斜分布为 $q_t \propto q e^{tr}$。逐项微分得 $\varphi^{(j)}(t)$ 为 q_t 下第 j 阶累积量。有限阶 Taylor 公式给出

$$\varphi(\eta) = \sum_{j=1}^{L} \frac{\eta^j}{j!}\varphi^{(j)}(0) + \frac{\eta^{L+1}}{L!}\int_0^1 (1-u)^L \varphi^{(L+1)}(u\eta)\, du. \tag{E.31}$$

每阶累积量可按集合分拆 π 写成

$$\kappa_j(r) = \sum_{\pi \in \mathcal{P}_j} (|\pi|-1)!(-1)^{|\pi|-1} \prod_{B\in\pi} \mathbb{E} r^{|B|}. \tag{E.32}$$

用互异样本索引的乘积平均替代每个矩乘积，即得到无偏估计，要求样本数 $M \ge j$。独立性逐项保证均值正确。固定阶有界核的两项乘积只在索引交叠时可能有协方差，交叠概率为 $O(1/M)$，故方差及各阶协方差均为 $O(1/M)$。截断估计的偏差正是上式积分余项的负值；无限级数还需位于收敛半径内。

另一种展开从确定头部 $Z_H > 0$ 开始。令 $\tau = \mathbb{E}_q u$ 为尾部贡献，若 $\tau/Z_H < 1$，则

$$\log(Z_H + \tau) = \log Z_H + \sum_{j=1}^{L} \frac{(-1)^{j+1}}{j}(\tau/Z_H)^j + R_{L+1}, \quad |R_{L+1}| \le \frac{(\tau/Z_H)^{L+1}}{L+1}. \tag{E.33}$$

用互异索引乘积的 U-统计量无偏估计 τ^j，样本数 $M \ge L$，留下可控的确定截断偏差。尾部均值小不自动提供逐样本小上界，实际方差仍要由核的矩计算。

附录 F 条件中心与有限样本拟合

F.1 中心估计代入损失后的对象

固定前缀、锚点和候选参数，记 $h_a = U_a - f_a$、$R = C_q h$、$\psi_a = \nabla \log p_a$。BPO 梯度为 $\eta^{-1}\operatorname{Cov}_q(h,\psi)$。这里中心化是损失定义的一部分；用于 score 估计的额外 baseline 是另一个选择。

对 Mean，设 $\widehat{c}_f$ 与主动作 $A \sim q$ 独立，且其分布不依赖学生参数，$\mathbb{E}\widehat{c}_f = \mathbb{E}_q f$。平方展开给出

$$\mathbb{E}\left[\tfrac{1}{2}(U_A - f_A + \widehat{c}_f)^2\right] = L_{\text{Mean}} + \tfrac{1}{2}\operatorname{Var}(\widehat{c}_f). \tag{F.1}$$

独立零均值误差使交叉项消失，最后一项与学生无关，因此梯度无偏。只知道数值估计无偏而没有独立性时，不能做此抵消。

对 BPO，令主动作 A 和 M 个辅助动作 B_j 独立同分布于 q。记 $\bar{h}_B = M^{-1}\sum_j h_{B_j}$。独立性给出

$$\mathbb{E}(h_A - \bar{h}_B)^2 = (1 + M^{-1})\operatorname{Var}_q h. \tag{F.2}$$

因此 $\frac{M}{M+1}(h_A - \bar{h}_B)^2/(2\eta)$ 对损失和直接反传梯度均无偏。与 Mean 不同，辅助中心含有学生参数，额外方差项的导数不能丢掉。同前缀共 $M \geq 2$ 个动作的留一中心对应倍率 $(M-1)/M$。

F.2 无中心样本方差与 U-统计量

两个独立动作给出

$$L_{\text{BPO}} = \frac{1}{4\eta}\mathbb{E}_{a,b\sim q}(h_a - h_b)^2, \qquad \boldsymbol{G} = \nabla L_{\text{BPO}} = \mathbb{E}_{a,b}\frac{(h_a - h_b)(\psi_a - \psi_b)}{2\eta}. \tag{F.3}$$

逐项展开利用 $\mathbb{E}h_a h_b = (\mathbb{E}h)^2$ 即证。若 $p = \operatorname{softmax}(z)$，$h_a - h_b = z_a - z_b - \log(q_a/q_b) - (f_a - f_b)$，学生配分函数与两个条件中心全部消失。

对 $M \geq 2$ 个独立动作，定义

$$\widehat{L}_M = \frac{\sum_i (h_i - \bar{h})^2}{2\eta(M-1)}, \qquad \nabla\widehat{L}_M = \frac{\sum_i (h_i - \bar{h})\psi_i}{\eta(M-1)}. \tag{F.4}$$

恒等式 $\sum_{i<j}(h_i - h_j)^2 = M\sum_i (h_i - \bar{h})^2$ 使其等于成对核的 U-统计量平均。每一对的均值正确，故整体无偏；各对相互相关，不能把方差简单除以对数。

定理 F.1 (消去中心的精确方差代价)

令成对梯度核 $H(a,b) = (h_a - h_b)(\psi_a - \psi_b)/(2\eta)$ 的逐方差为 V_2。令精确双中心估计器

$$g_c(a) = \frac{(h_a - \mathbb{E}_q h)(\psi_a - \mathbb{E}_q \psi)}{\eta}, \qquad V_c = \operatorname{Var}_q g_c. \tag{F.5}$$

则

$$\operatorname{Var}(\nabla\widehat{L}_M) = \frac{(M-2)V_c + 2V_2}{M(M-1)}, \qquad \operatorname{Var}(\nabla\widehat{L}_M) - \frac{V_c}{M} = \frac{2V_2 - V_c}{M(M-1)} \geq 0. \tag{F.6}$$

♡

证明 对 b 条件积分，展开乘积得到 $\mathbb{E}_b H(a,b) = [g_c(a) + \boldsymbol{G}]/2$。令

$$H_1(a) = \mathbb{E}_b H(a,b) - \boldsymbol{G} = (g_c(a) - \boldsymbol{G})/2, \quad H_2(a,b) = H(a,b) - \boldsymbol{G} - H_1(a) - H_1(b). \tag{F.7}$$

有 $\mathbb{E}H_1 = 0$、$\mathbb{E}[H_2(a,b) \mid a] = \mathbb{E}[H_2(a,b) \mid b] = 0$。因此一阶项与二阶余项正交，两不同配对的二阶余项即使共用一个索引，其协方差也由条件零均值消失。单对核给出 $V_2 = 2\operatorname{Var} H_1 + \operatorname{Var} H_2 = V_c/2 + \operatorname{Var} H_2$。

样本平均核的中心化表达为

$$\frac{2}{M}\sum_i H_1(a_i) + \binom{M}{2}^{-1}\sum_{i<j} H_2(a_i, a_j). \tag{F.8}$$

第一项方差为 $4\operatorname{Var} H_1/M$，第二项为 $\operatorname{Var} H_2/\binom{M}{2}$，交叉项为零。代入 $\operatorname{Var} H_1 = V_c/4$ 与 $\operatorname{Var} H_2 = V_2 - V_c/2$ 并整理，即得公式及非负性。

命题 F.1 (排除重复动作的半正定改进)

先抽 $a \sim q$，再抽 $b \sim q(\cdot \mid b \neq a)$，使用加权核 $H_{\mathrm{nr}} = (1-q_a)H(a,b)$。则均值仍为 $\boldsymbol{G}$，且

$$\operatorname{Cov}_{q\otimes q} H - \operatorname{Cov}_{\mathrm{nr}} H_{\mathrm{nr}} = \mathbb{E}_{q\otimes q}[q_a H(a,b)H(a,b)^\top] \succeq 0. \tag{F.9}$$

证明 有序对概率为 $q_a q_b/(1-q_a)$，且 $H(a,a)=0$。乘以一个 $(1-q_a)$ 后求和恢复独立抽样均值；外积含两个权重，故二阶矩变为 $\mathbb{E}_{q\otimes q}[(1-q_a)HH^\top]$。两个均值相同，协方差之差等于二阶矩之差，每项均为非负权重的外积。正支持且至少二动作保证 $1-q_a>0$。

若两个独立动作来自另一个提案 β，成对损失需乘 $(q_a/\beta_a)(q_b/\beta_b)$。先对单动作 residual 乘权重再平方，会产生错误的权重平方。

F.3 教师中心的有符号与非负估计

记 $\rho = T/q$、$A = A_{\kappa,\eta}$、$\phi(\rho) = \rho - 1 - A(\rho)$。两个无偏估计为

$$\widehat{K}_- = -M^{-1}\sum_i A(\rho_i), \qquad \widehat{K}_+ = M^{-1}\sum_i \phi(\rho_i), \qquad a_i \overset{\text{iid}}{\sim} q. \tag{F.10}$$

ϕ 凸且在一处值与导数为零，所以第二个逐样本非负。第一种方差为 $V_{\kappa,\eta}/M$。非负不保证更小方差：取 $q = (\epsilon, 1-\epsilon)$、$T = (1/2, 1/2)$，固定正 $\kappa, \eta < 1$。稀有项的 $A = O(\log(1/\epsilon))$，有符号估计方差趋零；$\phi \sim 1/(2\epsilon)$，非负估计方差按 $1/(4\epsilon)$ 发散。

局部情况不同。若 $\rho = 1 + \epsilon u$、$\mathbb{E}_q u = 0$ 且 u 有界，令 $c_0 = 1 - \kappa(1-\eta)$，则

$$-A = -\epsilon u + \tfrac{1}{2}c_0\epsilon^2 u^2 + O(\epsilon^3), \qquad \phi = \tfrac{1}{2}c_0\epsilon^2 u^2 + O(\epsilon^3). \tag{F.11}$$

两种方差分别为 $\epsilon^2\mathbb{E}_q u^2 + O(\epsilon^3)$ 与 $\frac{1}{4}c_0^2\epsilon^4 \operatorname{Var}_q u^2 + O(\epsilon^5)$。这需要比率一致接近一，不能只用 KL 小替代。

同动作估计中心尤其需要核对：若用该动作的 ϕ 补到 A 上，逐样本有 $A + \phi = \rho - 1$，形状变换被完全抵消。若用同一组 M 个样本减去经验均值，

$$\mathbb{E}\left[M^{-1}\sum_i (A_i - \bar{A})\psi_i\right] = \frac{M-1}{M}\operatorname{Cov}_q(A,\psi). \tag{F.12}$$

展开双重和，同索引项 M 个、异索引项 $M(M-1)$ 个，即得到该系数；$M=1$ 时更新为零。

固定前缀的精确中心化不改变标量条件方差。跨冻结前缀测度 d，记 $V_s = \operatorname{Var}_{q(\cdot\mid s)} A_s$，则全方差公式给出 $\operatorname{Var}_{d,q} A = \mathbb{E}_d V_s + \operatorname{Var}_d K_T(s)$，而 $\operatorname{Var}_{d,q}(A + K_T) = \mathbb{E}_d V_s$。中心化移除不同前缀的均值差异；这不直接推出乘以 score 后的参数梯度方差排序。

F.4 有界包络与头尾区间

当 $\kappa > 0, \eta < 1$，$c = -\log(1-\eta)/(\kappa\eta) > 1$，且 $0 \le \phi(x) \le x + c - 1$。定义

$$\mu_c = (1 - 1/c)q + T/c, \qquad Z(a) = q_a\phi(\rho_a)/\mu_c(a). \tag{F.13}$$

则 $\mathbb{E}_{\mu_c} Z = K_T$、$0 \le Z \le c$。由于 $Z^2 \le cZ$，

$$\operatorname{Var}_{\mu_c} Z \le K_T(c - K_T) \le c^2/4. \tag{F.14}$$

独立平均 M 次后方差除以 M，Hoeffding 给 $\Pr(|\widehat{K} - K_T| \ge \epsilon) \le 2e^{-2M\epsilon^2/c^2}$。整个分布类上 K_T 可逼近 c，所以任何无偏估计器的统一样本上界不能低于 c。

一般混合 $\mu_\zeta = (1-\zeta)q + \zeta T$ 的逐样本上确界为

$$C_\zeta = \max\{(c-1)/(1-\zeta), 1/\zeta\}. \tag{F.15}$$

两个值分别由 $\rho \to 0, \infty$ 逼近。使统一范围最小的唯一权重是 $\zeta = 1/c$。固定输入的方差则为 $\mathbb{E}_q[\phi(\rho)^2/(1+\zeta(\rho-1))] - K_T^2$，二阶导数为

$$2\mathbb{E}_q \frac{\phi(\rho)^2(\rho-1)^2}{[1+\zeta(\rho-1)]^3} \geq 0. \tag{F.16}$$

所以输入方差最优权重可经一维凸优化得到，但一般不同于最小统一范围权重。

保留头部 S，尾部质量为 $\delta = q(S^c)$、$\tau = T(S^c)$。令 $K_S^T = -\sum_S q_a A(\rho_a)$。尾部条件均值 $\mathbb{E}_{q^{\text{tail}}}\rho = \tau/\delta$，由 $-A$ 凸以及 $-A \leq c$，

$$K_S^T - \delta A(\tau/\delta) \leq K_T \leq K_S^T + \delta c. \tag{F.17}$$

扩大嵌套头部时，下界由 Jensen 非减，上界每加入动作减少 $q_a[c + A(\rho_a)] \geq 0$，故非增。尾部为空时直接取精确头部值，不计算零质量比。

还能构造始终落在区间内的无偏估计。令 $r_0 = \tau/\delta$、$H = \sum_S q\phi$，

$$L = H + \delta\phi(r_0), \quad U = H + \tau + (c-1)\delta, \quad w = U - L. \tag{F.18}$$

取凸余项 $g(x) = \phi(x) - \phi(r_0) - \phi'(r_0)(x - r_0)$，令 $u = A'(r_0) > 0$、$v = c + A(r_0) - r_0 u \geq 0$。$v \geq 0$ 来自凹函数 A 的切线在零处不低于 $A(0) = -c$。于是 $0 \leq g(x) \leq ux + v$，且

$$\sum_{S^c} q_a g(\rho_a) = K_T - L, \quad u\tau + v\delta = w. \tag{F.19}$$

若 $w > 0$，在尾部取 $\nu_a = (uT_a + vq_a)/w$、$Y = q_a g(\rho_a)/\nu_a$，则 $0 \leq Y \leq w$。因此

$$\widehat{K} = L + M^{-1}\sum_i Y_i, \quad \mathbb{E}\widehat{K} = K_T, \quad L \leq \widehat{K} \leq U, \quad \operatorname{Var}\widehat{K} \leq (K_T - L)(U - K_T)/M. \tag{F.20}$$

证明分别由期望相消和 $Y^2 \leq wY$ 得到。$w = 0$ 时直接返回 L。该方案要求能从条件尾部分布采样并查询抽中动作概率；只有头部和尾部总质量时不能恢复未知尾部形状。

F.5 中心误差、baseline 与更新场

设学生、教师中心误差分别为 $e_S = \widehat{K}_S - K_S$、$e_T = \widehat{K}_T - K_T$。原始 score 形式的梯度误差为

$$\widehat{g} - g = (e_S/\eta - e_T)\mathbb{E}_q\psi. \tag{F.21}$$

在 $p = q$ 时该均值为零，一般内层不为零。若中心与主动作相关，需保留 $\mathbb{E}[e(A)\psi_A]$，不能把误差提出期望。

若学生中心精确、教师误差为冻结常数 e_T，直接微分平方损失时，残差变为 $R - \eta e_T$。由于 $\mathbb{E}_q R = 0$，损失仅增加 $\eta e_T^2/2$，梯度不变；对应的 score 应为 $(R/\eta - e_T)(\psi - \mathbb{E}_q\psi)$。在目标点 $p = m$，其采样噪声为

$$e_T^2 \mathbb{E}_q\|\psi - \mathbb{E}_q\psi\|^2. \tag{F.22}$$

完整求和精确抵消该噪声，单动作抽样则保留。用学生反馈 $y = C_q U/\eta - A$ 估计同一个教师中心时，$\mathbb{E}_q y = K_T$ 且 $\operatorname{Var}_q y = 2L_{\text{BPO}}/\eta$，噪声可随拟合消失。

若 e_S 随参数变化，式 (F.21) 的场含 $-(e_S/\eta - e_T)\nabla K_S$。其反对称 Jacobian 一般不为零，因为 ∇e_S 与 ∇K_S 未必平行。直接微分含近似中心的平方损失则多出 $\mathbb{E}_q \widehat{R}\nabla\widehat{K}_S/\eta$，得到另一个保守场。有限中心近似后，两种反传方式需要分别定义。

在锚点 $p = q$，action-independent baseline b 不改变 $\mathbb{E}_q[(A - b)\psi]$ 的均值。最小迹方差的选择为

$$b_\star = \frac{\mathbb{E}_q[A\|\psi\|^2]}{\mathbb{E}_q\|\psi\|^2}, \quad V_g(b) - V_g(b_\star) = \mathbb{E}_q\|\psi\|^2(b - b_\star)^2. \tag{F.23}$$

这是对加权二次式配方的结果，不一般等于 $\mathbb{E}_q A$。重要性采样估计器改用权重 $(p/q)^2\|\psi_p\|^2$。对普通 BPO 的 q 测度，离开锚点后随意改 baseline 会改变均值，除非保留补偿或使用精确中心化 score。

独立随机 baseline 额外增加其方差乘以相应 score 二阶矩。同样本 baseline 即使数值无偏也可能有偏：取 baseline 等于该动作的信号，整个更新逐样本为零。跨前缀 token 不能替代同前缀独立辅助动作。

附录 G 外层动力学、扰动与序列边界

G.1 幂均值的 escort 轨迹

对 $\kappa>0$，定义 $S_\kappa(q)=\sum_a q_a^\kappa$ 和 escort 分布 $E_\kappa(q)_a=q_a^\kappa/S_\kappa(q)$。它的逆为 $q_a\propto E_\kappa(q)_a^{1/\kappa}$。对幂均值目标取 κ 次幂，公共归一化消去，得

$$E_\kappa(m)=(1-b)E_\kappa(q)+bE_\kappa(T),\quad b=\frac{\eta S_\kappa(T)}{(1-\eta)S_\kappa(q)+\eta S_\kappa(T)}. \tag{G.1}$$

因此固定教师的精确轨迹在 escort 坐标中位于同一条直线：

$$E_\kappa(q_n)-E_\kappa(T)=\prod_{j<n}(1-b_j)[E_\kappa(q_0)-E_\kappa(T)]. \tag{G.2}$$

词表大小为 V，Jensen 给 $S_\kappa(q)\le V^{1-\kappa}$。令

$$c=\frac{(1-\eta)V^{1-\kappa}}{(1-\eta)V^{1-\kappa}+\eta S_\kappa(T)}<1. \tag{G.3}$$

定义距离

$$d_\kappa(q,T)=\|E_\kappa(q)-E_\kappa(T)\|_1. \tag{G.4}$$

精确更新满足 $d_\kappa(q_{n+1},T)\le c\,d_\kappa(q_n,T)$。设近似输出的误差满足

$$d_\kappa(q_{n+1},m(q_n,T))\le\epsilon_n. \tag{G.5}$$

三角不等式给

$$d_\kappa(q_n,T)\le c^n d_\kappa(q_0,T)+\sum_{j<n}c^{n-1-j}\epsilon_j. \tag{G.6}$$

若 $\limsup\epsilon_n\le\epsilon_\infty$，拆开有限前缀与充分晚的尾和，得到 $\limsup d_\kappa(q_n,T)\le\epsilon_\infty/(1-c)$。这是到固定教师的定向收缩，不声称两任意锚点间有相同收缩常数。

连续流也有同一轨迹。令 $a_\kappa=\mathbb{E}_q(T/q)^\kappa$，由 $\dot q_a=q_a[(T_a/q_a)^\kappa-a_\kappa]/\kappa$ 得

$$\frac{d}{dt}q_a^\kappa=T_a^\kappa-a_\kappa q_a^\kappa,\qquad \frac{d}{dt}E_\kappa(q)=\frac{S_\kappa(T)}{S_\kappa(q)}[E_\kappa(T)-E_\kappa(q)]. \tag{G.7}$$

重新定义时间 $d\sigma/dt=S_\kappa(T)/S_\kappa(q)>0$，轨迹即为指数趋近教师的直线。$\kappa\downarrow0$ 时 escort 本身趋均匀，需要重标度：

$$\frac{V}{\kappa}\left(E_\kappa(q)_a-\frac1V\right)\longrightarrow\log q_a-\frac1V\sum_b\log q_b. \tag{G.8}$$

G.2 几何端点的完整稳定区间

这一节允许 $\eta>0$，但只讨论 $\kappa=0$ 的几何更新及后面相应的 Mean 更新。正形状的概率插值仍取 $0<\eta<1$。

固定正教师 T，令 $q^+\propto q^{1-\eta}T^\eta$。归一化常数在动作差中消失，所以

$$d_H(q^+,T)=|1-\eta|d_H(q,T),\qquad d_H(q^+,\widetilde{q}^+)=|1-\eta|d_H(q,\widetilde{q}). \tag{G.9}$$

对变步长，记 $\chi_k=\prod_{j<k}(1-\eta_j)$、$u=\log(q_0/T)$，归纳得到

$$q_k(a)=\frac{T_a e^{\chi_k u_a}}{\sum_b T_b e^{\chi_k u_b}}. \tag{G.10}$$

归纳步骤中上一轮的配分函数仅产生公共乘数，归一化后消去。非教师初值下，收敛当且仅当 $\chi_k\to0$。常步长 $0<\eta<2$ 收敛，$\eta=1$ 一步到教师，$\eta=2$ 为两周期，$\eta>2$ 的跨度发散。

若所有 $\eta_k\in(0,2)$ 且没有一步等于一，令 $a_k=|1-\eta_k|\in(0,1)$。乘积趋零当且仅当 $\sum_k(1-a_k)=\infty$：一边由 $-\log a\ge1-a$，另一边在 a 接近一时由 $-\log a\le2(1-a)$ 得到。再用 $1-a_k\le1-a_k^2\le2(1-a_k)$，得到

等价判据 $\sum_k \eta_k(2-\eta_k)=\infty$。

定义 $\Psi(\chi)=\log\sum_a T_a e^{\chi u_a}$。有限求和微分给 $\Psi'=\mathbb{E}_{q^{[\chi]}}u$、$\Psi''=\mathrm{Var}_{q^{[\chi]}}u$。于是

$$\mathrm{KL}(q^{[\chi]}\|T)=\chi\Psi'(\chi)-\Psi(\chi)=\int_0^\chi s\Psi''(s)\,ds, \tag{G.11}$$

$$\mathrm{KL}(T\|q^{[\chi]})=\Psi(\chi)-\chi\Psi'(0)=\int_0^\chi(\chi-s)\Psi''(s)\,ds. \tag{G.12}$$

正、负半轴上两种 KL 各自随离零距离增加而增加，但跨越两侧的值不能仅由 $|\chi|$ 比较。教师附近有 KL 比例极限 $(1-\eta)^2$；全局只有绝对界 $\mathrm{KL}(q_k\|T)\le\chi_k^2(\operatorname{osc}u)^2/8$，由 $\Psi''\le(\operatorname{osc}u)^2/4$ 积分得到。

直接展开更新方程还得到

$$\eta\,\mathrm{KL}(q\|T)=\eta\,\mathrm{KL}(q^+\|T)+(1-\eta)\,\mathrm{KL}(q^+\|q)+\mathrm{KL}(q\|q^+). \tag{G.13}$$

当 $0<\eta\le1$ 时，这给单步 KL 下降及 $\sum_k\mathrm{KL}(q_k\|q_{k+1})\le\eta\,\mathrm{KL}(q_0\|T)$。$\eta>1$ 时不能把跨度稳定性换成每步 KL 下降。例如 $q=(10^{-12},1-10^{-12})$、$T=(0.1,0.9)$、$\eta=1.1$，逆向 KL 从约 0.10536 增至 0.71385。

G.3 Mean 的单轮界与精确外层

本节取 $r=\log(T/q)$、$d=\mathrm{KL}(q\|T)$、$G=\eta(r+d)$。Mean 的 KKT 为

$$\log w_a+\lambda w_a=\eta(r_a+d),\quad w_a=p_a^{\mathrm{M}}/q_a,\quad \mathbb{E}_q w=1,\quad \lambda=\mathrm{KL}(q\|p^{\mathrm{M}}). \tag{G.14}$$

令 $X=e^G$、$A_1=\mathbb{E}_qX$、$A_2=\mathbb{E}_qX^2$。由 $\lambda=\mathbb{E}_qW_0(\lambda X)$，$W_0$ 的凹性给 $\lambda\le\log A_1$。其凹性可由 $W_0'(x)=e^{-W_0(x)}/(1+W_0(x))$ 再求导看出。

下界使用 $W_0(z)\ge z/(1+z)$：写 $z=we^w$，等价于 $(1-w)e^w\le1$；该函数在 $w\ge0$ 非增。Cauchy–Schwarz 再给

$$\lambda\ge\mathbb{E}_q\frac{\lambda X}{1+\lambda X}\ge\frac{\lambda A_1^2}{A_1+\lambda A_2},\qquad \frac{A_1(A_1-1)}{A_2}\le\lambda\le\log A_1. \tag{G.15}$$

非恒定信号时 $\lambda>0$ 可以约去；恒定信号两边为零。代入 $A_1=e^{\eta d}Z_\eta, A_2=e^{2\eta d}Z_{2\eta}$，得到原稿的 Rényi 归一化界，其中 $Z_\nu=\sum q^{1-\nu}T^\nu$。

Mean 最大化式 (C.12)，将它与可行点 q 比较，再除以 η，得到

$$\mathrm{KL}(p^{\mathrm{M}}\|T)\le d-(\eta^{-1}-1)\,\mathrm{KL}(p^{\mathrm{M}}\|q)-\frac{\lambda}{2\eta}\chi^2(p^{\mathrm{M}}\|q). \tag{G.16}$$

当 $0<\eta\le1, q\ne T$，最后一项严格为正，所以教师 KL 严格下降。

定理 G.1 (Mean 的跨度稳定性)

固定正教师和正初值，逐轮精确 Mean 求解并同步。$0<\eta\le2$ 时跨度严格下降到零；$0<\eta<2$ 时

$$b_{k+1}\le C_\eta(b_k)b_k,\quad C_\eta(b)=\max\{1-\eta/(1+\eta b),\eta-1\}<1 \tag{G.17}$$

对 $b>0$ 成立。$\eta>2$ 时教师局部不稳定。 ♡

证明 在一轮中固定 λ,d，把 w 看成 r 的函数。隐式求导给 $d\log w/dr=\eta/(1+\lambda w)$。因此相对教师的新 log-ratio $v(r)=\log w(r)-r$ 满足

$$v'(r)=-1+\eta/(1+\lambda w(r)). \tag{G.18}$$

非教师状态 $\lambda>0$，当 $\eta\le2$ 时 $-1<v'<1$。在有限 reward 区间上连续，故均值定理给严格跨度收缩。为得到显式系数，归一化保证 $w_{\max}\ge1$；最大 reward 处 KKT 给

$$\lambda w_{\max}=\eta(r_{\max}+d)-\log w_{\max}\le\eta(r_{\max}-r_{\min})=\eta b. \tag{G.19}$$

所以导数落在 $[-1+\eta/(1+\eta b),\eta-1)$，绝对值由 $C_\eta(b)$ 控制。该系数随 b 非减，故 $\eta<2$ 时由初始跨度给出统一几何界。

在 $\eta=2$，显式系数只有一。跨度有界蕴含 $T_ae^{-b_0}\le q_a\le T_ae^{b_0}$，迭代位于正单纯形内的紧集。归一化根严

格单调且连续，教师附近 $\lambda \le \log \mathbb{E}_q e^G \to 0$，故更新也连续。若跨度极限 $b_\infty > 0$，该紧集上远离教师的更新跨度差处处正且连续，有统一正下界，与跨度收敛矛盾。故极限为零。最后，下节线性化为 $(1-\eta)y$，$\eta > 2$ 时其模大于一，局部不稳定。

G.4 Mean 的三次项与边界率

定义教师中心坐标 $y = C_T \log(q/T)$, $q = Te^y/\mathbb{E}_T e^y$, $V = \mathbb{E}_T y^2$、$\delta = \|y\|_\infty$。固定正教师使 $T_{\min}\delta^2 \le V \le \delta^2$。Taylor 展开给

$$\log \mathbb{E}_T e^y = V/2 + O(\delta^3), \quad \mathbb{E}_q y = V + O(\delta^3), \quad d = V/2 + O(\delta^3). \tag{G.20}$$

此时 $G = \eta(-y + \mathbb{E}_q y)$。归一化方程

$$\Phi(\lambda, y) = \mathbb{E}_q \exp[G - W_0(\lambda e^G)] - 1 = 0 \tag{G.21}$$

在原点对 λ 的导数为 -1，隐函数定理给解析根。展开 $W_0(z) = z + O(z^2)$,

$$0 = \mathbb{E}_q e^G - 1 - \lambda \mathbb{E}_q e^{2G} + O(\lambda^2), \qquad \mathbb{E}_q e^G - 1 = \eta^2 V/2 + O(\delta^3). \tag{G.22}$$

因 $\mathbb{E}_q e^{2G}$ 在邻域内远离零，先得 $\lambda = O(\delta^2)$，再得 $\lambda = \eta^2 V/2 + O(\delta^3)$。

将 KKT 输出按教师中心化：

$$y^+ = (1-\eta)y - C_T W_0(\lambda e^G), \tag{G.23}$$

$$C_T W_0(\lambda e^G) = \lambda C_T e^G + O(\delta^4) = -\eta\lambda y + O(\delta^4). \tag{G.24}$$

故

$$y^+ = (1-\eta)y + \frac{\eta^3}{2} V y + O(\delta^4). \tag{G.25}$$

$\eta = 1$ 时 $V^+ = V^3/4 + O(V^{7/2})$，两次使用 $\mathrm{KL}(q\|T) = V/2 + O(V^{3/2})$，得到 $\mathrm{KL}(p^{\mathrm{M}}\|T)/\mathrm{KL}(q\|T)^3 \to 1$。

还可给出全局三次跨度上界。$\eta = 1$ 时 $\lambda \le d$、$w_{\max} \le e^b$。令 $F(t) = \log \mathbb{E}_q e^{t(r - \mathbb{E}_q r)}$，有 $F(0) = F'(0) = 0$、$F''(t) \le b^2/4$；两次积分得 $d = F(1) \le b^2/8$。因此

$$b^+ \le \frac{\lambda w_{\max}}{1 + \lambda w_{\max}} b \le \frac{e^b b^2}{8 + e^b b^2} b. \tag{G.26}$$

在 $\eta = 2$，式 (G.25) 给 $V^+ = V - 8V^2 + O(V^{5/2})$。若不在有限步精确到达教师，则 $V_k > 0$ 且由全局稳定性 $V_k \to 0$,

$$V_{k+1}^{-1} - V_k^{-1} = 8 + O(\sqrt{V_k}) \to 8. \tag{G.27}$$

累加并除以轮数得 $kV_k \to 1/8$，进而 $k\,\mathrm{KL}(q_k\|T) \to 1/16$。几何更新在相同步长是两周期，Mean 的三次阻尼改变了边界行为。

固定锚点令 $\eta \to \infty$ 时，Mean 还有不同于 Gibbs 的极限。令 $h = C_q r$、$c = \mathbb{E}_q[h]_+ > 0$，则 $\lambda/\eta \to c$、$p_a^{\mathrm{M}} \to q_a[h_a]_+/c$。证明如下：最大 $h_a = M > 0$ 处 KKT 与 $p_a/q_a \le 1/q_a$ 给 $\lambda \ge q_a \eta M - q_a \log(1/q_a)$；上界 $\lambda \le \log \mathbb{E}_q e^{\eta h} \le \eta M$。所以 λ/η 有严格正常数界。沿任一收敛子列，$W_0(\lambda e^{\eta h_a})/\eta \to [h_a]_+$，正、零、负三种情形分别使用 $W + \log W = \log\lambda + \eta h_a$、$W_0(\lambda) = O(\log\eta)$、$W_0(z) \le z$。有限求和归一化强制子列极限为 c，从而整个序列收敛。Gibbs 则只保留最高 reward 动作；两个极限不能互换。

G.5 有限 inner 的误差接口

由式 (C.13)，Mean 超额损失 δ 控制 $\mathbb{E}_q \log^2(p/p^{\mathrm{M}}) \le 2\delta$；Part 超额损失正好等于该平方项（目标换成 m）。若 $q_a \ge q_{\min}$，附录 A 给

$$d_H(p, p^\star) \le 2\sqrt{\delta/q_{\min}}, \qquad d_H(p, m) \le 2\sqrt{\eta L_{\mathrm{BPO}}/q_{\min}}. \tag{G.28}$$

MDPO 给 $\mathrm{KL}(p\|m)=\eta\delta$ 和 TV 界，但没有统一 log-ratio 界。取 $m=(1-\epsilon,\epsilon)$、$p=(1-\epsilon^2,\epsilon^2)$，KL 趋零，第二坐标的 log-ratio 为 $\log\epsilon\to-\infty$。

直接检查教师逆向 KL 时，记 $\varepsilon=\mathrm{KL}(p\|m)$、$\ell=\log(m/T)$、$H=\operatorname{osc}\ell$。恒等式

$$\mathrm{KL}(p\|T)=\varepsilon+\mathrm{KL}(m\|T)+\sum_a(p_a-m_a)\ell_a \tag{G.29}$$

配合区间中点和 Pinsker，得到上界 $\mathrm{KL}(m\|T)+\varepsilon+H\sqrt{\varepsilon/2}$。另一种按概率加权的证书是：对 $u>0$，取 $r_u\propto m^{1+u}T^{-u}$，展开 $\mathrm{KL}(p\|r_u)\ge 0$ 得

$$\mathrm{KL}(p\|T)\le(1+1/u)\,\mathrm{KL}(p\|m)+D^{\mathrm{R}}_{1+u}(m\|T). \tag{G.30}$$

可在多个 u 上取最小值；这里只用其精确有限 u 形式作为保证。

梯度范数界还需额外条件才能连接到这些输出证书。若随机梯度条件无偏、方差不超过 σ^2/M，且损失 L_{sm} 光滑，SGD 步长 $\alpha\le 1/L_{\mathrm{sm}}$ 满足

$$\frac{1}{N}\sum_{n<N}\mathbb{E}\|\nabla L(\theta_n)\|^2\le\frac{2(L_0-L_\star)}{\alpha N}+\frac{L_{\mathrm{sm}}\alpha\sigma^2}{M}. \tag{G.31}$$

证明由光滑性、$\mathbb{E}\|g\|^2=\|\nabla L\|^2+\operatorname{Var}g$，每步下降至少 $\alpha\|\nabla L\|^2/2$，再求和。此式本身不控制超额损失或分布距离。

复用数据还会破坏条件无偏前提。例如单个零均值样本 X，样本梯度 $\theta-X$ 在固定 θ 时无偏。从零更新得 $\theta_1=\alpha X$ 后，

$$\mathbb{E}[\theta_1-X\mid\theta_1]=(1-\alpha^{-1})\theta_1\ne\theta_1. \tag{G.32}$$

因此独立动作的估计恒等式不能直接用于数据依赖的反复更新参数。平均前缀误差也不等于逐前缀误差；若另有 $d(s)\ge d_{\min}>0$ 才能由 $\mathbb{E}_d\delta_s\le\bar\delta$ 得 $\delta_s\le\bar\delta/d_{\min}$。

G.6 输出扰动、噪声与同步

几何端点的近似输出写为 $q_{k+1}\propto q_k^{1-\eta_k}T_k^{\eta_k}e^{e_k}$。取相对 T_{k+1} 的对数并用跨度三角不等式：

$$b_{k+1}\le|1-\eta_k|b_k+\operatorname{osc}e_k+d_H(T_k,T_{k+1}). \tag{G.33}$$

固定 $0<\eta<2$ 时，误差按系数 $c=|1-\eta|$ 作几何卷积；有界扰动上限 B 给稳态界 $B/(1-c)$，趋零扰动给收敛。对 Mean 的 $0<\eta\le1$，若输出逐坐标 log 误差不超过 ϵ_k，则

$$b_{k+1}\le b_k-\frac{\eta b_k}{1+\eta b_k}+2\epsilon_k. \tag{G.34}$$

当 $\epsilon_k\le\bar\epsilon<1/2$，映射 $F(b)=b-\eta b/(1+\eta b)+2\bar\epsilon$ 递增，不动点为 $b_\infty=2\bar\epsilon/[\eta(1-2\bar\epsilon)]$。从 $\max(b_0,b_\infty)$ 起的比较递推单调降到 b_∞，给出不变跨度与稳态上界。

固定教师，定义 $y_k=C_T\log(q_k/T)$、$\xi_k=C_Te_k$，几何更新精确满足

$$y_{k+1}=(1-\eta)y_k+\xi_k. \tag{G.35}$$

若 y_0 确定，ξ_k 关于历史为鞅差且条件协方差为确定矩阵 Σ_k，不同时间交叉项由塔式期望为零，所以

$$\mathrm{Cov}(y_K)=\sum_{j<K}(1-\eta)^{2(K-1-j)}\Sigma_j. \tag{G.36}$$

常协方差时极限为 $\Sigma/[\eta(2-\eta)]$。固定均值误差 μ 给均值极限 μ/η。只有在另有小噪声高阶矩控制时，才能用局部 KL 展开转换成

$$\mathbb{E}\,\mathrm{KL}(q_\infty\|T)=\frac{\mu^\top\operatorname{diag}(T)\mu}{2\eta^2}+\frac{\operatorname{tr}(\operatorname{diag}(T)\Sigma)}{2\eta(2-\eta)}+O(\epsilon^3), \tag{G.37}$$

其中例如高斯误差的均值与标准差同时按 ϵ 缩小即可。若注入的是 reward 误差，输出噪声多乘 η，协方差多乘 η^2；不能混用两种步长依赖。

概率 soft sync 定义为 $q^+=(1-\zeta)q+\zeta p_{\mathrm{out}}$。在教师附近，几何、幂均值与 Mean 的一阶输出均为 $T+(1-$

$\eta)(q-T)$，因此中心坐标变为 $(1-\zeta\eta)y+O(\|y\|^2)$。$0<\zeta\eta<2$ 给局部稳定，边界需高阶分析。参数 EMA 通常不是这个概率混合。

若理想外层收缩因子为 c、内层输出误差 $\le C\rho_{\text{in}}^{N_k}$，希望输出误差 $\le B\rho_{\text{out}}^{k}$，充分条件是

$$N_k \ge \max\left\{0, \frac{\log(C/B)+k\log(1/\rho_{\text{out}})}{\log(1/\rho_{\text{in}})}\right\}. \tag{G.38}$$

内层指数率必须先有独立依据。Mean 在 $\eta=1$ 的三次局部率需要输出跨度误差 $O(b_k^3)$；若使用损失证书，则充分要求超额损失为 $O(q_{\min,k}b_k^6)$。

G.7 共享参数的自然梯度投影

固定有限前缀及正权重 d_s，令 $B=\partial q_\theta/\partial\theta$、$W=\operatorname{diag}(d_s/q_{\theta,sa})$、$\mathcal{I}=B^\top WB$。逐前缀自由负自然梯度为 v，有 $\nabla_\theta L=-B^\top Wv$。参数自然梯度流诱导

$$\dot q = B\mathcal{I}^\dagger B^\top Wv = Pv. \tag{G.39}$$

令 $C=W^{1/2}B$，则 $W^{1/2}PW^{-1/2}=C(C^\top C)^\dagger C^\top$ 是欧氏正交投影。因此 $\|\dot q\|_W\le\|v\|_W$、$\dot L=-\|Pv\|_W^2\le 0$。平方根自由速度不超过二，投影后也不超过二；这控制分布的 Fisher 速度，不控制参数欧氏速度。还可能 $Pv=0$ 而 $q_\theta\neq T$，故不保证消除表示误差。

G.8 条件更新与完整序列

固定长度序列分布 $Q(y)=\prod_t q(y_t\mid y_{<t})$，教师序列分布为 T。链式法则给

$$\mathrm{KL}(Q\|\mathsf{T})=\sum_t \mathbb{E}_{s_t\sim Q}\,\mathrm{KL}(q(\cdot\mid s_t)\|T(\cdot\mid s_t)). \tag{G.40}$$

更新条件策略同时改变访问权重。一个两步反例取根节点 $q_0=(0.99,0.01), T_0=(0.01,0.99)$；分支 A 中二者均为 $(1/2,1/2)$；分支 B 中 $q_B=(1-10^{-6},10^{-6})$、$T_B=(10^{-30},1-10^{-30})$。对全部条件分布同时做 $\eta=0.1$ 的精确更新，条件双向 KL 均不增加，但序列逆向 KL 由约 5.19399 变为 6.07445（几何）、7.09792（平方根）或 10.44581（算术）。学生进入高误差分支的概率上升。

完整序列的算术混合 $\mathsf{M}=(1-\eta)Q+\eta\mathsf{T}$ 的条件权重为

$$\eta_s=\frac{\eta\mathsf{T}(s)}{(1-\eta)Q(s)+\eta\mathsf{T}(s)}. \tag{G.41}$$

所以它一般不同于每个前缀使用固定 η 的条件混合。序列几何混合也含后缀配分因子：

$$\mathsf{M}(a\mid s)=q(a\mid s)^{1-\eta}T(a\mid s)^\eta\frac{Z_\eta(sa)}{Z_\eta(s)},\quad Z_\eta(s)=\sum_z Q(z\mid s)^{1-\eta}\mathsf{T}(z\mid s)^\eta. \tag{G.42}$$

直接对序列 KL 求导，先用 $\nabla\log Q=\sum_t\psi_t$，再用条件 score 均值为零消去过去成本，得到

$$\nabla\,\mathrm{KL}(Q\|\mathsf{T})=\mathbb{E}_Q\sum_t\psi_t\sum_{j\ge t}\log\frac{q(a_j\mid s_j)}{T(a_j\mid s_j)}. \tag{G.43}$$

记后缀值 $V^q(s)=\mathrm{KL}(Q(\cdot\mid s)\|\mathsf{T}(\cdot\mid s))$，即时负梯度信号应含 $\log(T(a\mid s)/q(a\mid s))-V^q(sa)$。固定测度的条件目标只保留即时项。若将幂均值问题直接定义在完整有限序列空间，前面的分布定理仍成立，但目标表达、采样和投影成本是另一问题。

附录 H TOP-D 目标教师的退化与性质

H.1 参数对应与精确可达性

本附录比较 TOP-D 的目标教师及相关分布性质，依据其 v1 第 3.1 节、定理 4.2、4.4 和附录 C.1、C.2[1]。固定同一前缀，TOP-D 的教师混合权重记为 α，教师为 T，构造混合时的学生记为 q。本文对应关系是

$$\boxed{\kappa = 1, \qquad \eta = \alpha, \qquad m_{1,\eta} = (1-\eta)q + \eta T.} \tag{H.1}$$

这在目标分布上是精确等式，无需小步近似，也无需对两分布接近作假设。两者必须作用于同一个条件分布空间。

目标教师由正文的算术端点最优化问题产生：

$$m_{1,\eta} = \arg\min_{p \in \Delta} \{(1-\eta)\,\mathrm{KL}(q\|p) + \eta\,\mathrm{KL}(T\|p)\}. \tag{H.2}$$

其概率梯度为 $-[(1-\eta)q_a + \eta T_a]/p_a$。约束乘子使 p_a 与分子成比例；分子总和已经为一，所以 $p = m$。完整误差恒等式是

$$F(p) - F(m) = \mathrm{KL}(m\|p). \tag{H.3}$$

因此原问题的最优分布与 TOP-D 目标教师完全重合。

在本文三个精确拟合目标中，MDPO、Part、BPO 都能在完整可实现条件下到达该分布。Mean 一般仍有 Lambert-W 目标偏离。可达性指总体最优分布；有限参数更新是否到达，应由拟合误差证书判断。

H.2 监督信号、中心与教师目标

算术端点的配分函数恒为一，故

$$f_{1,\eta} = \log(m/q) = \log(1 - \eta + \eta T/q), \qquad A_{1,\eta} = f_{1,\eta}/\eta, \qquad K_T = \mathrm{KL}(q\|m)/\eta. \tag{H.4}$$

第一项恢复 TOP-D 式（5）的未缩放信号。第二项是本文内层归一化使用的信号，比较方差时需保留 $1/\eta^2$。

本文由逆向积分定义的教师目标在此端点为

$$J_{1,\eta}(p;T) = \frac{(1-\eta)\,\mathrm{KL}(p\|M_p) + \eta\,\mathrm{KL}(T\|M_p)}{\eta(1-\eta)}, \qquad M_p = (1-\eta)p + \eta T. \tag{H.5}$$

推导已在附录 B 给出。这里 M_p 随候选学生 p 变化，用于定义同一个教师目标；本轮目标 $m = M_q$ 在内层冻结。对 J 在 q 处执行步长 η 的负熵镜像下降，恰好得到算术目标。这是本文对该目标教师的变分解释，不把它与其他同名目标混用。

H.3 覆盖与散度收缩

由算术混合逐坐标有 $m_a \geq (1-\eta)q_a$、$m_a \geq \eta T_a$，因此

$$f_{1,\eta} \geq \log(1-\eta), \quad \mathrm{KL}(q\|m) \leq -\log(1-\eta), \quad \mathrm{KL}(T\|m) \leq -\log\eta. \tag{H.6}$$

前者控制教师极小概率造成的负监督尾部，后两者控制到两端分布的覆盖代价。

对于精确更新，

$$m - T = (1-\eta)(q-T), \qquad \|m-T\|_1 = (1-\eta)\|q-T\|_1. \tag{H.7}$$

---

[1] Zhengpeng Xie et al. *Trust Region Policy Distillation*. 目标教师见第 3.1 节；方差与收缩见定理 4.2、4.4 及附录 C.1、C.2. 2026. arXiv: 2607.04751v1.

反复精确更新的闭式为 $q_k = T + (1-\eta)^k(q_0 - T)$。所以原文定理 4.4 所用的算术收缩结构在这个条件分布空间直接恢复。

命题 H.1 (算术端点的凸散度收缩)

对任意凸函数 φ、$\varphi(1) = 0$，

$$D_\varphi(m\|T) \le (1-\eta) D_\varphi(q\|T). \tag{H.8}$$

证明 逐坐标有 $m_a/T_a = (1-\eta)q_a/T_a + \eta$。凸性给

$$\varphi(m_a/T_a) \le (1-\eta)\varphi(q_a/T_a) + \eta\varphi(1). \tag{H.9}$$

乘以 T_a 并求和，第二项为零。取 $\varphi(x) = x\log x$、$-\log x$、$(\sqrt{x}-1)^2$、$|x-1|/2$，分别得到两个 KL 方向、平方 Hellinger 和 TV 的界。

式 (H.8) 是算术映射自身的凸性结论。一般幂均值保留所有凸生成散度的非增性，但不自动具有同一个 $(1-\eta)$ 全局因子；平方根点的 Hellinger 因子由它的球面结构另行给出。

H.4 有限拟合的误差累积

令 $\epsilon_k = \|q_{k+1} - m(q_k, T)\|_1$。三角不等式给

$$\|q_{k+1} - T\|_1 \le (1-\eta)\|q_k - T\|_1 + \epsilon_k. \tag{H.10}$$

归纳展开：

$$\|q_K - T\|_1 \le (1-\eta)^K \|q_0 - T\|_1 + \sum_{k=0}^{K-1} (1-\eta)^{K-1-k}\epsilon_k. \tag{H.11}$$

若 $\limsup \epsilon_k \le \epsilon_\infty$，对任意 $\delta > 0$ 取足够晚的 k_0 使 $\epsilon_k \le \epsilon_\infty + \delta$。有限前缀和趋零，后段几何和不超过 $(\epsilon_\infty + \delta)/\eta$。令 $\delta \downarrow 0$，得到 $\limsup \|q_K - T\|_1 \le \epsilon_\infty/\eta$。这恢复原文误差累积与稳态上界的形式。

固定前缀测度下可以逐条件取平均，再用同一个线性递推。如果用 MDPO 的超额损失 δ_k，Pinsker 给 $\epsilon_k \le \sqrt{2\eta\delta_k}$；若用 BPO，则先应用附录 G 的跨度证书。本文在这里补上的是不同 inner loss 到外层输出误差的接口。

H.5 方差定理的尺度对应

TOP-D 定理 4.2 在有限词表和 score 范数不超过 S 的条件下，给未缩放信号的梯度方差上界

$$S^2|\mathcal{V}|\max\{\log^2(1-\eta), C_\star\eta\}. \tag{H.12}$$

在同一条件下，利用概率归一化可以得到无词表大小因子的界。对 $f = \log(1-\eta+\eta\rho)$，将 $\rho < 1$ 与 $\rho \ge 1$ 分开：

$$\mathbb{E}_q[f^2\mathbf{1}_{\rho<1}] \le \log^2(1-\eta), \tag{H.13}$$

$$\mathbb{E}_q[f^2\mathbf{1}_{\rho\ge1}] \le C_\star\eta\mathbb{E}_q[\rho\mathbf{1}_{\rho\ge1}] \le C_\star\eta. \tag{H.14}$$

其中 $C_\star = \sup_{u>0}\log^2(1+u)/u$，和原文单变量上界使用同一个常数。因此

$$\mathrm{Var}_q(f\psi) \le S^2[\log^2(1-\eta) + C_\star\eta]. \tag{H.15}$$

这个推导控制条件单动作梯度；前缀加权后只要使用同一 score 上界，二阶矩界仍成立。

未缩放信号的最坏二阶矩在 $\eta \downarrow 0$ 时为 $\Theta(\eta)$。上界由前式，下界取 $q_1 = \eta/2, T_1 = 1/2$，稀有动作 $f_1 = \log(2-\eta)$，贡献至少 $\eta\log^2(2-\eta)/2$。对二元分布，中心化方差 $q_1q_2(f_1-f_2)^2$ 也有同阶，因为另一项 $f_2 = O(\eta)$。

所以本文标准化监督满足

$$\sup_{q,T}\mathrm{Var}_q A_{1,\eta} = \Theta(\eta^{-1}). \tag{H.16}$$

这与未缩放信号随小 η 衰减相容：两者相差 η^2。它也说明算术端点虽有固定强度方差界，却不属于统一小步标准化方差有界的 $0 < \kappa \le 1/2$ 区间。

H.6 比较结论的作用范围

对象	精确对应或进一步性质
目标教师	$\kappa = 1, \eta = \alpha$ 时完全一致，$Z = 1$
未缩放信号	$f = \log(1 - \eta + \eta T/q)$ 完全一致
最优化来源	加权正向 KL 重心，超额损失为 $\mathrm{KL}(m\|p)$
教师目标解释	本文的 $J_{1,\eta}$ 是归一化加权 JS，其熵镜像步等于混合教师
精确与近似外层	算术 L_1 收缩、几何误差累积、ϵ_∞/η 稳态界
其他教师散度	凸性给任意凸生成散度的 $(1 - \eta)$ 上界
监督方差	未缩放 f 与标准化 $A = f/\eta$ 分开比较

上述比较针对相同的条件分布空间。若直接在完整序列空间定义算术混合，同一代数也成立；逐 token 固定权重混合一般不等于完整序列混合，不能把两个空间的距离直接认作同一指标。这里保留目标教师与定理层面的对应。

来源对应与复现

本稿对五组本地理论来源按数学依赖重新组织。外部散度、PMD-Mean 和 TOP-D 资料在对应位置引用；本地来源保留原文件，以便追溯定义及历史语境。同一命题在多个版本中出现时，本稿只维护一个完整证明。

随源文件提供的 `source-map.csv` 记录原文件、命题位置、源文件校验和及新稿主题归属。主题合并可能是多对一关系；对应表用于追溯材料，不将重复版本计为独立理论结果。原文没有命题环境的推导另以文件条目登记。

来源目录	主要材料	新稿归属
`alpha-divergence/`	密度比矩、散度端点、score 梯度、几何重加权测度	附录 A、B、D；统一教师记号与 Hellinger 常数
`book/`	重心、J、四种 inner、信息访问、估计、动力学与边界	正文及附录 A–H 的主要数学来源
`book-old/`	Mean 修订、KL 控制族、几何与 Mean 的同步推导	附录 C、E、F、G；保留历史差异的数学内容
`Notes/`	整合证明、成对 BPO、无重复动作、方差与误差连接	附录 B、D、F、G，特别是 U-统计量完整分解
`paper/`	参数化叙事、曲率、受限投影与有限步论证	正文结构及附录 C、D；精确展开曲率与驻点证明

来源中的纯实验配置、旧生产模块路径与任务成绩保留在原材料中。本稿的反例和验证针对所写数学对象。来源名相同不表示统计口径相同：头部可能由教师或锚点选出，条件动作采样可能来自当前学生或旧锚点，必须按本稿每条定理的条件代入。

一些跨主题内容的归属为：多教师重心与通用单调信号在附录 B；独立拟合形状、共享参数投影和标量谱调度在 C、G；最坏矩、相对噪声和绝对噪声准则在 D；配分函数、自动微分与非保守场在 E、F；教师漂移、同步及序列反例在 G。幂散度梯度中的几何重加权分布 $p(T/p)^{\kappa}$ 与本轮幂均值目标 $m_{\kappa,\eta}$ 是不同对象，前者用于积分测度解释，后者由重心问题定义。

数学核验的范围

数值核验采用有限词表的确定性求和，对照解析恒等式、自动微分和独立的概率公式。重点包括重心超额损失、J 的梯度与 JS 端点、四种 inner 的梯度和 Hessian、成对估计的协方差、形状端点、TOP-D 算术收缩以及条件与序列的反例。测试入口为 `tests/reference/test_core_monograph.py`。

2026 年 10 月 15 日的 CPU 核验中，该入口的 46 个参数化测试全部通过；仓库全套测试为 316 项通过。积分目标采用 96 点 Gauss–Legendre 求积与解析梯度对照，主要恒等式容差为 10^{-11} 或 10^{-12}。U-统计量使用三动作词表、$M = 2, 3, 4$ 的全部有序样本组合；无重复抽样直接比较协方差矩阵，检查半正定差值。局部三次率采用逐渐接近教师的固定方向，不以有限差分噪声替代极限系数。运行环境与命令保存于 `validation.json`。

数值测试用于暴露符号、尺度和实现错误；有限实例通过不构成定理证明。理论正文中的结论以相应解析证明和显式条件为依据。测试结果不用于声称共享参数大模型的训练收敛或任务准确率。

在仓库根执行 `make theory-core` 构建完整稿和正文阅读版；在本目录执行 `make` 等价。构建复用相邻 `../book/elegantbook.cls`，使用 XeLaTeX、latexmk 与 Biber。正文阅读版由同一主源通过条件装配生成，附录引用保留完整稿的编号。

参考文献

[1] Shun-ichi Amari. “Integration of Stochastic Models by Minimizing Alpha-Divergence”. In: *Neural Computation* 19.10 (2007), pp. 2780–2796. DOI: 10.1162/neco.2007.19.10.2780.

[2] Andrzej Cichocki and Shun-ichi Amari. “Families of Alpha- Beta- and Gamma- Divergences: Flexible and Robust Measures of Similarities”. In: *Entropy* 12.6 (2010), pp. 1532–1568. DOI: 10.3390/e12061532.

[3] Zhengpeng Xie et al. *Trust Region Policy Distillation*. 目标教师见第 3.1 节；方差与收缩见定理 4.2、4.4 及附录 C.1、C.2. 2026. arXiv: 2607.04751v1.

[4] Zhenghao Xu et al. *Approximation of Log-Partition Function in Policy Mirror Descent Induces Implicit Regularization for LLM Post-Training*. 2026. arXiv: 2602.05933v1.

[5] Lunjun Zhang and Jimmy Ba. *EMA Policy Gradient: Taming Reinforcement Learning for LLMs with EMA Anchor and Top-k KL*. 2026. arXiv: 2602.04417v1.